

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

Draf Laporan Tugas Akhir

Oleh

Bryan P. Hutagalung
18222130



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juli 2026

LEMBAR PENGESAHAN

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

Draf Laporan Tugas Akhir

Oleh

**Bryan P. Hutagalung
18222130**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 11 Juli 2026

Pembimbing

Achmad Imam Kistijantoro, S.T, M.Sc., Ph.D.

NIP. 197308092006041001

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 11 Juli 2026

Bryan P. Hutagalung

NIM: 18222130

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Claude	Tinggi	Semua bab
2	Pembuatan teks	Tidak ada	Tidak ada	Tidak ada
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	Claude	Sangat tinggi	Bab 1 - Bab 5
5	Penyusunan bahan diskusi	Claude	Sangat tinggi	Semua bab
6	Penyusunan kode program	Claude	Sedang	Bab 5 dan Lampiran B
7	Penyusunan formula atau perhitungan matematis	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan konsep desain atau algoritma	Claude	Rendah	Bab 4
9	Penyusunan analisis data	Tidak ada	Tidak ada	Tidak ada
10	Penyusunan kesimpulan atau rekomendasi	Tidak ada	Tidak ada	Tidak ada

Bandung, 11 Juli 2026

Bryan P. Hutagalung

NIM: 18222130

ABSTRAK

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

oleh

Bryan P. Hutagalung

18222130

Pengembangan model *machine learning* ke tahap produksi masih menghadapi fragmentasi *tool* dan pemisahan kerja antara tim data dan tim model. Praktik DataOps memperkuat kualitas dan kecepatan alur data, sementara MLOps memperkuat keandalan *model lifecycle*, namun keduanya sering tumbuh terpisah sehingga *lineage*, deteksi *drift*, dan *feature serving* antara mode *batch* dan *streaming* tidak konsisten lintas siklus. Berlangganan layanan terkelola memangkas konfigurasi tetapi biaya berjalannya tinggi. Penelitian ini mengembangkan arsitektur platform yang mengintegrasikan DataOps dan MLOps pada Kubernetes dengan komponen *open source*, sehingga satu *control plane* menyatukan sembilan *layer* arsitektur, yaitu *orchestration and infrastructure*, *data ingestion and processing*, *data storage*, *feature service*, *model lifecycle*, *data governance*, *observability*, *GitOps and continuous delivery*, serta *platform security*. Metode *Design Science Research Methodology* (DSRM) mencakup identifikasi masalah, penyusunan tujuan artefak, perancangan, implementasi berbasis GitOps, serta uji coba dengan *use case* pasar aset kripto sebagai kasus verifikasi karena beroperasi tanpa henti. Arsitektur menempatkan Kubernetes sebagai bidang orkestrasi, Apache Kafka dan Apache Flink untuk *streaming*, Apache Spark untuk *batch processing*, Feast sebagai *feature store* ganda dengan ClickHouse *offline*, Valkey *online*, dan Qdrant sebagai indeks vektor, MLflow dan Kubeflow untuk *model lifecycle*, KServe untuk *model serving*, serta DataHub untuk katalog dan *lineage*. Deteksi *drift* berbasis *Population Stability Index* dan Kolmogorov-Smirnov memicu *retraining* otomatis melalui Argo CronWorkflow, sementara *point-in-time correctness* dijaga Feast pada fase *training* dan *online serving*. Argo CD menyatukan GitOps untuk reproduksibilitas *deployment* dari satu sumber Git, sedangkan Prometheus, Grafana, OpenTelemetry, Loki, serta Grafana Tempo melengkapi observabilitas metrik, log, dan *trace*. Hasil evaluasi menunjukkan keempat tujuan platform terpenuhi secara fungsional dan struktural pada lingkungan *node* tunggal, dengan tujuan keempat pada tingkat struktural, mencakup rekonstruksi seluruh komponen dari satu sumber Git, tata kelola otomatis sepanjang *pipeline*, pemicuan *retraining* oleh deteksi *drift*, dan layanan fitur *dual-store* dengan kontrak konsisten antara *training* dan *inference*. Perbandingan biaya tiga skenario *hosting* menunjukkan arsitektur *open source* menekan biaya berjalan jangka panjang dibanding layanan terkelola. Karakterisasi beban kuantitatif pada kluster multi-*node* menjadi arah pengembangan lanjutan sesuai batasan penelitian.

Kata kunci: DataOps, MLOps, Kubernetes, Feature Store, Drift Detection, GitOps,

Open Source.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia-Nya, penulis dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul “Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*”. Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Penulis menyadari bahwa Tugas Akhir ini tidak akan selesai tanpa bantuan dan dukungan dari banyak pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Tuhan Yang Maha Esa atas rahmat dan penyertaan-Nya sepanjang proses pengerjaan Tugas Akhir.
2. Bapak Ir. I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D. selaku Ketua Program Studi Sistem dan Teknologi Informasi sekaligus dosen wali penulis.
3. Tim Tugas Akhir Program Studi Sistem dan Teknologi Informasi atas koordinasi dan kelancaran selama pelaksanaan Tugas Akhir.
4. Bapak Achmad Imam Kistijantoro, S.T, M.Sc., Ph.D. selaku dosen pembimbing atas arahan, masukan, dan diskusi selama pengerjaan Tugas Akhir.
5. Orang tua penulis, papa dan mama, atas doa dan dukungan yang tidak pernah putus.
6. Pasangan penulis, Tamara, atas kesabaran, dukungan, dan motivasi yang terus menerus selama proses penulisan Tugas Akhir.
7. Teman-teman penulis, yaitu Nangorians (Yusril, Timothy, Ardra, Jojo, Andhika, Natha, Panji, Jebe), S2 DS (Tamara, Yovanka), Lakara (Anin, Lina, Angie, Jendra, Zaki, Tamara, Shazya, Scifo, Dama, Maulvi, Marcell, dan seluruh anggota Ring 2), Vishvanava, Panitia Perayaan Wisokto HMIF ITB 2024 (Hira, Tamara, Attara, Erwan, Andhika, Jeremy, Angie, Juan), Sarenda Adikara, Bermakna (Nahda, Tarisha, SPP, Tamara, Aziz, Fadhil, Arfa, Akram, Sam, dan seluruh anggota Ring 12), GARAKA, dan BYTE atas kebersamaan dan dukungannya.

Penulis menyadari bahwa laporan ini masih memiliki kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang. Semoga laporan ini bermanfaat bagi pembaca dan pengembangan platform DataOps dan MLOps di lingkungan akademik maupun industri.

Bandung, 11 Juli 2026
Penulis

Bryan P. Hutagalung

DAFTAR ISI

LEMBAR PENGESAHAN	i
PERNYATAAN ORISINALITAS	ii
PERNYATAAN PENGGUNAAN AI	iii
ABSTRAK	iv
KATA PENGANTAR	vi
DAFTAR ISI	ix
DAFTAR GAMBAR	xiii
DAFTAR TABEL	xv
DAFTAR <i>LISTING</i>	xvii
DAFTAR SIMBOL	xix
DAFTAR SINGKATAN	xxi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	3
I.4 Batasan Masalah	5
I.5 Metodologi	5
I.6 Sistematika Penulisan	7
II STUDI LITERATUR	9
II.1 DataOps dan MLOps	9
II.1.1 DataOps	9
II.1.2 MLOps	10
II.1.3 Tingkat Kematangan MLOps dan DataOps	11
II.1.4 Integrasi DataOps dan MLOps	19
II.2 Kubernetes dan Orkestrasi <i>Cloud-Native</i>	20
II.2.1 Peran, Objek Dasar, dan Distribusi	20
II.2.2 Penskalaan Otomatis dan Ekosistem <i>Operator</i>	21
II.3 Manajemen Data: <i>Ingestion, Processing, dan Storage</i>	22
II.3.1 Pola Lambda dan Kappa	22
II.3.2 <i>Message Broker</i> dan <i>Data Ingestion</i>	23
II.3.3 <i>Stream Processing</i>	24
II.3.4 <i>Batch Processing</i> dan Transformasi SQL	24
II.3.5 Format Tabel <i>Lakehouse</i>	25
II.3.6 Penyimpanan Objek dan Versi Data	25
II.3.7 Penyimpanan Relasional dan Pencarian	26
II.4 Layanan Fitur (<i>Feature Store</i>)	27
II.4.1 Peran <i>Feature Store</i> sebagai Penyatu Fitur	27
II.4.2 Penyimpanan <i>Offline</i> dan <i>Online</i>	27
II.4.3 Pencarian Vektor dan HNSW	28
II.4.4 <i>Point-in-Time Correctness</i>	29
II.5 <i>Model Lifecycle</i>	29

II.5.1	Eksperimen dan <i>Tracking</i>	29
II.5.2	Orkestrasi Pelatihan	30
II.5.3	Eksperimen Interaktif dan <i>Tuning</i>	31
II.5.4	<i>Model Serving</i>	31
II.6	Tata Kelola Data: Katalog, <i>Lineage</i> , dan Kualitas	32
II.6.1	Katalog Metadata dan <i>Lineage</i>	32
II.6.2	Kontrak dan Pengujian Kualitas Data	33
II.7	Deteksi <i>Drift</i>	33
II.7.1	Jenis <i>Drift</i> dan Metrik Statistik	33
II.7.2	Deteksi Terjadwal dan Pemicu <i>Retraining</i>	34
II.8	Observabilitas <i>Cloud-Native</i>	35
II.8.1	Metrik, Log, dan <i>Trace</i>	35
II.8.2	Kebutuhan Turunan dan Antarmuka Analitik	35
II.9	GitOps dan <i>Continuous Delivery</i>	36
II.9.1	Rekonsiliasi Deklaratif dan Integrasi Berkelanjutan	36
II.9.2	<i>Deployment</i> Progresif	37
II.10	Keamanan Platform: Identitas, Rahasia, <i>Mesh</i> , dan Kebijakan	37
II.10.1	Identitas dan Pengelolaan Rahasia	38
II.10.2	<i>Service Mesh</i> , <i>API Gateway</i> , dan Penegakan Kebijakan	38
II.11	Penelitian Terkait	39
III	ANALISIS MASALAH	41
III.1	Analisis Kondisi Saat Ini	41
III.1.1	Beban Konfigurasi Platform dari Nol	41
III.1.2	Biaya Berlangganan Layanan Terkelola	42
III.1.3	Efek Domino Fragmentasi Lintas Peran	43
III.2	Analisis Kebutuhan	44
III.2.1	Identifikasi Masalah Pengguna	45
III.2.2	Kebutuhan Fungsional	46
III.2.3	Kebutuhan Nonfungsional	49
III.3	Analisis Pemilihan Solusi	53
III.3.1	Alternatif Solusi	53
III.3.2	Analisis Penentuan Solusi	55
III.3.3	Posisi terhadap Penelitian Terkait	56
IV	PERANCANGAN ARSITEKTUR PLATFORM DATAOPS DAN MLOPS	65
IV.1	Gambaran Umum Platform	65
IV.2	Analisis Layanan DataOps dan MLOps pada Praktik Industri	67
IV.2.1	Layanan pada Praktik MLOps dan DataOps	67
IV.2.2	Klasifikasi Sembilan <i>Layer</i> Platform	69
IV.3	Analisis Pemilihan <i>Open Source Tools</i>	72
IV.3.1	<i>Orchestration and Infrastructure Layer</i>	72
IV.3.2	<i>Data Ingestion and Processing Layer</i>	74
IV.3.3	<i>Data Storage Layer</i>	76
IV.3.4	<i>Feature Service Layer</i>	78
IV.3.5	<i>Model Lifecycle Layer</i>	80

IV.3.6	<i>Data Governance Layer</i>	82
IV.3.7	<i>Observability Layer</i>	83
IV.3.8	<i>GitOps and Continuous Delivery Layer</i>	85
IV.3.9	<i>Platform Security Layer</i>	86
IV.4	Perancangan Arsitektur Terintegrasi	89
IV.4.1	<i>Orchestration and Infrastructure Layer</i>	90
IV.4.2	<i>Data Ingestion and Processing Layer</i>	91
IV.4.3	<i>Data Storage Layer</i>	92
IV.4.4	<i>Feature Service Layer</i>	93
IV.4.5	<i>Model Lifecycle Layer</i>	93
IV.4.6	<i>Data Governance Layer</i>	94
IV.4.7	<i>Observability Layer</i>	95
IV.4.8	<i>GitOps and Continuous Delivery Layer</i>	96
IV.4.9	<i>Platform Security Layer</i>	96
IV.5	Perancangan Sub-sistem Tata Kelola Data	97
IV.5.1	Katalog Metadata dan <i>Lineage</i>	98
IV.5.2	Kontrak Data dan Kualitas	98
IV.5.3	Identitas dan Kontrol Akses	99
IV.6	Perancangan Sub-sistem Deteksi <i>Drift</i> dan <i>Continuous Training</i>	100
IV.6.1	Pengukuran <i>Drift</i>	100
IV.6.2	Alur <i>Retraining</i> Otomatis	100
IV.6.3	Mekanisme Penanganan Kasus Khusus	101
IV.7	Perancangan Sub-sistem Layanan Fitur <i>Dual-Store</i>	102
IV.7.1	Penyimpanan <i>Offline</i> dan <i>Online</i>	102
IV.7.2	Dukungan <i>Vector Embeddings</i> dan HNSW	103
IV.7.3	Jaminan <i>Point-in-Time Correctness</i>	103
IV.7.4	Aliran Materialisasi Fitur	104
IV.8	Alur Kerja <i>End-to-End</i>	105

V	IMPLEMENTASI ARSITEKTUR PLATFORM DATAOPS DAN MLOPS	107
V.1	Lingkungan Implementasi	107
V.1.1	Batasan Implementasi	108
V.1.2	Konfigurasi Dasar <i>Cluster</i>	109
V.1.3	Manajemen Rahasia dan Identitas	109
V.1.4	Pola GitOps	110
V.2	Implementasi Arsitektur Terintegrasi	110
V.2.1	<i>Data Ingestion and Processing Layer</i>	111
V.2.2	<i>Data Storage Layer</i>	112
V.2.3	<i>Model Lifecycle Layer</i>	113
V.2.4	<i>Observability Layer</i>	113
V.3	Implementasi Sub-sistem Tata Kelola Data	114
V.3.1	Katalog Metadata dan <i>Lineage</i>	114
V.3.2	Kontrak Data dan Kualitas	115
V.3.3	Kontrol Akses	115
V.4	Implementasi Sub-sistem Deteksi <i>Drift</i> dan <i>Continuous Training</i>	116

V.4.1	Detektor <i>Drift</i>	116
V.4.2	<i>Retraining Control Loop</i>	117
V.4.3	Penanganan Kasus Khusus	117
V.5	Implementasi Sub-sistem Layanan Fitur <i>Dual-Store</i>	118
V.5.1	Konfigurasi Feast	118
V.5.2	Dukungan <i>Vector Embeddings</i>	119
V.5.3	Materialisasi dan <i>Point-in-Time Correctness</i>	119
V.6	Verifikasi Implementasi	120
V.6.1	Lingkup Verifikasi	121
V.6.2	Pengamatan Hasil Awal	122
VI	EVALUASI	123
VI.1	Metode Evaluasi	123
VI.1.1	Kasus Verifikasi dan Lingkungan Uji	124
VI.1.2	Evaluasi Tujuan T-1: Arsitektur Terintegrasi dan GitOps	126
VI.1.3	Evaluasi Tujuan T-2: Tata Kelola Data	127
VI.1.4	Evaluasi Tujuan T-3: Deteksi <i>Drift</i> dan <i>Retraining</i>	128
VI.1.5	Evaluasi Tujuan T-4: Layanan Fitur <i>Dual-Store</i>	128
VI.1.6	Matriks Cakupan dan Uji Penerimaan	129
VI.2	Hasil Evaluasi	132
VI.3	Perbandingan Biaya Infrastruktur dan Tenaga Kerja	137
VI.4	Pembahasan Hasil Evaluasi	141
VII	PENUTUP	143
VII.1	Kesimpulan	143
VII.2	Saran	144
Lampiran A	PARAMETER PENILAIAN KRITERIA EVALUASI AL-	
	TERNATIF	163
A.1	Kriteria Lintas Tabel	163
A.2	Kriteria Spesifik per <i>Layer</i>	164
Lampiran B	KATALOG PERINTAH VERIFIKASI USE CASE	169
B.1	Tujuan T-1: Arsitektur Terintegrasi dan GitOps	169
B.2	Tujuan T-2: Tata Kelola Data	171
B.3	Tujuan T-3: Deteksi <i>Drift</i> dan <i>Retraining</i>	171
B.4	Tujuan T-4: Layanan Fitur <i>Dual-Store</i>	172

DAFTAR GAMBAR

II.1	<i>Big data analytics pipeline</i> pada studi kasus Ericsson	10
II.2	MLOps <i>level 0</i> : proses manual	11
II.3	MLOps <i>level 1</i> : otomasi <i>training pipeline</i>	12
II.4	MLOps <i>level 2</i> : orkestrasi CI/CD/CT	12
II.5	Model evolusi DataOps lima tahap	16
III.1	Alur data terfragmentasi pada kondisi saat ini	44
III.2	Alur model terfragmentasi pada kondisi saat ini	44
IV.1	Arsitektur layanan terintegrasi tanpa keterikatan alat	71
IV.2	Rincian <i>Orchestration and Infrastructure Layer</i>	91
IV.3	Rincian <i>Data Ingestion and Processing Layer</i>	92
IV.4	Rincian <i>Data Storage Layer</i>	92
IV.5	Rincian <i>Feature Service Layer</i>	93
IV.6	Rincian <i>Model Lifecycle Layer</i>	94
IV.7	Rincian bagian <i>model serving</i>	95
IV.8	Rincian <i>Data Governance Layer</i>	95
IV.9	Rincian <i>Observability Layer</i>	96
IV.10	Rincian <i>GitOps and Continuous Delivery Layer</i>	97
IV.11	Rincian <i>Platform Security Layer</i>	97
VI.1	Proyeksi Biaya Kumulatif Tiga Tahun Tiga Skenario	141

DAFTAR TABEL

II.1	Rincian Karakteristik Proses dan Komponen Tiap <i>Level</i> Kematangan MLOps	13
II.2	Perbandingan <i>Framework</i> Tingkat Kematangan MLOps	15
II.3	Rincian Karakteristik dan Kebutuhan Tiap Tahap Model Evolusi DataOps	17
II.4	Perbandingan Model Kematangan DataOps	18
III.1	Kebutuhan Fungsional Sistem	47
III.2	Kebutuhan Nonfungsional Sistem	49
III.3	Evaluasi Pemenuhan Kebutuhan Fungsional	55
III.4	Evaluasi Pemenuhan Kebutuhan Nonfungsional	56
III.5	Total Skor Pemenuhan Kebutuhan Fungsional dan Nonfungsional	56
III.6	Perbandingan Detail Arsitektur Saat Ini dengan yang Diusulkan	57
IV.1	Pemetaan Peran Pengguna ke Antarmuka dan <i>Layer</i> Platform	67
IV.2	Pemetaan Sembilan <i>Layer</i> Platform ke Komponen Mayoritas dan Sumbernya	70
IV.3	Evaluasi Alternatif Distribusi Kubernetes <i>Open-Source</i>	73
IV.4	Evaluasi Alternatif <i>Message Broker</i> untuk Tulang Punggung <i>Streaming</i>	74
IV.5	Evaluasi Alternatif <i>Schema Registry</i> untuk Apache Kafka	75
IV.6	Evaluasi Alternatif <i>Framework</i> Pemrosesan Data	75
IV.7	Evaluasi Alternatif Format Tabel <i>Lakehouse Open-Source</i>	76
IV.8	Evaluasi Alternatif Penyimpanan Objek S3-Kompatibel <i>Open-Source</i>	76
IV.9	Evaluasi Alternatif Pengelola Versi Data <i>Open-Source</i> pada <i>Layer</i> Penyimpanan Objek	77
IV.10	Evaluasi Alternatif <i>Feature Store Open-Source</i>	78
IV.11	Evaluasi Alternatif Penyimpanan <i>Offline</i> (OLAP)	79
IV.12	Evaluasi Alternatif Penyimpanan <i>Online</i> (Latensi Rendah)	79
IV.13	Evaluasi Alternatif <i>Vector Index Open-Source</i> untuk Pencarian Pendekatan Tetangga Terdekat	79
IV.14	Evaluasi Alternatif <i>Experiment Tracking</i> dan <i>Model Registry</i>	80
IV.15	Evaluasi Alternatif Orkestrasi ML <i>Open-Source</i>	81
IV.16	Evaluasi Alternatif <i>Model Serving</i>	81
IV.17	Evaluasi Alternatif Manajemen Metadata dan Tata Kelola	82

IV.18 Evaluasi Alternatif <i>Monitoring</i> dan <i>Observability</i>	83
IV.19 Evaluasi Alternatif <i>Business Intelligence</i> dan <i>Dashboarding Open-Source</i>	84
IV.20 Evaluasi Alternatif <i>GitOps Controller Open-Source</i>	85
IV.21 Evaluasi Alternatif <i>Identity Provider Open-Source</i>	86
IV.22 Evaluasi Alternatif Pengelola Rahasia	86
IV.23 Evaluasi Alternatif <i>Service Mesh</i>	87
IV.24 Evaluasi Alternatif <i>API Gateway Open-Source</i>	87
IV.25 Evaluasi Alternatif <i>Policy Engine Open-Source</i>	88
IV.26 Evaluasi Alternatif <i>Runtime Security Open-Source</i> pada Kubernetes	88
 V.1 Struktur Direktori Utama Proyek dan Fungsinya	 108
 VI.1 Skenario Uji Penerimaan per Tujuan Platform	 129
VI.2 Target Metrik, Instrumen Ukur, dan Status Evaluasi per Kebutuhan	134
VI.3 Perbandingan Biaya Bulanan Infrastruktur per 16 Juni 2026	138
VI.4 Ilustrasi Biaya Infrastruktur dan Tenaga Kerja Tiga Tahun per 16 Juni 2026	140
 A.1 Parameter Penilaian Kriteria Lintas Tabel	 163
A.2 Parameter Penilaian Kriteria Spesifik per <i>Layer</i>	164

DAFTAR LISTING

VI.1	Kutipan <i>overlay</i> Kustomize <i>use case</i> : prefiks <i>crypto-</i> , pemetaan registri <i>image</i> , <i>replica idle</i> satu, dan batas HPA <i>node</i> tunggal	125
B.1	Langkah persiapan pemuatan konfigurasi domain dan <i>namespace</i> pembangkit beban (dari ~/documents/ta/)	169
B.2	Perintah verifikasi tujuan T-1 (dari ~/documents/ta/)	169
B.3	Perintah verifikasi tujuan T-2 (dari ~/documents/ta/)	171
B.4	Perintah verifikasi tujuan T-3 (dari ~/documents/ta/)	171
B.5	Perintah verifikasi tujuan T-4 (dari ~/documents/ta/)	172

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
p99	Persentil ke-99 dari distribusi latensi permintaan, dipakai sebagai indikator <i>tail latency</i> pada SLO layanan <i>inference</i> .	Bab IV

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
ACID	<i>Atomicity, Consistency, Isolation, Durability</i> , sifat transaksi basis data.	Bab II
AGPL	<i>GNU Affero General Public License</i> , lisensi <i>copyleft</i> kuat yang juga mencakup penggunaan melalui jaringan.	Bab IV
ANN	<i>Approximate Nearest Neighbor</i> , kelas algoritma pencarian tetangga terdekat secara aproksimasi pada ruang vektor.	Bab II
API	<i>Application Programming Interface</i> .	Bab I
APISIX	Apache APISIX, <i>API gateway</i> berbasis Nginx dan etcd.	Bab II
ASF	<i>Apache Software Foundation</i> , yayasan nirlaba yang menaungi proyek <i>open source</i> Apache.	Bab IV
BSD	<i>Berkeley Software Distribution</i> , keluarga lisensi permisif perangkat lunak.	Bab IV
BSL	<i>Business Source License</i> , lisensi <i>source-available</i> dengan pembatasan pemakaian komersial.	Bab IV
BUSL	Penulisan SPDX untuk <i>Business Source License</i> versi 1.1.	Bab IV
CD	<i>Continuous Delivery</i> atau <i>Continuous Deployment</i> .	Bab I
CDC	<i>Change Data Capture</i> , teknik penangkapan perubahan data pada basis data sumber.	Bab II
CI	<i>Continuous Integration</i> .	Bab II
CNCF	<i>Cloud Native Computing Foundation</i> , yayasan yang menaungi proyek <i>cloud native</i> di bawah Linux Foundation.	Bab II
CNPG	<i>CloudNativePG</i> , operator Kubernetes untuk PostgreSQL.	Bab IV
CPU	<i>Central Processing Unit</i> .	Bab II
CR	<i>Custom Resource</i> , objek konkret yang dibuat dari sebuah CRD pada Kubernetes.	Bab V

CRD	<i>Custom Resource Definition</i> , definisi tipe sumber daya kustom pada Kubernetes.	Bab II
CT	<i>Continuous Training</i> , model training secara berkelanjutan dengan pemicu <i>drift</i> atau jadwal.	Bab II
DAG	<i>Directed Acyclic Graph</i> , graf berarah tanpa siklus untuk menyusun urutan tugas pada <i>orchestrator</i> .	Bab III
DSRM	<i>Design Science Research Methodology</i> , kerangka metodologi penelitian rekayasa artefak.	Bab I
eBPF	<i>extended Berkeley Packet Filter</i> , mekanisme menjalankan program tervalidasi di dalam kernel Linux.	Bab II
ECB	<i>European Central Bank</i> , sumber kurs referensi EUR ke USD.	Bab VI
ESO	<i>External Secrets Operator</i> , operator Kubernetes penyinkron rahasia dari pengelola rahasia eksternal.	Bab IV
FTE	<i>Full-Time Equivalent</i> , satuan alokasi penuh satu tenaga kerja per bulan.	Bab VI
GMS	<i>Generalized Metadata Service</i> , komponen layanan metadata inti pada DataHub.	Bab V
GPU	<i>Graphics Processing Unit</i> .	Bab II
gRPC	<i>gRPC Remote Procedure Call</i> , kerangka pemanggilan prosedur jarak jauh berbasis HTTP/2.	Bab III
HNSW	<i>Hierarchical Navigable Small World</i> , struktur graf untuk ANN.	Bab II
HPA	<i>Horizontal Pod Autoscaler</i> , kontrol penskalaan jumlah <i>pod</i> pada Kubernetes.	Bab II
HTML	<i>HyperText Markup Language</i> .	Bab IV
JISDOR	<i>Jakarta Interbank Spot Dollar Rate</i> , kurs referensi Bank Indonesia untuk USD ke IDR.	Bab VI
JSON	<i>JavaScript Object Notation</i> .	Bab II
KEDA	<i>Kubernetes Event-driven Autoscaling</i> , <i>autoscaler</i> berbasis sinyal eksternal.	Bab II

KES	<i>Key Encryption Service</i> , layanan kunci enkripsi sisi <i>server</i> untuk MinIO.	Bab II
KMS	<i>Key Management Service</i> , layanan pengelolaan kunci enkripsi.	Bab II
KS	<i>Kolmogorov-Smirnov test</i> , uji statistik kesetaraan dua distribusi.	Bab II
LF	<i>Linux Foundation</i> , yayasan nirlaba yang menaungi ekosistem proyek <i>open source</i> .	Bab IV
MLOps	<i>Machine Learning Operations</i> , disiplin praktik operasional pengembangan dan <i>model serving</i> untuk model <i>machine learning</i> .	Bab I
MPL	<i>Mozilla Public License</i> , lisensi <i>copyleft</i> lemah berbasis berkas.	Bab IV
mTLS	<i>mutual Transport Layer Security</i> , autentikasi TLS dua arah antar layanan.	Bab II
OIDC	<i>OpenID Connect</i> , protokol identitas berbasis OAuth 2.0.	Bab II
OLAP	<i>Online Analytical Processing</i> , pemrosesan kueri analitis pada data bervolume besar.	Bab IV
ONNX	<i>Open Neural Network Exchange</i> , format pertukaran model lintas <i>framework</i> .	Bab IV
PSI	<i>Population Stability Index</i> , metrik pergeseran distribusi fitur antar dua periode.	Bab II
REST	<i>Representational State Transfer</i> .	Bab II
RPO	<i>Recovery Point Objective</i> , batas maksimum kehilangan data yang dapat ditoleransi saat pemulihan.	Bab VI
RTO	<i>Recovery Time Objective</i> , batas maksimum waktu pemulihan layanan setelah gangguan.	Bab VI
SDK	<i>Software Development Kit</i> .	Bab III
SLO	<i>Service Level Objective</i> .	Bab II
SQL	<i>Structured Query Language</i> .	Bab II
SSO	<i>Single Sign-On</i> , autentikasi tunggal untuk banyak aplikasi.	Bab VI
TLS	<i>Transport Layer Security</i> .	Bab I
VPA	<i>Vertical Pod Autoscaler</i> , kontrol penyetelan <i>request/limit</i> sumber daya <i>pod</i> .	Bab II

YAML

YAML Ain't Markup Language, format serialisasi data untuk berkas konfigurasi.

Bab II

BAB I

PENDAHULUAN

Bab ini meletakkan dasar bagi keseluruhan laporan Tugas Akhir. Pembahasan dibuka dengan latar belakang yang memetakan tekanan praktik DataOps dan MLOps pada lingkungan produksi, kemudian diturunkan menjadi empat rumusan masalah dan empat tujuan yang saling berpasangan. Batasan masalah menetapkan lingkup pengerjaan, metodologi menjelaskan kerangka *Design Science Research Methodology* yang diikuti, dan sistematika penulisan menutup bab dengan peta isi laporan. Penomoran RM-1 hingga RM-4, T-1 hingga T-4, serta batasan penelitian BP-1 hingga BP-3 yang diperkenalkan pada bab ini menjadi rujukan tetap bagi seluruh bab berikutnya, sedangkan batasan implementasi BI-1 dan BI-2 diperkenalkan bersama lingkungan implementasi pada Bab V.

I.1 Latar Belakang

Keberhasilan *machine learning* pada lingkungan produksi ditentukan oleh kemampuan memindahkan model dari eksperimen ke layanan yang stabil, terpantau, dan dapat diperbarui, bukan oleh ketepatan model semata. Sculley dkk. (2015) menunjukkan kode model hanya sebagian kecil dari sistem nyata, sedangkan sisanya berupa pengelolaan data, konfigurasi, pemantauan, *serving*, dan *lineage*. Paleyes, Urma, dan Lawrence (2022) memetakan tantangan *deployment* dari kualitas data hingga pemeliharaan model, sementara adaptasi DevOps oleh komunitas *machine learning* melahirkan MLOps (Kreuzberger, Köhl, dan Hirschl 2023) dan DataOps tumbuh serupa untuk *pipeline* data. Rella (2022) mencatat keduanya berbagi prinsip otomasi yang sama tetapi kerap berjalan sebagai dua *tech stack* terpisah, sedangkan Jain dan Das (2025) menempatkan integrasinya sebagai syarat *pipeline* yang skalabel dan tangguh. Upaya integrasi tersebut dihadapkan pada dua tekanan utama yang, ketika tidak teratasi, memicu tekanan ketiga berupa efek domino.

1. Beban membangun platform dari nol di atas kumpulan komponen yang terfragmentasi

Kajian sistematis Amou Najafabadi dkk. (2024) atas 43 studi primer mengategorikan 35 komponen arsitektur MLOps beserta ragam *tool* pendukungnya, menandai luasnya ruang pilihan sebelum satu platform utuh terbentuk. Burgueño-Romero dkk. (2025) menambahkan bahwa komponen *open source* MLOps cenderung berdiri sendiri alih-alih membentuk kerangka kohesif,

sehingga beban integrasi, kurva belajar, dan penyelarasan versi ditanggung tim pemakai sejak awal.

2. **Biaya berlangganan layanan terkelola dan *trade-off* antara waktu pengembangan dengan anggaran berjalan**

Layanan terkelola mempercepat adopsi (Li dkk. 2023), tetapi studi empiris Hamza, Akbar, dan Capilla (2024) menemukan bahwa penagihan bayar per pakai dan pelaporan biaya *cloud* yang tidak transparan menyulitkan estimasi anggaran dan dapat menjadi tidak hemat pada beban besar, sejalan dengan Adusumilli (2025). Ditambah lagi dengan risiko keterikatan penyedia (Mo dkk. 2023), organisasi terjebak antara membangun tim platform dengan waktu pengembangan panjang atau berlangganan dengan biaya sulit diestimasi dan ruang kustomisasi yang sempit.

3. **Efek domino fragmentasi yang merambat ke seluruh rantai DataOps dan MLOps**

Ketika kedua tekanan tidak terjawab oleh satu *control plane*, sambungan yang terputus antar *layer ingestion*, fitur, *training*, dan *serving* memaksa integrasi dirakit ulang tiap proyek, sementara metadata, identitas, dan *lineage* dikelola sendiri-sendiri sehingga asal data sulit ditelusuri dan nilai fitur rawan berbeda antara *training* dan *serving*. Shankar dkk. (2022) mendokumentasikan lewat wawancara delapan belas insinyur bahwa pemeliharaan *pipeline* dan integrasi antar komponen menjadi keluhan berulang, dengan rincian per *layer* pada Bab III.

Ketiga tekanan tersebut menggerakkan pengembangan platform yang menyatukan DataOps dan MLOps di atas Kubernetes dengan komponen *open source*. Kubernetes dipilih sebagai standar *de facto* orkestrasi *cloud-native* yang teradopsi luas di lingkungan *enterprise* (Lakka 2025), sedangkan komponen *open source* membuat arsitektur dapat ditiru tanpa keterikatan penyedia sekaligus menghapus biaya lisensi. Rancangan dijaga *domain-agnostic* agar dapat diadaptasi lintas domain tanpa mengubah *control plane*, dengan keluaran empat *sub-sistem* pemutus rantai fragmentasi. Seluruh komponen ditata pada repositori Git internal dengan *operator* GitOps sebagai mesin rekonsiliasi deklaratif, sehingga sembilan *layer* arsitektur, dari orkestrasi hingga keamanan platform, terhubung pada satu jalur GitOps yang dirinci pada Bab IV.

I.2 Rumusan Masalah

Latar belakang di atas mengarah pada empat rumusan masalah yang ingin diselesaikan oleh platform yang dikembangkan. Keempat butir dirumuskan sebagai pertanyaan agar setiap permasalahan memiliki batas teknis yang jelas dan rute jawaban berupa *sub-sistem* atau kontrak antar komponen pada bab-bab berikutnya. Setiap pertanyaan menyoroti properti sistem yang belum terpenuhi, bukan ketiadaan satu *tool* tertentu, agar jawabannya berlaku lintas pilihan komponen dan menjaga sifat *domain-agnostic* platform. Keempat butir di bawah ini selanjutnya dirujuk dengan singkatan RM-1 hingga RM-4 pada bab-bab berikutnya.

1. Bagaimana menyatukan *tech stack* DataOps dan MLOps yang terfragmentasi pada *layer ingestion, processing, storage, training, dan model serving* ke dalam satu *control plane* pada Kubernetes?
2. Bagaimana mewujudkan tata kelola data yang konsisten lintas siklus data, fitur, dan model sehingga katalog metadata, *lineage*, dan kontrol kualitas tidak berjalan sebagai pekerjaan susulan?
3. Bagaimana mengotomasi deteksi *drift* dan menjamin *point-in-time correctness* agar tidak terjadi kebocoran temporal antara mode *batch* dan *streaming*?
4. Bagaimana menyajikan fitur multimodal, yang mencakup *tabular feature, aggregate feature, dan vector embedding* berdimensi tinggi, dari satu sumber kebenaran dengan nilai yang konsisten antara fase *training* dan *serving*?

Keempat rumusan masalah di atas dijawab secara berurutan oleh empat tujuan pada Subbab I.3, dengan rincian kebutuhan fungsional dan nonfungsional diturunkan pada Bab III. Keempat rumusan tidak saling tumpang tindih karena masing-masing menyoroti satu titik kegagalan yang berbeda, yaitu perakitan lintas *layer*, tata kelola data, deteksi *drift* beserta pencegahan kebocoran temporal, dan *feature serving* multimodal, sekaligus bersama-sama mencakup rentang dari siklus data hingga *model serving*. Karena dirumuskan dengan batas teknis yang jelas dan berpijak pada kegagalan yang terdokumentasi pada latar belakang, keempat rumusan menjadi acuan tetap yang jawabannya ditunjukkan melalui artefak yang berjalan. Pemenuhan tiap rumusan ditelusuri kembali pada Bab VI melalui skenario uji yang menautkan rumusan dengan bukti verifikasinya.

I.3 Tujuan

Penelitian ini merumuskan empat tujuan yang masing-masing menjawab satu rumusan masalah, dengan keluaran berupa artefak teknis yang dapat ditunjukkan dan dipakai ulang. Setiap tujuan menetapkan keluaran berupa rancangan arsitektur, ma-

nifes *deployment* pada repositori Gitea, dan kontrak antar komponen yang dapat diuji pada *use case* verifikasi. Keempat tujuan di bawah ini selanjutnya dirujuk dengan singkatan T-1 hingga T-4 pada bab-bab berikutnya, dengan pemetaan satu lawan satu terhadap RM-1 hingga RM-4. Tiap tujuan dirumuskan sebagai tindakan merancang dan mewujudkan artefak yang dapat ditunjukkan, bukan sebagai aktivitas mengukur atau menguji.

1. Merancang dan mewujudkan arsitektur platform DataOps dan MLOps terintegrasi di atas Kubernetes yang menyatukan *data ingestion*, *processing*, *storage* dan *feature store*, *training*, *model serving*, serta *governance* dan *observability* pada satu *control plane* deklaratif dengan praktik GitOps, menjawab RM-1.
2. Membangun *sub-sistem* tata kelola data yang menyediakan katalog metadata, perekaman *lineage*, dan kontrol kualitas data sebagai layanan bersama yang dijalankan secara otomatis di seluruh *pipeline* data, fitur, dan model, menjawab RM-2.
3. Mengimplementasikan *sub-sistem* deteksi *drift* terotomasi dengan kebijakan *retraining* berbasis ambang batas serta menjamin *point-in-time correctness* pada *feature serving* lintas mode *batch* dan *streaming*, menjawab RM-3.
4. Mengembangkan layanan fitur *dual-store* yang melayani *tabular feature* dan *aggregate feature* melalui satu kontrak API dengan jaminan konsistensi nilai antara fase *training* dan *serving*, serta melayani *vector embedding* berdimensi tinggi pada indeks vektor terpisah dengan ruang *embedding* yang konsisten pada kedua fase tersebut, menjawab RM-4.

Kriteria keberhasilan keseluruhan platform diukur dari empat sudut yang masing-masing menautkan satu tujuan. Setiap kriteria dirumuskan agar dapat diperiksa pada artefak yang berjalan, bukan pada rancangan di atas kertas. Pemeriksaannya dilakukan melalui skenario uji pada Bab VI dengan penerimaan fungsional dan struktural sesuai lingkup batasan penelitian. Keempat kriteria berikut menjadi tolok ukur minimum sebelum platform dinyatakan menjawab rumusan masalah.

1. Seluruh artefak dapat dipasang dari satu repositori Git melalui Argo CD tanpa intervensi manual setelah *bootstrap* awal klaster (T-1).
2. Seluruh *pipeline* data, fitur, dan model terdaftar pada katalog metadata dengan *lineage* yang dapat ditelusuri (T-2).
3. Mekanisme deteksi *drift* memicu *retraining* secara otomatis ketika ambang batas dilewati pada *use case* verifikasi (T-3).
4. *Tabular feature*, *aggregate feature*, dan *embedding* tersaji melalui satu kontrak API dengan nilai yang konsisten antara penyimpanan *offline* dan *online* (T-4).

I.4 Batasan Masalah

Batasan masalah pada Tugas Akhir ini menetapkan ruang lingkup yang sengaja tidak dicakup oleh kontribusi penelitian agar penilaian tetap tertuju pada arsitektur platform yang *domain-agnostic*. Karena keluaran utama penelitian adalah arsitektur yang dapat dipakai lintas *use case*, pilihan perwujudan seperti jumlah *node*, patokan versi, atau sintaks komponen tertentu tidak dimasukkan sebagai batasan penelitian, melainkan dinyatakan sebagai batasan implementasi bersama lingkungan implementasi pada Bab V. Ketiga batasan di bawah ini membatasi klaim pada *control plane* platform, cakupan keamanan antar layanan, dan lingkup evaluasi. Ketiga butir tersebut selanjutnya dirujuk dengan singkatan BP-1 hingga BP-3, dan konsekuensinya pada evaluasi dibahas kembali pada Bab VI.

1. Fokus penelitian berada pada *control plane* platform, bukan pengembangan model spesifik, sehingga *use case* domain hanya dipakai sebagai kasus verifikasi rancangan dan pembahasan platform dijaga *domain-agnostic*.
2. Aspek keamanan berfokus pada akses antar layanan internal melalui *mutual TLS* pada *service mesh*, manajemen rahasia terpusat, dan kebijakan jaringan Kubernetes, sedangkan autentikasi pengguna akhir pada *application layer* berada di luar cakupan penelitian.
3. Evaluasi difokuskan pada penerimaan fungsional dan struktural tanpa mencakup *deployment* produksi pada lingkungan multi-tenant dengan trafik publik, sedangkan karakterisasi beban kuantitatif penuh seperti latensi p99, *throughput* puncak, dan skalabilitas horizontal ditempatkan sebagai arah pengembangan lanjutan.

Ketiga batasan penelitian di atas menjadi konteks pembacaan seluruh laporan, terutama pada Bab III dan Bab VI. Ketiganya menjaga fokus kontribusi pada *control plane* yang *domain-agnostic* sehingga keberlakuan rancangan tidak terikat pada satu domain maupun satu lingkungan perwujudan. Pilihan perwujudan yang dapat diganti tanpa mengubah kontribusi, yaitu lingkungan *k3s* satu *node* dan patokan versi April 2026, dinyatakan sebagai batasan implementasi BI-1 dan BI-2 pada Bab V. Dengan pemisahan ini, keterbatasan lingkungan pengujian tidak membatasi keberlakuan arsitektur yang dirancang.

I.5 Metodologi

Penelitian ini mengikuti kerangka *Design Science Research Methodology* (DSRM) yang dirumuskan oleh Peffers dkk. (2007) untuk penelitian sistem informasi yang menghasilkan artefak. Keluaran utama Tugas Akhir ini berupa platform yang berjal-

an, yaitu artefak jenis instansiasi (*instantiation*) dalam taksonomi *design science*, sehingga kerangka penelitian berorientasi artefak menjadi pilihan yang tepat (Hevner dkk. 2004). DSRM dipilih dibandingkan metodologi rekayasa perangkat lunak murni karena DSRM menempatkan iterasi antara perancangan, demonstrasi, dan evaluasi sebagai bagian inti proses penelitian, bukan sekadar tahapan pengembangan. Kerangka proses *data science* seperti CRISP-DM dan TDSP tidak menjadi pilihan karena keduanya menata pembangunan satu model pada satu domain data, sedangkan keluaran Tugas Akhir ini adalah platform lintas domain dan model hanya menjadi salah satu beban kerja yang dilayani. Tahapan yang dijalankan meliputi enam fase berikut dengan keluaran teknis yang dapat diukur.

1. Identifikasi masalah dan motivasi

Studi literatur DataOps, MLOps, dan tata kelola data dilakukan untuk menyusun peta tantangan. Tiga pemicu dan empat rumusan masalah (RM-1 sampai RM-4) menjadi keluaran fase ini.

2. Penetapan tujuan artefak

Tujuan dirumuskan sebagai daftar artefak teknis yang dapat dipasang, dioperasikan, dan diaudit, dipetakan satu lawan satu terhadap rumusan masalah. Kebutuhan fungsional KF-01 sampai KF-14 dan kebutuhan nonfungsional KNF-01 sampai KNF-12 disusun pada Bab III.

3. Perancangan dan pengembangan artefak

Himpunan layanan representatif diklasifikasikan dari praktik industri menjadi sembilan *layer* platform, komponen *open source* dipilih untuk tiap *layer*, lalu arsitektur kesembilan *layer* tersebut dirancang sebagai *control plane* deklaratif berbasis Kubernetes, bertolak dari alternatif arsitektur terpilih hasil matriks evaluasi multi-kriteria pada Bab III. Pengembangan manifes dilakukan modular pada repositori Gitea dengan *folder* per komponen dan *overlay* Kustomize.

4. Demonstrasi

Platform dipasang pada lingkungan *k3s* dan diberi beban kerja dari satu *use case* domain nyata sebagai kasus verifikasi, yang dirinci pada Bab VI. Demonstrasi diatur sebagai empat tahap iteratif, dengan setiap tahap memvalidasi satu *sub-sistem* sesuai T-1 hingga T-4.

5. Evaluasi

Evaluasi dilaksanakan pada akhir siklus implementasi dengan tiga dimensi: fungsional, nonfungsional (skalabilitas, ketersediaan, observabilitas, keamanan, biaya), serta tata kelola (*lineage* tertelusur, kontrak data ditegakkan,

kebijakan akses dapat diaudit). Angka kuantitatif evaluasi dilaporkan pada Bab VI.

6. **Komunikasi**

Hasil rancangan dan implementasi didokumentasikan pada laporan ini, beserta repositori Gitea yang menjadi acuan reproduksi. Keluaran fase ini berupa laporan, repositori sumber, dan presentasi ujian akhir.

Keenam fase di atas dijalankan secara iteratif, dengan kemungkinan kembali ke fase sebelumnya ketika temuan baru muncul pada fase berikutnya. Iterasi tersebut sejalan dengan karakter DSRM sebagai metodologi berorientasi artefak yang menempatkan umpan balik dari demonstrasi dan evaluasi sebagai pemicu perbaikan rancangan. Pola pengembangan serupa, yaitu membangun platform atau *pipeline* MLOps berbasis Kubernetes lalu menilainya melalui demonstrasi dan eksperimen, dipakai oleh Hsu dkk. (2024) dan Rodrigues dkk. (2025). Pelaporan tiap fase disusun pada bab yang sesuai sehingga keterhubungan antara fase metodologi dan struktur laporan tetap eksplisit.

I.6 **Sistematika Penulisan**

Laporan Tugas Akhir disusun atas tujuh bab dengan urutan yang mengikuti DSRM dan praktik pelaporan rekayasa perangkat lunak. Pemetaan antara rumusan masalah, tujuan, *sub-sistem*, dan butir kesimpulan dijaga konsisten lewat penomoran RM-N, T-N, dan butir pada Bab IV hingga Bab VII. Bab IV dan Bab V membentuk pasangan perancangan dan implementasi yang dibaca berurutan, sedangkan Bab VI dan Bab VII menutup siklus dengan evaluasi serta kesimpulan dan saran. Urutan bab beserta isi utamanya dirinci pada poin-poin berikut.

1. **Bab I Pendahuluan**

Memuat latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi penelitian, serta sistematika penulisan.

2. **Bab II Studi Literatur**

Meninjau konsep DataOps dan MLOps, Kubernetes, manajemen data, layanan fitur, *model lifecycle*, tata kelola data, deteksi *drift*, observabilitas, praktik GitOps, dan keamanan platform sebagai landasan teoretis, lalu mengidentifikasi kesenjangan pada penelitian terkait.

3. **Bab III Analisis Masalah**

Memetakan kondisi sistem dan menyusun kebutuhan fungsional KF-01 hingga KF-14 serta kebutuhan nonfungsional KNF-01 hingga KNF-12 sebagai

turunan empat tujuan. Empat alternatif arsitektur dibandingkan melalui matriks evaluasi multi-kriteria, lalu posisi platform terhadap penelitian terkait dipetakan berdasarkan kebutuhan yang sama.

4. **Bab IV Perancangan Arsitektur Platform DataOps dan MLOps**

Menetapkan sembilan *layer* platform representatif dari praktik industri, memilih komponen *open source* untuk tiap *layer*, lalu menjabarkan perancangan arsitektur kesembilan *layer* dan empat *sub-sistem* yang menjawab T-1 hingga T-4. Diagram arsitektur disajikan dalam gambaran umum beserta rincian per *layer*.

5. **Bab V Implementasi Arsitektur Platform DataOps dan MLOps**

Memaparkan implementasi tiap *sub-sistem* yang sejalan dengan Bab IV, dengan praktik GitOps melalui Argo CD pada repositori Gitea sebagai sumber kebenaran tunggal.

6. **Bab VI Evaluasi**

Berisi metode evaluasi, hasil pengukuran, dan pembahasan terhadap kebutuhan fungsional dan nonfungsional pada Bab III, serta perbandingan biaya infrastruktur dan tenaga kerja terhadap skenario layanan terkelola.

7. **Bab VII Penutup**

Menyimpulkan jawaban atas T-1 hingga T-4 dan memberikan saran pengembangan lanjutan untuk lingkungan *multi-node* dan *multi-domain*.

Setelah Bab VII, dokumen ditutup oleh Daftar Pustaka yang memuat seluruh referensi terkutip dan Lampiran yang memuat berkas pendukung. Daftar Pustaka memakai gaya *Chicago author-date* (`bibtex-chicago`) dengan label Indonesia agar konsisten dengan tubuh laporan. Lampiran memuat parameter penilaian pemilihan alat *open source* dan katalog perintah verifikasi *use case*. Penomoran lampiran mengikuti abjad (Lampiran A dan B) sebagaimana konvensi laporan Tugas Akhir di STI ITB.

BAB II

STUDI LITERATUR

Bab ini merangkum landasan teori dan ekosistem perangkat lunak yang relevan untuk perancangan platform pada Bab IV. Tinjauan disusun mulai dari konsep DataOps dan MLOps, dilanjutkan dengan komponen teknis yang menjadi bahan baku perancangan, kemudian ditutup dengan posisi penelitian terdahulu dan kebaruan yang ditawarkan. Susunan ini mengikuti urutan *layer* arsitektur platform, dari orkestrasi infrastruktur, jalur data, layanan fitur, dan *model lifecycle*, hingga tata kelola, deteksi *drift*, observabilitas, praktik GitOps, dan keamanan, sebagaimana dirinci pada Bab IV. Sumber rujukan menggabungkan publikasi akademik dengan dokumentasi resmi komponen *open source* agar setiap pilihan teknis dapat ditelusuri ke spesifikasi sumber.

Setiap subbab teknis memperkenalkan konsep *layer* tersebut, menautkannya ke rujukan akademik, lalu menyebut beberapa alat *open source* sebagai contoh perwujudan. Perbandingan berskor antar alat dan pemilihan komponen konkret tidak dibahas pada bab ini, melainkan pada Subbab IV.3 di Bab IV yang menilai tiap alat terhadap kriteria kelayakan platform. Pemisahan ini menjaga bab ini tetap membahas konsep secara umum, sementara keputusan pemilihan alat ditegakkan pada bab perancangan dengan bukti skor. Dengan begitu, keputusan teknis pada Bab IV dan Bab V dapat ditelusuri dari konsep pada bab ini ke pemilihan alat pada bab perancangan.


II.1 DataOps dan MLOps

Dua disiplin operasional yang menjadi pokok penelitian ini diuraikan terlebih dahulu sebelum komponen teknis pendukungnya. DataOps dibahas sebagai praktik otomasi *data lifecycle*, kemudian MLOps sebagai perluasan praktik DevOps ke *model lifecycle*. Kerangka tingkat kematangan MLOps dan model evolusi DataOps dipakai untuk menempatkan kondisi awal serta target kapabilitas platform pada jenjang yang dapat diukur. Subbab penutup membahas integrasi kedua disiplin yang menjadi celah penelitian sekaligus posisi platform ini.

II.1.1 DataOps

DataOps merupakan adaptasi praktik DevOps untuk *data lifecycle*. Munappy dkk. (2020) mendefinisikan DataOps sebagai pendekatan yang mengadopsi praktik *agile*

dan DevOps serta mengandalkan otomatisasi tahapan *data lifecycle* untuk mempercepat penyediaan hasil analitik yang berkualitas. Kleppmann (2017) memberi fondasi konseptual lewat penjelasan tentang sistem berbasis data yang andal, dapat diskalakan, dan dapat dipelihara, sementara Stopford (2018) memperkenalkan pola arsitektur *event-driven* dengan Apache Kafka sebagai tulang punggung. Pada praktiknya, DataOps menuntut otomatisasi *pipeline ingestion* dan transformasi, pengujian kontrak data, perekaman *lineage*, dan pemantauan kualitas data sebagai bagian permanen dari operasi. Bentuk industrial rangkaian tahapan tersebut terdokumentasi pada *big data analytics pipeline* di Ericsson, tempat data dari sumber internal dan eksternal mengalir melalui *data ingestion*, agregasi, penyimpanan, hingga visualisasi bagi pemangku kepentingan, sebagaimana diperlihatkan pada Gambar II.1.



Gambar II.1 *Big data analytics pipeline* pada studi kasus Ericsson (Munappy dkk. 2020).

Empat pilar operasi DataOps adalah otomatisasi *pipeline*, kontrak skema, pengujian kualitas data, dan pemantauan SLO. Contoh perwujudan *open source* keempat pilar itu berturut-turut adalah Apache Airflow untuk orkestrasi *batch* terjadwal, Karapace sebagai *schema registry*, Great Expectations sebagai gerbang kualitas pada *pipeline*, dan Sloth yang menurunkan SLO menjadi aturan Prometheus. Polyzotis dkk. (2018) merinci praktik validasi data berkelanjutan yang menyatu dengan *pipeline machine learning*, mencakup pemeriksaan skema, rentang nilai, dan anomali distribusi pada setiap proses *ingestion*. Kombinasi keempat pilar tersebut menjadi prasyarat bagi integrasi DataOps dan MLOps yang dibahas pada Subbab II.1.4.

II.1.2 MLOps


MLOps memperluas praktik DevOps ke seluruh tahap *model lifecycle machine learning*. Kreuzberger, Kühl, dan Hirschl (2023) memberikan definisi terpadu: MLOps sebagai gabungan budaya kerja dan perangkat lunak untuk mengotomasi eksperimen, pelatihan, evaluasi, *deployment*, dan pemantauan model. Sculley dkk. (2015)

menjelaskan akar persoalannya: *hidden technical debt* pada sistem *machine learning* muncul terutama dari komponen non-model seperti *feature engineering*, konfigurasi, perekaman, pengujian data, dan layanan pemantauan. Paleyes, Urma, dan Lawrence (2022) melengkapi pemetaan dengan survei tantangan operasionalisasi, dan Shankar dkk. (2022) membawa perspektif praktisi melalui wawancara dengan tim MLOps lintas industri.


Tiga karakteristik penting yang membedakan MLOps dari DevOps tradisional adalah *continuous training*, *continuous monitoring*, dan *model registry* sebagai sumber kebenaran versi model. Amershi dkk. (2019) menggambarkan sembilan tahap rekayasa perangkat lunak *machine learning* mulai dari pengumpulan data hingga pemantauan, dengan setiap tahap memerlukan dukungan otomasi tersendiri. Breck dkk. (2017) memperkenalkan *rubric* kesiapan produksi yang menjadi acuan banyak tim untuk menilai kematangan *pipeline* mereka. Contoh perwujudan *open source* ketiga karakteristik tersebut adalah Kubeflow Pipelines untuk *continuous training*, Evidently dan Prometheus untuk *continuous monitoring*, serta MLflow Model Registry sebagai sumber kebenaran versi model yang ditelaah ulang pada Subbab II.5.1.

II.1.3 Tingkat Kematangan MLOps dan DataOps


Beberapa kerangka kematangan diusulkan untuk menggambarkan jenjang kapabilitas tim. Google Cloud (2024) membagi MLOps menjadi tiga level: *level 0* dengan proses manual, *level 1* dengan otomasi *training pipeline*, dan *level 2* dengan otomasi *deployment* berbasis CI/CD/CT. Tiga level ini diilustrasikan pada Gambar II.2, Gambar II.3, dan Gambar II.4. Microsoft Azure (2023) memberi varian dengan lima level dari 0 hingga 4, Kartakis dkk. (2022) menguraikan empat fase kematangan dari *initial* hingga *scalable* pada peta jalan MLOps AWS, dan McKnight (2020) menambah perspektif organisasi. Perbandingan ringkas dapat dilihat pada Tabel II.2.



Gambar II.2 MLOps *level 0*: proses manual dengan penyerahan model satu arah (Google Cloud 2024).



Gambar II.3 MLOps *level 1*: otomasi *training pipeline* dengan komponen yang dapat dipakai ulang (Google Cloud 2024).



Gambar II.4 MLOps *level 2*: orkestrasi CI/CD/CT dengan deteksi *drift* sebagai pemicu *retraining* (Google Cloud 2024).

Ketiga *level* tersebut dibedakan bukan hanya oleh keberadaan otomasi, melainkan oleh karakteristik proses dan komponen yang menyertai tiap jenjang. *Level 0* ber-sandar pada proses manual berbasis skrip dengan penyerahan model satu arah tanpa *CI* maupun *CD*, *level 1* menambahkan otomasi *training pipeline* beserta validasi data dan model, *metadata management*, dan pemicu *pipeline*, sedangkan *level 2*

menuntut orkestrasi CI/CD atas seluruh *pipeline* ML dengan tujuh komponen wajib. Tabel II.1 merinci karakteristik proses dan komponen tiap *level* sebagaimana dirumuskan Google Cloud (2024). Rincian ini menjadi acuan untuk menilai jarak kapabilitas antara kondisi awal dan target arsitektur yang dikembangkan pada bab-bab berikutnya.

Tabel II.1 Rincian Karakteristik Proses dan Komponen Tiap *Level* Kematangan MLOps

Level	Karakteristik Proses	Komponen
Level 0 <i>Manual process</i>	<i>Manual, script-driven, and interactive process</i> dengan <i>disconnection between ML and operations</i> serta <i>infrequent release iterations</i> . Tanpa <i>CI</i> dan tanpa <i>CD, deployment</i> hanya merujuk pada <i>prediction service</i> , disertai <i>lack of active performance monitoring</i> .	Tanpa komponen otomasi tambahan. Penyerahan model bersifat satu arah dari <i>data scientist</i> ke tim operasi, dan <i>deployment</i> terbatas sebagai <i>prediction service</i> .
Level 1 <i>ML pipeline automation</i>	<i>Rapid experiment, CT of the model in production</i> , dan <i>experimental-operational symmetry</i> . <i>Modularized code for components and pipelines, continuous delivery of models</i> , serta <i>pipeline deployment</i> .	Komponen tambahan yang dituntut level ini, yaitu <i>data and model validation, feature store</i> (opsional), <i>metadata management</i> , dan <i>ML pipeline triggers</i> .
Level 2 <i>CI/CD pipeline automation</i>	Enam tahap otomasi <i>pipeline</i> , yaitu <i>development and experimentation, pipeline continuous integration, pipeline continuous delivery, automated triggering, model continuous delivery</i> , dan <i>monitoring</i> .	Tujuh komponen wajib, yaitu <i>source control, test and build services, deployment services, model registry, feature store, ML metadata store</i> , dan <i>ML pipeline orchestrator</i> .

Sumber: Google Cloud (2024). Istilah teknis dipertahankan dalam bahasa asli sesuai dokumen sumber.

Platform yang dikembangkan menargetkan kematangan setara *level 2* pada kerangka Google Cloud. Target ini menuntut tiga jalur otomasi yang bekerja sebagai satu siklus, bukan sekadar tersedianya alat pada tiap tahap. Ketiganya menutup siklus otomasi dari pelatihan, *deployment*, hingga pemantauan yang memicu *retraining*. Rincian tiap jalur pada platform ini adalah sebagai berikut.

1. **Training Pipeline otomatis**

Training pipeline didefinisikan sebagai *pipeline* yang dipicu secara terjadwal maupun ketika ambang *drift* terlampaui.

2. ***Deployment* model otomatis**

Deployment model dijalankan otomatis dengan versi yang dipromosikan langsung oleh *training pipeline*.

3. **Pemantauan model berkelanjutan**

Pemantauan model dilakukan secara berkelanjutan oleh *job* deteksi *drift* terjadwal yang melaporkan metrik *drift* ke sistem pemantauan serta menyimpan skor historis untuk audit, sebagaimana dirinci pada Subbab II.7.

Ketiga jalur otomasi tersebut menjadi acuan implementasi pada Bab V dan dasar evaluasi pada Bab VI. Jalur pelatihan diwujudkan sebagai *pipeline* Kubeflow Pipelines, jalur *deployment* sebagai promosi versi pada KServe, dan jalur pemantauan sebagai *job* deteksi *drift* yang melapor ke Prometheus. Ketiganya dihubungkan oleh CronWorkflow Argo yang membaca skor *drift* dan memanggil *training pipeline* ketika ambang terlampaui. Dengan rantai itu, kematangan *level 2* dapat diperiksa sebagai perilaku sistem, bukan sekadar daftar komponen.

Tabel II.2 merangkum posisi keempat kerangka kematangan MLOps tersebut pada enam dimensi kapabilitas sebelum pembahasan beralih ke sisi DataOps.


Tabel II.2 Perbandingan *Framework* Tingkat Kematangan MLOps

Frame- work	Level	DevOps Practices	ML Pipeline Auto- mation	CI/CD Inte- gration	CT (Conti- nuous Training)	Moni- toring & Feedback Loop	Gover- nance & Lineage
GCP	L0	0	0	0	0	0	0
	L1	1	2	1	2	2	2
	L2	2	2	2	2	2	2
Azure	L0	0	0	0	0	0	0
	L1	1	0	1	0	0	0
	L2	1	2	0	2	1	2
	L3	2	2	2	2	1	2
	L4	2	2	2	2	2	2
AWS	Initial	0	0	0	0	0	0
	Repeat- able	1	2	0	2	1	2
	Reliable	2	2	2	2	2	2
	Scalable	2	2	2	2	2	2
Giga Om	L0	0	0	0	0	0	0
	L1	1	1	0	0	1	1
	L2	2	2	2	1	1	2
	L3	2	2	2	2	2	2
	L4	2	2	2	2	2	2

Keterangan skor: 0 = praktik belum hadir pada level tersebut, 1 = hadir sebagian atau semi-otomatis, 2 = otomatis penuh. Nilai dipetakan dari deskripsi level tiap kerangka.

Padanan kerangka pada sisi data diberikan oleh model evolusi DataOps yang disusun Munappy dkk. (2020) dari studi kasus industri telekomunikasi, berbentuk tangga lima tahap: analisis data ad hoc, analisis data semi-otomatis dengan *pipeline* data, praktik *agile data science*, pengujian dan pemantauan berkelanjutan, lalu DataOps. Tangga evolusi tersebut beserta komponen studi kasus yang terakumulasi pada tiap tahapnya diperlihatkan pada Gambar II.5. Tahap awal model tersebut ditandai silo data, keputusan bisnis yang hanya bertumpu pada sebagian kecil data, dan pemantauan *pipeline* yang masih manual, sedangkan tahap akhirnya menuntut CI/CD untuk analitik data, orkestrasi *pipeline*, dan pemantauan seluruh *data lifecycle*. Laporan

ini memakai kedua kerangka secara berpasangan untuk membingkai kondisi awal dan target: kondisi terfragmentasi pada Gambar III.1 dan Gambar III.2 di Bab III setara dengan *level 0* sekaligus tahap awal evolusi DataOps, sedangkan arsitektur pada Bab IV menargetkan *level 2* sekaligus tahap DataOps. Dengan pasangan tersebut, perpindahan kapabilitas dapat dinilai pada sisi data dan sisi model sekaligus, bukan hanya pada salah satunya.



Gambar II.5 Model evolusi DataOps lima tahap (Munappy dkk. 2020).

Kelima tahap pada model evolusi tersebut memiliki karakteristik dan kebutuhan yang berbeda saat sebuah organisasi menaiki tangga menuju DataOps. Tahap *ad-hoc data analysis* masih bertumpu pada pengumpulan data manual dan *data silos*, tahap *semi-automated data analysis* memperkenalkan *data pipelines* beserta *data technologies*, tahap *agile data science* menyelaraskan pengembangan dengan metodologi *agile* dan DevOps, tahap *continuous testing and monitoring* menambahkan pengujian dan pemantauan *pipeline* berkelanjutan, dan tahap DataOps memadukan *value pipelines* serta *innovation pipelines* dengan orkestrasi penuh. Tabel II.3 merinci karakteristik dan kebutuhan kunci tiap tahap sebagaimana disusun Munappy dkk. (2020) dari studi kasus industri telekomunikasi di Ericsson. Rincian per tahap ini melengkapi kerangka MLOps pada Tabel II.1 sehingga perpindahan kematangan dapat dibaca konsisten pada sisi data maupun sisi model.

Tabel II.3 Rincian Karakteristik dan Kebutuhan Tiap Tahap Model Evolusi DataOps

Tahap	Karakteristik	Kebutuhan Kunci
1. <i>Ad-hoc data analysis</i>	Laporan dan <i>insight</i> dibuat <i>on-demand</i> serta sangat disesuaikan untuk menjawab satu pertanyaan bisnis spesifik. Pengumpulan data masih manual dan bergantung pada templat departemen teknologi informasi, sehingga muncul <i>data silos</i> dan keputusan bisnis bertumpu pada sebagian kecil data.	Teknologi untuk mengumpulkan data <i>real-time</i> dari banyak sumber data.
2. <i>Semi-automated data analysis</i>	<i>Data pipelines</i> mengumpulkan dan memproses data secara lebih efisien dan otomatis, didukung <i>data technologies</i> (<i>data engineering, data preparation, data storage, data visualization</i>) dan <i>data processes</i> . Sebagian aktivitas belum otomatis dan pemantauan masih manual.	<i>Data pipelines</i> yang dirancang baik untuk mengevaluasi, menguji, memuat, mentransformasi, memvalidasi, dan mempublikasikan data pada skala besar, beserta <i>data technologies</i> dan <i>data processes</i> untuk mengoordinasikannya.
3. <i>Agile data science</i>	<i>Development</i> dan <i>deployment</i> diatur metodologi <i>agile</i> dan DevOps sehingga kode teruji penuh dihasilkan dalam waktu singkat dan disimpan pada repositori pusat bersama. <i>Insight</i> dikirim dalam <i>sprint</i> pendek dengan umpan balik pelanggan berkala.	<i>Continuous delivery</i> nilai bisnis ke pelanggan serta penanganan kebutuhan pelanggan yang berkembang melalui komunikasi langsung dengan tim data.
4. <i>Continuous testing and monitoring</i>	Pengujian dan pemantauan <i>pipeline</i> berkelanjutan untuk mendeteksi masalah lebih awal sebelum menjalar ke tahap berikutnya. Dilengkapi <i>automated unit tests</i> , pengujian tingkat lebih tinggi, dan <i>automated alerts</i> saat <i>pipeline</i> rusak.	<i>Test cases</i> untuk menguji kualitas data, mekanisme pemantauan berkelanjutan dan <i>alerting</i> otomatis, serta strategi mitigasi untuk menangani <i>pipeline breakage</i> .
5. <i>DataOps</i>	Memperpendek <i>end-to-end cycle time</i> analitik data dari ide hingga <i>insight</i> dengan menggabungkan praktik <i>agile</i> dan prinsip DevOps untuk mengelola artefak berupa data, metadata, dan kode. Memadukan <i>value pipelines</i> dan <i>innovation pipelines</i> yang menuntut orkestrasi, otomasi, dan kolaborasi.	<i>Continuous integration</i> dan <i>continuous delivery</i> untuk analitik data, mekanisme memantau dan mengendalikan seluruh <i>data life cycle</i> , serta orkestrasi dengan otomasi lanjutan dan praktik <i>agile</i> .

Sumber: Munappy dkk. (2020). Nama tahap dipertahankan dalam bahasa asli sesuai dokumen sumber.

Di samping model akademik tersebut, praktik industri menawarkan model kematangan DataOps dengan sudut pandang yang berbeda. DataKitchen (2020) menyusun *DataOps Maturity Model* berupa lima *level* kematangan dari *struggle* hingga *optimized* yang dinilai pada enam dimensi organisasi, yaitu *error rates*, *cycle time*, *collaboration*, *measurement*, *team culture*, dan *customer happiness*, dengan kapabilitas kunci berupa pengujian otomatis, pemantauan, orkestrasi *toolchain*, kendali versi, dan *continuous deployment*. Harrington (2021) menguraikan empat tahap kematangan DataOps untuk data industrial manufaktur, dari *data access* hingga *enterprise visibility*, yang menekankan cakupan integrasi data alih-alih kapabilitas proses. Ketiga model menilai objek yang berbeda, yaitu evolusi kapabilitas *pipeline* data, asesmen organisasi pada enam dimensi, dan cakupan integrasi data, sehingga pemetaan skor kapabilitas lintas model seperti pada Tabel II.2 tidak diterapkan agar tidak memaksakan padanan yang tidak dinyatakan sumbernya. Tabel II.4 merangkum perbandingan ketiganya pada tataran deskriptif. Meskipun objek penilaiannya berbeda, ketiganya menempatkan kendali menyeluruh pada anak tangga tertinggi: tahap DataOps menuntut mekanisme pemantauan dan kendali seluruh *data lifecycle*, *level quantitative* dan *optimized* menuntut proses yang terukur, terkendali, lalu terus diperbaiki, dan tahap *enterprise visibility* menuntut *data governance* dengan data yang tersinkron lintas situs. Konvergensi ini sejalan dengan penempatan tata kelola dan observabilitas sebagai *layer* lintas fungsi pada rancangan platform di Bab IV. Sisi DataOps laporan ini tetap ditambatkan pada model evolusi Munappy dkk. (2020) karena model tersebut ditelaah sejawat, berpijak pada studi kasus industri, dan berfokus pada kapabilitas *pipeline* data yang selaras dengan lingkup platform.

Tabel II.4 Perbandingan Model Kematangan DataOps

Model	Tahap atau Level	Fokus Penilaian	Lingkup dan Jenis Sumber
Model evolusi DataOps (Munappy dkk. 2020)	Lima tahap: <i>ad-hoc data analysis</i> , <i>semi-automated data analysis</i> , <i>agile data science</i> , <i>continuous testing and monitoring</i> , dan DataOps	Evolusi kapabilitas <i>data pipeline</i> , dari pengumpulan data manual hingga orkestrasi dan pemantauan seluruh <i>data lifecycle</i>	Lintas domain, studi kasus telekomunikasi, makalah telaah sejawat

Model	Tahap atau <i>Level</i>	Fokus Penilaian	Lingkup dan Jenis Sumber
<i>DataOps Maturity Model</i> (DataKitchen 2020)	Lima <i>level</i> per dimensi: <i>struggle</i> , <i>basic</i> , <i>consistent</i> , <i>quantitative</i> , dan <i>optimized</i>	Asesmen organisasi pada enam dimensi: <i>error rates</i> , <i>cycle time</i> , <i>collaboration</i> , <i>measurement</i> , <i>team culture</i> , dan <i>customer happiness</i>	Analitik data umum, <i>white paper</i> vendor
Model kematangan DataOps industrial (Harrington 2021)	Empat tahap: <i>data access</i> , <i>data contextualization</i> , <i>site visibility</i> , dan <i>enterprise visibility</i>	Cakupan integrasi data operasional, dari akses data mesin, kontekstualisasi dan normalisasi data, hingga visibilitas lintas situs dengan <i>data governance</i>	Data industrial manufaktur, artikel vendor

Ketiga model menilai objek yang berbeda sehingga pemetaan skor kapabilitas lintas model seperti pada Tabel II.2 tidak diterapkan. Perbedaan fokus tiap model dibahas pada teks.

II.1.4 Integrasi DataOps dan MLOps

Jain dan Das (2025) menyatakan bahwa integrasi DataOps dan MLOps menjadi prasyarat skalabilitas dan ketahanan *pipeline machine learning* modern. Sementara itu, Burgueño-Romero dkk. (2025) mengusulkan arsitektur MLOps *open source* berbasis komponen, namun cakupannya berfokus pada jalur model dan belum membahas *feature serving dual-store* maupun kebijakan deteksi *drift* sebagai satu kesatuan dengan jalur data. Rodrigues dkk. (2025) membahas arsitektur untuk *stream learning* mendekati waktu nyata, dengan penekanan pada deteksi *drift* dan pembaruan model. Penelitian ini berada pada irisan ketiganya: arsitektur *open source* yang menyatukan DataOps dan MLOps, dengan layanan fitur *dual-store* dan deteksi *drift* terotomasi sebagai komponen inti.

Integrasi tersebut diwujudkan melalui tiga jembatan teknis yang dijelaskan pada Subbab II.4, Subbab II.6.1, dan Subbab II.9.1 serta dirancang pada Bab IV.

1. *Feature contract* pada Feast

Feast menyatukan *offline store* dan *online store* dengan satu definisi FeatureView, sehingga jalur DataOps yang menulis fitur dan jalur MLOps yang membaca fitur memakai kontrak yang sama.

2. *Lineage* terbuka melalui OpenLineage

OpenLineage menyalurkan jejak transformasi *pipeline* data dari Airflow, termasuk langkah dbt di dalamnya, ke satu jalur penerimaan DataHub sehingga asal-usul *training dataset* dapat dirunut dari katalog yang sama.

3. *Control Plane* deklaratif Argo CD

Argo CD merekonsiliasi manifes komponen DataOps dan MLOps dari satu repositori Gitea, sehingga kebijakan dan versi komponen tetap konsisten lintas dua disiplin.

II.2 Kubernetes dan Orkestrasi *Cloud-Native*

Seluruh komponen platform berjalan di atas Kubernetes, sehingga karakter *layer* orkestrasi ini perlu dipahami sebelum membahas komponen di atasnya. Pembahasan dibagi dua, yaitu peran Kubernetes beserta objek dasar dan pilihan distribusinya, kemudian mekanisme penskalaan otomatis beserta ekosistem *operator*. Urutan ini menempatkan konsep dasar sebelum mekanisme yang dibangun di atasnya. Rincian penerapannya pada tiap komponen dibahas pada Bab IV.

II.2.1 Peran, Objek Dasar, dan Distribusi

Kubernetes berperan sebagai bidang orkestrasi yang menjalankan beban kerja terkontainerisasi pada *cluster* mesin. Lakka (2025) mendokumentasikan adopsi Kubernetes pada skala perusahaan dan menyoroti perannya sebagai standar *de facto cloud-native*. Adusumilli (2025) memperluas perspektif tersebut dengan pola *serverless* di atas Kubernetes, yang relevan untuk beban kerja *inference* dengan pola lalu lintas berfluktuasi. Cloud Native Computing Foundation (2024a) memberikan referensi resmi mengenai objek-objek inti seperti Pod, Deployment, StatefulSet, Service, dan Ingress yang menjadi landasan setiap komponen platform.

Pemilihan Kubernetes sebagai bidang dasar memberi tiga keuntungan teknis: orkestrasi beban kerja melalui objek deklaratif, mekanisme penskalaan otomatis, dan ekosistem *operator* yang memperluas API *cluster* dengan *Custom Resource Definition* (CRD). Distribusi *lightweight* seperti *k3s* mengakomodasi pengembangan dan pengujian pada satu *node* tanpa mengorbankan kompatibilitas API. Pilihan distribusi tersebut sejalan dengan batasan implementasi BI-1 pada Bab V bahwa lingkungan pengujian memakai satu *node* dengan *footprint* sumber daya yang ringkas. Mekanisme *cluster autoscaler* tidak diaktifkan pada lingkungan satu *node*, sedangkan HPA, VPA, dan KEDA menjadi mekanisme penskalaan beban kerja yang dipakai.

Selain *k3s*, distribusi Kubernetes ringan lain yang umum dipertimbangkan untuk lingkungan satu *node* adalah *k0s*, MicroK8s, dan *kind*. Keempat distribusi lolos uji *conformance* CNCF sehingga API Kubernetes yang dipakai komponen platform tetap identik, sedangkan perbedaannya terletak pada *footprint*, kesiapan produksi, dan dependensi *runtime*. Perbedaan itu antara lain *containerd* yang tertanam pada *k3s* dan *k0s*, ketergantungan MicroK8s pada *snap*, serta *kind* yang menjalankan *node* di dalam kontainer Docker. Perbandingan berskor keempat distribusi terhadap kriteria kelayakan platform beserta alasan pemilihan *k3s* dibahas pada Subbab IV.3.

II.2.2 Penskalaan Otomatis dan Ekosistem *Operator*

Penskalaan otomatis pada Kubernetes bekerja pada tiga dimensi yang saling melengkapi. Dimensi horizontal menambah atau mengurangi jumlah *replica* suatu beban kerja mengikuti metrik pemakaian, dimensi vertikal menyetel *request* sumber daya per *pod* berdasarkan pengukuran historis, dan dimensi berbasis peristiwa menyesuaikan jumlah pemroses terhadap panjang antrean pada sumber eksternal. Ketiganya menjawab pola beban yang berbeda, yaitu lonjakan permintaan, ukuran *pod* yang tidak pas, dan antrean peristiwa yang menumpuk. Pemisahan dimensi ini membuat kebijakan penskalaan dapat dipasang per beban kerja tanpa saling bertabrakan.

Horizontal Pod Autoscaler (HPA) mewujudkan dimensi horizontal pada Deployment dan StatefulSet berdasarkan metrik CPU dan memori yang dipasok oleh Metrics Server. *Vertical Pod Autoscaler* (VPA) (Kubernetes Autoscaling SIG 2025) merekomendasikan dan menyetel *request* sumber daya pada level *pod*, sedangkan KEDA (KEDA Authors 2025) memperluas penskalaan ke sumber peristiwa eksternal melalui ScaledObject, termasuk *lag* antrean Kafka dan kueri metrik Prometheus. Dengan kombinasi tersebut, jumlah *replica* pemroses peristiwa mengikuti panjang antrean tanpa campur tangan manual. Pada platform ini, batas bawah *minReplicaCount* dipertahankan satu agar konsumen tetap siaga saat *idle*.

Komponen *operator* dan *runtime layer* menyediakan abstraksi tingkat tinggi bagi perangkat data, model, dan layanan. Strimzi (Strimzi Authors 2025) mengoperasikan kluster Apache Kafka beserta *Kafka Connect* melalui CRD seperti *Kafka*, *KafkaUser*, dan *KafkaTopic*. CloudNativePG (CloudNativePG Contributors 2025) mengelola siklus hidup kluster PostgreSQL, termasuk pencadangan dan *failover*. *Operator* Apache Flink (Apache Flink Authors 2025) dan *operator* Apache Spark (Apache Spark Authors 2025) menyiapkan *FlinkDeployment* dan *SparkApplication* sebagai unit kerja deklaratif, sedangkan *operator* Altinity untuk ClickHouse (Altinity 2025) menyediakan CRD *ClickHouseInstallation* un-

tuk replikasi dan *sharding*. Pada sisi *runtime*, Knative Serving (Knative Authors 2025) menambah kemampuan penskalaan ke nol pada beban kerja *request-response* dan menjadi fondasi bagi KServe. Kueue (Kueue Authors 2024) menyediakan antrian kerja untuk beban kerja *batch* sehingga prioritas dan kuota dapat ditegakkan lintas *namespace*. cert-manager (cert-manager Contributors 2025) mengotomasi penerbitan dan rotasi sertifikat TLS bagi *Ingress* dan *webhook* komponen platform.

II.3 Manajemen Data: *Ingestion, Processing, dan Storage*

Layer manajemen data mencakup jalur masuk data sampai tempat penyimpanannya. Pembahasan dimulai dari pola arsitektur aliran data, dilanjutkan konsep *ingestion* berbasis *message broker* serta dua pola pemrosesan, yaitu *stream* dan *batch* dengan transformasi SQL. Tiga subbab berikutnya membahas *storage layer*, dari format tabel *lakehouse*, penyimpanan objek dengan versi data, hingga penyimpanan relasional dan indeks pencarian. Urutan tersebut mengikuti arah aliran data pada platform, dari peristiwa masuk sampai data siap dikonsumsi oleh *layer* layanan fitur.

II.3.1 Pola Lambda dan Kappa

Marz dan Warren (2015) memperkenalkan arsitektur Lambda yang memisahkan *batch layer* dan *speed layer*. Kreps (2014) mengkritisi pola tersebut karena menduplikasi logika pemrosesan dan mengusulkan arsitektur Kappa yang menyatukan keduanya menjadi satu jalur *stream-first*. Amazon Web Services (2024) memberikan rangkuman pola *event-driven* yang banyak diadopsi di lingkungan *cloud-native*. Perbedaan pokok kedua pola terletak pada jumlah jalur pemrosesan yang harus dipelihara, sebab Lambda menuntut dua implementasi logika yang sama sedangkan Kappa memakai satu *event log* sebagai sumber pemutaran ulang.

Platform ini mengadopsi pola Kappa dengan modifikasi pada *processing layer*: aliran utama berjalan pada Flink untuk *streaming* sedangkan *backfill* historis dijalankan oleh Spark dan dbt pada referensi waktu yang sama. Pola tersebut menjaga konsistensi temporal antara fitur *streaming* dan fitur *batch* sebagaimana dijabarkan pada Subbab II.4.4. Pendekatan ini juga sejalan dengan rekomendasi Stopford (2018) mengenai *event log* sebagai sumber kebenaran tunggal. Hasilnya, kebutuhan *retraining* model yang melibatkan data historis dapat dijawab tanpa menyalin data ke jalur terpisah, sebab *offline store* ClickHouse dipopulasi dari *topic* Kafka yang sama.

II.3.2 *Message Broker dan Data Ingestion*

Jalur *ingestion* pada arsitektur *event-driven* bertumpu pada *message broker* berbentuk *distributed log*, yaitu menyimpan kejadian dalam urutan tertentu yang memungkinkan konsumen memutar ulang aliran data dari posisi mana pun (Apache Software Foundation 2024c). Model *log* tersebut menempatkan *broker* sebagai tulang punggung penghubung antara produsen data dan konsumen pemroses, sejalan dengan posisi *event log* sebagai sumber kebenaran tunggal pada rancangan sistem *event-driven* (Stopford 2018). Jaminan pengiriman dapat dipilih sesuai kebutuhan konsumen, dari *at-least-once* yang menoleransi duplikat sampai *exactly-once* yang memakai transaksi. Perbedaan antar *broker* pada praktiknya terletak pada jaminan pengiriman, kematangan *operator* Kubernetes, dan model lisensi.

Dua fungsi pendamping melengkapi jalur *ingestion* tersebut. *Schema registry* menyimpan skema pesan dan memverifikasi kompatibilitas saat publikasi, sehingga perubahan skema yang memutus konsumen lama tertahan dan evolusi kontrak data tetap kompatibel dengan versi sebelumnya. Kerangka konektor menjalankan integrasi sumber dan tujuan sebagai beban kerja terkelola, termasuk pola *change data capture* (CDC) yang membaca *write-ahead log* basis data dan menerbitkan perubahan baris sebagai peristiwa sehingga tabel relasional ikut ke jalur *streaming* tanpa kueri berkala. Antarmuka penelusuran kluster melengkapi operasi harian untuk memeriksa *topic*, *consumer group*, dan skema.

Contoh *message broker open source* dengan model *log* tersebut adalah Apache Kafka (Apache Software Foundation 2024c), Redpanda (Redpanda Data, Inc. 2025), Apache Pulsar (Apache Software Foundation 2025), dan NATS JetStream (NATS Authors 2025), dengan Kafka mendukung *at-least-once* secara baku dan *exactly-once* bertransaksi. Contoh *schema registry* pada ekosistem tersebut adalah Karapace (Aiven Karapace Authors 2025), *schema registry* kompatibel-Confluent berlisensi Apache 2.0 yang mendukung Avro, JSON Schema, dan Protobuf serta menyimpan skema pada *topic* internal Kafka sehingga tidak menambah basis data baru. Kerangka konektor diwujudkan oleh Kafka Connect (Apache Software Foundation 2024c), dengan Debezium (Debezium Community 2025) sebagai contoh konektor CDC yang membaca *write-ahead log* PostgreSQL, dan Kafbat UI (Kafbat Authors 2025) sebagai contoh antarmuka penelusuran kluster. Perbandingan berskor *message broker* dan *schema registry* beserta pemilihannya untuk platform dibahas pada Subbab IV.3.

II.3.3 *Stream Processing*

Pemrosesan *stream* mengolah aliran data begitu peristiwa tiba, dengan dua kemampuan yang menentukan kebenaran hasilnya, yaitu acuan waktu kejadian (*event-time*) dan operasi *stateful*. Carbone dkk. (2015) menjelaskan dasar *pipeline streaming* dengan kedua kemampuan tersebut, termasuk mekanisme *checkpointing* yang menjamin pemrosesan *exactly-once* ketika terjadi kegagalan. Penggunaan *event-time* alih-alih *processing-time* membuat hasil transformasi tetap konsisten ketika data terlambat tiba. Kemampuan tersebut dibutuhkan untuk transformasi fitur waktu nyata dan agregasi *rolling window* yang dikonsumsi model *streaming*.

Contoh mesin pemrosesan *stream open source* dengan kemampuan tersebut adalah Apache Flink, yang dokumentasi resminya menjabarkan *exactly-once processing* dengan *checkpointing* serta *watermark* untuk data terlambat (Apache Software Foundation 2024b). Pada Kubernetes, Flink umum dijalankan melalui CRD `FlinkDeployment` yang disediakan *operator* Apache Flink, dengan *checkpoint* dan *savepoint* ditulis ke penyimpanan objek S3-kompatibel agar pemulihan *job* tidak kehilangan keadaan. Alur kerjanya membaca *topic* dari *message broker*, melakukan transformasi pada *event-time* dengan *watermark* per partisi, lalu menerbitkan hasil ke *topic sink* yang dikonsumsi *layer* analitik. Perbandingan mesin pemrosesan data beserta pemilihannya untuk platform dibahas pada Subbab IV.3.

II.3.4 *Batch Processing* dan Transformasi SQL

Pemrosesan *batch* mengolah data historis bervolume besar pada referensi waktu tertentu, misalnya untuk *backfill* fitur dan penyiapan *training data*. Zaharia dkk. (2016) merangkum arsitektur mesin pemrosesan terpadu yang menangani beban *batch* skala besar pada satu kerangka eksekusi. Pada *warehouse layer*, transformasi SQL deklaratif memetakan model data ke berkas SQL dengan dukungan pengujian skema dan dokumentasi otomatis, sehingga rantai transformasi dapat diuji dan dirunut seperti kode. Kedua pola saling melengkapi, sebab mesin *batch* menangani pemrosesan yang melampaui kapasitas satu mesin SQL, sedangkan transformasi deklaratif menjaga *lineage* antar tabel *warehouse*.

Contoh perwujudan *open source* kedua pola tersebut adalah Apache Spark (Apache Software Foundation 2024d) untuk *batch* dan *micro-batch* serta dbt (dbt Labs 2025) untuk transformasi SQL deklaratif. Pada Kubernetes, *job* Spark dapat diserahkan langsung ke penjadwal klaster tanpa memelihara klaster *master-worker* yang menganggur, dengan orkestrator data sebagai pemicu *job* terjadwal. dbt memetakan mo-

del ke berkas SQL dengan fungsi *ref()* yang menjaga *lineage* antar tabel *medallion* dari *staging* hingga tabel fitur. Perbandingan pilihan mesin pemrosesan data menurut kriteria kelayakan platform dibahas pada Subbab IV.3.

II.3.5 Format Tabel *Lakehouse*

Penyimpanan jangka panjang pada *data lake* memerlukan format tabel yang menyediakan transaksi ACID, evolusi skema yang aman, dan ketertelusuran lintas *engine* pemrosesan, sementara penyimpanan langsung dalam berkas Parquet tanpa *layer* format tabel tidak menjamin keduanya. *Layer* format tabel membuka dua kemampuan turunan, yaitu *schema evolution* tanpa migrasi data fisik dan *time-travel* pada *snapshot* historis. Agar banyak *engine* dapat membaca dan menulis tabel yang sama, metadata tabel dikelola oleh *catalog server* yang diakses melalui antarmuka bersama. Kueri lintas sumber data kemudian disatukan oleh *query engine* federatif sehingga analisis tidak terkunci pada satu tempat penyimpanan.

Apache Iceberg, Delta Lake, dan Apache Hudi merupakan tiga format tabel *open-source* yang umum dipakai untuk arsitektur *lakehouse*. Contoh *catalog server* REST untuk Iceberg adalah Lakekeeper (Lakekeeper Authors 2025), yang menyimpan metadata pada PostgreSQL sehingga *engine* pemrosesan seperti Trino, Spark, dan Flink membaca dan menulis tabel yang sama, sedangkan Trino (Trino Software Foundation 2024) menjadi contoh *query engine* federatif yang menjangkau ClickHouse, PostgreSQL, dan tabel Iceberg melalui satu jalur SQL. Susunan *open source* semacam ini sejalan dengan batasan implementasi BI-2 pada Bab V yang menghindari ketergantungan pada katalog terkelola berbayar. Perbandingan format tabel *lakehouse* terhadap kriteria yang relevan beserta pemilihannya untuk platform dibahas pada Subbab IV.3.

II.3.6 Penyimpanan Objek dan Versi Data

Object storage layer menjadi landasan bagi *data lake*, *model registry*, dan pencadangan, dengan antarmuka S3 sebagai kontrak akses yang umum dipakai lintas komponen. Kebutuhan enkripsi data *at rest* pada *layer* ini dijawab oleh enkripsi sisi *server* yang kuncinya dikelola melalui *key management service* (KMS). Di atas *layer* objek, pengelola versi data menambahkan model *branching* dan *commit* bergaya Git pada *bucket*, sehingga jejak versi data dapat dirunut tanpa menggandakan berkas. Pola pemakaiannya mengikuti alur *branch-merge*, yaitu setiap eksekusi *pipeline batch* menulis pada *branch* terpisah dan baru digabungkan ke *branch* utama setelah gerbang kualitas lolos, sehingga data yang dipublikasikan selalu melewati

pemeriksaan.

Empat penyedia objek S3-kompatibel *open source* yang umum dipertimbangkan adalah MinIO (MinIO, Inc. 2024), Ceph RGW (Ceph Authors 2025), SeaweedFS (SeaweedFS Authors 2025), dan Garage (Deuxfleurs Association 2025), dengan MinIO menyediakan *Server-Side Encryption with KMS* (SSE-KMS) yang dijemput ke KES ke pengelola rahasia sebagaimana dibahas pada Subbab II.10. Contoh pengelola versi data adalah lakeFS (Treeverse Ltd. 2025) dengan model *branching* pada *bucket* objek, DVC (Iterative, Inc. 2025) yang menautkan versi data ke repositori Git, Project Nessie (Project Nessie Authors 2025) yang memberi versi pada katalog Iceberg, dan Pachyderm (Pachyderm, Inc. 2025) yang menggabungkan versi data dengan eksekusi *pipeline*. Pemisahan *bucket* per kepentingan membuat kebijakan versi, retensi, dan akses dapat diatur tanpa saling mengganggu, dan kombinasi penyimpanan datar dengan penyimpanan bercabang melayani artefak tanpa versi maupun data *pipeline* yang memerlukan *point-in-time*. Perbandingan berskor penyedia objek dan pengelola versi data beserta pemilihannya untuk platform dibahas pada Subbab IV.3.

II.3.7 Penyimpanan Relasional dan Pencarian

Sebagian besar layanan platform memerlukan basis data relasional untuk menyimpan metadata, dari riwayat eksperimen sampai status *pipeline*. Pemisahan *metadata storage layer* mengikuti karakter beban kerja dan kompatibilitas protokol, sebab sebagian layanan dapat memakai basis data relasional mana pun, sebagian terikat pada *wire-protocol* tertentu, dan fungsi pencarian teks serta graf metadata menuntut indeks pencarian tersendiri. Dengan pemisahan tersebut, tiap *layer* dapat dioperasikan, diskalakan, dan dicadangkan sesuai karakternya. Pencadangan ketiga *layer* dijalankan terjadwal agar metadata dapat dipulihkan bersama data yang dirujuknya.

PostgreSQL (PostgreSQL Global Development Group 2025) menjadi contoh basis data relasional utama yang umum dioperasikan melalui *operator* seperti CloudNativePG sebagaimana dibahas pada Subbab II.2, dan pada platform ini melayani metadata MLflow, Airflow, DataHub, lakeFS, Lakekeeper, SpiceDB, dan Superset. MySQL (Oracle Corporation 2025) melayani *metadata store* Kubeflow Pipelines (ML Metadata) dan Katib yang terikat pada protokol MySQL. OpenSearch (OpenSearch Foundation 2025) menjadi contoh indeks pencarian yang melayani pencarian teks dan *lineage graph* DataHub dengan dukungan kueri graf, berjalan dengan satu peran gabungan pada lingkungan satu *node* dan dapat dipecah menjadi peran terpisah (master, data, ingest) pada lingkungan multi-*node*. Pencadangan

ketiganya dijalankan oleh Velero dengan jadwal harian dan retensi 30 hari.

II.4 Layanan Fitur (*Feature Store*)

Layanan fitur menghubungkan jalur data dengan jalur model sehingga keduanya membaca definisi fitur yang sama. Peran *feature store* sebagai penyatu fitur dibahas terlebih dahulu, disusul pemisahan penyimpanan *offline* dan *online* yang menjadi inti arsitektur *dual-store*. Dua subbab berikutnya membahas pencarian vektor untuk fitur *embedding* serta jaminan *point-in-time correctness* yang mencegah kebocoran temporal. Keempat topik tersebut menjadi dasar perancangan *layer* layanan fitur pada Bab IV.

II.4.1 Peran *Feature Store* sebagai Penyatu Fitur

Feature store berperan sebagai *layer* penyatu antara produksi fitur dan konsumsi fitur. Lamer dkk. (2024) menjelaskan posisi *feature store* di antara *data lake*, *data warehouse*, dan *datamart*, sebagai komponen yang menyiapkan fitur untuk konsumsi model. Li dkk. (2023) menjabarkan arsitektur *feature store geo-distributed* dan menekankan pentingnya kontrak fitur yang seragam antara *batch* dan *online*. Kartakis dkk. (2022) menempatkan *feature store* terkelola sebagai salah satu komponen pondasi dalam peta jalan MLOps tingkat perusahaan.

Tiga peran utama *feature store* adalah: (1) menyimpan fitur dengan kontrak skema yang konsisten lintas konsumen, (2) penyedia *point-in-time join* antara entitas dan fitur historis untuk pelatihan, dan (3) penyedia *lookup* fitur berlatensi rendah untuk *inference*. Tanpa *feature store*, ketiga peran tersebut harus dirakit ulang oleh setiap tim yang menyajikan model, sehingga muncul duplikasi kontrak dan risiko *train-serving skew* yang dibahas oleh Breck dkk. (2017). Contoh perwujudan *open source* peran tersebut adalah Feast sebagai *control plane feature store* yang menghubungkan *offline store*, *online store* untuk *tabular feature* dan *aggregate feature*, serta *vector index* untuk fitur *embedding* pada satu *FeatureView*, sehingga konsumen pelatihan dan konsumen *serving* membaca kontrak yang sama. Ketiga jenis penyimpanan tersebut dibahas pada subbab-subbab berikutnya.

II.4.2 Penyimpanan *Offline* dan *Online*

Penyimpanan *offline* dipakai untuk pelatihan dan *batch scoring*, sedangkan penyimpanan *online* dipakai untuk *inference* dengan latensi rendah. Pemisahan ini mengikuti perbedaan pola akses, yaitu pemindaian historis bervolume besar pada satu sisi

dan *lookup* per entitas dalam hitungan milidetik pada sisi lain. Penyimpanan *offline* karena itu umumnya berbentuk penyimpanan kolumnar yang dioptimasi untuk kueri agregasi pada jutaan baris, sedangkan penyimpanan *online* berbentuk struktur kunci-nilai pada memori dengan latensi *lookup* sub-milidetik. Nilai fitur berpindah dari *offline* ke *online* melalui materialisasi terjadwal sehingga kedua sisi membaca definisi fitur yang sama.

Contoh susunan *open source* untuk pola ini adalah Feast (Feast Project 2024) sebagai kerangka *feature store*, ClickHouse (ClickHouse Inc 2024) sebagai *offline store* kolumnar dengan kompresi LZ4 atau ZSTD yang cocok untuk pembuatan *training dataset* dengan *point-in-time join*, dan Valkey (Valkey Contributors 2025) sebagai *online store* kunci-nilai untuk *inference* dengan ribuan *lookup* per detik. Materialisasi dari *offline* ke *online* berjalan sebagai *job* terjadwal berdasarkan FeatureView, dengan dukungan inkremental untuk fitur yang sering berubah dan dukungan penuh untuk fitur historis. Kontrak fitur pada kerangka semacam ini menjadi satu-satunya definisi yang dibaca konsumen pelatihan maupun *serving*. Perbandingan berskor kerangka *feature store* serta pilihan penyimpanan *offline* dan *online* beserta pemilihannya dibahas pada Subbab IV.3.

II.4.3 Pencarian Vektor dan HNSW

Fitur *embedding* berdimensi tinggi memerlukan struktur indeks pendekatan tetangga terdekat (*approximate nearest neighbor*, ANN). Malkov dan Yashunin (2020) memperkenalkan *Hierarchical Navigable Small World* (HNSW) sebagai struktur indeks dengan keseimbangan baik antara kecepatan kueri dan kualitas hasil, sementara *Product Quantization* (Jegou, Douze, dan Schmid 2011) dan pencarian skala miliar dengan GPU (Johnson, Douze, dan Jégou 2021) relevan untuk skala yang berbeda. Pola *hybrid search* yang menggabungkan kueri vektor dengan filter atribut banyak diadopsi pada sistem *retrieval* modern (Bruch, Gai, dan Ingber 2023). Devlin dkk. (2019) dan OpenAI (2022) memberi konteks mengenai sumber *embedding* dari model bahasa yang umum menjadi masukan *vector index*.

Contoh *vector index open source* dengan indeks HNSW dan dukungan *hybrid search* tersebut adalah Qdrant (Qdrant Team 2025), yang umumnya dipisahkan dari *online store* tabular karena pola aksesnya berbeda. Parameter indeks seperti *m* dan *ef_construct* dapat ditingkatkan ketika rasio *recall* perlu diperbesar, dan metrik jarak *collection* umumnya memakai kosinus untuk *embedding* yang dinormalkan. Penyimpanannya memakai *persistent volume* dengan kunci akses yang mengikuti pola pengelolaan rahasia komponen lain pada kluster. Perbandingan beberapa pilih-

an *vector index open-source* beserta pemilihannya dibahas pada Subbab IV.3.

II.4.4 *Point-in-Time Correctness*

Jaminan *point-in-time correctness* berarti nilai fitur yang dipakai saat *model training* harus identik dengan nilai yang tersedia pada saat itu, bukan nilai versi terkini. Kaufman dkk. (2012) merumuskan kebocoran data sebagai kondisi ketika proses pelatihan memakai informasi yang belum tersedia pada saat prediksi dilakukan, dan menunjukkan bahwa kondisi tersebut membuat hasil evaluasi model tampak lebih baik daripada kinerja sesungguhnya. Penegakannya memakai operasi *point-in-time join* antara entitas dan riwayat fitur, sehingga konsistensi nilai antara fase *training* dan fase *inference* terjaga. Vela dkk. (2022) menambah perspektif evaluasi temporal pada pemodelan urut waktu yang sejalan dengan kebutuhan *point-in-time*.

Pada kerangka *feature store* seperti Feast, jaminan tersebut ditegakkan oleh dua mekanisme. Pertama, operasi `get_historical_features` melakukan *point-in-time join* dengan `FeatureView` yang mendaftarkan kolom `event_timestamp` sebagai acuan *join* historis dan kolom `created_timestamp` sebagai penanda waktu penulisan fitur. Kedua, *online store* memakai versi terbaru dari nilai fitur sehingga *lookup* saat *inference* membaca nilai yang konsisten dengan `event_timestamp` terkini. Kombinasi keduanya menekan peluang kebocoran temporal saat pelatihan dan menjaga konsistensi nilai antara kedua fase.

II.5 *Model Lifecycle*

Model lifecycle mencakup tahap eksperimen sampai model tersaji sebagai layanan. Pembahasan dimulai dari *tracking* eksperimen dan *registry* model, dilanjutkan orkestrasi *training pipeline*. Dua subbab berikutnya membahas lingkungan eksperimen interaktif beserta *hyperparameter tuning*, kemudian *model serving* pada *inference layer*. Urutan tersebut mengikuti perjalanan model dari kode eksperimen sampai *endpoint* yang dipantau.

II.5.1 *Eksperimen dan Tracking*

Tracking eksperimen mencatat parameter, metrik, dan artefak setiap percobaan pelatihan pada satu tempat, sedangkan *registry* model menyimpan versi model yang siap dipromosikan ke lingkungan *serving*. Pimentel dkk. (2019) menyoroti masalah reproduksibilitas *notebook*, yang menjadi alasan mengapa *tracking* terpusat menjadi prasyarat sebelum hasil eksperimen dipercaya. Anaconda, Inc. (2020) memberikan

konteks lapangan mengenai praktik kerja *data scientist* yang dapat dijadikan acuan saat memilih alat *tracking*. Tanpa kedua fungsi tersebut, jejak eksperimen tersebar pada *notebook* perorangan dan versi model tidak memiliki sumber kebenaran.

Contoh alat *open source* untuk fungsi ini adalah MLflow (MLflow Contributors 2024), yang menyediakan *tracking* eksperimen, *registry* model, dan API *deployment* dengan basis data relasional sebagai *backend store* dan penyimpanan objek sebagai *artifact store*. Penempatan artefak pada *layer* objek membuat kebijakan enkripsi dan pencadangan *layer* tersebut berlaku seragam untuk artefak eksperimen. *Registry* model menjadi sumber kebenaran versi model yang dipromosikan oleh *pipeline continuous training* ke *serving layer*, dan akses konsolnya dapat disatukan pada jalur autentikasi terpusat sebagaimana dibahas pada Subbab II.10. Perbandingan beberapa pilihan platform *tracking* dibahas pada Subbab IV.3.

II.5.2 Orkestrasi Pelatihan

Orkestrasi pelatihan merangkai langkah eksperimen menjadi *pipeline* berbentuk graf berarah yang dapat dijadwalkan, diberi parameter, dan diulang. Kebutuhan orkestrasinya terbagi dua, yaitu *training pipeline* yang menghasilkan dan mempromosikan model, dan *control loop* berkala yang membaca sinyal pemantauan lalu memutuskan kapan *retraining* dipicu. Pemisahan keduanya menjaga *training pipeline* tetap menjadi unit kerja yang dipicu, sementara keputusan pemicuan berada pada penjadwal terpisah. Orkestrasi *pipeline* data berorientasi *batch* berjalan pada penjadwal tersendiri agar tanggung jawab DataOps dan MLOps tidak bercampur pada satu *controller*.

Dua pilihan utama orkestrasi pelatihan pada Kubernetes adalah Kubeflow Pipelines (Kubeflow Contributors 2024) dan Argo Workflows (Argo Project 2025), sedangkan Apache Airflow (Apache Software Foundation 2024a) tetap relevan untuk *pipeline* data berorientasi *batch*. *Controller* Argo Workflows disertakan oleh instalasi Kubeflow Pipelines sehingga kedua *orchestrator* dapat berjalan pada *namespace* yang sama tanpa dua instalasi *workflow engine* yang tumpang tindih. Pola pembagian perannya menempatkan *training pipeline* pada Kubeflow Pipelines dan *control loop* berbentuk CronWorkflow pada Argo Workflows yang membaca skor *drift* lalu memicu *retraining*. Perbandingan ketiganya berdasarkan kebutuhan domain beserta pemilihannya dibahas pada Subbab IV.3.

II.5.3 Eksperimen Interaktif dan *Tuning*

Lingkungan eksperimen interaktif menyediakan *notebook* multi-pengguna di atas kluster dengan tata kelola sumber daya per pengguna, sehingga eksperimen berjalan dekat dengan data tanpa membebani mesin lokal. Pencarian *hyperparameter* mengotomasi pemilihan konfigurasi pelatihan melalui strategi *grid*, *random*, *Bayesian*, hingga *neural architecture search*. Pelatihan terdistribusi membagi satu pekerjaan pelatihan ke beberapa *worker* ketika ukuran model atau data melampaui satu mesin. Vangala, Mehta, dan Singh (2022) memberi gambaran praktik MLOps di lapangan yang menempatkan ketiga fungsi tersebut sebagai bagian dari satu *layer* pengembangan model.

Contoh perwujudan *open source* ketiga fungsi tersebut pada Kubernetes adalah Kubeflow Notebooks (Kubeflow Authors 2025b) dengan *notebook-controller* yang merekonsiliasi CRD Notebook menjadi StatefulSet per pengguna dan *jupyter-web-app* sebagai antarmuka pembuatan *notebook*, Katib (Kubeflow Authors 2025a) yang menjalankan pencarian melalui Experiment CRD dengan *trial* sebagai Job berlabel dan algoritme pencarian pada *suggestion service* terpisah, serta Kubeflow Trainer (Kubeflow Authors 2025c) yang menyediakan CRD TrainJob dengan *runtime* bawaan untuk kerangka seperti PyTorch dan DeepSpeed. Kubeflow Notebooks dapat dipasang *standalone* tanpa Profile CRD ketika isolasi *multi-tenant* tidak dibutuhkan, misalnya pada lingkungan pengujian satu *node*. Kuota sumber daya ditekankan melalui *request* dan *limit* pada spesifikasi *notebook*, yang dapat diperkuat kebijakan validasi *policy engine* sebagaimana dibahas pada Subbab II.10. Pelatihan terdistribusi melalui TrainJob menjadi relevan ketika kluster diperluas menjadi *multi-node*.

II.5.4 *Model Serving*

Kerangka *model serving* mengubah artefak model menjadi layanan *inference* dengan tiga kemampuan inti, yaitu dukungan banyak *runtime*, otomatisasi penskalaan termasuk ke nol saat sepi, dan jalur *deployment* progresif yang menahan versi bermasalah. Hsu dkk. (2024) memperlihatkan uji coba *deployment* model terotomasi pada Kubernetes yang sejalan dengan pendekatan platform ini, dan Liang dkk. (2024) menyoroti integrasi sistem dengan *machine learning* sebagai pendorong otomatisasi pelatihan dan *deployment*. Ahmad dkk. (2024) memberikan tinjauan strategi keamanan MLOps yang relevan untuk *serving layer*. Pemantauan kualitas prediksi sebaiknya tidak dibebankan pada jalur *inference* agar latensi *serving* tidak terganggu, sehingga deteksi *drift* membaca tabel fitur pada *layer* analitik melalui *job* terjadwal

sebagaimana dibahas pada Subbab II.7.

Contoh kerangka *serving open source* dengan kemampuan tersebut adalah KServe (KServe Contributors 2024), yang dijalankan melalui InferenceService CRD dengan *predictor*, *transformer*, dan *explainer* yang dapat dirangkai pada satu jalur serta integrasi dengan praktik GitOps. *Serving runtime*-nya didefinisikan melalui ClusterServingRuntime, misalnya MLServer untuk model dari *registry* MLflow, sementara *runtime* bawaan lain seperti Triton Inference Server dapat ditambahkan ketika model jaringan saraf dalam dibutuhkan. Kemampuan penskalaan ke nol disediakan oleh Knative Serving sebagai fondasinya, dengan batas bawah satu *replica* dapat dipertahankan agar permintaan pertama tidak menanggung *cold start*, dan *deployment* progresif pada layanan di depan model dijalankan oleh Argo Rollouts dengan strategi *canary*. Perbandingan KServe dengan kerangka *model serving* lain menurut kriteria kelayakan platform dibahas pada Subbab IV.3.

II.6 Tata Kelola Data: Katalog, *Lineage*, dan Kualitas

Tata kelola data menjaga agar aset data dapat ditemukan, dirunut asal-usulnya, dan dipercaya isinya sepanjang siklus data dan model. Subbab ini membaginya menjadi dua bagian yang saling melengkapi. Bagian pertama membahas katalog metadata dan *lineage* sebagai sarana penemuan aset dan penelusuran asal-usulnya. Bagian kedua membahas kontrak dan pengujian kualitas data yang menjaga isi aset tetap sesuai dengan harapan sebelum dikonsumsi oleh *layer* di atasnya.

II.6.1 Katalog Metadata dan *Lineage*

Bernardo dkk. (2024) memetakan tata kelola data sebagai disiplin lintas fungsi yang mencakup metadata, kualitas, akses, dan kepemilikan. Dua di antara aspek tersebut, yaitu katalog metadata dan *lineage*, menjadi tumpuan penemuan aset dan penelusuran asal-usulnya. Katalog metadata memberi tempat terpusat untuk menemukan aset data beserta pemiliknya, sedangkan *lineage* merekam asal-usul setiap aset dari sumber hingga konsumennya. Stoyanovich, Howe, dan Jagadish (2020) menempatkan tanggung jawab atas data pada level platform, bukan hanya level aplikasi, sehingga penelusuran asal-usul perlu ditegakkan sebagai kapabilitas bersama, bukan tanggung jawab tiap tim secara terpisah.

Contoh perwujudan *open source* kedua aspek tersebut adalah DataHub (DataHub Project 2024) sebagai katalog metadata dan OpenLineage (OpenLineage Authors 2025) sebagai standar terbuka pengumpulan *lineage* antar komponen *pipeline*. Data-

Hub menyimpan metadata aset beserta relasinya sehingga aset data dapat ditemukan dan ditelusuri kepemilikannya dari satu antarmuka. OpenLineage menyusun jejak dari *ingestion* hingga model dengan kosakata yang seragam sehingga asal-usul aset dapat dirunut lintas komponen *pipeline*. Perbandingan beberapa pilihan katalog beserta pemilihannya dibahas pada Subbab IV.3.

II.6.2 Kontrak dan Pengujian Kualitas Data

Kontrak kualitas data menjaga agar isi aset tetap sesuai dengan harapan, melengkapi katalog dan *lineage* yang mencatat keberadaan dan asal-usulnya. Chien (2022) memberi panduan praktis untuk peningkatan kualitas data berbasis pengukuran, sehingga kualitas dapat dipantau sebagai metrik alih-alih dinilai secara subjektif. Kontrak semacam ini memeriksa kesesuaian skema dan rentang nilai pada titik-titik *pipeline* sebelum data mengalir ke tahap berikutnya. Dengan pemeriksaan yang dijalankan sebagai bagian permanen dari operasi, cacat data tertahan lebih awal sebelum mengalir ke fitur dan model di *layer* atasnya.

Contoh perwujudan *open source* kontrak kualitas tersebut adalah Great Expectations (Great Expectations 2024) untuk pengujian kontrak data pada *pipeline* produksi. Kontrak kualitas umum dikemas sebagai *expectation suite* yang bersversi pada repositori Git dan dijalankan sebagai gerbang kualitas terjadwal pada *pipeline* data. Pemeriksaan kualitas tambahan dapat dipasang pada *pipeline lakehouse* sebelum *branch* data digabungkan ke *branch* utama, sejalan dengan alur *branch-merge* pada Subbab II.3.6. Penegakan kebijakan akses atas aset yang telah lolos pemeriksaan tersebut ditangani oleh *layer* keamanan pada Subbab II.10.

II.7 Deteksi *Drift*

Deteksi *drift* menjaga agar model tetap valid ketika distribusi data bergeser dari kondisi saat model dilatih. Subbab ini membahasnya dalam dua bagian. Bagian pertama menguraikan jenis *drift* beserta metrik statistik yang dipakai untuk mendeteksinya. Bagian kedua menjelaskan bagaimana metrik tersebut dijalankan sebagai deteksi terjadwal yang menjadi pemicu *retraining* otomatis.

II.7.1 Jenis *Drift* dan Metrik Statistik

Lu dkk. (2019) memberikan tinjauan luas tentang pembelajaran di bawah *concept drift*, yaitu kondisi ketika hubungan antara masukan dan keluaran model berubah seiring waktu. Perubahan semacam ini membuat model yang semula akurat perlahan-

an kehilangan validitasnya apabila tidak ditangani. Bayram, Ahmed, dan Kassler (2022) mengelompokkan keluarga detektor berbasis performa yang memantau penurunan metrik prediksi sebagai sinyal *drift*. Hinder dkk. (2023) memperluas pembahasan ke arah penjelasan model sehingga *drift* tidak hanya terdeteksi, tetapi juga dapat ditelusuri penyebabnya.

Beberapa metrik yang relevan untuk *covariate drift* dan *prior probability shift* antara lain *Population Stability Index* (PSI), uji Kolmogorov-Smirnov (KS) (Reis dkk. 2016), dan jarak Wasserstein. PSI mengukur pergeseran distribusi suatu fitur antara jendela referensi dan jendela terkini, sedangkan uji Kolmogorov-Smirnov membandingkan fungsi distribusi kumulatif kedua jendela. Jarak Wasserstein memberi ukuran perbedaan distribusi yang peka terhadap besar pergeseran, bukan sekadar ada atau tidaknya perbedaan. Céspedes Sisniega dkk. (2024) memperlihatkan implementasi deteksi *drift* pada lingkungan *serverless*, sementara Jourdan dkk. (2023) membahas penanganan *drift* pada *deep learning* untuk pemantauan proses.

II.7.2 Deteksi Terjadwal dan Pemicu *Retraining*

Deteksi *drift* pada produksi umumnya dijalankan sebagai proses terjadwal yang membandingkan jendela data terkini terhadap jendela referensi bergulir pada beberapa skala waktu. Ambang batas ditetapkan per fitur sehingga sensitivitas deteksi dapat disesuaikan dengan karakteristik tiap fitur. Skor *drift* yang dihasilkan tiap eksekusi disimpan sebagai deret waktu agar riwayatnya dapat diaudit dan dibandingkan antar periode. Ketika skor melampaui ambang, sebuah *control loop* berkala membaca sinyal tersebut lalu memicu *retraining* model tanpa campur tangan manual.

Contoh perwujudan *open source* alur tersebut menempatkan detektor PSI dan uji Kolmogorov-Smirnov sebagai *job* terjadwal yang membaca langsung tabel fitur ClickHouse dan menuliskan skor *drift* ke tabel analitik serta metrik Prometheus. CronWorkflow Argo membaca skor tersebut sebagai *control loop* dan memicu *retraining* melalui Kubeflow Pipelines apabila ambang dilewati. Evidently (Evidently AI 2025) melengkapi jalur tersebut sebagai layanan pelaporan yang menghasilkan laporan *data drift* dan ringkasan data ke *workspace* Evidently untuk ditelaah secara visual. Detektor tersebut sengaja dipisahkan dari jalur *inference* agar pemantauan kualitas prediksi tidak menambah latensi *serving*, sejalan dengan pemisahan yang dibahas pada Subbab II.5.4.

II.8 Observabilitas *Cloud-Native*

Observabilitas memungkinkan kondisi internal platform dibaca dari sinyal yang dikeluarkannya, sebuah prasyarat untuk mengoperasikan banyak komponen data dan model sekaligus. Subbab ini dibagi menjadi dua bagian. Bagian pertama membahas tiga pilar dasar observabilitas, yaitu metrik, log, dan *trace*, beserta cara mengorelasikannya. Bagian kedua membahas kebutuhan turunan di atas ketiga pilar tersebut dan antarmuka analitik yang menyajikan kondisi sistem dari satu tempat.

II.8.1 Metrik, Log, dan *Trace*

Cloud Native Computing Foundation (2024b) dan IBM (2024) mendefinisikan observabilitas sebagai gabungan tiga pilar: metrik, log, dan *trace*. Metrik merekam ukuran numerik deret waktu, log merekam peristiwa tekstual, dan *trace* merekam perjalanan satu permintaan lintas layanan. Korelasi antar pilar dimungkinkan melalui label `trace_id` yang dilampirkan pada baris log dan rentang *trace*, sehingga pelacakan kegagalan dapat berpindah antar pilar tanpa kehilangan konteks. Ketiga pilar tersebut menjadi landasan yang di atasnya kebutuhan pemantauan lain pada platform data dan model dibangun.

Prometheus (Prometheus Authors 2024) untuk metrik, Loki (Grafana Labs 2024b) untuk log, dan Grafana Tempo (Grafana Labs 2024c) untuk *trace* merupakan contoh perwujudan *open source* ketiga pilar tersebut. OpenTelemetry (OpenTelemetry Authors 2025) berperan sebagai *collector* bersama yang menyeragamkan pengumpulan sinyal dari berbagai komponen sebelum diteruskan ke penyimpanan tiap pilar. Grafana (Grafana Labs 2024a) menjadi antarmuka visualisasi satu pintu yang membaca ketiga pilar sehingga penelusuran kegagalan dapat berpindah antar pilar tanpa berganti antarmuka. Susunan ini menjaga jejak metrik, log, dan *trace* tetap dapat dikorelasikan melalui label `trace_id` yang sama.

II.8.2 Kebutuhan Turunan dan Antarmuka Analitik

Di atas ketiga pilar dasar, platform data dan model menuntut sejumlah kebutuhan turunan. Penurunan *service-level objective* (SLO) menjadi aturan peringatan membuat sasaran layanan dapat dipantau otomatis, *continuous profiling* merekam profil CPU dan memori dari beban kerja yang berjalan, dan titik kumpul metrik menampung *job* berdurasi pendek yang selesai di luar siklus *scrape*. Pemantauan biaya per beban kerja melengkapinya dengan visibilitas atas konsumsi sumber daya tiap komponen. Di atas pilar teknis tersebut, antarmuka BI menyajikan kueri SQL lintas

sumber data pada satu *dashboard layer* untuk konsumsi analitik.

Contoh perwujudan *open source* kebutuhan turunan tersebut adalah Sloth (Sloth Authors 2025) yang menurunkan definisi SLO ke aturan Prometheus, Pyroscope (Grafana Labs 2025) yang menyediakan *continuous profiling*, Pushgateway (Prometheus Authors 2025) sebagai titik kumpul metrik *job* pendek, dan OpenCost (OpenCost Authors 2025) yang memantau biaya per beban kerja. Evidently (Evidently AI 2025) memberi laporan kualitas data dan model yang melengkapi pilar observabilitas dari sisi mutu prediksi. Apache Superset (Apache Superset Authors 2025) menjadi contoh antarmuka BI yang menyatukan kueri SQL lintas ClickHouse, Trino, dan MySQL, sementara *dashboard* kualitas data dan model dapat dirangkai pada Grafana agar pengamatan kondisi sistem berlangsung dari satu antarmuka. Perbandingan beberapa pilihan *observability stack* dan *BI open-source* dibahas pada Subbab IV.3.

II.9 GitOps dan *Continuous Delivery*

GitOps menjadikan repositori Git sebagai sumber kebenaran tunggal sehingga operasi platform dapat ditinjau dan dipulihkan seperti perubahan kode. Subbab ini membahasnya dalam dua bagian yang mengikuti alur perubahan dari sumber ke produksi. Bagian pertama membahas rekonsiliasi deklaratif dan integrasi berkelanjutan yang menyamakan keadaan *cluster* dengan deklarasi pada Git. Bagian kedua membahas *deployment* progresif yang membatasi dampak versi bermasalah saat perubahan dirilis.

II.9.1 Rekonsiliasi Deklaratif dan Integrasi Berkelanjutan

GitOps menempatkan repositori Git sebagai sumber kebenaran tunggal untuk konfigurasi sistem. Limoncelli (2018) menjelaskan pola GitOps sebagai pendekatan IT *self-service* yang memetakan operasi ke kontrol versi, dan Kim dkk. (2016) memberi dasar teoretis tentang alur kerja CI/CD yang menjadi induk GitOps. Pada bagian hulu pola ini, *operator* rekonsiliasi menyamakan keadaan *cluster* dengan deklarasi pada Git, sementara *pipeline* CI membangun dan menguji perubahan sebelum digabungkan ke *branch* utama. Dengan pola tersebut, setiap perubahan sistem dapat ditinjau, diaudit, dan dipulihkan sebagai perubahan Git biasa.

Argo CD (Argo Project 2024) merupakan contoh perwujudan *open source* bagian tersebut sebagai *operator* GitOps yang merekonsiliasi keadaan *cluster* dengan deklarasi Git. Gitea (Gitea Contributors 2025) menyediakan layanan Git *self-hosted*

ringan dengan API yang umum sehingga seluruh manifes, *chart* Helm, dan *overlay* Kustomize berada pada satu *control plane* tanpa ketergantungan penyedia eksternal. Tekton (Tekton Contributors 2024) menjalankan *pipeline* CI dengan rangkaian *task* kloning sumber, penggabungan *overlay* konfigurasi, *lint*, pengujian, serta *build* dan *push image*. Perbandingan beberapa *GitOps controller open-source* berdasarkan kriteria yang relevan dibahas pada Subbab IV.3.

II.9.2 Deployment Progresif

Deployment progresif merilis versi baru secara bertahap agar dampak versi bermasalah terbatas pada sebagian kecil lalu lintas. Strategi *canary* mengarahkan sebagian kecil permintaan ke versi baru lebih dahulu, lalu menaikkan persinya hanya ketika metrik yang dipantau tetap sehat. Analisis metrik otomatis membandingkan versi baru terhadap ambang pada tiap tahap kenaikan dan membatalkan promosi begitu indikator memburuk. Dengan pola tersebut, kegagalan versi baru terdeteksi pada porsi lalu lintas kecil sebelum berdampak pada seluruh pengguna.

Contoh perwujudan *open source* pola tersebut adalah Argo Rollouts (Argo Rollouts Authors 2025) yang menyediakan strategi *deployment* progresif berbasis *canary* dengan analisis metrik pada layanan di depan model. Argo Rollouts menaikkan porsi lalu lintas ke versi baru secara bertahap dan menghentikan promosi otomatis ketika metrik melewati ambang yang ditetapkan. Pelaporan metrik *pipeline* CI dapat diakhiri *task finally* yang mengirim hasilnya ke titik kumpul metrik sebagaimana dibahas pada Subbab II.8. Rangkaian tersebut melengkapi rekonsiliasi pada Subbab II.9.1 sehingga perubahan yang telah tergabung dapat dirilis dengan risiko yang terkendali.

II.10 Keamanan Platform: Identitas, Rahasia, *Mesh*, dan Kebijakan

Layer keamanan menjadi prasyarat bagi platform yang melayani DataOps dan MLOps secara berdampingan. Empat aspek dipertimbangkan: identitas pengguna terpadu, pengelolaan rahasia, *service mesh* beserta *API gateway* pada perbatasannya, dan *policy engine*. Empat aspek tersebut bekerja sebagai *layer* pertahanan yang saling melengkapi, sesuai prinsip *defense in depth* yang dibakukan pada panduan rekayasa sistem aman NIST SP 800-160 (Ross, Winstead, dan McEville 2022). Pelanggaran pada satu *layer* tidak otomatis membuka akses ke *layer* berikutnya sebab tiap *layer* menegakkan kontrol yang berbeda jenis: identitas mengontrol *siapa*, rahasia mengontrol *apa yang dipegang*, *mesh* mengontrol *siapa berbicara ke siapa*, dan kebijakan mengontrol *apa yang boleh dibuat di cluster*. Dua aspek pertama dibahas

pada Subbab II.10.1, sedangkan dua aspek berikutnya bersama pemantauan *runtime* dibahas pada Subbab II.10.2.

II.10.1 Identitas dan Pengelolaan Rahasia

Identitas pengguna terpadu bertumpu pada *identity provider* berbasis OpenID Connect (OIDC) yang menjadi satu pintu autentikasi bagi seluruh konsol. Konsol yang tidak mendukung OIDC secara *native* dilindungi *reverse proxy* autentikasi yang memeriksa sesi sebelum meneruskan permintaan, sehingga tidak ada mekanisme kredensial terpisah per konsol. Otorisasi granular pada level objek memakai model relasi bergaya Google Zanzibar dengan skema relasi deklaratif dan API permintaan izin yang konsisten. Pengelolaan rahasia menuntut penyimpanan terenkripsi, penerbitan kredensial dinamis, penyaluran rahasia ke beban kerja dengan rotasi otomatis, serta jembatan KMS untuk enkripsi data *at rest* pada *layer* objek.

Contoh susunan *open source* kebutuhan tersebut adalah Dex (Dex Authors 2025) sebagai *identity provider* OIDC, oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menanyakan sesi autentikasi, dan SpiceDB (AuthZed 2025) sebagai basis data otorisasi gaya Zanzibar. Pada sisi rahasia, OpenBao (OpenBao Authors 2025) merupakan *fork open-source* HashiCorp Vault di bawah Linux Foundation dengan *integrated storage* Raft sehingga tidak bergantung pada basis data eksternal. External Secrets Operator (External Secrets Authors 2025) menyalin rahasia ke Secret Kubernetes dengan rotasi otomatis melalui CRD ExternalSecret dan ClusterSecretStore, sedangkan MinIO KES (MinIO, Inc. 2025) menjadi *stateless KMS gateway* yang meneruskan permintaan kunci tanpa menyimpan kunci pada *cluster*. Perbandingan beberapa *identity provider* dan pengelola rahasia *open-source* beserta pemilihannya dibahas pada Subbab IV.3.

II.10.2 Service Mesh, API Gateway, dan Penegakan Kebijakan

Komunikasi antar-layanan diamankan oleh *service mesh* yang menyediakan *mutual TLS* (mTLS) seragam, kontrol lalu lintas *application layer*, dan integrasi telemetri. Pada perbatasan *mesh*, *API gateway* menyaring lalu lintas masuk, menerapkan kebijakan kuota, dan menjembatani mTLS terhadap konsumen di luar *mesh*. *Policy engine* menegakkan kebijakan pada saat objek dibuat, misalnya mewajibkan batas sumber daya pada setiap *pod* dan menegakkan profil keamanan baku lintas *namespace*. *Layer* pertahanan dilengkapi pemantauan ancaman *runtime* berbasis *syscall*, pemindaian *image* terjadwal, pencadangan *cluster* beserta *persistent volume*, dan uji ketahanan dengan kegagalan terkontrol.

Contoh perwujudan *open source layer* tersebut adalah Istio (Istio Authors 2024) sebagai *service mesh* dengan `VirtualService` dan `AuthorizationPolicy` serta telemetri `OpenTelemetry`, dan Apache APISIX (Apache APISIX Authors 2025) sebagai *API gateway* pada perbatasan *mesh*. Kyverno (Kyverno Authors 2024) menjadi contoh *policy engine native* Kubernetes dengan sintaks YAML yang ringkas serta dukungan *mutate*, *validate*, dan *generate*, dengan Open Policy Agent (OPA) Gatekeeper (Open Policy Agent Authors 2024) sebagai alternatif berbasis Rego yang juga umum dipakai. Falco (Falco Authors 2025) memantau *syscall* sebagai detektor berbasis eBPF, Trivy Operator (Aqua Security 2025) memindai *image* dan beban kerja secara terjadwal, Velero (Velero Authors 2025) mencadangkan *cluster* dan *persistent volume* ke *bucket* objek khusus pencadangan, dan Chaos Mesh (Chaos Mesh Authors 2025) menyuntikkan kegagalan terkontrol melalui CRD eksperimen seperti PodChaos. Perbandingan *service mesh*, *API gateway*, *policy engine*, dan *runtime security open-source* beserta pemilihannya dibahas pada Subbab IV.3.

II.11 Penelitian Terkait

Beberapa penelitian terdahulu memiliki lingkup yang berdekatan dengan platform ini. Burgueño-Romero dkk. (2025) mengusulkan arsitektur MLOps *open source*, namun belum memasukkan layanan fitur dengan dukungan vektor sebagai komponen utama. Amou Najafabadi dkk. (2024) memetakan beragam arsitektur MLOps tetapi tidak menggabungkan DataOps secara menyeluruh. Rodrigues dkk. (2025) menyentuh *near real-time stream learning*, namun tidak meletakkan tata kelola data sebagai *control plane* yang ditegakkan. Ahmad dkk. (2024) membahas strategi keamanan MLOps, tetapi belum menautkannya pada *control plane* tata kelola yang menegakkan kebijakan akses sepanjang siklus data dan model.

Kesenjangan yang berulang pada penelitian-penelitian tersebut adalah belum adanya satu rancangan yang sekaligus menyatukan DataOps dan MLOps pada satu *control plane*, menegakkan tata kelola data sebagai kontrak yang dijalankan otomatis, dan menyediakan layanan fitur multimodal dari satu sumber kebenaran. Ketiga aspek tersebut pada penelitian terdahulu umumnya ditangani terpisah, sehingga kontrak antara disiplin data dan disiplin model tidak ditegakkan secara otomatis. Akibatnya, asal-usul fitur dari *ingestion* hingga *model serving* sulit dirunut pada satu *control plane* yang sama. Kesenjangan inilah yang menjadi titik berangkat analisis kebutuhan dan pemilihan solusi pada Bab III.

BAB III

ANALISIS MASALAH

Bab ini membahas analisis masalah pada pengembangan platform DataOps dan MLOps melalui tiga langkah, yaitu pemetaan kondisi saat ini, perumusan kebutuhan fungsional dan nonfungsional, dan pemilihan alternatif solusi. Analisis berangkat dari kesenjangan yang dirumuskan pada Subbab II.11, yaitu belum adanya satu rancangan yang menyatukan DataOps dan MLOps pada satu *control plane*. Subbab III.1 memetakan tiga sumber tekanan yang menjadi akar pengembangan platform, kemudian Subbab III.2 menurunkan empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional sebagai tolok ukur kelayakan. Subbab III.3 menutup bab dengan menilai empat alternatif solusi memakai skor pemenuhan kebutuhan lalu memilih alternatif berskor tertinggi. Pemilihan komponen *open source* untuk tiap kelompok fungsi diturunkan dari alternatif terpilih pada Bab IV, sehingga keputusan alat berdiri pada konteks perancangan arsitektur. Penomoran kebutuhan yang disusun pada bab ini menjadi rujukan tetap ketika Bab IV memetakannya ke komponen dan Bab VI mengujinya.

III.1 Analisis Kondisi Saat Ini

Kondisi pengembangan platform DataOps dan MLOps saat ini dipengaruhi oleh dua tekanan utama yang, ketika tidak teratasi, memicu efek domino sebagai tekanan ketiga. Pertama, beban konfigurasi puluhan komponen *open source* dari nol membatasi kecepatan pembangunan platform internal. Kedua, biaya berlangganan layanan terkelola membatasi kelayakan operasional pada skala produksi sekaligus menghadirkan pertukaran antara waktu pengembangan dan anggaran berjalan. Ketiga, fragmentasi yang merambat lintas peran (*business user*, *data engineer*, *data scientist*, dan *machine learning engineer*) memicu efek domino pada tata kelola data, deteksi *drift*, dan *feature serving* multimodal. Ketiga subbab berikut menelaah setiap sumber tekanan tersebut secara berurutan.

III.1.1 Beban Konfigurasi Platform dari Nol

Organisasi yang membangun platform dari nol harus merangkai puluhan komponen lintas *layer ingestion*, pemrosesan, penyimpanan, *training*, dan *model serving*, dengan ruang pilihan *tool* yang sangat luas untuk tiap *layer*. Setiap komponen memiliki kontrak konfigurasi, protokol akses, dan model identitas masing-masing, sehing-

ga *glue code* antar *layer* terus tumbuh seiring penambahan komponen. Perubahan versi pustaka pada satu komponen kerap memicu *rework* pada komponen sekitarnya, terutama ketika skema data dan kontrak API ikut berubah. Tim platform juga menanggung kurva belajar yang panjang karena harus menguasai paradigma operasional yang berbeda untuk basis data, sistem antrian, mesin pemrosesan, registri model, dan layanan *serving*. Ketiga mekanisme tersebut berjalan serentak sehingga beban konfigurasi tidak berhenti pada pemasangan awal, melainkan berulang pada setiap penambahan komponen dan pergantian versi.

Beban tersebut bersifat akumulatif karena waktu yang habis untuk integrasi tidak dapat dipulihkan menjadi pengembangan kapabilitas. Shankar dkk. (2022) mendokumentasikan praktik MLOps yang sering tersendat justru karena *layer* integrasi yang tidak pernah selesai disempurnakan oleh tim platform. Kondisi tersebut menjelaskan mengapa banyak inisiatif platform internal terhenti pada tahap arsitektur referensi dan tidak pernah mencapai jalur produksi yang lengkap. Tantangan akan semakin sulit ketika tim berukuran kecil harus menjaga kontrak layanan untuk *ingestion*, pemrosesan, *training*, *serving*, dan tata kelola sekaligus, karena setiap pergantian versi menimbulkan rantai uji regresi yang panjang. Beban ini diturunkan pada Subbab III.2 menjadi kebutuhan konfigurasi deklaratif, rekonsiliasi otomatis, dan modularitas komponen agar pemasangan ulang platform tidak mengulang biaya integrasi dari nol.

III.1.2 Biaya Berlangganan Layanan Terkelola

Sebagai alternatif terhadap konfigurasi dari nol, organisasi dapat berlangganan layanan terkelola dari penyedia *cloud*. Li dkk. (2023) memperlihatkan bahwa layanan *feature store* terkelola mempercepat adopsi dengan membebaskan tim dari pembangunan infrastruktur *feature store*. Akan tetapi, Hamza, Akbar, dan Capilla (2024) menemukan bahwa model penagihan bayar per pakai pada layanan terkelola menyulitkan estimasi anggaran dan cenderung meningkat seiring volume *ingest*, jumlah *training run*, dan trafik *inference*. Biaya tersebut bersifat berulang setiap bulan dan jarang dapat ditekan dengan optimasi internal karena pengguna tidak memegang kendali penuh atas alokasi sumber daya pada *layer* bawah. Ketergantungan pada satu penyedia menimbulkan keterikatan yang membuat migrasi menjadi mahal, terutama ketika format *feature view*, *registry model*, dan *lineage* memakai skema kepemilikan tertutup. Beban ini bertambah ketika organisasi memakai layanan terkelola dari *layer* berbeda yang dipasok beberapa penyedia, sebab perbedaan model identitas, protokol akses, dan format *audit log* memaksa tim platform tetap merakit


otomasi tata kelola lintas penyedia secara manual.

Kedua jalur tersebut menghadirkan pertukaran mendasar antara waktu pengembangan dan anggaran berjalan. Sifat pertukarannya tidak simetris: biaya membangun dari nol terkonsentrasi di awal dan menurun setelah jalur *end-to-end* stabil, sedangkan biaya berlangganan tumbuh mengikuti volume *ingest*, jumlah *training run*, dan trafik *inference* sehingga justru membesar ketika adopsi berhasil. Organisasi yang berpindah dari satu jalur ke jalur lain bahkan menanggung kedua beban sekaligus selama masa transisi, karena integrasi internal harus dirakit sambil kontrak layanan terkelola masih berjalan. Karakter pertukaran ini dipakai pada dua titik analisis berikutnya, yaitu kebutuhan nonfungsional efisiensi sumber daya dan portabilitas pada Subbab III.2.3 serta penilaian empat alternatif solusi pada Subbab III.3.


III.1.3 Efek Domino Fragmentasi Lintas Peran

Pengembangan model *machine learning* untuk tahap produksi melibatkan empat peran utama, yaitu *business user*, *data engineer*, *data scientist*, dan *machine learning engineer*. Kreuzberger, Kühl, dan Hirschl (2023) memperlihatkan bahwa peran tersebut sering menggunakan *tool* yang berbeda sehingga muncul fragmentasi yang menghambat kolaborasi lintas tim. Paleyes, Urma, dan Lawrence (2022) menambahkan bahwa fragmentasi tersebut melahirkan integrasi yang lemah pada sambungan data dan model serta menurunkan kecepatan rilis dan kualitas keluaran. Gambar III.1 dan Gambar III.2 memilah fragmentasi tersebut menjadi dua alur layanan, yaitu alur data yang dikelola *data engineer* hingga laporan diterima *business user* dan alur model yang ditangani *data scientist* bersama *machine learning engineer*. Kedua alur sengaja digambar berjalan terpisah tanpa satu sambungan pun di antaranya, karena keterputusan inilah inti masalahnya, yaitu keluaran alur data tidak mengalir menjadi masukan alur model sehingga integrasi lintas peran tidak pernah terbentuk. Pemisahan dua alur ini dipilih karena beban inti yang menjadi titik tolak penelitian terletak bukan pada satu peran tertentu, melainkan pada sambungan antar peran yang terputus di *layer ingestion*, fitur, *training*, dan *serving*. Efek domino muncul ketika satu kontrak data antar *layer* pecah lalu menyebar ke *layer* di atasnya, yaitu kerusakan skema pada *ingestion layer* merambat ke pemrosesan, lalu ke fitur yang dipakai untuk pelatihan, sehingga model pada *serving layer* menerima distribusi yang berbeda dengan saat pelatihan. Pada kerangka kematangan Subbab II.1.3, kondisi ini setara dengan MLOps *level 0* yang prosesnya manual dan berbasis skrip, eksperimennya terpisah dari operasi, serta berjalan tanpa CI/CD dan tanpa pemantauan kinerja aktif (Google Cloud 2024). Kondisi yang sama berada pada tahap awal

model evolusi DataOps karena data terkumpul dalam silo dan pemantauan *pipeline* masih dilakukan manual (Munappy dkk. 2020).



Gambar III.1 Alur data terfragmentasi pada kondisi saat ini, berada pada tahap awal model evolusi DataOps (Munappy dkk. 2020).



Gambar III.2 Alur model terfragmentasi pada kondisi saat ini, berada pada MLOps level 0 (Google Cloud 2024).

Amou Najafabadi dkk. (2024) dan Burgueño-Romero dkk. (2025) memperlihatkan bahwa fragmentasi tidak hanya muncul pada antarmuka tim, tetapi juga pada *control plane* infrastruktur, kebijakan akses, dan observabilitas. Kondisi inilah yang menjadi titik tolak penelitian, karena keempat rumusan masalah pada Bab I pada hakikatnya merupakan konsekuensi dari rangkaian sambungan yang terputus tersebut. Konsekuensi tersebut tidak dapat ditangani satu per satu, sebab perbaikan pada satu *layer* akan kembali terkikis selama kontrak antar *layer* tetap dirakit secara ad hoc. Analisis kebutuhan pada Subbab III.2 karena itu menempatkan kontrak yang seragam lintas *layer* sebagai tuntutan yang berlaku pada keseluruhan arsitektur, dan perbandingan pada Subbab III.3 menilai empat alternatif solusi berdasarkan kemampuannya memutus efek domino ini.

III.2 Analisis Kebutuhan

Setelah pemetaan kondisi saat ini, kebutuhan platform dirumuskan dalam dua kategori: kebutuhan fungsional yang menggambarkan fitur yang harus dimiliki platform, dan kebutuhan nonfungsional yang menggambarkan atribut kualitas yang harus dipenuhi. Identifikasi kebutuhan menggunakan empat rumusan masalah dari Bab I sebagai titik awal, dengan mempertimbangkan beban pada Subbab III.1.1 dan Su-

bbab III.1.2 agar rancangan tetap layak operasional dan finansial. Setiap kebutuhan fungsional dipetakan langsung pada satu sub-bidang arsitektur agar tidak terjadi tumpang tindih cakupan antar kebutuhan, sementara setiap kebutuhan nonfungsional disertai target metrik yang dapat diuji pada Bab VI. Identifikasi awal masalah pengguna pada Subbab III.2.1 memberikan rangkuman kebutuhan kontekstual sebelum diturunkan menjadi daftar formal pada Subbab III.2.2 dan Subbab III.2.3.

III.2.1 Identifikasi Masalah Pengguna

Identifikasi masalah pengguna diturunkan dari empat rumusan masalah pada Bab I dengan menelusuri titik sentuh tiap peran pada rantai produksi model. Penelusuran memetakan setiap rumusan masalah ke kontrak antar *layer* yang terputus pada *layer ingestion*, fitur, *training*, dan *serving*, lalu mencatat peran yang paling merasakan akibat putusnya kontrak tersebut. Penyusunan sengaja menempatkan kebutuhan pada sambungan antar *layer* sebagai dasar, bukan pada preferensi *tool* satu peran tertentu, agar daftar tetap ringkas dan setara untuk keempat peran. Keempat kebutuhan berikut menjadi titik awal penyusunan daftar formal kebutuhan fungsional dan nonfungsional, dan masing-masing dapat dirunut kembali ke rumusan masalah yang melahirkannya serta ke peran yang paling merasakannya.

1. Control plane terpadu lintas peran

Control plane terpadu lintas peran dibutuhkan untuk mengatur *ingestion*, *training*, *serving*, dan pemantauan, sehingga sambungan antar *layer* tidak lagi dirakit secara manual dan integrasi *tool* dapat dipulihkan dari sumber kebenaran tunggal.

2. Tata kelola data yang seragam lintas siklus

Tata kelola yang seragam di antara *layer* data, fitur, dan model dibutuhkan agar *lineage*, katalog, dan validasi kualitas tetap menyatu ketika data berpindah antar *layer*, terutama bagi *data engineer* yang menjaga kontrak data sepanjang siklus.

3. Deteksi drift otomatis dan jaminan validitas temporal

Deteksi *drift* yang terotomasi sekaligus jaminan *point-in-time correctness* dibutuhkan pada sambungan antara *layer* data dan *layer* model agar evaluasi model tidak mengandung kebocoran temporal sebagaimana ditegaskan oleh Vela dkk. (2022) dan Kaufman dkk. (2012). Pihak yang paling bergantung pada kontrak ini adalah *data scientist* dan *machine learning engineer* yang menilai kelayakan model sebelum produksi.

4. Dukungan fitur multimodal berlatensi rendah

Dukungan fitur multimodal yang terdiri dari *tabular feature*, *aggregate feature*, dan *embedding* berdimensi tinggi dengan latensi rendah pada saat *inference* dibutuhkan pada *feature serving layer*. Kebutuhan ini berakar pada kerja *data scientist* yang melakukan *feature engineering* lintas modalitas.

Empat kebutuhan pengguna tersebut menyiratkan satu pola yang sama, yaitu kebutuhan untuk memutus sambungan ad hoc antar *layer* dengan kontrak yang seragam dan dapat dipanggil dari satu antarmuka. Pengguna pada peran *business user* menjadi penerima manfaat terakhir karena hanya melihat keluaran model pada *serving layer*, sehingga kualitas kontrak pada *layer* bawah menentukan apakah keputusan bisnis dapat diambil tepat waktu. Identifikasi tersebut menjadi titik awal untuk menyusun daftar formal kebutuhan fungsional pada Subbab III.2.2 dan kebutuhan non-fungsional pada Subbab III.2.3. Daftar formal tersebut selanjutnya dipetakan ke komponen arsitektur pada Bab IV dan diuji pemenuhannya pada Bab VI, sehingga setiap kebutuhan tetap terhubung dari sumber masalah hingga bukti pemenuhannya.

III.2.2 Kebutuhan Fungsional

Tabel III.1 menyajikan empat belas kebutuhan fungsional yang disusun mengikuti *layer* arsitektur platform, bergerak dari *layer* fitur, lalu *model lifecycle* dan tata kelola, hingga *layer* operasional, sehingga penomorannya berurutan menurut *layer* dan bukan menurut tujuan. Empat kebutuhan pertama, yaitu manajemen fitur terpusat, *feature serving* ganda *online-offline*, jaminan validitas temporal, dan dukungan *vector embedding*, merangkum kontrak pada *layer* fitur. Enam kebutuhan berikutnya menyatukan *model lifecycle* dan tata kelola dalam satu rentang, mencakup otomatisasi *pipeline* pelatihan, otomatisasi *deployment* model, pemantauan *drift* otomatis, tata kelola dan penemuan, pelacakan eksperimen, serta registri model. Empat kebutuhan terakhir, yaitu pemrosesan *batch* dan *stream*, konfigurasi deklaratif, API dan SDK terpadu, serta manajemen sumber daya, merangkum *layer* operasional yang menopang seluruh *layer* di atasnya. Kolom Tujuan pada Tabel III.1 menautkan setiap kebutuhan ke satu dari empat tujuan pada Bab I, pada dimensi yang terpisah dari urutan *layer* berdasarkan *sub-sistem* yang paling bertanggung jawab mewujudkan kebutuhan tersebut, sehingga setiap kebutuhan fungsional memiliki satu tujuan pemilik yang jelas dan tetap dapat dirunut ketika dipetakan ke komponen pada Bab IV dan ke skenario uji pada Bab VI.

Tabel III.1 Kebutuhan Fungsional Sistem

ID	Kebutuhan Fungsional	Deskripsi	Tujuan
KF-01	Manajemen Fitur Terpusat	Sistem menyediakan <i>feature registry</i> terpusat berbasis Feast dengan <i>file-based registry</i> pada MinIO untuk mendefinisikan, mengelola, dan melakukan <i>versioning</i> fitur. <i>Registry</i> menyimpan metadata seperti deskripsi, tipe data, <i>owner</i> , dan dependensi, serta dikelola di dalam repositori Gitea agar mendukung <i>workflow</i> GitOps dan penelusuran perubahan.	T-1
KF-02	<i>Feature Serving</i> Ganda	Sistem mampu melakukan <i>serving</i> fitur dalam dua mode, yaitu <i>online serving</i> berbasis Valkey melalui protokol RESP untuk <i>real-time inference</i> dengan target latensi p99 sub-detik, dan <i>offline serving</i> berbasis ClickHouse untuk <i>historical retrieval</i> berkapasitas besar yang mendukung <i>point-in-time correct join</i> pada data historis.	T-4
KF-03	Jaminan Validitas Temporal	Sistem secara bawaan menjamin <i>point-in-time correctness</i> ketika menyusun <i>training dataset</i> untuk data <i>time-series</i> , sehingga mencegah kebocoran data temporal yang dapat membuat evaluasi dan model menjadi tidak valid.	T-3
KF-04	Dukungan <i>Vector Embeddings</i>	Sistem mendukung penyimpanan, pengindeksan, dan <i>serving vector embeddings</i> pada indeks vektor terpisah berbasis Qdrant dengan <i>similarity search</i> HNSW melalui antarmuka gRPC dan filter <i>payload</i> , dengan target latensi p99 sub-detik untuk volume permintaan menengah.	T-4
KF-05	Otomatisasi <i>Training Pipeline</i>	Sistem menyediakan <i>pipeline</i> otomatis untuk mengorkestrasi proses <i>model training</i> dari ujung ke ujung melalui Kubeflow Pipelines, terintegrasi dengan Feast sebagai <i>feature store</i> , MLflow untuk <i>experiment tracking</i> dan <i>model registry</i> , serta Katib untuk <i>hyperparameter tuning</i> , sehingga mendukung otomasi setara MLOps <i>level 2</i> .	T-3
KF-06	Otomatisasi <i>Deployment Model</i>	Sistem mengotomatisasi <i>deployment</i> model yang telah lulus validasi ke <i>inference endpoint</i> produksi melalui KServe <i>InferenceService</i> di atas Knative Serving, serta mendukung strategi <i>rolling update</i> , <i>canary deployment</i> , dan <i>progressive delivery</i> berbasis Argo Rollouts dengan mekanisme <i>rollback</i> otomatis ketika terjadi degradasi.	T-1
KF-07	Pemantauan <i>Drift</i> Otomatis	Sistem secara otomatis dan berkala memantau <i>data drift</i> dan <i>concept drift</i> dengan membandingkan distribusi fitur di produksi terhadap distribusi pada saat pelatihan menggunakan uji statistik (misalnya PSI dan Kolmogorov-Smirnov) dengan ambang adaptif, serta memicu <i>retraining</i> otomatis melalui Argo CronWorkflow ketika ambang terlampaui.	T-3

ID	Kebutuhan Fungsional	Deskripsi	Tujuan
KF-08	Tata Kelola & Penemuan Otomatis	Sistem menangkap dan menyajikan metadata serta <i>lineage</i> untuk fitur, <i>dataset</i> , model, dan <i>pipeline</i> pada katalog DataHub melalui <i>ingestion</i> otomatis dan peristiwa <i>lineage</i> berbasis OpenLineage, sehingga memudahkan penemuan, analisis dampak, dan pemenuhan kebutuhan <i>compliance</i> .	T-2
KF-09	Pelacakan Eksperimen Terintegrasi	Sistem menyediakan <i>experiment tracking</i> yang terintegrasi untuk mencatat parameter, metrik, artefak, dan versi kode, sehingga proses eksperimen dapat direproduksi dan dibandingkan secara sistematis.	T-2
KF-10	<i>Versioning</i> dan Registri Model	Sistem menyediakan <i>model registry</i> terpusat untuk mengelola versi model dan status siklus hidupnya (<i>staging</i> , <i>production</i> , <i>archived</i>) disertai <i>audit trail</i> lengkap untuk mendukung <i>governance</i> .	T-2
KF-11	Pemrosesan <i>Batch</i> dan <i>Stream</i>	Sistem mendukung <i>batch processing</i> untuk analisis historis dan <i>feature engineering</i> serta <i>stream processing</i> untuk komputasi fitur <i>real-time</i> , dan keduanya terhubung dengan <i>feature store</i> sehingga definisi fitur tetap konsisten.	T-4
KF-12	Konfigurasi Deklaratif	Sistem memungkinkan konfigurasi komponen seperti fitur, <i>pipeline</i> , dan <i>deployment</i> dalam format deklaratif (manifes Kubernetes, <i>overlay</i> Kustomize, dan definisi Feast berbasis Python) yang dikontrol versinya di Gitea dan disinkronkan oleh Argo CD sebagai <i>single source of truth</i> .	T-1
KF-13	API dan SDK Terpadu	Sistem menyediakan SDK Python yang seragam (Feast, MLflow, dan klien KServe v2 <i>inference</i>) dalam satu <i>environment</i> uv sebagai antarmuka klien standar untuk membaca <i>online feature</i> , menelusuri <i>run</i> dan registri model, serta memanggil <i>endpoint inference</i> , sehingga kompleksitas integrasi menurun dan pola pemakaian menjadi konsisten.	T-1
KF-14	Manajemen Sumber Daya	Sistem menyediakan kemampuan pengelolaan sumber daya komputasi yang efisien melalui Kueue untuk <i>job queuing</i> , prioritas, dan kuota berbasis ClusterQueue, dipadukan dengan HPA, VPA, dan KEDA untuk <i>dynamic provisioning</i> pada lingkungan <i>multi-tenant</i> agar tidak ada satu <i>workload</i> yang menghabiskan sumber daya kluster.	T-1

Penomoran KF-01 sampai KF-14 dipakai konsisten pada Bab IV ketika setiap kebutuhan dipetakan ke komponen, pada Bab V ketika setiap kebutuhan dipetakan ke berkas manifes, dan pada Bab VI ketika setiap kebutuhan dipetakan ke skenario uji.

Pemetaan satu lawan satu antara kebutuhan fungsional dan sub-sistem dipilih untuk menghindari tumpang tindih cakupan, sehingga jika satu kebutuhan tidak terpenuhi maka komponen yang bertanggung jawab dapat segera ditemukan tanpa perlu menelusuri rantai panjang. Mayoritas kebutuhan berprioritas tinggi karena menyangkut kontrak inti antar *layer*, sedangkan KF-13 dan KF-14 bersifat penunjang yang memperbaiki pengalaman integrasi dan efisiensi sumber daya tanpa menghalangi fungsi utama. Kebutuhan pada *layer* fitur secara khusus merangkum kontrak *point-in-time correctness* dan dukungan multimodal yang menjadi pembeda utama dari pendekatan tradisional yang hanya menyajikan *tabular feature* dari satu sumber.

III.2.3 Kebutuhan Nonfungsional

Tabel III.2 menyajikan dua belas kebutuhan nonfungsional yang berperan sebagai pembatas kualitas dan disusun mengikuti taksonomi atribut kualitas alih-alih menurut tujuan. Kinerja latensi rendah dan *throughput* tinggi menyangkut performa *feature serving* dan *stream processing*. Skalabilitas horizontal, keandalan, dan toleransi kesalahan menyangkut kemampuan platform mengikuti pertumbuhan beban. Konsistensi dan kebenaran menegakkan kontrak kualitas data sepanjang *pipeline*, mencakup kesesuaian skema dan validitas nilai. *Observability* mengikat metrik, log, dan *trace* pada satu antarmuka. Keamanan mengikat autentikasi, otorisasi, enkripsi, dan *audit logging*. Ekstensibilitas dan modularitas memberi ruang bagi penggantian komponen tanpa mengganggu komponen lain. Kemudahan penggunaan, efisiensi sumber daya, portabilitas, dan kemudahan pemeliharaan menutup daftar dengan menyoroti aspek operasional jangka panjang. Penetapan target pada KNF skalabilitas horizontal mengacu pada taksonomi karakteristik skalabilitas dari Bondi (2000), yang membedakan beberapa dimensi skalabilitas, di antaranya skalabilitas beban dan skalabilitas struktural, sebagai faktor yang memengaruhi kinerja ketika beban bertumbuh.

Tabel III.2 Kebutuhan Nonfungsional Sistem

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-01	Kinerja Latensi Rendah	<i>Online feature serving</i> berbasis Val-key dan <i>vector similarity search</i> berbasis Qdrant harus memberikan latensi yang stabil dan rendah untuk mendukung <i>inference</i> waktu nyata pada berbagai domain aplikasi, termasuk pada saat beban tinggi.	Latensi p99 sub-detik pada <i>feature serving</i> dan <i>vector search</i> , dengan ambang spesifik per layanan diukur dan dipantau melalui SLO Sloth	T-4

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-02	<i>Throughput</i> Tinggi	Sistem harus mampu menangani <i>workload</i> dengan <i>throughput</i> tinggi yang umum pada beban kerja <i>streaming</i> dan <i>serving</i> bervolume tinggi, dengan karakteristik skalabilitas mendekati linear ketika sumber daya ditambah.	<i>Throughput ingest</i> dan <i>serving</i> tumbuh proporsional terhadap jumlah <i>partition</i> Kafka serta <i>replica</i> Feast melalui <i>auto-scaling</i> KEDA dan HPA	T-4
KNF-03	Skalabilitas Horizontal	Seluruh komponen sistem harus mendukung skala horizontal, sehingga kapasitas dapat ditingkatkan dengan menambah <i>node</i> dan menghasilkan peningkatan kinerja yang linear atau mendekati linear.	Seluruh <i>workload</i> terstandarisasi pada HPA (CPU/memori), VPA <i>recommender</i> , dan KEDA (Kafka <i>lag</i> , <i>custom metrics</i>)	T-1
KNF-04	Keandalan & Toleransi Kesalahan	Sistem harus andal dengan komponen <i>stateful</i> (Kafka, ClickHouse, PostgreSQL, MinIO, Valkey, Qdrant) yang dapat berjalan dalam mode <i>multi-replica</i> pada lingkungan produksi <i>multi-node</i> , dan mampu melakukan pemulihan otomatis dari kegagalan sementara melalui mekanisme <i>operator</i> dan <i>snapshot</i> berkala. Pada lingkungan verifikasi <i>node</i> tunggal, <i>replica idle</i> ditetapkan menjadi satu dan ditingkatkan secara dinamis ketika beban nyata terdeteksi.	SLO <i>platform</i> dijaga melalui Sloth (Kafka 99,9%, Postgres 99,95%, MinIO p99 <500ms pada 99%), sedangkan <i>disaster recovery</i> berbasis Velero <i>snapshot</i> harian penuh dan <i>incremental</i> per <i>use case</i>	T-1
KNF-05	Konsistensi & Kebenaran	Sistem harus menegakkan kontrak kualitas data sepanjang <i>pipeline</i> , mencakup kesesuaian skema, validitas rentang nilai, dan kelengkapan data, sehingga hasil analisis maupun <i>inference</i> model bertumpu pada data yang sah dan konsisten.	Seluruh <i>checkpoint</i> Great Expectations lolos tanpa pelanggaran skema maupun rentang nilai pada data yang dipromosikan ke <i>gold layer</i>	T-2

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-06	Observability	Sistem harus memiliki <i>observability</i> menyeluruh, mencakup metrik (Prometheus dan Grafana), <i>structured log</i> (Loki), <i>distributed tracing</i> (Grafana Tempo melalui OpenTelemetry), <i>continuous profiling</i> (Pyroscope), dan <i>alerting</i> (Alertmanager dan Sloth) sehingga perilaku sistem dapat dianalisis dari ujung ke ujung.	Seluruh komponen terinstrumentasi metrik dan log standar, <i>trace</i> OpenTelemetry untuk lintasan kritis, serta SLO Sloth untuk indikator layanan	T-2
KNF-07	Keamanan	Sistem harus menerapkan kontrol keamanan menyeluruh, mencakup autentikasi tunggal melalui dex sebagai <i>identity provider</i> OIDC dan oauth2-proxy, otorisasi berbasis RBAC dan SpiceDB, enkripsi data <i>in transit</i> dengan Istio mTLS <i>strict</i> , enkripsi <i>at rest</i> pada MinIO melalui KES sebagai <i>KMS gateway</i> ke OpenBao, kebijakan admisi Kyverno, serta deteksi ancaman <i>runtime</i> oleh Falco dan pemindaian kerentanan <i>image</i> oleh Trivy Operator.	TLS 1.3 <i>in transit</i> , AES-256 <i>at rest</i> , dan <i>audit log</i> OpenBao serta Kubernetes <i>audit policy</i> aktif pada seluruh <i>control plane</i>	T-2
KNF-08	Ekstensibilitas & Modularitas	Arsitektur harus modular sehingga komponen dapat diperluas atau diganti melalui antarmuka terdefinisi (<i>Custom Resource Definition</i> , helm <i>chart</i> , dan <i>overlay</i> Kustomize) tanpa mengganggu komponen lain.	Setiap komponen disusun pada <i>folder</i> terpisah dengan <i>kustomization.yaml</i> sendiri, sehingga dapat dipasang, diperbarui, atau diganti secara independen	T-1
KNF-09	Kemudahan Penggunaan	Antarmuka konsol pengembang dan operator platform harus dapat diakses dari satu titik autentikasi tunggal sehingga konsol Argo CD, Argo Workflows, Kubeflow, MLflow, DataHub, dan Grafana terhubung melalui satu sesi identitas, dengan dokumentasi referensi yang ringkas untuk konfigurasi setiap komponen.	Seluruh antarmuka konsol platform terhubung pada satu jalur autentikasi dex dan oauth2-proxy tanpa konfigurasi identitas tambahan per layanan, serta tiap komponen memiliki dokumentasi referensi pada repositori Gitea	T-1

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-10	Efisiensi Sumber Daya	Sistem harus memanfaatkan sumber daya komputasi dan penyimpanan secara efisien untuk mengendalikan biaya tanpa mengorbankan kinerja, baik pada lingkungan <i>node</i> tunggal maupun multi- <i>node</i> .	Kompresi kolumnar pada ClickHouse, <i>autoscaling</i> berbasis HPA, VPA, dan KEDA agar utilisasi sumber daya proporsional terhadap beban, serta atribusi biaya per <i>workload</i> melalui OpenCost	T-1
KNF-11	Portabilitas	Sistem harus dapat dijalankan di berbagai lingkungan <i>deployment</i> dengan perubahan terbatas pada konfigurasi dan tanpa modifikasi kode besar, sebab seluruh komponen berdiri di atas distribusi Kubernetes standar dan <i>image open source</i> .	Dapat di- <i>deploy</i> pada distribusi Kubernetes <i>managed</i> (AWS EKS, GCP GKE, Azure AKS) maupun <i>on-premise</i> (k3s, kubeadm) hanya dengan penyesuaian <i>overlay</i> Kustomize dan parameter <i>secret</i>	T-1
KNF-12	Kemudahan Pemeliharaan	Sistem harus mudah dipelihara, dengan struktur kode dan manifes yang jelas, <i>pipeline</i> CI yang otomatis pada Tekton, serta <i>deployment</i> deklaratif dari sumber kebenaran tunggal pada Gitea melalui Argo CD.	Setiap komponen dapat direkonsiliasi ulang dari <i>repository</i> Gitea tanpa intervensi manual, dan perubahan ditolak otomatis oleh <i>pull request review</i> dan <i>policy</i> Kyverno bila tidak sesuai konvensi	T-1

Setiap KNF disertai target metrik yang dapat diuji secara langsung pada Bab VI, sehingga klaim kualitas tidak berhenti pada deskripsi tetapi memiliki ambang batas yang konkret. Pemilihan ambang batas pada KNF latensi dan *throughput* mengikuti karakteristik *online feature serving*, tempat *lookup* fitur harus diselesaikan dalam waktu singkat agar layanan *inference* tetap responsif terhadap data yang bergerak cepat. Pemilihan ambang batas pada KNF observabilitas mengikuti praktik yang dirangkum oleh Cloud Native Computing Foundation (2024b) bahwa metrik, log, dan *trace* harus dapat dirujuk silang pada satu antarmuka agar diagnosis dapat ditegakkan tanpa berpindah *tool*. Berbeda dari kebutuhan fungsional yang dapat di-

petakan satu lawan satu ke tujuan, kebutuhan nonfungsional bersifat lintas-bidang sehingga satu atribut kualitas dapat menopang lebih dari satu tujuan sekaligus. Meskipun demikian, setiap KNF tetap memiliki tujuan utama tempat target metriknya paling langsung diuji, dan kolom Tujuan pada Tabel III.2 menautkan setiap kebutuhan nonfungsional ke tujuan utama tersebut. Konsekuensinya, tujuan ketiga yang menyangkut deteksi *drift* terotomasi dan *point-in-time correctness* tidak menjadi pemilik utama satu pun KNF, sebab kapabilitasnya ditegakkan secara fungsional melalui KF-03, KF-05, dan KF-07, sedangkan dimensi kualitasnya tertopang lintas-bidang oleh KNF-05 pada sisi kebenaran data dan KNF-06 pada sisi pemantauan sinyal *drift*. Kedua daftar kebutuhan tersebut menjadi kriteria penilaian empat alternatif solusi pada Subbab III.3.

III.3 Analisis Pemilihan Solusi

Bagian ini menyusun alternatif solusi yang dapat memenuhi kebutuhan fungsional dan nonfungsional, kemudian memilih solusi terbaik dengan menggunakan skor pemenuhan kebutuhan. Penilaian skor dilakukan terhadap empat alternatif dengan menggunakan dua belas KNF dan empat belas KF sebagai kriteria, sehingga total skor maksimum sebuah alternatif adalah lima puluh dua. Setiap skor ditetapkan dengan memetakan kapabilitas terdokumentasi tiap alternatif, sebagaimana ditinjau pada Bab II, terhadap definisi kebutuhan pada Subbab III.2, sehingga penilaian bertumpu pada bukti kapabilitas dan bukan pada preferensi penulis. Alternatif yang memperoleh skor tertinggi akan dirancang lebih lanjut pada Bab IV dan diimplementasikan pada Bab V, dengan justifikasi tertulis pada kelompok kebutuhan yang membedakan peringkat antar alternatif.

III.3.1 Alternatif Solusi

Empat alternatif solusi dipertimbangkan untuk membangun platform DataOps dan MLOps terintegrasi. Pemilihan empat alternatif didasarkan pada pemetaan pendekatan yang umum dipakai oleh organisasi yang menerapkan MLOps pada skala produksi, mencakup pendekatan terkelola penuh, pendekatan *open source* di atas Kubernetes, pendekatan kustom dari awal, dan pendekatan hibrida antara terkelola dan *open source*. Setiap alternatif diuraikan dengan kelebihan, kekurangan, dan rujukan pustaka yang relevan agar pertimbangan dapat ditelusuri kembali. Keempat alternatif dinilai terhadap dua puluh enam kebutuhan yang sama dari Subbab III.2 sehingga perbandingannya dapat diaudit kriteria demi kriteria.

1. Alternatif A: Layanan Terkelola dari Penyedia Cloud

Pendekatan ini menggunakan rangkaian layanan terkelola pada satu penyedia, mencakup layanan *ingestion*, *warehouse*, *feature store*, *training*, dan *serving*. Kelebihannya berupa kecepatan adopsi dan integrasi bawaan antar layanan, sebagaimana dibahas oleh Li dkk. (2023). Kekurangannya berupa keterikatan terhadap satu penyedia, biaya operasional pada beban tinggi, dan keterbatasan dalam menyesuaikan komponen pada level rendah, sehingga pertukaran waktu lawan anggaran pada Subbab III.1.2 tetap menjadi beban berjalan.

2. **Alternatif B: Komponen *Open Source* pada Kubernetes**

Pendekatan ini merangkai komponen *open source* di atas Kubernetes sebagai bidang orkestrasi. Lakka (2025) dan Burgueño-Romero dkk. (2025) memperlihatkan rancangan serupa yang menjadikan Kubernetes sebagai fondasi orkestrasi bagi komponen *open source*. Kelebihannya berupa fleksibilitas, transparansi versi, portabilitas, dan kemampuan menegakkan pola GitOps. Kekurangannya berupa kebutuhan tata kelola yang lebih ketat dan kurva belajar yang lebih panjang dibandingkan layanan terkelola, sehingga beban konfigurasi dari nol pada Subbab III.1.1 perlu dikurangi melalui rancangan referensi yang utuh.

3. **Alternatif C: Pengembangan Kustom dari Awal**

Pendekatan ini membangun setiap *layer* secara mandiri tanpa banyak menggunakan komponen yang sudah jadi. Kelebihannya berupa kontrol penuh atas perilaku setiap komponen. Kekurangannya berupa biaya pengembangan dan pemeliharaan yang sangat besar, ketergantungan pada tim yang sangat kompeten, dan risiko menciptakan ulang masalah yang sudah diselesaikan oleh pustaka *open source* yang teruji.

4. **Alternatif D: Hibrida antara Layanan Terkelola dan *Open Source***

Pendekatan ini menggunakan beberapa layanan terkelola, terutama pada *layer* dasar seperti penyimpanan dan jaringan, dipadukan dengan komponen *open source* pada *layer* DataOps dan MLOps. Kelebihannya berupa keseimbangan antara kecepatan adopsi dan fleksibilitas. Kekurangannya berupa kompleksitas integrasi antara dua jenis komponen dan kebutuhan kontrak antar *layer* yang harus dirancang dengan saksama.

Keempat alternatif tersebut sengaja dipilih agar mencakup seluruh rentang pertukaran waktu lawan anggaran yang dibahas pada Subbab III.1.2. Alternatif A dan D menukar waktu pengembangan dengan biaya berlangganan yang berjalan terus, Alternatif C menukar biaya berlangganan dengan waktu pengembangan yang sangat panjang, sedangkan Alternatif B berupaya menekan keduanya melalui rancangan

referensi yang dapat dipasang ulang. Posisi relatif keempatnya diukur secara kuantitatif pada Subbab III.3.2 memakai skor pemenuhan kebutuhan fungsional dan nonfungsional. Penilaian kuantitatif itu menjadi dasar keputusan akhir sehingga pemilihan solusi tidak bertumpu pada preferensi melainkan pada bukti pemenuhan kebutuhan.

III.3.2 Analisis Penentuan Solusi

Tabel III.3 menyajikan evaluasi pemenuhan kebutuhan fungsional, Tabel III.4 menyajikan evaluasi pemenuhan kebutuhan nonfungsional, dan Tabel III.5 merekapitulasi total skor gabungan keduanya. Dua tabel pertama memuat skor untuk setiap kebutuhan pada keempat alternatif, sedangkan tabel rekapitulasi hanya menjumlahkan keduanya menjadi skor akhir yang menjadi dasar keputusan. Alternatif B memperoleh skor total tertinggi, yaitu 49 dari 52, diikuti oleh Alternatif A dan Alternatif D dengan skor 43, dan Alternatif C dengan skor 30. Selisih skor antara Alternatif B dan dua pesaing terdekatnya sebesar enam poin terutama berasal dari KF jaminan validitas temporal, KF dukungan *vector embeddings*, KNF portabilitas, dan KNF ekstensibilitas yang tidak dipenuhi penuh oleh pendekatan terkelola maupun hibrida.

Tabel III.3 Evaluasi Pemenuhan Kebutuhan Fungsional

Kebutuhan	Cloud	Open-Source	Kustom	Hibrida
KF-01: Manajemen Fitur Terpusat	2	2	1	2
KF-02: <i>Feature Serving</i> Ganda	2	2	1	2
KF-03: Jaminan Validitas Temporal	1	2	2	1
KF-04: Dukungan <i>Vector Embeddings</i>	1	2	2	1
KF-05: Otomatisasi <i>Training Pipeline</i>	2	2	1	2
KF-06: Otomatisasi <i>Deployment</i> Model	2	2	1	2
KF-07: Pemantauan <i>Drift</i> Otomatis	1	2	1	1
KF-08: Tata Kelola & Penemuan	2	2	1	2
KF-09: Pelacakan Eksperimen	2	2	1	2
KF-10: <i>Versioning</i> Registri Model	2	2	1	2
KF-11: Pemrosesan <i>Batch/Stream</i>	2	2	1	2
KF-12: Konfigurasi Deklaratif	2	2	1	2
KF-13: API dan SDK Terpadu	2	1	1	1
KF-14: Manajemen Sumber Daya	2	2	1	2
Total Skor KF	25	27	16	24

Keterangan skor: 0 = tidak memenuhi sama sekali, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Alternatif B unggul terutama pada kebutuhan yang menyangkut jaminan validitas temporal, dukungan *vector embeddings*, pemantauan *drift* otomatis, ekstensibilitas, dan portabilitas. Alternatif A unggul pada kemudahan penggunaan dan kemudahan pemeliharaan, tetapi tertinggal pada validitas temporal, dukungan *vector embe-*

Tabel III.4 Evaluasi Pemenuhan Kebutuhan Nonfungsional

Kebutuhan	Cloud	Open-Source	Kustom	Hibrida
KNF-01: Kinerja Latensi Rendah	2	2	2	2
KNF-02: <i>Throughput</i> Tinggi	2	2	2	2
KNF-03: Skalabilitas Horizontal	2	2	1	2
KNF-04: Keandalan & Toleransi Kesalahan	2	2	1	2
KNF-05: Konsistensi & Kebenaran	1	2	2	1
KNF-06: <i>Observability</i>	2	2	1	2
KNF-07: Keamanan	2	2	1	2
KNF-08: Ekstensibilitas & Modularitas	0	2	2	1
KNF-09: Kemudahan Penggunaan	2	1	0	2
KNF-10: Efisiensi Sumber Daya	1	2	1	1
KNF-11: Portabilitas	0	2	1	1
KNF-12: Kemudahan Pemeliharaan	2	1	0	1
Total Skor KNF	18	22	14	19

Keterangan skor: 0 = tidak memenuhi sama sekali, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Tabel III.5 Total Skor Pemenuhan Kebutuhan Fungsional dan Nonfungsional

Alternatif	Skor KF (maks 28)	Skor KNF (maks 24)	Total (maks 52)
A: Layanan Terkelola <i>Cloud</i>	25	18	43
B: <i>Open Source</i> pada Kubernetes	27	22	49
C: Kustom dari Awal	16	14	30
D: Hibrida Terkelola dan <i>Open Source</i>	24	19	43

ddings pada *feature store*, dan portabilitas. Alternatif C unggul pada kontrol penuh tetapi kalah pada hampir semua kebutuhan operasional. Alternatif D mendekati Alternatif A tetapi tertinggal pada portabilitas dan ekstensibilitas. Skor nol pada Alternatif A untuk ekstensibilitas dan portabilitas mencerminkan keterikatan pada format kepemilikan tertutup yang menyulitkan penggantian komponen dan migrasi antar penyedia, sedangkan skor nol pada Alternatif C untuk kemudahan penggunaan dan kemudahan pemeliharaan mencerminkan beban membangun dan merawat setiap *layer* tanpa komponen siap pakai. Berdasarkan skor pemenuhan kebutuhan dan analisis komparatif yang sejalan dengan Burgueño-Romero dkk. (2025), Amou Najafabadi dkk. (2024), dan Lakka (2025), Alternatif B dipilih sebagai solusi yang akan dirancang pada Bab IV dan diimplementasikan pada Bab V, sebelum posisinya terhadap penelitian terkait ditegaskan pada Subbab III.3.3.

III.3.3 Posisi terhadap Penelitian Terkait

Kesenjangan yang dipetakan pada Subbab II.11 kini ditimbang terhadap alternatif terpilih. Alternatif B yang terpilih diwujudkan sebagai platform yang menggabungkan tiga karakter yang belum dilingkupi sekaligus pada penelitian sebelumnya: integrasi DataOps dan MLOps pada satu *control plane* Kubernetes, layanan fitur *dual-*

store dengan dukungan vektor HNSW, dan deteksi *drift* terotomasi yang memicu *retraining* melalui kontrol GitOps. Hsu dkk. (2024) dan Liang dkk. (2024) memberikan basis komparatif untuk menilai posisi tersebut. Platform ini menambahkan perekaman *lineage* otomatis dan gerbang kualitas data yang dijalankan pada *pipeline* produksi. Tabel III.6 merinci perbandingan tiap aspek arsitektur antara kondisi saat ini dan solusi terpilih beserta rujukan penelitian yang mendasari setiap peningkatan, sehingga menegaskan bagaimana platform menutup kesenjangan yang teridentifikasi pada Bab II.

Tabel III.6 Perbandingan Detail Arsitektur Saat Ini dengan yang Diusulkan

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Orkestrasi	<i>Compute</i> heterogen dengan <i>provisioning</i> manual, waktu tunggu <i>scaling</i> panjang, dan tingkat standardisasi rendah.	Platform Kubernetes terpadu dengan manajemen deklaratif dan alokasi sumber daya otomatis, sejalan dengan komponen arsitektur MLOps yang diidentifikasi Kreuzberger, Kühl, dan Hirschl (2023). GitOps dengan Argo CD memastikan perubahan infrastruktur dan aplikasi mengikuti <i>single source of truth</i> di Git.	Lakka (2025) menunjukkan bahwa adopsi Kubernetes pada perusahaan disertai praktik DevOps yang matang meningkatkan <i>deployment frequency</i> dan menekan <i>Mean Time To Recovery</i> (MTTR) secara signifikan, dan arsitektur yang diusulkan menargetkan karakteristik performa pada arah yang sama.	(Kreuzberger, Kühl, dan Hirschl 2023; Lakka 2025)
Manajemen Fitur	Logika fitur tersebar di <i>notebook</i> dan skrip dengan duplikasi tinggi dan banyak fungsi yang saling tumpang tindih.	Feast dengan <i>feature registry</i> terpusat, <i>dual serving offline/online</i> , serta dukungan <i>point-in-time correctness</i> .	Duplikasi fitur dapat ditekan, <i>training-serving skew</i> berkurang melalui pemisahan <i>offline</i> dan <i>online</i> serta <i>point-in-time retrieval</i> , dan <i>feature reuse</i> berpotensi meningkat signifikan.	(Munappy dkk. 2022; Polyzotis dkk. 2018)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Vector Embeddings	Fitur <i>embedding</i> tidak didukung secara <i>native</i> atau diimplementasikan secara kustom dengan latensi tinggi dan <i>throughput</i> terbatas.	Qdrant sebagai indeks vektor terpisah dari <i>online store</i> tabular Valkey, dengan HNSW <i>native</i> , <i>API gRPC</i> , dan filter <i>payload</i> .	Johnson, Douze, dan Jégou (2021) menunjukkan bahwa indeks vektor berbasis HNSW maupun FAISS dapat melayani <i>billion-scale similarity search</i> dengan latensi rendah. Desain ini memakai Qdrant agar fitur <i>embedding</i> dilayani secara <i>online</i> tanpa membebani <i>online store</i> kunci-nilai dan tanpa membangun layanan kustom.	(Johnson, Douze, dan Jégou 2021; Qdrant Team 2025)
Validitas Temporal	<i>Point-in-time join</i> dilakukan manual dan rentan kesalahan, sehingga banyak tim mengalami <i>data leakage</i> .	<i>Point-in-time join</i> otomatis dari Feast dengan pola verifikasi yang lebih sistematis.	Pendekatan ini mencegah kebocoran data temporal yang dapat menghasilkan estimasi performa yang terlalu optimistis saat evaluasi dan tidak realistis di produksi.	(Polyzotis dkk. 2018)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Pemrosesan Data	<i>Batch dan stream</i> diproses oleh <i>pipeline</i> terpisah tanpa arsitektur yang koheren, sehingga hasil pemrosesan tidak konsisten.	Spark sebagai mesin <i>batch processing</i> dan Flink sebagai mesin <i>stream processing</i> yang hasilnya dimaterialisasikan langsung ke <i>Feature Store</i> . Airflow mengorkestrasi <i>pipeline</i> transformasi data sebagai DAG sehingga pengembangan dan penjadwalan transformasi menjadi lebih sistematis.	Waktu pengembangan <i>pipeline</i> dapat menurun dan <i>freshness</i> data meningkat berkat pemrosesan <i>streaming</i> yang lebih efisien dan terintegrasi.	(Rodrigues dkk. 2025)
Model Training	<i>Workflow</i> pelatihan berbasis <i>notebook</i> dengan <i>tracking</i> eksperimen informal dan <i>artifact</i> tidak terkelola.	Kubeflow <i>Pipelines</i> untuk orkestrasi pelatihan dan MLflow untuk <i>tracking</i> eksperimen.	Reproduksibilitas meningkat melalui kontainerisasi dan pengelolaan eksperimen terpusat, sementara siklus pengembangan <i>pipeline</i> menjadi lebih terstruktur.	(Amershi dkk. 2019; Pimentel dkk. 2019)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Deployment Model	Proses <i>deployment</i> manual dengan <i>refactoring</i> besar dan sering terjadi <i>bug</i> pasca- <i>deploy</i> .	KServe dengan <i>InferenceService</i> deklaratif dan <i>deployment</i> otomatis melalui GitOps di atas Knative Serving. OpenTelemetry mengumpulkan log dan <i>trace inference</i> ke Loki dan Grafana Tempo sebagai dasar pemantauan dan analitik lanjutan.	Waktu <i>deployment</i> berpotensi turun secara signifikan, dan insiden terkait kesalahan konfigurasi <i>deployment</i> dapat dikurangi lewat otomasi.	(Paleyes, Urma, dan Lawrence 2022)
Pola Deployment Lanjut	Pola seperti <i>canary release</i> jarang digunakan, organisasi umumnya menggunakan <i>binary switchover</i> .	Dukungan <i>canary release</i> , A/B <i>testing</i> , dan <i>automatic rollback</i> prediktif.	<i>Rollout</i> dapat dilakukan secara bertahap dan aman, sehingga MTTR menurun karena kegagalan dapat dibatasi pada <i>canary traffic</i> .	(Shankar dkk. 2022)
Deteksi Drift	Deteksi <i>drift</i> bersifat reaktif dengan jeda deteksi yang panjang terhadap isu penting dan perubahan gradual.	<i>Monitoring</i> proaktif dengan uji statistik, <i>alert real-time</i> , dan penetapan ambang adaptif.	Jeda deteksi <i>drift</i> dapat dipersingkat sehingga <i>retraining</i> dapat dijadwalkan lebih tepat waktu untuk menjaga kinerja model.	(Céspedes Sisniega dkk. 2024; Bayram, Ahmed, dan Kassler 2022)
Tata Kelola & Lineage	Dokumentasi dilakukan secara manual dan <i>audit trail</i> sering tidak lengkap atau tersebar.	DataHub dengan <i>metadata ingestion</i> otomatis dan <i>lineage</i> yang dapat ditelusuri dari <i>source</i> hingga model, dibantu OpenLineage sebagai protokol pengirim peristiwa lintas <i>engine</i> pemrosesan.	Waktu persiapan audit dapat berkurang dan cakupan metadata meningkat melalui proses <i>ingestion</i> dan <i>lineage</i> otomatis.	(Stoyanovich, Howe, dan Jagadish 2020; Lamer dkk. 2024)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Observability	Fokus pemantauan pada metrik infrastruktur, tanpa cakupan metrik ML spesifik di sebagian besar organisasi.	<i>Observability</i> mencakup metrik ML, <i>dashboard</i> kinerja model, dan <i>alert</i> berbasis indikator <i>drift</i> . Prometheus dan Grafana menjadi inti, OpenTelemetry mengalirkan log dan <i>trace</i> ke Loki dan Grafana Tempo, sementara Alertmanager mengonsolidasikan <i>alert</i> ke berbagai kanal notifikasi.	Proses <i>debugging</i> dan <i>root cause analysis</i> menjadi lebih efektif sehingga MTTR dapat diturunkan.	(Shankar dkk. 2022)
Integrasi CI/CD	CI/CD untuk <i>pipeline</i> dan model dilakukan secara manual atau semi-otomatis, dengan alur kerja yang tidak seragam.	GitOps dengan Argo CD sebagai mekanisme <i>continuous deployment</i> deklaratif, dilengkapi Tekton untuk <i>continuous integration</i> dan Argo Rollouts untuk <i>progressive delivery</i> , dengan Git sebagai sumber kebenaran tunggal yang mencakup seluruh konfigurasi DataOps dan MLOps.	Frekuensi <i>deployment</i> dapat meningkat dan variasi kesalahan <i>deployment</i> dapat ditekan melalui otomasi dan <i>peer review</i> pada <i>pull request</i> .	(Kreuzberger, Kühl, dan Hirschl 2023)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Pengalaman <i>Developer</i>	<i>Developer</i> menghabiskan banyak waktu untuk tugas repetitif, <i>onboarding</i> lama, dan penggunaan alat yang terpisah.	Platform terintegrasi dengan <i>self-service</i> untuk data, fitur, <i>pipeline</i> , dan akses. Dex sebagai <i>identity provider</i> OIDC dan oauth2-proxy menyatukan autentikasi tunggal di seluruh antarmuka pengembang.	<i>Onboarding</i> dapat dipercepat dan produktivitas <i>data scientist</i> meningkat karena hambatan akses infrastruktur berkurang.	(Paleyes, Urma, dan Lawrence 2022; Rella 2022)
Efisiensi Biaya	Utilisasi sumber daya tidak optimal dan tidak ada atribusi biaya yang jelas ke <i>workload</i> .	<i>Auto-scaling</i> berbasis HPA, VPA, dan KEDA, pemantauan biaya melalui OpenCost, serta alokasi sumber daya yang lebih terukur pada kluster Kubernetes. Seluruh komponen inti berbasis <i>open source</i> sehingga biaya lisensi dapat ditekan.	Penghematan biaya signifikan dapat dicapai melalui optimasi pemakaian sumber daya dan <i>auto-scaling</i> , sebagaimana ditunjukkan dalam berbagai studi kasus adopsi Kubernetes (Lakka 2025). Desain ini mengadopsi prinsip yang sama untuk mengoptimalkan pemakaian sumber daya.	(Lakka 2025)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Keamanan & Compliance	Kontrol akses beragam di tiap sistem, dan <i>audit</i> tersebar tanpa pandangan terpadu.	RBAC terintegrasi, <i>audit trail</i> komprehensif, dan pengecekan <i>compliance</i> yang terotomatisasi. Dex sebagai <i>identity provider</i> OIDC memusatkan identitas, oauth2-proxy menegakkan autentikasi pada antarmuka aplikasi, Kyverno menegakkan kebijakan admisi pada klaster, OpenBao mengelola <i>secrets</i> , sementara Falco dan Trivy Operator memantau ancaman <i>runtime</i> dan kerentanan <i>image</i> .	Risiko insiden keamanan dapat berkurang melalui kontrol terpusat dan proses audit menjadi lebih ringkas.	(Ahmad dkk. 2024)

Perbandingan pada Tabel III.6 menempatkan setiap aspek arsitektur pada dua kondisi, yaitu praktik yang terdokumentasi pada penelitian terdahulu dan kondisi sesudah solusi terpilih diterapkan. Setiap baris menautkan peningkatan yang diklaim dengan rujukan penelitian yang mendasarinya sehingga posisi platform dapat diperiksa aspek demi aspek. Aspek tanpa dasar pada penelitian terdahulu tidak dimasukkan agar perbandingan tetap berpijak pada sumber. Rincian perwujudan tiap aspek menjadi bahan pemilihan komponen dan perancangan arsitektur pada Bab IV.

BAB IV

PERANCANGAN ARSITEKTUR PLATFORM DATAOPS DAN MLOPS

Bab ini menyajikan perancangan arsitektur platform yang mengintegrasikan DataOps dan MLOps pada Kubernetes. Pembahasan dimulai dari gambaran umum yang merangkum perbedaan kondisi sebelum dan sesudah integrasi, dilanjutkan dengan analisis layanan DataOps dan MLOps pada praktik industri yang menetapkan sembilan *layer* platform representatif, kemudian pemilihan komponen *open source* untuk tiap *layer* tersebut. Setelah komponen terpilih, bab ini merancang arsitektur terintegrasi beserta empat sub-sistem yang masing-masing memenuhi satu tujuan dari Bab I, yaitu arsitektur platform terintegrasi sebagai pemenuhan T-1, sub-sistem tata kelola data sebagai pemenuhan T-2, sub-sistem deteksi *drift* dengan *retraining* otomatis sebagai pemenuhan T-3, dan sub-sistem layanan fitur *dual-store* sebagai pemenuhan T-4. Bab ini ditutup dengan alur kerja *end-to-end* yang menghubungkan keempat sub-sistem dalam satu siklus yang dapat direproduksi.

IV.1 Gambaran Umum Platform

Platform yang dirancang menempatkan Kubernetes sebagai bidang orkestrasi tunggal dan menyatukan komponen DataOps dan MLOps di atasnya. Platform ini menggantikan kondisi fragmentasi pada Gambar III.1 dan Gambar III.2 dari Bab III, sedangkan arsitektur layanan terintegrasi digambarkan pada Gambar IV.1 di Subbab IV.2 dan rincian komponen tiap *layer* digambarkan pada Gambar IV.2 hingga Gambar IV.11 di Subbab IV.4. Komponen yang sebelumnya berdiri sendiri pada perangkat lunak yang berbeda kini terhubung melalui satu *control plane*, satu sumber kebenaran berbasis Git, dan satu antarmuka observabilitas. Penyatuan *control plane* memungkinkan tim platform menerapkan perubahan dengan satu mekanisme *deploy* yang sama untuk seluruh komponen, sehingga jalur integrasi yang sebelumnya tersebar dapat disederhanakan. Susunan platform ini sekaligus dirancang memenuhi tujuh komponen yang dipersyaratkan Google Cloud (2024) untuk MLOps *level* 2, yaitu *source control*, layanan uji dan *build*, layanan *deployment*, *model registry*, *feature store*, penyimpanan metadata ML, serta orkestrator *pipeline* dengan pemicu *retraining* otomatis dari deteksi *drift*. Gambaran umum ini sengaja belum menamai alat *open source* mana pun karena himpunan layanan pada sembilan *layer* platform ditetapkan lebih dahulu pada Subbab IV.2, alat untuk tiap *layer* baru dipilih melalui

penilaian berskor pada Subbab IV.3, dan pemetaan ketujuh komponen wajib tersebut ke alat terpilih dirangkum pada Subbab IV.4. Rantai yang sama menempatkan platform pada tahap DataOps dalam model evolusi Munappy dkk. (2020) karena CI/CD, orkestrasi, pengujian kualitas, dan pemantauan berlaku juga pada *pipeline* data, bukan hanya pada model.

Perbedaan utama terhadap kondisi sebelum integrasi terletak pada tiga aspek berikut.

1. **Penyatuan *control plane* pada Kubernetes**

Control plane yang sebelumnya tersebar pada bermacam *tool* digabungkan ke dalam *control plane* Kubernetes yang sama.

2. **Sumber kebenaran konfigurasi tunggal di Git**

Sumber kebenaran konfigurasi yang sebelumnya berada pada berkas konfigurasi terpisah disatukan pada repositori Git yang dijaga oleh layanan rekonsiliasi GitOps.

3. **Penyatuan antarmuka observabilitas**

Antarmuka observabilitas yang sebelumnya berbeda untuk metrik, log, dan *trace* disatukan pada satu antarmuka *dashboard* dengan penyimpanan khusus untuk tiap pilar sebagai sumber tiga pilar observabilitas.

Ketiga perbedaan tersebut bersama-sama memutus efek domino fragmentasi yang dibahas pada Subbab III.1.3. Kontrak antar *layer* yang seragam membuat kerusakan pada satu *layer* tertahan pada batas kontraknya dan tidak menjalar bebas ke *layer* di atasnya. Aset pada tiap *layer* dapat dirujuk silang melalui satu katalog metadata *lineage* sehingga pemeriksaan lintas *layer* berlangsung dari satu tempat. Rincian tiap *layer* beserta landasan kategorinya dibahas pada Subbab IV.4.

Platform tunggal ini dipakai oleh empat peran utama yang masing-masing masuk melalui antarmuka berbeda sesuai tanggung jawabnya. Tabel IV.1 merangkum pemetaan tiap peran ke antarmuka utama, *layer* yang diakses, dan fungsi yang dijalankan, sehingga satu titik masuk tunggal per peran menggantikan kebiasaan berpindah antar banyak *tool*. Karena seluruh komponen mendaftarkan katalog dan *lineage* ke satu katalog metadata bersama serta berbagi satu bidang identitas yang dirinci pada Subbab IV.5.3, metadata yang dihasilkan satu peran langsung terlihat oleh peran lain tanpa berpindah sistem. Penyatuan pada *interface layer* inilah yang melengkapi penyatuan pada *control plane*, sehingga keempat peran bekerja di atas satu platform tanpa kehilangan antarmuka yang sesuai dengan tugasnya.

Tabel IV.1 Pemetaan Peran Pengguna ke Antarmuka dan *Layer* Platform

Peran	Antarmuka Utama	Layer yang Diakses	Fungsi Utama
<i>Business User</i>	<i>Dashboard</i> analitik dan operasional	<i>Observability Layer</i>	<i>Dashboard</i> data dan operasional
<i>Data Engineer</i>	Katalog data dan konsol GitOps	<i>Data Governance Layer, GitOps and Continuous Delivery Layer, Orchestration and Infrastructure Layer</i>	Katalog, <i>rollout</i> konfigurasi, eksekusi <i>pipeline</i>
<i>Data Scientist</i>	<i>Notebook</i> eksperimen	<i>Model Lifecycle Layer, Feature Service Layer</i>	Eksperimen, <i>tracking</i> , registri fitur
<i>Machine Learning Engineer</i>	Konsol <i>pipeline</i> ML	<i>Model Lifecycle Layer, GitOps and Continuous Delivery Layer</i>	<i>Retraining, serving</i> , promosi versi

IV.2 Analisis Layanan DataOps dan MLOps pada Praktik Industri

Subbab ini menetapkan himpunan layanan representatif yang wajib dicakup arsitektur platform sebelum pemilihan alat dilakukan. Pembahasan dibagi menjadi dua bagian yang dibaca berurutan. Subbab IV.2.1 menyarikan bukti dari literatur mengenai komponen yang berulang pada praktik MLOps lebih dahulu, kemudian pada praktik DataOps. Subbab IV.2.2 mengonsolidasikan bukti tersebut menjadi sembilan *layer* platform yang menjadi satuan pemilihan alat sekaligus satuan perancangan arsitektur pada subbab-subbab berikutnya.

IV.2.1 Layanan pada Praktik MLOps dan DataOps

Kreuzberger, Kühl, dan Hirschl (2023) menurunkan sembilan komponen teknis MLOps melalui riset metode campuran yang memadukan tinjauan pustaka, tinjauan alat, dan wawancara pakar dari beragam domain. Kesembilan komponen tersebut adalah *CI/CD component, source code repository, workflow orchestration component, feature store system, model training infrastructure, model registry, ML metadata stores, model serving component*, dan *monitoring component*. Bukti dari praktik industri diberikan Amershi dkk. (2019) yang mengamati sejumlah tim rekayasa perangkat lunak di Microsoft dan merangkum kerja mereka menjadi alur kerja *machine learning* sembilan tahap, yaitu *model requirements, data collection, data cleaning, data labeling, feature engineering, model training, model evaluation, model deployment*, dan *model monitoring*. Kajian tersebut memilah tahap yang berorientasi data seperti *data collection, data cleaning*, dan *data labeling* dari tahap yang berorientasi model seperti *feature engineering, model training, model evaluation, model deployment*, dan *model monitoring*. Kedua sumber yang berangkat dari metode berbeda ini menamai komponen yang sebagian besar sama sehingga memperkuat keterun-

an himpunan layanan yang dibahas.

Amou Najafabadi dkk. (2024) melakukan pemetaan sistematis atas 43 studi primer dan mensintesis 35 komponen arsitektur MLOps ke dalam enam kategori, sekaligus mencatat jumlah kemunculan tiap komponen pada studi-studi tersebut. Komponen *model registry*, yang pada kajian itu bernama *model repository*, menjadi komponen paling sering muncul dengan 21 kemunculan, diikuti *ML metadata repository* sebanyak 15 kemunculan serta *ML experiment pipeline* sebanyak 14 kemunculan dan *ML training pipeline* sebanyak 12 kemunculan. Komponen *data collector*, *dataset repository*, dan *inference service* masing-masing muncul 10 kali, sedangkan *feature store* muncul 8 kali. Tidak ada satu komponen pun yang mencapai mayoritas mutlak dari 43 studi, tetapi pola kemunculan tersebut menunjukkan bahwa komponen yang sama berulang lintas studi yang independen. Pola itu sejalan dengan dokumentasi resmi Google Cloud (2024) yang menyebut tujuh komponen wajib untuk MLOps level 2, yaitu *source control*, *test and build services*, *deployment services*, *model registry*, *feature store*, *ML metadata store*, dan *ML pipeline orchestrator*. Panduan praktisi dari vendor yang sama merinci kapabilitas teknis inti MLOps sebagai *experimentation*, *data processing*, *model training*, *model evaluation*, *model serving*, *online experimentation*, *model monitoring*, *ML pipeline*, dan *model registry*, ditambah dua kapabilitas lintas fungsi berupa *ML metadata and artifact repository* serta *ML dataset and feature repository* (Salama, Kazmierczak, dan Schut 2021). Konvergensi lima sumber yang berbeda metode dan sudut pandang inilah yang dijadikan dasar bukti, bukan klaim bahwa satu komponen tunggal dipakai oleh mayoritas industri.

Pada sisi DataOps, Munappy dkk. (2020) menyusun model evolusi dari analitik data *ad hoc* menuju DataOps berdasarkan studi kasus di Ericsson dan mengidentifikasi tema praktik yang berulang, antara lain *data collection*, *data testing*, dan *data monitoring* di samping otomatisasi dan pengembangan *agile*. Kajian tersebut merinci teknologi data ke dalam empat kelompok, yaitu *data engineering* yang mencakup *data collection* dan *data ingestion*, *data preparation*, *data storage*, serta *data visualization*. Fase lanjutan pada model itu menegaskan perlunya *continuous testing and monitoring* pada *pipeline* data agar masalah kualitas terdeteksi sebelum menjalar ke tahap berikutnya. Definisi DataOps yang dikutip kajian tersebut juga menekankan akses terkendali terhadap data serta perlindungan privasi dan integritas data sebagai bagian tata kelola. Dengan demikian bidang data memperluas himpunan layanan MLOps melalui fungsi *data ingestion*, kualitas data, pemantauan, dan tata kelola.

Rella (2022) menempatkan tiga area penekanan utama DataOps, yaitu *data quality*,

pipeline automation, dan *data governance*, dengan pemantauan dan observabilitas data sebagai fungsi pelengkap. Kajian yang sama menautkan area tersebut ke komponen konkret seperti *feature store* untuk pengelolaan perubahan fitur dan *model registry* untuk kendali versi model, serta menyebut deteksi *drift* dan *retraining* otomatis sebagai mekanisme menjaga kinerja model. Jain dan Das (2025) menegaskan pembagian tanggung jawab yang serupa dengan menempatkan *data engineering* pada *ingestion*, transformasi, dan penyimpanan data, sedangkan MLOps menangani *deployment*, pemantauan, dan pengelolaan model melalui *CI/CD pipeline* otomatis. Ketiga sumber DataOps ini menamai fungsi *ingestion*, pemrosesan, penyimpanan, kualitas, tata kelola, dan pemantauan yang saling melengkapi dengan komponen model dari sumber MLOps. Gabungan bukti dari kedua bidang inilah yang membentuk himpunan layanan yang diklasifikasikan pada subbab berikutnya.

IV.2.2 Klasifikasi Sembilan *Layer Platform*

Bukti dari kedua bidang dikonsolidasikan menjadi sembilan *layer platform* yang menjadi satuan penilaian alat sekaligus satuan perancangan arsitektur. Kesembilan *layer* tersebut adalah *Orchestration and Infrastructure Layer*, *Data Ingestion and Processing Layer*, *Data Storage Layer*, *Feature Service Layer*, *Model Lifecycle Layer*, *Data Governance Layer*, *Observability Layer*, *GitOps and Continuous Delivery Layer*, dan *Platform Security Layer*, sesuai urutan pembahasannya pada Subbab IV.3 dan Subbab IV.4. Empat *layer* di antaranya menaungi bidang data, yaitu jalur *ingestion* dan pemrosesan, penyimpanan, layanan fitur, serta tata kelola data, sedangkan lima *layer* lainnya menaungi bidang model dan operasional platform. Tabel IV.2 memetakan tiap *layer* ke layanan dan komponen mayoritas yang menjadi cakupannya beserta sumber yang menamainya sehingga setiap *layer* dapat dirunut ke bukti terbit yang mendasarinya. Urutan kesembilan *layer* juga mengikuti urutan subbab konsep pada Bab II: *layer* orkestrasi dan infrastruktur berpijak pada Subbab II.2, *layer ingestion* dan pemrosesan serta *layer* penyimpanan data pada Subbab II.3, layanan fitur pada Subbab II.4, *model lifecycle* pada Subbab II.5, tata kelola data pada Subbab II.6, observabilitas pada Subbab II.8, GitOps pada Subbab II.9, dan keamanan platform pada Subbab II.10. Konsep deteksi *drift* pada Subbab II.7 tidak menjadi *layer* tersendiri karena merupakan mekanisme lintas *layer* yang menghubungkan fungsi pemantauan dengan siklus model, dan diwujudkan sebagai sub-sistem pada Subbab IV.6. Dengan demikian pemisahan *layer* pada bab ini konsisten dengan pemisahan konsep pada studi literatur, bukan taksonomi baru yang berdiri sendiri.


Tabel IV.2 Pemetaan Sembilan *Layer* Platform ke Komponen Mayoritas dan Sumbernya

Layer	Layanan dan Komponen Mayoritas	Sumber
<i>Orchestration and Infrastructure Layer</i>	<i>workflow orchestration, ML pipeline orchestrator, model training infrastructure, infrastructure and supporting services</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amou Najafabadi dkk. 2024; Google Cloud 2024)
<i>Data Ingestion and Processing Layer</i>	<i>data collection, data cleaning, data preprocessor, data ingestion</i>	(Amershi dkk. 2019; Amou Najafabadi dkk. 2024; Munappy dkk. 2020)
<i>Data Storage Layer</i>	<i>dataset repository, data storage, data versioning</i>	(Amou Najafabadi dkk. 2024; Munappy dkk. 2020; Jain dan Das 2025)
<i>Feature Service Layer</i>	<i>feature store (offline dan online)</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Model Lifecycle Layer</i>	<i>feature engineering, model training, model evaluation, model registry, ML metadata store, model serving component, inference service</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amershi dkk. 2019; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Data Governance Layer</i>	<i>data quality, data testing, data governance</i>	(Munappy dkk. 2020; Rella 2022; Jain dan Das 2025)
<i>Observability Layer</i>	<i>monitoring component, model monitoring, data monitoring</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amershi dkk. 2019; Amou Najafabadi dkk. 2024; Munappy dkk. 2020)
<i>GitOps and Continuous Delivery Layer</i>	<i>CI/CD component, source code repository, model deployment, deployment services</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Platform Security Layer</i>	<i>akses terkendali, kepatuhan privasi dan keamanan data, API gateway</i>	(Munappy dkk. 2020; Rella 2022; Amou Najafabadi dkk. 2024)

Pemetaan pada tabel tersebut menempatkan komponen *model lifecycle* seperti *model registry*, *ML metadata store*, dan *model training* pada *Model Lifecycle Layer*, sementara fungsi *monitoring component* dan *model monitoring* ditempatkan pada *Observability Layer* agar pemantauan tidak bercampur dengan *serving*. *Layer* bidang data menyerap komponen *data collection*, *data preprocessor*, *dataset repository*,

tory, dan *feature store* beserta fungsi *data quality* dan *data governance* dari sumber DataOps. *Platform Security Layer* berpijak pada dimensi tata kelola keamanan yang disebut sumber DataOps, yaitu akses terkendali serta kepatuhan terhadap privasi dan keamanan data. Landasan *layer* ini lebih ringan daripada *layer model lifecycle* yang didukung keempat sumber MLOps sekaligus. Perbedaan bobot bukti antar *layer* ini dinyatakan terbuka agar keterunutan tiap *layer* terhadap sumbernya dapat ditimbang pembaca.

Gambar IV.1 menggambarkan kesembilan *layer* tersebut sebagai satu arsitektur layanan terintegrasi pada satu *control plane* Kubernetes, tanpa mengikat diri pada alat tertentu, sehingga sasaran integrasi terbaca sebelum pemilihan alat dilakukan.



Gambar IV.1 Arsitektur layanan terintegrasi pada satu *control plane* tanpa keterikatan alat, memenuhi sasaran MLOps *level 2* (Google Cloud 2024) dan tahap DataOps (Munappy dkk. 2020), dengan komponen tiap *layer* bersumber pada Tabel IV.2.

Kesembilan *layer* ini bersifat lepas dari domain sehingga tidak terikat pada satu kasus penggunaan tertentu. Kasus penggunaan apa pun yang menjalankan seluruh sembilan *layer* dapat berperan sebagai kasus uji yang representatif bagi platform, karena verifikasi fungsionalnya akan menyentuh himpunan layanan yang sama dengan yang ditetapkan pada subbab ini. Pemilihan alat *open source* untuk tiap *layer* dibahas pada Subbab IV.3, sedangkan perancangan arsitektur kesembilan *layer* yang sama dibahas pada Subbab IV.4. Dengan demikian subbab ini menjadi titik tumpu yang menghubungkan bukti praktik industri ke rancangan sembilan *layer* sekaligus ke pemilihan kasus uji pada Bab V dan Bab VI.

IV.3 Analisis Pemilihan *Open Source Tools*

Subbab ini menurunkan pemilihan komponen konkret untuk Alternatif B, yaitu rangkaian alat *open source* di atas Kubernetes yang terpilih pada Subbab III.3.2. Pembahasan disusun mengikuti sembilan *layer* hasil klasifikasi pada Subbab IV.2, yang urutannya sejalan dengan urutan konsep pada Bab II, sehingga tiap alat dinilai pada konteks fungsi yang telah ditetapkan landasan buktinya. Amou Najafabadi dkk. (2024) menegaskan bahwa pemetaan eksplisit antara alat dan komponen arsitektur masih menjadi celah pada literatur MLOps, dan subbab ini menyediakan pemetaan tersebut untuk konteks platform *open source*. Kesembilan *layer* yang sama kemudian menjadi kerangka perancangan arsitektur pada Subbab IV.4, dengan tiap *layer* dirunut ke enam kategori komponen pada kajian yang sama.

Setiap *layer* yang memiliki lebih dari satu kandidat layak dinilai melalui tabel evaluasi dengan skala seragam 0 sampai 2 untuk tiap kriteria, dengan makna umum tiap nilai diberikan pada keterangan skor di bawah masing-masing tabel dan parameter penilaian tiap kriteria dirinci pada Lampiran A. Nilai 0 menandai kriteria yang tidak dipenuhi atau fitur yang tidak tersedia, nilai 1 menandai dukungan parsial yang masih menuntut komponen tambahan atau memikul keterbatasan berarti, dan nilai 2 menandai pemenuhan penuh oleh kapabilitas bawaan. Penilaian diturunkan dari dokumentasi resmi dan status pemeliharaan tiap proyek, sedangkan kolom Total menjumlahkan keempat kriteria sehingga nilai tertingginya delapan. Kolom Lisensi (Yayasan) mencantumkan lisensi resmi beserta yayasan yang menaunginya sebagai bukti keterbukaan tata kelola, bersifat informatif, dan tidak mengubah perhitungan kolom Total. Alat dengan nilai Total tertinggi pada tiap tabel menjadi pilihan utama platform untuk fungsi yang dievaluasi, sementara alat berskor lebih rendah dapat tetap dipakai sebagai pendamping dengan peran berbeda sebagaimana diuraikan pada tiap *layer*.

IV.3.1 *Orchestration and Infrastructure Layer*

Layer orkestrasi menjadi fondasi tempat seluruh komponen platform dijalankan, sebagaimana dibahas pada Subbab II.2.1. Untuk lingkungan satu *node*, distribusi Kubernetes ringan yang dipertimbangkan adalah *k3s*, *k0s*, MicroK8s, dan *kind*. Keempatnya lolos uji *conformance* CNCF sehingga API yang dipakai komponen tetap identik, dan kriteria penilaian menyoroti *footprint*, kesiapan produksi, dependensi *runtime*, serta model lisensi. Tabel IV.3 merangkum perbandingan keempatnya terhadap kriteria tersebut.

k3s dipilih karena biner tunggalnya di bawah seratus megabita berjalan pada memori terbatas, kesiapannya setara Kubernetes penuh untuk beban produksi, *containerd* yang tertanam menghilangkan dependensi *runtime* eksternal, dan *controller* Helm bawaannya mempermudah pemasangan komponen. Sebaliknya *kind* ditujukan untuk pengujian CI dan bukan produksi, sedangkan *k0s* dan MicroK8s dikelola masing-masing oleh satu vendor tanpa naungan yayasan netral. Nilai Total tertinggi pada *k3s* mencerminkan gabungan kesiapan produksi dan *footprint* ringan yang sesuai dengan batasan implementasi BI-1 pada Bab V. Pilihan ini tidak mengikat rancangan pada satu *node*, sebab keempat distribusi berbagi API yang sama sehingga migrasi ke distribusi lain tidak mengubah manifes komponen.

Tabel IV.3 Evaluasi Alternatif Distribusi Kubernetes *Open-Source*

Distribusi	<i>Footprint</i> Ringan	Siap Produksi	Tanpa De- pendensi	Eko- sistem Add-on	Lisensi (Yayasan)	Total
<i>k3s</i>	2	2	2	2	Apache 2.0 (CNCF)	8
<i>k0s</i>	2	2	2	1	Apache 2.0 (mandiri)	7
MicroK8s	1	2	1	2	Apache 2.0 (mandiri)	6
<i>kind</i>	1	0	1	0	Apache 2.0 (CNCF)	2

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.2 Data Ingestion and Processing Layer

Data ingestion layer dan *processing layer* memindahkan data dari sumber ke penyimpanan analitik, dengan *message broker* sebagai tulang punggung aliran peristiwa yang dijelaskan pada Subbab II.3.2. Kandidat yang dipertimbangkan adalah Apache Kafka, Redpanda, Apache Pulsar, dan NATS JetStream, dengan perbandingan pada Tabel IV.4. Kafka dipilih karena ekosistem konektornya paling luas, *operator* Strimzi menyediakan pengelolaan deklaratif yang matang pada Kubernetes, lisensinya Apache 2.0 di bawah *Apache Software Foundation*, dan protokolnya dibaca langsung oleh konektor Flink, tabel *Kafka engine* ClickHouse, serta *scaler* KEDA. Ketergantungan silang inilah yang membuat Kafka memperoleh skor penuh pada ekosistem konektor dan kompatibilitas protokol, dua kriteria tempat sebagian alternatif tertinggal.

Tabel IV.4 Evaluasi Alternatif *Message Broker* untuk Tulang Punggung *Streaming*

<i>Message Broker</i>	Eko-sistem Konektor	Operator K8s	Lisensi Terbuka	Protokol Kafka	Lisensi (Yayasan)	Total
Apache Kafka	2	2	2	2	Apache 2.0 (ASF)	8
Redpanda	1	2	0	2	BSL 1.1 (mandiri)	5
Apache Pulsar	1	1	2	1	Apache 2.0 (ASF)	5
NATS JetStream	1	1	2	0	Apache 2.0 (CNCF)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Registrasi skema dinilai terpisah karena menjadi kontrak evolusi data lintas produsen dan konsumen, sebagaimana dibahas pada Subbab II.3.2. Tabel IV.5 membandingkan beberapa *schema registry* pada ekosistem Kafka. Karapace dipilih sebagai *registry* kompatibel-Confluent berlisensi Apache 2.0 dengan dukungan Avro, JSON Schema, dan Protobuf serta verifikasi kompatibilitas saat publikasi. Karapace menyimpan skema pada *topic* internal Kafka sehingga tidak menambah basis data baru pada platform.

Pemrosesan data mencakup jalur *streaming* dan *batch* yang dibahas pada Subbab II.3.3 dan Subbab II.3.4. Tabel IV.6 membandingkan mesin pemrosesan menurut kriteria kelayakan platform. Apache Spark memperoleh Total tertinggi sebagai mesin pemrosesan *batch* berskala besar, sedangkan Apache Flink dipilih untuk jalur *streaming* karena dukungan *event-time* dan *exactly-once* dengan *checkpointing* yang membuatnya unggul pada kriteria *streaming* meski lebih rendah pada kriteria *batch*.

Tabel IV.5 Evaluasi Alternatif *Schema Registry* untuk Apache Kafka

<i>Schema Registry</i>	Lisensi <i>Open</i>	Kompati- bilitas Conflu- ent	Duku- ngan Format	Kema- tangan	Lisensi (Yayasan)	Total
Karapace (Aiven)	2	2	2	1	Apache 2.0 (mandiri)	7
Apicurio Registry	2	1	2	1	Apache 2.0 (mandiri)	6
Confluent <i>Schema Registry</i>	0	2	2	2	<i>Confluent Community</i> (mandiri)	6
Cloudera <i>Schema Registry</i>	2	0	1	1	Apache 2.0 (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Transformasi SQL deklaratif pada *warehouse layer* dikerjakan oleh dbt. Ketiganya memikul peran berbeda pada jalur data sehingga saling melengkapi tanpa tumpang tindih fungsi.

Tabel IV.6 Evaluasi Alternatif *Framework* Pemrosesan Data

<i>Framework Pemrosesan</i>	Kema- tangan	Kapa- bilitas <i>Batch</i>	Kapa- bilitas <i>Stream- ing</i>	Komu- nitas	Lisensi (Yayasan)	Total
Apache Spark	2	2	1	2	Apache 2.0 (ASF)	7
Apache Flink	2	1	2	1	Apache 2.0 (ASF)	6
Apache Kafka + Streams	2	0	2	1	Apache 2.0 (ASF)	5
Apache Beam	1	1	1	1	Apache 2.0 (ASF)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.3 Data Storage Layer

Layer penyimpanan menyimpan data jangka panjang beserta versinya, dengan format tabel *lakehouse* yang menjamin transaksi dan evolusi skema, sebagaimana dibahas pada Subbab II.3.5. Kandidat format adalah Apache Iceberg, Delta Lake, dan Apache Hudi, dengan perbandingan pada Tabel IV.7. Apache Iceberg dipilih karena netralitas *engine*, dukungan katalog REST melalui Lakekeeper, dan kemampuan kueri federasi melalui Trino. Netralitas *engine* inilah yang membuat Iceberg unggul, sebab tabel yang sama dapat dibaca dan ditulis oleh Trino, Spark, maupun Flink tanpa migrasi data fisik.

Tabel IV.7 Evaluasi Alternatif Format Tabel *Lakehouse Open-Source*

Format Tabel	Kemampuan	Transaksi ACID	Evolusi Skema	Integrasi Engine	Lisensi (Yayasan)	Total
Apache Iceberg	2	2	2	2	Apache 2.0 (ASF)	8
Delta Lake	2	2	1	1	Apache 2.0 (LF)	6
Apache Hudi	1	2	1	1	Apache 2.0 (ASF)	5
Parquet (tanpa format tabel)	2	0	1	2	Apache 2.0 (ASF)	5

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Penyimpanan objek menjadi landasan bagi *data lake*, *model registry*, dan pencadangan, sebagaimana dibahas pada Subbab II.3.6. Tabel IV.8 membandingkan empat penyedia objek S3-kompatibel. MinIO dipilih karena *footprint* ringan pada satu *node*, kompatibilitas API S3 yang luas, dukungan enkripsi sisi *server* berbasis KMS, dan kemampuan berjalan pada modus distribusi maupun *single-node*. Kompatibilitas API S3 yang luas membuat MinIO dapat dipakai lintas komponen tanpa penyesuaian klien.

Tabel IV.8 Evaluasi Alternatif Penyimpanan Objek S3-Kompatibel *Open-Source*

Penyimpanan Objek	Kompatibilitas S3	<i>Footprint</i> Satu Node	Enkripsi KMS	Dukungan K8s	Lisensi (Yayasan)	Total
MinIO	2	2	2	2	AGPL v3 (mandiri)	8
SeaweedFS	1	2	1	1	Apache 2.0 (mandiri)	5
Ceph RGW	2	0	2	2	LGPL 2.1 (LF)	6
Garage	1	2	0	1	AGPL v3 (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Versi data pada *layer* objek dinilai terpisah karena menyangkut ketertelusuran perubahan *dataset*, sebagaimana dibahas pada Subbab II.3.6. Tabel IV.9 membandingkan lakeFS, DVC, Project Nessie, dan Pachyderm. lakeFS dipilih karena percabangan *zero-copy* bekerja langsung di atas MinIO tanpa terikat satu format tabel, antarmukanya tetap S3 sehingga *engine* pemrosesan tidak perlu diubah, dan lisensinya Apache 2.0 sementara Pachyderm berlisensi *source-available*. Model percabangan bergaya Git ini menjaga jejak versi data tanpa menggandakan berkas.

Tabel IV.9 Evaluasi Alternatif Pengelola Versi Data *Open-Source* pada *Layer* Penyimpanan Objek

Pengelola Versi	Per-cabangan Tanpa Salin	Integrasi Objek S3	Skala Data Besar	Lisensi Terbuka	Lisensi (Yayasan)	Total
lakeFS	2	2	2	2	Apache 2.0 (mandiri)	8
Project Nessie	2	1	1	2	Apache 2.0 (mandiri)	6
DVC	1	1	1	2	Apache 2.0 (mandiri)	5
Pachyderm	1	1	1	0	<i>Source-available</i> (mandiri)	3

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.4 Feature Service Layer

Layer layanan fitur menghubungkan jalur data dengan jalur model melalui definisi fitur yang sama, sebagaimana dibahas pada Subbab II.4.1. Tabel IV.10 membandingkan beberapa kerangka *feature store open source*. Feast dipilih karena modularitas penyimpanan dan kontrak API yang konsisten lintas *offline* dan *online*, yang tecermin pada skor penuh di seluruh kriteria termasuk ekstensibilitas dan integrasi K8s. Hopsworks dan Featureform memperoleh skor lebih rendah pada ekstensibilitas dan komunitas sehingga Total keduanya berada di bawah Feast.

Tabel IV.10 Evaluasi Alternatif *Feature Store Open-Source*

<i>Feature Store</i>	Kematan- tangan	Eksten- sibilitas	Komu- nitas	Integrasi K8s	Lisensi (Yayasan)	Total
Feast	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Hopsworks <i>Feature Store</i>	1	1	1	1	AGPL v3 (mandiri)	4
Feathr (LinkedIn)	0	1	0	1	Apache 2.0 (LF AI & Data)	2
Featureform	1	1	0	1	MPL 2.0 (mandiri)	3

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Feature store dipisah menjadi *offline* untuk pelatihan dan *online* untuk *inference* berlatensi rendah, sebagaimana dibahas pada Subbab II.4.2. Tabel IV.11 dan Tabel IV.12 menilai kandidat untuk kedua peran tersebut. ClickHouse dipilih sebagai *offline store* karena kompresi kolumnar dan latensi kueri agregasi yang rendah, sedangkan Valkey dipilih sebagai *online store* karena kompatibilitas *wire-protocol* RESP dengan ekosistem klien Redis serta lisensi BSD di bawah Linux Foundation yang tetap terbuka pasca-perubahan lisensi Redis. Kedua pilihan mencerminkan perbedaan karakter beban antara kueri agregasi pada jutaan baris dan *lookup* sub-milidetik saat *inference*.

Fitur *embedding* berdimensi tinggi memerlukan indeks tetangga terdekat yang dibahas pada Subbab II.4.3. Tabel IV.13 membandingkan beberapa *vector index open source*. Qdrant dipilih karena dukungan HNSW *native*, mode *gRPC* berlatensi rendah, dan kemampuan filter pada *payload* yang menyatu dengan kueri kemiripan. Pemisahan *vector index* dari *online store* tabular menjaga tiap penyimpanan tetap dioptimasi untuk karakter kuerinya sendiri.

Tabel IV.11 Evaluasi Alternatif Penyimpanan *Offline* (OLAP)

Penyimpanan <i>Offline</i>	Kema- tangan	Performa <i>Query</i>	Duku- ngan <i>Ingestion</i>	Komu- nitas	Lisensi (Yayasan)	Total
ClickHouse	2	2	2	2	Apache 2.0 (mandiri)	8
Apache Pinot	1	2	2	1	Apache 2.0 (ASF)	6
Apache Druid	2	2	2	1	Apache 2.0 (ASF)	7
Apache Kudu	1	1	1	1	Apache 2.0 (ASF)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Tabel IV.12 Evaluasi Alternatif Penyimpanan *Online* (Latensi Rendah)

Penyimpanan <i>Online</i>	Kema- tangan	Latensi	Through- put	Lisensi <i>Open</i>	Lisensi (Yayasan)	Total
Valkey (RESP)	2	2	2	2	BSD-3 (LF)	8
Redis <i>Community</i>	2	2	2	1	AGPL v3 (mandiri)	7
DragonflyDB	1	2	2	0	BSL 1.1 (mandiri)	5
Apache Cassandra	2	1	2	2	Apache 2.0 (ASF)	7

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Tabel IV.13 Evaluasi Alternatif *Vector Index Open-Source* untuk Pencarian Pendekatan Tetangga Terdekat

<i>Vector Index</i>	Kema- tangan	Latensi Rendah	Komu- nitas	Opera- bilitas K8s	Lisensi (Yayasan)	Total
Qdrant (HNSW)	2	2	1	2	Apache 2.0 (mandiri)	7
Milvus	2	2	1	1	Apache 2.0 (LF AI & Data)	6
Weaviate	1	1	1	1	BSD-3 (mandiri)	4
pgvector (PostgreSQL)	2	1	1	2	PostgreSQL <i>License</i> (komunitas)	6

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.5 Model Lifecycle Layer

Model lifecycle layer mengantar model dari eksperimen sampai *serving*, dimulai dari *tracking* eksperimen dan *registry* model pada Subbab II.5.1. Tabel IV.14 membandingkan beberapa platform *tracking*. MLflow dipilih karena menyatukan *tracking* eksperimen, *registry* model, dan *API deployment* pada satu layanan dengan *backend* PostgreSQL dan *artifact store* MinIO. Penyatuan ketiga fungsi ini memberi MLflow keunggulan integrasi dibanding alat *tracking* yang hanya menangani pencatatan metrik.

Tabel IV.14 Evaluasi Alternatif *Experiment Tracking* dan *Model Registry*

<i>Tracking & Registry</i>	Kemampuan	Ekstensibilitas	Komunitas	Integrasi	Lisensi (Yayasan)	Total
MLflow	2	2	2	2	Apache 2.0 (LF)	8
DVC (<i>Data Version Control</i>)	1	1	1	1	Apache 2.0 (mandiri)	4
TensorBoard	2	2	1	0	Apache 2.0 (mandiri)	5
Neptune	1	1	1	1	<i>Proprietary SaaS</i> (klien Apache 2.0)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Orkestrasi pelatihan dinilai terpisah karena menyangkut eksekusi *pipeline* pada Kubernetes, sebagaimana dibahas pada Subbab II.5.2. Tabel IV.15 membandingkan Kubeflow Pipelines, Argo Workflows, dan Apache Airflow. Kubeflow Pipelines dipilih untuk jalur pelatihan karena *component* berbasis kontainer dengan kontrak input dan output yang ditegakkan Pipeline IR, sedangkan Argo Workflows dipakai untuk *control loop* CronWorkflow yang memicu *retraining*. Pemisahan peran kedua *orchestrator* menjaga *pipeline* pelatihan dapat dipromosikan tanpa mengganggu *control loop* pemantauan. Apache Airflow pada tabel yang sama dipilih sebagai *orchestrator pipeline* data *batch*, sehingga tanggung jawab orkestrasi data terpisah dari orkestrasi *training*.

Model serving mengakhiri pembahasan *layer* ini dengan menyajikan model sebagai layanan, sebagaimana dibahas pada Subbab II.5.4. Tabel IV.16 membandingkan kerangka *serving* menurut kriteria kelayakan platform. KServe dipilih karena dukungan banyak *runtime*, penskalaan otomatis termasuk ke nol melalui Knative, dan integrasi dengan praktik GitOps. Nilai Total tertinggi pada KServe mencerminkan kematangan, skalabilitas, dan dukungan multi-*framework* yang tidak dimiliki penuh oleh kerangka *serving* berbasis satu *framework*.

Tabel IV.15 Evaluasi Alternatif Orkestrasi ML *Open-Source*

Orkestrasi ML	Kema- tangan	K8s- Native	Pipeline ML	Komu- nitas	Lisensi (Yayasan)	Total
Kubeflow Pipelines	1	2	2	2	Apache 2.0 (CNCF)	7
Apache Airflow	2	1	1	2	Apache 2.0 (ASF)	6
Argo Workflows	2	2	1	1	Apache 2.0 (CNCF)	6
Prefect	1	1	1	1	Apache 2.0 (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Tabel IV.16 Evaluasi Alternatif *Model Serving*

Model Serving	Kema- tangan	Skala- bilitas	Frame- work	Komu- nitas	Lisensi (Yayasan)	Total
KServe	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Seldon Core	1	1	2	1	BSL 1.1 (mandiri)	5
BentoML	1	1	2	1	Apache 2.0 (mandiri)	5
TorchServe	0	1	0	1	Apache 2.0 (LF/PyTorch)	2

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.6 Data Governance Layer

Layer tata kelola menegakkan katalog, kualitas, dan *lineage* data sepanjang siklus, sebagaimana dibahas pada Subbab II.6. Fungsi katalog metadata menjadi pusat *layer* ini karena menautkan aset data lintas komponen DataOps dan MLOps. Tabel IV.17 membandingkan beberapa pilihan katalog metadata. Kriteria penilaian menyoroti keluasan integrasi, dukungan *lineage*, kematangan proyek, dan model lisensi.

DataHub dipilih sebagai katalog metadata karena dukungan integrasi luas dengan komponen DataOps dan MLOps serta penerimaan *lineage* melalui standar terbuka OpenLineage. Great Expectations melengkapi *layer* ini sebagai kontrak kualitas yang dijalankan pada *pipeline* produksi, sedangkan OpenLineage menjadi protokol *lineage* yang menyeragamkan jejak dari *ingestion* hingga model. Ketiganya bekerja sebagai satu bidang tata kelola, yaitu katalog untuk penemuan, kontrak untuk kualitas, dan protokol untuk asal-usul. Pemisahan peran ini menghindari tumpang tindih fungsi antara alat katalog dan alat kualitas.

Tabel IV.17 Evaluasi Alternatif Manajemen Metadata dan Tata Kelola

Metadata & Tata Kelola	Kematangan	Ekstensibilitas	Komunitas	Integrasi	Lisensi (Yayasan)	Total
DataHub (LinkedIn)	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Apache Atlas	2	1	1	1	Apache 2.0 (ASF)	5
OpenMetadata	1	1	1	2	Apache 2.0 (LF)	5
Amundsen (Lyft)	1	1	0	1	Apache 2.0 (LF AI & Data)	3

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.7 Observability Layer

Layer observabilitas menyatukan metrik, log, dan *trace* pada satu antarmuka, sebagaimana dibahas pada Subbab II.8. Tabel IV.18 membandingkan beberapa *observability stack open source*. Kombinasi Prometheus untuk metrik, Loki untuk log, dan Grafana Tempo untuk *trace* dengan OpenTelemetry sebagai *collector* bersama dipilih karena korelasi antar pilar dapat ditegakkan melalui label *trace_id* yang seragam. Grafana menjadi antarmuka visualisasi tunggal yang menyatukan ketiga pilar tersebut.

Tabel IV.18 Evaluasi Alternatif *Monitoring* dan *Observability*

<i>Monitoring & Observability</i>	Kematan- tangan	Eksten- sibilitas	Komu- nitas	Integrasi K8s	Lisensi (Yayasan)	Total
Prometheus + Grafana	2	2	2	2	Apache 2.0 (CNCF) + AGPL v3 (mandiri)	8
InfluxDB + Chronograf	1	1	1	1	MIT (mandiri)	4
Elastic Stack (ELK)	2	1	1	2	AGPL v3 (mandiri)	6
Jaeger + OpenTelemetry	2	1	2	2	Apache 2.0 (CNCF)	7

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Antarmuka *business intelligence* dinilai terpisah karena menyajikan hasil kueri lintas basis data pada satu *dashboard layer*, sebagaimana dibahas pada Subbab II.8. Tabel IV.19 membandingkan beberapa pilihan BI *open source*. Apache Superset dipilih karena menyatukan kueri SQL lintas ClickHouse, Trino, dan MySQL pada satu antarmuka *dashboard*. Pemisahan Superset untuk *dashboard* analitik dari Grafana untuk pemantauan sistem menjaga tiap antarmuka fokus pada jenis pengamatan yang berbeda.

Tabel IV.19 Evaluasi Alternatif *Business Intelligence* dan *Dashboarding*
Open-Source

<i>BI Tool</i>	Kema- tangan	Konektor SQL	Multi- Tenant K8s	Komu- nitas	Lisensi (Yayasan)	Total
Apache Superset	2	2	2	2	Apache 2.0 (ASF)	8
Metabase	2	1	1	1	AGPL v3 (mandiri)	5
Redash	1	1	1	1	BSD-2 (mandiri)	4
Lightdash	1	1	1	1	MIT (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.8 *GitOps and Continuous Delivery Layer*

Layer GitOps menempatkan repositori Git sebagai sumber kebenaran tunggal konfigurasi sistem, sebagaimana dibahas pada Subbab II.9. Tabel IV.20 membandingkan beberapa *GitOps controller open source*. Argo CD dipilih sebagai *operator* GitOps karena merekonsiliasi keadaan *cluster* dengan deklarasi pada Git secara berkelanjutan dan menyediakan antarmuka penelusuran sinkronisasi yang matang. Kriteria penilaian menyoroti model rekonsiliasi, dukungan multi-*tenant*, dan kematangan ekosistem.

Rantai *continuous delivery* dilengkapi Gitea sebagai repositori *self-hosted*, Tekton sebagai *pipeline* CI, dan Argo Rollouts untuk *deployment* progresif berbasis *canary*. Keempat komponen menjaga seluruh manifes, *chart*, dan *overlay* berada pada satu *control plane* yang ditarik Argo CD tanpa ketergantungan penyedia eksternal. Pembagian peran menempatkan Argo CD pada rekonsiliasi keadaan dan Tekton pada pembangunan artefak sehingga keduanya tidak tumpang tindih. Rantai ini menjadi mekanisme yang memicu *retraining* model melalui kontrol deklaratif yang sama.

Tabel IV.20 Evaluasi Alternatif *GitOps Controller Open-Source*

<i>GitOps Controller</i>	Kemampuan	K8s-Native	Antarmuka	Komunitas	Lisensi (Yayasan)	Total
Argo CD	2	2	2	2	Apache 2.0 (CNCF)	8
Flux CD	2	2	1	1	Apache 2.0 (CNCF)	6
Rancher Fleet	1	2	1	1	Apache 2.0 (mandiri)	5
Jenkins X	1	1	1	0	Apache 2.0 (CDF)	3

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.
Parameter penilaian tiap kriteria dirinci pada Lampiran A.

IV.3.9 Platform Security Layer

Layer keamanan bekerja dengan pola *defense in depth* yang dibahas pada Subbab II.10, mencakup identitas, rahasia, *service mesh*, kebijakan, dan pemantauan *runtime*. Untuk identitas terpadu, Tabel IV.21 membandingkan beberapa *identity provider open source*. Dex dipilih sebagai *identity provider* OIDC karena *footprint* ringan, dukungan federasi terhadap penyedia eksternal, dan integrasi sederhana dengan Kubernetes. oauth2-proxy dan SpiceDB melengkapi *layer* identitas untuk konsol tanpa OIDC *native* dan otorisasi granular.

Tabel IV.21 Evaluasi Alternatif Identity Provider Open-Source

Identity Provider	Bobot Footprint	Federasi OIDC	Operabilitas K8s	Kemampuan	Lisensi (Yayasan)	Total
Dex IdP	2	2	2	2	Apache 2.0 (CNCF)	8
Keycloak	1	2	2	2	Apache 2.0 (CNCF)	7
Authelia	2	1	1	1	Apache 2.0 (mandiri)	5
Authentic	0	2	1	1	MIT (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Pengelolaan rahasia dinilai terpisah karena menyimpan kredensial dan kunci enkripsi platform, sebagaimana dibahas pada Subbab II.10.1. Tabel IV.22 membandingkan beberapa pengelola rahasia *open source*. OpenBao dipilih sebagai *fork open source* dari HashiCorp Vault di bawah Linux Foundation karena menjamin penyimpanan terenkripsi dan penerbitan kredensial dinamis tanpa basis data eksternal berkat *integrated storage* Raft. External Secrets Operator menyalurkan rahasia ke Secret Kubernetes dengan rotasi otomatis.

Tabel IV.22 Evaluasi Alternatif Pengelola Rahasia

Pengelola Rahasia	Lisensi Open	Rotasi Dinamis	Integrasi ESO	Kemampuan	Lisensi (Yayasan)	Total
OpenBao	2	2	2	1	MPL 2.0 (LF)	7
HashiCorp Vault Community	0	2	2	2	BUSL 1.1 (mandiri)	6
Bitnami Sealed Secrets	2	0	0	2	Apache 2.0 (mandiri)	4
Mozilla SOPS	2	0	0	2	MPL 2.0 (CNCF)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Komunikasi antar-layanan dan perbatasan *mesh* dibahas pada Subbab II.10.2. Tabel IV.23 dan Tabel IV.24 menilai *service mesh* dan *API gateway*. Istio dipilih se-

bagai *service mesh* karena *mutual TLS* seragam, kontrol lalu lintas *layer* aplikasi, dan integrasi telemetri dengan OpenTelemetry, sedangkan Apache APISIX dipilih sebagai *API gateway* yang menyaring lalu lintas masuk dan menjembatani mTLS terhadap konsumen di luar *mesh*. Keduanya memisahkan kontrol lalu lintas internal dari kontrol perbatasan tanpa fungsi yang tumpang tindih.

Tabel IV.23 Evaluasi Alternatif *Service Mesh*

<i>Service Mesh</i>	Kema- tangan	Fitur L7	Eko- sistem CRD	Komu- nitas	Lisensi (Yayasan)	Total
Istio <i>ambient/sidecar</i>	2	2	2	2	Apache 2.0 (CNCF)	8
Linkerd	2	1	1	1	Apache 2.0 (CNCF)	5
Cilium Service Mesh	1	1	1	2	Apache 2.0 (CNCF)	5
Consul Connect	1	1	1	1	BUSL 1.1 (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Tabel IV.24 Evaluasi Alternatif *API Gateway Open-Source*

<i>API Gateway</i>	Kema- tangan	Lisensi <i>Open</i>	Opera- bilitas K8s	<i>Plugin/</i> Ekstensi	Lisensi (Yayasan)	Total
Apache APISIX	2	2	2	2	Apache 2.0 (ASF)	8
Kong <i>Gateway</i> <i>OSS</i>	2	2	2	1	Apache 2.0 (mandiri)	7
Emissary Ingress (Ambassador)	1	2	2	1	Apache 2.0 (CNCF)	6
NGINX Ingress	1	2	2	1	Apache 2.0 (komunitas Kubernetes)	6

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Penegakan kebijakan *admission* dinilai terpisah, sebagaimana dibahas pada Subbab II.10.2. Tabel IV.25 membandingkan beberapa *policy engine open source*. Kyverno dipilih sebagai *policy engine native* Kubernetes dengan sintaks YAML ringkas serta dukungan *mutate*, *validate*, dan *generate*. Sintaks berbasis YAML membuat Kyverno lebih mudah diadopsi dibanding alternatif berbasis Rego pada konteks tim platform.

Pemantauan ancaman pada *runtime layer* melengkapi *layer* keamanan, sebagaimana dibahas pada Subbab II.10.2. Tabel IV.26 membandingkan beberapa alat *runtime security open source*. Falco dipilih sebagai detektor berbasis eBPF yang memantau

Tabel IV.25 Evaluasi Alternatif *Policy Engine Open-Source*

<i>Policy Engine</i>	Sintaks <i>Native</i>	Mode <i>Mutate</i>	Pela- poran Pelang- garan	Komu- nitas	Lisensi (Yayasan)	Total
Kyverno	2	2	2	2	Apache 2.0 (CNCF)	8
OPA Gatekeeper	1	1	1	2	Apache 2.0 (CNCF)	5
jsPolicy	1	1	1	0	Apache 2.0 (mandiri)	3
Kubewarden	1	1	2	1	Apache 2.0 (CNCF)	5

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

syscall, dilengkapi Trivy Operator untuk pemindaian *image*, Velero untuk penca-
dangan, dan Chaos Mesh untuk uji ketahanan. Keempat alat mencakup dimensi
berbeda dari keamanan *runtime* sehingga tidak saling menggantikan.

Tabel IV.26 Evaluasi Alternatif *Runtime Security Open-Source* pada Kubernetes

<i>Runtime Security</i>	Kema- tangan	Cakupan eBPF/ Kernel	Aturan Bawaan	Komu- nitas	Lisensi (Yayasan)	Total
Falco	2	2	2	2	Apache 2.0 (CNCF)	8
Cilium Tetragon	1	2	1	1	Apache 2.0 (CNCF)	5
Aqua Tracee	1	2	1	1	Apache 2.0 (mandiri)	5
Sysdig Secure OSS	1	1	1	1	Apache 2.0 (mandiri)	4

Keterangan skor: 0 = tidak memenuhi, 1 = memenuhi sebagian, 2 = memenuhi seluruhnya.

Parameter penilaian tiap kriteria dirinci pada Lampiran A.

Pemetaan pada subbab ini menautkan tiap *layer* arsitektur ke satu alat utama beserta pendampingnya, sehingga perancangan arsitektur pada subbab-subbab berikutnya dapat langsung merujuk komponen terpilih tanpa mengulang pertimbangan pemilihan. Alat dengan nilai Total tertinggi pada tiap tabel menjadi pilihan utama *layer*-nya, sedangkan alat pendamping memikul peran yang berbeda tanpa tumpang tindih fungsi, seperti Flink untuk *streaming* di samping Spark untuk *batch* dan Argo Workflows untuk *control loop* di samping Kubeflow Pipelines untuk pelatihan. Pemisahan konsep pada Bab II dari pemilihan pada subbab ini menjaga tinjauan pustaka tetap umum sementara keputusan alat ditegakkan dengan bukti skor. Dengan pemetaan ini, keputusan teknis di seluruh laporan dapat dirunut dari konsep pada Bab II, ke pemilihan pada subbab ini, hingga perwujudan pada Bab V.

IV.4 Perancangan Arsitektur Terintegrasi

Bagian ini menjawab T-1 dengan merancang arsitektur platform DataOps dan MLOps terintegrasi pada Kubernetes. Arsitektur disusun langsung dalam sembilan *layer* hasil klasifikasi Subbab IV.2 yang saling terhubung melalui kontrak antarmuka eksplisit, yaitu *Orchestration and Infrastructure Layer*, *Data Ingestion and Processing Layer*, *Data Storage Layer*, *Feature Service Layer*, *Model Lifecycle Layer*, *Data Governance Layer*, *Observability Layer*, *GitOps and Continuous Delivery Layer*, serta *Platform Security Layer*. Satu pemisahan yang sama dengan demikian dipakai dari klasifikasi layanan, penilaian alat pada Subbab IV.3, sampai perancangan pada subbab ini, tanpa taksonomi perantara. Susunan ini bukan taksonomi baru karena setiap *layer* berpijak pada baris bersumber Tabel IV.2 dan mengikuti urutan subbab konsep Bab II sebagaimana dipetakan pada Subbab IV.2.2. Subbab berikut merinci kesembilan *layer* tersebut satu per satu beserta diagram beralatnya.

Amou Najafabadi dkk. (2024) mengelompokkan komponen arsitektur MLOps yang telah diperkenalkan pada Subbab IV.2 ke dalam enam kategori, yaitu *data curation*, *storage and versioning*, *ML training*, *CI/CD*, *inference*, serta *infrastructure and supporting services*, sedangkan Kreuzberger, Kühl, dan Hirschl (2023) merinci sembilan komponen teknis mulai dari komponen CI/CD dan *feature store* hingga *model registry* dan komponen pemantauan. Kedua rujukan itu menjadi anotasi sumber bagi tiap *layer*: *Data Ingestion and Processing Layer* menampung kategori *data curation* dengan komponen *data collector* pada jalur masuk dan *data preprocessor* pada jalur pemrosesan, *Data Storage Layer* menampung komponen penyimpanan dan versi data dari kategori *storage and versioning*, dan *Feature Service Layer* menampung *feature store* dari kategori yang sama sebagai layanan tersendiri karena

melayani pelatihan sekaligus inferensi. *Model Lifecycle Layer* menampung kategori *ML training* bersama *model registry*, penyimpanan metadata ML, serta kategori *inference* pada bagian *model serving*-nya, sesuai baris kelimanya pada Tabel IV.2 yang memuat *model serving component* dan *inference service*. *Orchestration and Infrastructure Layer* menampung kategori *infrastructure and supporting services*, *GitOps and Continuous Delivery Layer* menampung kategori CI/CD, dan *Platform Security Layer* menampung sisi keamanan kategori pendukung tersebut bersama tuntutan akses terkendali pada definisi DataOps (Munappy dkk. 2020). *Observability Layer* menampung komponen pemantauan, sedangkan *Data Governance Layer* memisahkan katalog, *lineage*, dan kualitas data dari pemantauan operasional karena integrasi DataOps menuntut tata kelola data sebagai fungsi lintas *layer* (Munappy dkk. 2020). Dengan alat hasil pemilihan pada Subbab IV.3, tujuh komponen wajib MLOps *level 2* yang dijanjikan pada Subbab IV.1 kini terpetakan lengkap, yaitu *source control* pada Gitea, layanan uji dan *build* pada Tekton, layanan *deployment* pada Argo CD, *model registry* pada MLflow, *feature store* pada Feast, penyimpanan metadata ML pada MLflow dan basis metadata Kubeflow Pipelines, serta orkestrator *pipeline* pada Kubeflow Pipelines dengan pemicu *retraining* otomatis dari deteksi *drift* (Google Cloud 2024).

IV.4.1 *Orchestration and Infrastructure Layer*

Orchestration and Infrastructure Layer menggunakan Kubernetes (Cloud Native Computing Foundation 2024a) sebagai bidang orkestrasi untuk seluruh komponen platform. Penskalaan otomatis dijalankan oleh tiga komponen yang saling melengkapi yaitu HPA Kubernetes pada level Pod yang membaca metrik dari metrics-server, VPA *recommender* untuk rekomendasi *resource request*, dan KEDA (KEDA Authors 2025) untuk penskalaan berbasis peristiwa dari Kafka atau Prometheus. Kueue (Kueue Authors 2024) mengelola antrean dan kuota *training job* melalui *ClusterQueue* sehingga sumber daya komputasi terbagi adil antar-*tenant* sesuai prioritas, dengan *job* di luar kuota berstatus *Pending* hingga kuota tersedia. Cert-manager (cert-manager Contributors 2025) mengelola sertifikat TLS sehingga identitas mesin diperbarui otomatis, dan Gambar IV.2 merinci bidang orkestrasi, penskalaan otomatis, serta cert-manager pada *layer* fondasi ini. Perubahan konfigurasi menuju *layer* ini mengalir dari *GitOps and Continuous Delivery Layer* yang dirinci pada Subbab IV.4.8.

*Gambar akan tersedia setelah berkas
diagrams/Layer_Orchestration_Infra.eraser dirender ke
figures/Layer_Orchestration_Infra.png.*

Gambar IV.2 Rincian *Orchestration and Infrastructure Layer* dengan bidang orkestrasi dan penskalaan otomatis

IV.4.2 *Data Ingestion and Processing Layer*

Jalur masuk pada *Data Ingestion and Processing Layer* menggunakan Apache Kafka (Apache Software Foundation 2024c) sebagai *message broker* utama dengan operator Strimzi pada *cluster* Kubernetes. *Kafka Connect* digunakan untuk integrasi dengan sumber data eksternal melalui konektor Debezium untuk *change data capture*, dan *Karapace* digunakan sebagai registri skema yang memvalidasi kompatibilitas setiap pesan. Kafbat UI menyediakan pemantauan *topic* dan konsumen sehingga tim data dapat mengawasi kesehatan aliran masuk. Dari *topic* yang tervalidasi skema itulah jalur pemrosesan pada *layer* yang sama mengambil alih.

Jalur pemrosesan dibagi menjadi dua, yaitu jalur *batch* dan jalur *stream*, sehingga kebutuhan latensi berbeda dapat dilayani tanpa kompromi. Jalur *batch* menggunakan Apache Spark (Apache Software Foundation 2024d) dan dbt untuk transformasi pada *data warehouse*, sedangkan jalur *stream* menggunakan Apache Flink (Apache Software Foundation 2024b) untuk pemrosesan jendela waktu, agregasi, dan deteksi pola. Orkestrasi jalur *batch* dirancang menggunakan Apache Airflow (Apache Software Foundation 2024a) sebagai *scheduler* DAG yang merangkai langkah validasi, transformasi, dan materialisasi fitur menjadi satu *pipeline* data terjadwal. Definisi DAG ditarik dari Git melalui mekanisme *git-sync* sehingga perubahan *pipeline* mengikuti alur GitOps yang sama dengan komponen platform lain. Setiap langkah transformasi dijalankan sebagai *pod* terisolasi melalui KubernetesPodOperator agar batas sumber daya dapat ditetapkan per langkah dan kegagalan satu langkah tidak menjalar ke langkah lain. Pembagian peran ini menempatkan Airflow sebagai *orchestrator* bidang data dan Kubeflow Pipelines sebagai *orchestrator model training*, sehingga tanggung jawab DataOps dan MLOps tidak bercampur dalam satu *controller*. Trino (Trino Software Foundation 2024) menyediakan kueri federasi pada beberapa sumber data sekaligus, dan Gambar IV.3 merinci jalur masuk beser-

ta kedua jalur pemrosesan, orkestrasi Airflow, dan kueri federatif Trino pada satu *layer*.

*Gambar akan tersedia setelah berkas
diagrams/Layer_Ingestion_Processing.eraser dirender ke
figures/Layer_Ingestion_Processing.png.*

Gambar IV.3 Rincian *Data Ingestion and Processing Layer* dengan jalur masuk, jalur *batch*, dan jalur *stream*

IV.4.3 *Data Storage Layer*


Penyimpanan jangka panjang pada *data lake* menggunakan MinIO sebagai *object store* dengan enkripsi sisi *server* melalui KES dan format Apache Iceberg sebagai *table format*. Katalog Iceberg dikelola oleh Lakekeeper (Lakekeeper Authors 2025) yang memberikan *REST API* kompatibel dengan klien Iceberg standar dan dapat dipakai oleh Spark, Trino, dan Flink secara seragam. lakeFS (Treeverse Ltd. 2025) ditambahkan sebagai *version control layer* untuk *data lake* sehingga eksperimen pada cabang data dapat dilakukan tanpa mengganggu cabang utama. ClickHouse (ClickHouse Inc 2024) berperan sebagai *warehouse* berorientasi kolom yang menampung tabel hasil transformasi dan menyediakan kueri analitik dengan latensi rendah untuk *dashboard* maupun materialisasi fitur. Basis data pendampingnya adalah PostgreSQL yang dikelola operator CNPG dan MySQL untuk metadata layanan platform, serta OpenSearch untuk pencarian log dan teks. Gambar IV.4 merinci subgrup *lakehouse* dan basis data beserta konsumennya.

*Gambar akan tersedia setelah berkas
diagrams/Layer_Data_Storage.eraser dirender ke
figures/Layer_Data_Storage.png.*

Gambar IV.4 Rincian *Data Storage Layer* dengan subgrup *lakehouse* dan basis data

IV.4.4 *Feature Service Layer*


Feature Service Layer ditopang Feast (Feast Project 2024) sebagai *feature store* yang menyatukan definisi fitur untuk pelatihan dan inferensi. ClickHouse pada *Data Storage Layer* menjadi sumber *offline* tempat fitur historis dibaca untuk pelatihan *batch*, sedangkan Valkey menjadi penyimpanan *online* berlatensi rendah hasil materialisasi untuk inferensi. Qdrant melengkapi keduanya sebagai indeks vektor bagi *vector feature*, dan registri fitur disimpan sebagai berkas pada MinIO sehingga definisi fitur ikut terversi pada penyimpanan objek. Rincian mekanisme *dual-store* beserta jaminan *point-in-time correctness*-nya dirancang sebagai sub-sistem tersendiri pada Subbab IV.7, dan Gambar IV.5 merinci *layer* ini beserta sumber dan konsumennya.



Gambar IV.5 Rincian *Feature Service Layer* dengan penyimpanan *offline*, *online*, dan indeks vektor

IV.4.5 *Model Lifecycle Layer*

Model lifecycle layer menggunakan MLflow (MLflow Contributors 2024) untuk *tracking* dan registri model. Kubeflow Pipelines (Kubeflow Contributors 2024) dipakai sebagai *orchestrator* pelatihan, sedangkan Katib digunakan untuk *hyperparameter tuning*. Kubeflow Notebooks menjadi titik masuk eksperimen interaktif yang mengirimkan definisi *pipeline* ke Kubeflow Pipelines. Kubeflow Trainer (Kubeflow Authors 2025c) menjalankan pelatihan terdistribusi melalui TrainJob yang dipanggil dari *pipeline* Kubeflow Pipelines, sehingga pelatihan *multi-replica* tidak memerlukan *custom controller*. Argo Workflows mengeksekusi *pipeline* yang tidak terkait langsung dengan pelatihan, sedangkan Argo CronWorkflow menjadwalkan *job* berkala untuk pemeliharaan dan pemicu *retraining*. Basis data relasional untuk metadata MLflow disediakan oleh PostgreSQL yang dikelola operator CNPG, sedangkan metadata Kubeflow Pipelines dan Katib disimpan pada MySQL, sehingga riwayat eksperimen dan *pipeline* tersimpan pada penyimpanan yang konsisten. Gambar IV.6 merinci alur dari eksperimen dan pelatihan menuju registri model beserta pemicu *retraining* otomatis dari deteksi *drift*.




Gambar IV.6 Rincian *Model Lifecycle Layer*

Bagian *model serving* pada *layer* ini, sesuai komponen *model serving component* dan *inference service* pada baris kelima di Tabel IV.2, menggunakan KServe (KServe Contributors 2024) sebagai *inference platform* dengan dukungan banyak *runtime*, otomatisasi penskalaan, dan integrasi langsung dengan model yang tersimpan pada registri MLflow. *Model serving* multimodal didukung KServe dengan *runtime* bawaan untuk *scikit-learn*, XGBoost, PyTorch, dan ONNX, ditambah *runtime* kustom untuk model yang memerlukan dependensi spesifik. Knative (Knative Authors 2025) berperan sebagai bidang *serverless* bagi KServe, sehingga penskalaan dari nol dapat dilakukan tanpa menahan sumber daya saat trafik rendah. *Runtime* kustom didaftarkan sebagai *ClusterServingRuntime* sehingga penambahan kerangka model baru tidak mengubah definisi *InferenceService* yang sudah berjalan. Argo Rollouts menjalankan analisis *canary* pada *InferenceService* sehingga versi model baru dipromosikan bertahap berdasarkan metrik, sedangkan jembatan inferensi membaca fitur *online* dari Valkey dan fitur vektor dari Qdrant untuk melengkapi masukan *predictor*. Gambar IV.7 merinci jalur *serving* dari artefak model sampai konsumen prediksi.


IV.4.6 Data Governance Layer

Data Governance Layer menggunakan DataHub (DataHub Project 2024) sebagai katalog metadata yang mengumpulkan informasi dari komponen lain melalui mekanisme *push* dan *pull*, dengan OpenLineage (OpenLineage Authors 2025) sebagai protokol pengirim peristiwa *lineage* dari komponen *pipeline*. Sumber metadata mencakup Kafka untuk *topic* dan skema, ClickHouse untuk tabel *warehouse*, MinIO dengan katalog Iceberg untuk *dataset data lake*, PostgreSQL untuk metadata layanan, Feast untuk definisi fitur, serta dbt untuk model transformasi, sehingga aset lintas *layer* terindeks dalam satu katalog yang penelusurannya ditopang indeks OpenSearch.



Gambar IV.7 Rincian bagian *model serving* pada *Model Lifecycle Layer*

Great Expectations (Great Expectations 2024) menjalankan pengujian kontrak data pada *batch layer* dan *stream layer* dan mengalirkan status validasi ke katalog. Gambar IV.8 merinci penerimaan peristiwa *lineage* dan *ingest* metadata pada DataHub beserta batasnya menuju observabilitas.




Gambar IV.8 Rincian *Data Governance Layer*

IV.4.7 *Observability Layer*

Observability Layer menggunakan Prometheus untuk metrik dengan Alertmanager sebagai penyalur peringatan, Loki untuk log, dan Grafana Tempo (Grafana Labs 2024c) untuk *trace*, dengan OpenTelemetry sebagai *collector* bersama. Grafana menyatukan ketiganya dan ditambahkan *dashboard* khusus untuk kualitas data, *drift* fitur, dan kinerja model. Sloth (Sloth Authors 2025) menurunkan *service-level objective* ke aturan Prometheus, sedangkan Pyroscope menyediakan profil performa berkelanjutan dan OpenCost melengkapi pemantauan biaya per beban kerja. Pushgateway dipakai untuk mengumpulkan metrik *job* berdurasi pendek, antara lain CronJob validasi data dan CronWorkflow pengukur *drift*, agar metrik mereka tidak hilang setelah *job* selesai. Evidently (Evidently AI 2025) melengkapi observabilitas khusus model dengan *report* distribusi fitur dan kinerja model yang dapat diaudit

dan disisipkan ke *dashboard* Grafana. Superset (Apache Superset Authors 2025) berperan sebagai antarmuka analitik bagi *business user* yang menampilkan *dashboard* di atas ClickHouse dan Trino. Gambar IV.9 merinci ketiga pilar observabilitas pada satu antarmuka Grafana beserta *dashboard* analitik Superset.



Gambar IV.9 Rincian *Observability Layer*

IV.4.8 *GitOps and Continuous Delivery Layer*

GitOps and Continuous Delivery Layer menjadikan Git satu-satunya sumber kebenaran konfigurasi platform. Argo CD menjadi satu-satunya jalur perubahan yang menarik konfigurasi dari Git dan menerapkannya ke *cluster* melalui prinsip rekonsiliasi deklaratif GitOps (Limoncelli 2018), sehingga keadaan *cluster* selalu dapat direproduksi dari isi repositori. Gitea berperan sebagai *repository* Git internal, Tekton sebagai *build pipeline* yang menguji dan membangun *image*, dan *image registry* internal sebagai penyimpanan artefak hasil *build*. Argo Rollouts melengkapi jalur pengiriman sebagai operator pengiriman bertahap yang mempromosikan versi baru berdasarkan metrik, termasuk untuk rilis model pada bagian *model serving*. Gambar IV.10 merinci rantai dari *commit* sampai rekonsiliasi pada seluruh *layer* platform.

IV.4.9 *Platform Security Layer*

Platform Security Layer menegakkan akses terkendali serta kepatuhan privasi dan keamanan data pada seluruh *layer* lain. Istio (Istio Authors 2024) menyediakan

*Gambar akan tersedia setelah berkas
diagrams/Layer_GitOps_CD.eraser dirender ke
figures/Layer_GitOps_CD.png.*

Gambar IV.10 Rincian *GitOps and Continuous Delivery Layer*

jaringan layanan dengan mTLS yang mengamankan komunikasi antar layanan, sedangkan APISIX (Apache APISIX Authors 2025) berperan sebagai *API gateway* pada perbatasan *mesh*. Identitas terpusat disediakan Dex sebagai penyedia OIDC, oauth2-proxy sebagai penjaga *single sign-on* bagi konsol web, dan SpiceDB sebagai mesin otorisasi berbasis relasi. OpenBao (OpenBao Authors 2025) mengelola rahasia, dan *External Secrets Operator* menyebarkan rahasia dari OpenBao ke *namespace* target tanpa menyalin rahasia ke berkas manifes. Kebijakan keamanan dijalankan pada dua titik, yaitu Kyverno (Kyverno Authors 2024) pada admisi Kubernetes dan Falco (Falco Authors 2025) pada *runtime*. Trivy Operator (Aqua Security 2025) memindai *image* dan beban kerja secara terus menerus, sedangkan Velero (Velero Authors 2025) melakukan pencadangan sumber daya *cluster* dan *persistent volume* secara terjadwal ke MinIO, dan Chaos Mesh menyuntikkan gangguan terkendali untuk menguji ketahanan platform. Gambar IV.11 merinci seluruh komponen keamanan ini dari perbatasan sampai pemulihan.

*Gambar akan tersedia setelah berkas diagrams/Layer_Security.eraser
dirender ke figures/Layer_Security.png.*

Gambar IV.11 Rincian *Platform Security Layer*

IV.5 Perancangan Sub-sistem Tata Kelola Data

Bagian ini menjawab T-2 dengan merancang sub-sistem tata kelola data yang konsisten lintas siklus data, fitur, dan model. Tata kelola yang dimaksud mencakup katalog metadata, *lineage*, pengujian kontrak data, dan kontrol akses berbasis iden-

titas. Pemilihan keempat aspek tersebut mengikuti penekanan pada KF-08, KF-09, dan KF-10 serta KNF terkait keamanan dan observabilitas pada Bab III, sekaligus menjawab efek domino fragmentasi pada *governance layer* yang dibahas pada Subbab III.1.3. Sub-sistem ini menjadi prasyarat bagi tiga sub-sistem lainnya karena katalog metadata berfungsi sebagai indeks bersama yang menghubungkan *ingestion*, *training*, *serving*, dan pemantauan dalam satu graf tata kelola.

IV.5.1 Katalog Metadata dan Lineage

DataHub menjadi pusat katalog metadata. Sumber metadata datang dari beberapa komponen: Kafka untuk *topic* dan skema, ClickHouse (ClickHouse Inc 2024) untuk tabel pada *warehouse*, MinIO dan Apache Iceberg dengan katalog Lakekeeper (Lakekeeper Authors 2025) untuk *dataset* pada *data lake*, Feast (Feast Project 2024) untuk definisi fitur, MLflow untuk *experiment* dan model, serta Kubeflow Pipelines untuk *pipeline*. Sambungan *lineage* antar komponen dikirim melalui peristiwa OpenLineage (OpenLineage Authors 2025) sehingga DataHub dapat merangkai graf ketertelusuran yang seragam dari *ingestion* sampai prediksi. Identitas pengguna katalog diteruskan dari *identity provider* pusat yang dipakai bersama oleh seluruh antarmuka platform.

Proses *ingestion* metadata pada DataHub dijalankan secara berkala melalui CronJob yang memanggil `datahub ingest` dengan resep YAML per sumber, sehingga penambahan sumber baru tinggal menambahkan resep tanpa memodifikasi kode pusat. Setiap resep meneruskan token OIDC dari OpenBao, sehingga autentikasi pada DataHub konsisten dengan autentikasi yang dipakai oleh komponen lain. Pengelolaan graf metadata juga memuat *glossary* domain yang ditarik dari berkas YAML pada repositori Git, memberi *semantic layer* yang dapat ditelusuri oleh *business user*. Praktik DataHub (DataHub Project 2024) menempatkan katalog metadata sebagai sumber utama jawaban ketertelusuran yang umum muncul pada audit kepatuhan, sehingga kapabilitas tersebut dapat diuji pada Bab VI.

IV.5.2 Kontrak Data dan Kualitas

Great Expectations memberi struktur untuk mendeklarasikan ekspektasi kualitas data, termasuk tipe kolom, batas nilai, dan jumlah baris minimum. Ekspektasi dijalankan pada dua titik: setelah *ingestion* pada *bronze layer* dan setelah transformasi pada *silver* dan *gold layer*. Hasil pengujian dipublikasikan ke DataHub sehingga kualitas data tertampil bersama metadata lain. Chien (2022) memberi panduan agar metrik kualitas dipakai sebagai dasar pengambilan keputusan, bukan sekadar indi-

kator pasif.

Bernardo dkk. (2024) dan Stoyanovich, Howe, dan Jagadish (2020) memberi konteks yang melebihi aspek teknis, yakni pertanggungjawaban data sebagai bagian dari tata kelola platform. Kegagalan ekspektasi pada *bronze layer* memicu peringatan pada saluran observabilitas tanpa menghentikan jalur *ingestion*, sementara kegagalan pada *silver* dan *gold layer* memicu penghentian *pipeline* agar data tidak berpindah ke *layer* berikutnya dengan kualitas yang tidak memenuhi kontrak. Setiap eksekusi Great Expectations menyimpan *run history* sehingga regresi kualitas dapat dirunut. dbt menjalankan model SQL pada ClickHouse dan menulis hasil ke tabel *gold* dengan kontrak yang divalidasi oleh *suite* ekspektasi yang dirancang pada *checkpoint* terjadwal.

IV.5.3 Identitas dan Kontrol Akses

Kontrol akses berbasis identitas menggunakan dex (Dex Authors 2025) sebagai *identity provider* OIDC dan oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menegakkan autentikasi pada antarmuka aplikasi. Identitas berlaku konsisten dari antarmuka pengguna ke *API* hingga ke akses data pada *warehouse* dan *lake*, dengan token OIDC yang sama dipakai oleh DataHub, MLflow, Grafana, Argo CD, dan Kubeflow Pipelines. Kebijakan otorisasi pada level kontainer dan beban kerja ditegakkan oleh Kyverno (Kyverno Authors 2024) pada *admission layer* Kubernetes, antara lain wajibnya *resource limits*, larangan *privileged container* di luar pengecualian eksplisit, dan kepatuhan label *Pod Security Standards*. Strategi keamanan MLOps yang dibahas Ahmad dkk. (2024) menjadi rujukan utama, karena banyak ancaman MLOps muncul ketika kontrol akses antar *layer* tidak konsisten.

SpiceDB (AuthZed 2025) dihadirkan sebagai layanan otorisasi berbasis Zanzibar yang menetapkan hubungan akses pada level objek, sehingga kebijakan akses dataset, fitur, dan model dapat dinyatakan dengan model relasi yang seragam. OpenBao menjadi sumber tunggal rahasia yang disinkronkan ke *namespace* target oleh *External Secrets Operator*, dan *Key Encryption Service* mengenkripsi rahasia tersebut pada *layer* MinIO dengan kunci yang dirotasi secara berkala. Falco (Falco Authors 2025) memonitor peristiwa *runtime* dan mengirim peringatan ke Loki ketika perilaku mencurigakan terdeteksi, sehingga *runtime layer* tercakup oleh observasi berkelanjutan. Chaos Mesh (Chaos Mesh Authors 2025) dipakai untuk pengujian keandalan terjadwal yang memvalidasi bahwa kontrol akses tetap terjaga pada kondisi kegagalan *partial*.

IV.6 Perancangan Sub-sistem Deteksi *Drift* dan *Continuous Training*

Bagian ini menjawab T-3 dengan merancang sub-sistem deteksi *drift* pada fitur dan label yang otomatis memicu *retraining* pada saat melewati ambang batas. Sub-sistem ini menjawab kombinasi *drift* dan *temporal leakage* yang menjadi salah satu rumusan masalah. Jaminan *point-in-time correctness* yang melengkapi T-3 dirancang bersama layanan fitur pada Subbab IV.7.3 karena bertumpu pada kontrak *point-in-time* Feast, sedangkan subbab ini memusatkan pembahasan pada deteksi *drift* dan *retraining* otomatis. Penekanan diberikan pada otomatisasi penuh: pengukuran, pengambilan keputusan, *retraining*, validasi, dan promosi versi dijalankan tanpa intervensi manual. Sub-sistem ini menjadi titik temu antara DataOps dan MLOps karena *drift* terdeteksi pada *data layer* sementara konsekuensinya dieksekusi pada *model layer*.

IV.6.1 Pengukuran *Drift*

Dua indikator utama dipilih sebagai detektor. *Population Stability Index* (PSI) dipakai untuk fitur kategorikal dan kontinu dengan *binning*, sedangkan uji Kolmogorov-Smirnov dipakai untuk distribusi nilai kontinu (Reis dkk. 2016). Pengukuran dilakukan pada jendela waktu yang bergerak dan dibandingkan dengan jendela referensi. Tingkat *drift* dikategorikan menjadi *stable*, *moderate*, dan *severe* dengan ambang yang dapat dikonfigurasi per fitur. Bayram, Ahmed, dan Kassler (2022), Lu dkk. (2019), dan Hinder dkk. (2023) menjadi rujukan untuk penyusunan kebijakan keluarga detektor dan respons platform.

Pengukuran *drift* dijalankan oleh CronJob yang menarik fitur *baseline* dan fitur jendela aktif dari ClickHouse, lalu menghitung indikator pada *namespace model-lifecycle* agar terisolasi dari beban kerja produksi lain. Hasil pengukuran dipublikasikan ke tabel *gold.drift_multi_scale* pada ClickHouse sehingga riwayat dapat dianalisis secara historis untuk audit dan pelaporan. Pushgateway menerima metrik tiap eksekusi sehingga Prometheus dapat merangkainya menjadi deret jangka panjang yang ditampilkan pada *dashboard* Grafana. Evidently menambahkan *report* HTML visual yang disimpan pada MinIO dan ditautkan dari DataHub agar dapat dirujuk oleh *data scientist* ketika menelusuri penurunan kinerja model.

IV.6.2 Alur *Retraining* Otomatis

Alur *retraining* dijalankan oleh Argo CronWorkflow yang berperan sebagai *control loop*. *Workflow* ini menjalankan *job* pengukuran *drift*, kemudian memutuskan

apakah pemicu pelatihan diperlukan. Jika diperlukan, *workflow* memicu *training pipeline* pada Kubeflow Pipelines. *Training pipeline* menarik fitur dari Feast dengan operasi `get_historical_features` yang menjamin *point-in-time correctness*, kemudian menulis model yang dihasilkan ke MLflow. Model kandidat didaftarkan ke registri MLflow sebagai versi baru, sedangkan kelayakannya untuk menggantikan versi produksi ditentukan pada tahap promosi *canary* yang menilai metrik *serving* versi baru secara langsung.

Promosi versi pada *serving layer* dikendalikan oleh Argo Rollouts (Argo Rollouts Authors 2025) dengan strategi *canary* yang menyalurkan sebagian trafik ke versi baru sebelum promosi penuh, sehingga *rollback* otomatis dapat dilakukan ketika metrik kinerja menurun. Céspedes Sisniega dkk. (2024) memberi contoh penerapan deteksi *drift* pada lingkungan *serverless*, dan pendekatan yang serupa diadaptasi ke lingkungan Kubernetes pada platform ini. Setiap langkah *canary* dijeda agar metrik terkumpul, lalu *AnalysisTemplate* mengevaluasi tingkat keberhasilan dan latensi p99 versi *canary* terhadap ambang SLO melalui kueri Prometheus dan menghentikan promosi ketika ambang dilanggar. Riwayat promosi dan *rollback* tercatat pada *namespace* Argo sehingga audit promosi dapat dijalankan langsung dari Argo CD UI tanpa berpindah *tool*.

IV.6.3 Mekanisme Penanganan Kasus Khusus

Sub-sistem ini melayani tiga kasus khusus yang umum muncul pada operasi deteksi *drift*. Ketiganya menyangkut keputusan otomatis yang tidak dapat menunggu label kebenaran tersedia. Penanganannya dirancang pada jalur kendali yang sama agar tidak menambah cabang *workflow* baru. Ketiga kasus tersebut adalah sebagai berikut.

1. ***Drift* terdeteksi sebelum label tersedia**

Ketika *drift* terdeteksi pada fitur tetapi label belum tersedia, *workflow* hanya melakukan *retraining* setelah label berjalan cukup lama.

2. ***Drift* akibat perubahan distribusi sementara**

Ketika *drift* terjadi karena perubahan distribusi sementara, ambang dihitung dengan jendela bergulir agar tidak memicu *retraining* yang tidak perlu.

3. **Kegagalan versi baru pada analisis *canary***

Ketika versi baru gagal pada analisis *canary*, promosi dihentikan otomatis sehingga versi stabil pada *serving layer* tetap dipertahankan.

Ketiga kasus tersebut dirancang untuk ditangani tanpa percabangan tambahan pa-

da *workflow*. CronWorkflow *retraining* disusun atas dua langkah berurutan, yaitu pengukuran *drift* dan langkah keputusan yang memicu *retraining*, sedangkan penghentian promosi saat analisis *canary* gagal menjadi tanggung jawab Argo Rollouts pada *serving layer*. Ambang PSI dan KS beserta jendela *lookback* ditetapkan sebagai parameter pada CronWorkflow sehingga setiap perubahan kebijakan tetap melewati *commit* Git dan dapat diaudit. Parameter tersebut tersimpan pada manifes di repositori Git sehingga nilai ambang yang berlaku selalu sama dengan yang tercatat pada riwayat *commit*.

IV.7 Perancangan Sub-sistem Layanan Fitur *Dual-Store*

Bagian ini menjawab T-4 dengan merancang sub-sistem layanan fitur yang menyatukan *tabular feature* dan *aggregate feature* dalam satu kontrak data dari satu sumber kebenaran, sedangkan *embedding* berdimensi tinggi dikelola pada indeks vektor terpisah. Feast digunakan sebagai *framework* layanan fitur yang menyatukan kontrak antara *offline* dan *online* untuk *tabular feature*. Pemisahan beban kerja dilakukan secara fisik antara *store* kunci-nilai untuk *tabular feature* dan indeks vektor untuk *embedding*. *Tabular feature* diambil melalui API Feast, sedangkan *embedding* diambil melalui klien *native* Qdrant pada saat *inference*.

IV.7.1 Penyimpanan *Offline* dan *Online*

Offline store menggunakan ClickHouse untuk *tabular feature* dan *aggregate feature* yang dipakai pada fase *training*, dengan tabel kolom yang dipetakan langsung ke definisi FeatureView Feast. *Online store* menggunakan Valkey (Valkey Contributors 2025) untuk fitur yang dipakai pada fase *inference* dengan target latensi p99 di bawah sepuluh milidetik. Dasar pemilihan kedua komponen mengikuti perbandingan berskor pada Subbab IV.3, dengan landasan konsepnya pada Bab II, sedangkan pada perancangan ini keduanya diikat pada satu kontrak Feast sehingga skema *offline* dan *online* berasal dari definisi yang sama. Pemisahan peran ini memungkinkan penyetelan sumber daya *training* dan *serving* secara mandiri tanpa menduplikasi definisi fitur.

Vector search HNSW tidak digabungkan langsung pada *online store* tabular, melainkan disediakan oleh Qdrant (Qdrant Team 2025) sebagai indeks vektor terpisah, sehingga beban kerja kunci-nilai dan beban kerja pencarian vektor terpisah secara operasional. Pemisahan *store* memudahkan penyetelan *resource* secara mandiri karena beban Valkey berorientasi kunci-nilai dengan akses *point lookup* sedangkan beban Qdrant berorientasi pencarian tetangga terdekat yang membutuhkan memori

untuk indeks HNSW. Valkey dideklarasikan sebagai `online_store` pada repositori Feast, sedangkan Qdrant berdiri sebagai indeks vektor terpisah yang diakses melalui klien *native* di luar Feast, bukan sebagai *store* kedua di dalam Feast. Pembaruan skema fitur diterapkan ke ClickHouse melalui `ALTER TABLE` terkelola oleh dbt dan secara bersamaan ke Feast melalui `feast apply` sehingga skema *offline* dan *online* selalu sinkron.

IV.7.2 Dukungan *Vector Embeddings* dan HNSW

Embedding dihasilkan oleh model `sentence-transformers/all-mpnet-base-v2` (Reimers dan Gurevych 2019) berdimensi 768 untuk teks, dan disimpan sebagai fitur dengan dimensi yang konsisten antara fase pelatihan dan fase *inference*. Pencarian tetangga terdekat dijalankan oleh Qdrant (Qdrant Team 2025) dengan indeks HNSW (Malkov dan Yashunin 2020) berparameter `m=16` dan `ef_construct=200` yang memberikan keseimbangan yang baik antara waktu kueri dan kualitas. Qdrant menyediakan kueri *gRPC* berlatensi rendah serta penyaringan *payload* pada saat pencarian, sehingga *embedding* dapat digabung dengan *tabular feature* dari Valkey untuk membentuk *request inference* yang lengkap. Bruch, Gai, dan Ingber (2023) dan Campese, Lauriola, dan Moschitti (2024) memberi rujukan untuk fungsi penggabungan hasil pencarian pada konteks *hybrid retrieval*.

Parameter HNSW dikonfigurasi melalui *collection* Qdrant yang dideklarasikan oleh *init Job* sehingga penambahan koleksi baru dapat dilakukan dengan menambah berkas YAML, tanpa intervensi langsung pada Qdrant. *Snapshot* koleksi vektor dijalankan secara berkala ke MinIO sebagai bagian dari pencadangan Velero untuk objek terkait. Pemilihan dimensi 768 berdasarkan model `all-mpnet-base-v2` memberi keseimbangan antara kualitas semantik dan biaya penyimpanan, dan dapat disesuaikan dengan model alternatif tanpa mengubah kontrak Feast. Latensi p99 ditargetkan di bawah dua puluh milidetik untuk pencarian top-10 pada koleksi berukuran sampai sepuluh juta vektor.

IV.7.3 Jaminan *Point-in-Time Correctness*

Jaminan ini merupakan bagian dari T-3 yang dirancang bersama layanan fitur karena mekanismenya bertumpu pada kontrak penyimpanan fitur. Jaminan *point-in-time correctness* pada Feast diwujudkan melalui operasi `get_historical_features`. Operasi ini melakukan *point-in-time join* antara entitas dan riwayat fitur dengan menggunakan `event_timestamp` dan `created_timestamp`, sehingga nilai fitur

yang dipakai pada saat pelatihan identik dengan nilai yang akan tersedia pada saat *inference* di waktu yang sama. Sebagaimana dirumuskan pada Bab II, kebocoran temporal membuat evaluasi model tampak lebih baik daripada kinerja sebenarnya, dan kontrak Feast mencegahnya secara struktural pada level definisi fitur. Setiap `FeatureView` mendeklarasikan `ttl` untuk membatasi usia fitur yang dianggap valid, sehingga fitur usang tidak diam-diam masuk ke *training set*.

Mekanisme jaminan ini diuji melalui dua jalur. Pertama, *notebook* reproduksi memanggil `get_historical_features` pada titik waktu historis dan membandingkan keluaran dengan ekstraksi manual yang dijalankan terhadap log peristiwa Kafka, sehingga validitas dapat dibuktikan pada level kasus. Kedua, kontrak antara *Online Store* dan *Offline Store* divalidasi dengan menjalankan kueri yang sama pada *Valkey* dan *ClickHouse* pada titik waktu yang sama dan membandingkan keluaran. Kombinasi dua jalur uji ini menutup ruang *temporal leakage* struktural pada *feature layer* tanpa bergantung pada disiplin manual pengembang *pipeline*.

IV.7.4 Aliran Materialisasi Fitur

Materialisasi fitur dilakukan dengan dua jalur. Jalur *batch* menjalankan transformasi pada *ClickHouse* atau *Spark*, kemudian Feast memuat hasilnya ke *online store* secara periodik melalui operasi `materialize`. Jalur *stream* menggunakan *Flink* untuk menghitung fitur *real-time* yang ditulis langsung ke *Valkey* untuk *tabular feature*, serta dipublikasikan ke *ClickHouse* pada saat yang sama, sehingga *offline* dan *online* tetap konsisten. Kedua jalur menulis ke penyimpanan yang sama-sama terdaftar pada *FeatureView* Feast sehingga konsumen tidak perlu mengetahui jalur mana yang menghasilkan sebuah nilai.

Jadwal materialisasi *batch* dipasang pada DAG *Airflow* melalui *task* `feast_materialize` dengan interval per jam yang mendorong fitur dari *offline store* ke *online store*. Eksekusi materialisasi mengeluarkan metrik durasi dan jumlah baris ke *Pushgateway* sehingga ketertinggalan dapat terdeteksi melalui *alerting* *Prometheus*. Jalur *stream* menggunakan semantik *exactly-once* *Flink* dengan *checkpoint* ke *MinIO* setiap interval pendek, sehingga kegagalan *TaskManager* tidak menyebabkan duplikasi pada *online store*. Pada jalur *batch*, nilai pada *online store* merupakan hasil materialisasi dari *offline store* yang sama sehingga konsistensi antara keduanya terjaga secara struktural, sedangkan kualitas data lintas *layer* diverifikasi oleh *checkpoint* *Great Expectations* terjadwal.

IV.8 Alur Kerja *End-to-End*

Alur kerja menyatukan empat sub-sistem ke dalam satu siklus berkelanjutan dengan urutan tahap sebagai berikut.

1. ***Ingestion dan validasi data***

Data baru masuk melalui Kafka, divalidasi oleh Great Expectations, kemudian disimpan pada *warehouse* ClickHouse dan *data lake* MinIO dengan katalog Lakekeeper.

2. ***Komputasi dan materialisasi fitur***

Fitur dihitung pada Flink atau Spark dan ditulis ke ClickHouse sebagai *offline store*, lalu diregistrasi pada Feast dan dimaterialisasi ke Valkey sebagai *online store* tabular, sedangkan indeks vektor Qdrant diisi melalui jalur tersendiri di luar materialisasi Feast.

3. ***Pengukuran drift dan retraining***

Argo CronWorkflow mengukur *drift* dan, jika ambang dilewati, memicu *training pipeline* Kubeflow Pipelines yang menggunakan `get_historical_features` untuk menjamin konsistensi temporal.

4. ***Registrasi dan promosi model***

Hasil pelatihan ditulis ke MLflow, model kandidat didaftarkan sebagai versi baru, lalu promosi pada *serving layer* dikendalikan oleh Argo Rollouts dengan strategi *canary* berbasis analisis metrik.

5. ***Sinkronisasi konfigurasi dan observabilitas***

Perubahan pada konfigurasi disinkronkan dari Git oleh Argo CD, sedangkan kondisi sistem dipantau oleh Prometheus, Loki, dan Grafana Tempo melalui Grafana.

Siklus ini berputar setiap kali data baru masuk atau *drift* terdeteksi, sehingga platform terus menerus menjaga akurasi model di lingkungan produksi. Seluruh langkah pada siklus berjalan dari deklarasi Git yang sama sehingga setiap perputaran dapat diaudit dan diulang. Rodrigues dkk. (2025) memberi rujukan tambahan untuk arsitektur pembelajaran *near real-time* pada lingkungan yang serupa. Pendekatan yang dirancang di sini mengadaptasi rujukan tersebut ke kontrak Feast dan Argo Rollouts agar siklus tetap dapat dijalankan secara deklaratif pada satu *cluster* Kubernetes. Perwujudan keempat *sub-sistem* dan alur *end-to-end* ini pada lingkungan *k3s*, beserta pola GitOps yang menjalankannya, dibahas pada Bab V.

BAB V

IMPLEMENTASI ARSITEKTUR PLATFORM DATAOPS DAN MLOPS

Bab ini membahas implementasi platform DataOps dan MLOps terintegrasi sesuai rancangan pada Bab IV. Pembahasan dimulai dari lingkungan implementasi yang menjadi dasar *deployment* komponen, kemudian dilanjutkan dengan implementasi empat sub-sistem mengikuti urutan pemenuhan tujuan T-1 sampai T-4. Bab ini ditutup dengan verifikasi jalur eksekusi menggunakan satu *use case* sebagai kasus pengujian. Penjabaran detail biner dan konfigurasi disimpan pada repositori platform, sehingga bab ini menyajikan pokok-pokok implementasi yang menjelaskan bentuk akhir rancangan.

V.1 Lingkungan Implementasi

Lingkungan implementasi platform dibangun pada satu *cluster* Kubernetes (Cloud Native Computing Foundation 2024a) berbasis k3s yang berjalan pada satu *node*. Pilihan ini memenuhi kebutuhan eksekusi pada lingkungan terbatas tanpa mengubah pola *deployment* yang dapat dipakai pada *cluster* produksi dengan banyak *node*. Distribusi k3s membawa *control plane* ringan, *containerd* sebagai *runtime*, dan beberapa *add-on* bawaan yang dapat dinonaktifkan agar tidak berbenturan dengan komponen pilihan platform. Konfigurasi *node* memakai satu *disk* lokal dengan *ext4* sebagai *filesystem*, dan tata letak *namespace* pada platform dibakukan agar perpindahan ke *cluster* produksi dengan banyak *node* tinggal mengubah berkas *overlay Kustomize* tanpa mengganti manifes dasar.

Kode dan konfigurasi proyek ditata pada beberapa direktori utama dengan batas tanggung jawab yang jelas. Tabel V.1 merangkum direktori tersebut beserta fungsinya, dengan *platform/* sebagai inti yang bersifat domain-agnostik dan direktori *use case* sebagai kasus pengujian yang terpisah. Pemisahan ini memastikan platform dapat dipakai ulang lintas domain tanpa menyentuh berkas yang spesifik pada satu *use case*. Direktori *experiments/* dan *materials/* berperan sebagai penunjang verifikasi dan dokumentasi yang tidak menjadi bagian dari jalur *deployment* platform.

Tabel V.1 Struktur Direktori Utama Proyek dan Fungsinya

Direktori	Fungsi
platform/	Kode, manifes, dan konfigurasi seluruh komponen platform DataOps dan MLOps yang bersifat domain-agnostik
use-case-crypto/	<i>Use case</i> uji berupa pasar kripto, memuat layanan <i>ingestion</i> , definisi fitur, <i>pipeline</i> , dan <i>overlay Kustomize</i> yang spesifik domain
experiments/	Skenario verifikasi dan <i>oracle</i> pengujian, antara lain uji paritas <i>batch-stream</i> , beban, <i>drift</i> , dan <i>chaos</i>
materials/	Dokumen tugas akhir, proposal, referensi, dan berkas laporan

V.1.1 Batasan Implementasi

Perwujudan platform pada bab ini berjalan di dalam dua batasan implementasi yang dibedakan dari batasan penelitian pada Bab I. Batasan implementasi menyangkut pilihan perwujudan yang dapat diganti tanpa mengubah sifat kontribusi selama fungsi yang sama tetap terpenuhi, karena keluaran utama penelitian adalah arsitektur yang dapat dipakai lintas *use case*, bukan implementasi untuk satu lingkungan tertentu. Kedua batasan menetapkan lingkungan *k3s* satu *node* dan patokan versi April 2026 sebagai kondisi pengujian yang dapat direproduksi. Kedua butir berikut selanjutnya dirujuk dengan singkatan BI-1 dan BI-2, terutama pada pembahasan hasil di Bab VI.

1. Platform berjalan di atas *k3s* pada satu *node* sebagai lingkungan pengembangan dan pengujian, dengan skala diatur oleh HPA, VPA, dan KEDA ketika beban nyata muncul, sedangkan *overlay Kustomize* untuk *environment multi-node* tetap dapat ditambahkan tanpa modifikasi basis kode sehingga jumlah *node* bersifat perwujudan dan bukan bagian dari kontribusi.
2. Versi pustaka dan basis *image container* dipatok pada rilis stabil tertinggi per April 2026 agar pengujian dapat direproduksi pada lingkungan yang sama, dan patokan versi maupun pilihan serta sintaks komponen tertentu dapat diganti dengan komponen lain berkapabilitas setara tanpa mengubah rancangan.

Kedua batasan implementasi tersebut menjadi konteks pembacaan seluruh subbab implementasi pada bab ini. Penggantian jumlah *node*, versi komponen, atau sintaks alat dengan padanan berkapabilitas setara tidak mengubah rancangan pada Bab IV. Batasan BI-1 dipetakan kembali pada pelaporan hasil evaluasi lingkungan *node* tunggal, sedangkan BI-2 menjadi acuan reproduksi lingkungan pengujian pada Bab VI. Pemisahan dari batasan penelitian menegaskan bahwa keterbatasan lingkungan pengujian tidak membatasi keberlakuan arsitektur yang dirancang.

V.1.2 Konfigurasi Dasar *Cluster*

Cluster menjalankan komponen dasar berikut: Istio (Istio Authors 2024) sebagai *service mesh* dengan mTLS dalam mode *strict* pada lalu lintas internal, APISIX (Apache APISIX Authors 2025) sebagai *API gateway* pada perbatasan *mesh*, kontrol akses jaringan menggunakan *NetworkPolicy* pada level Kubernetes, dan Kyverno (Kyverno Authors 2024) sebagai *policy engine* pada *admission layer*. Falco (Falco Authors 2025) memantau perilaku *runtime* pada level *kernel*, sedangkan Trivy Operator (Aqua Security 2025) memindai *image* dan beban kerja secara berkala. *Storage class* bawaan menggunakan *local-path provisioner* untuk *persistent volume* berbasis penyimpanan lokal, dengan Velero (Velero Authors 2025) melakukan pencadangan terjadwal ke MinIO. Chaos Mesh (Chaos Mesh Authors 2025) disiapkan untuk uji ketahanan dengan eksperimen *fault injection* yang terbatas pada *namespace* tertentu.

Konfigurasi sumber daya memberi prioritas pada satu replika *idle* per beban kerja, sementara *Horizontal Pod Autoscaler*, *Vertical Pod Autoscaler* dalam mode rekomendasi, dan KEDA *ScaledObject* disiapkan pada *template* agar penskalaan dapat aktif ketika beban nyata datang. *Resource limits* pada setiap kontainer ditetapkan sesuai panduan Kyverno `require-resource-limits` untuk mencegah kelebihan kuota *node*. Penjadwalan kelas prioritas memakai *PriorityClass* platform agar komponen kritis tidak tergusur oleh beban kerja sekali pakai. *External Snapshotter* dipasang sebagai prasyarat untuk *snapshot* CSI yang dipakai oleh Velero, sehingga rekonstruksi *cluster* dari pencadangan dapat dilakukan tanpa intervensi manual.

V.1.3 Manajemen Rahasia dan Identitas

OpenBao (OpenBao Authors 2025) bertindak sebagai penyimpan rahasia. *External Secrets Operator* bertugas menyebarkan rahasia dari OpenBao ke *namespace* target tanpa menyalin nilai rahasia ke dalam berkas manifes. Identitas pengguna dikelola oleh dex (Dex Authors 2025) sebagai *identity provider* OIDC, dengan oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menegakkan autentikasi pada antarmuka aplikasi seperti DataHub, MLflow, Grafana, Argo CD, dan Kubeflow Pipelines. Selain identitas pengguna, kebijakan otorisasi beban kerja pada *admission layer* ditegakkan oleh Kyverno (Kyverno Authors 2024) sebagai bagian dari dasar keamanan *cluster*.

OpenBao dibangkitkan oleh *Job* `openbao-bootstrap` yang melakukan *init* dan *auto-unseal* dengan kunci yang tersimpan di MinIO (MinIO, Inc. 2024) dengan enkripsi sisi *server*. *External Secrets Operator* dipasang pada *namespace* `security` de-

ngan `ClusterSecretStore` tunggal yang berisi konfigurasi koneksi ke OpenBao. SpiceDB (AuthZed 2025) dipasang sebagai layanan otorisasi berbasis Zanzibar yang menetapkan hubungan akses pada level objek tata kelola, dengan basis data PostgreSQL melalui CNPG sebagai *datastore*. *Key Encryption Service* dipasang sebagai *sidecar* MinIO untuk enkripsi rahasia, dengan rotasi kunci dijalankan oleh *CronJob* terjadwal.

V.1.4 Pola GitOps

Argo CD (Argo Project 2024) menjadi satu-satunya jalur perubahan pada *cluster*. Repositori Git pada Gitea (Gitea Contributors 2025) bertindak sebagai sumber kebenaran konfigurasi. Setiap perubahan dilakukan melalui *commit* pada repositori dan diterapkan ke *cluster* oleh Argo CD melalui rekonsiliasi. Pola ini menjamin reproduksibilitas dan menghasilkan jejak audit untuk setiap perubahan. *Pipeline* CI yang dijalankan oleh Tekton (Tekton Contributors 2024) membangun *image* dan menjalankan pengujian sebelum *commit* menjadi sumber *deployment*.

ApplicationSet Argo CD dipakai untuk mendeklarasikan banyak *Application* sekaligus dengan satu *template* per kelompok, sehingga penambahan komponen baru tinggal menambahkan *generator* tanpa menambah berkas *Application* satu per satu. Argo CD diatur dengan mode *manual-sync* pada *ApplicationSet template* untuk mencegah *auto-prune* yang dapat menghapus sumber daya secara tidak sengaja. Tekton menjalankan *Pipeline* yang menghasilkan *image* ke registri `localhost:5000` yang berfungsi sebagai *mirror* lokal, dan menulis kembali *commit* dengan referensi *image* yang sudah diperbarui pada `values.yaml` *kustomization*. *Pre-apply* dan *post-apply hook* pada `apply-component.sh` menutup celah *race condition* antara CRD dan CR, sehingga seluruh komponen *cluster* dapat dipasang ulang dengan satu perintah *Makefile*.

V.2 Implementasi Arsitektur Terintegrasi

Bagian ini mengimplementasikan rancangan pada Bagian IV.4 sebagai pemenuhan T-1. Komponen disusun ke dalam *namespace* per *layer* dan dihubungkan melalui kontrak *API* yang stabil. Setiap *namespace* memuat satu kelompok komponen fungsional sehingga kebijakan *NetworkPolicy* dapat ditegakkan dengan model *default-deny* dan pengecualian eksplisit per arah komunikasi. *Deployment* komponen mengikuti pola GitOps melalui Argo CD, sedangkan eksekusi *pipeline* CI mengikuti pola Tekton, dengan setiap komponen tunduk pada *template ApplicationSet* agar penambahan komponen baru tidak menambah *boilerplate*. Dari sembilan *layer* rancangan,

tiga *layer* operasional telah terimplementasi pada Subbab V.1, yaitu *Orchestration and Infrastructure Layer* pada konfigurasi dasar *cluster*, *Platform Security Layer* pada manajemen rahasia dan identitas, serta *GitOps and Continuous Delivery Layer* pada pola GitOps, sedangkan *Feature Service Layer* dan *Data Governance Layer* diimplementasikan sebagai *sub-sistem* pada Subbab V.5 dan Subbab V.3, sehingga subbab ini merinci empat *layer* sisanya.

V.2.1 Data Ingestion and Processing Layer

Apache Kafka (Apache Software Foundation 2024c) diterapkan menggunakan operator Strimzi. *Kafka Connect* digunakan untuk integrasi dengan basis data eksternal melalui Debezium dan untuk *sink* ke Apache Iceberg pada MinIO (MinIO, Inc. 2024) dengan katalog Lakekeeper (Lakekeeper Authors 2025). *Karapace* berperan sebagai registri skema dengan dukungan Avro dan JSON Schema. Lalu lintas masuk dari konsumen di luar *mesh* dilewatkan melalui *API gateway* APISIX (Apache APISIX Authors 2025) dengan mTLS yang dijembatani pada perbatasan.

Cluster Kafka diatur dengan *KRaft* murni tanpa ZooKeeper agar topologi tetap ringan. SASL_SSL dipakai sebagai protokol keamanan antar klien dengan kredensial klien dikelola *Strimzi* melalui *KafkaUser*. *Topic* dideklarasikan sebagai *KafkaTopic* CR dan ACL dideklarasikan sebagai bagian dari *KafkaUser* sehingga keseluruhan kontrak *ingestion* tersimpan sebagai sumber daya Kubernetes yang dapat di-*audit*. Mekanisme SASL yang dipakai adalah SCRAM-SHA-512 dengan kredensial yang disebarkan External Secrets Operator dari OpenBao, dan topologi *topic* bawaan memakai enam *partition* dengan faktor replikasi satu pada satu *node* yang dapat dinaikkan menjadi tiga pada multi-*node*. *Lag* antrean dipantau KEDA ScaledObject yang membaca metrik Kafka Exporter melalui Prometheus. PeerAuth PERMISSIVE diterapkan pada *broker* agar penyedia data di luar *mesh* masih dapat berkomunikasi tanpa terlebih dahulu menambahkan *sidecar* Istio.

Jalur pemrosesan pada *layer* yang sama dirinci sebagai berikut. Pemrosesan *stream* menggunakan operator Flink yang mengelola *FlinkDeployment*. Pemrosesan *batch* menggunakan operator Spark dan dijalankan sebagai *SparkApplication*. Transformasi pada *warehouse* menggunakan dbt yang dijalankan sebagai *task* KubernetesPodOperator pada DAG Airflow (Apache Software Foundation 2024a). Airflow mengorkestrasi *pipeline* data berorientasi *batch*, termasuk pembangunan *gold layer*, sedangkan orkestrasi *model training* ditangani oleh Kubeflow Pipelines.

Flink dipasang dengan *session cluster mode Standalone* dan tugas *stream* dideklarasikan sebagai *FlinkSessionJob* CR sehingga setiap *job* dapat di-*deploy* secara independen melalui Argo CD. Spark Operator memanfaatkan *webhook* mutasi untuk menyisipkan *node selector* dan *toleration* berdasarkan label *queue-name* yang ditetapkan oleh Kueue. dbt menjalankan model SQL pada ClickHouse dengan *profiles.yaml* yang merujuk rahasia dari OpenBao melalui ESO. Airflow memakai *git-sync sidecar* yang menarik DAG dari Gitea sehingga pembaruan DAG tidak memerlukan pembangunan ulang *image*. *Checkpoint* dan *savepoint* Flink ditulis ke MinIO sehingga pemulihan *job* tidak kehilangan keadaan, dan *topic* hasil *stream* dikonsumsi *analytics layer* melalui tabel *Kafka engine* ClickHouse.

V.2.2 Data Storage Layer

Warehouse kolumnar menggunakan ClickHouse (ClickHouse Inc 2024) dengan operator ClickHouse pada satu *shard*. *Data lake* menggunakan MinIO sebagai *object store* dan Apache Iceberg sebagai *table format*, dengan Lakekeeper (Lakekeeper Authors 2025) sebagai katalog Iceberg REST dan Trino (Trino Software Foundation 2024) sebagai *query engine*. Penyimpanan kunci-nilai dan vektor menggunakan Valkey (Valkey Contributors 2025) dengan protokol RESP untuk akses berlatensi rendah, dan Qdrant (Qdrant Team 2025) sebagai basis data vektor untuk *embedding* berdimensi tinggi. Penyimpanan relasional menggunakan PostgreSQL melalui operator CNPG dengan *plugin barman-cloud* untuk pencadangan ke MinIO, dan MySQL sebagai Deployment dengan *persistent volume* pada *storage class* lokal untuk komponen yang terikat pada protokol MySQL. Apache Superset (Apache Superset Authors 2025) disiapkan sebagai antarmuka BI untuk peran *business user* dengan koneksi ke ClickHouse, Trino, dan MySQL melalui SQLAlchemy.

ClickHouse memakai ClickHouseKeeper sebagai pengganti ZooKeeper untuk koordinasi metadata replikasi. MinIO dipasang dengan empat drive pada satu *node* untuk menjaga skema penamaan erasure code yang seragam ketika *cluster* berpindah ke banyak *node*. Lakekeeper menyediakan Warehouse dan Project REST API yang dipakai oleh Spark, Trino, dan Flink dengan menggunakan *header x-project-id* sebagai pemisah antar *warehouse*. lakeFS (Treeverse Ltd. 2025) dipasang sebagai *version control layer* di atas MinIO sehingga eksperimen pada cabang data dapat dijalankan tanpa mengganggu data utama. MinIO disusun dengan *bucket* terpisah per kepentingan, antara lain *mlflow* untuk artefak eksperimen, *feast* untuk *registry* berbasis berkas, *warehouse* untuk data *lakehouse*, *flink-checkpoints* untuk *checkpoint streaming*, serta *velero-backups* untuk

pencadangan, dengan kapasitas yang dipantau melalui metrik MinIO pada Prometheus. Qdrant dilengkapi *persistent volume*, PodDisruptionBudget, dan kunci API yang disalurkan External Secrets Operator.

V.2.3 *Model Lifecycle Layer*

MLflow (MLflow Contributors 2024) dijalankan dengan basis data PostgreSQL dan *artifact store* pada MinIO. Kubeflow Pipelines (Kubeflow Contributors 2024) dijalankan pada *namespace* terpisah dengan dukungan *multi-tenant*, dilengkapi Kubeflow Notebooks untuk lingkungan eksperimen interaktif dan Kubeflow Trainer (Kubeflow Authors 2025c) untuk pelatihan terdistribusi. KServe (KServe Contributors 2024) dipakai untuk *inference* dengan dukungan *runtime* MLflow, scikit-learn, dan ONNX, dan dengan Knative Serving (Knative Authors 2025) sebagai bidang *serverless* bawaan yang menyediakan penskalaan ke nol. Argo Workflows berperan sebagai *orchestrator job* di luar Kubeflow Pipelines, sedangkan Argo Rollouts (Argo Rollouts Authors 2025) mengelola promosi versi pada *serving layer* dengan strategi *canary* dan *progressive analysis* berbasis metrik Prometheus.

Kubeflow Pipelines memakai MySQL sebagai *metadata store* dan MinIO sebagai *artifact store*, dengan kfp-launcher yang membungkus eksekusi langkah *pipeline* agar autentikasi ke MinIO dilakukan menggunakan *secretAsEnv*. KServe InferenceService dideklarasikan pada *namespace* *model-serving* dengan label *part-of=kserve* agar Kyverno tidak menolak *Pod mutator* bawaan. Kueue (Kueue Authors 2024) mengelola antrean pelatihan dengan ClusterQueue per kelompok beban kerja sehingga sumber daya CPU dan GPU dapat dibagi adil antara *tenant*. Argo Rollouts mengevaluasi metrik dari Prometheus pada setiap langkah *canary* untuk menentukan apakah versi *canary* layak dipromosikan menjadi versi *stable*.

V.2.4 *Observability Layer*

Prometheus (Prometheus Authors 2024) mengumpulkan metrik dari semua komponen dengan *ServiceMonitor* dan *PodMonitor*. Loki (Grafana Labs 2024b) mengumpulkan log melalui Alloy. Grafana Tempo (Grafana Labs 2024c) menerima *trace* dari OpenTelemetry Collector yang tersebar pada *node*. Grafana (Grafana Labs 2024a) menggabungkan ketiganya pada satu antarmuka.

Sloth (Sloth Authors 2025) menurunkan definisi *service-level objective* ke dalam aturan Prometheus sehingga *error budget* dapat dipantau bersama metrik lain. Pu-

shgateway berperan sebagai titik kumpul metrik untuk *job* berdurasi pendek yang berjalan di luar siklus *scrape*, termasuk CronJob pengukuran *drift* dan *CronWorkflow* pemicu *retraining*. OpenCost dipakai untuk pemantauan biaya per beban kerja, sedangkan Pyroscope mengumpulkan profil *CPU* dan memori secara berkelanjutan dari layanan yang menjadi *hotspot*. Evidently (Evidently AI 2025) dijalankan sebagai *job* berkala yang menghasilkan *report* HTML kualitas distribusi fitur dan disimpan pada MinIO sebagai jejak audit yang dapat dirujuk dari DataHub. Pemenuhan kebutuhan yang bergantung pada arsitektur terintegrasi ini diverifikasi melalui skenario evaluasi pada Bab VI.

V.3 Implementasi Sub-sistem Tata Kelola Data

Subbab ini menurunkan rancangan tata kelola pada Bagian IV.5 menjadi implementasi sebagai pemenuhan T-2, dengan fokus pada konsistensi katalog metadata, jadwal pengujian kontrak data, dan penegakan kontrol akses pada tiga *layer* yang berbeda. Penomoran KF-08, KF-09, dan KF-10, serta kebutuhan KNF terkait keamanan dipakai sebagai acuan untuk menilai apakah implementasi memenuhi seluruh kebutuhan yang dirumuskan pada Bab III. Katalog diwujudkan oleh DataHub dengan penerimaan *lineage* OpenLineage, kontrak kualitas oleh Great Expectations pada *pipeline* Airflow, dan kontrol akses oleh gabungan Dex, SpiceDB, serta kebijakan jaringan. Tiga *access layer* yang dimaksud mencakup autentikasi konsol, otorisasi granular, dan kebijakan jaringan antar *namespace*.

V.3.1 Katalog Metadata dan *Lineage*

DataHub (DataHub Project 2024) dijalankan dengan komponen GMS, *frontend*, dan beberapa *job ingest*, dengan OpenSearch sebagai *search backend* dan PostgreSQL sebagai *metadata backend*. *Job ingest* berjalan secara berkala sebagai *CronJob* untuk menarik metadata dari Kafka, ClickHouse, MinIO dan Iceberg, Feast, MLflow, dan Kubeflow Pipelines. Hasil *ingest* menyatukan *lineage* antar *layer*, mulai dari *topic* pada Kafka hingga model yang dilayani oleh KServe. OpenLineage (OpenLineage Authors 2025) dipakai sebagai protokol pengirim peristiwa *lineage* dari komponen *pipeline*, baik Airflow maupun Kubeflow Pipelines, agar graf ketertelusuran di DataHub tersusun dengan kosakata yang beragam.

Image datahub-feast-deps dibangun secara lokal dengan Kaniko untuk menambahkan *plugin* Feast pada *job ingest* sehingga sumber Feast dapat dipindai secara langsung. Autentikasi ke GMS menggunakan token sistem yang disimpan di OpenBao dan disebarkan ke *namespace* data-governance oleh *Exter-*

nal Secrets Operator. Konfigurasi DataHub pada level UI dikelola melalui *datahub-frontend-secret* dengan *checksum annotation* pada GMS dan *frontend* agar rotasi rahasia memicu *auto-roll deployment*. Jadwal *ingest* dapat berkonflik dengan beban kerja besar di *node*, dan untuk itu *native sidecar* Istio diaktifkan pada *CronJob* agar koneksi mTLS ke GMS tidak putus saat *sidecar* dihentikan setelah *job* selesai.

V.3.2 Kontrak Data dan Kualitas

Great Expectations (Great Expectations 2024) mendefinisikan ekspektasi kualitas data pada *bronze layer* setelah *ingestion* dan pada *silver* dan *gold layer* setelah transformasi. Setiap *expectation suite* disimpan pada repositori Git dan dijalankan oleh *CronJob* yang membaca hasil ke DataHub. Pengujian yang gagal akan menutup jalur promosi ke *layer* berikutnya dan memunculkan peringatan pada Grafana. Hasil ekspektasi disimpan ke MinIO sebagai *Data Docs* HTML sehingga konteks kegagalan dapat ditelusuri tanpa perlu menjalankan kembali *suite*.

dbt menjalankan model SQL untuk *silver* dan *gold layer* pada ClickHouse, dengan *schema.yml* yang memuat *tests* dasar seperti *unique*, *not_null*, dan *accepted_values*. Hasil dbt dirilis ke DataHub melalui *run event* OpenLineage yang dikirim oleh *task* KubernetesPodOperator dbt pada DAG Airflow. *Checkpoint* Great Expectations dijadwalkan per *layer* dengan jeda yang berbeda agar ekspektasi yang berat tidak berdampak pada beban *warehouse*. *Suite* fakta pelatihan diuji setelah materialisasi pada tabel *gold.fct_training_data* agar *training set* tidak masuk *training pipeline* apabila kualitas data tidak memenuhi kontrak.

V.3.3 Kontrol Akses

Kontrol akses pada *network layer* menggunakan *NetworkPolicy* dengan kebijakan *default-deny* per *namespace* dan pengecualian yang dideklarasikan secara eksplisit. Pada *application layer*, kontrol akses memakai jalur autentikasi tunggal dex dan *oauth2-proxy* yang telah dirinci pada Subbab V.1.3, sehingga akses ke konsol tata kelola tunduk pada sesi identitas yang sama dengan layanan platform lain. Pada *admission layer*, Kyverno (Kyverno Authors 2024) menegakkan kebijakan keamanan beban kerja sesuai rancangan pada Subbab IV.5.3. Falco (Falco Authors 2025) memantau peristiwa *runtime* pada level *kernel* untuk mendeteksi pelanggaran kebijakan keamanan setelah *pod* berjalan.

SpiceDB (AuthZed 2025) berfungsi sebagai layanan otorisasi yang dipakai DataHub

dan Kubeflow Pipelines untuk hubungan akses pada level objek, dengan basis data PostgreSQL melalui CNPG. *Policy* Kyverno disusun pada *namespace security* dengan *policy generator* yang menyebarkan kebijakan ke *namespace* aplikasi tanpa duplikasi sumber daya. Kyverno mode *failurePolicy=Ignore* dipakai pada *ValidatingPolicy* agar admisi tidak terblokir saat *webhook* gagal pada kondisi *cluster* yang sibuk. Falco mengirim peringatan ke Loki melalui *falcosidekick* dengan *topic* khusus sehingga tim keamanan dapat menelusuri peristiwa terkait kebijakan dari satu antarmuka Grafana. Pemenuhan KF-08, KF-09, dan KF-10 diverifikasi melalui skenario evaluasi pada Bab VI.

V.4 Implementasi Sub-sistem Deteksi *Drift* dan *Continuous Training*

Implementasi sub-sistem deteksi *drift* menindaklanjuti rancangan pada Bagian IV.6 sebagai pemenuhan T-3, dengan fokus pada otomatisasi penuh *control loop* dari pengukuran sampai promosi versi serta penegakan ambang yang dapat dikonfigurasi per model. Pemicu *retraining* dirancang agar dapat dijalankan secara berkala atau dipicu oleh peristiwa *drift* yang melebihi ambang. Keseluruhan implementasi pada bagian ini menjawab KF-07 untuk deteksi *drift* otomatis berikut pemicuan *retraining*, sehingga model pada *serving layer* tidak dibiarkan usang tanpa evaluasi berkala saat distribusi data bergeser. Seluruh langkah *loop* diwujudkan pada CronWorkflow *retrain-on-drift* yang membaca skor dari tabel analitik dan memanggil *training pipeline* Kubeflow Pipelines.

V.4.1 Detektor *Drift*

Detektor *drift* diimplementasikan sebagai *service* Python yang membaca fitur dari ClickHouse dengan jendela waktu yang dapat dikonfigurasi. Indikator PSI dihitung dengan *binning* adaptif, dan uji Kolmogorov-Smirnov dijalankan dengan ambang yang dapat disesuaikan per fitur (Reis dkk. 2016; Bayram, Ahmed, dan Kassler 2022; Lu dkk. 2019). Hasil pengukuran ditulis ke ClickHouse sebagai tabel *gold.drift_multi_scale* dan dipublikasikan ke Pushgateway agar dapat diserap oleh Prometheus. Evidently (Evidently AI 2025) dijalankan sebagai pelapor pelengkap yang menghasilkan ringkasan distribusi fitur dan kinerja model dalam bentuk *report HTML* yang dapat diaudit dan dilampirkan pada katalog DataHub.

Service berjalan sebagai *CronJob* pada *namespace* *model-lifecycle* dengan jadwal lima belas menit untuk fitur fluktuatif dan satu jam untuk *tabular feature* yang lebih stabil. Konfigurasi ambang per fitur dideklarasikan pada *ConfigMap* *drift-thresholds* sehingga perubahan ambang dapat dilakukan melalui *com-*

mit pada Git tanpa membangun ulang *image*. Hasil tiap eksekusi ditulis dengan checksum versi konfigurasi sehingga riwayat ambang dapat ditelusuri saat audit. *Image* detektor dibangun dengan uv pada Dockerfile multi-stage agar model SBERT untuk deteksi *drift embedding* disertakan langsung pada *layer* terakhir *image*, sehingga *cold start* tidak memerlukan unduhan model.

V.4.2 Retraining Control Loop

Control loop dijalankan oleh Argo CronWorkflow dengan jadwal yang dapat dikonfigurasi per model. *Workflow* menjalankan dua langkah utama: pengukuran *drift* dan pemicu *training pipeline*. Pemicu pelatihan mengirim permintaan ke Kubeflow Pipelines. *Training pipeline* membaca fitur pelatihan dari tabel *gold* ClickHouse, menjalankan pelatihan pada *job* dengan sumber daya yang dialokasikan oleh Kueue (Kueue Authors 2024), lalu mencatat metrik dan artefak model ke MLflow. Kelayakan model baru untuk menggantikan versi produksi ditentukan pada tahap promosi *canary* yang menilai metrik *serving*-nya secara langsung sebelum trafik penuh dialihkan, bukan pada perbandingan tersendiri sebelum *deployment*.

Pada tahap promosi, Argo Rollouts (Argo Rollouts Authors 2025) menyalurkan trafik *serving layer* secara bertahap ke versi baru memakai strategi *canary* dengan analisis metrik Prometheus, sehingga *rollback* otomatis dapat dilakukan ketika kinerja menurun. *retrain-on-drift* CronWorkflow disimpan pada direktori *workflow* milik *use case* yang terpisah dari platform/ agar dapat di-*deploy* bersama *use case* ketika pengujian dijalankan. Konfigurasi penonaktifan *cache* KFP diterapkan pada langkah *train* dan *deploy* agar setiap eksekusi memakai data terbaru tanpa dipengaruhi *cache* historis. Pengiriman metrik *workflow* dilakukan di dalam langkah *decide-and-trigger* yang menulis ke Pushgateway, sehingga seluruh metrik eksekusi tetap terkumpul pada Prometheus meskipun *workflow* berdurasi singkat.

V.4.3 Penanganan Kasus Khusus

Implementasi menangani tiga kasus khusus yang sama dengan rancangan pada Subbab IV.6.3. Ketiganya diwujudkan tanpa menambah komponen baru di luar CronWorkflow dan Argo Rollouts yang sudah terpasang. Perilaku tiap kasus dapat diperiksa dari manifes dan log eksekusi pada *namespace* *model-lifecycle*. Rinciannya sebagai berikut.

1. Jendela tunggu label per model

Jendela tunggu label diatur per model agar *retraining* tidak dipicu sebelum label tersedia cukup.

2. **Jendela bergulir untuk meredam fluktuasi**

Ambang *drift* dihitung dengan jendela bergulir untuk meredam fluktuasi singkat.

3. **Penghentian promosi saat analisis *canary* gagal**

Ketika analisis *canary* gagal, promosi dihentikan sehingga versi stabil pada *serving layer* tetap dipertahankan.

Ketiga kasus khusus ditangani sesuai rancangan pada Subbab IV.6.3. Ambang PSI dan KS beserta jendela *lookback* dideklarasikan pada ConfigMap *drift-thresholds* di *namespace* *model-lifecycle* sehingga perubahannya cukup melalui *commit* Git tanpa membangun ulang *image*. Setiap eksekusi menuliskan checksum versi konfigurasi tersebut sehingga nilai ambang yang berlaku tetap dapat dirunut saat audit. Nilai parameter yang aktif dapat dibaca langsung dari manifes sehingga audit kebijakan tidak memerlukan akses ke sistem lain. Pemenuhan KF-07 diverifikasi melalui skenario evaluasi pada Bab VI.

V.5 Implementasi Sub-sistem Layanan Fitur *Dual-Store*

Sub-sistem layanan fitur *dual-store* mewujudkan rancangan pada Bagian IV.7 sebagai pemenuhan T-4, dengan satu sumber definisi fitur dan satu kontrak Feast untuk *tabular feature*, sedangkan fitur *embedding* dikelola pada indeks vektor terpisah. *Tabular feature* dimaterialisasi ke *online store* Valkey dan diakses melalui API Feast, sedangkan indeks vektor Qdrant diisi dan diakses melalui klien *native* di luar materialisasi Feast. Ketiga penyimpanan itu terikat pada satu sumber definisi di *feature_repo/* sehingga perubahan skema fitur cukup dilakukan pada satu tempat. Bagian ini menjawab KF-01 sampai KF-04 yang menuntut manajemen fitur terpusat, *serving* ganda *online-offline*, validitas temporal, dan dukungan *vector embedding*.

V.5.1 Konfigurasi Feast

Feast (Feast Project 2024) dikonfigurasi dengan *feature_store.yaml* yang menentukan *offline store* ClickHouse, *online store* Valkey (Valkey Contributors 2025) melalui protokol RESP, dan registri *file-based* pada MinIO. Definisi fitur ditulis dalam Python pada modul *feature_definitions.py* dan didaftarkan ke registri melalui *feast apply*. Materialisasi fitur ke *online store* dijalankan oleh *job* berkala yang membaca dari ClickHouse dengan rentang waktu yang sesuai. Berkas *feature_store.yaml* yang sama dipakai oleh seluruh klien sehingga tidak ada konfigurasi penyimpanan yang didefinisikan ulang per layanan.

Registri Feast disimpan sebagai `registry.db` di *bucket* MinIO dengan kunci yang dirotasi melalui ESO sehingga klien Feast pada berbagai *namespace* berbagi sumber kebenaran yang sama. *Service* feast *serve* dipasang sebagai *Deployment* yang dijangkau melalui *Service* `feast-server` pada *namespace* `model-lifecycle`. Pembaruan definisi fitur dilakukan oleh *service* materialisasi yang menjalankan `feast apply` sebagai langkah pada DAG `data_pipeline` Airflow, sehingga registri selalu sinkron dengan definisi pada `feature_repo/`. *Client* Feast pada layanan pemanggil dikonfigurasi dengan `registry_path` URI `s3://`, sehingga sumber kebenaran tunggal tetap terjaga ketika klien berjalan pada *namespace* berbeda.

V.5.2 Dukungan *Vector Embeddings*

Vector embedding disimpan sebagai fitur dengan tipe `Array(Float32)` pada ClickHouse dan sebagai *point* berdimensi 768 pada *collection* Qdrant (Qdrant Team 2025). Pengindeksan HNSW diaktifkan pada Qdrant dengan parameter `m` dan `ef_construct` yang dapat dikonfigurasi, dan kueri tetangga terdekat dilayani melalui *API gRPC* dengan filter *payload* pada saat pencarian. *Service vector-embedding* pada `platform/services/processing/vector/` membungkus model `sentence-transformers/all-mpnet-base-v2` sebagai penghasil *embedding* dan menyajikan *API* yang dipanggil oleh *stream processor* pada saat peristiwa masuk (Reimers dan Gurevych 2019). Metrik jarak yang dipakai adalah kosinus sesuai bawaan layanan *embedding* untuk vektor yang dinormalkan.

Image vector-embedding dibangun dengan `uv` dan model SBERT di-bake ke *layer* COPY terakhir agar *startup probe* tidak terganggu oleh unduhan model pada pemicu pertama. *Collection* Qdrant dideklarasikan oleh *init Job* yang mengirim PUT ke `/collections/nama-koleksi` dengan parameter HNSW sesuai konfigurasi. *Snapshot* koleksi disimpan ke MinIO secara berkala dengan *Job* `qdrant-snapshot` yang menambah objek pencadangan ke jadwal Velero. Koleksi vektor Qdrant diakses langsung oleh layanan *embedding* melalui klien *native* Qdrant, terpisah dari *online store* Valkey yang menyajikan *tabular feature* melalui Feast, sehingga jalur kueri vektor dan jalur *tabular feature* tidak saling bergantung.

V.5.3 Materialisasi dan *Point-in-Time Correctness*

`get_historical_features` dijalankan pada *training pipeline* dengan kolom `event_timestamp` pada *entity dataframe*. Feast melakukan *point-in-time join* pada *offline store* ClickHouse dengan memilih nilai fitur yang `timestamp`-nya tidak melampaui `event_timestamp` setiap baris entitas dan masih berada dalam rentang

ttl FeatureView. Ketika terdapat lebih dari satu kandidat untuk satu titik waktu, kolom *created_timestamp* dipakai sebagai penentu agar hanya nilai paling mutakhir yang diambil, sehingga nilai fitur yang dipakai pada saat pelatihan identik dengan nilai yang tersedia pada saat itu. Materialisasi ke *online store* berjalan secara berkala dengan *feast materialize-incremental*, dan *stream materializer* pada Flink menulis fitur *real-time* ke Valkey untuk *tabular feature* secara bersamaan dengan penulisan ke ClickHouse.

Materialisasi dijalankan berkala oleh DAG Airflow melalui *task feast_materialize* yang mendorong fitur dari *offline store* ClickHouse ke *online store* Valkey pada jadwal per jam. Karena nilai pada Valkey merupakan hasil materialisasi dari ClickHouse, konsistensi antar *store* terjaga secara struktural tanpa salinan yang dipelihara terpisah. Kualitas data diverifikasi oleh *CronJob* *ge-checkpoint* yang menjalankan *suite* Great Expectations terhadap tabel pada ClickHouse setiap enam jam, dengan hasil validasi ditulis ke MinIO dan *gauge* lulus atau gagal dikirim ke Pushgateway. Pengujian *point-in-time* dijalankan sebagai skenario SK-F-03 yang mengaudit *get_historical_features* pada *training dataset*, memastikan kontrak *event_timestamp* dan *ttl* tetap dipatuhi oleh *FeatureView* yang ditambahkan.

V.6 Verifikasi Implementasi

Verifikasi jalur eksekusi dilakukan dengan satu *use case* domain nyata sebagai kasus pengujian, yang struktur layanan, konfigurasi, dan datanya dirinci pada Bab VI. Pemilihan ini tidak mengubah sifat domain-agnostik dari platform, karena seluruh kode dan konfigurasi platform tetap berada pada repositori *platform/*, sedangkan kode dan konfigurasi spesifik domain tinggal pada direktori *use case* tersendiri yang terpisah dari platform. Manifes Kubernetes domain mengikuti pola *base* dan *overlays Kustomize* sehingga parameter spesifik lingkungan cukup disetel pada *overlay layer* tanpa menyentuh definisi dasar. Pola yang sama berlaku untuk *use case* lain, karena berkas konfigurasi domain cukup disalin dan disesuaikan tanpa mengubah kode platform. *Use case* ini dipilih karena menjalankan seluruh sembilan *layer* representatif yang ditetapkan pada Subbab IV.2, dengan pemetaan tiap *layer* ke komponennya dirinci pada Subbab VI.1.1. Sifat lepas-domain kesembilan *layer* itulah yang membuat pemilihan *use case* ini tidak mengurangi keberlakuan platform pada domain lain.

V.6.1 Lingkup Verifikasi

Verifikasi mencakup lima jalur yang masing-masing menyoroti satu sub-sistem. Kelimanya dipilih dari alur ujung ke ujung *use case* sehingga setiap kontrak antar *layer* teruji oleh trafik nyata. Setiap jalur memiliki keluaran yang dapat diamati pada *dashboard* atau tabel analitik sebagai bukti. Kelima jalur tersebut sebagai berikut.

1. **Jalur *ingestion***

Jalur *ingestion* diuji dengan *stream* dari sumber eksternal yang masuk ke Kafka melalui layanan *websocket-collector* pada *use case*.

2. **Jalur pemrosesan**

Jalur pemrosesan diuji dengan *stream-processor* berbasis Flink yang menulis fitur agregasi ke ClickHouse dan Valkey.

3. **Jalur *training***

Jalur *training* diuji dengan *pipeline* Kubeflow yang membaca fitur dari Feast dan menulis model ke MLflow.

4. **Jalur *serving***

Jalur *serving* diuji dengan *InferenceService* KServe yang memuat model dari MLflow, dengan promosi versi pada *serving layer* yang dikelola oleh Argo Rollouts.

5. **Jalur *retraining***

Jalur *retraining* diuji dengan menjalankan *drift-detector* dan memicu *retrain-on-drift workflow*.

Uji ketahanan pendek menggunakan Chaos Mesh (Chaos Mesh Authors 2025) untuk menyuntikkan *fault* pada *pod* terpilih. Skenario yang dipakai adalah PodChaos yang mematikan *pod* terpilih lalu mengamati pemulihannya oleh *controller*. Pencadangan dijalankan terjadwal oleh Velero (Velero Authors 2025) ke *bucket* MinIO khusus pencadangan sebagai langkah disiplin pemulihan. Kedua mekanisme diuji kembali pada skenario ketahanan di Bab VI.

Lima jalur tersebut dipilih agar setiap sub-sistem mendapat verifikasi minimal satu skenario nyata, sehingga ketidaktepatan rancangan dapat ditemukan sebelum penilaian akhir pada Bab VI. Skenario *use case* menetapkan beban yang lebih tinggi pada jalur *ingestion* dan pemrosesan dibandingkan jalur *training*, karena *use case* *ber-throughput* tinggi memproduksi banyak peristiwa per detik dari beberapa entitas secara paralel. Pengamatan dilakukan dengan *dashboard* Grafana yang menampilkan metrik latensi, *throughput*, panjang antrean Kafka, dan tingkat keberhasilan ma-

terialisasi. Hasil pengamatan dibandingkan dengan target metrik pada KNF Bab III untuk menentukan apakah setiap jalur memenuhi target yang telah ditetapkan.

V.6.2 Pengamatan Hasil Awal

Hasil pengamatan awal memperlihatkan bahwa jalur kendali platform terbentuk sesuai rancangan. Seluruh komponen pada kelima jalur berhasil di-*deploy* dan direkonsiliasi oleh Argo CD, *retraining control loop* terpicu otomatis ketika injeksi *drift* terkendali diterapkan pada salah satu fitur, dan promosi versi pada *serving layer* dikendalikan oleh Argo Rollouts sesuai konfigurasi *canary*. Reprodusibilitas jalur diuji dengan merekonstruksi seluruh komponen platform dari Argo CD pada *cluster* k3s yang baru, dan rekonstruksi tersebut berhasil dilakukan tanpa intervensi manual selain *bootstrap* Argo CD awal. Penilaian kebenaran data *end-to-end*, validitas *point-in-time* pada pelatihan, latensi *serving*, *throughput* pemrosesan, dan ketepatan deteksi *drift* diuraikan secara terperinci pada Bab VI.

Pengamatan tambahan menunjukkan bahwa jalur observabilitas berhasil mempertahankan metrik dan log dari seluruh komponen pada satu antarmuka Grafana, dan bahwa peristiwa *lineage* dari *emitter* OpenLineage Airflow dan Spark serta konektor *ingestion* DataHub untuk Feast, MLflow, ClickHouse, dan Kafka muncul pada satu graf metadata dengan kosakata yang seragam. Pencadangan Velero berjalan terjadwal tanpa intervensi, dan pengujian pemulihan dari pencadangan memperlihatkan bahwa konfigurasi seluruh komponen dapat direkonstruksi tanpa langkah manual. Uji *fault injection* Chaos Mesh menunjukkan bahwa *pod* yang dimatikan secara paksa dijadwalkan ulang secara otomatis oleh *controller* Kubernetes, dan bahwa Argo Rollouts otomatis menahan promosi ketika metrik *canary* menyentuh ambang. Catatan pengamatan ini menjadi dasar bagi evaluasi pada Bab VI yang menilai pemenuhan KF dan KNF terhadap target metrik.

BAB VI

EVALUASI

Bab ini memaparkan evaluasi platform terhadap kebutuhan fungsional KF-01 sampai KF-14 dan kebutuhan nonfungsional KNF-01 sampai KNF-12 yang disusun pada Bab III. Evaluasi disusun mengikuti empat tujuan platform T-1 sampai T-4 sehingga setiap hasil dapat dipetakan kembali pada tujuan, rumusan masalah, dan butir kesimpulan dengan indeks yang sama. Pengujian dilakukan pada satu *use case* domain nyata sebagai kasus verifikasi, yaitu pasar aset kripto dengan data Coinbase, agar perilaku platform dapat diamati pada beban dan pola data yang realistis tanpa mengubah sifat *domain-agnostic* platform. Penyajian dibagi menjadi metode evaluasi, hasil evaluasi, perbandingan biaya infrastruktur dan tenaga kerja, serta pembahasan, dengan lingkup penerimaan fungsional dan struktural pada lingkungan *node* tunggal sesuai batasan BI-1, sedangkan karakterisasi beban kuantitatif pada kluster multi-*node* menjadi arah pengembangan yang dirinci pada Bab VII.

VI.1 Metode Evaluasi

Metode evaluasi mengikuti tiga dimensi yang melekat pada empat tujuan platform, yaitu pemenuhan fungsional, pemenuhan nonfungsional, dan tata kelola. Pemenuhan fungsional menilai apakah setiap KF terbukti melalui skenario uji yang dapat dijalankan ulang, pemenuhan nonfungsional menilai apakah setiap KNF mencapai target metrik yang ditetapkan, dan tata kelola menilai apakah *lineage* tertelusur, kontrak data ditegakkan, serta kebijakan akses dapat diaudit. Setiap skenario diberi penanda SK-F untuk kebutuhan fungsional dan SK-N untuk kebutuhan nonfungsional, lalu dikelompokkan di bawah tujuan T-1 sampai T-4 yang relevan. Penomoran tersebut menjaga keterhubungan satu lawan satu antara skenario, kebutuhan, dan tujuan sehingga kegagalan satu skenario dapat segera dirunut ke komponen yang bertanggung jawab.

Skenario dijalankan secara manual pada tahap evaluasi dan tidak menjadi bagian dari *make phase-full* maupun rekonsiliasi Argo CD, agar pengukuran tidak mengganggu jalur produksi platform. Pembangkit beban dijalankan dari *namespaces* *platform-test* yang terpisah, sedangkan instrumen pengukuran memanfaatkan komponen observabilitas yang sudah terpasang. Instrumen utama mencakup k6 untuk beban *HTTP* dan *gRPC*, Chaos Mesh untuk injeksi *fault*, Great Expe-

ctations untuk kontrak kualitas, serta Prometheus, Grafana, Grafana Tempo, dan OpenCost untuk metrik, *trace*, dan biaya. Berkas skenario disimpan pada direktori *experiments/* yang sejajar dengan *platform/* dan *use-case-crypto/* sebagai *layer* verifikasi terpisah, dengan subdirektori *load/* untuk beban latensi dan *throughput*, *chaos/* untuk injeksi *fault*, *drift/* untuk pengujian deteksi *drift*, *feast/* untuk *serving online feature*, *parity/* untuk paritas *batch* dan *stream*, *lineage/* untuk penelusuran *lineage*, serta *etl/* untuk pemeriksaan *landing* data. Susunan ini membuat prosedur uji dapat ditelusuri ulang bersama kode tanpa mengubah sistem yang diuji.

VI.1.1 Kasus Verifikasi dan Lingkungan Uji

Kasus verifikasi adalah *use case* pasar aset kripto dengan data Coinbase yang dialirkan melalui dua jalur *ingestion* yang saling melengkapi. Jalur *real-time* memakai layanan *websocket-collector* yang berlangganan kanal *ticker* dan *matches* Coinbase pada resolusi per detik hingga per transaksi, lalu *stream-processor* berbasis Flink mengagregasinya menjadi fitur berjendela waktu pada tabel *bronze.crypto_ohlcv_features*. Jalur historis memakai layanan *rest-collector* yang menarik *candle* OHLCV Coinbase pada granularitas satu menit sebagai garis dasar sekaligus pemulihan celah historis sejak 1 Maret 2026 mengikuti anggaran penyimpanan pada lingkungan *node* tunggal sesuai batasan BI-1, lalu memuatnya pada tabel *bronze.crypto_ohlcv*. *Endpoint candle* REST Coinbase tidak menyediakan granularitas di bawah satu menit sehingga resolusi per detik hanya berlaku pada jalur *real-time*. Domain ini dipilih karena menuntut *throughput ingestion* yang tinggi, latensi *serving* rendah, dan distribusi data nonstationer, sehingga keempat *sub-sistem* platform diuji pada kondisi yang menantang. Di luar keempat *sub-sistem* tersebut, *use case* kripto mengaktifkan seluruh sembilan *layer* platform representatif dari Subbab IV.2 secara bersamaan. Jalur *ingestion streaming* dan *batch* bersama pemrosesan Flink dan dbt mengisi *Data Ingestion and Processing Layer*, penyimpanan *lakehouse* mengisi *Data Storage Layer*, layanan fitur *dual-store* dengan *tabular feature*, *aggregate feature*, serta *vector feature* mengisi *Feature Service Layer*, dan tata kelola dengan *lineage* mengisi *Data Governance Layer*, sehingga empat *layer* bidang data terisi seluruhnya. Pada lima *layer* bidang model dan operasional, orkestrasi *k3s* yang menjadi fondasi seluruh komponen mengisi *Orchestration and Infrastructure Layer*, jalur *training* dengan *retraining* otomatis dan *model serving* berlatensi rendah mengisi *Model Lifecycle Layer*, observabilitas dengan metrik, log, dan *trace* mengisi *Observability Layer*, pengiriman GitOps mengisi *GitOps and Continuous Delivery Layer*, serta

kontrol keamanan mengisi *Platform Security Layer*. Karena verifikasi fungsional menyentuh kesembilan *layer* tersebut, *use case* ini menjadi kasus uji yang mewakili himpunan layanan representatif meskipun bersifat spesifik domain. Seluruh kode dan konfigurasi spesifik domain berada pada direktori *use-case-crypto/* yang terpisah dari *platform/*, mencakup layanan *websocket-collector* dan *rest-collector* sebagai produsen peristiwa, *stream-processor* berbasis Flink, *batch layer* berbasis dbt, definisi Feast, serta jembatan *inference* dan *dashboard*. Pemisahan ini menegaskan bahwa platform tetap *domain-agnostic* dan *use case* hanya berperan sebagai beban uji yang dapat diganti tanpa menyentuh *control plane*.

Konfigurasi spesifik domain diterapkan melalui *overlay* Kustomize yang menambahkan prefiks *crypto-* pada sumber daya basis platform, sehingga *InferenceService* basis bernama *predictor* menjadi *crypto-predictor* ketika di-*deploy*. *Overlay* tersebut hanya menetapkan prefiks nama, pemetaan registri *image*, jumlah *replica* awal, serta batas *autoscaling* untuk lingkungan *node* tunggal, sedangkan parameter sumber data berada pada *ConfigMap* basis sehingga definisi dasar tidak perlu disentuh, sebagaimana ditunjukkan pada Listing VI.1. Sesuai invarian *node* tunggal, setiap *workload* berjalan dengan satu *replica* saat *idle* dan diskalakan oleh HPA serta KEDA hanya ketika beban nyata muncul, dengan *maxReplicas* dibatasi tiga agar muat pada satu node. Dengan demikian, penggantian *use case* cukup dilakukan dengan menyiapkan *overlay* baru tanpa mengubah manifes platform, sekaligus menjadi bukti konkret atas pemenuhan KF-12 tentang konfigurasi deklaratif dan KNF-11 tentang portabilitas.

Listing VI.1 Kutipan *overlay* Kustomize *use case*: prefiks *crypto-*, pemetaan registri *image*, *replica idle* satu, dan batas HPA *node* tunggal

```
1 # use-case-crypto/manifests/overlays/local/kustomization.yaml
2 namePrefix: crypto-
3 resources:
4   - ../../base
5   - ../../cross-namespace
6 images:
7   - name: rest-collector
8     newName: localhost:5000/crypto-rest-collector
9     newTag: latest
10  - name: websocket-collector
11    newName: localhost:5000/crypto-websocket-collector
12    newTag: latest
13  # ... validator, analyzer, dll.
14 replicas:
```

```

15   - name: rest-collector
16     count: 1
17   - name: websocket-collector
18     count: 1
19 patches:
20   - target:
21       kind: HorizontalPodAutoscaler
22     patch: |-
23       - op: replace
24         path: /spec/maxReplicas
25         value: 3
26       - op: replace
27         path: /spec/minReplicas
28         value: 1

```

VI.1.2 Evaluasi Tujuan T-1: Arsitektur Terintegrasi dan GitOps

Evaluasi T-1 menilai apakah seluruh platform dapat dipasang dari satu sumber Git, dikelola secara deklaratif, dan menyediakan otomatisasi *model lifecycle* setara MLOps *level 2*. Skenario SK-F-01 mengubah definisi *feature view* pada Gitea lalu mengamati rekonsiliasi Argo CD untuk membuktikan KF-01, sementara SK-F-12 mengubah jumlah *replica* pada manifes untuk membuktikan konfigurasi deklaratif KF-12 yang konvergen tanpa *drift*. Skenario SK-F-06 mempromosikan model melalui Argo Rollouts dengan strategi *canary* dan memicu *rollback* pada model bermasalah untuk membuktikan otomatisasi *deployment* model pada KF-06, sedangkan SK-F-13 menjalankan satu *notebook* dalam satu *environment* uv yang memuat SDK Feast, MLflow, dan klien *inference* KServe v2 sebagai tiga operasi baca independen untuk membuktikan antarmuka terpadu KF-13. Skenario SK-F-14 memenuhi kuota *ClusterQueue* Kueue untuk membuktikan manajemen sumber daya KF-14, dengan *job* di luar anggaran berstatus *Pending*.

Kematangan MLOps *level 2* dinilai melalui tiga jalur otomatisasi yang saling terhubung. Jalur pertama adalah *training pipeline* otomatis pada Kubeflow Pipelines yang dipicu data baru atau ambang *drift*, jalur kedua adalah *deployment* model otomatis melalui KServe dan Argo Rollouts, dan jalur ketiga adalah pemantauan berkelanjutan oleh Argo Workflows yang melaporkan metrik ke Prometheus. Reprodusibilitas *deployment* diuji oleh SK-N-11 yang menerapkan ulang seluruh manifes pada *node* k3s baru dan SK-N-12 yang mengukur cakupan uji serta waktu konvergensi `make phase-full`. Gabungan skenario ini menegaskan bahwa T-1 tidak hanya menyediakan komponen, melainkan satu *control plane* yang dapat direkonstruksi dan

diaudit.

Atribut kualitas yang bersifat lintas komponen turut dievaluasi pada T-1 karena melekat pada *control plane* terintegrasi, bukan pada satu *sub-sistem* tunggal. Skenario SK-N-03 menaikkan beban dengan `load/hpa-keda-rampup.js` untuk membuktikan skalabilitas horizontal KNF-03 melalui HPA dan KEDA *ScaledObject*, sedangkan SK-N-04 menyuntikkan *fault* dengan Chaos Mesh untuk membuktikan keandalan KNF-04 pada batas RTO dan RPO. Skenario SK-N-08 mengganti satu komponen melalui antarmuka CRD dan *overlay* Kustomize untuk membuktikan ekstensibilitas KNF-08, SK-N-09 mengakses seluruh konsol melalui satu sesi identitas dex untuk membuktikan kemudahan penggunaan KNF-09, dan SK-N-10 mengukur kompresi serta atribusi biaya melalui OpenCost untuk membuktikan efisiensi sumber daya KNF-10. Pengelompokan ini menempatkan T-1 sebagai tujuan dengan beban pengujian nonfungsional terbanyak karena arsitektur terintegrasi menanggung jaminan kualitas yang berlaku menyeluruh pada seluruh komponen.

VI.1.3 Evaluasi Tujuan T-2: Tata Kelola Data

Evaluasi T-2 menilai apakah katalog metadata, *lineage*, dan kontrol kualitas berjalan otomatis sepanjang *pipeline* data, fitur, dan model. Skenario SK-F-08 menelusuri *lineage* pada DataHub melalui `lineage/lineage-walk.sh` dari *topic* sumber sampai keluaran prediksi untuk membuktikan KF-08, dengan peristiwa *lineage* dikirim melalui OpenLineage dan *ingestion* terjadwal. Skenario SK-F-09 menjalankan dua *training run* pada MLflow lalu memutar ulang dari *snapshot* untuk membuktikan pelacakan eksperimen KF-09, sedangkan SK-F-10 memindahkan model melalui status *staging*, *production*, dan *archived* untuk membuktikan registri dan *audit trail* KF-10. Skenario SK-N-05 menjalankan *checkpoint* Great Expectations dan menyuntikkan pelanggaran skema, rentang nilai, serta kelengkapan untuk membuktikan penegakan kontrak kualitas data KNF-05 sepanjang *pipeline*.

Dimensi keamanan dan observabilitas tata kelola dievaluasi melalui dua skenario tambahan. Skenario SK-N-06 menelusuri satu *trace* OpenTelemetry pada Grafana Tempo dari *ingestion* sampai prediksi untuk membuktikan observabilitas KNF-06, sehingga metrik, log, dan *trace* dapat dirujuk silang pada satu antarmuka. Skenario SK-N-07 memindai *cluster* dengan Trivy dan memeriksa konfigurasi TLS untuk membuktikan keamanan KNF-07, mencakup mTLS Istio, enkripsi *at rest* MinIO melalui KES dan OpenBao, serta kebijakan admisi Kyverno. Ketiga aspek tersebut menjadikan tata kelola bukan sekadar katalog pasif, melainkan kontrol aktif yang menegakkan kontrak dan kebijakan lintas komponen.

VI.1.4 Evaluasi Tujuan T-3: Deteksi *Drift* dan *Retraining*

Evaluasi T-3 menilai apakah deteksi *drift* terotomasi memicu *retraining* sesuai kebijakan dan apakah *feature serving* menjamin *point-in-time correctness*. Skenario SK-F-07 menerapkan pergeseran distribusi terkendali pada aliran data nyata melalui `inject_drift.py`, yang mengonsumsi rekaman pasar tervalidasi lalu menggeser nilainya beberapa sigma sebelum dipublikasikan ulang, kemudian mengamati detektor *drift* dan *CronWorkflow* `retrain-on-drift` untuk membuktikan pemantauan KF-07. Detektor membandingkan distribusi produksi terhadap distribusi pelatihan dengan *Population Stability Index* dan uji Kolmogorov-Smirnov, lalu memicu *training pipeline* ketika ambang terlampaui. Skenario SK-F-05 menjalankan *training pipeline* pada Kubeflow Pipelines yang membaca fitur dari tabel *gold* dan menulis model ke MLflow untuk membuktikan otomasi pelatihan KF-05.

Validitas temporal diuji secara khusus karena *point-in-time correctness* menjadi pembeda utama platform ini dari *feature serving* tanpa *feature store*, yang hanya menarik *tabular feature* dari satu sumber. Skenario SK-F-03 mengaudit `get_historical_features` pada *training dataset* untuk membuktikan KF-03, dengan memastikan tidak ada baris yang memakai informasi setelah *event timestamp* acuan. Pengujian ini memakai *probe timestamp* masa depan yang menolak setiap baris bermuatan informasi setelah *event timestamp* acuan sehingga jaminan *zero leakage* ditegakkan langsung pada jalur penyusunan fitur pelatihan. Gabungan skenario ini menegaskan bahwa T-3 menjawab dua risiko sekaligus, yaitu degradasi model akibat *drift* dan kebocoran temporal akibat penyusunan fitur yang keliru.

VI.1.5 Evaluasi Tujuan T-4: Layanan Fitur *Dual-Store*

Evaluasi T-4 menilai apakah layanan fitur *dual-store* menyajikan *tabular feature* dan *aggregate feature* dengan kontrak yang konsisten antara *training* dan *serving*, serta menyajikan *vector feature* pada indeks terpisah dengan ruang *embedding* yang sama pada kedua fase tersebut. Skenario SK-F-02 memeriksa *serving online feature non-null* pada Valkey melalui `feast/online-serving-check.py` sebagai bukti sisi *online serving* ganda KF-02, sementara kesetaraan nilainya terhadap penyimpanan *offline* ClickHouse bersandar pada proses materialisasi Feast yang menyalin nilai dari penyimpanan *offline* tersebut ke penyimpanan *online* Valkey sehingga keduanya memuat nilai yang sama. Skenario SK-F-04 menjalankan beban pencarian vektor pada Qdrant melalui `load/vector-search-latency.js` untuk membuktikan dukungan *vector embeddings* KF-04. Skenario SK-F-11 membandingkan fitur hasil *batch* dan hasil *stream* pada indikator yang sama melalui `parity/parity-check.sh`

untuk membuktikan pemrosesan ganda KF-11 dengan definisi fitur yang konsisten. Skenario SK-F-02 dan SK-F-11 menelusuri kontrak *tabular feature* dari sisi kebenaran nilai, sedangkan SK-F-04 menegaskan terbentuknya jalur *serving* vektor, sebelum beban tinggi diterapkan.

Kinerja layanan fitur diuji oleh kelompok skenario nonfungsional yang khusus mengukur latensi dan *throughput* jalur *serving*. Skenario SK-N-01 mengukur latensi *feature serving* dan *vector search* dengan k6 melalui `load/feast-online-latency.js` dan SLO Sloth untuk membuktikan KNF-01, dengan sasaran latensi p99 pada orde sub-detik. Skenario SK-N-02 mengukur *throughput* jalur *serving* dan *stream* dengan k6 melalui `load/feast-throughput.js` serta `kafka-producer-perf-test` untuk membuktikan KNF-02, sambil memantau *lag* konsumen pada beban puncak. Kedua skenario tersebut menempatkan *layer* fitur sebagai titik temu seluruh jalur data sehingga kebenaran nilai fitur menjadi prasyarat bagi kualitas layanan yang diukur, sedangkan atribut kualitas lintas komponen ditangani pada T-1.

VI.1.6 Matriks Cakupan dan Uji Penerimaan

Pemetaan antara skenario dan kebutuhan bersifat banyak-ke-banyak, sebab satu skenario kerap menegaskan lebih dari satu kebutuhan dan satu kebutuhan dapat diperkuat oleh beberapa skenario. Sebagai contoh, SK-F-04 yang menguji latensi pencarian vektor sekaligus menegaskan KNF-01, sedangkan SK-N-01 yang mengukur latensi p99 *serving* turut memperkuat KF-04 pada sisi kualitas layanan vektor. Tabel VI.1 merangkum prosedur uji dan kriteria penerimaan untuk setiap skenario yang dikelompokkan di bawah tujuan T-1 sampai T-4. Susunan tersebut memastikan seluruh empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional memiliki sekurang-kurangnya satu skenario uji yang konkret. Katalog perintah yang dapat dijalankan ulang untuk setiap skenario, termasuk langkah persiapan pemuatan konfigurasi `config.crypto.env` dan pembuatan *namespace* `platform-test`, dirangkum pada Lampiran B sehingga setiap baris Tabel VI.1 dapat ditelusuri ke perintah konkret yang menghasilkan buktinya.

Tabel VI.1 Skenario Uji Penerimaan per Tujuan Platform

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
Tujuan T-1: arsitektur platform terintegrasi dan praktik GitOps			

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-01	KF-01	Mengubah definisi <i>feature view</i> pada repositori Gitea lalu mengamati rekonsiliasi Argo CD, kemudian memverifikasi <i>feast feature-views list</i> .	<i>Feature view</i> baru aktif tanpa intervensi manual dan perubahan terlacak pada riwayat Git.
SK-F-06	KF-06	Mempromosikan model melalui Argo Rollouts dengan strategi <i>canary</i> , lalu menyuntikkan model bermasalah untuk memicu <i>rollback</i> .	Model valid dipromosikan dan model bermasalah memicu <i>rollback</i> otomatis tanpa kehilangan permintaan.
SK-F-12	KF-12	Mengubah jumlah <i>replica</i> pada manifest YAML di Gitea, lalu mengamati rekonsiliasi Argo CD.	Status <i>cluster</i> konvergen ke definisi Git dan tidak menyisakan <i>drift</i> .
SK-F-13	KF-13	Menjalankan <i>notebook</i> satu <i>environment</i> yang memuat SDK Feast, MLflow, dan klien <i>inference</i> KServe v2, lalu mengamati ketiganya sebagai operasi baca independen.	Ketiga klien termuat dan berjalan dari satu <i>environment</i> tanpa konfigurasi tambahan per layanan.
SK-F-14	KF-14	Mengirim sejumlah <i>training job</i> melebihi kuota <i>ClusterQueue</i> Kueue, lalu mengamati status admisi.	<i>Job</i> di luar anggaran kuota berstatus <i>Pending</i> . Admisi mengikuti <i>nominalQuota</i> dan <i>borrowingLimit</i> .
SK-N-03	KNF-03	Menaikkan beban dengan <code>load/hpa-keda-rampup.js</code> sambil mengamati HPA, KEDA <i>ScaledObject</i> , dan jumlah <i>pod</i> .	Jumlah <i>replica</i> naik mengikuti beban dan <i>throughput</i> bertambah mendekati linear.
SK-N-04	KNF-04	Menyuntikkan <i>fault</i> dengan Chaos Mesh (<i>pod-chaos</i> dan <i>network-chaos</i>) lalu mengamati pemulihan.	Beban kerja pulih otomatis dengan RTO dan RPO di bawah ambang yang ditetapkan.
SK-N-08	KNF-08	Mengganti satu komponen (misalnya <i>seerving runtime</i>) melalui antarmuka CRD dan <i>overlay</i> Kustomize.	Penggantian terisolasi pada antarmuka tanpa mengubah komponen lain.
SK-N-09	KNF-09	Mengakses seluruh konsol platform melalui satu sesi identitas dex serta memeriksa ketersediaan dokumentasi operasional pada repositori Gitea.	Seluruh konsol dapat dicapai melalui satu jalur autentikasi tanpa login ulang dan dokumentasi prosedur inti tersedia.
SK-N-10	KNF-10	Mengukur rasio kompresi ClickHouse, utilisasi sumber daya, dan atribusi biaya <i>workload</i> pada OpenCost.	Rasio kompresi dan utilisasi memenuhi target serta biaya per <i>workload</i> dapat diatribusikan.

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-N-11	KNF-11	Menerapkan ulang seluruh manifes GitOps pada <i>node</i> k3s baru dari satu sumber Git.	Seluruh komponen terekonstruksi tanpa intervensi manual selain <i>bootstrap</i> Argo CD.
SK-N-12	KNF-12	Menjalankan <code>make usecase-crypto-test</code> untuk cakupan uji dan <code>make phase-full</code> pada <i>cluster</i> bersih sambil mengukur waktu konvergensi.	Cakupan uji melewati ambang yang ditetapkan dan <code>phase-full</code> konvergen tanpa langkah manual.
Tujuan T-2: sub-sistem tata kelola data			
SK-F-08	KF-08	Menelusuri <i>lineage</i> pada DataHub dari <i>topic</i> sumber hingga keluaran prediksi melalui antarmuka katalog.	Rantai <i>lineage</i> utuh dari sumber data sampai prediksi tersaji pada satu graf metadata.
SK-F-09	KF-09	Menjalankan dua <i>training run</i> lalu mencatatnya pada MLflow, kemudian memutar ulang <i>run</i> dari <i>snapshot</i> data dan parameter tercatat.	<i>Run</i> tercatat lengkap dan pemutaran ulang menghasilkan selisih metrik di bawah satu persen.
SK-F-10	KF-10	Memindahkan model melalui status <i>none</i> , <i>staging</i> , <i>production</i> , dan <i>archived</i> pada registri MLflow.	Transisi mengikuti aturan yang ditetapkan dan <i>audit trail</i> terekam lengkap.
SK-N-05	KNF-05	Menjalankan <i>checkpoint</i> Great Expectations pada <i>batch</i> data, lalu menyuntikkan pelanggaran skema, rentang nilai, dan kelengkapan untuk menguji penegakan kontrak.	Setiap pelanggaran kontrak kualitas terdeteksi dan <i>batch</i> cacat ditolak sebelum masuk <i>layer</i> hilir.
SK-N-06	KNF-06	Menelusuri satu <i>trace</i> OpenTelemetry pada Grafana Tempo dari <i>ingestion</i> hingga prediksi.	Satu <i>trace</i> menautkan lintasan kritis dan metrik, log, serta <i>trace</i> dapat dirujuk silang.
SK-N-07	KNF-07	Memindai <i>cluster</i> dengan Trivy dan memeriksa konfigurasi TLS pada <i>endpoint</i> layanan.	TLS 1.3 <i>in transit</i> dan AES-256 <i>at rest</i> terverifikasi tanpa kerentanan kritis terbuka.
Tujuan T-3: deteksi <i>drift</i> dan <i>retraining</i>			
SK-F-03	KF-03	Mengaudit <code>get_historical_features</code> pada <i>training dataset</i> untuk memastikan jendela <i>point-in-time</i> dipatuhi.	Tidak ada baris yang memakai informasi setelah <i>event timestamp</i> acuan.
SK-F-05	KF-05	Menjalankan <i>training pipeline</i> pada KubeFlow Pipelines yang membaca fitur dari tabel <i>gold</i> dan menulis model ke MLflow.	<i>Pipeline</i> berjalan dari ujung ke ujung dan model tercatat sebagai artefak <i>run</i> pada MLflow yang dapat disajikan KServe.

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-07	KF-07	Menyuntikkan <i>drift</i> terkendali pada satu fitur data nyata, lalu mengamati detektor <i>drift</i> dan <i>CronWorkflow retrain-on-drift</i> .	<i>Drift</i> terdeteksi saat ambang PSI atau KS terlampaui dan <i>retraining pipeline</i> terpicu otomatis.
Tujuan T-4: layanan fitur <i>dual-store</i>			
SK-F-02	KF-02	Memeriksa <i>online feature serving</i> pada Valkey mengembalikan nilai non-null melalui <code>online-serving-check.py</code> .	<i>Online serving</i> mengembalikan nilai non-null dan kesetaraan nilai <i>online</i> dan <i>offline</i> terpenuhi secara struktural melalui materialisasi.
SK-F-04	KF-04	Menjalankan beban pencarian vektor pada Qdrant melalui <code>load/vector-search-latency.js</code> dengan k6.	Latensi pencarian vektor berada pada orde sub-detik. Pengujian <i>recall</i> dilakukan saat koleksi vektor terisi.
SK-F-11	KF-11	Membandingkan fitur hasil <i>batch</i> (dbt) dan hasil <i>stream</i> (Flink) untuk indikator yang sama.	Nilai fitur <i>batch</i> dan <i>stream</i> setara dalam toleransi yang ditetapkan.
SK-N-01	KNF-01	Menjalankan <code>load/feast-online-latency.js</code> dan beban pencarian vektor dengan k6 sambil memantau SLO Sloth.	Latensi p99 berada pada orde sub-detik pada <i>feature serving</i> dan <i>vector search</i> .
SK-N-02	KNF-02	Menjalankan <code>load/feast-throughput.js</code> untuk <i>serving</i> dan <code>kafka-producer-perf-test</code> untuk <i>stream</i> , sambil memantau <i>lag</i> .	<i>Throughput</i> mencapai target dan <i>lag</i> konsumen tetap terkendali pada beban puncak.

Kelengkapan matriks diperiksa dengan menelusuri setiap kebutuhan pada Tabel III.1 dan Tabel III.2 ke sekurang-kurangnya satu baris skenario. Pemeriksaan berjalan dua arah, yaitu dari kebutuhan ke skenario untuk memastikan cakupan dan dari skenario ke kebutuhan untuk memastikan setiap uji memiliki sasaran yang jelas. Skenario yang menegaskan lebih dari satu kebutuhan dicatat pada semua kebutuhan terkait agar redundansi verifikasi terlihat. Hasil penelusuran itulah yang dirangkum sebagai status per kebutuhan pada Tabel VI.2.

VI.2 Hasil Evaluasi

Hasil evaluasi dilaporkan sebagai uji penerimaan fungsional dan struktural pada lingkungan *node* tunggal sesuai batasan BI-1. Status setiap kebutuhan dinyatakan dalam tiga tingkat, yaitu terverifikasi struktural ketika jalur kendali terbentuk dan terekonsiliasi sesuai rancangan, terverifikasi fungsional ketika skenario uji dijalankan dan keluarannya memenuhi kriteria penerimaan, serta terinstrumentasi ketika instrumen

ukur telah terpasang dan jalur melayani permintaan sementara profil beban kuantitatif penuh berada pada lingkup pengembangan lanjutan. Pembagian tiga tingkat ini menjaga agar setiap klaim sepadan dengan bukti yang tersedia dan tidak melampaui hasil yang benar-benar diamati. Tabel VI.2 merangkum target, instrumen ukur, dan status setiap kebutuhan, sedangkan karakterisasi beban kuantitatif pada kluster multi-*node*, seperti distribusi latensi p99 dan *throughput* puncak, dirinci sebagai arah pengembangan pada Bab VII.

Pada T-1, verifikasi struktural menunjukkan seluruh komponen berhasil dipasang dan direkonsiliasi oleh Argo CD dari satu repositori Gitea, perubahan *replica* dan definisi fitur konvergen tanpa *drift*, dan rekonstruksi pada *node* k3s baru berhasil tanpa intervensi manual selain *bootstrap* awal. Dengan jalur *training pipeline* (KF-05) dan *deployment* model (KF-06) terbentuk secara struktural serta jalur deteksi *drift* pemicu *retraining* (KF-07) terverifikasi fungsional, komponen yang dipersyaratkan untuk MLOps *level 2* pada Subbab II.1.3 terpenuhi pada lingkungan implementasi. Pada T-2, peristiwa *lineage* dari *emitter* OpenLineage Airflow dan Spark serta konektor *ingestion* DataHub untuk Feast, MLflow, ClickHouse, dan Kafka muncul pada satu graf metadata dengan kosakata seragam, registri MLflow menyediakan jalur transisi status model sebagai prosedur, dan kontrol keamanan mTLS serta enkripsi *at rest* aktif sesuai konfigurasi. Praktik yang sama menempatkan sisi data pada tahap DataOps dalam model evolusi Subbab II.1.3, karena CI/CD, orkestrasi, pengujian kualitas, dan pemantauan terverifikasi berlaku pada *pipeline* data. Pada T-3, *control loop retraining* terpicu otomatis ketika injeksi *drift* terkendali diterapkan pada satu fitur, sehingga rantai deteksi hingga pemicuan *retraining* terbukti berfungsi pada jalur kendali. Pada T-4, jalur *serving* untuk *online feature*, *offline feature*, dan *vector feature* berhasil dibentuk dan melayani permintaan, sementara karakterisasi latensi p99 dan *throughput* pada beban tinggi dirinci sebagai arah pengembangan pada kluster multi-*node* di Bab VII.

Beberapa skenario pada kasus verifikasi menghasilkan keluaran kuantitatif yang dapat dijalankan ulang melalui katalog perintah pada Lampiran B, sebelum status ringkas setiap kebutuhan dirangkum pada Tabel VI.2. Skenario yang dilaporkan secara rinci dipilih karena menghasilkan angka yang bermakna pada lingkungan *node* tunggal, sedangkan skenario struktural cukup dilaporkan sebagai status terpenuhi. Angka yang dihasilkan dibaca dalam batasan BP-3 sehingga tidak ditafsirkan sebagai karakterisasi beban penuh. Keluaran tersebut beserta konteks dan batasan penafsirannya dirangkum sebagai berikut.

1. Pemicuan *retraining* oleh deteksi *drift* (KF-07)

Injeksi pergeseran terkendali sebesar dua sigma pada fitur `return_24h` menghasilkan *Population Stability Index* sebesar 18,107 yang jauh melampaui ambang 0,2 dan statistik Kolmogorov-Smirnov sebesar 0,815 di atas ambang 0,15, sehingga detektor menandai *drift* dan memicu satu eksekusi *CronWorkflow* *retrain-on-drift*. Angka ini berasal dari injeksi terkendali pada aliran tervalidasi melalui `experiments/drift/inject_drift.py --sigma 2.0`, sehingga membuktikan terpicunya rantai *retraining* dan bukan ketepatan deteksi terhadap pergeseran distribusi alami berdurasi panjang.

2. *Landing data nyata pada medallion layer*

Pemeriksaan *landing* melaporkan sekitar 307.556 baris pada `bronze.crypto_ohlcv` dan `silver.stg_ohlcv` serta sekitar 307.522 baris pada `gold.fct_ohlcv_features` dan `gold.fct_training_data`, mencakup dua pasangan instrumen pada jendela 1 Maret sampai 16 Juni 2026 dengan resolusi satu menit. Data ini menjadi dasar skenario yang membaca *gold layer* seperti penyusunan fitur historis (KF-03) dan otomasi pelatihan (KF-05), dijalankan melalui `experiments/etl/data-landed-check.sh` pada jalur *batch* REST yang masih terus bertambah. Pemeriksaan ini menilai *landing batch* dan bukan paritas fitur *batch* dan *stream* (KF-11).

3. *Keterhubungan lineage (KF-08)*

Penelusuran graf metadata DataHub menemukan 270 *dataset*, 18 *DataJob*, dan 3 *DataFlow* yang saling terhubung dari *topic* sumber sampai keluaran prediksi, dijalankan melalui `experiments/lineage/lineage-walk.sh discover`. Cakupan graf ditentukan oleh *namespace* OpenLineage yang dipakai *emitter*, sehingga angka ini mengukur keterhubungan *lineage* yang ter-kirim dan terkatalog, bukan kelengkapan seluruh aset lintas *namespace*.

4. *Serving pencarian vektor (KF-04)*

Beban pencarian vektor pada Qdrant mencatat latensi p50 sebesar 4,25 ms dan p95 sebesar 5,02 ms pada 100 iterasi, dijalankan melalui `k6 run experiments/load/vector-search-latency.js`. Pengukuran ini menegaskan jalur pencarian vektor terpasang dan melayani permintaan pada orde milidetik, bukan kualitas *recall* karena koleksi uji masih kosong, sedangkan nilai p99 sebesar 157 ms merupakan artefak fase penurunan beban dan bukan latensi *steady-state*.

Tabel VI.2 Target Metrik, Instrumen Ukur, dan Status Evaluasi per Kebutuhan

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
Kebutuhan Fungsional			

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-01	<i>Feature view</i> berversi dan rekonsiliasi otomatis	Feast <i>registry</i> , Argo CD, Gitea	Terverifikasi struktural. Rekonsiliasi Argo CD konvergen dan definisi <i>feature view</i> tanpa <i>drift</i> .
KF-02	Konsistensi nilai <i>online</i> dan <i>offline</i>	Feast SDK, materialisasi	Terverifikasi struktural. Nilai <i>online</i> dan <i>offline</i> sama melalui materialisasi Feast.
KF-03	<i>Zero leakage</i> pada <i>point-in-time join</i>	Feast PIT, probe <i>leakage</i>	Terverifikasi struktural. Probe <i>timestamp</i> masa depan menolak baris bocor.
KF-04	Pencarian vektor HNSW berfungsi, latensi sub-detik	Qdrant, k6	Terinstrumentasi. Latensi p50 4,25 ms dan p95 5,02 ms pada 100 iterasi. <i>Recall</i> belum diuji karena koleksi kosong.
KF-05	<i>Pipeline end-to-end</i> , run tercatat di MLflow	Kubeflow Pipelines, MLflow	Terverifikasi struktural. <i>Pipeline</i> Kubeflow merangkai deteksi <i>drift</i> , pelatihan dari tabel <i>gold</i> , dan <i>deploy</i> ke KServe. Definisinya terkompilasi dan terdaftar pada KFP dengan jalur pencatatan ke MLflow.
KF-06	Promosi <i>canary</i> dan <i>rollback</i> otomatis	KServe, Argo Rollouts, Prometheus	Terverifikasi struktural. <i>Rollout canary</i> dan <i>rollback</i> otomatis terbentuk.
KF-07	<i>Drift</i> memicu <i>retraining</i>	<i>drift-detector</i> , Argo CronWorkflow	Terverifikasi fungsional. PSI 18,107 dan KS 0,815 melampaui ambang sehingga <i>retraining</i> terpicu.
KF-08	<i>Lineage</i> data ke fitur ke model utuh	DataHub, OpenLineage	Terverifikasi struktural. Terhubung 270 <i>dataset</i> , 18 <i>DataJob</i> , dan 3 <i>DataFlow</i> .
KF-09	<i>Run</i> dapat direproduksi, selisih ulang kecil	MLflow	Terverifikasi struktural. Seed tetap (42), pelacakan MLflow, dan jendela tanggal terparameter memungkinkan <i>run</i> direproduksi dari <i>snapshot</i> .
KF-10	Transisi status dan <i>audit trail</i>	MLflow Tracking dan Model Registry	Terverifikasi struktural. Transisi status pada <i>Model Registry</i> tersedia sebagai prosedur dan belum dijalankan otomatis oleh <i>trainer</i> . MLflow Tracking merekam parameter, metrik, dan artefak tiap <i>run</i> sebagai jejak audit.

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-11	Paritas fitur <i>batch</i> dan <i>stream</i>	dbt, Flink	Terverifikasi struktural. Definisi fitur <i>batch</i> dan <i>stream</i> konsisten.
KF-12	Konvergensi deklaratif tanpa <i>drift</i>	Kustomize, Argo CD, Gitea	Terverifikasi struktural. Hasil <code>argocd diff</code> bersih dan konvergen tanpa <i>drift</i> .
KF-13	SDK Feast, MLflow, dan klien KServe v2 termuat dalam satu <i>environment uv</i>	<i>Notebook uv run</i> , <i>pyproject</i>	Terverifikasi struktural. <i>Notebook unified_sdk_walkthrough</i> memuat ketiga klien dalam satu <i>environment uv</i> lalu menjalankannya sebagai operasi baca independen.
KF-14	<i>Job</i> luar kuota <i>Pending</i> , admisi sesuai	Kueue <i>ClusterQueue</i> , HPA, VPA, KEDA	Terverifikasi struktural. <i>Job</i> di luar kuota berstatus <i>Pending</i> sesuai admisi Kueue.
Kebutuhan Nonfungsional			
KNF-01	Latensi p99 sub-detik <i>feature serving</i> dan <i>vector search</i>	k6, SLO Sloth	Terinstrumentasi. Jalur <i>feature serving</i> dan <i>vector search</i> terukur. Nilai p99 pada beban tinggi belum diukur.
KNF-02	<i>Throughput</i> jalur <i>serving</i> dan <i>stream</i> tinggi	k6, kafka-producer-perf-test, KEDA	Terinstrumentasi. Instrumen beban k6 dan KEDA terpasang. <i>Throughput</i> puncak belum diukur.
KNF-03	<i>Replica</i> dan <i>throughput</i> naik mendekati linear	HPA, KEDA, k6	Terinstrumentasi. HPA dan KEDA aktif pada satu <i>node</i> . Skala mendekati linear belum diuji pada multi- <i>node</i> .
KNF-04	Pemulihan otomatis, RTO dan RPO terjaga	Chaos Mesh, Velero, Sloth	Terverifikasi struktural. Jalur pemulihan otomatis Chaos Mesh dan Velero terbentuk.
KNF-05	Kontrak skema, rentang, dan kelengkapan ditegakkan	Great Expectations	Terverifikasi fungsional. <i>Checkpoint</i> Great Expectations menolak pelanggaran skema dan rentang.
KNF-06	Metrik, log, dan <i>trace</i> dirujuk silang	Prometheus, Loki, Tempo, OTel	Terverifikasi struktural. Metrik, log, dan <i>trace</i> OTel saling dirujuk melalui konteks <i>trace</i> lintas Prometheus, Loki, dan Tempo.
KNF-07	TLS 1.3, AES-256, dan <i>audit log</i> aktif	Istio mTLS, KES, OpenBao, Trivy	Terverifikasi struktural. Enkripsi mTLS Istio dan enkripsi <i>at rest</i> aktif sesuai konfigurasi.

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KNF-08	Penggantian komponen terisolasi	CRD, Helm, Kustomize	Terverifikasi struktural. Penggantian komponen melalui CRD dan <i>overlay</i> terisolasi.
KNF-09	SSO satu sesi tanpa login ulang, dokumentasi tersedia	dex, oauth2-proxy, Gitea	Terverifikasi struktural. Konsol terhubung pada satu sesi identitas dex dan oauth2-proxy.
KNF-10	Kompresi, utilisasi, dan atribusi biaya	OpenCost, ClickHouse	Terinstrumentasi. OpenCost dan kompresi kolumnar ClickHouse terpasang. Rasio dan atribusi biaya belum diukur penuh.
KNF-11	Rekonstruksi penuh dari Git	Argo CD, Kustomize	Terverifikasi struktural. Rekonstruksi penuh pada <i>node</i> k3s baru dari satu sumber Git.
KNF-12	Cakupan uji dan <i>phase-full</i> konvergen	Tekton CI, Argo CD	Terverifikasi struktural. <i>make phase-full</i> konvergen dan uji CI Tekton berjalan.

VI.3 Perbandingan Biaya Infrastruktur dan Tenaga Kerja

Analisis pada Subbab III.1.2 menempatkan biaya berlangganan layanan terkelola sebagai salah satu tekanan utama yang melatarbelakangi platform ini, sehingga evaluasi ditutup dengan membandingkan biaya infrastruktur bulanan tiga skenario *hosting* pada kapasitas komputasi yang setara, beserta perkiraan biaya tenaga kerja pengelolanya. Karena batasan BI-1 tidak mengikat spesifikasi perangkat keras tertentu, perbandingan memakai konfigurasi acuan 16 vCPU, memori 64 GB, dan penyimpanan sekitar 400 GB yang mencukupi seluruh komponen platform pada satu *node*. Implementasi penelitian ini sendiri berjalan pada VPS yang disediakan institusi tanpa biaya sewa langsung, sehingga skenario pertama memakai harga daftar publik enam penyedia VPS sebagai acuan pasar pada spesifikasi yang setara. Skenario pertama menyewa satu *virtual private server* dari salah satu penyedia tersebut dan menjalankan seluruh komponen *open source* seperti pada implementasi ini, skenario kedua memindahkan pola yang sama ke kluster GKE pada Google Cloud, dan skenario ketiga menambah penggantian empat komponen *stateful*, yaitu PostgreSQL, Valkey, Kafka, dan penyimpanan objek, dengan layanan terkelola Google Cloud. Seluruh angka pada Tabel VI.3 merupakan harga daftar publik per 16 Juni 2026, dengan baris Google Cloud pada *region* us-central1 dan konversi 730 jam per bulan, tanpa diskon komitmen, biaya trafik keluar, maupun biaya dukungan.

Tabel VI.3 memperlihatkan selisih biaya yang berarti antar skenario pada kapasitas

Tabel VI.3 Perbandingan Biaya Bulanan Infrastruktur per 16 Juni 2026

Komponen	Konfigurasi	Biaya per Bulan	Sumber
Skenario A: VPS tunggal, seluruh komponen <i>open source</i> (alternatif penyedia)			
Contabo Cloud VPS 50	16 vCPU <i>shared</i> , 64 GB, NVMe 300 GB	EUR 37,00	(Contabo GmbH 2026)
Hetzner CCX43	16 vCPU <i>dedicated</i> AMD, 64 GB, SSD 360 GB	EUR 275,99	(Hetzner Online GmbH 2026)
OVHcloud B3-64	16 vCore <i>dedicated</i> , 64 GB, NVMe 400 GB	USD 352,52	(OVHcloud 2026)
Akamai Linode 64 GB	16 vCPU <i>shared</i> , 64 GB, SSD 1.280 GB	USD 384,00	(Akamai Technologies 2026)
Vultr Optimized Cloud Compute	16 vCPU <i>dedicated</i> , 64 GB, NVMe 320 GB	USD 480,00	(Vultr 2026)
DigitalOcean General Purpose	16 vCPU <i>dedicated</i> , 64 GB, SSD 200 GB dan <i>volume</i> 200 GB	USD 524,00	(DigitalOcean 2026)
<i>Rentang Skenario A, satu penyedia dipilih</i>		USD 43 sampai 524	
Skenario B: GKE dengan komponen <i>open source</i> yang sama			
Biaya pengelolaan kluster GKE	Satu kluster <i>Standard</i>	USD 73,00	(Google Cloud 2026d)
Node Compute Engine	e2-standard-16, 16 vCPU, 64 GB	USD 391,35	(Google Cloud 2026c)
<i>Persistent disk</i> pd-balanced	400 GB	USD 40,00	(Google Cloud 2026g)
<i>Subtotal Skenario B</i>		USD 504,35	
Skenario C: Skenario B ditambah layanan terkelola pengganti komponen <i>stateful</i>			
Cloud SQL for PostgreSQL	4 vCPU, 16 GB, tanpa <i>high availability</i>	USD 202,36	(Google Cloud 2026a)
Memorystore for Redis	<i>Basic tier</i> , 5 GB	USD 98,55	(Google Cloud 2026f)
Managed Service for Apache Kafka	Minimum 3 vCPU pada 3 <i>broker</i>	USD 197,10	(Google Cloud 2026e)
Cloud Storage <i>Standard</i>	100 GB	USD 2,00	(Google Cloud 2026b)
<i>Total Skenario C</i>		USD 1.004,36	

Harga daftar publik per 16 Juni 2026 yang diverifikasi melalui arsip halaman harga resmi tiap penyedia. Baris Google Cloud memakai *region* us-central1 dengan konversi 730 jam per bulan, seluruhnya tanpa diskon komitmen, trafik keluar, dan biaya dukungan. Harga Vultr dan *block storage* DigitalOcean memakai harga daftar Juli 2026 karena arsip halamannya tidak memuat angka harga. Harga Contabo tercantum termasuk pajak pada halaman resminya, sedangkan harga penyedia lain belum memuat pajak. Biaya bulanan OVHcloud dihitung dari tarif USD 0,4829 per jam, dan biaya DigitalOcean sudah mencakup *block storage* 200 GB agar kapasitas penyimpanan setara. Biaya Cloud SQL dan Managed Service for Apache Kafka mencakup komputasi saja. Dengan kurs referensi ECB 1,1594 USD per EUR pada 16 Juni 2026 (European Central Bank 2026), harga Contabo setara sekitar USD 43 dan Hetzner sekitar USD 320.

yang sama. Menjalankan seluruh komponen pada satu VPS berbiaya sekitar USD 43 sampai USD 524 per bulan, dengan batas bawah pada penyedia dengan vCPU *shared* dan kisaran USD 320 sampai USD 524 pada penyedia dengan vCPU *dedi-*

cated. Memindahkan pola yang sama ke GKE berbiaya sekitar USD 504 per bulan, sebanding dengan batas atas kisaran VPS *dedicated*, dan mengganti empat komponen *stateful* dengan layanan terkelola menaikkannya menjadi sekitar USD 1.004 per bulan. Kenaikan pada skenario ketiga terjadi meskipun baru empat dari puluhan komponen platform yang berpindah ke layanan terkelola, sebab komponen lain tetap membutuhkan *node* komputasi yang sama. Hasil ini sejalan dengan karakter pertukaran biaya pada Subbab III.1.2: biaya layanan terkelola tumbuh per komponen dan per pemakaian, sedangkan arsitektur *open source* pada Kubernetes menahan biaya berjalan pada harga sewa kapasitas komputasinya. Angka tersebut bersifat indikatif pada tingkat orde besaran karena harga daftar dapat berubah, seperti penyesuaian harga Hetzner yang berlaku sejak 15 Juni 2026 (Hetzner Online GmbH 2026), perlakuan pajak antar penyedia berbeda, dan kebutuhan produksi nyata menambah biaya penyimpanan, trafik, serta ketersediaan tinggi pada ketiga skenario.

Perbandingan di atas belum mencakup biaya tenaga kerja yang menyertai kedua pola pengelolaan, padahal pertukaran antara waktu rekayasa dan biaya berlangganan telah diidentifikasi pada Subbab III.1.2. Sebagai acuan dipakai gaji IDR 15.000.000 per bulan dari batas atas kisaran *Data Engineer* pada panduan gaji PERSOLKELLY Indonesia (PERSOLKELLY Indonesia 2023), setara sekitar USD 847 pada kurs referensi JISDOR 15 Juni 2026 (Bank Indonesia 2026). Profil alokasi tenaga pada Tabel VI.4 merupakan asumsi ilustratif: pembangunan awal dari nol menuntut alokasi penuh pada bulan pertama, lalu menurun pada bulan berikutnya karena rekonsiliasi GitOps, pemantauan terpadu, dan *retraining* otomatis mengambil alih pekerjaan operasional harian (Limoncelli 2018). Skenario layanan terkelola diberi alokasi lebih rendah karena tanggung jawab operasional komponen *stateful* berpindah ke penyedia, meskipun konfigurasi awal dan integrasi tetap membutuhkan tenaga (Shankar dkk. 2022).

Tabel VI.4 memperlihatkan bahwa struktur biaya kedua pola berbeda arah. Pada tahun pertama, skenario VPS dengan seluruh komponen *open source* menghabiskan sekitar USD 8.170 dengan porsi tenaga kerja hampir dua perlima, sedangkan skenario layanan terkelola menghabiskan sekitar USD 13.407 dengan porsi tenaga kerja sekitar sepersepuluh. Selisih biaya infrastruktur kedua skenario sekitar USD 588 per bulan setara dengan 0,7 bulan kerja *engineer* pada gaji acuan, sehingga penghematan alokasi yang diasumsikan sebesar 0,15 FTE per bulan tidak mengimbangnya, dan titik impas baru tercapai bila gaji *engineer* melebihi sekitar IDR 69 juta per bulan atau penghematan tenaganya jauh lebih besar. Karena angka alokasi merupakan asumsi, hasil ini dibaca sebagai arah struktur biaya, yaitu pola *open source*

Tabel VI.4 Ilustrasi Biaya Infrastruktur dan Tenaga Kerja Tiga Tahun per 16 Juni 2026


Komponen Biaya	Skenario A (VPS)	Skenario B (GKE)	Skenario C (Terkelola)
Infrastruktur per bulan	USD 416,26	USD 504,35	USD 1.004,36
Infrastruktur 12 bulan	USD 4.995,12	USD 6.052,20	USD 12.052,32
Alokasi tenaga bulan pertama	1,0 FTE	1,0 FTE	0,5 FTE
Alokasi tenaga bulan kedua sampai kedua belas	0,25 FTE per bulan	0,25 FTE per bulan	0,1 FTE per bulan
Biaya tenaga 12 bulan	USD 3.174,56	USD 3.174,56	USD 1.354,48
Total tahun pertama	USD 8.169,68	USD 9.226,76	USD 13.406,80
Biaya per tahun sesudah tahun pertama	USD 7.534,77	USD 8.591,85	USD 13.068,18
Total tiga tahun	USD 23.239,22	USD 26.410,46	USD 39.543,16

Alokasi tenaga merupakan asumsi ilustratif untuk memperlihatkan struktur biaya, bukan hasil pengukuran. Satu FTE (*full-time equivalent*) berarti alokasi penuh satu *engineer* selama satu bulan. Infrastruktur Skenario A memakai median empat penyedia vCPU *dedicated* pada Tabel VI.3, yaitu USD 416,26 per bulan. Biaya tenaga memakai gaji acuan IDR 15.000.000 per bulan dari batas atas kisaran *Data Engineer* pada panduan gaji PERSOLKELLY Indonesia (PERSOLKELLY Indonesia 2023), setara USD 846,55 pada kurs referensi JISDOR IDR 17.719 per USD tanggal 15 Juni 2026, hari penerbitan terakhir sebelum 16 Juni yang merupakan libur nasional (Bank Indonesia 2026). Tahun kedua dan ketiga memakai alokasi tetap 0,25 FTE per bulan pada Skenario A dan B serta 0,1 FTE per bulan pada Skenario C, dengan harga daftar dianggap tetap.

memindahkan pengeluaran dari langganan ke tenaga kerja yang menurun setelah pembangunan awal, bukan sebagai pengukuran empiris.

Gambar VI.1 memproyeksikan biaya kumulatif tiga tahun pertama dari asumsi yang sama, dengan alokasi tenaga dan harga daftar dianggap tetap sesudah tahun pertama. Tagihan infrastruktur ketiga skenario tetap setiap bulan, sehingga bentuk kurva ditentukan oleh alokasi tenaga: skenario VPS dan GKE sama-sama terbebani pada bulan pertama oleh alokasi penuh untuk pembangunan awal lalu turun begitu operasi rutin diambil alih otomatis, sedangkan skenario layanan terkelola bergerak paling mendekati linear karena alokasi tenaganya paling kecil. Pada gaji acuan, biaya bulanan skenario VPS bergerak dari sekitar USD 1.263 pada bulan pertama menjadi sekitar USD 628 pada bulan berikutnya, sedangkan layanan terkelola bergerak dari sekitar USD 1.428 menjadi sekitar USD 1.089, sehingga jarak kumulatif keduanya melebar sepanjang tahun. Pola biaya awal yang lebih mahal pada sisi *open source* baru muncul bila gaji *engineer* melebihi sekitar IDR 20,8 juta per bulan, titik ketika biaya bulan pertama skenario VPS mulai melampaui layanan terkelola, meskipun biaya bulanan sesudah pembangunan awal tetap lebih rendah. Pada horizon yang lebih panjang keunggulan itu semakin tegas: selisih kumulatif kedua pola tumbuh dari sekitar USD 5.237 pada akhir tahun pertama menjadi sekitar USD 16.304 pada akhir tahun ketiga, karena setiap tahun berikutnya menambah selisih sekitar USD 5.533, sehingga pola *open source* makin murah dalam jangka panjang selama asumsi

alokasi tenaganya bertahan.



Gambar VI.1 Proyeksi Biaya Kumulatif Tiga Tahun Tiga Skenario

VI.4 Pembahasan Hasil Evaluasi

Pembahasan mengaitkan setiap hasil dengan tujuan yang dijawab dan dengan rumusan masalah yang menjadi titik awal. Verifikasi struktural pada T-1 menjawab RM-1 dengan menunjukkan bahwa fragmentasi *tech stack* dapat diganti oleh satu *control plane* GitOps yang dapat direkonstruksi. Verifikasi pada T-2 menjawab RM-2 dengan menunjukkan tata kelola berjalan sebagai layanan bersama, bukan pekerjaan susulan, sehingga *lineage* dan kontrak kualitas tertanam pada *pipeline*. Verifikasi pada T-3 menjawab RM-3 dengan menunjukkan bahwa deteksi *drift* memicu *retraining* secara otomatis pada jalur kendali, sehingga jawaban atas RM-3 terpenuhi pada tingkat fungsional dan struktural. Verifikasi pada T-4 menjawab RM-4 dengan menunjukkan bahwa layanan fitur *dual-store* terbentuk dan melayani permintaan dengan kontrak fitur yang konsisten, sehingga jawaban atas RM-4 terpenuhi pada tingkat struktural dengan jalur *serving* yang telah terinstrumentasi, sedangkan karakteristik beban kuantitatifnya menjadi arah pengembangan.

Cakupan evaluasi telah memenuhi syarat ketertelusuran, karena seluruh empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional memiliki sekurang-kurangnya satu skenario uji pada Tabel VI.1 dan satu baris status pada Tabel VI.2. Pemetaan banyak-ke-banyak memperkuat keyakinan karena beberapa kebutuhan kritis, seperti KNF-01 dan KF-04, ditegaskan oleh lebih dari satu skenario. Dengan demikian, kegagalan pada satu skenario tidak langsung membatalkan klaim pemenuhan kebutuhan terkait, melainkan menyisakan jalur verifikasi lain yang ma-

sih dapat ditelusuri. Susunan ini sekaligus menyiapkan struktur kesimpulan pada Bab VII yang menjawab tepat satu tujuan untuk setiap butir. Meskipun demikian, evaluasi ini memiliki tiga keterbatasan yang perlu dicatat secara terbuka.

1. Lingkungan pengujian *node* tunggal

Lingkungan pengujian adalah k3s *node* tunggal sesuai batasan BI-1, sehingga klaim skalabilitas horizontal diukur melalui *multi-replica* dan *autoscaling* pada satu *node*, bukan pada kluster multi-*node*.

2. Verifikasi *drift* melalui injeksi terkendali

Deteksi *drift* diverifikasi melalui injeksi *drift* terkendali pada data nyata sehingga ketepatan terhadap pergeseran distribusi alami berdurasi panjang masih perlu diamati lebih lama, sedangkan karakterisasi beban penuh seperti latensi p99 dan *throughput* puncak menjadi arah pengembangan pada lingkungan multi-*node*.

3. Verifikasi kesetaraan nilai fitur *dual-store*

Kesetaraan nilai fitur antara penyimpanan *online* Valkey dan *offline* ClickHouse pada KF-02 bersifat *structural-by-construction* karena proses materialisasi Feast menyalin nilai dari penyimpanan *offline* ke penyimpanan *online* sehingga keduanya memuat nilai yang sama, sedangkan uji pembandingan nilai eksplisit per entitas melalui SDK Feast masih berupa prosedur manual yang belum terotomasi pada jalur evaluasi, sehingga KF-02 dilaporkan pada tingkat struktural dan penegasan fungsionalnya menjadi tindak lanjut.

Ketiga keterbatasan tersebut menjadi dasar saran tindak lanjut pada Bab VII. Keterbatasan pertama dan kedua mengarah pada pengujian beban serta pengamatan *drift* berdurasi panjang pada lingkungan multi-*node*. Keterbatasan ketiga mengarah pada otomasi uji kesetaraan nilai fitur per entitas pada jalur evaluasi. Dengan pemetaan ini, setiap keterbatasan memiliki tindak lanjut yang jelas dan tidak ada klaim yang dibiarkan tanpa batas penafsiran.

BAB VII

PENUTUP

Bab ini merangkum capaian penelitian dan menutup rantai keterhubungan yang dijaga sejak rumusan masalah. Setiap butir kesimpulan menjawab tepat satu tujuan T-1 sampai T-4 dengan urutan yang sama, sehingga setiap klaim dapat ditelusuri kembali ke tujuan, kebutuhan, dan skenario uji yang sesuai. Kesimpulan disusun pada tingkat capaian yang telah terverifikasi secara fungsional dan struktural pada lingkungan *node* tunggal, sedangkan karakterisasi beban kuantitatif pada kluster multi-*node* ditempatkan sebagai arah pengembangan sesuai lingkup batasan BP-3 pada Subbab I.4. Saran kemudian mengarahkan langkah lanjutan untuk memperluas karakterisasi beban dan untuk mengembangkan platform pada tahap berikutnya.

VII.1 Kesimpulan

Penelitian ini menghasilkan satu implementasi arsitektur DataOps dan MLOps terintegrasi pada Kubernetes yang dievaluasi melalui *use case* pasar aset kripto sebagai kasus verifikasi. Verifikasi dilakukan pada lingkungan *k3s node* tunggal dengan penerimaan fungsional dan struktural sesuai batasan BP-3. Setiap butir berikut menjawab tepat satu tujuan dan merujuk bukti evaluasinya pada Bab VI, dengan rincian status tiap kebutuhan dirangkum pada Tabel VI.2. Berdasarkan hasil evaluasi tersebut, empat tujuan platform dapat disimpulkan sebagai berikut.

1. **Arsitektur terintegrasi dan GitOps (T-1)**

Seluruh komponen platform terbukti dapat dipasang dan direkonsiliasi dari satu sumber Git oleh Argo CD, dengan perubahan definisi konvergen tanpa *drift* dan rekonstruksi penuh pada *node k3s* baru tanpa intervensi manual selain *bootstrap* awal. Capaian ini menjawab RM-1 dengan menggantikan fragmentasi *tech stack* dengan satu *control plane* deklaratif yang dapat diaudit.

2. **Tata kelola data otomatis (T-2)**

Katalog metadata, *lineage*, dan kontrol kualitas terbukti berjalan sebagai layanan bersama sepanjang *pipeline* data, fitur, dan model, dengan peristiwa *lineage* OpenLineage dan kontrak Great Expectations tertanam pada jalur produksi. Capaian ini menjawab RM-2 dengan menjadikan tata kelola bagian melekat dari *pipeline*, bukan pekerjaan susulan.

3. **Deteksi *drift* dan *point-in-time correctness* (T-3)**

Control loop retraining terbukti terpicu otomatis ketika injeksi *drift* terkendali

diterapkan pada satu fitur dan penyusunan fitur historis terbukti menolak kebo-
coran temporal pada jalur pelatihan. Capaian ini menjawab RM-3, sedangkan
pengamatan ketepatan deteksi pada pergeseran distribusi alami berdurasi pan-
jang menjadi arah pengembangan lanjutan.

4. Layanan fitur *dual-store* (T-4)

Jalur *serving online* dan *offline* untuk *tabular feature* terbukti terbentuk de-
ngan kontrak fitur yang konsisten antara fase *training* dan fase *inference*, se-
dangkan jalur *vector feature* terbentuk pada indeks terpisah dengan ruang *em-
bedding* yang sama pada kedua fase tersebut. Capaian ini menjawab RM-4
pada tingkat struktural dengan jalur *serving* yang telah terinstrumentasi, se-
dangkan karakterisasi latensi p99 dan *throughput* pada beban tinggi di kluster
multi-*node* menjadi arah pengembangan lanjutan.

Keempat kesimpulan tersebut menegaskan bahwa kontribusi utama penelitian ber-
upa implementasi arsitektur terintegrasi telah tercapai dan tertelusur secara penuh
dari rumusan masalah hingga skenario uji. Pemenuhan yang dilaporkan bersifat
fungsional dan struktural pada lingkungan *node* tunggal, sehingga setiap klaim di-
batasi pada bukti yang telah diamati. Nilai utama implementasi ini terletak pada
penyatuan beban integrasi yang sebelumnya berulang ke dalam satu deskripsi dekla-
ratif, sehingga rekonstruksi *control plane* tidak lagi bergantung pada pengetahuan
tak terdokumentasi satu pengembang. Platform terbukti dapat direkonstruksi, dike-
lola secara deklaratif, dan menjalankan *lifecycle* data serta model secara terotomasi,
sedangkan penilaian kinerja menyeluruh menjadi pekerjaan lanjutan yang terdefini-
si jelas. Di luar keempat tujuan, perbandingan biaya pada Subbab VI.3 memperkuat
motivasi pada Subbab III.1.2, karena skenario *open source* menunjukkan biaya ku-
mulatif tiga tahun yang lebih rendah daripada layanan terkelola.

VII.2 Saran

Berdasarkan capaian dan keterbatasan yang telah diuraikan, penelitian ini mengajuk-
an dua arah tindak lanjut. Arah pertama menuntaskan karakterisasi kuantitatif yang
pada penelitian ini dibatasi oleh lingkungan *node* tunggal. Arah kedua memperluas
kapabilitas platform tanpa mengubah sifat *domain-agnostic control plane*-nya. Ke-
duanya diuraikan sebagai berikut.

1. Perluasan karakterisasi beban kuantitatif

Pengujian beban penuh perlu dijalankan pada lingkungan multi-*node* untuk
memverifikasi skalabilitas horizontal, latensi p99, dan *throughput* puncak
yang pada penelitian ini baru terinstrumentasi di lingkungan *node* tunggal de-
ngan instrumen ukur terpasang dan jalur *serving* yang telah melayani permin-

taan. Pengamatan *drift* juga perlu diperpanjang durasinya pada aliran data nyata agar ketepatan deteksi terhadap pergeseran distribusi alami berdurasi panjang dapat dinilai untuk melengkapi verifikasi melalui injeksi *drift* terkontrol. Selain itu, kesetaraan nilai fitur antara penyimpanan *online* dan *offline* yang pada penelitian ini terpenuhi secara *structural-by-construction* perlu ditegaskan lebih lanjut melalui uji pembandingan nilai per entitas yang terotomasi pada jalur evaluasi.

2. Pengembangan platform pada tahap berikutnya

Beberapa arah yang teridentifikasi mencakup perluasan dukungan *multi-tenancy* pada *layer* tata kelola, otomatisasi kebijakan kuota pada Kueue untuk beban pelatihan yang lebih besar, integrasi metrik biaya OpenCost dengan kebijakan *retraining*, serta adopsi profil keamanan Kyverno yang lebih ketat setelah profil dasar matang. Arah tersebut melanjutkan sifat *domain-agnostic* platform sehingga *use case* lain dapat diadopsi tanpa mengubah *control plane*.

Melalui kedua arah tersebut, platform dapat berkembang dari implementasi yang terverifikasi struktural menjadi fondasi yang teruji pada beban produksi nyata. Prioritas terdekat adalah karakterisasi beban pada kluster *multi-node* karena batasan itulah yang paling membatasi klaim kinerja saat ini. Perluasan kapabilitas dapat menyusul tanpa perombakan karena penggantian komponen telah diakomodasi oleh batasan implementasi BI-2. Dengan demikian, hasil penelitian ini menjadi titik berangkat yang terdokumentasi bagi pengembangan berikutnya.

DAFTAR PUSTAKA

- Adusumilli, Lakshmi Vara Prasad. 2025. “Serverless Kubernetes: The Evolution of Container Orchestration”. *European Journal of Computer Science and Information Technology* 13 (30): 20–36. <https://doi.org/10.37745/ejcsit.2013/vol13n302036>. <https://doi.org/10.37745/ejcsit.2013/vol13n302036>.
- Ahmad, Tazeem, Mohd Adnan, Saima Rafi, Muhammad Azeem Akbar, dan Ayesha Anwar. 2024. “MLOps-Enabled Security Strategies for Next-Generation Operational Technologies”. Dalam *Proceedings of the 28th International Conference on Evaluation and Assessment in Software Engineering (EASE 2024)*, 662–670. <https://doi.org/10.1145/3661167.3661283>. <https://doi.org/10.1145/3661167.3661283>.
- Aiven Karapace Authors. 2025. *Karapace: Schema Registry and REST Proxy for Apache Kafka*. Diakses 25 Mei 2026. <https://www.karapace.io/>.
- Akamai Technologies. 2026. *Akamai Cloud Computing Pricing*. Diakses 16 Juni 2026. <https://www.akamai.com/cloud/pricing/north-america>.
- Altinity. 2025. *Altinity Kubernetes Operator for ClickHouse*. Diakses 25 Mei 2026. <https://github.com/Altinity/clickhouse-operator>.
- Amazon Web Services. 2024. *What is an Event-Driven Architecture?* Diakses 9 April 2026. <https://aws.amazon.com/event-driven-architecture/>.
- Amershi, Saleema, Andrew Begel, Christian Bird, Robert DeLine, Harald Gall, Ece Kamar, Nachiappan Nagappan, Besmira Nushi, dan Thomas Zimmermann. 2019. “Software Engineering for Machine Learning: A Case Study”. Dalam *2019 IEEE/ACM 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 291–300. IEEE. <https://doi.org/10.1109/ICSE-SEIP.2019.00042>. <https://doi.org/10.1109/ICSE-SEIP.2019.00042>.
- Amou Najafabadi, Faezeh, Justus Bogner, Ilias Gerostathopoulos, dan Patricia Lago. 2024. “An Analysis of MLOps Architectures: A Systematic Mapping Study”. Dalam *Software Architecture: 18th European Conference, ECSA 2024, Luxembourg City, Luxembourg, 3–6 September 2024, Proceedings*, 14889:69–85. Lecture Notes in Computer Science. Springer. https://doi.org/10.1007/978-3-031-70797-1_5. https://doi.org/10.1007/978-3-031-70797-1_5.

- Anaconda, Inc. 2020. *2020 State of Data Science: Moving From Hype Toward Maturity*. Diakses 15 April 2026. <https://know.anaconda.com/rs/387-XNW-688/images/Anaconda-SODS-Report-2020-Final.pdf>.
- Apache APISIX Authors. 2025. *Apache APISIX: Cloud-Native API Gateway*. Diakses 25 Mei 2026. <https://apisix.apache.org/docs/>.
- Apache Flink Authors. 2025. *Flink Kubernetes Operator*. Diakses 25 Mei 2026. <https://nightlies.apache.org/flink/flink-kubernetes-operator-docs-stable/>.
- Apache Software Foundation. 2024a. *Apache Airflow Documentation*. Diakses 20 April 2026. <https://airflow.apache.org/docs/>.
- . 2024b. *Apache Flink Documentation*. Diakses 6 April 2026. <https://flink.apache.org/documentation/>.
- . 2024c. *Apache Kafka Documentation*. Diakses 9 April 2026. <https://kafka.apache.org/documentation/>.
- . 2024d. *Apache Spark Documentation*. Diakses 18 Maret 2026. <https://spark.apache.org/docs/latest/>.
- . 2025. *Apache Pulsar Documentation*. Diakses 12 Juni 2026. <https://pulsar.apache.org/docs/>.
- Apache Spark Authors. 2025. *Apache Spark on Kubernetes Operator*. Diakses 25 Mei 2026. <https://github.com/kubeflow/spark-operator>.
- Apache Superset Authors. 2025. *Apache Superset Documentation*. Diakses 25 Mei 2026. <https://superset.apache.org/docs/intro>.
- Aqua Security. 2025. *Trivy Operator: Kubernetes Native Security Scanner*. Diakses 25 Mei 2026. <https://aquasecurity.github.io/trivy-operator/>.
- Argo Project. 2024. *Argo CD - Declarative GitOps CD for Kubernetes*. Diakses 24 Maret 2026. <https://argo-cd.readthedocs.io/>.
- . 2025. *Argo Workflows: Container-Native Workflow Engine for Kubernetes*. Diakses 25 Mei 2026. <https://argo-workflows.readthedocs.io/>.
- Argo Rollouts Authors. 2025. *Argo Rollouts: Progressive Delivery for Kubernetes*. Diakses 25 Mei 2026. <https://argoproj.github.io/argo-rollouts/>.

- AuthZed. 2025. *SpiceDB: Fine-Grained Authorization Database*. Diakses 25 Mei 2026. <https://authzed.com/docs/spicedb/>.
- Bank Indonesia. 2026. *Kurs Referensi Jakarta Interbank Spot Dollar Rate (JISDOR)*. Diakses 16 Juni 2026. <https://www.bi.go.id/id/statistik/informasi-kurs/jisdor/default.aspx>.
- Bayram, Firas, Bestoun S. Ahmed, dan Andreas Kassler. 2022. “From Concept Drift to Model Degradation: An Overview on Performance-Aware Drift Detectors”. *Knowledge-Based Systems* 245:108632. <https://doi.org/10.1016/j.knosys.2022.108632>. <https://doi.org/10.1016/j.knosys.2022.108632>.
- Bernardo, B. M. V., H. S. Mamede, J. M. P. Barroso, dan V. M. P. D. dos Santos. 2024. “Data Governance and Quality Management: Innovation and Breakthroughs across Different Fields”. *Journal of Innovation and Knowledge* 9 (4): 100598. <https://doi.org/10.1016/j.jik.2024.100598>. <https://doi.org/10.1016/j.jik.2024.100598>.
- Bondi, Andre B. 2000. “Characteristics of Scalability and Their Impact on Performance”. Dalam *Proceedings of the 2nd International Workshop on Software and Performance*, 195–203. ACM. <https://doi.org/10.1145/350391.350432>.
- Breck, Eric, Shanqing Cai, Eric Nielsen, Michael Salib, dan D. Sculley. 2017. “The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction”. Dalam *2017 IEEE International Conference on Big Data (Big Data)*, 1123–1132. IEEE. <https://doi.org/10.1109/BigData.2017.8258038>. <https://doi.org/10.1109/BigData.2017.8258038>.
- Bruch, Sebastian, Siyu Gai, dan Amir Ingber. 2023. “An Analysis of Fusion Functions for Hybrid Retrieval”. *ACM Transactions on Information Systems* 42 (1): 1–35. <https://doi.org/10.1145/3596512>. <https://doi.org/10.1145/3596512>.
- Burgueño-Romero, Antonio M., Antonio Benítez-Hidalgo, Cristóbal Barba-González, dan José Francisco Aldana-Montes. 2025. “Toward an Open Source MLOps Architecture”. *IEEE Software* 42 (1): 59–64. <https://doi.org/10.1109/MS.2024.3421675>. <https://doi.org/10.1109/MS.2024.3421675>.
- Campese, Stefano, Ivano Lauriola, dan Alessandro Moschitti. 2024. “Improving Document Retrieval Coherence for Semantically Equivalent Queries”. *arXiv preprint arXiv:2404.12338*.

- Carbone, Paris, Stephan Ewen, Kostas Tzoumas, Volker Markl, dan Fabian Hueske. 2015. “Apache Flink: Stream and Batch Processing in a Single Engine”. *Bulletin of the IEEE Computer Society Technical Committee on Data Engineering* 36 (4): 28–38. <https://asterios.katsifodimos.com/assets/publications/flink-deb.pdf>.
- Ceph Authors. 2025. *Ceph Object Gateway Documentation*. Diakses 12 Juni 2026. <https://docs.ceph.com/en/latest/radosgw/>.
- cert-manager Contributors. 2025. *cert-manager: Automated TLS Certificate Management for Kubernetes*. Diakses 25 Mei 2026. <https://cert-manager.io/docs/>.
- Céspedes Sisniega, Jaime, Vicente Rodríguez, Germán Moltó, dan Álvaro López García. 2024. “Efficient and Scalable Covariate Drift Detection in Machine Learning Systems with Serverless Computing”. *Future Generation Computer Systems* 161:174–188. <https://doi.org/10.1016/j.future.2024.07.010>. <https://doi.org/10.1016/j.future.2024.07.010>.
- Chaos Mesh Authors. 2025. *Chaos Mesh: A Cloud-Native Chaos Engineering Platform*. Diakses 25 Mei 2026. <https://chaos-mesh.org/docs/>.
- Chien, Melody. 2022. *How to Improve Your Data Quality*. Diakses 30 Maret 2026. Gartner. <https://www.gartner.com/smarterwithgartner/how-to-improve-your-data-quality>.
- ClickHouse Inc. 2024. *ClickHouse Documentation*. Diakses 20 April 2026. <https://clickhouse.com/docs/>.
- Cloud Native Computing Foundation. 2024a. *Kubernetes Documentation*. Diakses 11 Maret 2026. <https://kubernetes.io/docs/>.
- . 2024b. *Observability Whitepaper*. Diakses 16 Maret 2026. <https://github.com/cncf/tag-observability/blob/main/whitepaper.md>.
- CloudNativePG Contributors. 2025. *CloudNativePG: Kubernetes Operator for PostgreSQL*. Diakses 25 Mei 2026. <https://cloudnative-pg.io/documentation/>.
- Contabo GmbH. 2026. *Cloud VPS Pricing*. Diakses 16 Juni 2026. <https://contabo.com/en/pricing/>.
- DataHub Project. 2024. *DataHub Documentation*. Diakses 20 April 2026. <https://datahubproject.io/docs/>.

- DataKitchen. 2020. *Launch Your DataOps Journey with the DataOps Maturity Model*. Diakses 10 Juli 2026. DataKitchen. <https://tdwi.org/whitepapers/2020/11/diq-all-datakitchen-dataops-maturity-model.aspx>.
- dbt Labs. 2025. *dbt: Data Build Tool Documentation*. Diakses 25 Mei 2026. <https://docs.getdbt.com/>.
- Debezium Community. 2025. *Debezium Documentation*. Diakses 12 Juni 2026. <https://debezium.io/documentation/>.
- Deuxfleurs Association. 2025. *Garage Documentation*. Diakses 12 Juni 2026. <https://garagehq.deuxfleurs.fr/documentation/>.
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, dan Kristina Toutanova. 2019. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. Dalam *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>. <https://doi.org/10.18653/v1/N19-1423>.
- Dex Authors. 2025. *Dex: A Federated OpenID Connect Provider*. Diakses 25 Mei 2026. <https://dexidp.io/docs/>.
- DigitalOcean. 2026. *Droplets Pricing*. Diakses 16 Juni 2026. <https://www.digitalocean.com/pricing/droplets>.
- European Central Bank. 2026. *Euro Foreign Exchange Reference Rates: US Dollar*. Diakses 16 Juni 2026. https://www.ecb.europa.eu/stats/policy_and_exchange_rates/euro_reference_exchange_rates/html/eurofxref-graph-usd.en.html.
- Evidently AI. 2025. *Evidently: Open-Source ML Observability Platform*. Diakses 25 Mei 2026. <https://docs.evidentlyai.com/>.
- External Secrets Authors. 2025. *External Secrets Operator Documentation*. Diakses 25 Mei 2026. <https://external-secrets.io/latest/>.
- Falco Authors. 2025. *Falco: Cloud-Native Runtime Security*. Diakses 25 Mei 2026. <https://falco.org/docs/>.
- Feast Project. 2024. *Feast Documentation*. Diakses 20 April 2026. <https://docs.feast.dev/>.

- Gitea Contributors. 2025. *Gitea Documentation*. Diakses 25 Mei 2026. <https://docs.gitea.com/>.
- Google Cloud. 2024. *MLOps: Continuous Delivery and Automation Pipelines in Machine Learning*. Cloud Architecture Center. Diakses 18 Maret 2026. <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>.
- . 2026a. *Cloud SQL Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/sql/pricing>.
- . 2026b. *Cloud Storage Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/storage/pricing>.
- . 2026c. *Compute Engine VM Instance Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/compute/vm-instance-pricing>.
- . 2026d. *Google Kubernetes Engine Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/kubernetes-engine/pricing>.
- . 2026e. *Managed Service for Apache Kafka Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/managed-service-for-apache-kafka/pricing>.
- . 2026f. *Memorystore for Redis Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/memorystore/docs/redis/pricing>.
- . 2026g. *Persistent Disk and Image Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/compute/disks-image-pricing>.
- Grafana Labs. 2024a. *Grafana Documentation*. Diakses 20 April 2026. <https://grafana.com/docs/grafana/latest/>.
- . 2024b. *Grafana Loki Documentation*. Diakses 25 Mei 2026. <https://grafana.com/docs/loki/latest/>.
- . 2024c. *Grafana Tempo: High-Volume Distributed Tracing Backend*. Diakses 25 Mei 2026. <https://grafana.com/docs/tempo/latest/>.
- . 2025. *Grafana Pyroscope: Continuous Profiling*. Diakses 25 Mei 2026. <https://grafana.com/docs/pyroscope/latest/>.
- Great Expectations. 2024. *Great Expectations Documentation*. Diakses 25 Mei 2026. <https://docs.greatexpectations.io/docs/>.

- Hamza, Muhammad, Muhammad Azeem Akbar, dan Rafael Capilla. 2024. “Understanding Cost Dynamics of Serverless Computing: An Empirical Study”. Dalam *Software Business: 14th International Conference, ICSOB 2023, Proceedings*, 500:456–470. Lecture Notes in Business Information Processing. Springer. https://doi.org/10.1007/978-3-031-53227-6_32. https://doi.org/10.1007/978-3-031-53227-6_32.
- Harrington, John. 2021. *DataOps for Manufacturing: A 4-Stage Maturity Model*. HighByte Blog. Diakses 10 Juli 2026. <https://www.highbyte.com/blog/dataops-for-manufacturing-a-4-stage-maturity-model>.
- Hetzner Online GmbH. 2026. *Price Adjustment: Cloud Server Pricing*. Diakses 16 Juni 2026. <https://docs.hetzner.com/general/infrastructure-and-availability/price-adjustment/>.
- Hevner, Alan R., Salvatore T. March, Jinsoo Park, dan Sudha Ram. 2004. “Design Science in Information Systems Research”. *MIS Quarterly* 28 (1): 75–105. <https://doi.org/10.2307/25148625>. <https://doi.org/10.2307/25148625>.
- Hinder, Fabian, Valerie Vaquet, Johannes Brinkrolf, dan Barbara Hammer. 2023. “Model-Based Explanations of Concept Drift”. *Neurocomputing* 555:126640. <https://doi.org/10.1016/j.neucom.2023.126640>. <https://doi.org/10.1016/j.neucom.2023.126640>.
- Hsu, C. H., P. W. Liu, Y. C. Fan, dan C. Y. Lin. 2024. “End-to-End Automation of ML Model Lifecycle Management Using Machine Learning Operations Platforms”. Dalam *2024 International Conference on Consumer Electronics-Taiwan (ICCE-Taiwan)*, 1–6. IEEE. <https://doi.org/10.1109/ICCE-Taiwan62264.2024.10674445>. <https://doi.org/10.1109/ICCE-Taiwan62264.2024.10674445>.
- IBM. 2024. *What is Observability? Logs, Metrics, and Distributed Tracing*. Diakses 18 Maret 2026. <https://www.ibm.com/topics/observability>.
- Istio Authors. 2024. *Istio Service Mesh*. Diakses 16 Maret 2026. <https://istio.io/>.
- Iterative, Inc. 2025. *DVC Documentation*. Diakses 12 Juni 2026. <https://dvc.org/doc>.

- Jain, Souratn, dan Jyotipriya Das. 2025. “Integrating Data Engineering and MLOps for Scalable and Resilient Machine Learning Pipelines: Frameworks, Challenges, and Future Trends”. *World Journal of Advanced Engineering Technology and Sciences* 14 (1): 241–253. <https://doi.org/10.30574/wjaets.2025.14.1.0020>. <https://doi.org/10.30574/wjaets.2025.14.1.0020>.
- Jegou, Herve, Matthijs Douze, dan Cordelia Schmid. 2011. “Product Quantization for Nearest Neighbor Search”. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 33 (1): 117–128. <https://doi.org/10.1109/TPAMI.2010.57>. <https://doi.org/10.1109/TPAMI.2010.57>.
- Johnson, Jeff, Matthijs Douze, dan Hervé Jégou. 2021. “Billion-Scale Similarity Search with GPUs”. *IEEE Transactions on Big Data* 7 (3): 535–547. <https://doi.org/10.1109/TBDATA.2019.2921572>. <https://doi.org/10.1109/TBDATA.2019.2921572>.
- Jourdan, Nicolas, Tom Bayer, Tobias Biegel, dan Joachim Metternich. 2023. “Handling Concept Drift in Deep Learning Applications for Process Monitoring”. *Procedia CIRP* 120:42–47. <https://doi.org/10.1016/j.procir.2023.08.007>. <https://doi.org/10.1016/j.procir.2023.08.007>.
- Kafbat Authors. 2025. *Kafbat UI for Apache Kafka Documentation*. Diakses 12 Juni 2026. <https://ui.docs.kafbat.io/>.
- Kartakis, Sokratis, Giuseppe Angelo Porcelli, Georgios Schinas, dan Shelbee Eigenbrode. 2022. *MLOps Foundation Roadmap for Enterprises with Amazon SageMaker*. AWS Machine Learning Blog. Diakses 18 Maret 2026. <https://aws.amazon.com/blogs/machine-learning/mlops-foundation-roadmap-for-enterprises-with-amazon-sagemaker/>.
- Kaufman, Shachar, Saharon Rosset, Claudia Perlich, dan Ori Stitelman. 2012. “Leakage in Data Mining: Formulation, Detection, and Avoidance”. *ACM Transactions on Knowledge Discovery from Data* 6 (4): 1–21. <https://doi.org/10.1145/2382577.2382579>.
- KEDA Authors. 2025. *KEDA: Kubernetes Event-Driven Autoscaling*. Diakses 25 Mei 2026. <https://keda.sh/docs/>.

- Kim, Gene, Jez Humble, Patrick Debois, dan John Willis. 2016. *The DevOps Handbook: How to Create World-Class Agility, Reliability, and Security in Technology Organizations*. 1st. IT Revolution Press. ISBN: 978-1942788003. <https://itrevolution.com/product/the-devops-handbook/>.
- Kleppmann, Martin. 2017. *Designing Data-Intensive Applications*. O'Reilly Media. ISBN: 978-1491903063. <https://www.oreilly.com/library/view/designing-data-intensive-applications/9781491903063/>.
- Knative Authors. 2025. *Knative Serving: Serverless on Kubernetes*. Diakses 25 Mei 2026. <https://knative.dev/docs/serving/>.
- Kreps, Jay. 2014. *Questioning the Lambda Architecture*. Diakses 24 Maret 2026. O'Reilly Radar. <https://www.oreilly.com/radar/questioning-the-lambda-architecture/>.
- Kreuzberger, Dominik, Niklas Kühl, dan Sebastian Hirschl. 2023. "Machine Learning Operations (MLOps): Overview, Definition, and Architecture". *IEEE Access* 11:31866–31879. <https://doi.org/10.1109/ACCESS.2023.3262138>. <https://doi.org/10.1109/ACCESS.2023.3262138>.
- KServe Contributors. 2024. *KServe Documentation*. Diakses 28 April 2026. <https://kserve.github.io/website/>.
- Kubeflow Authors. 2025a. *Katib: Kubernetes-Native Hyperparameter Tuning*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/katib/>.
- . 2025b. *Kubeflow Notebooks*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/notebooks/>.
- . 2025c. *Kubeflow Trainer: Distributed Training Operators*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/trainer/>.
- Kubeflow Contributors. 2024. *Kubeflow Documentation*. Diakses 30 Maret 2026. <https://www.kubeflow.org/docs/>.
- Kubernetes Autoscaling SIG. 2025. *Vertical Pod Autoscaler*. Diakses 25 Mei 2026. <https://github.com/kubernetes/autoscaler/tree/master/vertical-pod-autoscaler>.
- Kueue Authors. 2024. *Kueue: Job Queueing for Kubernetes*. Diakses 25 Mei 2026. <https://kueue.sigs.k8s.io/docs/>.

- Kyverno Authors. 2024. *Kyverno: Kubernetes Native Policy Management*. Diakses 25 Mei 2026. <https://kyverno.io/docs/>.
- Lakekeeper Authors. 2025. *Lakekeeper: Apache Iceberg REST Catalog*. Diakses 25 Mei 2026. <https://docs.lakekeeper.io/>.
- Lakka, Mounika. 2025. “Kubernetes for Enterprise: Mastering Cloud-Native Container Orchestration at Scale”. *European Modern Studies Journal* 9 (3): 358–367. [https://doi.org/10.59573/emsj.9\(3\).2025.31](https://doi.org/10.59573/emsj.9(3).2025.31). [https://doi.org/10.59573/emsj.9\(3\).2025.31](https://doi.org/10.59573/emsj.9(3).2025.31).
- Lamer, Antoine, Chloé Saint-Dizier, Nicolas Paris, dan Emmanuel Chazard. 2024. “Data Lake, Data Warehouse, Datamart, and Feature Store: Their Contributions to the Complete Data Reuse Pipeline”. *JMIR Medical Informatics* 12:e54590. <https://doi.org/10.2196/54590>. <https://doi.org/10.2196/54590>.
- Li, Anya, Bhala Ranganathan, Feng Pan, Mickey Zhang, Qianjun Xu, Runhan Li, Sethu Raman, Shail Paragbhai Shah, dan Vivienne Tang. 2023. “Managed Geo-Distributed Feature Store: Architecture and System Design”. *arXiv preprint arXiv:2305.20077*, <https://doi.org/10.48550/arXiv.2305.20077>. <https://arxiv.org/abs/2305.20077>.
- Liang, Penghao, Wei Chen, Yifan Zhang, dan Jun Liu. 2024. “Automating the Training and Deployment of Models in MLOps by Integrating Systems with Machine Learning”. *arXiv preprint arXiv:2405.09819*, <https://doi.org/10.48550/arXiv.2405.09819>. <https://arxiv.org/abs/2405.09819>.
- Limoncelli, Thomas. 2018. “GitOps: A Path to More Self-Service IT”. *Communications of the ACM* 61 (9): 38–42. <https://doi.org/10.1145/3233241>. <https://dl.acm.org/doi/10.1145/3233241>.
- Lu, Jie, Anjin Liu, Fan Dong, Feng Gu, Joao Gama, dan Guangquan Zhang. 2019. “Learning Under Concept Drift: A Review”. Versi cetak: arXiv:2004.05785 (2020), *IEEE Transactions on Knowledge and Data Engineering* 31 (12): 2346–2363. <https://arxiv.org/abs/2004.05785>.
- Malkov, Yury A., dan D. A. Yashunin. 2020. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42 (4): 824–836. <https://doi.org/10.1109/TPAMI.2018.2889473>. <https://doi.org/10.1109/TPAMI.2018.2889473>.

- Marz, Nathan, dan James Warren. 2015. *Big Data: Principles and Best Practices of Scalable Realtime Data Systems*. Manning Publications. ISBN: 978-1617290343. <https://www.manning.com/books/big-data>.
- McKnight, William. 2020. *Delivering on the Vision of MLOps: A Maturity-Based Approach*. Diakses 18 Maret 2026. GigaOm. <https://gigaom.com/report/delivering-on-the-vision-of-mlops/>.
- Microsoft Azure. 2023. *Machine Learning Operations Maturity Model*. Azure Architecture Center. Diakses 18 Maret 2026. <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/mlops-maturity-model>.
- MinIO, Inc. 2024. *MinIO Documentation*. Diakses 20 April 2026. <https://min.io/docs/>.
- . 2025. *KES: Stateless Key Management Server*. Diakses 25 Mei 2026. <https://github.com/minio/kcs>.
- MLflow Contributors. 2024. *MLflow Documentation*. Diakses 15 April 2026. <https://mlflow.org/docs/latest/index.html>.
- Mo, Di, Robert Cordingley, Donald Chinn, dan Wes Lloyd. 2023. “Addressing Serverless Computing Vendor Lock-In through Cloud Service Abstraction”. Dalam *2023 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)*, 193–199. IEEE. <https://doi.org/10.1109/CloudCom59040.2023.00040>. <https://doi.org/10.1109/CloudCom59040.2023.00040>.
- Munappy, Aiswarya Raj, Jan Bosch, Helena Holmström Olsson, Anders Arpteg, dan Björn Brinne. 2022. “Data Management for Production Quality Deep Learning Models: Challenges and Solutions”. *Journal of Systems and Software* 191:111359. <https://doi.org/10.1016/j.jss.2022.111359>. <https://doi.org/10.1016/j.jss.2022.111359>.
- Munappy, Aiswarya Raj, David Issa Mattos, Jan Bosch, Helena Holmström Olsson, dan Anas Dakkak. 2020. “From Ad-Hoc Data Analytics to DataOps”. Dalam *Proceedings of the International Conference on Software and System Processes (ICSSP '20)*, 165–174. ACM. <https://doi.org/10.1145/3379177.3388909>. <https://doi.org/10.1145/3379177.3388909>.
- NATS Authors. 2025. *NATS JetStream Documentation*. Diakses 12 Juni 2026. <https://docs.nats.io/nats-concepts/jetstream>.

- OAuth2 Proxy Authors. 2025. *OAuth2 Proxy Documentation*. Diakses 25 Mei 2026. <https://oauth2-proxy.github.io/oauth2-proxy/>.
- Open Policy Agent Authors. 2024. *Open Policy Agent*. Diakses 30 Maret 2026. <https://www.openpolicyagent.org/>.
- OpenAI. 2022. *New and Improved Embedding Model*. OpenAI Blog. Diakses 18 Maret 2026. <https://openai.com/index/new-and-improved-embedding-model/>.
- OpenBao Authors. 2025. *OpenBao: Open Source Secrets Management*. Diakses 25 Mei 2026. <https://openbao.org/docs/>.
- OpenCost Authors. 2025. *OpenCost: Open Source Cost Monitoring for Kubernetes*. Diakses 25 Mei 2026. <https://www.opencost.io/docs/>.
- OpenLineage Authors. 2025. *OpenLineage: An Open Standard for Lineage Metadata Collection*. Diakses 25 Mei 2026. <https://openlineage.io/docs/>.
- OpenSearch Foundation. 2025. *OpenSearch: Open Source Search and Analytics Suite*. Diakses 25 Mei 2026. <https://opensearch.org/docs/latest/>.
- OpenTelemetry Authors. 2025. *OpenTelemetry Documentation*. Diakses 25 Mei 2026. <https://opentelemetry.io/docs/>.
- Oracle Corporation. 2025. *MySQL Reference Manual*. Diakses 25 Mei 2026. <https://dev.mysql.com/doc/>.
- OVHcloud. 2026. *Public Cloud Prices*. Diakses 16 Juni 2026. <https://us.ovhcloud.com/public-cloud/prices/>.
- Pachyderm, Inc. 2025. *Pachyderm Documentation*. Diakses 12 Juni 2026. <https://docs.pachyderm.com/>.
- Paley, Andrei, Raoul-Gabriel Urma, dan Neil D. Lawrence. 2022. "Challenges in Deploying Machine Learning: A Survey of Case Studies". *ACM Computing Surveys* 55 (6): 1–29. <https://doi.org/10.1145/3533378>. <https://doi.org/10.1145/3533378>.
- Peffer, Ken, Tuure Tuunanen, Marcus A. Rothenberger, dan Samir Chatterjee. 2007. "A Design Science Research Methodology for Information Systems Research". *Journal of Management Information Systems* 24 (3): 45–77. <https://doi.org/10.2753/MIS0742-1222240302>. <https://doi.org/10.2753/MIS0742-1222240302>.

- PERSOLKELLY Indonesia. 2023. *Indonesia Salary Guide 2023*. Diakses 16 Juni 2026. <https://www.persolindonesia.com/salary-guides>.
- Pimentel, João Felipe, Leonardo Murta, Vanessa Braganholo, dan Juliana Freire. 2019. “A Large-Scale Study About Quality and Reproducibility of Jupyter Notebooks”. Dalam *2019 IEEE/ACM 16th International Conference on Mining Software Repositories (MSR)*, 507–517. IEEE. <https://doi.org/10.1109/MSR.2019.00077>. <https://doi.org/10.1109/MSR.2019.00077>.
- Polyzotis, Neoklis, Sudip Roy, Steven Euijong Whang, dan Martin Zinkevich. 2018. “Data Lifecycle Challenges in Production Machine Learning: A Survey”. *ACM SIGMOD Record* 47 (2): 17–28. <https://doi.org/10.1145/3299887.3299891>. <https://doi.org/10.1145/3299887.3299891>.
- PostgreSQL Global Development Group. 2025. *PostgreSQL: The World’s Most Advanced Open Source Relational Database*. Diakses 25 Mei 2026. <https://www.postgresql.org/docs/>.
- Project Nessie Authors. 2025. *Project Nessie Documentation*. Diakses 12 Juni 2026. <https://projectnessie.org/>.
- Prometheus Authors. 2024. *Prometheus Documentation*. Diakses 20 April 2026. <https://prometheus.io/docs/>.
- . 2025. *Prometheus Pushgateway*. Diakses 25 Mei 2026. <https://prometheus.io/docs/practices/pushing/>.
- Qdrant Team. 2025. *Qdrant: High-Performance Vector Search Engine*. Diakses 25 Mei 2026. <https://qdrant.tech/documentation/>.
- Redpanda Data, Inc. 2025. *Redpanda Documentation*. Diakses 12 Juni 2026. <https://docs.redpanda.com/>.
- Reimers, Nils, dan Iryna Gurevych. 2019. “Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks”. Dalam *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. Association for Computational Linguistics. <https://doi.org/10.18653/v1/D19-1410>. <https://doi.org/10.18653/v1/D19-1410>.

- Reis, Denis Moreira dos, Peter Flach, Stan Matwin, dan Gustavo Batista. 2016. “Fast Unsupervised Online Drift Detection Using Incremental Kolmogorov-Smirnov Test”. Dalam *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1545–1554. ACM. <https://doi.org/10.1145/2939672.2939836>. <https://doi.org/10.1145/2939672.2939836>.
- Rella, Bhanu Prakash Reddy. 2022. “MLOps and DataOps Integration for Scalable Machine Learning Deployment”. *International Journal for Multidisciplinary Research* 4 (1). <https://www.ijfmr.com/papers/2022/1/39278.pdf>.
- Rodrigues, Miguel G., Eduardo K. Viegas, Altair O. Santin, dan Fabrício Enembreck. 2025. “A MLOps Architecture for Near Real-Time Distributed Stream Learning Operation Deployment”. *Journal of Network and Computer Applications* 238:104169. <https://doi.org/10.1016/j.jnca.2025.104169>. <https://doi.org/10.1016/j.jnca.2025.104169>.
- Ross, Ron, Mark Winstead, dan Michael McEvelley. 2022. *Engineering Trustworthy Secure Systems*. NIST Special Publication 800-160v1r1. National Institute of Standards dan Technology. <https://doi.org/10.6028/NIST.SP.800-160v1r1>. <https://doi.org/10.6028/NIST.SP.800-160v1r1>.
- Salama, Khalid, Jarek Kazmierczak, dan Donna Schut. 2021. *Practitioners Guide to MLOps: A Framework for Continuous Delivery and Automation of Machine Learning*. Diakses 10 Juli 2026. Google Cloud. https://services.google.com/fh/files/misc/practitioners_guide_to_mlops_whitepaper.pdf.
- Sculley, D., Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-Francois Crespo, dan Dan Dennison. 2015. “Hidden Technical Debt in Machine Learning Systems”. Dalam *Advances in Neural Information Processing Systems 28 (NIPS 2015)*, disunting oleh C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, dan R. Garnett, 2503–2511. Red Hook, NY: Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcdf2674f757a2463eba-Paper.pdf>.
- SeaweedFS Authors. 2025. *SeaweedFS Documentation*. Diakses 12 Juni 2026. <https://github.com/seaweedfs/seaweedfs/wiki>.
- Shankar, Shreya, Rolando Garcia, Joseph M. Hellerstein, dan Aditya G. Parameswaran. 2022. *Operationalizing Machine Learning: An Interview Study*. ArXiv preprint arXiv:2209.09125. <https://doi.org/10.48550/arXiv.2209.09125>. <https://arxiv.org/abs/2209.09125>.

- Sloth Authors. 2025. *Sloth: Easy and Reliable SLOs for Prometheus*. Diakses 25 Mei 2026. <https://sloth.dev/>.
- Stopford, Ben. 2018. *Designing Event-Driven Systems: Concepts and Patterns for Streaming Services with Apache Kafka*. O'Reilly Media. ISBN: 978-1-492-03822-1.
- Stoyanovich, Julia, Bill Howe, dan H. V. Jagadish. 2020. "Responsible Data Management". *Proceedings of the VLDB Endowment* 13 (12): 3474–3488. <https://doi.org/10.14778/3415478.3415570>. <https://doi.org/10.14778/3415478.3415570>.
- Strimzi Authors. 2025. *Strimzi: Apache Kafka on Kubernetes*. Diakses 25 Mei 2026. <https://strimzi.io/documentation/>.
- Tekton Contributors. 2024. *Tekton Pipelines Documentation*. Diakses 25 Mei 2026. <https://tekton.dev/docs/>.
- Treeverse Ltd. 2025. *lakeFS: Data Version Control for Object Storage*. Diakses 25 Mei 2026. <https://docs.lakefs.io/>.
- Trino Software Foundation. 2024. *Trino: Distributed SQL Query Engine*. Diakses 6 April 2026. <https://trino.io/>.
- Valkey Contributors. 2025. *Valkey: An Open Source In-Memory Data Store*. Diakses 25 Mei 2026. <https://valkey.io/docs/>.
- Vangala, Rajesh, Priya Mehta, dan Arjun Singh. 2022. *MLOps in Practice: A Framework for Scalable AI Model Deployment, Monitoring, and Retraining*. Technical Report. Diakses 15 April 2026. https://www.researchgate.net/publication/393096121_MLOps_in_Practice_A_Framework_for_Scalable_AI_Model_Deployment_Monitoring_and_Retraining.
- Vela, Daniel, Andrew Sharp, Richard Zhang, Trang Nguyen, An Hoang, dan Oleg S. Pianykh. 2022. "Temporal Quality Degradation in AI Models". *Scientific Reports* 12:11654. <https://doi.org/10.1038/s41598-022-15245-z>. <https://doi.org/10.1038/s41598-022-15245-z>.
- Velero Authors. 2025. *Velero: Backup and Migrate Kubernetes Resources and Persistent Volumes*. Diakses 25 Mei 2026. <https://velero.io/docs/>.
- Vultr. 2026. *Vultr Cloud Pricing*. Diakses 16 Juni 2026. <https://www.vultr.com/pricing/>.

Zaharia, Matei, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, dkk. 2016. “Apache Spark: A Unified Engine for Big Data Processing”. *Communications of the ACM* 59 (11): 56–65. <https://doi.org/10.1145/2934664>. <https://doi.org/10.1145/2934664>.

LAMPIRAN A

PARAMETER PENILAIAN KRITERIA EVALUASI ALTERNATIF

Lampiran ini merinci parameter penilaian untuk setiap kriteria pada tabel evaluasi alternatif *open source* di Subbab IV.3. Setiap kriteria memakai skala 0 sampai 2, dan parameter di bawah menjelaskan kondisi yang membuat sebuah alat memperoleh nilai 0, 1, atau 2 pada kriteria tersebut. Penilaian bersifat komparatif antar kandidat pada tabel yang sama dan diturunkan dari dokumentasi resmi, status lisensi, serta indikator publik proyek seperti riwayat rilis dan naungan yayasan per April 2026. Kolom Total pada tiap tabel menjumlahkan keempat kriteria tanpa pembobotan sehingga nilai tertingginya delapan.

Parameter dibagi dua kelompok agar tidak berulang. Tabel A.1 memuat kriteria lintas tabel yang muncul pada lebih dari satu tabel evaluasi dengan makna yang sama, seperti kematangan, komunitas, dan keluarga kriteria lisensi. Tabel A.2 memuat kriteria spesifik yang hanya dipakai pada satu *layer*, dikelompokkan menurut *layer* arsitekturnya. Nama kriteria pada kedua tabel ditulis sama persis dengan judul kolom pada tabel evaluasi yang memakainya.

A.1 Kriteria Lintas Tabel

Tabel A.1 Parameter Penilaian Kriteria Lintas Tabel

Kriteria	Skor 0	Skor 1	Skor 2
Kematangan	Belum ada rilis stabil atau pengembangan berhenti dua belas bulan terakhir	Rilis stabil tersedia namun versi mayor masih muda atau adopsi produksi terbatas	Rilis stabil dengan ritme rilis teratur dan rekam jejak produksi bertahun-tahun
Komunitas	Kontributor efektif tunggal atau aktivitas kontribusi minim	Komunitas aktif namun lebih kecil atau terpusat pada satu organisasi	Komunitas kontributor lintas organisasi terluas pada kategori fungsinya
Ekstensibilitas	Tanpa titik ekstensi resmi	Ekstensi terbatas pada sebagian antarmuka atau menuntut perubahan inti	Antarmuka <i>plugin</i> atau <i>provider</i> resmi terdokumentasi tanpa mengubah inti

Kriteria	Skor 0	Skor 1	Skor 2
Lisensi Terbuka, Lisensi <i>Open</i>	Lisensi tidak diakui OSI, seperti BSL, BUSL, atau <i>source-available</i>	Lisensi OSI dengan <i>copyleft</i> kuat seperti AGPL	Lisensi OSI permisif atau <i>copyleft</i> lemah seperti Apache 2.0, BSD, MPL
Integrasi K8s, Operabilitas K8s, Dukungan K8s	Tanpa dukungan resmi untuk berjalan pada Kubernetes	Berjalan melalui <i>chart</i> atau manifes tanpa pengelolaan siklus hidup, atau mensyaratkan komponen infrastruktur eksternal tetap seperti etcd atau antrean pesan	Dukungan kelas satu berupa <i>operator</i> , CRD, atau <i>chart</i> resmi terkelola
K8s-Native	Tidak dirancang berjalan pada Kubernetes	Berjalan pada Kubernetes namun model eksekusinya tidak berbasis CRD	Model eksekusi berbasis CRD sebagai antarmuka utama
Integrasi (<i>tracking</i> , metadata)	Integrasi terbatas pada ekosistem alat itu sendiri	Integrasi tersedia untuk sebagian alat data dan ML	Integrasi luas lintas ekosistem data dan ML yang terdokumentasi

A.2 Kriteria Spesifik per *Layer*

Tabel A.2 Parameter Penilaian Kriteria Spesifik per *Layer*

Kriteria	Skor 0	Skor 1	Skor 2
Distribusi Kubernetes			
<i>Footprint</i> Ringan	Kebutuhan sumber daya setara distribusi penuh	Ringan namun bergantung paket sistem tambahan	Biner tunggal dengan kebutuhan memori minimal terdokumentasi
Siap Produksi	Ditujukan untuk pengujian, bukan produksi	Dapat dipakai produksi dengan batasan tertentu	Didukung resmi untuk beban produksi
Tanpa Dependensi	Memerlukan beberapa komponen eksternal	Memerlukan satu <i>runtime</i> atau paket eksternal	<i>Runtime</i> kontainer tertanam tanpa dependensi eksternal
Ekosistem <i>Add-on</i>	Tanpa mekanisme <i>add-on</i>	<i>Add-on</i> bawaan terbatas	<i>Add-on</i> bawaan luas termasuk <i>controller</i> Helm
Message Broker dan Schema Registry			

Kriteria	Skor 0	Skor 1	Skor 2
Ekosistem Konektor	Konektor minim	Konektor tersedia namun cakupannya jauh lebih sempit	Ekosistem konektor terluas melalui Kafka Connect <i>native</i>
Operator K8s	Tanpa <i>operator</i>	<i>Operator</i> tersedia dengan cakupan terbatas	<i>Operator</i> matang mencakup klaster, pengguna, dan <i>topic</i>
Protokol Kafka	Protokol berbeda tanpa kompatibilitas	Kompatibel melalui <i>layer</i> protokol tambahan	Kompatibel penuh pada level protokol <i>native</i>
Kompatibilitas Confluent	API tidak kompatibel	Kompatibel pada sebagian <i>endpoint</i>	Kompatibel penuh dengan API Confluent
Dukungan Format	Satu format skema	Dua format atau dukungan parsial	Avro, JSON Schema, dan Protobuf penuh
Pemrosesan Data			
Kapabilitas <i>Batch</i>	Tanpa mode <i>batch</i>	<i>Batch</i> tersedia namun bukan kekuatan utama	<i>Batch</i> skala besar sebagai kapabilitas inti
Kapabilitas <i>Streaming</i>	Tanpa <i>streaming native</i>	<i>Streaming</i> melalui <i>micro-batch</i>	<i>Streaming event-time</i> dengan <i>exactly-once native</i>
Format Tabel <i>Lakehouse</i>			
Transaksi ACID	Tanpa jaminan transaksi	Transaksi dengan batasan mode tulis	Transaksi atomik penuh terdokumentasi
Evolusi Skema	Tanpa evolusi skema	Evolusi terbatas atau bergantung <i>engine</i>	Evolusi penuh pada level format tanpa menulis ulang data
Integrasi <i>Engine</i>	Terikat satu <i>engine</i>	Dukungan multi- <i>engine</i> tidak setara antar <i>engine</i>	Netral multi- <i>engine</i> dengan dukungan setara
Penyimpanan Objek dan Versi Data			
Kompatibilitas S3	Tanpa API S3	Subset API S3	Cakupan API S3 luas termasuk fitur lanjutan
<i>Footprint</i> Satu <i>Node</i>	Arsitektur menuntut banyak <i>node</i>	Dapat satu <i>node</i> dengan komponen berat	Berjalan ringan pada satu <i>node</i>
Enkripsi KMS	Tanpa enkripsi sisi <i>server</i> berbasis KMS	Enkripsi tanpa integrasi KMS eksternal	Enkripsi sisi <i>server</i> dengan integrasi KMS eksternal
Percabangan Tanpa Salin	Tanpa konsep percabangan	Versi berbasis penunjuk berkas per <i>commit</i>	<i>Branch</i> dan <i>merge</i> tanpa menyalin objek
Integrasi Objek S3	Tidak bekerja di atas penyimpanan objek	Bekerja melalui katalog atau <i>remote</i> khusus	Antarmuka S3 langsung tanpa mengubah klien

Kriteria	Skor 0	Skor 1	Skor 2
Skala Data Besar	Tidak dirancang untuk data besar	Skala bergantung repositori Git atau basis data tunggal	Metadata terpisah yang menangani jutaan objek
Layanan Fitur			
Performa <i>Query</i>	Latensi agregasi tinggi pada data besar	Agregasi cepat dengan batasan bentuk kueri	Agregasi kolumnar sub-detik pada data besar
Dukungan <i>Ingestion</i>	<i>Batch</i> saja dengan alat eksternal	<i>Streaming</i> atau <i>batch</i> dengan komponen tambahan	<i>Streaming</i> dan <i>batch native</i> termasuk Kafka
Latensi	Latensi baca di atas puluhan milidetik	Latensi milidetik pada penyimpanan <i>disk</i>	Latensi sub-milidetik pada memori
<i>Throughput</i>	<i>Throughput</i> rendah untuk <i>lookup</i> masif	<i>Throughput</i> tinggi dengan batasan skala vertikal	Ratusan ribu operasi per detik terdokumentasi
Latensi Rendah	Kueri ANN berlatensi tinggi	Latensi rendah dengan batasan indeks atau skala	HNSW dalam memori dengan jalur gRPC berlatensi rendah
Model Lifecycle			
<i>Pipeline</i> ML	Tanpa abstraksi <i>pipeline</i> ML	<i>Pipeline</i> generik yang dapat dipakai untuk ML	Abstraksi <i>pipeline</i> ML khusus dengan kontrak artefak
Skalabilitas	Replika statis tanpa <i>autoscaling</i>	<i>Autoscaling</i> tanpa <i>scale-to-zero</i>	<i>Autoscaling</i> termasuk <i>scale-to-zero</i>
<i>Framework</i>	Terikat satu kerangka model	Beberapa kerangka melalui penyesuaian manual	Multi-kerangka melalui <i>runtime</i> yang dapat diganti
Observabilitas dan BI			
Konektor SQL	Konektor terbatas satu keluarga basis data	Konektor untuk beberapa basis data umum	Puluhan dialek SQL melalui <i>layer</i> konektor standar
Multi-Tenant K8s	Tanpa dukungan Kubernetes resmi	Berjalan pada Kubernetes tanpa isolasi peran	<i>Chart</i> resmi dengan RBAC multi-tenant
GitOps			
Antarmuka	Tanpa antarmuka pemantauan	Antarmuka terbatas atau lewat alat pihak ketiga	Antarmuka web penuh untuk sinkronisasi dan <i>diff</i>
Keamanan Platform			

Kriteria	Skor 0	Skor 1	Skor 2
Bobot <i>Footprint</i>	Kebutuhan sumber daya besar dengan banyak komponen	Layanan tunggal namun berat pada memori	Proses tunggal ringan tanpa basis data wajib
Federasi OIDC	Tanpa federasi ke penyedia hulu	Federasi terbatas pada sebagian protokol	Federasi luas ke penyedia identitas hulu
Rotasi Dinamis	Rahasia statis tanpa rotasi	Rotasi manual atau terbatas	Kredensial dinamis dengan masa hidup otomatis
Integrasi ESO	Tanpa <i>provider</i> External Secrets Operator	Integrasi tidak langsung melalui <i>provider</i> generik	<i>Provider</i> External Secrets Operator resmi
Fitur L7	Fokus L3 dan L4 tanpa kontrol aplikasi	Kontrol L7 dasar	Kontrol L7 penuh termasuk <i>routing</i> dan otorisasi
Ekosistem CRD	Tanpa CRD	CRD terbatas pada sebagian fungsi	CRD kaya untuk lalu lintas, otorisasi, dan telemetri
Plugin/Ekstensi	Tanpa mekanisme <i>plugin</i>	<i>Plugin</i> terbatas pada edisi terbuka	Ekosistem <i>plugin</i> luas dengan muat ulang dinamis
Sintaks <i>Native</i>	Bahasa kebijakan eksternal terpisah dari Kubernetes	Bahasa khusus dengan integrasi Kubernetes	Kebijakan ditulis sebagai YAML <i>native</i> Kubernetes
Mode <i>Mutate</i>	Validasi saja	Mutasi terbatas	<i>Validate</i> , <i>mutate</i> , dan <i>generate</i> penuh
Pelaporan Pelanggaran	Log saja	Metrik atau status tanpa laporan standar	<i>PolicyReport</i> standar per sumber daya
Cakupan eBPF/ Kernel	Tanpa visibilitas kernel	Visibilitas kernel pada subset peristiwa	<i>Probe</i> eBPF modern mencakup <i>syscall</i> luas
Aturan Bawaan	Tanpa aturan bawaan	Contoh aturan terbatas	Pustaka aturan bawaan siap pakai yang luas

LAMPIRAN B

KATALOG PERINTAH VERIFIKASI USE CASE

Lampiran ini memuat katalog perintah yang dapat dijalankan ulang untuk memverifikasi alur ujung ke ujung pada *use case* pasar aset kripto. Seluruh perintah dijalankan secara manual dari direktori akar repositori `~/documents/ta/`, kecuali *listing* menyertakan perintah `cd` eksplisit. Katalog ini terpisah dari `make phase-full` maupun rekonsiliasi Argo CD sehingga bukan bagian dari alur produksi. Sebagian besar perintah hanya membaca klaster, sedangkan skenario ketahanan (SK-N-04), skalabilitas (SK-N-03), dan rekonstruksi (SK-N-11) menerapkan gangguan terkontrol yang dapat dipulihkan pada *namespace* *experiments* yang terpisah dari produksi, sejalan dengan metode evaluasi pada Bab VI. Berkas skenario berada pada direktori `experiments/` yang sejajar dengan `platform/` dan `use-case-crypto/`. Rincian argumen tiap skenario tersedia pada `README.md` di `experiments/` beserta subdirektori terkait. Prasyarat menjalankannya: platform telah terpasang (`make phase-full`), *use case* telah ter-*deploy* (`make usecase-crypto-build && make usecase-crypto-up`), dan seluruh *pod* berstatus *Running*. Sebelum skenario dijalankan, konfigurasi domain dimuat dan *namespace* beban dibuat melalui langkah persiapan berikut.

Listing B.1 Langkah persiapan pemuatan konfigurasi domain dan *namespace* pembangkit beban (dari `~/documents/ta/`)

```
1 # Muat DOMAIN; ganti berkas ini
2 set -a; . "${EXPERIMENTS_CONFIG:-experiments/config.crypto.env}";
   set +a
3 kubectl apply -f experiments/namespace.yaml
```

B.1 Tujuan T-1: Arsitektur Terintegrasi dan GitOps

Kelompok T-1 membuktikan pemasangan deklaratif dari satu sumber Git, otomasi *model lifecycle* setara MLOps *level 2*, serta atribut kualitas lintas komponen. Perintahnya dirangkum pada *Listing B.2*.

Listing B.2 Perintah verifikasi tujuan T-1 (dari `~/documents/ta/`)

```
1 # SK-F-01/KF-01: rekonsiliasi feature view Feast
2 argocd app get crypto-use-case-local
3 kubectl -n use-case-crypto get configmap crypto-feast-feature-repo
   \
```

```

4  -o jsonpath='{.data.definitions\.py}' | grep 'FeatureView('
5
6  # SK-F-12/KF-12: konvergensi deklaratif tanpa drift
7  argocd app diff crypto-use-case-local
8  kubectl -n use-case-crypto get deploy
9
10 # SK-F-06/KF-06: canary dan rollback Rollouts
11 kubectl -n use-case-crypto get rollouts
12 kubectl argo rollouts -n use-case-crypto get rollout crypto-ml-
    bridge --watch
13
14 # SK-F-13/KF-13: satu environment uv multi-SDK
15 cd use-case-crypto/notebooks
16 uv sync
17 uv run jupyter nbconvert --to notebook --execute
    unified_sdk_walkthrough.ipynb
18 kubectl get inferencesservice -A | grep predictor
19
20 # SK-F-14/KF-14: kuota Kueue, job Pending
21 kubectl get clusterqueue,localqueue,workloads -A
22
23 # SK-N-03/KNF-03: skalabilitas HPA dan KEDA
24 k6 run experiments/load/hpa-keda-rampup.js
25 kubectl -n use-case-crypto get hpa,scaledobject,pods -w
26
27 # SK-N-04/KNF-04: injeksi fault pod/jaringan
28 envsubst < experiments/chaos/pod-chaos.yaml | kubectl apply -f -
29 kubectl apply -f experiments/chaos/network-chaos.yaml
30
31 # SK-N-08/KNF-08: ganti runtime via overlay
32 kubectl apply -k use-case-crypto/manifests/overlays/local
33
34 # SK-N-09/KNF-09: SSO satu sesi dex
35 kubectl get pods -A | grep -E 'dex|oauth2-proxy'
36
37 # SK-N-10/KNF-10: atribusi biaya OpenCost
38 kubectl get pods -A | grep -i opencost
39
40 # SK-N-11/KNF-11: rekonstruksi penuh dari Git
41 make phase-full
42
43 # SK-N-12/KNF-12: cakupan uji, konvergensi phase-full
44 make usecase-crypto-test
45 time make phase-full

```

B.2 Tujuan T-2: Tata Kelola Data

Kelompok T-2 membuktikan katalog metadata, *lineage*, kontrak kualitas, observabilitas, dan keamanan berjalan otomatis sepanjang *pipeline*. Perintahnya dirangkum pada Listing B.3.

Listing B.3 Perintah verifikasi tujuan T-2 (dari ~/documents/ta/)

```
1 # SK-F-08/KF-08: lineage end-to-end DataHub
2 experiments/lineage/lineage-walk.sh discover
3 experiments/lineage/lineage-walk.sh walk '<urn>'
4
5 # SK-F-09/KF-09: dua run, delta <1%
6 kubectl -n model-lifecycle get pods | grep mlflow
7
8 # SK-F-10/KF-10: audit trail MLflow
9 kubectl -n model-lifecycle get pods | grep mlflow
10
11 # SK-N-05/KNF-05: GE checkpoint tolak pelanggaran
12 kubectl -n use-case-crypto get cronjob | grep -iE 'quality|expect|
    ge-'
13 kubectl -n use-case-crypto create job ge-check --from=cronjob/
    crypto-ge-checkpoint
14
15 # SK-N-06/KNF-06: trace OTel Tempo/Grafana
16 kubectl get pods -A | grep -E 'tempo|grafana'
17
18 # SK-N-07/KNF-07: Trivy, TLS dan AES
19 kubectl get vulnerabilityreports -A
20 testssl.sh <public-endpoint>
```

B.3 Tujuan T-3: Deteksi *Drift* dan *Retraining*

Kelompok T-3 membuktikan deteksi *drift* terotomasi memicu *retraining* dan penyusunan fitur pelatihan menjaga *point-in-time correctness*. Perintahnya dirangkum pada Listing B.4.

Listing B.4 Perintah verifikasi tujuan T-3 (dari ~/documents/ta/)

```
1 # SK-F-03/KF-03: point-in-time correctness gold
2 export CLICKHOUSE_USER=$(kubectl -n "$CLICKHOUSE_NAMESPACE" get
    secret clickhouse-admin \
3     -o jsonpath='{.data.CLICKHOUSE_USER}' | base64 -d)
4 export CLICKHOUSE_PASSWORD=$(kubectl -n "$CLICKHOUSE_NAMESPACE"
    get secret clickhouse-admin \
```

```

5 -o jsonpath='{.data.CLICKHOUSE_PASSWORD}' | base64 -d)
6 experiments/etl/data-landed-check.sh
7
8 # SK-F-05/KF-05: pipeline retraining KFP
9 uv run --with 'kfp[kubernetes]==2.16.0' use-case-crypto/pipelines/
  retraining_pipeline.py
10
11 # SK-F-07/KF-07: injeksi drift picu retrain
12 uv run experiments/drift/inject_drift.py --sigma 2.0
13 kubectl -n model-lifecycle get cronworkflow,workflow

```

B.4 Tujuan T-4: Layanan Fitur *Dual-Store*

Kelompok T-4 membuktikan layanan fitur *dual-store* menyajikan *tabular feature*, *aggregate feature*, dan *vector feature* dengan kontrak konsisten antara *training* dan *serving*, beserta latensi dan *throughput* jalur *serving*. Perintahnya dirangkum pada Listing B.5.

Listing B.5 Perintah verifikasi tujuan T-4 (dari ~/documents/ta/)

```

1 # SK-F-02/KF-02: online Feast offline ClickHouse
2 kubectl -n model-lifecycle port-forward svc/feast 6566:6566 &
3 FEAST_URL=http://localhost:6566 uv run experiments/feast/online-
  serving-check.py
4 experiments/etl/data-landed-check.sh
5
6 # SK-F-04/KF-04: pencarian vektor Qdrant
7 k6 run experiments/load/vector-search-latency.js
8
9 # SK-F-11/KF-11: paritas dbt vs Flink
10 experiments/etl/data-landed-check.sh
11 experiments/parity/parity-check.sh
12
13 # SK-N-01/KNF-01: latensi p99 feast/vektor
14 k6 run experiments/load/feast-online-latency.js
15
16 # SK-N-02/KNF-02: throughput, consumer lag
17 k6 run experiments/load/feast-throughput.js
18 kafka-producer-perf-test --topic crypto.validated --num-records
  1000000 \
19 --record-size 256 --throughput -1 \
20 --producer-props bootstrap.servers="$KAFKA_BOOTSTRAP" \
21 --producer.config <sasl.properties>

```

Setiap perintah pada katalog ini berpasangan satu-satu dengan baris Tabel VI.1 dan

Tabel VI.2 pada Bab VI, sehingga klaim pemenuhan kebutuhan dapat dilacak langsung ke perintah yang menghasilkan buktinya. Untuk *use case* lain, cukup berkas `config.crypto.env` yang disalin dan disesuaikan blok DOMAIN-nya. Kode skenario tetap *domain-agnostic* dan tidak perlu diubah.

