

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

Draf Laporan Tugas Akhir

Oleh

Bryan P. Hutagalung
18222130



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juli 2026

LEMBAR PENGESAHAN

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

Draf Laporan Tugas Akhir

Oleh

**Bryan P. Hutagalung
18222130**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 15 Juli 2026

Pembimbing

Achmad Imam Kistijantoro, S.T, M.Sc., Ph.D.

NIP. 197308092006041001

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 15 Juli 2026

Bryan P. Hutagalung

NIM: 18222130

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Claude	Tinggi	Semua bab
2	Pembuatan teks	Tidak ada	Tidak ada	Tidak ada
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	Claude	Sangat tinggi	Bab 1 - Bab 5
5	Penyusunan bahan diskusi	Claude	Sangat tinggi	Semua bab
6	Penyusunan kode program	Claude	Sedang	Bab 5 dan Lampiran B
7	Penyusunan formula atau perhitungan matematis	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan konsep desain atau algoritma	Claude	Rendah	Bab 4
9	Penyusunan analisis data	Tidak ada	Tidak ada	Tidak ada
10	Penyusunan kesimpulan atau rekomendasi	Tidak ada	Tidak ada	Tidak ada

Bandung, 15 Juli 2026

Bryan P. Hutagalung

NIM: 18222130

ABSTRAK

Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*

oleh

Bryan P. Hutagalung

18222130

Penerapan DataOps dan MLOps secara berdampingan masih menghadapi fragmentasi *tools* dan pemisahan kerja antara tim data dan tim *machine learning*. DataOps memperkuat kualitas dan kecepatan alur data, sementara MLOps memperkuat keandalan *model lifecycle*, namun keduanya sering tumbuh terpisah sehingga *lineage*, deteksi *drift*, dan *feature serving* antara mode *batch* dan *streaming* tidak konsisten lintas siklus. Berlangganan layanan terkelola memangkas konfigurasi, tetapi biaya operasionalnya tinggi dan menimbulkan keterikatan terhadap satu penyedia. Berdasarkan masalah tersebut, penelitian ini melakukan pengembangan arsitektur platform DataOps dan MLOps terintegrasi pada Kubernetes dengan pemanfaatan *open source tools*. Metode *Design Science Research Methodology* (DSRM) dipakai secara berurutan, mulai dari identifikasi masalah, penyusunan tujuan artefak, perancangan, implementasi berbasis GitOps, sampai evaluasi dengan *use case* pasar aset kripto sebagai kasus verifikasi karena beroperasi tanpa henti dengan distribusi data yang nonstasioner. Rancangan yang dihasilkan menyatukan sembilan *layer* arsitektur pada satu *control plane*, mulai dari *orchestration and infrastructure* sampai *security*. Pemanfaatan *open source tools* pada tiap *layer* ditetapkan melalui penilaian berkriteria agar arsitektur tetap dapat dipakai lintas domain dan tiap *tools* dapat diganti tanpa mengubah rancangan. Hasil evaluasi menunjukkan keempat tujuan platform terpenuhi secara fungsional dan struktural pada lingkungan *node* tunggal, mencakup rekonstruksi seluruh komponen dari satu sumber Git, tata kelola otomatis sepanjang *pipeline*, *trigger retraining* oleh deteksi *drift*, serta layanan fitur *dual-store* dengan kontrak yang konsisten antara *training* dan *inference*. Perbandingan biaya tiga opsi penyediaan platform menunjukkan rancangan *open source* menekan biaya jangka panjang dibanding layanan terkelola. Karakterisasi beban kuantitatif pada *cluster multi-node* menjadi arah pengembangan lanjutan.

Kata kunci: DataOps, MLOps, Kubernetes, Feature Store, Drift Detection, GitOps, Open Source.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia-Nya, penulis dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul “Pengembangan Arsitektur Platform DataOps dan MLOps Terintegrasi pada Kubernetes dengan Pemanfaatan *Open Source Tools*”. Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Penulis menyadari bahwa Tugas Akhir ini tidak akan selesai tanpa bantuan dan dukungan dari banyak pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Tuhan Yang Maha Esa atas rahmat dan penyertaan-Nya sepanjang proses pengerjaan Tugas Akhir.
2. Bapak Ir. I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D. selaku Ketua Program Studi Sistem dan Teknologi Informasi sekaligus dosen wali penulis.
3. Tim Tugas Akhir Program Studi Sistem dan Teknologi Informasi atas koordinasi dan kelancaran selama pelaksanaan Tugas Akhir.
4. Bapak Achmad Imam Kistijantoro, S.T, M.Sc., Ph.D. selaku dosen pembimbing atas arahan, masukan, dan diskusi selama pengerjaan Tugas Akhir.
5. Orang tua penulis, papa dan mama, atas doa dan dukungan yang tidak pernah putus.
6. Pasangan penulis, Tamara, atas kesabaran, dukungan, dan motivasi yang terus menerus selama proses penulisan Tugas Akhir.
7. Teman-teman penulis, yaitu Nangorians (Yusril, Timothy, Ardra, Jojo, Andhika, Natha, Panji, Jebe), S2 DS (Tamara, Yovanka), HMIF Lakara (Anin, Lina, Angie, Jendra, Zaki, Tamara, Shazya, Scifo, Dama, Maulvi, Marcell, dan seluruh Ring 2 serta anggota dan magang lainnya), Vishvanava, Kepanitiaan Perayaan Wisuda Oktober HMIF ITB 2024 (Hira, Tamara, Attara, Kevinza, Erwan, Thalia, Andhika, Jeremy, Irfan, Angie, Juan, dan seluruh Ring 2 serta panitia lainnya), Sarenda Adikara, Kabinet Bermakna (Nahda, Tari-sha, SPP, Yos, Tamara, Aziz, Erwan, Fadhil, Fathur, Arfa, Haura, Akram, Awang, Alfian, Sam, Hayfa, dan seluruh Ring 12 lainnya), GARAKA, dan BYTE, CIPHER, PROXY, serta yang terutama HMIF ITB atas kebersamaan dan dukungannya.

Penulis menyadari bahwa laporan ini masih memiliki kekurangan. Oleh karena itu,

kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang. Semoga laporan ini bermanfaat bagi pembaca dan pengembangan platform DataOps dan MLOps di lingkungan akademik maupun industri.

Bandung, 15 Juli 2026

Penulis

Bryan P. Hutagalung

DAFTAR ISI

LEMBAR PENGESAHAN	i
PERNYATAAN ORISINALITAS	iii
PERNYATAAN PENGGUNAAN AI	v
ABSTRAK	vii
KATA PENGANTAR	ix
DAFTAR ISI	xi
DAFTAR GAMBAR	xv
DAFTAR TABEL	xvii
DAFTAR <i>LISTING</i>	xix
DAFTAR SIMBOL	xxi
DAFTAR SINGKATAN	xxiii
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	3
I.4 Batasan Masalah	5
I.5 Metodologi	6
I.6 Sistematika Penulisan	7
II STUDI LITERATUR	9
II.1 DataOps dan MLOps	9
II.1.1 DataOps	10
II.1.2 MLOps	14
II.1.3 Integrasi DataOps dan MLOps	19
II.2 Kubernetes dan Orkestrasi <i>Cloud-Native</i>	20
II.2.1 Peran, Objek Dasar, dan Distribusi	20
II.2.2 <i>Autoscaling</i> dan Ekosistem <i>Operator</i>	21
II.3 Manajemen Data: <i>Ingestion</i> , <i>Processing</i> , dan <i>Storage</i>	22
II.3.1 Pola Lambda dan Kappa	22
II.3.2 <i>Message Broker</i> dan <i>Data Ingestion</i>	22
II.3.3 <i>Stream Processing</i>	23
II.3.4 <i>Batch Processing</i> dan Transformasi SQL	24
II.3.5 Format Tabel <i>Lakehouse</i>	25
II.3.6 Penyimpanan Objek dan Versi Data	25
II.3.7 Penyimpanan Relasional dan Pencarian	26
II.4 Layanan Fitur (<i>Feature Store</i>)	26
II.4.1 Peran <i>Feature Store</i> sebagai Penyatu Fitur	27
II.4.2 Penyimpanan <i>Offline</i> dan <i>Online</i>	27
II.4.3 Pencarian Vektor dan HNSW	28
II.4.4 <i>Point-in-Time Correctness</i>	28
II.5 <i>Model Lifecycle</i>	29
II.5.1 Eksperimen dan <i>Tracking</i>	29

II.5.2	Orkestrasi <i>Training</i>	30
II.5.3	Eksperimen Interaktif dan <i>Tuning</i>	30
II.5.4	<i>Model Serving</i>	31
II.6	Tata Kelola Data: Katalog, <i>Lineage</i> , dan Kualitas	32
II.6.1	Katalog Metadata dan <i>Lineage</i>	32
II.6.2	Kontrak dan Pengujian Kualitas Data	33
II.7	Deteksi <i>Drift</i>	33
II.7.1	Jenis <i>Drift</i> dan Metrik Statistik	33
II.7.2	Deteksi Terjadwal dan Pemicu <i>Retraining</i>	34
II.8	Observabilitas <i>Cloud-Native</i>	34
II.8.1	Metrik, Log, dan <i>Trace</i>	35
II.8.2	Kebutuhan Turunan dan Antarmuka Analitik	35
II.9	GitOps dan <i>Continuous Delivery</i>	36
II.9.1	Rekonsiliasi Deklaratif dan Integrasi Berkelanjutan	36
II.9.2	<i>Deployment</i> Progresif	37
II.10	Keamanan Platform: Identitas, <i>Secret</i> , <i>Mesh</i> , dan Kebijakan	37
II.10.1	Identitas dan Pengelolaan <i>Secret</i>	37
II.10.2	<i>Service Mesh</i> , <i>API Gateway</i> , dan Penegakan Kebijakan	38
II.11	Penelitian Terkait	39
III	ANALISIS MASALAH	41
III.1	Analisis Kondisi Saat Ini	41
III.1.1	Beban Konfigurasi Platform dari Awal	41
III.1.2	Biaya Berlangganan Layanan Terkelola	42
III.1.3	Efek Domino Fragmentasi Lintas Peran	43
III.2	Analisis Kebutuhan	44
III.2.1	Identifikasi Masalah Pengguna	45
III.2.2	Kebutuhan Fungsional	46
III.2.3	Kebutuhan Nonfungsional	49
III.3	Analisis Pemilihan Solusi	53
III.3.1	Alternatif Solusi	53
III.3.2	Analisis Penentuan Solusi	55
III.3.3	Posisi terhadap Penelitian Terkait	57
IV	PERANCANGAN ARSITEKTUR PLATFORM DATAOPS DAN MLOPS	65
IV.1	Analisis Layanan DataOps dan MLOps pada Praktik Industri	65
IV.1.1	Layanan pada Praktik MLOps dan DataOps	65
IV.1.2	Klasifikasi <i>Platform Layer</i>	67
IV.2	Analisis Pemilihan <i>Open Source Tools</i>	70
IV.2.1	<i>Orchestration and Infrastructure Layer</i>	71
IV.2.2	<i>Data Ingestion and Processing Layer</i>	72
IV.2.3	<i>Data Storage Layer</i>	74
IV.2.4	<i>Feature Service Layer</i>	75
IV.2.5	<i>Model Lifecycle Layer</i>	77
IV.2.6	<i>Data Governance Layer</i>	78
IV.2.7	<i>Observability Layer</i>	79

IV.2.8	<i>GitOps and Continuous Delivery Layer</i>	80
IV.2.9	<i>Security Layer</i>	80
IV.3	Perancangan Arsitektur Terintegrasi	84
IV.3.1	<i>Orchestration and Infrastructure Layer</i>	85
IV.3.2	<i>Data Ingestion and Processing Layer</i>	86
IV.3.3	<i>Data Storage Layer</i>	87
IV.3.4	<i>Feature Service Layer</i>	88
IV.3.5	<i>Model Lifecycle Layer</i>	89
IV.3.6	<i>Data Governance Layer</i>	90
IV.3.7	<i>Observability Layer</i>	92
IV.3.8	<i>GitOps and Continuous Delivery Layer</i>	93
IV.3.9	<i>Security Layer</i>	94
IV.4	Perancangan Sub-sistem Tata Kelola Data	95
IV.4.1	Katalog Metadata dan <i>Lineage</i>	95
IV.4.2	Kontrak Data dan Kualitas	96
IV.4.3	Identitas dan Kontrol Akses	97
IV.5	Perancangan Sub-sistem Deteksi <i>Drift</i> dan <i>Continuous Training</i>	97
IV.5.1	Pengukuran <i>Drift</i>	98
IV.5.2	Alur <i>Retraining</i> Otomatis	98
IV.5.3	Mekanisme Penanganan Kasus Khusus	99
IV.6	Perancangan Sub-sistem Layanan Fitur <i>Dual-Store</i>	99
IV.6.1	Penyimpanan <i>Offline</i> dan <i>Online</i>	100
IV.6.2	Dukungan <i>Vector Embeddings</i> dan HNSW	100
IV.6.3	Jaminan <i>Point-in-Time Correctness</i>	101
IV.6.4	Aliran Materialisasi Fitur	102
IV.7	Alur Kerja <i>End-to-End</i>	102
V	IMPLEMENTASI ARSITEKTUR PLATFORM DATAOPS DAN MLOPS	105
V.1	Lingkungan Implementasi	105
V.1.1	Batasan Implementasi	106
V.1.2	Konfigurasi Dasar <i>Cluster</i>	107
V.1.3	Manajemen <i>Secret</i> dan Identitas	107
V.1.4	Pola <i>GitOps</i>	108
V.2	Implementasi Arsitektur Terintegrasi	108
V.2.1	<i>Data Ingestion and Processing Layer</i>	109
V.2.2	<i>Data Storage Layer</i>	111
V.2.3	<i>Model Lifecycle Layer</i>	112
V.2.4	<i>Observability Layer</i>	112
V.3	Implementasi Sub-sistem Tata Kelola Data	113
V.3.1	Katalog Metadata dan <i>Lineage</i>	113
V.3.2	Kontrak Data dan Kualitas	114
V.3.3	Kontrol Akses	114
V.4	Implementasi Sub-sistem Deteksi <i>Drift</i> dan <i>Continuous Training</i>	115
V.4.1	Detektor <i>Drift</i>	115
V.4.2	<i>Retraining Control Loop</i>	116

V.4.3	Penanganan Kasus Khusus	117
V.5	Implementasi Sub-sistem Layanan Fitur <i>Dual-Store</i>	117
V.5.1	Konfigurasi Feast	118
V.5.2	Dukungan <i>Vector Embeddings</i>	118
V.5.3	Materialisasi dan <i>Point-in-Time Correctness</i>	119
V.6	Verifikasi Implementasi	120
V.6.1	Lingkup Verifikasi	120
V.6.2	Pengamatan Hasil Awal	121
VI	EVALUASI	123
VI.1	Metode Evaluasi	123
VI.1.1	Kasus Verifikasi dan Lingkungan Uji	124
VI.1.2	Evaluasi Tujuan T-1: Arsitektur Terintegrasi dan GitOps	126
VI.1.3	Evaluasi Tujuan T-2: Tata Kelola Data	128
VI.1.4	Evaluasi Tujuan T-3: Deteksi <i>Drift</i> dan <i>Retraining</i>	130
VI.1.5	Evaluasi Tujuan T-4: Layanan Fitur <i>Dual-Store</i>	131
VI.1.6	Matriks Cakupan dan Uji Penerimaan	132
VI.2	Hasil Evaluasi	133
VI.2.1	Pemenuhan Tujuan Platform	133
VI.2.2	Perbandingan Biaya Infrastruktur dan Tenaga Kerja	138
VI.3	Pembahasan	141
VII	PENUTUP	145
VII.1	Kesimpulan	145
VII.2	Saran	146
Lampiran A	PARAMETER PENILAIAN KRITERIA EVALUASI	165
A.1	Parameter Pemetaan Kematangan MLOps	165
A.2	Parameter Evaluasi Pemilihan Solusi	166
A.3	Parameter Evaluasi Pemilihan <i>Open Source Tools</i>	166
A.3.1	Kriteria Lintas Tabel	167
A.3.2	Kriteria Spesifik per <i>Layer</i>	167
Lampiran B	KATALOG PERINTAH VERIFIKASI USE CASE	173
B.1	Tujuan T-1: Arsitektur Terintegrasi dan GitOps	173
B.2	Tujuan T-2: Tata Kelola Data	175
B.3	Tujuan T-3: Deteksi <i>Drift</i> dan <i>Retraining</i>	175
B.4	Tujuan T-4: Layanan Fitur <i>Dual-Store</i>	176

DAFTAR GAMBAR

II.1	<i>Big data analytics pipeline</i> pada studi kasus Ericsson	10
II.2	Model evolusi DataOps lima tahap	11
II.3	MLOps <i>level 0</i> : proses manual	15
II.4	MLOps <i>level 1</i> : otomasi <i>training pipeline</i>	16
II.5	MLOps <i>level 2</i> : orkestrasi CI/CD/CT	16
III.1	Alur data terfragmentasi pada kondisi saat ini	44
III.2	Alur model terfragmentasi pada kondisi saat ini	44
IV.1	Arsitektur layanan terintegrasi tanpa keterikatan <i>tools</i>	68
IV.2	Rincian <i>Orchestration and Infrastructure Layer</i>	86
IV.3	Rincian <i>Data Ingestion and Processing Layer</i>	87
IV.4	Rincian <i>Data Storage Layer</i>	88
IV.5	Rincian <i>Feature Service Layer</i>	89
IV.6	Rincian <i>Model Lifecycle Layer</i>	90
IV.7	Rincian bagian <i>model serving</i>	91
IV.8	Rincian <i>Data Governance Layer</i>	92
IV.9	Rincian <i>Observability Layer</i>	93
IV.10	Rincian <i>GitOps and Continuous Delivery Layer</i>	94
IV.11	Rincian <i>Security Layer</i>	95
VI.1	Proyeksi Biaya Kumulatif per Opsi Penyediaan	143

DAFTAR TABEL

II.1	Karakteristik dan Kebutuhan Tiap Tahap Model Evolusi DataOps . . .	12
II.2	Perbandingan Model Kematangan DataOps	13
II.3	Karakteristik dan Komponen Tiap <i>Level</i> Kematangan MLOps . . .	17
II.4	Perbandingan <i>Framework</i> Tingkat Kematangan MLOps	18
III.1	Kebutuhan Fungsional Sistem	47
III.2	Kebutuhan Nonfungsional Sistem	49
III.3	Evaluasi Pemenuhan Kebutuhan Fungsional	55
III.4	Evaluasi Pemenuhan Kebutuhan Nonfungsional	56
III.5	Total Skor Pemenuhan Kebutuhan Fungsional dan Nonfungsional .	56
III.6	Perbandingan Detail Arsitektur Saat Ini dengan yang Diusulkan . .	57
IV.1	Pemetaan <i>Layer</i> Platform ke Komponen Mayoritas	69
IV.2	Pemetaan Peran Pengguna ke Antarmuka dan <i>Layer</i> Platform	70
IV.3	Evaluasi Alternatif Distribusi Kubernetes <i>Open-Source</i>	72
IV.4	Evaluasi Alternatif <i>Message Broker</i> untuk <i>Streaming</i>	72
IV.5	Evaluasi Alternatif <i>Schema Registry</i> untuk Apache Kafka	73
IV.6	Evaluasi Alternatif <i>Framework</i> Pemrosesan Data	73
IV.7	Evaluasi Alternatif Format Tabel <i>Lakehouse Open-Source</i>	74
IV.8	Evaluasi Alternatif Penyimpanan Objek S3-Kompatibel <i>Open-Source</i>	74
IV.9	Evaluasi Alternatif Pengelola Versi Data <i>Open-Source</i>	75
IV.10	Evaluasi Alternatif <i>Feature Store Open-Source</i>	75
IV.11	Evaluasi Alternatif Penyimpanan <i>Offline</i> (OLAP)	76
IV.12	Evaluasi Alternatif Penyimpanan <i>Online</i> (Latensi Rendah)	76
IV.13	Evaluasi Alternatif <i>Vector Index Open-Source</i>	77
IV.14	Evaluasi Alternatif <i>Experiment Tracking</i> dan <i>Model Registry</i>	77
IV.15	Evaluasi Alternatif Orkestrasi ML <i>Open-Source</i>	78
IV.16	Evaluasi Alternatif <i>Model Serving</i>	78
IV.17	Evaluasi Alternatif Manajemen Metadata dan Tata Kelola	79
IV.18	Evaluasi Alternatif <i>Monitoring</i> dan <i>Observability</i>	79
IV.19	Evaluasi Alternatif <i>Business Intelligence</i> dan <i>Dashboarding</i>	80
IV.20	Evaluasi Alternatif <i>GitOps Controller Open-Source</i>	81
IV.21	Evaluasi Alternatif <i>Identity Provider Open-Source</i>	81
IV.22	Evaluasi Alternatif <i>Secret Manager</i>	82
IV.23	Evaluasi Alternatif <i>Service Mesh</i>	82

IV.24 Evaluasi Alternatif <i>API Gateway Open-Source</i>	82
IV.25 Evaluasi Alternatif <i>Policy Engine Open-Source</i>	83
IV.26 Evaluasi Alternatif <i>Runtime Security Open-Source</i> pada Kubernetes	83
V.1 Struktur Direktori Utama Proyek dan Fungsinya	106
V.2 Pemetaan <i>Layer</i> Platform ke Komponen Terpasang dan <i>Namespace</i>	109
V.3 Konfigurasi <i>Ingress</i> Kafka pada Lingkungan Implementasi	110
V.4 Tata Letak <i>Bucket</i> MinIO per Kepentingan	112
VI.1 Skenario Uji Penerimaan Tujuan T-1	127
VI.2 Skenario Uji Penerimaan Tujuan T-2	129
VI.3 Skenario Uji Penerimaan Tujuan T-3	130
VI.4 Skenario Uji Penerimaan Tujuan T-4	132
VI.5 Status Evaluasi Kebutuhan Tujuan T-1	133
VI.6 Status Evaluasi Kebutuhan Tujuan T-2	134
VI.7 Status Evaluasi Kebutuhan Tujuan T-3	135
VI.8 Status Evaluasi Kebutuhan Tujuan T-4	136
VI.9 Biaya Opsi A: Layanan Terkelola Penuh pada GCP	139
VI.10 Biaya Opsi B: Kustom dari Awal pada VPS dan Kubernetes	140
VI.11 Biaya Opsi C: Open Source pada VPS dan Kubernetes	140
A.1 Parameter Pemetaan Skor Perbandingan Kematangan MLOps	165
A.2 Parameter Nilai Evaluasi Pemilihan Solusi	166
A.3 Parameter Penilaian Kriteria Lintas Tabel	167
A.4 Parameter Penilaian Kriteria Spesifik per <i>Layer</i>	168

DAFTAR *LISTING*

VI.1	Kutipan <i>overlay</i> Kustomize <i>use case</i>	125
B.1	Persiapan <i>namespace load generator</i> (dari ~/documents/ta/) . . .	173
B.2	Perintah verifikasi tujuan T-1 (dari ~/documents/ta/)	173
B.3	Perintah verifikasi tujuan T-2 (dari ~/documents/ta/)	175
B.4	Perintah verifikasi tujuan T-3 (dari ~/documents/ta/)	175
B.5	Perintah verifikasi tujuan T-4 (dari ~/documents/ta/)	176

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
p50	Persentil ke-50 atau median dari distribusi latensi permintaan, dipakai sebagai acuan latensi tipikal.	Bab VI
p95	Persentil ke-95 dari distribusi latensi permintaan, dipakai sebagai acuan latensi tinggi di luar kondisi tipikal.	Bab VI
p99	Persentil ke-99 dari distribusi latensi permintaan, dipakai sebagai indikator <i>tail latency</i> pada SLO layanan <i>inference</i> .	Bab IV

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
ACID	<i>Atomicity, Consistency, Isolation, Durability</i> , sifat transaksi basis data.	Bab II
AGPL	<i>GNU Affero General Public License</i> , lisensi <i>copyleft</i> kuat yang juga mencakup penggunaan melalui jaringan.	Bab IV
ANN	<i>Approximate Nearest Neighbor</i> , kelas algoritma yang mencari vektor terdekat secara aproksimasi pada ruang <i>embedding</i> .	Bab II
API	<i>Application Programming Interface</i> .	Bab I
APISIX	Apache APISIX, <i>API gateway</i> berbasis Nginx dan etcd.	Bab II
ASF	<i>Apache Software Foundation</i> , yayasan nirlaba yang menaungi proyek <i>open source</i> Apache.	Bab IV
BSD	<i>Berkeley Software Distribution</i> , keluarga lisensi permisif perangkat lunak.	Bab IV
BSL	<i>Business Source License</i> , lisensi <i>source-available</i> dengan pembatasan pemakaian komersial.	Bab IV
BUSL	Penulisan SPDX untuk <i>Business Source License</i> versi 1.1.	Bab IV
CD	<i>Continuous Delivery</i> atau <i>Continuous Deployment</i> .	Bab I
CDC	<i>Change Data Capture</i> , teknik penangkapan perubahan data pada basis data sumber.	Bab II
CI	<i>Continuous Integration</i> .	Bab II
CNCF	<i>Cloud Native Computing Foundation</i> , yayasan yang menaungi proyek <i>cloud native</i> di bawah Linux Foundation.	Bab II
CNPG	<i>CloudNativePG</i> , operator Kubernetes untuk PostgreSQL.	Bab IV
CPU	<i>Central Processing Unit</i> .	Bab II
CR	<i>Custom Resource</i> , objek konkret yang dibuat dari sebuah CRD pada Kubernetes.	Bab V

CRD	<i>Custom Resource Definition</i> , definisi tipe sumber daya kustom pada Kubernetes.	Bab II
CT	<i>Continuous Training</i> , model training secara berkelanjutan dengan pemicu <i>drift</i> atau jadwal.	Bab II
DAG	<i>Directed Acyclic Graph</i> , graf berarah tanpa siklus untuk menyusun urutan tugas pada <i>orchestrator</i> .	Bab III
DSRM	<i>Design Science Research Methodology</i> , <i>framework</i> metodologi penelitian rekayasa artefak.	Bab I
eBPF	<i>extended Berkeley Packet Filter</i> , mekanisme menjalankan program tervalidasi di dalam kernel Linux.	Bab II
ECB	<i>European Central Bank</i> , sumber kurs referensi EUR ke USD.	Bab VI
ESO	<i>External Secrets Operator</i> , operator Kubernetes penyinkron <i>secret</i> dari <i>secret manager</i> eksternal.	Bab IV
FTE	<i>Full-Time Equivalent</i> , satuan alokasi penuh satu tenaga kerja per bulan.	Bab VI
GMS	<i>Generalized Metadata Service</i> , komponen layanan metadata inti pada DataHub.	Bab V
GPU	<i>Graphics Processing Unit</i> .	Bab II
gRPC	<i>gRPC Remote Procedure Call</i> , <i>framework</i> pemanggilan prosedur jarak jauh berbasis HTTP/2.	Bab III
HNSW	<i>Hierarchical Navigable Small World</i> , struktur graf untuk ANN.	Bab II
HPA	<i>Horizontal Pod Autoscaler</i> , kontrol <i>scaling</i> jumlah <i>pod</i> pada Kubernetes.	Bab II
HTML	<i>HyperText Markup Language</i> .	Bab IV
JISDOR	<i>Jakarta Interbank Spot Dollar Rate</i> , kurs referensi Bank Indonesia untuk USD ke IDR.	Bab VI
JSON	<i>JavaScript Object Notation</i> .	Bab II
KEDA	<i>Kubernetes Event-driven Autoscaling</i> , <i>autoscaler</i> berbasis sinyal eksternal.	Bab II

KES	<i>Key Encryption Service</i> , layanan kunci enkripsi sisi <i>server</i> untuk MinIO.	Bab II
KMS	<i>Key Management Service</i> , layanan pengelolaan kunci enkripsi.	Bab II
KS	<i>Kolmogorov-Smirnov test</i> , uji statistik kesetaraan dua distribusi.	Bab II
LF	<i>Linux Foundation</i> , yayasan nirlaba yang menaungi ekosistem proyek <i>open source</i> .	Bab IV
MLOps	<i>Machine Learning Operations</i> , disiplin praktik operasional pengembangan dan <i>model serving</i> untuk model <i>machine learning</i> .	Bab I
MPL	<i>Mozilla Public License</i> , lisensi <i>copyleft</i> lemah berbasis berkas.	Bab IV
mTLS	<i>mutual Transport Layer Security</i> , autentikasi TLS dua arah antar layanan.	Bab II
OIDC	<i>OpenID Connect</i> , protokol identitas berbasis OAuth 2.0.	Bab II
OLAP	<i>Online Analytical Processing</i> , pemrosesan kueri analitis pada data bervolume besar.	Bab IV
ONNX	<i>Open Neural Network Exchange</i> , format <i>trade-off</i> model lintas <i>framework</i> .	Bab IV
PSI	<i>Population Stability Index</i> , metrik pergeseran distribusi fitur antar dua periode.	Bab II
REST	<i>Representational State Transfer</i> .	Bab II
RPO	<i>Recovery Point Objective</i> , batas maksimum kehilangan data yang dapat ditoleransi saat pemulihan.	Bab VI
RTO	<i>Recovery Time Objective</i> , batas maksimum waktu pemulihan layanan setelah gangguan.	Bab VI
SDK	<i>Software Development Kit</i> .	Bab III
SLO	<i>Service Level Objective</i> .	Bab II
SQL	<i>Structured Query Language</i> .	Bab II
SSO	<i>Single Sign-On</i> , autentikasi tunggal untuk banyak aplikasi.	Bab VI
TLS	<i>Transport Layer Security</i> .	Bab I
VPA	<i>Vertical Pod Autoscaler</i> , kontrol penyetelan <i>request/limit</i> sumber daya <i>pod</i> .	Bab II

YAML

YAML Ain't Markup Language, format serialisasi data untuk berkas konfigurasi.

Bab II

BAB I

PENDAHULUAN

Bab ini meletakkan dasar bagi keseluruhan laporan Tugas Akhir. Pembahasan dibuka dengan latar belakang yang memetakan tekanan praktik DataOps dan MLOps pada lingkungan produksi, kemudian diturunkan menjadi empat rumusan masalah dan empat tujuan yang saling berpasangan. Batasan masalah menetapkan lingkup pengerjaan, metodologi menjelaskan *framework Design Science Research Methodology* yang diikuti, dan sistematika penulisan menutup bab dengan peta isi laporan. Penomoran RM-1 hingga RM-4, T-1 hingga T-4, serta batasan penelitian BP-1 hingga BP-3 yang diperkenalkan pada bab ini menjadi rujukan tetap bagi seluruh bab berikutnya, sedangkan batasan implementasi BI-1 dan BI-2 diperkenalkan bersama lingkungan implementasi pada Bab V.

I.1 Latar Belakang

Keberhasilan *machine learning* pada lingkungan produksi ditentukan oleh kemampuan memindahkan model dari eksperimen ke layanan yang stabil, terpantau, dan dapat diperbarui, bukan oleh ketepatan model semata. Sculley dkk. (2015) menunjukkan kode model hanya sebagian kecil dari sistem nyata, sedangkan sisanya berupa pengelolaan data, konfigurasi, pemantauan, *serving*, dan *lineage*. Paleyes, Urma, dan Lawrence (2022) memetakan tantangan *deployment* dari kualitas data hingga pemeliharaan model, sementara adaptasi DevOps oleh komunitas *machine learning* melahirkan MLOps (Kreuzberger, Köhl, dan Hirschl 2023) dan DataOps tumbuh serupa untuk *pipeline* data. Rella (2022) mencatat keduanya berbagi prinsip otomasi yang sama tetapi kerap berjalan sebagai dua *tech stack* terpisah, sedangkan Jain dan Das (2025) menempatkan integrasinya sebagai syarat *pipeline* yang skalabel dan tangguh. Upaya integrasi tersebut dihadapkan pada dua tekanan utama yang, ketika tidak teratasi, memicu tekanan ketiga berupa efek domino.

1. Beban membangun platform dari awal di atas kumpulan komponen yang terfragmentasi

Kajian sistematis Amou Najafabadi dkk. (2024) atas 43 studi primer mengategorikan 35 komponen arsitektur MLOps beserta ragam *tool* pendukungnya, menandai luasnya ruang pilihan sebelum satu platform utuh terbentuk. Burgueño-Romero dkk. (2025) menambahkan bahwa komponen *open source* MLOps cenderung berdiri sendiri alih-alih membentuk *framework* kohesif,

sehingga upaya integrasi, kurva belajar, dan penyelarasan versi ditanggung tim pemakai sejak awal.

2. **Biaya berlangganan layanan terkelola dan *trade-off* antara waktu pengembangan dan biaya operasional**

Layanan terkelola (*managed services*) mempercepat adopsi (Li dkk. 2023), tetapi studi empiris Hamza, Akbar, dan Capilla (2024) menemukan bahwa penagihan *pay-as-you-go* dan pelaporan biaya *cloud* yang tidak transparan menyulitkan estimasi anggaran dan dapat menjadi tidak hemat pada beban besar, sejalan dengan Adusumilli (2025). Ditambah pula risiko *vendor lock-in* (Mo dkk. 2023), organisasi terjebak antara membangun tim platform dengan waktu pengembangan panjang atau berlangganan dengan biaya sulit diestimasi dan ruang kustomisasi yang sempit.

3. **Efek domino fragmentasi yang merambat ke seluruh rantai DataOps dan MLOps**

Ketika kedua tekanan tidak terjawab oleh satu *control plane*, sambungan yang terputus antar *layer ingestion*, fitur, *training*, dan *serving* memaksa integrasi dirakit ulang tiap proyek. Pada saat yang sama, metadata, identitas, dan *lineage* dikelola sendiri-sendiri sehingga asal data sulit ditelusuri dan nilai fitur rawan berbeda antara *training* dan *serving*. Shankar dkk. (2022) mendokumentasikan lewat wawancara delapan belas insinyur bahwa pemeliharaan *pipeline* dan integrasi antar komponen menjadi keluhan berulang, dengan rincian per *layer* pada Bab III.

Gabungan ketiga tekanan itu menggerakkan pengembangan platform yang menyatukan DataOps dan MLOps di atas Kubernetes dengan komponen *open source*. Kubernetes dipilih sebagai standar *de facto* orkestrasi *cloud-native* yang teradopsi luas di lingkungan *enterprise* (Lakka 2025), sedangkan komponen *open source* membuat arsitektur dapat ditiru tanpa *vendor lock-in* sekaligus menghapus biaya lisensi. Rancangan dijaga *domain-agnostic* agar dapat diadaptasi lintas domain tanpa mengubah *control plane*, dengan keluaran empat *sub-sistem* pemutus rantai fragmentasi. Seluruh komponen ditata pada repositori Git internal dengan *operator* GitOps sebagai mekanisme rekonsiliasi deklaratif, sehingga sembilan *layer* arsitektur, dari orkestrasi hingga keamanan platform, terhubung pada satu *GitOps flow* yang dirinci pada Bab IV.

I.2 Rumusan Masalah

Latar belakang di atas mengarah pada empat rumusan masalah yang ingin diselesaikan oleh platform yang dikembangkan. Butir-butir tersebut dirumuskan sebagai pertanyaan agar setiap permasalahan memiliki batas teknis yang jelas dan rute jawaban berupa *sub-sistem* atau kontrak antar komponen pada bab-bab berikutnya. Setiap pertanyaan menyoroti properti sistem yang belum terpenuhi, bukan ketiadaan satu *tool* tertentu, agar jawabannya berlaku lintas pilihan komponen dan menjaga sifat *domain-agnostic* platform. Rumusan di bawah ini selanjutnya dirujuk dengan singkatan RM-1 hingga RM-4 pada bab-bab berikutnya.

1. Bagaimana menyatukan *tech stack* DataOps dan MLOps yang terfragmentasi pada *layer ingestion, processing, storage, training, dan model serving* ke dalam satu *control plane* pada Kubernetes?
2. Bagaimana mewujudkan tata kelola data yang konsisten lintas siklus data, fitur, dan model sehingga katalog metadata, *lineage*, dan kontrol kualitas tidak menjadi proses yang ditambahkan belakangan?
3. Bagaimana mengotomasi deteksi *drift* dan menjamin *point-in-time correctness* agar tidak terjadi *temporal leakage* antara mode *batch* dan *streaming*?
4. Bagaimana melayani fitur multimodal, yang mencakup *tabular feature, aggregate feature*, dan *vector embedding* berdimensi tinggi, dari satu *single source of truth* dengan nilai yang konsisten antara fase *training* dan *serving*?

Secara berurutan, keempat rumusan masalah di atas dijawab oleh empat tujuan pada Subbab I.3, dengan rincian kebutuhan fungsional dan nonfungsional diturunkan pada Bab III. Rumusan-rumusan itu tidak saling tumpang tindih karena masing-masing menyoroti satu titik kegagalan yang berbeda, yaitu perakitan lintas *layer*, tata kelola data, deteksi *drift* beserta pencegahan *temporal leakage*, dan *feature serving* multimodal, sekaligus mencakup rentang dari siklus data hingga *model serving*. Karena dirumuskan dengan batas teknis yang jelas dan berpijak pada kegagalan yang terdokumentasi pada latar belakang, keempat rumusan menjadi acuan tetap yang jawabannya ditunjukkan melalui artefak yang berjalan. Pemenuhan tiap rumusan ditelusuri kembali pada Bab VI melalui skenario uji yang menautkan rumusan dengan bukti verifikasinya.

I.3 Tujuan

Penelitian ini merumuskan empat tujuan yang masing-masing menjawab satu rumusan masalah, dengan keluaran berupa artefak teknis yang dapat ditunjukkan dan dipakai ulang. Setiap tujuan menetapkan keluaran berupa rancangan arsitektur, ma-

nifes *deployment* pada repositori Gitea, dan kontrak antar komponen yang dapat diuji pada *use case* verifikasi. Singkatan T-1 hingga T-4 dipakai untuk merujuk keempat tujuan di bawah ini pada bab-bab berikutnya, dengan pemetaan satu lawan satu terhadap RM-1 hingga RM-4. Tiap tujuan dirumuskan sebagai tindakan merancang dan mewujudkan artefak yang dapat ditunjukkan, bukan sebagai aktivitas mengukur atau menguji.

1. Merancang dan mewujudkan arsitektur platform DataOps dan MLOps terintegrasi di atas Kubernetes yang menyatukan *data ingestion*, *processing*, *storage* dan *feature store*, *training*, *model serving*, serta *governance* dan *observability* pada satu *control plane* deklaratif dengan praktik GitOps, menjawab RM-1.
2. Membangun *sub-sistem* tata kelola data yang menyediakan katalog metadata, perekaman *lineage*, dan kontrol kualitas data sebagai layanan bersama yang dijalankan secara otomatis di seluruh *pipeline* data, fitur, dan model, menjawab RM-2.
3. Mengimplementasikan *sub-sistem* deteksi *drift* terotomasi dengan kebijakan *retraining* berbasis ambang batas serta menjamin *point-in-time correctness* pada *feature serving* lintas mode *batch* dan *streaming*, menjawab RM-3.
4. Mengembangkan layanan fitur *dual-store* yang melayani *tabular feature* dan *aggregate feature* melalui satu kontrak API dengan jaminan konsistensi nilai antara fase *training* dan *serving*, serta melayani *vector embedding* berdimensi tinggi pada indeks vektor terpisah dengan ruang *embedding* yang konsisten pada kedua fase tersebut, menjawab RM-4.

Kriteria keberhasilan keseluruhan platform diukur dari empat sudut yang masing-masing menautkan satu tujuan. Setiap kriteria dirumuskan agar dapat diperiksa pada artefak yang berjalan, bukan pada rancangan di atas kertas. Pemeriksaannya dilakukan melalui skenario uji pada Bab VI dengan penerimaan fungsional dan struktural sesuai lingkup batasan penelitian. Kriteria-kriteria berikut menjadi tolok ukur minimum sebelum platform dinyatakan menjawab rumusan masalah.

1. Seluruh artefak dapat dipasang dari satu repositori Git melalui Argo CD tanpa intervensi manual setelah *bootstrap* awal *cluster* (T-1).
2. Seluruh *pipeline* data, fitur, dan model terdaftar pada katalog metadata dengan *lineage* yang dapat ditelusuri (T-2).
3. Mekanisme deteksi *drift* memicu *retraining* secara otomatis ketika ambang batas dilewati pada *use case* verifikasi (T-3).
4. *Tabular feature* dan *aggregate feature* dilayani melalui satu kontrak API dengan nilai yang konsisten antara penyimpanan *offline* dan *online*, sedang-

an *embedding* dilayani pada indeks vektor terpisah dengan ruang *embedding* yang konsisten antara fase *training* dan *serving* (T-4).

I.4 Batasan Masalah

Batasan masalah pada Tugas Akhir ini menetapkan ruang lingkup yang sengaja tidak dicakup oleh kontribusi penelitian agar penilaian tetap tertuju pada arsitektur platform yang *domain-agnostic*. Karena keluaran utama penelitian adalah arsitektur yang dapat dipakai lintas *use case*, pilihan perwujudan seperti jumlah *node*, *version pinning*, atau sintaks komponen tertentu tidak dimasukkan sebagai batasan penelitian, melainkan dinyatakan sebagai batasan implementasi bersama lingkungan implementasi pada Bab V. Batasan-batasan di bawah ini membatasi klaim pada *control plane* platform, cakupan keamanan antar layanan, dan lingkup evaluasi. Butir-butir tersebut selanjutnya dirujuk dengan singkatan BP-1 hingga BP-3, dan konsekuensinya pada evaluasi dibahas kembali pada Bab VI.

1. Fokus penelitian berada pada *control plane* platform, bukan pengembangan model spesifik, sehingga *use case* domain hanya dipakai sebagai kasus verifikasi rancangan dan pembahasan platform dijaga *domain-agnostic*.
2. Aspek keamanan berfokus pada akses antar layanan internal melalui *mutual TLS* pada *service mesh*, manajemen *secret* terpusat, dan kebijakan jaringan Kubernetes, sedangkan autentikasi pengguna akhir pada *application layer* berada di luar cakupan penelitian.
3. Evaluasi difokuskan pada penerimaan fungsional dan struktural tanpa mencakup *deployment* produksi pada lingkungan *multi-tenant* dengan trafik publik. Pengukuran latensi dan *throughput* pada Bab VI bersifat indikatif pada lingkungan *node* tunggal, sedangkan karakterisasi beban kuantitatif penuh pada skala produksi, seperti titik jenuh *throughput* dan verifikasi skalabilitas horizontal lintas *node*, ditempatkan sebagai arah pengembangan lanjutan.

Konteks pembacaan seluruh laporan, terutama pada Bab III dan Bab VI, berpijak pada ketiga batasan penelitian di atas. Batasan-batasan itu menjaga fokus kontribusi pada *control plane* yang *domain-agnostic* sehingga keberlakuan rancangan tidak terikat pada satu domain maupun satu lingkungan perwujudan. Pilihan perwujudan yang dapat diganti tanpa mengubah kontribusi, yaitu lingkungan k3s satu *node* dan *version pinning* April 2026, dinyatakan sebagai batasan implementasi BI-1 dan BI-2 pada Bab V. Dengan pemisahan ini, keterbatasan lingkungan pengujian tidak membatasi keberlakuan arsitektur yang dirancang.

I.5 Metodologi

Penelitian ini mengikuti *framework Design Science Research Methodology* (DSRM) yang dirumuskan oleh Peffers dkk. (2007) untuk penelitian sistem informasi yang menghasilkan artefak. Keluaran utama Tugas Akhir ini berupa platform yang berjalan, yaitu artefak jenis instansiasi (*instantiation*) dalam taksonomi *design science*, sehingga *framework* penelitian berorientasi artefak menjadi pilihan yang tepat (Hevner dkk. 2004). DSRM dipilih dibandingkan metodologi rekayasa perangkat lunak murni karena DSRM menempatkan iterasi antara perancangan, demonstrasi, dan evaluasi sebagai bagian inti proses penelitian, bukan sekadar tahapan pengembangan. *Framework* proses *data science* seperti CRISP-DM dan TDSP tidak menjadi pilihan karena keduanya menata pembangunan satu model pada satu domain data, sedangkan keluaran Tugas Akhir ini adalah platform lintas domain, dengan model hanya sebagai salah satu *workload* yang dilayani. Tahapan yang dijalankan meliputi enam fase berikut dengan keluaran teknis yang dapat diukur.

1. Identifikasi masalah dan motivasi

Studi literatur DataOps, MLOps, dan tata kelola data dilakukan untuk menyusun peta tantangan. Fase ini menghasilkan tiga pemicu dan empat rumusan masalah (RM-1 sampai RM-4).

2. Penetapan tujuan artefak

Tujuan dirumuskan sebagai daftar artefak teknis yang dapat dipasang, dioperasikan, dan diaudit, dipetakan satu lawan satu terhadap rumusan masalah. Kebutuhan fungsional KF-01 sampai KF-14 dan kebutuhan nonfungsional KNF-01 sampai KNF-12 disusun pada Bab III.

3. Perancangan dan pengembangan artefak

Himpunan layanan representatif diklasifikasikan dari praktik industri menjadi sembilan *layer* platform, komponen *open source* dipilih untuk tiap *layer*, lalu arsitektur kesembilan *layer* tersebut dirancang sebagai *control plane* deklaratif berbasis Kubernetes, bertolak dari alternatif arsitektur terpilih hasil matriks evaluasi multi-kriteria pada Bab III. Pengembangan manifes dilakukan modular pada repositori Gitea dengan *folder* per komponen dan *overlay* Kustomize.

4. Demonstrasi

Platform dipasang pada lingkungan k3s dan diberi *workload* dari satu *use case* domain nyata sebagai kasus verifikasi, yang dirinci pada Bab VI. Demonstrasi diatur sebagai empat tahap iteratif, dengan setiap tahap memvalidasi satu *sub-*

sistem sesuai T-1 hingga T-4.

5. Evaluasi

Evaluasi dilaksanakan pada akhir siklus implementasi dengan tiga dimensi, yaitu fungsional, nonfungsional (latensi indikatif, skalabilitas struktural, ketersediaan, observabilitas, keamanan, biaya), serta tata kelola (*lineage* tertelusur, kontrak data ditegakkan, kebijakan akses dapat diaudit). Angka kuantitatif evaluasi dilaporkan pada Bab VI.

6. Komunikasi

Hasil rancangan dan implementasi didokumentasikan pada laporan ini, beserta repositori Gitea yang menjadi acuan reproduksi. Keluaran fase ini berupa laporan, repositori sumber, dan presentasi ujian akhir.

Rangkaian enam fase di atas dijalankan secara iteratif, dengan kemungkinan kembali ke fase sebelumnya ketika temuan baru muncul pada fase berikutnya. Iterasi tersebut sejalan dengan karakter DSRM sebagai metodologi berorientasi artefak yang menempatkan umpan balik dari demonstrasi dan evaluasi sebagai pemicu perbaikan rancangan. Pola pengembangan serupa, yaitu membangun platform atau *pipeline* MLOps berbasis Kubernetes lalu menilainya melalui demonstrasi dan eksperimen, dipakai oleh Hsu dkk. (2024) dan Rodrigues dkk. (2025). Pelaporan tiap fase disusun pada bab yang sesuai sehingga keterhubungan antara fase metodologi dan struktur laporan tetap eksplisit.

I.6 Sistematika Penulisan

Laporan Tugas Akhir disusun atas tujuh bab dengan urutan yang mengikuti DSRM dan praktik pelaporan rekayasa perangkat lunak. Pemetaan antara rumusan masalah, tujuan, *sub-sistem*, dan butir kesimpulan dijaga konsisten lewat penomoran RM-N, T-N, dan butir pada Bab IV hingga Bab VII. Bab IV dan Bab V membentuk pasangan perancangan dan implementasi yang dibaca berurutan, sedangkan Bab VI dan Bab VII menutup siklus dengan evaluasi serta kesimpulan dan saran. Urutan bab beserta isi utamanya dirinci pada poin-poin berikut.

1. Bab I Pendahuluan

Memuat latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi penelitian, serta sistematika penulisan.

2. Bab II Studi Literatur

Meninjau konsep DataOps dan MLOps, Kubernetes, manajemen data, layanan fitur, *model lifecycle*, tata kelola data, deteksi *drift*, observabilitas, praktik

GitOps, dan keamanan platform sebagai landasan teoretis, lalu mengidentifikasi kesenjangan pada penelitian terkait.

3. **Bab III Analisis Masalah**

Memetakan kondisi sistem dan menyusun kebutuhan fungsional KF-01 hingga KF-14 serta kebutuhan nonfungsional KNF-01 hingga KNF-12 sebagai turunan empat tujuan. Matriks evaluasi multi-kriteria membandingkan empat alternatif arsitektur, lalu posisi platform terhadap penelitian terkait dipetakan berdasarkan kebutuhan yang sama.

4. **Bab IV Perancangan Arsitektur Platform DataOps dan MLOps**

Menetapkan sembilan *layer* platform representatif dari praktik industri, memilih komponen *open source* untuk tiap *layer*, lalu menjabarkan perancangan arsitektur kesembilan *layer* dan empat *sub-sistem* yang menjawab T-1 hingga T-4. Diagram arsitektur disajikan sebagai satu arsitektur layanan terintegrasi beserta rincian *tool* per *layer*.

5. **Bab V Implementasi Arsitektur Platform DataOps dan MLOps**

Memaparkan implementasi tiap *sub-sistem* yang sejalan dengan Bab IV, dengan praktik GitOps melalui Argo CD pada repositori Gitea sebagai *single source of truth*.

6. **Bab VI Evaluasi**

Berisi metode evaluasi, hasil pengukuran, dan pembahasan terhadap kebutuhan fungsional dan nonfungsional pada Bab III, serta perbandingan biaya infrastruktur dan tenaga kerja terhadap skenario layanan terkelola.

7. **Bab VII Penutup**

Menyimpulkan jawaban atas T-1 hingga T-4 dan memberikan saran pengembangan lanjutan untuk lingkungan *multi-node* dan multi-domain.

Setelah Bab VII, dokumen ditutup oleh Daftar Pustaka yang memuat seluruh referensi terkutip dan Lampiran yang memuat berkas pendukung. Daftar Pustaka memakai gaya *Chicago author-date* (`bibtex-chicago`) dengan label Indonesia agar konsisten dengan tubuh laporan. Lampiran memuat parameter penilaian pemilihan *open source tools* dan katalog perintah verifikasi *use case*. Penomoran lampiran mengikuti abjad (Lampiran A dan B) sebagaimana konvensi laporan Tugas Akhir di STI ITB.

BAB II

STUDI LITERATUR

Bab ini merangkum landasan teori dan ekosistem perangkat lunak yang relevan untuk perancangan platform pada Bab IV. Tinjauan disusun mulai dari konsep DataOps dan MLOps, dilanjutkan dengan komponen teknis yang menjadi bahan baku perancangan, kemudian ditutup dengan posisi penelitian terdahulu dan kebaruan yang ditawarkan. Susunan ini mengikuti urutan *layer* arsitektur platform, dari orkestrasi infrastruktur, *data flow*, layanan fitur, dan *model lifecycle*, hingga tata kelola, deteksi *drift*, observabilitas, praktik GitOps, dan keamanan, sebagaimana dirinci pada Bab IV. Sumber rujukan menggabungkan publikasi akademik dengan dokumentasi resmi komponen *open source* agar setiap pilihan teknis dapat ditelusuri ke spesifikasi sumber.


Setiap subbab teknis memperkenalkan konsep *layer* tersebut, menautkannya ke rujukan akademik, lalu menyebut beberapa *open source tools* sebagai contoh perwujudan. Perbandingan berskor antar *tools* dan pemilihan komponen konkret tidak dibahas pada bab ini, melainkan pada Subbab IV.2 di Bab IV yang menilai tiap *tool* terhadap kriteria kelayakan platform. Pemisahan ini menjaga bab ini tetap membahas konsep secara umum, sementara keputusan pemilihan *tools* ditegakkan pada bab perancangan dengan bukti skor. Dengan begitu, keputusan teknis pada Bab IV dan Bab V dapat ditelusuri dari konsep pada bab ini ke pemilihan *tools* pada bab perancangan.

II.1 DataOps dan MLOps

Penelitian ini berpusat pada dua disiplin operasional yang diuraikan terlebih dahulu sebelum komponen teknis pendukungnya. DataOps dibahas tuntas lebih dahulu, dari definisi, pilar operasinya, sampai model evolusi kematangannya, baru kemudian MLOps dengan urutan yang sama dari definisi sampai *framework* tingkat kematangannya. Urutan satu arah ini dipilih agar tiap disiplin selesai dibahas sebelum pindah ke disiplin berikutnya, dan kedua *framework* kematangan tetap dipakai untuk menempatkan kondisi awal serta target kapabilitas platform pada jenjang yang dapat diukur. Subbab penutup membahas integrasi kedua disiplin yang menjadi celah penelitian sekaligus posisi platform ini.

II.1.1 DataOps

DataOps merupakan adaptasi praktik DevOps untuk *data lifecycle*. Munappy dkk. (2020) mendefinisikan DataOps sebagai pendekatan yang mengadopsi praktik *agile* dan DevOps serta mengandalkan otomatisasi tahapan *data lifecycle* untuk mempercepat penyediaan hasil analitik yang berkualitas. Kleppmann (2017) memberi fondasi konseptual lewat penjelasan tentang sistem berbasis data yang andal, dapat diskalakan, dan dapat dipelihara, sementara Stopford (2018) memperkenalkan pola arsitektur *event-driven* dengan Apache Kafka sebagai tulang punggung. Pada praktiknya, DataOps menuntut otomatisasi *pipeline ingestion* dan transformasi, pengujian kontrak data, perekaman *lineage*, dan pemantauan kualitas data sebagai bagian permanen dari operasi. Bentuk industrial rangkaian tahapan tersebut terdokumentasi pada *big data analytics pipeline* di Ericsson, tempat data dari sumber internal dan eksternal mengalir melalui *data ingestion*, agregasi, penyimpanan, hingga visualisasi bagi pemangku kepentingan, sebagaimana diperlihatkan pada Gambar II.1.




Gambar II.1 *Big data analytics pipeline* pada Ericsson (Munappy dkk. 2020)

Operasi DataOps bertumpu pada empat pilar, yaitu otomatisasi *pipeline*, kontrak skema, pengujian kualitas data, dan pemantauan SLO. Contoh perwujudan *open source* keempat pilar itu berturut-turut adalah Apache Airflow untuk orkestrasi *batch* terjadwal, Karapace sebagai *schema registry*, Great Expectations sebagai *quality gate* pada *pipeline*, dan Sloth yang menurunkan SLO menjadi aturan Prometheus. Polyzotis dkk. (2018) merinci praktik validasi data berkelanjutan yang menyatu dengan *pipeline machine learning*, mencakup pemeriksaan skema, rentang nilai, dan anomali distribusi pada setiap proses *ingestion*. Kombinasi keempat pilar tersebut menjadi prasyarat bagi integrasi DataOps dan MLOps yang dibahas pada Subbab II.1.3.

Jenjang kematangan praktik DataOps digambarkan oleh model evolusi yang disusun Munappy dkk. (2020) dari studi kasus industri telekomunikasi, berbentuk tangga lima tahap, yaitu analisis data ad hoc, analisis data semi-otomatis dengan *pipeline*

data, praktik *agile data science*, pengujian dan pemantauan berkelanjutan, lalu DataOps. Tangga evolusi tersebut beserta komponen studi kasus yang terakumulasi pada tiap tahapnya diperlihatkan pada Gambar II.2. Tahap awal model tersebut ditandai silo data, keputusan bisnis yang hanya bertumpu pada sebagian kecil data, dan pemantauan *pipeline* yang masih manual. Tahap akhirnya menuntut CI/CD untuk analitik data, orkestrasi *pipeline*, dan pemantauan seluruh *data lifecycle*.



Gambar II.2 Model evolusi DataOps lima tahap (Munappy dkk. 2020)

Model evolusi tersebut mencakup lima tahap dengan karakteristik dan kebutuhan yang berbeda saat sebuah organisasi menaiki tangga menuju DataOps. Tahap *ad-hoc data analysis* masih bertumpu pada pengumpulan data manual dan *data silos*, tahap *semi-automated data analysis* memperkenalkan *data pipelines* beserta *data technologies*, tahap *agile data science* menyelaraskan pengembangan dengan metodologi *agile* dan DevOps, tahap *continuous testing and monitoring* menambahkan pengujian dan pemantauan *pipeline* berkelanjutan, dan tahap DataOps memadukan *value pipelines* serta *innovation pipelines* dengan orkestrasi penuh. Tabel II.1 merinci karakteristik dan kebutuhan kunci tiap tahap sebagaimana disusun Munappy dkk. (2020) dari studi kasus industri telekomunikasi di Ericsson. Rincian per tahap ini menjadi acuan sisi data ketika perpindahan kematangan platform dinilai pada bab-bab berikutnya.

Tabel II.1 Karakteristik dan Kebutuhan Tiap Tahap Model Evolusi DataOps

Tahap	Karakteristik	Kebutuhan Kunci
Stage 1 <i>Ad-hoc data analysis</i>	Laporan dan <i>insight</i> dibuat <i>on-demand</i> serta sangat disesuaikan untuk menjawab satu pertanyaan bisnis spesifik. Pengumpulan data masih manual dan bergantung pada templat departemen teknologi informasi, sehingga muncul <i>data silos</i> dan keputusan bisnis bertumpu pada sebagian kecil data.	Teknologi untuk mengumpulkan data <i>real-time</i> dari banyak sumber data.
Stage 2 <i>Semi-automated data analysis</i>	<i>Data pipelines</i> mengumpulkan dan memproses data secara lebih efisien dan otomatis, didukung <i>data technologies</i> (<i>data engineering, data preparation, data storage, data visualization</i>) dan <i>data processes</i> . Sebagian aktivitas belum otomatis dan pemantauan masih manual.	<i>Data pipelines</i> yang dirancang baik untuk mengevaluasi, menguji, memuat, mentransformasi, memvalidasi, dan mempublikasikan data pada skala besar, beserta <i>data technologies</i> dan <i>data processes</i> untuk mengoordinasikannya.
Stage 3 <i>Agile data science</i>	<i>Development</i> dan <i>deployment</i> diatur metodologi <i>agile</i> dan DevOps sehingga kode teruji penuh dihasilkan dalam waktu singkat dan disimpan pada repositori pusat bersama. <i>Insight</i> dikirim dalam <i>sprint</i> pendek dengan umpan balik pelanggan berkala.	<i>Continuous delivery</i> nilai bisnis ke pelanggan serta penanganan kebutuhan pelanggan yang berkembang melalui komunikasi langsung dengan tim data.
Stage 4 <i>Continuous testing and monitoring</i>	Pengujian dan pemantauan <i>pipeline</i> berkelanjutan untuk mendeteksi masalah lebih awal sebelum menjalar ke tahap berikutnya. Dilengkapi <i>automated unit tests</i> , pengujian tingkat lebih tinggi, dan <i>automated alerts</i> saat <i>pipeline</i> rusak.	<i>Test cases</i> untuk menguji kualitas data, mekanisme pemantauan berkelanjutan dan <i>alerting</i> otomatis, serta strategi mitigasi untuk menangani <i>pipeline breakage</i> .
Stage 5 <i>DataOps</i>	Memperpendek <i>end-to-end cycle time</i> analitik data dari ide hingga <i>insight</i> dengan menggabungkan praktik <i>agile</i> dan prinsip DevOps untuk mengelola artefak berupa data, metadata, dan kode. Memadukan <i>value pipelines</i> dan <i>innovation pipelines</i> yang menuntut orkestrasi, otomasi, dan kolaborasi.	<i>Continuous integration</i> dan <i>continuous delivery</i> untuk analitik data, mekanisme memantau dan mengendalikan seluruh <i>data life cycle</i> , serta orkestrasi dengan otomasi lanjutan dan praktik <i>agile</i> .

Sumber: Munappy dkk. (2020). Nama tahap dipertahankan dalam bahasa asli sesuai dokumen sumber.

Di samping model akademik tersebut, praktik industri menawarkan model kematangan DataOps dengan sudut pandang yang berbeda. DataKitchen (2020) menyusun *DataOps Maturity Model* berupa lima *level* kematangan dari *struggle* hingga *optimized* yang dinilai pada enam dimensi organisasi, yaitu *error rates*, *cycle time*, *collaboration*, *measurement*, *team culture*, dan *customer happiness*, dengan kapabilitas kunci berupa pengujian otomatis, pemantauan, orkestrasi *toolchain*, kendali versi, dan *continuous deployment*. Harrington (2023) menguraikan empat tahap kematangan DataOps untuk data industrial manufaktur, dari *data access* hingga *enterprise visibility*, yang menekankan cakupan integrasi data alih-alih kapabilitas proses. Objek penilaian berbeda pada ketiga model, yaitu evolusi kapabilitas *pipeline* data, asesmen organisasi pada enam dimensi, dan cakupan integrasi data, sehingga pemetaan skor kapabilitas lintas model tidak diterapkan agar tidak memaksakan padanan yang tidak dinyatakan sumbernya. Tabel II.2 merangkum perbandingan ketiganya pada tataran deskriptif. Meskipun objek penilaiannya berbeda, ketiganya menempatkan kendali menyeluruh pada tingkat tertinggi, sebab tahap DataOps menuntut mekanisme pemantauan dan kendali seluruh *data lifecycle*, *level quantitative* dan *optimized* menuntut proses yang terukur, terkendali, lalu terus diperbaiki, dan tahap *enterprise visibility* menuntut *data governance* dengan data yang tersinkron lintas situs. Konvergensi ini sejalan dengan penempatan tata kelola dan observabilitas sebagai *layer* lintas fungsi pada rancangan platform di Bab IV. Sisi DataOps laporan ini tetap ditambatkan pada model evolusi Munappy dkk. (2020) karena model tersebut ditelaah sejawat, berpijak pada studi kasus industri, dan berfokus pada kapabilitas *pipeline* data yang selaras dengan lingkup platform.

Tabel II.2 Perbandingan Model Kematangan DataOps

Model	Tahap atau <i>Level</i>	Fokus Penilaian	Lingkup dan Jenis Sumber
Model evolusi DataOps (Munappy dkk. 2020)	Lima tahap: <i>ad-hoc data analysis</i> , <i>semi-automated data analysis</i> , <i>agile data science</i> , <i>continuous testing and monitoring</i> , dan DataOps	Evolusi kapabilitas <i>data pipeline</i> , dari pengumpulan data manual hingga orkestrasi dan pemantauan seluruh <i>data lifecycle</i>	Lintas domain, studi kasus telekomunikasi, makalah telaah sejawat

Model	Tahap atau Level	Fokus Penilaian	Lingkup dan Jenis Sumber
<i>DataOps Maturity Model</i> (DataKitchen 2020)	Lima level per dimensi: <i>struggle, basic, consistent, quantitative, dan optimized</i>	Asesmen organisasi pada enam dimensi: <i>error rates, cycle time, collaboration, measurement, team culture, dan customer happiness</i>	Analitik data umum, <i>white paper</i> vendor
Model kematangan DataOps industrial (Harrington 2023)	Empat tahap: <i>data access, data contextualization, site visibility, dan enterprise visibility</i>	Cakupan integrasi data operasional, dari akses data mesin, kontekstualisasi dan normalisasi data, hingga visibilitas lintas situs dengan <i>data governance</i>	Data industrial manufaktur, artikel vendor

Model-model di atas menilai objek yang berbeda sehingga pemetaan skor kapabilitas lintas model seperti pada Tabel II.4 tidak diterapkan. Perbedaan fokus tiap model dibahas pada teks.


II.1.2 MLOps

MLOps memperluas praktik DevOps ke seluruh tahap *model lifecycle machine learning*. Kreuzberger, Kühl, dan Hirschl (2023) memberikan definisi terpadu yang menempatkan MLOps sebagai gabungan budaya kerja dan perangkat lunak untuk mengotomasi eksperimen, *training*, evaluasi, *deployment*, dan pemantauan model. Sculley dkk. (2015) menjelaskan akar persoalannya berupa *hidden technical debt* pada sistem *machine learning* yang muncul terutama dari komponen non-model seperti *feature engineering*, konfigurasi, perekaman, pengujian data, dan layanan pemantauan. Paleyes, Urma, dan Lawrence (2022) melengkapi pemetaan dengan survei tantangan operasionalisasi, dan Shankar dkk. (2022) membawa perspektif praktisi melalui wawancara dengan tim MLOps lintas industri.

MLOps dibedakan dari DevOps tradisional oleh tiga karakteristik penting, yaitu *continuous training, continuous monitoring, dan model registry* sebagai sumber rujukan versi model. Amershi dkk. (2019) menggambarkan sembilan tahap rekayasa perangkat lunak *machine learning* mulai dari penentuan kebutuhan model hingga pemantauan, dengan setiap tahap memerlukan dukungan otomasi tersendiri. Breck dkk. (2017) memperkenalkan *rubric* kesiapan produksi yang menjadi acuan banyak tim untuk menilai kematangan *pipeline* mereka. Contoh perwujudan *open source*


ketiga karakteristik tersebut adalah Kubeflow Pipelines untuk *continuous training*, Evidently dan Prometheus untuk *continuous monitoring*, serta MLflow Model Registry sebagai sumber rujukan versi model yang ditelaah ulang pada Subbab II.5.1.

Beberapa *framework* kematangan diusulkan untuk menggambarkan jenjang kapabilitas tim. Google Cloud (2024) membagi MLOps menjadi tiga level, yaitu *level 0* dengan proses manual, *level 1* dengan otomasi *training pipeline*, dan *level 2* dengan otomasi *deployment* berbasis CI/CD/CT. Masing-masing level diilustrasikan pada Gambar II.3, Gambar II.4, dan Gambar II.5, berbeda dari sisi data yang merangkum kelima tahap evolusinya dalam satu diagram tangga pada Gambar II.2 karena sumbernya memang menerbitkan tiga diagram terpisah. Microsoft Azure (2023) memberi varian dengan lima level dari 0 hingga 4, Kartakis dkk. (2022) menguraikan empat fase kematangan dari *initial* hingga *scalable* pada peta jalan MLOps AWS, dan McKnight (2020) menambah perspektif organisasi. Perbandingan ringkas dapat dilihat pada Tabel II.4.




Gambar II.3 MLOps *level 0*: proses manual (Google Cloud 2024)

Perbedaan ketiga *level* tersebut tidak hanya terletak pada keberadaan otomasi, melainkan pada karakteristik proses dan komponen yang menyertai tiap jenjang. *Level 0* bersandar pada proses manual berbasis skrip dengan penyerahan model satu arah tanpa CI maupun CD, *level 1* menambahkan otomasi *training pipeline* beserta validasi data dan model, *metadata management*, dan pemicu *pipeline*, sedangkan *level 2* menuntut orkestrasi CI/CD atas seluruh *pipeline* ML dengan tujuh komponen wajib. Tabel II.3 merinci karakteristik proses dan komponen tiap *level* sebagaimana dirumuskan Google Cloud (2024). Rincian ini menjadi acuan untuk menilai jarak kapabilitas antara kondisi awal dan target arsitektur yang dikembangkan pada bab-bab berikutnya.



Gambar II.4 MLOps *level 1*: otomasi *training pipeline* (Google Cloud 2024)



Gambar II.5 MLOps *level 2*: orkestrasi CI/CD/CT (Google Cloud 2024)

<i>Level</i>	Karakteristik Proses	Komponen
--------------	-----------------------------	-----------------

Tabel II.3 Karakteristik dan Komponen Tiap *Level* Kematangan MLOps

<i>Level</i>	Karakteristik Proses	Komponen
Level 0 <i>Manual process</i>	<i>Manual, script-driven, and interactive process dengan disconnection between ML and operations serta infrequent release iterations. Tanpa CI dan tanpa CD, deployment hanya merujuk pada prediction service, disertai lack of active performance monitoring.</i>	Tanpa komponen otomasi tambahan. Penyerahan model bersifat satu arah dari <i>data scientist</i> ke tim operasi, dan <i>deployment</i> terbatas sebagai <i>prediction service</i> .
Level 1 <i>ML pipeline automation</i>	<i>Rapid experiment, CT of the model in production, dan experimental-operational symmetry. Modularized code for components and pipelines, continuous delivery of models, serta pipeline deployment.</i>	Komponen tambahan yang dituntut <i>level</i> ini, yaitu <i>data and model validation</i> , <i>feature store</i> (opsional), <i>metadata management</i> , dan <i>ML pipeline triggers</i> .
Level 2 <i>CI/CD pipeline automation</i>	Enam tahap otomasi <i>pipeline</i> , yaitu <i>development and experimentation</i> , <i>pipeline continuous integration</i> , <i>pipeline continuous delivery</i> , <i>automated triggering</i> , <i>model continuous delivery</i> , dan <i>monitoring</i> .	Tujuh komponen wajib, yaitu <i>source control</i> , <i>test and build services</i> , <i>deployment services</i> , <i>model registry</i> , <i>feature store</i> , <i>ML metadata store</i> , dan <i>ML pipeline orchestrator</i> .

Sumber: Google Cloud (2024). Istilah teknis dipertahankan dalam bahasa asli sesuai dokumen sumber.

Platform yang dikembangkan menargetkan kematangan setara *level 2* pada *framework* Google Cloud. Target ini menuntut tiga *automation flow* yang bekerja sebagai satu siklus, bukan sekadar tersedianya *tools* pada tiap tahap. Rangkaian itu menutup siklus otomasi dari *training*, *deployment*, hingga pemantauan yang memicu *retraining*. Rincian tiap *flow* pada platform ini adalah sebagai berikut.

1. **Training Pipeline otomatis**

Training pipeline didefinisikan sebagai *pipeline* yang dipicu secara terjadwal maupun ketika ambang *drift* terlampaui.

2. **Deployment model otomatis**

Deployment model dijalankan otomatis dengan versi yang dipromosikan langsung oleh *training pipeline*.

3. **Pemantauan model berkelanjutan**

Pemantauan model dilakukan secara berkelanjutan oleh *job* deteksi *drift* ter-

jadwal yang melaporkan metrik *drift* ke sistem pemantauan serta menyimpan skor historis untuk audit, sebagaimana dirinci pada Subbab II.7.

Ketiga *automation flow* tersebut menjadi acuan implementasi pada Bab V dan dasar evaluasi pada Bab VI. *Training flow* diwujudkan sebagai *pipeline* Kubeflow Pipelines, *deployment flow* sebagai promosi versi pada KServe, dan *monitoring flow* sebagai *job* deteksi *drift* yang melapor ke Prometheus. Penghubung ketiganya adalah CronWorkflow Argo yang membaca skor *drift* dan memanggil *training pipeline* ketika ambang terlampaui. Dengan rantai itu, kematangan *level 2* dapat diperiksa sebagai perilaku sistem, bukan sekadar daftar komponen. Tabel II.4 merangkum posisi keempat *framework* kematangan MLOps tersebut pada enam dimensi kapabilitas.

Tabel II.4 Perbandingan *Framework* Tingkat Kematangan MLOps

Frame- work	Level	DevOps Practices	ML Pipeline Auto- mation	CI/CD Inte- gration	CT (Conti- nuous Training)	Moni- toring & Feedback Loop	Gover- nance & Lineage
GCP	L0	0	0	0	0	0	0
	L1	1	2	1	2	2	2
	L2	2	2	2	2	2	2
Azure	L0	0	0	0	0	0	0
	L1	1	0	1	0	0	0
	L2	1	2	0	2	1	2
	L3	2	2	2	2	1	2
	L4	2	2	2	2	2	2
AWS	Initial	0	0	0	0	0	0
	Repeat- able	1	2	0	2	1	2
	Reliable	2	2	2	2	2	2
	Scalable	2	2	2	2	2	2
Giga Om	L0	0	0	0	0	0	0
	L1	1	1	0	0	1	1
	L2	2	2	2	1	1	2
	L3	2	2	2	2	2	2
	L4	2	2	2	2	2	2

Nilai 0 menandai praktik belum hadir pada *level* tersebut, nilai 1 hadir sebagian atau semi-otomatis, dan nilai 2 otomatis penuh. Nilai dipetakan dari deskripsi terbit tiap *level* mengikuti parameter pada Lampiran A.1.

Laporan ini memakai *framework* kematangan MLOps dan model evolusi DataOps secara berpasangan untuk membingkai kondisi awal dan target platform. Kondisi terfragmentasi pada Gambar III.1 dan Gambar III.2 di Bab III setara dengan *level* 0 sekaligus tahap awal evolusi DataOps. Arsitektur yang dirancang pada Bab IV menargetkan *level* 2 sekaligus tahap DataOps pada tahapan evolusi tersebut. Dengan pasangan ini, perpindahan kapabilitas dapat dinilai pada sisi data dan sisi model sekaligus, bukan hanya pada salah satunya.

II.1.3 Integrasi DataOps dan MLOps

Jain dan Das (2025) menyatakan bahwa integrasi DataOps dan MLOps menjadi prasyarat skalabilitas dan ketahanan *pipeline machine learning* modern. Sementara itu, Burgueño-Romero dkk. (2025) mengusulkan arsitektur MLOps *open source* berbasis komponen, namun cakupannya berfokus pada *model flow* dan belum membahas *feature serving dual-store* maupun kebijakan deteksi *drift* sebagai satu kesatuan dengan *data flow*. Rodrigues dkk. (2025) membahas arsitektur untuk *stream learning* mendekati waktu nyata, dengan penekanan pada deteksi *drift* dan pembaruan model. Penelitian ini berada pada irisan ketiganya, yaitu arsitektur *open source* yang menyatukan DataOps dan MLOps, dengan layanan fitur *dual-store* dan deteksi *drift* terotomasi sebagai komponen inti.

Integrasi tersebut diwujudkan melalui tiga jembatan teknis yang dijelaskan pada Subbab II.4, Subbab II.6.1, dan Subbab II.9.1 serta dirancang pada Bab IV. Jembatan-jembatan itu bekerja pada tiga titik pertemuan antara *data flow* dan *model flow*, yaitu kontrak fitur, katalog *lineage*, dan manifes komponen. Pada tiap titik itu, *DataOps flow* yang memproduksi data dan *MLOps flow* yang mengonsumsinya bersandar pada satu definisi bersama alih-alih kontrak yang dirakit terpisah. Susunan ini menjadikan kontrak antara disiplin data dan disiplin model ditegakkan otomatis dari satu sumber rujukan bersama, bukan dirakit ulang oleh tiap tim secara terpisah.

1. *Feature contract* pada Feast

Feast menyatukan *offline store* dan *online store* dengan satu definisi FeatureView, sehingga *DataOps flow* yang menulis fitur dan *MLOps flow* yang membaca fitur memakai kontrak yang sama.

2. *Lineage* terbuka melalui OpenLineage

OpenLineage menyalurkan jejak transformasi *pipeline* data dari Airflow, termasuk langkah dbt di dalamnya, ke satu *metadata ingestion flow* DataHub sehingga *lineage training dataset* dapat dirunut dari katalog yang sama.

3. *Control Plane* deklaratif Argo CD

Argo CD merekonsiliasi manifes komponen DataOps dan MLOps dari satu repositori Gitea, sehingga kebijakan dan versi komponen tetap konsisten lintas dua disiplin.

II.2 Kubernetes dan Orkestrasi *Cloud-Native*

Seluruh komponen platform berjalan di atas Kubernetes, sehingga karakter *layer* orkestrasi ini perlu dipahami sebelum membahas komponen di atasnya. Pembahasan dibagi dua, yaitu peran Kubernetes beserta objek dasar dan pilihan distribusinya, kemudian mekanisme *autoscaling* beserta ekosistem *operator*. Urutan ini menempatkan konsep dasar sebelum mekanisme yang dibangun di atasnya. Rincian penerapannya pada tiap komponen dibahas pada Bab IV.

II.2.1 Peran, Objek Dasar, dan Distribusi

Kubernetes berperan sebagai *orchestration plane* yang menjalankan *workload* terkontainerisasi pada *cluster* mesin. Lakka (2025) mendokumentasikan adopsi Kubernetes pada skala perusahaan dan menyoroti perannya sebagai standar *de facto cloud-native*. Adusumilli (2025) memperluas perspektif tersebut dengan pola *serverless* di atas Kubernetes, yang relevan untuk *workload inference* dengan pola trafik berfluktuasi. Cloud Native Computing Foundation (2024a) memberikan referensi resmi mengenai objek-objek inti seperti Pod, Deployment, StatefulSet, Service, dan Ingress yang menjadi landasan setiap komponen platform.

Pemilihan Kubernetes sebagai bidang dasar memberi tiga keuntungan teknis, yaitu orkestrasi *workload* melalui objek deklaratif, mekanisme *autoscaling*, dan ekosistem *operator* yang memperluas API *cluster* dengan *Custom Resource Definition* (CRD). Distribusi *lightweight* seperti k3s mengakomodasi pengembangan dan pengujian pada satu *node* tanpa mengorbankan kompatibilitas API. Pilihan distribusi tersebut sejalan dengan batasan implementasi BI-1 pada Bab V bahwa lingkungan pengujian memakai satu *node* dengan *footprint* sumber daya yang ringkas. Mekanisme *cluster autoscaler* tidak diaktifkan pada lingkungan satu *node*, sedangkan HPA, VPA, dan KEDA menjadi mekanisme *scaling workload* yang dipakai.

Selain k3s, distribusi Kubernetes ringan lain yang umum dipertimbangkan untuk lingkungan satu *node* adalah k0s, MicroK8s, dan *kind*. Semua distribusi itu lolos uji *conformance* CNCF (Cloud Native Computing Foundation 2026) sehingga API Kubernetes yang dipakai komponen platform tetap identik, sedangkan perbedaannya

terletak pada *footprint*, kesiapan produksi, dan dependensi *runtime*. Perbedaan itu antara lain *containerd* yang tertanam pada k3s dan k0s, ketergantungan MicroK8s pada *snap*, serta *kind* yang menjalankan *node* di dalam kontainer Docker. Perbandingan berskor keempat distribusi terhadap kriteria kelayakan platform beserta alasan pemilihan k3s dibahas pada Subbab IV.2.

II.2.2 *Autoscaling dan Ekosistem Operator*

Scaling otomatis pada Kubernetes bekerja pada tiga dimensi yang saling melengkapi. Dimensi horizontal menambah atau mengurangi jumlah *replica* suatu *workload* mengikuti metrik pemakaian, dimensi vertikal menyetel *request* sumber daya per *pod* berdasarkan pengukuran historis, dan dimensi berbasis *event* menyesuaikan jumlah pemroses terhadap panjang antrean pada sumber eksternal. Setiap dimensi menjawab pola beban yang berbeda, yaitu lonjakan permintaan, ukuran *pod* yang tidak pas, dan antrean *event* yang menumpuk. Pemisahan dimensi ini membuat kebijakan *scaling* dapat dipasang per *workload* tanpa saling bertabrakan.

Horizontal Pod Autoscaler (HPA) mewujudkan dimensi horizontal pada Deployment dan StatefulSet berdasarkan metrik CPU dan memori yang dipasok oleh Metrics Server. *Vertical Pod Autoscaler* (VPA) (Kubernetes Autoscaling SIG 2025) merekomendasikan dan menyetel *request* sumber daya pada level *pod*, sedangkan KEDA (KEDA Authors 2025) memperluas *scaling* ke sumber *event* eksternal melalui ScaledObject, termasuk *lag* antrean Kafka dan kueri metrik Prometheus. Dengan kombinasi tersebut, jumlah *replica* pemroses *event* mengikuti panjang antrean tanpa campur tangan manual. Pada platform ini, batas bawah *minReplicaCount* dipertahankan satu agar konsumen tetap siaga saat *idle*.

Komponen *operator* dan *runtime layer* menyediakan abstraksi tingkat tinggi bagi perangkat data, model, dan layanan. Strimzi (Strimzi Authors 2025) mengoperasikan *cluster* Apache Kafka beserta *Kafka Connect* melalui CRD seperti *Kafka*, *KafkaUser*, dan *KafkaTopic*. CloudNativePG (CloudNativePG Contributors 2025) mengelola siklus hidup *cluster* PostgreSQL, termasuk pencadangan dan *failover*. *Operator* Apache Flink (Apache Flink Authors 2025) dan *operator* Apache Spark (Apache Spark Authors 2025) menyiapkan *FlinkDeployment* dan *SparkApplication* sebagai unit kerja deklaratif, sedangkan *operator* Altinity untuk ClickHouse (Altinity 2025) menyediakan CRD *ClickHouseInstallation* untuk replikasi dan *sharding*. Pada sisi *runtime*, Knative Serving (Knative Authors 2025) menambah kemampuan *scale-to-zero* pada *workload request-response* dan menjadi fondasi bagi KServe. Kueue (Kueue Authors 2024) menyediakan antrean

kerja untuk *workload batch* sehingga prioritas dan kuota dapat ditegakkan lintas *namespace*. *cert-manager* (*cert-manager Contributors* 2025) mengotomasi penerbitan dan rotasi sertifikat TLS bagi *Ingress* dan *webhook* komponen platform.

II.3 Manajemen Data: *Ingestion, Processing, dan Storage*

Layer manajemen data mencakup *ingress flow* data sampai tempat penyimpanannya. Pembahasan dimulai dari pola arsitektur aliran data, dilanjutkan konsep *ingestion* berbasis *message broker* serta dua pola pemrosesan, yaitu *stream* dan *batch* dengan transformasi SQL. Bahasan *storage layer* berlanjut pada tiga subbab berikutnya, dari format tabel *lakehouse*, penyimpanan objek dengan versi data, hingga penyimpanan relasional dan indeks pencarian. Urutan tersebut mengikuti arah aliran data pada platform, dari *event* masuk sampai data siap dikonsumsi oleh *layer* layanan fitur.

II.3.1 Pola Lambda dan Kappa

Marz dan Warren (2015) memperkenalkan arsitektur Lambda yang memisahkan *batch layer* dan *speed layer*. Kreps (2014) mengkritisi pola tersebut karena menduplikasi logika pemrosesan dan mengusulkan arsitektur Kappa yang menyatukan keduanya menjadi satu *stream-first pipeline*. Amazon Web Services (2024) memberikan rangkuman pola *event-driven* yang banyak diadopsi di lingkungan *cloud-native*. Perbedaan pokok kedua pola terletak pada jumlah *processing pipeline* yang harus dipelihara, sebab Lambda menuntut dua implementasi logika yang sama sedangkan Kappa memakai satu *event log* sebagai sumber *replay*.

Platform ini mengadopsi pola Kappa dengan modifikasi pada *processing layer*, yaitu aliran utama berjalan pada Flink untuk *streaming* sedangkan *backfill* historis dijalankan oleh Spark dan dbt pada referensi waktu yang sama. Pola tersebut menjaga konsistensi temporal antara fitur *streaming* dan fitur *batch* sebagaimana dijabarkan pada Subbab II.4.4. Pendekatan ini juga sejalan dengan rekomendasi Stopford (2018) mengenai *event log* sebagai *single source of truth*. Hasilnya, kebutuhan *re-training* model yang melibatkan data historis dapat dijawab tanpa menyalin data ke *flow* terpisah, sebab *offline store* ClickHouse dipopulasi dari *topic* Kafka yang sama.

II.3.2 Message Broker dan Data Ingestion

Ingestion pipeline pada arsitektur *event-driven* bertumpu pada *message broker* berbentuk *distributed log*, yaitu menyimpan *event* dalam urutan tertentu yang memungkinkan konsumen melakukan *replay* aliran data dari posisi mana pun (Apache Soft-

ware Foundation 2024c). Model *log* tersebut menempatkan *broker* sebagai tulang punggung penghubung antara produsen data dan konsumen pemroses, sejalan dengan posisi *event log* sebagai *single source of truth* pada rancangan sistem *event-driven* (Stopford 2018). Jaminan pengiriman dapat dipilih sesuai kebutuhan konsumen, dari *at-least-once* yang menoleransi duplikat sampai *exactly-once* yang memakai transaksi. Perbedaan antar *broker* pada praktiknya terletak pada jaminan pengiriman, kematangan *operator* Kubernetes, dan model lisensi.

Ingestion pipeline tersebut dilengkapi oleh dua fungsi pendamping. *Schema registry* menyimpan skema pesan dan memverifikasi kompatibilitas saat publikasi, sehingga perubahan skema yang memutus konsumen lama tertahan dan evolusi kontrak data tetap kompatibel dengan versi sebelumnya. *Framework* konektor menjalankan integrasi sumber dan tujuan sebagai *workload* terkelola, termasuk pola *change data capture* (CDC) yang membaca *write-ahead log* basis data dan menerbitkan perubahan baris sebagai *event* sehingga tabel relasional ikut ke *streaming pipeline* tanpa kueri berkala. Antarmuka penelusuran *cluster* melengkapi operasi harian untuk memeriksa *topic*, *consumer group*, dan skema.

Contoh *message broker open source* dengan model *log* tersebut adalah Apache Kafka (Apache Software Foundation 2024c), Redpanda (Redpanda Data, Inc. 2025), Apache Pulsar (Apache Software Foundation 2025), dan NATS JetStream (NATS Authors 2025), dengan Kafka mendukung *at-least-once* secara baku dan *exactly-once* bertransaksi. Contoh *schema registry* pada ekosistem tersebut adalah Karapace (Aiven Karapace Authors 2025), *schema registry* kompatibel-Confluent berlisensi Apache 2.0 yang mendukung Avro, JSON Schema, dan Protobuf serta menyimpan skema pada *topic* internal Kafka sehingga tidak menambah basis data baru. *Framework* konektor diwujudkan oleh Kafka Connect (Apache Software Foundation 2024c). Debezium (Debezium Community 2025) menjadi contoh konektor CDC yang membaca *write-ahead log* PostgreSQL, sedangkan Kafbat UI (Kafbat Authors 2025) menjadi contoh antarmuka penelusuran *cluster*. Perbandingan berskor *message broker* dan *schema registry* beserta pemilihannya untuk platform dibahas pada Subbab IV.2.

II.3.3 *Stream Processing*

Pemrosesan *stream* mengolah aliran data begitu *event* tiba, dengan dua kemampuan yang menentukan kebenaran hasilnya, yaitu acuan *event-time* dan operasi *stateful*. Carbone dkk. (2015) menjelaskan dasar *pipeline streaming* dengan kedua kemampuan tersebut, termasuk mekanisme *checkpointing* yang menjamin pemrosesan

exactly-once ketika terjadi kegagalan. Penggunaan *event-time* alih-alih *processing-time* membuat hasil transformasi tetap konsisten ketika data terlambat tiba. Kemampuan tersebut dibutuhkan untuk transformasi fitur waktu nyata dan agregasi *sliding window* yang dikonsumsi model *streaming*.

Contoh *engine* pemrosesan *stream open source* dengan kemampuan tersebut adalah Apache Flink, yang dokumentasi resminya menjabarkan *exactly-once processing* dengan *checkpointing* serta *watermark* untuk data terlambat (Apache Software Foundation 2024b). Pada Kubernetes, Flink umum dijalankan melalui CRD `FlinkDeployment` yang disediakan *operator* Apache Flink, dengan *checkpoint* dan *savepoint* ditulis ke penyimpanan objek S3-kompatibel agar pemulihan *job* tidak kehilangan *state*. Alur kerjanya membaca *topic* dari *message broker*, melakukan transformasi pada *event-time* dengan *watermark* per partisi, lalu menerbitkan hasil ke *topic sink* yang dikonsumsi *layer* analitik. Perbandingan *engine* pemrosesan data beserta pemilihannya untuk platform dibahas pada Subbab IV.2.

II.3.4 Batch Processing dan Transformasi SQL

Pemrosesan *batch* mengolah data historis bervolume besar pada referensi waktu tertentu, misalnya untuk *backfill* fitur dan penyiapan *training data*. Zaharia dkk. (2016) merangkum arsitektur *engine* pemrosesan terpadu yang menangani beban *batch* skala besar pada satu *framework* eksekusi. Pada *warehouse layer*, transformasi SQL deklaratif memetakan model data ke berkas SQL dengan dukungan pengujian skema dan dokumentasi otomatis, sehingga rantai transformasi dapat diuji dan dirunut seperti kode. Pola-pola tersebut saling melengkapi, sebab mesin *batch* menangani pemrosesan yang melampaui kapasitas satu mesin SQL, sedangkan transformasi deklaratif menjaga *lineage* antar tabel *warehouse*.

Contoh perwujudan *open source* kedua pola tersebut adalah Apache Spark (Apache Software Foundation 2024d) untuk *batch* dan *micro-batch* serta dbt (dbt Labs 2025) untuk transformasi SQL deklaratif. Pada Kubernetes, *job* Spark dapat diserahkan langsung ke penjadwal *cluster* tanpa memelihara *cluster master-worker* yang mengganggu, dengan orkestrator data sebagai pemicu *job* terjadwal. dbt memetakan model ke berkas SQL dengan fungsi `ref()` yang menjaga *lineage* antar tabel *medallion* dari *staging* hingga tabel fitur. Perbandingan pilihan *engine* pemrosesan data menurut kriteria kelayakan platform dibahas pada Subbab IV.2.

II.3.5 Format Tabel *Lakehouse*

Penyimpanan jangka panjang pada *data lake* memerlukan format tabel yang menyediakan transaksi ACID, evolusi skema yang aman, dan ketertelusuran lintas *engine* pemrosesan, sementara penyimpanan langsung dalam berkas Parquet tanpa *layer* format tabel tidak menjamin keduanya. *Layer* format tabel membuka dua kemampuan turunan, yaitu *schema evolution* tanpa migrasi data fisik dan *time-travel* pada *snapshot* historis. Agar banyak *engine* dapat membaca dan menulis tabel yang sama, metadata tabel dikelola oleh *catalog server* yang diakses melalui antarmuka bersama. Kueri lintas sumber data kemudian disatukan oleh *query engine* federatif sehingga analisis tidak terkunci pada satu tempat penyimpanan.

Apache Iceberg, Delta Lake, dan Apache Hudi merupakan tiga format tabel *open-source* yang umum dipakai untuk arsitektur *lakehouse*. Contoh *catalog server* REST untuk Iceberg adalah Lakekeeper (Lakekeeper Authors 2025), yang menyimpan metadata pada PostgreSQL sehingga *engine* pemrosesan seperti Trino, Spark, dan Flink membaca dan menulis tabel yang sama, sedangkan Trino (Trino Software Foundation 2024) menjadi contoh *query engine* federatif yang menjangkau ClickHouse, PostgreSQL, dan tabel Iceberg melalui satu antarmuka SQL. Susunan *open source* semacam ini sejalan dengan batasan implementasi BI-2 pada Bab V yang menghindari ketergantungan pada katalog terkelola berbayar. Perbandingan format tabel *lakehouse* terhadap kriteria yang relevan beserta pemilihannya untuk platform dibahas pada Subbab IV.2.

II.3.6 Penyimpanan Objek dan Versi Data

Object storage layer menjadi landasan bagi *data lake*, *model registry*, dan pencadangan, dengan antarmuka S3 sebagai kontrak akses yang umum dipakai lintas komponen. Kebutuhan enkripsi data *at rest* pada *layer* ini dijawab oleh enkripsi sisi *server* yang kuncinya dikelola melalui *key management service* (KMS). Di atas *layer* objek, pengelola versi data menambahkan model *branching* dan *commit* bergaya Git pada *bucket*, sehingga jejak versi data dapat dirunut tanpa menggandakan berkas. Pola pemakaiannya mengikuti alur *branch-merge*, yaitu setiap eksekusi *pipeline batch* menulis pada *branch* terpisah dan baru digabungkan ke *branch* utama setelah *quality gate* lolos, sehingga data yang dipublikasikan selalu melewati pemeriksaan.

Penyedia objek S3-kompatibel *open source* yang umum dipertimbangkan ada empat, yaitu MinIO (MinIO, Inc. 2024), Ceph RGW (Ceph Authors 2025), SeaweedFS (SeaweedFS Authors 2025), dan Garage (Deuxfleurs Association 2025), dengan Mi-

nIO menyediakan *Server-Side Encryption with KMS* (SSE-KMS) yang dijemput ke KES ke *secret manager* sebagaimana dibahas pada Subbab II.10. Contoh pengelolaan versi data adalah lakeFS (Treeverse Ltd. 2025) dengan model *branching* pada *bucket* objek, DVC (Iterative, Inc. 2025) yang menautkan versi data ke repositori Git, Project Nessie (Project Nessie Authors 2025) yang memberi versi pada katalog Iceberg, dan Pachyderm (Pachyderm, Inc. 2025) yang menggabungkan versi data dengan eksekusi *pipeline*. Pemisahan *bucket* per kepentingan membuat kebijakan versi, retensi, dan akses dapat diatur tanpa saling mengganggu, dan kombinasi *flat storage* dengan *branched storage* melayani artefak tanpa versi maupun data *pipeline* yang memerlukan *point-in-time*. Perbandingan berskor penyedia objek dan pengelolaan versi data beserta pemilihannya untuk platform dibahas pada Subbab IV.2.

II.3.7 Penyimpanan Relasional dan Pencarian

Sebagian besar layanan platform memerlukan basis data relasional untuk menyimpan metadata, dari riwayat eksperimen sampai status *pipeline*. Pemisahan *metadata storage layer* mengikuti karakter *workload* dan kompatibilitas protokol, sebab sebagian layanan dapat memakai basis data relasional mana pun, sebagian terikat pada *wire-protocol* tertentu, dan fungsi pencarian teks serta graf metadata menuntut indeks pencarian tersendiri. Dengan pemisahan tersebut, tiap *layer* dapat dioperasikan, diskalakan, dan dicadangkan sesuai karakternya. Pencadangan ketiga *layer* dijalankan terjadwal agar metadata dapat dipulihkan bersama data yang dirujuknya.

PostgreSQL (PostgreSQL Global Development Group 2025) menjadi contoh basis data relasional utama yang umum dioperasikan melalui *operator* seperti Cloud-NativePG sebagaimana dibahas pada Subbab II.2, dan pada platform ini melayani metadata MLflow, Airflow, DataHub, lakeFS, Lakekeeper, SpiceDB, dan Superset. MySQL (Oracle Corporation 2025) melayani *metadata store* Kubeflow Pipelines (ML Metadata) dan Katib yang terikat pada protokol MySQL. OpenSearch (OpenSearch Foundation 2025) menjadi contoh indeks pencarian yang melayani pencarian teks dan *lineage graph* DataHub dengan dukungan kueri graf, berjalan dengan satu peran gabungan pada lingkungan satu *node* dan dapat dipecah menjadi peran terpisah (master, data, ingest) pada lingkungan *multi-node*. Pencadangan ketiganya dijalankan oleh Velero dengan jadwal harian dan retensi 30 hari.

II.4 Layanan Fitur (*Feature Store*)

Layanan fitur menghubungkan *data flow* dengan *model flow* sehingga keduanya membaca definisi fitur yang sama. Peran *feature store* sebagai penyatu fitur dibahas

terlebih dahulu, disusul pemisahan penyimpanan *offline* dan *online* yang menjadi inti arsitektur *dual-store*. Pencarian vektor untuk fitur *embedding* serta jaminan *point-in-time correctness* yang mencegah *temporal leakage* dibahas pada dua subbab berikutnya. Topik-topik tersebut menjadi dasar perancangan *layer* layanan fitur pada Bab IV.

II.4.1 Peran *Feature Store* sebagai Penyatu Fitur

Feature store berperan sebagai *layer* penyatu antara produksi fitur dan konsumsi fitur. Lamer dkk. (2024) menjelaskan posisi *feature store* di antara *data lake*, *data warehouse*, dan *datamart*, sebagai komponen yang menyiapkan fitur untuk konsumsi model. Li dkk. (2023) menjabarkan arsitektur *feature store geo-distributed* dan menekankan pentingnya kontrak fitur yang seragam antara *batch* dan *online*. Kartakis dkk. (2022) menempatkan *feature store* terkelola sebagai salah satu komponen pondasi dalam peta jalan MLOps tingkat perusahaan.

Feature store memiliki tiga peran utama, yaitu (1) menyimpan fitur dengan kontrak skema yang konsisten lintas konsumen, (2) penyedia *point-in-time join* antara entitas dan fitur historis untuk *training*, dan (3) penyedia *lookup* fitur berlatensi rendah untuk *inference*. Tanpa *feature store*, ketiga peran tersebut harus dirakit ulang oleh setiap tim yang melayani model, sehingga muncul duplikasi kontrak dan risiko *train-serving skew* yang dibahas oleh Breck dkk. (2017). Contoh perwujudan *open source* peran tersebut adalah Feast sebagai *control plane feature store* yang menghubungkan *offline store*, *online store* untuk *tabular feature* dan *aggregate feature*, serta *vector index* untuk fitur *embedding* pada satu *FeatureView*, sehingga konsumen *training* dan konsumen *serving* membaca kontrak yang sama. Pembahasan ketiga jenis penyimpanan tersebut berlanjut pada subbab-subbab berikutnya.

II.4.2 Penyimpanan *Offline* dan *Online*

Penyimpanan *offline* dipakai untuk *training* dan *batch scoring*, sedangkan penyimpanan *online* dipakai untuk *inference* dengan latensi rendah. Pemisahan ini mengikuti perbedaan pola akses, yaitu pemindaian historis bervolume besar pada satu sisi dan *lookup* per entitas dalam hitungan milidetik pada sisi lain. Penyimpanan *offline* karena itu umumnya berbentuk penyimpanan kolumnar yang dioptimasi untuk kueri agregasi pada jutaan baris, sedangkan penyimpanan *online* berbentuk struktur *key-value* pada memori dengan latensi *lookup* sub-milidetik. Nilai fitur berpindah dari *offline* ke *online* melalui materialisasi terjadwal sehingga kedua sisi membaca definisi fitur yang sama.

Contoh susunan *open source* untuk pola ini adalah Feast (Feast Project 2024) sebagai *framework feature store*, ClickHouse (ClickHouse Inc 2024) sebagai *offline store* kolumnar dengan kompresi LZ4 atau ZSTD yang cocok untuk pembuatan *training dataset* dengan *point-in-time join*, dan Valkey (Valkey Contributors 2025) sebagai *online store key-value* untuk *inference* dengan ribuan *lookup* per detik. Materialisasi dari *offline* ke *online* berjalan sebagai *job* terjadwal berdasarkan FeatureView, dengan dukungan inkremental untuk fitur yang sering berubah dan dukungan penuh untuk fitur historis. Kontrak fitur pada *framework* semacam ini menjadi satu-satunya definisi yang dibaca konsumen *training* maupun *serving*. Perbandingan berskor *framework feature store* serta pilihan penyimpanan *offline* dan *online* beserta pemilihannya dibahas pada Subbab IV.2.

II.4.3 Pencarian Vektor dan HNSW

Fitur *embedding* berdimensi tinggi memerlukan struktur indeks *approximate nearest neighbor* (ANN). Malkov dan Yashunin (2020) memperkenalkan *Hierarchical Navigable Small World* (HNSW) sebagai struktur indeks dengan keseimbangan baik antara kecepatan kueri dan kualitas hasil, sementara *Product Quantization* (Jegou, Douze, dan Schmid 2011) dan pencarian skala miliar dengan GPU (Johnson, Douze, dan Jégou 2021) relevan untuk skala yang berbeda. Pola *hybrid search* yang menggabungkan kueri vektor dengan filter atribut banyak diadopsi pada sistem *retrieval* modern (Bruch, Gai, dan Ingber 2023). Devlin dkk. (2019) dan OpenAI (2022) memberi konteks mengenai sumber *embedding* dari model bahasa yang umum menjadi masukan *vector index*.

Contoh *vector index open source* dengan indeks HNSW dan dukungan *hybrid search* tersebut adalah Qdrant (Qdrant Team 2025), yang umumnya dipisahkan dari *online store* tabular karena pola aksesnya berbeda. Parameter indeks seperti *m* dan *ef_construct* dapat ditingkatkan ketika rasio *recall* perlu diperbesar, dan metrik jarak *collection* umumnya memakai kosinus untuk *embedding* yang dinormalkan. Penyimpanannya memakai *persistent volume* dengan kunci akses yang mengikuti pola pengelolaan *secret* komponen lain pada *cluster*. Perbandingan beberapa pilihan *vector index open-source* beserta pemilihannya dibahas pada Subbab IV.2.

II.4.4 Point-in-Time Correctness

Jaminan *point-in-time correctness* berarti nilai fitur yang dipakai saat *model training* harus identik dengan nilai yang tersedia pada saat itu, bukan nilai versi terkini. Kaufman dkk. (2012) merumuskan kebocoran data sebagai kondisi ketika proses

training memakai informasi yang belum tersedia pada saat prediksi dilakukan, dan menunjukkan bahwa kondisi tersebut membuat hasil evaluasi model tampak lebih baik daripada kinerja sesungguhnya. Penegakannya memakai operasi *point-in-time join* antara entitas dan riwayat fitur, sehingga konsistensi nilai antara fase *training* dan fase *inference* terjaga. Vela dkk. (2022) menambah perspektif evaluasi temporal pada pemodelan urut waktu yang sejalan dengan kebutuhan *point-in-time*.

Pada *framework feature store* seperti Feast, jaminan tersebut ditegakkan oleh dua mekanisme. Mekanisme pertama, operasi `get_historical_features`, melakukan *point-in-time join* dengan `FeatureView` yang mendaftarkan kolom `event_timestamp` sebagai acuan *join* historis dan kolom `created_timestamp` sebagai penanda waktu penulisan fitur. Mekanisme kedua membuat *online store* memakai versi terbaru dari nilai fitur sehingga *lookup* saat *inference* membaca nilai yang konsisten dengan `event_timestamp` terkini. Kombinasi keduanya menekan peluang *temporal leakage* saat *training* dan menjaga konsistensi nilai antara kedua fase.

II.5 Model Lifecycle

Model lifecycle mencakup tahap eksperimen sampai model tersedia sebagai layanan. Pembahasan dimulai dari *tracking* eksperimen dan *registry* model, dilanjutkan orkestrasi *training pipeline*. Pembahasan pada dua subbab berikutnya beralih ke lingkungan eksperimen interaktif beserta *hyperparameter tuning*, kemudian ke *model serving* pada *inference layer*. Urutan tersebut mengikuti perjalanan model dari kode eksperimen sampai *endpoint* yang dipantau.

II.5.1 Eksperimen dan Tracking

Tracking eksperimen mencatat parameter, metrik, dan artefak setiap percobaan *training* pada satu tempat, sedangkan *registry* model menyimpan versi model yang siap dipromosikan ke lingkungan *serving*. Pimentel dkk. (2019) menyoroti masalah reproduksibilitas *notebook*, yang menjadi alasan mengapa *tracking* terpusat menjadi prasyarat sebelum hasil eksperimen dipercaya. Anaconda, Inc. (2020) memberikan konteks lapangan mengenai praktik kerja *data scientist* yang dapat dijadikan acuan saat memilih *tools tracking*. Tanpa kedua fungsi tersebut, jejak eksperimen tersebar pada *notebook* perorangan dan versi model tidak memiliki sumber rujukan.

Contoh *open source tools* untuk fungsi ini adalah MLflow (MLflow Contributors 2024), yang menyediakan *tracking* eksperimen, *registry* model, dan *API deployment*

dengan basis data relasional sebagai *backend store* dan penyimpanan objek sebagai *artifact store*. Penempatan artefak pada *layer* objek membuat kebijakan enkripsi dan pencadangan *layer* tersebut berlaku seragam untuk artefak eksperimen. *Registry* model menjadi sumber rujukan versi model yang dipromosikan oleh *pipeline continuous training* ke *serving layer*, dan akses konsolnya dapat disatukan pada *authentication flow* terpusat sebagaimana dibahas pada Subbab II.10. Perbandingan beberapa pilihan platform *tracking* dibahas pada Subbab IV.2.

II.5.2 Orkestrasi *Training*

Orkestrasi *training* merangkai langkah eksperimen menjadi *pipeline* berbentuk graf berarah yang dapat dijadwalkan, diberi parameter, dan diulang. Kebutuhan orkestrasinya terbagi dua. *Training pipeline* menghasilkan dan mempromosikan model, sedangkan *control loop* berkala membaca sinyal pemantauan lalu memutuskan kapan *retraining* dipicu. Pemisahan keduanya menjaga *training pipeline* tetap menjadi unit kerja yang dipicu, sementara keputusan untuk memicu berada pada penjadwal terpisah. Orkestrasi *pipeline* data berorientasi *batch* berjalan pada penjadwal tersendiri agar tanggung jawab DataOps dan MLOps tidak bercampur pada satu *controller*.

Orkestrasi *training* pada Kubernetes memiliki dua pilihan utama, yaitu Kubeflow Pipelines (Kubeflow Contributors 2024) dan Argo Workflows (Argo Project 2025), sedangkan Apache Airflow (Apache Software Foundation 2024a) tetap relevan untuk *pipeline* data berorientasi *batch*. *Controller* Argo Workflows disertakan oleh instalasi Kubeflow Pipelines sehingga kedua *orchestrator* dapat berjalan pada *namespace* yang sama tanpa dua instalasi *workflow engine* yang tumpang tindih. Pola pembagian perannya menempatkan *training pipeline* pada Kubeflow Pipelines dan *control loop* berbentuk *CronWorkflow* pada Argo Workflows yang membaca skor *drift* lalu memicu *retraining*. Perbandingan ketiganya berdasarkan kebutuhan domain beserta pemilihannya dibahas pada Subbab IV.2.

II.5.3 Eksperimen Interaktif dan *Tuning*

Lingkungan eksperimen interaktif menyediakan *notebook* multi-pengguna di atas *cluster* dengan tata kelola sumber daya per pengguna, sehingga eksperimen berjalan dekat dengan data tanpa membebani mesin lokal. Pencarian *hyperparameter* mengotomasi pemilihan konfigurasi *training* melalui strategi *grid*, *random*, *Bayesian*, hingga *neural architecture search*. *Training* terdistribusi membagi satu pekerjaan *training* ke beberapa *worker* ketika ukuran model atau data melampaui satu mesin. Vangala, Mehta, dan Singh (2022) memberi gambaran praktik MLOps di

lapangan yang menempatkan ketiga fungsi tersebut sebagai bagian dari satu *layer* pengembangan model.

Contoh perwujudan *open source* ketiga fungsi tersebut pada Kubernetes adalah Kubeflow Notebooks (Kubeflow Authors 2025b) dengan *notebook-controller* yang merekonsiliasi CRD Notebook menjadi StatefulSet per pengguna dan *jupyter-web-app* sebagai antarmuka pembuatan *notebook*, Katib (Kubeflow Authors 2025a) yang menjalankan pencarian melalui Experiment CRD dengan *trial* sebagai Job berlabel dan algoritme pencarian pada *suggestion service* terpisah, serta Kubeflow Trainer (Kubeflow Authors 2025c) yang menyediakan CRD TrainJob dengan *built-in runtime* untuk *framework* seperti PyTorch dan DeepSpeed. Kubeflow Notebooks dapat dipasang *standalone* tanpa Profile CRD ketika isolasi *multi-tenant* tidak dibutuhkan, misalnya pada lingkungan pengujian satu *node*. Kuota sumber daya ditegakkan melalui *request* dan *limit* pada spesifikasi *notebook*, yang dapat diperkuat kebijakan validasi *policy engine* sebagaimana dibahas pada Subbab II.10. *Training* terdistribusi melalui TrainJob menjadi relevan ketika *cluster* diperluas menjadi *multi-node*.

II.5.4 Model Serving

Framework model serving mengubah artefak model menjadi layanan *inference* dengan tiga kemampuan inti, yaitu dukungan banyak *runtime*, otomatisasi *scaling* termasuk *scale-to-zero* saat sepi, dan *deployment flow* progresif yang menahan versi bermasalah. Hsu dkk. (2024) memperlihatkan uji coba *deployment* model terotomasi pada Kubernetes yang sejalan dengan pendekatan platform ini, dan Liang dkk. (2024) menyoroti integrasi sistem dengan *machine learning* sebagai pendorong otomatisasi *training* dan *deployment*. Ahmad dkk. (2024) memberikan tinjauan strategi keamanan MLOps yang relevan untuk *serving layer*. Pemantauan kualitas prediksi sebaiknya tidak dibebankan pada *inference flow* agar latensi *serving* tidak terganggu, sehingga deteksi *drift* membaca tabel fitur pada *layer* analitik melalui *job* terjadwal sebagaimana dibahas pada Subbab II.7.

Contoh *framework serving open source* dengan kemampuan tersebut adalah KServe (KServe Contributors 2024), yang dijalankan melalui InferenceService CRD dengan *predictor*, *transformer*, dan *explainer* yang dapat dirangkai pada satu *flow* serta integrasi dengan praktik GitOps. *Serving runtime*-nya didefinisikan melalui ClusterServingRuntime, misalnya MLServer untuk model dari *registry* MLflow, sementara *built-in runtime* lain seperti Triton Inference Server dapat ditambahkan ketika model jaringan saraf dalam dibutuhkan. Kemampuan *scale-to-zero* disediakan

an oleh Knative Serving sebagai fondasinya, dengan batas bawah satu *replica* dapat dipertahankan agar permintaan pertama tidak menanggung *cold start*, dan *deployment* progresif pada layanan di depan model dijalankan oleh Argo Rollouts dengan strategi *canary*. Perbandingan KServe dengan *framework model serving* lain menurut kriteria kelayakan platform dibahas pada Subbab IV.2.

II.6 Tata Kelola Data: Katalog, *Lineage*, dan Kualitas

Tata kelola data menjaga agar aset data dapat ditemukan, dirunut *lineagenya*, dan dipercaya isinya sepanjang siklus data dan model. Subbab ini membaginya menjadi dua bagian yang saling melengkapi. Bagian pertama membahas katalog metadata dan *lineage* sebagai sarana *data discovery* dan penelusuran *lineagenya*. Bagian kedua membahas kontrak dan pengujian kualitas data yang menjaga isi aset tetap sesuai dengan harapan sebelum dikonsumsi oleh *layer* di atasnya.

II.6.1 Katalog Metadata dan *Lineage*

Bernardo dkk. (2024) memetakan tata kelola data sebagai disiplin lintas fungsi yang mencakup metadata, kualitas, akses, dan kepemilikan. Katalog metadata dan *lineage*, dua di antara aspek tersebut, menjadi tumpuan *data discovery* dan penelusuran *lineagenya*. Katalog metadata memberi tempat terpusat untuk menemukan aset data beserta pemiliknya, sedangkan *lineage* merekam *lineage* setiap aset dari sumber hingga konsumennya. Stoyanovich, Howe, dan Jagadish (2020) menempatkan tanggung jawab atas data pada level platform, bukan hanya level aplikasi, sehingga penelusuran *lineage* perlu ditegakkan sebagai kapabilitas bersama, bukan tanggung jawab tiap tim secara terpisah.

Contoh perwujudan *open source* kedua aspek tersebut adalah DataHub (DataHub Project 2024) sebagai katalog metadata dan OpenLineage (OpenLineage Authors 2025) sebagai standar terbuka pengumpulan *lineage* antar komponen *pipeline*. DataHub menyimpan metadata aset beserta relasinya sehingga aset data dapat ditemukan dan ditelusuri kepemilikannya dari satu antarmuka. OpenLineage menyusun jejak dari *ingestion* hingga model dengan kosakata yang seragam sehingga *lineage* aset dapat dirunut lintas komponen *pipeline*. Perbandingan beberapa pilihan katalog beserta pilihannya dibahas pada Subbab IV.2.

II.6.2 Kontrak dan Pengujian Kualitas Data

Kontrak kualitas data menjaga agar isi aset tetap sesuai dengan harapan, melengkapi katalog dan *lineage* yang mencatat keberadaan dan *lineagenya*. Chien (2022) memberi panduan praktis untuk peningkatan kualitas data berbasis pengukuran, sehingga kualitas dapat dipantau sebagai metrik alih-alih dinilai secara subjektif. Kontrak semacam ini memeriksa kesesuaian skema dan rentang nilai pada titik-titik *pipeline* sebelum data mengalir ke tahap berikutnya. Dengan pemeriksaan yang dijalankan sebagai bagian permanen dari operasi, cacat data tertahan lebih awal sebelum mengalir ke fitur dan model di *layer* atasnya.

Contoh perwujudan *open source* kontrak kualitas tersebut adalah Great Expectations (Great Expectations 2024) untuk pengujian kontrak data pada *pipeline* produksi. Kontrak kualitas umum dikemas sebagai *expectation suite* yang berversi pada repositori Git dan dijalankan sebagai *quality gate* terjadwal pada *pipeline* data. Pemeriksaan kualitas tambahan dapat dipasang pada *pipeline lakehouse* sebelum *branch* data digabungkan ke *branch* utama, sejalan dengan alur *branch-merge* pada Subbab II.3.6. Penegakan kebijakan akses atas aset yang telah lolos pemeriksaan tersebut ditangani oleh *layer* keamanan pada Subbab II.10.

II.7 Deteksi *Drift*

Deteksi *drift* menjaga agar model tetap valid ketika distribusi data bergeser dari kondisi saat model dilatih. Subbab ini membahasnya dalam dua bagian. Bagian pertama menguraikan jenis *drift* beserta metrik statistik yang dipakai untuk mendeteksinya. Bagian kedua menjelaskan bagaimana metrik tersebut dijalankan sebagai deteksi terjadwal yang menjadi pemicu *retraining* otomatis.

II.7.1 Jenis *Drift* dan Metrik Statistik

Lu dkk. (2019) memberikan tinjauan luas tentang pembelajaran di bawah *concept drift*, yaitu kondisi ketika hubungan antara masukan dan keluaran model berubah seiring waktu. Perubahan semacam ini membuat model yang semula akurat perlahan kehilangan validitasnya apabila tidak ditangani. Bayram, Ahmed, dan Kassler (2022) mengelompokkan keluarga detektor berbasis performa yang memantau penurunan metrik prediksi sebagai sinyal *drift*. Hinder dkk. (2023) memperluas pembahasan ke arah penjelasan model sehingga *drift* tidak hanya terdeteksi, tetapi juga dapat ditelusuri penyebabnya.

Beberapa metrik yang relevan untuk *covariate drift* dan *prior probability shift* anta-

ra lain *Population Stability Index* (PSI), uji Kolmogorov-Smirnov (KS) (Reis dkk. 2016), dan jarak Wasserstein. PSI mengukur pergeseran distribusi suatu fitur antara *reference window* dan *current window*, sedangkan uji Kolmogorov-Smirnov membandingkan fungsi distribusi kumulatif kedua *window*. Jarak Wasserstein memberi ukuran perbedaan distribusi yang peka terhadap besar pergeseran, bukan sekadar ada atau tidaknya perbedaan. Céspedes Sisniega dkk. (2024) memperlihatkan implementasi deteksi *drift* pada lingkungan *serverless*, sementara Jourdan dkk. (2023) membahas penanganan *drift* pada *deep learning* untuk pemantauan proses.

II.7.2 Deteksi Terjadwal dan Pemicu *Retraining*

Deteksi *drift* pada produksi umumnya dijalankan sebagai proses terjadwal yang membandingkan *current window* terhadap *reference window* bergulir pada beberapa skala waktu. Ambang batas ditetapkan per fitur sehingga sensitivitas deteksi dapat disesuaikan dengan karakteristik tiap fitur. Skor *drift* yang dihasilkan tiap eksekusi disimpan sebagai deret waktu agar riwayatnya dapat diaudit dan dibandingkan antar periode. Ketika skor melampaui ambang, sebuah *control loop* berkala membaca sinyal tersebut lalu memicu *retraining* model tanpa campur tangan manual.

Contoh perwujudan *open source* alur tersebut menempatkan detektor PSI dan uji Kolmogorov-Smirnov sebagai *job* terjadwal yang membaca langsung tabel fitur ClickHouse dan menuliskan skor *drift* ke tabel analitik serta metrik Prometheus. CronWorkflow Argo membaca skor tersebut sebagai *control loop* dan memicu *retraining* melalui Kubeflow Pipelines apabila ambang dilewati. Evidently (Evidently AI 2025) melengkapi *flow* tersebut sebagai layanan pelaporan yang menghasilkan laporan *data drift* dan ringkasan data ke *workspace* Evidently untuk ditelaah secara visual. Detektor tersebut sengaja dipisahkan dari *inference flow* agar pemantauan kualitas prediksi tidak menambah latensi *serving*, sejalan dengan pemisahan yang dibahas pada Subbab II.5.4.

II.8 Observabilitas *Cloud-Native*

Observabilitas memungkinkan kondisi internal platform dibaca dari sinyal yang dikeluarkannya, sebuah prasyarat untuk mengoperasikan banyak komponen data dan model sekaligus. Subbab ini dibagi menjadi dua bagian. Bagian pertama membahas tiga pilar dasar observabilitas, yaitu metrik, log, dan *trace*, beserta cara mengorelasikannya. Bagian kedua membahas kebutuhan turunan di atas ketiga pilar tersebut dan antarmuka analitik yang menyajikan kondisi sistem dari satu tempat.

II.8.1 Metrik, Log, dan Trace

Cloud Native Computing Foundation (2024b) dan IBM (2024) mendefinisikan observabilitas sebagai gabungan tiga pilar, yaitu metrik, log, dan *trace*. Metrik merekam ukuran numerik deret waktu, log merekam *event* tekstual, dan *trace* merekam perjalanan satu permintaan lintas layanan. Korelasi antar pilar dimungkinkan melalui label *trace_id* yang dilampirkan pada baris log dan rentang *trace*, sehingga pelacakan kegagalan dapat berpindah antar pilar tanpa kehilangan konteks. Metrik, log, dan *trace* menjadi landasan yang di atasnya kebutuhan pemantauan lain pada platform data dan model dibangun.

Prometheus (Prometheus Authors 2024) untuk metrik, Loki (Grafana Labs 2024b) untuk log, dan Grafana Tempo (Grafana Labs 2024c) untuk *trace* merupakan contoh perwujudan *open source* ketiga pilar tersebut. OpenTelemetry (OpenTelemetry Authors 2025) berperan sebagai *collector* bersama yang menyeragamkan pengumpulan sinyal dari berbagai komponen sebelum diteruskan ke penyimpanan tiap pilar. Grafana (Grafana Labs 2024a) menjadi antarmuka visualisasi satu pintu yang membaca ketiga pilar sehingga penelusuran kegagalan tidak perlu berganti antarmuka. Susunan ini menjaga jejak metrik, log, dan *trace* tetap dapat dikorelasikan melalui label *trace_id* yang sama.

II.8.2 Kebutuhan Turunan dan Antarmuka Analitik

Di atas ketiga pilar dasar, platform data dan model menuntut sejumlah kebutuhan turunan. Penerjemahan *service-level objective* (SLO) menjadi aturan peringatan membuat sasaran layanan dapat dipantau otomatis, *continuous profiling* merekam profil CPU dan memori dari *workload* yang berjalan, dan komponen pengumpul metrik menampung *job* berdurasi pendek yang selesai di luar siklus *scrape*. Pemantauan biaya per *workload* melengkapinya dengan visibilitas atas konsumsi sumber daya tiap komponen. Di atas pilar teknis tersebut, antarmuka BI menyajikan kueri SQL lintas sumber data pada satu *dashboard layer* untuk konsumsi analitik.

Contoh perwujudan *open source* kebutuhan turunan tersebut adalah Sloth (Sloth Authors 2025) yang menurunkan definisi SLO ke aturan Prometheus, Pyroscope (Grafana Labs 2025) yang menyediakan *continuous profiling*, Pushgateway (Prometheus Authors 2025) sebagai komponen pengumpul metrik *job* pendek, dan OpenCost (OpenCost Authors 2025) yang memantau biaya per *workload*. Evidently (Evidently AI 2025) memberi laporan kualitas data dan model yang melengkapi pilar observabilitas dari sisi mutu prediksi. Apache Superset (Apache Superset

Authors 2025) menjadi contoh antarmuka BI yang menyatukan kueri SQL lintas ClickHouse, Trino, dan MySQL, sementara *dashboard* kualitas data dan model dapat dirangkai pada Grafana agar pengamatan kondisi sistem berlangsung dari satu antarmuka. Perbandingan beberapa pilihan *observability stack* dan BI *open-source* dibahas pada Subbab IV.2.

II.9 GitOps dan *Continuous Delivery*

GitOps menjadikan repositori Git sebagai *single source of truth* sehingga operasi platform dapat ditinjau dan dipulihkan seperti perubahan kode. Subbab ini membahasnya dalam dua bagian yang mengikuti alur perubahan dari sumber ke produksi. Bagian pertama membahas rekonsiliasi deklaratif dan integrasi berkelanjutan yang menyamakan *state cluster* dengan deklarasi pada Git. Bagian kedua membahas *deployment* progresif yang membatasi dampak versi bermasalah saat perubahan dirilis.

II.9.1 Rekonsiliasi Deklaratif dan Integrasi Berkelanjutan

GitOps menempatkan repositori Git sebagai *single source of truth* untuk konfigurasi sistem. Limoncelli (2018) menjelaskan pola GitOps sebagai pendekatan IT *self-service* yang memetakan operasi ke kontrol versi, dan Kim dkk. (2016) memberi dasar teoretis tentang alur kerja CI/CD yang menjadi induk GitOps. Pada bagian hulu pola ini, *operator* rekonsiliasi menyamakan *state cluster* dengan deklarasi pada Git, sementara *pipeline* CI membangun dan menguji perubahan sebelum digabungkan ke *branch* utama. Dengan pola tersebut, setiap perubahan sistem dapat ditinjau, diaudit, dan dipulihkan sebagai perubahan Git biasa.

Argo CD (Argo Project 2024) merupakan contoh perwujudan *open source* bagian tersebut sebagai *operator* GitOps yang merekonsiliasi *state cluster* dengan deklarasi Git. Gitea (Gitea Contributors 2025) menyediakan layanan Git *self-hosted* ringan dengan API yang umum sehingga seluruh manifes, *chart* Helm, dan *overlay* Kustomize berada pada satu *control plane* tanpa ketergantungan penyedia eksternal. Tekton (Tekton Contributors 2024) menjalankan *pipeline* CI dengan rangkaian *task* kloning sumber, penggabungan *overlay* konfigurasi, *lint*, pengujian, serta *build* dan *push image*. Perbandingan beberapa *GitOps controller open-source* berdasarkan kriteria yang relevan dibahas pada Subbab IV.2.

II.9.2 *Deployment* Progresif

Deployment progresif merilis versi baru secara bertahap agar dampak versi bermasalah terbatas pada sebagian kecil trafik. Strategi *canary* mengarahkan sebagian kecil permintaan ke versi baru lebih dahulu, lalu menaikkan persinya hanya ketika metrik yang dipantau tetap sehat. Analisis metrik otomatis membandingkan versi baru terhadap ambang pada tiap tahap kenaikan dan membatalkan promosi begitu indikator memburuk. Dengan pola tersebut, kegagalan versi baru terdeteksi pada porsi trafik kecil sebelum berdampak pada seluruh pengguna.

Contoh perwujudan *open source* pola tersebut adalah Argo Rollouts (Argo Rollouts Authors 2025) yang menyediakan strategi *deployment* progresif berbasis *canary* dengan analisis metrik pada layanan di depan model. Argo Rollouts menaikkan porsi trafik ke versi baru secara bertahap dan menghentikan promosi otomatis ketika metrik melewati ambang yang ditetapkan. Pelaporan metrik *pipeline* CI dapat diakhiri *task finally* yang mengirim hasilnya ke komponen pengumpul metrik sebagaimana dibahas pada Subbab II.8. Rangkaian tersebut melengkapi rekonsiliasi pada Subbab II.9.1 sehingga perubahan yang telah tergabung dapat dirilis dengan risiko yang terkendali.

II.10 Keamanan Platform: Identitas, *Secret*, *Mesh*, dan Kebijakan

Layer keamanan menjadi prasyarat bagi platform yang melayani DataOps dan MLOps secara berdampingan. Aspek yang dipertimbangkan berjumlah empat, yaitu identitas pengguna terpadu, pengelolaan *secret*, *service mesh* beserta *API gateway* pada tepinya, dan *policy engine*. Sebagai *layer* pertahanan yang saling melengkapi, keempat aspek tersebut bekerja sesuai prinsip *defense in depth* yang dibakukan pada panduan rekayasa sistem aman NIST SP 800-160 (Ross, Winstead, dan McEvilly 2022). Pelanggaran pada satu *layer* tidak otomatis membuka akses ke *layer* berikutnya sebab tiap *layer* menegakkan kontrol yang berbeda jenis, yaitu identitas mengontrol *siapa*, *secret* mengontrol *apa yang dipegang*, *mesh* mengontrol *siapa berbicara ke siapa*, dan kebijakan mengontrol *apa yang boleh dibuat di cluster*. Aspek pertama dan kedua dibahas pada Subbab II.10.1, sedangkan dua aspek berikutnya bersama pemantauan *runtime* dibahas pada Subbab II.10.2.

II.10.1 Identitas dan Pengelolaan *Secret*

Identitas pengguna terpadu bertumpu pada *identity provider* berbasis OpenID Connect (OIDC) yang menjadi satu pintu autentikasi bagi seluruh konsol. Konsol yang

tidak mendukung OIDC secara *native* dilindungi *reverse proxy* autentikasi yang memeriksa sesi sebelum meneruskan permintaan, sehingga tidak ada mekanisme kredensial terpisah per konsol. Otorisasi granular pada level objek memakai model relasi bergaya Google Zanzibar dengan skema relasi deklaratif dan API permintaan izin yang konsisten. Pengelolaan *secret* menuntut penyimpanan terenkripsi, penerbitan kredensial dinamis, distribusi *secret* ke *workload* dengan rotasi otomatis, serta jembatan KMS untuk enkripsi data *at rest* pada *layer* objek.

Contoh susunan *open source* kebutuhan tersebut adalah dex (Dex Authors 2025) sebagai *identity provider* OIDC, oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menanyakan sesi autentikasi, dan SpiceDB (AuthZed 2025) sebagai basis data otorisasi gaya Zanzibar. Pada sisi *secret*, OpenBao (OpenBao Authors 2025) merupakan *fork open-source* HashiCorp Vault di bawah Linux Foundation dengan *integrated storage* Raft sehingga tidak bergantung pada basis data eksternal. External Secrets Operator (External Secrets Authors 2025) menyalin *secret* ke Secret Kubernetes dengan rotasi otomatis melalui CRD ExternalSecret dan ClusterSecretStore, sedangkan MinIO KES (MinIO, Inc. 2025) menjadi *stateless KMS gateway* yang meneruskan permintaan kunci tanpa menyimpan kunci pada *cluster*. Perbandingan beberapa *identity provider* dan *secret manager open-source* beserta pemilihannya dibahas pada Subbab IV.2.

II.10.2 *Service Mesh, API Gateway, dan Penegakan Kebijakan*

Komunikasi antar layanan diamankan oleh *service mesh* yang menyediakan *mutual TLS* (mTLS) seragam, kontrol trafik *application layer*, dan integrasi telemetri. Pada *mesh edge*, *API gateway* menyaring trafik masuk, menerapkan kebijakan kuota, dan menjembatani mTLS terhadap konsumen di luar *mesh*. *Policy engine* menegakkan kebijakan pada saat objek dibuat, misalnya mewajibkan batas sumber daya pada setiap *pod* dan menegakkan profil keamanan baku lintas *namespace*. *Layer* pertahanan dilengkapi pemantauan ancaman *runtime* berbasis *syscall*, pemindaian *image* terjadwal, pencadangan *cluster* beserta *persistent volume*, dan uji ketahanan dengan kegagalan terkontrol.

Contoh perwujudan *open source layer* tersebut adalah Istio (Istio Authors 2024) sebagai *service mesh* dengan VirtualService dan AuthorizationPolicy serta telemetri OpenTelemetry. Apache APISIX (Apache APISIX Authors 2025) melengkapinya sebagai *API gateway* pada *mesh edge*. Kyverno (Kyverno Authors 2024) menjadi contoh *policy engine native* Kubernetes dengan sintaks YAML yang ringkas serta dukungan *mutate*, *validate*, dan *generate*, dengan Open Policy Agent

(OPA) Gatekeeper (Open Policy Agent Authors 2024) sebagai alternatif berbasis Rego yang juga umum dipakai. Falco (Falco Authors 2025) memantau *syscall* sebagai detektor berbasis eBPF, Trivy Operator (Aqua Security 2025) memindai *image* dan *workload* secara terjadwal, Velero (Velero Authors 2025) mencadangkan *cluster* dan *persistent volume* ke *bucket* objek khusus pencadangan, dan Chaos Mesh (Chaos Mesh Authors 2025) menginjeksikan kegagalan terkontrol melalui CRD eksperimen seperti PodChaos. Perbandingan *service mesh*, *API gateway*, *policy engine*, dan *runtime security open-source* beserta pemilihannya dibahas pada Subbab IV.2.

II.11 Penelitian Terkait

Beberapa penelitian terdahulu memiliki lingkup yang berdekatan dengan platform ini. Burgueño-Romero dkk. (2025) mengusulkan arsitektur MLOps *open source*, namun belum memasukkan layanan fitur dengan dukungan vektor sebagai komponen utama. Amou Najafabadi dkk. (2024) memetakan beragam arsitektur MLOps tetapi tidak menggabungkan DataOps secara menyeluruh. Rodrigues dkk. (2025) menyentuh *near real-time stream learning*, namun tidak meletakkan tata kelola data sebagai *control plane* yang ditegakkan. Ahmad dkk. (2024) membahas strategi keamanan MLOps, tetapi belum menaunkannya pada *control plane* tata kelola yang menegakkan kebijakan akses sepanjang siklus data dan model.

Kesenjangan yang berulang pada penelitian-penelitian tersebut adalah belum adanya satu rancangan yang sekaligus menyatukan DataOps dan MLOps pada satu *control plane*, menegakkan tata kelola data sebagai kontrak yang dijalankan otomatis, dan menyediakan layanan fitur multimodal dari satu sumber rujukan. Pada penelitian terdahulu, ketiga aspek tersebut umumnya ditangani terpisah, sehingga kontrak antara disiplin data dan disiplin model tidak ditegakkan secara otomatis. Akibatnya, *lineage* fitur dari *ingestion* hingga *model serving* sulit dirunut pada satu *control plane* yang sama. Kesenjangan inilah yang menjadi titik berangkat analisis kebutuhan dan pemilihan solusi pada Bab III.

BAB III

ANALISIS MASALAH

Bab ini membahas analisis masalah pada pengembangan platform DataOps dan MLOps melalui tiga langkah, yaitu pemetaan kondisi saat ini, perumusan kebutuhan fungsional dan nonfungsional, dan pemilihan alternatif solusi. Analisis berangkat dari kesenjangan yang dirumuskan pada Subbab II.11, yaitu belum adanya satu rancangan yang menyatukan DataOps dan MLOps pada satu *control plane*. Subbab III.1 memetakan tiga sumber tekanan yang menjadi akar pengembangan platform, kemudian Subbab III.2 menurunkan empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional sebagai tolok ukur kelayakan. Subbab III.3 menutup bab dengan menilai empat alternatif solusi memakai skor pemenuhan kebutuhan lalu memilih alternatif berskor tertinggi. Pemilihan komponen *open source* untuk tiap kelompok fungsi diturunkan dari alternatif terpilih pada Bab IV, sehingga keputusan *tools* mengikuti konteks perancangan arsitektur. Penomoran kebutuhan yang disusun pada bab ini menjadi rujukan tetap ketika Bab IV memetakannya ke komponen dan Bab VI mengujinya.

III.1 Analisis Kondisi Saat Ini

Kondisi pengembangan platform DataOps dan MLOps saat ini dipengaruhi oleh dua tekanan utama yang, ketika tidak teratasi, memicu efek domino sebagai tekanan ketiga. Tekanan pertama, yaitu beban konfigurasi puluhan komponen *open source* dari awal, membatasi kecepatan pembangunan platform internal. Tekanan kedua, yaitu biaya berlangganan layanan terkelola, membatasi kelayakan operasional pada skala produksi sekaligus menghadirkan *trade-off* antara waktu pengembangan dan biaya operasional. Tekanan ketiga, yaitu fragmentasi yang merambat lintas peran (*business user*, *data engineer*, *data scientist*, dan *machine learning engineer*), memicu efek domino pada tata kelola data, deteksi *drift*, dan *feature serving* multimodal. Subbab-subbab berikut menelaah setiap sumber tekanan tersebut secara berurutan.

III.1.1 Beban Konfigurasi Platform dari Awal

Organisasi yang membangun platform dari awal harus merangkai puluhan komponen lintas *layer ingestion*, pemrosesan, penyimpanan, *training*, dan *model serving*, dengan ruang pilihan *tool* yang sangat luas untuk tiap *layer*. Setiap komponen memiliki kontrak konfigurasi, protokol akses, dan model identitas masing-masing, sehing-

ga *glue code* antar *layer* terus tumbuh seiring penambahan komponen. Perubahan versi pustaka pada satu komponen kerap memicu *rework* pada komponen sekitarnya, terutama ketika skema data dan kontrak API ikut berubah. Tim platform juga menanggung kurva belajar yang panjang karena harus menguasai paradigma operasional yang berbeda untuk basis data, sistem antrian, *engine* pemrosesan, registri model, dan layanan *serving*. Mekanisme-mekanisme tersebut berjalan serentak sehingga beban konfigurasi tidak berhenti pada pemasangan awal, melainkan berulang pada setiap penambahan komponen dan pergantian versi.

Beban tersebut bersifat akumulatif karena waktu yang habis untuk integrasi tidak dapat dipulihkan menjadi pengembangan kapabilitas. Shankar dkk. (2022) mendokumentasikan praktik MLOps yang sering tersendat justru karena *layer* integrasi yang tidak pernah selesai disempurnakan oleh tim platform. Kondisi tersebut memperlihatkan risiko inisiatif platform internal terhenti pada tahap arsitektur referensi tanpa pernah mencapai *production pipeline* yang lengkap. Tantangan akan semakin sulit ketika tim berukuran kecil harus menjaga kontrak layanan untuk *ingestion*, pemrosesan, *training*, *serving*, dan tata kelola sekaligus, karena setiap pergantian versi menimbulkan rantai uji regresi yang panjang. Beban ini diturunkan pada Subbab III.2 menjadi kebutuhan konfigurasi deklaratif, rekonsiliasi otomatis, dan modularitas komponen agar pemasangan ulang platform tidak mengulang biaya integrasi dari awal.

III.1.2 Biaya Berlangganan Layanan Terkelola

Sebagai alternatif terhadap konfigurasi dari awal, organisasi dapat berlangganan layanan terkelola dari penyedia *cloud*. Li dkk. (2023) memperlihatkan bahwa layanan *feature store* terkelola mempercepat adopsi dengan membebaskan tim dari pembangunan infrastruktur *feature store*. Akan tetapi, Hamza, Akbar, dan Capilla (2024) menemukan bahwa model penagihan *pay-as-you-go* pada layanan terkelola menyulitkan estimasi anggaran dan cenderung meningkat seiring volume *ingest*, jumlah *training run*, dan trafik *inference*. Biaya tersebut bersifat berulang setiap bulan dan jarang dapat ditekan dengan optimasi internal karena pengguna tidak memegang kendali penuh atas alokasi sumber daya pada *layer* bawah. Ketergantungan pada satu penyedia menimbulkan keterikatan yang membuat migrasi menjadi mahal, terutama ketika format *feature view*, *model registry*, dan *lineage* memakai skema kepemilikan tertutup. Beban ini bertambah ketika organisasi memakai layanan terkelola dari *layer* berbeda yang dipasok beberapa penyedia, sebab perbedaan model identitas, protokol akses, dan format *audit log* memaksa tim platform tetap merakit


otomasi tata kelola lintas penyedia secara manual.

Baik opsi membangun dari awal maupun opsi berlangganan menghadirkan *trade-off* mendasar antara waktu pengembangan dan biaya operasional. Sifat *trade-off*nya tidak simetris, karena biaya membangun dari awal terkonsentrasi pada tahap perancangan dan menurun setelah alur *end-to-end* stabil, sedangkan biaya berlangganan tumbuh mengikuti volume pemakaian sehingga justru membesar ketika adopsi berhasil. Organisasi yang berpindah dari satu opsi ke opsi lain bahkan menanggung kedua beban sekaligus selama masa transisi, karena integrasi internal harus dirakit sambil kontrak layanan terkelola masih berjalan. Karakter *trade-off* ini dipakai pada dua titik analisis berikutnya, yaitu kebutuhan nonfungsional efisiensi sumber daya dan portabilitas pada Subbab III.2.3 serta penilaian empat alternatif solusi pada Subbab III.3.


III.1.3 Efek Domino Fragmentasi Lintas Peran

Pengembangan model *machine learning* untuk tahap produksi melibatkan empat peran utama, yaitu *business user*, *data engineer*, *data scientist*, dan *machine learning engineer*. Kreuzberger, Köhl, dan Hirschl (2023) memperlihatkan bahwa peran tersebut sering menggunakan *tool* yang berbeda sehingga muncul fragmentasi yang menghambat kolaborasi lintas tim. Paleyes, Urma, dan Lawrence (2022) menambahkan bahwa fragmentasi tersebut melahirkan integrasi yang lemah pada sambungan data dan model serta menurunkan kecepatan rilis dan kualitas keluaran. Gambar III.1 dan Gambar III.2 memilah fragmentasi tersebut menjadi dua alur layanan, yaitu alur data yang dikelola *data engineer* hingga laporan diterima *business user* dan alur model yang ditangani *data scientist* bersama *machine learning engineer*. Secara sengaja, kedua alur digambar berjalan terpisah tanpa satu sambungan pun di antaranya, karena keterputusan inilah inti masalahnya, yaitu keluaran alur data tidak mengalir menjadi masukan alur model sehingga integrasi lintas peran tidak pernah terbentuk. Pemisahan dua alur ini dipilih karena beban inti yang menjadi titik tolak penelitian terletak bukan pada satu peran tertentu, melainkan pada sambungan antar peran yang terputus di *layer ingestion*, fitur, *training*, dan *serving*. Efek domino muncul ketika satu kontrak data antar *layer* pecah lalu menyebar ke *layer* di atasnya, yaitu kerusakan skema pada *ingestion layer* merambat ke pemrosesan, lalu ke fitur yang dipakai untuk *training*, sehingga model pada *serving layer* menerima distribusi yang berbeda dengan saat *training*. Pada *framework* kematangan Subbab II.1.2, kondisi ini setara dengan MLOps *level 0* yang prosesnya manual dan berbasis skrip, eksperimennya terpisah dari operasi, serta berjalan tanpa CI/CD dan

tanpa pemantauan kinerja aktif (Google Cloud 2024). Kondisi yang sama berada pada tahap awal model evolusi DataOps karena data terkumpul dalam silo dan pemantauan *pipeline* masih dilakukan manual (Munappy dkk. 2020).



Gambar III.1 Alur data terfragmentasi saat ini (Munappy dkk. 2020)



Gambar III.2 Alur model terfragmentasi saat ini (Google Cloud 2024)

Amou Najafabadi dkk. (2024) dan Burgueño-Romero dkk. (2025) memperlihatkan bahwa fragmentasi tidak hanya muncul pada antarmuka tim, tetapi juga pada *control plane* infrastruktur, kebijakan akses, dan observabilitas. Kondisi inilah yang melandasi keempat rumusan masalah pada Bab I, yang pada hakikatnya merupakan konsekuensi dari rangkaian sambungan yang terputus tersebut. Konsekuensi tersebut tidak dapat ditangani satu per satu, sebab perbaikan pada satu *layer* akan kembali terkikis selama kontrak antar *layer* tetap dirakit secara ad hoc. Karena itu, analisis kebutuhan pada Subbab III.2 menetapkan kontrak yang seragam lintas *layer* sebagai syarat bagi keseluruhan arsitektur. Perbandingan pada Subbab III.3 kemudian menilai empat alternatif solusi berdasarkan kemampuannya memutus efek domino tersebut.

III.2 Analisis Kebutuhan

Setelah pemetaan kondisi saat ini, kebutuhan platform dirumuskan dalam dua kategori, yaitu kebutuhan fungsional yang menggambarkan fitur yang harus dimiliki platform dan kebutuhan nonfungsional yang menggambarkan atribut kualitas yang harus dipenuhi. Identifikasi kebutuhan menggunakan empat rumusan masalah dari Bab I sebagai titik awal, dengan mempertimbangkan beban pada Subbab III.1.1

dan Subbab III.1.2 agar rancangan tetap layak operasional dan finansial. Setiap kebutuhan fungsional dipetakan langsung pada satu sub-bidang arsitektur agar tidak terjadi tumpang tindih cakupan antar kebutuhan, sementara setiap kebutuhan non-fungsional disertai target metrik yang dapat diuji pada Bab VI. Identifikasi awal masalah pengguna pada Subbab III.2.1 memberikan rangkuman kebutuhan kontekstual sebelum diturunkan menjadi spesifikasi kebutuhan pada Subbab III.2.2 dan Subbab III.2.3.

III.2.1 Identifikasi Masalah Pengguna

Identifikasi masalah pengguna diturunkan dari empat rumusan masalah pada Bab I dengan menelusuri titik interaksi tiap peran pada *pipeline* produksi model. Penelusuran memetakan setiap rumusan masalah ke kontrak antar *layer* yang terputus sebagaimana diuraikan pada Subbab III.1.3, lalu mencatat peran yang paling merasakan akibat putusnya kontrak tersebut. Penyusunan sengaja menempatkan kebutuhan pada sambungan antar *layer* sebagai dasar, bukan pada preferensi *tool* satu peran tertentu, agar daftar tetap ringkas dan setara untuk keempat peran. Kebutuhan-kebutuhan berikut menjadi titik awal penyusunan spesifikasi kebutuhan fungsional dan nonfungsional, dan masing-masing dapat dirunut kembali ke rumusan masalah yang melahirkannya serta ke peran yang paling merasakannya.

1. *Control plane* terpadu lintas peran

Control plane terpadu lintas peran dibutuhkan untuk mengatur *ingestion*, *training*, *serving*, dan pemantauan, sehingga sambungan antar *layer* tidak lagi dirakit secara manual dan integrasi *tool* dapat dipulihkan dari *single source of truth*.

2. Tata kelola data yang seragam lintas siklus

Tata kelola yang seragam di antara *layer* data, fitur, dan model dibutuhkan agar *lineage*, katalog, dan validasi kualitas tetap menyatu ketika data berpindah antar *layer*, terutama bagi *data engineer* yang menjaga kontrak data sepanjang siklus.

3. Deteksi *drift* otomatis dan jaminan validitas temporal

Deteksi *drift* yang terotomasi sekaligus jaminan *point-in-time correctness* dibutuhkan pada sambungan antara *layer* data dan *layer* model agar evaluasi model tidak mengandung *temporal leakage* sebagaimana ditegaskan oleh Veldk. (2022) dan Kaufman dkk. (2012). Pihak yang paling bergantung pada kontrak ini adalah *data scientist* dan *machine learning engineer* yang menilai kelayakan model sebelum produksi.

4. Dukungan fitur multimodal berlatensi rendah

Dukungan fitur multimodal yang terdiri dari *tabular feature*, *aggregate feature*, dan *embedding* berdimensi tinggi dengan latensi rendah pada saat *inference* dibutuhkan pada *feature serving layer*. Kebutuhan ini berakar pada kerja *data scientist* yang melakukan *feature engineering* lintas modalitas.

Kebutuhan-kebutuhan pengguna tersebut menyiratkan satu pola yang sama, yaitu kebutuhan untuk memutus sambungan ad hoc antar *layer* dengan kontrak yang seragam dan dapat dipanggil dari satu antarmuka. Pengguna pada peran *business user* menjadi penerima manfaat terakhir karena hanya melihat keluaran model pada *serving layer*, sehingga kualitas kontrak pada *layer* bawah menentukan apakah keputusan bisnis dapat diambil tepat waktu. Identifikasi tersebut menjadi titik awal untuk menyusun spesifikasi kebutuhan fungsional pada Subbab III.2.2 dan kebutuhan nonfungsional pada Subbab III.2.3. Spesifikasi tersebut selanjutnya dipetakan ke komponen arsitektur pada Bab IV dan diuji pemenuhannya pada Bab VI, sehingga setiap kebutuhan tetap terhubung dari sumber masalah hingga bukti pemenuhannya.

III.2.2 Kebutuhan Fungsional

Tabel III.1 menyajikan empat belas kebutuhan fungsional yang disusun mengikuti *layer* arsitektur platform, bergerak dari *layer* fitur, lalu *model lifecycle* dan tata kelola, hingga *layer* operasional, sehingga penomorannya berurutan menurut *layer* dan bukan menurut tujuan. Kebutuhan pertama sampai keempat, yaitu manajemen fitur terpusat, *feature serving* ganda *online-offline*, jaminan validitas temporal, dan dukungan *vector embedding*, merangkum kontrak pada *layer* fitur. Kebutuhan kelima sampai kesepuluh menyatukan *model lifecycle* dan tata kelola dalam satu rentang, mencakup otomatisasi *training pipeline*, otomatisasi *deployment* model, pemantauan *drift* otomatis, tata kelola dan *data discovery*, pelacakan eksperimen, serta registri model. Kebutuhan kesebelas sampai keempat belas, yaitu pemrosesan *batch* dan *stream*, konfigurasi deklaratif, API dan SDK terpadu, serta manajemen sumber daya, merangkum *layer* operasional yang menopang seluruh *layer* di atasnya. Kolom Tujuan pada Tabel III.1 menautkan setiap kebutuhan ke satu dari empat tujuan pada Bab I berdasarkan *sub-sistem* yang paling bertanggung jawab mewujudkannya. Dimensi tujuan ini terpisah dari urutan *layer*, sehingga setiap kebutuhan fungsional memiliki satu tujuan pemilik yang jelas dan tetap dapat dirunut ketika dipetakan ke komponen pada Bab IV dan ke skenario uji pada Bab VI.

Tabel III.1 Kebutuhan Fungsional Sistem

ID	Kebutuhan Fungsional	Deskripsi	Tujuan
KF-01	Manajemen Fitur Terpusat	Sistem menyediakan <i>feature registry</i> terpusat berbasis Feast dengan <i>file-based registry</i> pada MinIO untuk mendefinisikan, mengelola, dan melakukan <i>versioning</i> fitur. <i>Registry</i> menyimpan metadata seperti deskripsi, tipe data, <i>owner</i> , dan dependensi, serta dikelola di dalam repositori Gitea agar mendukung <i>workflow</i> GitOps dan penelusuran perubahan.	T-1
KF-02	<i>Feature Serving</i> Ganda	Sistem mampu melakukan <i>serving</i> fitur dalam dua mode, yaitu <i>online serving</i> berbasis Valkey melalui protokol RESP untuk <i>real-time inference</i> dengan target latensi p99 sub-detik, dan <i>offline serving</i> berbasis ClickHouse untuk <i>historical retrieval</i> berkapasitas besar yang mendukung <i>point-in-time correct join</i> pada data historis.	T-4
KF-03	Jaminan Validitas Temporal	Sistem secara <i>default</i> menjamin <i>point-in-time correctness</i> ketika menyusun <i>training dataset</i> untuk data <i>time-series</i> , sehingga mencegah kebocoran data temporal yang dapat membuat evaluasi dan model menjadi tidak valid.	T-3
KF-04	Dukungan <i>Vector Embeddings</i>	Sistem mendukung penyimpanan, pengindeksan, dan <i>serving vector embeddings</i> pada indeks vektor terpisah berbasis Qdrant dengan <i>similarity search</i> HNSW melalui antarmuka gRPC dan filter <i>payload</i> , dengan target latensi p99 sub-detik untuk volume permintaan menengah.	T-4
KF-05	Otomatisasi <i>Training Pipeline</i>	Sistem menyediakan <i>pipeline</i> otomatis untuk mengorkestrasi proses <i>model training</i> dari ujung ke ujung melalui Kubeflow Pipelines, terintegrasi dengan Feast sebagai <i>feature store</i> , MLflow untuk <i>experiment tracking</i> dan <i>model registry</i> , serta Katib untuk <i>hyperparameter tuning</i> , sehingga mendukung otomatisasi setara MLOps level 2.	T-3
KF-06	Otomatisasi <i>Deployment Model</i>	Sistem mengotomatisasi <i>deployment</i> model yang telah lulus validasi ke <i>inference endpoint</i> produksi melalui KServe <i>InferenceService</i> di atas Knative Serving, serta mendukung strategi <i>rolling update</i> , <i>canary deployment</i> , dan <i>progressive delivery</i> berbasis Argo Rollouts dengan mekanisme <i>rollback</i> otomatis ketika terjadi degradasi.	T-1
KF-07	Pemantauan <i>Drift</i> Otomatis	Sistem secara otomatis dan berkala memantau <i>data drift</i> dan <i>concept drift</i> dengan membandingkan distribusi fitur di produksi terhadap distribusi pada saat <i>training</i> menggunakan uji statistik (misalnya PSI dan Kolmogorov-Smirnov) dengan ambang adaptif, serta memicu <i>retraining</i> otomatis melalui Argo CronWorkflow ketika ambang terlampaui.	T-3

ID	Kebutuhan Fungsional	Deskripsi	Tujuan
KF-08	Tata Kelola & Data Discovery Otomatis	Sistem menangkap dan menyajikan metadata serta <i>lineage</i> untuk fitur, <i>dataset</i> , model, dan <i>pipeline</i> pada katalog DataHub melalui <i>ingestion</i> otomatis dan <i>event lineage</i> berbasis OpenLineage, sehingga memudahkan <i>data discovery</i> , analisis dampak, dan pemenuhan kebutuhan <i>compliance</i> .	T-2
KF-09	Pelacakan Eksperimen Terintegrasi	Sistem menyediakan <i>experiment tracking</i> yang terintegrasi untuk mencatat parameter, metrik, artefak, dan versi kode, sehingga proses eksperimen dapat direproduksi dan dibandingkan secara sistematis.	T-2
KF-10	Versioning dan Registri Model	Sistem menyediakan <i>model registry</i> terpusat untuk mengelola versi model dan status siklus hidupnya (<i>staging</i> , <i>production</i> , <i>archived</i>) disertai <i>audit trail</i> lengkap untuk mendukung <i>governance</i> .	T-2
KF-11	Pemrosesan Batch dan Stream	Sistem mendukung <i>batch processing</i> untuk analisis historis dan <i>feature engineering</i> serta <i>stream processing</i> untuk komputasi fitur <i>real-time</i> , dan keduanya terhubung dengan <i>feature store</i> sehingga definisi fitur tetap konsisten.	T-4
KF-12	Konfigurasi Deklaratif	Sistem memungkinkan konfigurasi komponen seperti fitur, <i>pipeline</i> , dan <i>deployment</i> dalam format deklaratif (manifes Kubernetes, <i>overlay</i> Kustomize, dan definisi Feast berbasis Python) yang dikontrol versinya di Gitea dan disinkronkan oleh Argo CD sebagai <i>single source of truth</i> .	T-1
KF-13	API dan SDK Terpadu	Sistem menyediakan SDK Python yang seragam (Feast, MLflow, dan klien KServe v2 <i>inference</i>) dalam satu <i>environment</i> uv sebagai antarmuka klien standar untuk membaca <i>online feature</i> , menelusuri <i>run</i> dan registri model, serta memanggil <i>endpoint inference</i> , sehingga kompleksitas integrasi menurun dan pola pemakaian menjadi konsisten.	T-1
KF-14	Manajemen Sumber Daya	Sistem menyediakan kemampuan pengelolaan sumber daya komputasi yang efisien melalui Kueue untuk <i>job queueing</i> , prioritas, dan kuota berbasis ClusterQueue, dipadukan dengan HPA, VPA, dan KEDA untuk <i>dynamic provisioning</i> pada lingkungan <i>multi-tenant</i> agar tidak ada satu <i>workload</i> yang menghabiskan sumber daya <i>cluster</i> .	T-1

Penomoran KF-01 sampai KF-14 dipakai konsisten pada bab-bab berikutnya. Bab IV memetakan kebutuhan ke rancangan melalui tujuan pemilik pada kolom Tujuan, Bab V menandai pemenuhan tiap nomor pada subbab implementasi yang mewujudkannya, dan Bab VI memetakan tiap nomor ke skenario uji. Pemetaan satu lawan satu antara kebutuhan fungsional dan sub-sistem dipilih untuk menghindari tumpang tindih cakupan, sehingga jika satu kebutuhan tidak terpenuhi maka kompo-

nen yang bertanggung jawab dapat segera ditemukan tanpa perlu menelusuri rantai panjang. Mayoritas kebutuhan berprioritas tinggi karena menyangkut kontrak inti antar *layer*, sedangkan KF-13 dan KF-14 bersifat penunjang yang memperbaiki pengalaman integrasi dan efisiensi sumber daya tanpa menghalangi fungsi utama. Kebutuhan pada *layer* fitur secara khusus merangkum kontrak *point-in-time correctness* dan dukungan multimodal yang menjadi pembeda utama dari pendekatan tradisional yang hanya menyajikan *tabular feature* dari satu sumber.

III.2.3 Kebutuhan Nonfungsional

Tabel III.2 menyajikan dua belas kebutuhan nonfungsional yang berperan sebagai batasan kualitas dan disusun mengikuti taksonomi atribut kualitas alih-alih menurut tujuan. Kinerja latensi rendah dan *throughput* tinggi menyangkut performa *feature serving* dan *stream processing*. Skalabilitas horizontal, keandalan, dan *fault tolerance* menyangkut kemampuan platform mengikuti pertumbuhan beban. Konsistensi dan kebenaran menegakkan kontrak kualitas data sepanjang *pipeline*, mencakup kesesuaian skema dan validitas nilai. *Observability* mengikat metrik, log, dan *trace* pada satu antarmuka. Keamanan mengikat autentikasi, otorisasi, enkripsi, dan *audit logging*. Ekstensibilitas dan modularitas memberi ruang bagi penggantian komponen tanpa mengganggu komponen lain. Kemudahan penggunaan, efisiensi sumber daya, portabilitas, dan kemudahan pemeliharaan menutup daftar dengan menyoroti aspek operasional jangka panjang. Penetapan target pada KNF skalabilitas horizontal mengacu pada taksonomi karakteristik skalabilitas dari Bondi (2000). Taksonomi tersebut membedakan beberapa dimensi skalabilitas, di antaranya skalabilitas beban dan skalabilitas struktural, yang memengaruhi kinerja ketika beban bertumbuh.

Tabel III.2 Kebutuhan Nonfungsional Sistem

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-01	Kinerja Latensi Rendah	<i>Online feature serving</i> berbasis Val-key dan <i>vector similarity search</i> berbasis Qdrant harus memberikan latensi yang stabil dan rendah untuk mendukung <i>inference</i> waktu nyata pada berbagai domain aplikasi, termasuk pada saat beban tinggi.	Latensi p99 sub-detik indikatif pada lingkungan <i>node</i> tunggal untuk <i>feature serving</i> dan <i>vector search</i> , dengan ambang spesifik per layanan diukur dan dipantau melalui SLO Sloth	T-4

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-02	<i>Throughput</i> Tinggi	Sistem harus mampu menangani <i>workload</i> dengan <i>throughput</i> tinggi yang umum pada <i>workload streaming</i> dan <i>serving</i> bervolume tinggi, dengan karakteristik skalabilitas mendekati linear ketika sumber daya ditambah.	<i>Throughput ingest</i> dan <i>serving</i> tumbuh proporsional terhadap jumlah <i>partition</i> Kafka serta <i>replica</i> Feast melalui <i>auto-scaling</i> KEDA dan HPA	T-4
KNF-03	Skalabilitas Horizontal	Seluruh komponen sistem harus mendukung skala horizontal, sehingga kapasitas dapat ditingkatkan dengan menambah <i>node</i> dan menghasilkan peningkatan kinerja yang linear atau mendekati linear.	Seluruh <i>workload</i> terstandarisasi pada HPA (CPU/memori), VPA <i>recommender</i> , dan KEDA (Kafka <i>lag</i> , <i>custom metrics</i>)	T-1
KNF-04	Keandalan & <i>Fault Tolerance</i>	Sistem harus andal dengan komponen <i>stateful</i> (Kafka, ClickHouse, PostgreSQL, MinIO, Valkey, Qdrant) yang dapat berjalan dalam mode <i>multi-replica</i> pada lingkungan produksi <i>multi-node</i> , dan mampu melakukan pemulihan otomatis dari kegagalan sementara melalui mekanisme <i>operator</i> dan <i>snapshot</i> berkala. Pada lingkungan verifikasi <i>node</i> tunggal, <i>replica idle</i> ditetapkan menjadi satu dan ditingkatkan secara dinamis ketika beban nyata terdeteksi.	SLO <i>platform</i> dijaga melalui Sloth (Kafka 99,9%, Postgres 99,95%, MinIO p99 <500ms pada 99%), sedangkan <i>disaster recovery</i> berbasis Velero <i>snapshot</i> harian penuh dan <i>incremental</i> per <i>use case</i>	T-1
KNF-05	Konsistensi & Kebenaran	Sistem harus menegakkan kontrak kualitas data sepanjang <i>pipeline</i> , mencakup kesesuaian skema, validitas rentang nilai, dan kelengkapan data, sehingga hasil analisis maupun <i>inference</i> model bertumpu pada data yang sah dan konsisten.	Seluruh <i>checkpoint</i> Great Expectations lolos tanpa pelanggaran skema maupun rentang nilai pada data yang dipromosikan ke <i>gold layer</i>	T-2

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-06	Observability	Sistem harus memiliki <i>observability</i> menyeluruh, mencakup metrik (Prometheus dan Grafana), <i>structured log</i> (Loki), <i>distributed tracing</i> (Grafana Tempo melalui OpenTelemetry), <i>continuous profiling</i> (Pyroscope), dan <i>alerting</i> (Alertmanager dan Sloth) sehingga perilaku sistem dapat dianalisis dari ujung ke ujung.	Seluruh komponen terinstrumentasi metrik dan log standar, <i>trace</i> OpenTelemetry untuk lintasan kritis, serta SLO Sloth untuk indikator layanan	T-2
KNF-07	Keamanan	Sistem harus menerapkan kontrol keamanan menyeluruh, mencakup autentikasi tunggal melalui dex sebagai <i>identity provider</i> OIDC dan oauth2-proxy, otorisasi berbasis RBAC dan SpiceDB, enkripsi data <i>in transit</i> dengan Istio mTLS <i>strict</i> , enkripsi <i>at rest</i> pada MinIO melalui KES sebagai <i>KMS gateway</i> ke OpenBao, kebijakan admisi Kyverno, serta deteksi ancaman <i>runtime</i> oleh Falco dan pemindaian kerentanan <i>image</i> oleh Trivy Operator.	TLS 1.3 <i>in transit</i> , AES-256 <i>at rest</i> , dan <i>audit log</i> OpenBao serta Kubernetes <i>audit policy</i> aktif pada seluruh <i>control plane</i>	T-2
KNF-08	Ekstensibilitas & Modularitas	Arsitektur harus modular sehingga komponen dapat diperluas atau diganti melalui antarmuka terdefinisi (<i>Custom Resource Definition</i> , helm <i>chart</i> , dan <i>overlay</i> Kustomize) tanpa mengganggu komponen lain.	Setiap komponen disusun pada <i>folder</i> terpisah dengan <i>kustomization.yaml</i> sendiri, sehingga dapat dipasang, diperbarui, atau diganti secara independen	T-1
KNF-09	Akses Konsol Terpadu	Antarmuka konsol pengembang dan operator platform harus dapat diakses dari satu titik autentikasi tunggal sehingga konsol Argo CD, Argo Workflows, Kubeflow, MLflow, DataHub, dan Grafana terhubung melalui satu sesi identitas, dengan dokumentasi referensi yang ringkas untuk konfigurasi setiap komponen.	Seluruh antarmuka konsol platform terhubung pada satu <i>authentication flow</i> dex dan oauth2-proxy tanpa konfigurasi identitas tambahan per layanan, serta tiap komponen memiliki dokumentasi referensi pada repositori Gitea	T-1

ID	Kebutuhan Nonfungsional	Deskripsi	Target Metrik	Tujuan
KNF-10	Efisiensi Sumber Daya	Sistem harus memanfaatkan sumber daya komputasi dan penyimpanan secara efisien untuk mengendalikan biaya tanpa mengorbankan kinerja, baik pada lingkungan <i>node</i> tunggal maupun <i>multi-node</i> .	Kompresi kolumnar pada ClickHouse, <i>autoscaling</i> berbasis HPA, VPA, dan KEDA agar utilisasi sumber daya proporsional terhadap beban, serta atribusi biaya per <i>workload</i> melalui OpenCost	T-1
KNF-11	Portabilitas	Sistem harus dapat dijalankan di berbagai lingkungan <i>deployment</i> dengan perubahan terbatas pada konfigurasi dan tanpa modifikasi kode besar, sebab seluruh komponen berdiri di atas distribusi Kubernetes standar dan <i>image open source</i> .	Dapat di- <i>deploy</i> pada distribusi Kubernetes <i>managed</i> (AWS EKS, GCP GKE, Azure AKS) maupun <i>on-premise</i> (k3s, kubeadm) hanya dengan penyesuaian <i>overlay</i> Kustomize dan parameter <i>secret</i>	T-1
KNF-12	Kemudahan Pemeliharaan	Sistem harus mudah dipelihara, dengan struktur kode dan manifes yang jelas, <i>pipeline</i> CI yang otomatis pada Tekton, serta <i>deployment</i> deklaratif dari <i>single source of truth</i> pada Gitea melalui Argo CD.	Setiap komponen dapat direkonsiliasi ulang dari <i>repository</i> Gitea tanpa intervensi manual, dan perubahan ditolak otomatis oleh <i>pull request review</i> dan <i>policy</i> Kyverno bila tidak sesuai konvensi	T-1

Setiap KNF disertai target metrik yang dapat diuji secara langsung pada Bab VI, sehingga klaim kualitas tidak berhenti pada deskripsi tetapi memiliki ambang batas yang konkret. Pemilihan ambang batas pada KNF latensi dan *throughput* mengikuti karakteristik *online feature serving*, tempat *lookup* fitur harus diselesaikan dalam waktu singkat agar layanan *inference* tetap responsif terhadap data yang bergerak cepat. Pemilihan ambang batas pada KNF observabilitas mengikuti praktik yang dirangkum oleh Cloud Native Computing Foundation (2024b) bahwa metrik, log, dan *trace* harus dapat dirujuk silang pada satu antarmuka agar diagnosis dapat ditegakkan tanpa berpindah *tool*. Berbeda dari kebutuhan fungsional yang dapat di-

petakan satu lawan satu ke tujuan, kebutuhan nonfungsional bersifat lintas-bidang sehingga satu atribut kualitas dapat menopang lebih dari satu tujuan sekaligus. Meskipun demikian, setiap KNF tetap memiliki tujuan utama tempat target metriknya paling langsung diuji, dan kolom Tujuan pada Tabel III.2 menautkan setiap kebutuhan nonfungsional ke tujuan utama tersebut. Konsekuensinya, tujuan ketiga yang menyangkut deteksi *drift* terotomasi dan *point-in-time correctness* tidak menjadi pemilik utama satu pun KNF, sebab kapabilitasnya ditegakkan secara fungsional melalui KF-03, KF-05, dan KF-07, sedangkan dimensi kualitasnya tertopang lintas-bidang oleh KNF-05 pada sisi kebenaran data dan KNF-06 pada sisi pemantauan sinyal *drift*. Daftar kebutuhan fungsional dan nonfungsional tersebut menjadi kriteria penilaian empat alternatif solusi pada Subbab III.3.

III.3 Analisis Pemilihan Solusi

Bagian ini menyusun alternatif solusi yang dapat memenuhi kebutuhan fungsional dan nonfungsional, kemudian memilih solusi terbaik dengan menggunakan skor pemenuhan kebutuhan. Penilaian skor dilakukan terhadap empat alternatif dengan menggunakan dua belas KNF dan empat belas KF sebagai kriteria, sehingga total skor maksimum sebuah alternatif adalah lima puluh dua. Setiap skor ditetapkan dengan memetakan kapabilitas terdokumentasi tiap alternatif, sebagaimana ditinjau pada Bab II, terhadap definisi kebutuhan pada Subbab III.2, sehingga penilaian bertumpu pada bukti kapabilitas dan bukan pada preferensi penulis. Alternatif yang memperoleh skor tertinggi akan dirancang lebih lanjut pada Bab IV dan diimplementasikan pada Bab V, dengan justifikasi tertulis pada kelompok kebutuhan yang membedakan peringkat antar alternatif.

III.3.1 Alternatif Solusi

Untuk membangun platform DataOps dan MLOps terintegrasi, empat alternatif solusi dipertimbangkan. Pemilihan empat alternatif didasarkan pada pemetaan pendekatan yang umum dipakai oleh organisasi yang menerapkan MLOps pada skala produksi, mencakup pendekatan terkelola penuh, pendekatan *open source* di atas Kubernetes, pendekatan kustom dari awal, dan pendekatan hibrida antara terkelola dan *open source*. Setiap alternatif diuraikan dengan kelebihan, kekurangan, dan rujukan pustaka yang relevan agar pertimbangan dapat ditelusuri kembali. Alternatif-alternatif tersebut dinilai terhadap dua puluh enam kebutuhan yang sama dari Subbab III.2 sehingga perbandingannya dapat diaudit kriteria demi kriteria.

1. Alternatif A: Layanan Terkelola dari Penyedia *Cloud*

Pendekatan ini menggunakan rangkaian layanan terkelola pada satu penyedia, mencakup layanan *ingestion*, *warehouse*, *feature store*, *training*, dan *serving*. Kelebihannya berupa kecepatan adopsi dan integrasi *native* antar layanan, sebagaimana dibahas oleh Li dkk. (2023). Kekurangannya berupa keterikatan terhadap satu penyedia, biaya operasional pada beban tinggi, dan keterbatasan dalam menyesuaikan komponen pada level rendah, sehingga *trade-off* waktu lawan anggaran pada Subbab III.1.2 tetap menjadi beban berjalan.

2. Alternatif B: Komponen *Open Source* pada Kubernetes

Pendekatan ini merangkai komponen *open source* di atas Kubernetes sebagai *orchestration plane*. Lakka (2025) dan Burgueño-Romero dkk. (2025) memperlihatkan rancangan serupa yang menjadikan Kubernetes sebagai fondasi orkestrasi bagi komponen *open source*. Kelebihannya berupa fleksibilitas, transparansi versi, portabilitas, dan kemampuan menegakkan pola GitOps. Kekurangannya berupa kebutuhan tata kelola yang lebih ketat dan kurva belajar yang lebih panjang dibandingkan layanan terkelola, sehingga beban konfigurasi dari awal pada Subbab III.1.1 perlu dikurangi melalui rancangan referensi yang utuh.

3. Alternatif C: Pengembangan Kustom dari Awal

Pendekatan ini membangun setiap *layer* secara mandiri tanpa banyak menggunakan komponen yang sudah jadi. Kelebihannya berupa kontrol penuh atas perilaku setiap komponen. Kekurangannya berupa biaya pengembangan dan pemeliharaan yang sangat besar, ketergantungan pada tim yang sangat kompeten, dan risiko menciptakan ulang masalah yang sudah diselesaikan oleh pustaka *open source* yang teruji.

4. Alternatif D: Hibrida antara Layanan Terkelola dan *Open Source*

Pendekatan ini menggunakan beberapa layanan terkelola, terutama pada *layer* dasar seperti penyimpanan dan jaringan, dipadukan dengan komponen *open source* pada *layer* DataOps dan MLOps. Kelebihannya berupa keseimbangan antara kecepatan adopsi dan fleksibilitas. Kekurangannya berupa kompleksitas integrasi antara dua jenis komponen dan kebutuhan kontrak antar *layer* yang harus dirancang dengan saksama.

Rangkaian keempat alternatif tersebut sengaja dipilih agar mencakup seluruh rentang *trade-off* waktu lawan anggaran yang dibahas pada Subbab III.1.2. Alternatif A dan D menukar waktu pengembangan dengan biaya berlangganan yang berjalan terus, Alternatif C menukar biaya berlangganan dengan waktu pengembangan yang sangat panjang, sedangkan Alternatif B berupaya menekan keduanya melalui

rancangan referensi yang dapat dipasang ulang. Posisi relatif keempatnya diukur secara kuantitatif pada Subbab III.3.2 memakai skor pemenuhan kebutuhan fungsional dan nonfungsional. Penilaian kuantitatif itu menjadi dasar keputusan akhir sehingga pemilihan solusi tidak bertumpu pada preferensi melainkan pada bukti pemenuhan kebutuhan.

III.3.2 Analisis Penentuan Solusi

Tabel III.3 menyajikan evaluasi pemenuhan kebutuhan fungsional, Tabel III.4 menyajikan evaluasi pemenuhan kebutuhan nonfungsional, dan Tabel III.5 merekapitulasi total skor gabungan keduanya. Skor untuk setiap kebutuhan pada keempat alternatif termuat pada dua tabel pertama, sedangkan tabel rekapitulasi hanya menjumlahkan keduanya menjadi skor akhir yang menjadi dasar keputusan. Alternatif B memperoleh skor total tertinggi, yaitu 49 dari 52, diikuti oleh Alternatif A dan Alternatif D dengan skor 43, dan Alternatif C dengan skor 30. Selisih skor antara Alternatif B dan dua pesaing terdekatnya sebesar enam poin terutama berasal dari KF jaminan validitas temporal, KF dukungan *vector embeddings*, KNF portabilitas, dan KNF ekstensibilitas yang tidak dipenuhi penuh oleh pendekatan terkelola maupun hibrida. Makna umum tiap nilai mengikuti keterangan di bawah masing-masing tabel, dengan parameter penuhnya dirinci pada Lampiran A.2.

Tabel III.3 Evaluasi Pemenuhan Kebutuhan Fungsional

Kebutuhan	Cloud	Open-Source	Kustom	Hibrida
KF-01: Manajemen Fitur Terpusat	2	2	1	2
KF-02: <i>Feature Serving</i> Ganda	2	2	1	2
KF-03: Jaminan Validitas Temporal	1	2	2	1
KF-04: Dukungan <i>Vector Embeddings</i>	1	2	2	1
KF-05: Otomatisasi <i>Training Pipeline</i>	2	2	1	2
KF-06: Otomatisasi <i>Deployment</i> Model	2	2	1	2
KF-07: Pemantauan <i>Drift</i> Otomatis	1	2	1	1
KF-08: Tata Kelola & <i>Data Discovery</i>	2	2	1	2
KF-09: Pelacakan Eksperimen	2	2	1	2
KF-10: <i>Versioning</i> Registri Model	2	2	1	2
KF-11: Pemrosesan <i>Batch/Stream</i>	2	2	1	2
KF-12: Konfigurasi Deklaratif	2	2	1	2
KF-13: API dan SDK Terpadu	2	1	1	1
KF-14: Manajemen Sumber Daya	2	2	1	2
Total Skor KF	25	27	16	24

Nilai 0 menandai kebutuhan tidak terpenuhi sama sekali, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter tiap nilai dirinci pada Lampiran A.2.

Alternatif B unggul terutama pada kebutuhan yang menyangkut jaminan validitas temporal, dukungan *vector embeddings*, pemantauan *drift* otomatis, ekstensibilitas,

Tabel III.4 Evaluasi Pemenuhan Kebutuhan Nonfungsional

Kebutuhan	Cloud	Open-Source	Kustom	Hibrida
KNF-01: Kinerja Latensi Rendah	2	2	2	2
KNF-02: <i>Throughput</i> Tinggi	2	2	2	2
KNF-03: Skalabilitas Horizontal	2	2	1	2
KNF-04: Keandalan & <i>Fault Tolerance</i>	2	2	1	2
KNF-05: Konsistensi & Kebenaran	1	2	2	1
KNF-06: <i>Observability</i>	2	2	1	2
KNF-07: Keamanan	2	2	1	2
KNF-08: Ekstensibilitas & Modularitas	0	2	2	1
KNF-09: Akses Konsol Terpadu	2	1	0	2
KNF-10: Efisiensi Sumber Daya	1	2	1	1
KNF-11: Portabilitas	0	2	1	1
KNF-12: Kemudahan Pemeliharaan	2	1	0	1
Total Skor KNF	18	22	14	19

Nilai 0 menandai kebutuhan tidak terpenuhi sama sekali, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter tiap nilai dirinci pada Lampiran A.2.

Tabel III.5 Total Skor Pemenuhan Kebutuhan Fungsional dan Nonfungsional

Alternatif	Skor KF (maks 28)	Skor KNF (maks 24)	Total (maks 52)
A: Layanan Terkelola <i>Cloud</i>	25	18	43
B: <i>Open Source</i> pada Kubernetes	27	22	49
C: Kustom dari Awal	16	14	30
D: Hibrida Terkelola dan <i>Open Source</i>	24	19	43

dan portabilitas. Alternatif A unggul pada kemudahan penggunaan dan kemudahan pemeliharaan, tetapi tertinggal pada validitas temporal, dukungan *vector embeddings* pada *feature store*, dan portabilitas. Alternatif C unggul pada kontrol penuh tetapi kalah pada hampir semua kebutuhan operasional. Alternatif D mendekati Alternatif A tetapi tertinggal pada portabilitas dan ekstensibilitas. Skor 0 pada Alternatif A untuk ekstensibilitas dan portabilitas mencerminkan keterikatan pada format kepemilikan tertutup yang menyulitkan penggantian komponen dan migrasi antar penyedia, sedangkan skor 0 pada Alternatif C untuk kemudahan penggunaan dan kemudahan pemeliharaan mencerminkan beban membangun dan merawat setiap *layer* tanpa komponen siap pakai. Berdasarkan skor pemenuhan kebutuhan dan analisis komparatif yang sejalan dengan Burgueño-Romero dkk. (2025), Amou Najafabadi dkk. (2024), dan Lakka (2025), Alternatif B dipilih sebagai solusi yang akan dirancang pada Bab IV dan diimplementasikan pada Bab V, sebelum posisinya terhadap penelitian terkait ditegaskan pada Subbab III.3.3.

III.3.3 Posisi terhadap Penelitian Terkait

Kesenjangan yang dipetakan pada Subbab II.11 kini ditimbang terhadap alternatif terpilih. Alternatif B yang terpilih diwujudkan sebagai platform yang menggabungkan tiga karakter yang belum dilingkupi sekaligus pada penelitian sebelumnya, yaitu integrasi DataOps dan MLOps pada satu *control plane* Kubernetes, layanan fitur *dual-store* dengan dukungan vektor HNSW, dan deteksi *drift* terotomasi yang memicu *retraining* melalui kontrol GitOps. Hsu dkk. (2024) dan Liang dkk. (2024) memberikan basis komparatif untuk menilai posisi tersebut. Platform ini menambahkan perekaman *lineage* otomatis dan *quality gate* data yang dijalankan pada *pipeline* produksi. Tabel III.6 merinci perbandingan tiap aspek arsitektur antara kondisi saat ini dan solusi terpilih beserta rujukan penelitian yang mendasari setiap peningkatan, sehingga menegaskan bagaimana platform menutup kesenjangan yang teridentifikasi pada Bab II.

Tabel III.6 Perbandingan Detail Arsitektur Saat Ini dengan yang Diusulkan

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Orkestrasi	<i>Compute</i> heterogen dengan <i>provisioning</i> manual, waktu tunggu <i>scaling</i> panjang, dan tingkat standarisasi rendah.	Platform Kubernetes terpadu dengan manajemen deklaratif dan alokasi sumber daya otomatis, sejalan dengan komponen arsitektur MLOps yang diidentifikasi Kreuzberger, Kühl, dan Hirschl (2023). GitOps dengan Argo CD memastikan perubahan infrastruktur dan aplikasi mengikuti <i>single source of truth</i> di Git.	Lakka (2025) menunjukkan bahwa adopsi Kubernetes pada perusahaan disertai praktik DevOps yang matang meningkatkan <i>deployment frequency</i> dan menekan <i>Mean Time To Recovery</i> (MTTR) secara signifikan, dan arsitektur yang diusulkan menargetkan karakteristik performa pada arah yang sama.	(Kreuzberger, Kühl, dan Hirschl 2023; Lakka 2025)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Manajemen Fitur	Logika fitur tersebar di <i>notebook</i> dan skrip dengan duplikasi tinggi dan banyak fungsi yang saling tumpang tindih.	Feast dengan <i>feature registry</i> terpusat, <i>dual serving offline/online</i> , serta dukungan <i>point-in-time correctness</i> .	Duplikasi fitur dapat ditekan, <i>training-serving skew</i> berkurang melalui pemisahan <i>offline</i> dan <i>online</i> serta <i>point-in-time retrieval</i> , dan <i>feature reuse</i> berpotensi meningkatkan signifikan.	(Munappy dkk. 2022; Polyzotis dkk. 2018)
Vector Embeddings	Fitur <i>embedding</i> tidak didukung secara <i>native</i> atau diimplementasikan secara kustom dengan latensi tinggi dan <i>throughput</i> terbatas.	Qdrant sebagai indeks vektor terpisah dari <i>online store</i> tabular Valkey, dengan HNSW <i>native</i> , API gRPC, dan filter <i>payload</i> .	Johnson, Douze, dan Jégou (2021) menunjukkan bahwa indeks vektor berbasis FAISS dapat melayani <i>billion-scale similarity search</i> dengan latensi rendah, sedangkan Malkov dan Yashunin (2020) menunjukkan <i>approximate nearest neighbor search</i> yang efisien pada indeks HNSW. Desain ini memakai Qdrant agar fitur <i>embedding</i> dilayani secara <i>online</i> tanpa membebani <i>online store key-value</i> dan tanpa membangun layanan kustom.	(Johnson, Douze, dan Jégou 2021; Malkov dan Yashunin 2020; Qdrant Team 2025)
Validitas Temporal	<i>Point-in-time join</i> dilakukan manual dan rentan kesalahan, sehingga banyak tim mengalami <i>data leakage</i> .	<i>Point-in-time join</i> otomatis dari Feast dengan pola verifikasi yang lebih sistematis.	Pendekatan ini mencegah kebocoran data temporal yang dapat menghasilkan estimasi performa yang terlalu optimistis saat evaluasi dan tidak realistis di produksi.	(Polyzotis dkk. 2018)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Pemrosesan Data	<i>Batch</i> dan <i>stream</i> diproses oleh <i>pipeline</i> terpisah tanpa arsitektur yang koheren, sehingga hasil pemrosesan tidak konsisten.	Spark sebagai mesin <i>batch processing</i> dan Flink sebagai mesin <i>stream processing</i> yang hasilnya dimaterialisasikan langsung ke <i>Feature Store</i> . Airflow mengorquestrasi <i>pipeline</i> transformasi data sebagai DAG sehingga pengembangan dan penjadwalan transformasi menjadi lebih sistematis.	Waktu pengembangan <i>pipeline</i> dapat menurun dan <i>freshness</i> data meningkat berkat pemrosesan <i>streaming</i> yang lebih efisien dan terintegrasi.	(Rodrigues dkk. 2025)
Model Training	<i>Workflow training</i> berbasis <i>notebook</i> dengan <i>tracking</i> eksperimen informal dan <i>artifact</i> tidak terkelola.	Kubeflow <i>Pipelines</i> untuk orkestrasi <i>training</i> dan MLflow untuk <i>tracking</i> eksperimen.	Reproduksibilitas meningkat melalui kontainerisasi dan pengelolaan eksperimen terpusat, sementara siklus pengembangan <i>pipeline</i> menjadi lebih terstruktur.	(Amershi dkk. 2019; Pimentel dkk. 2019)
Deployment Model	Proses <i>deployment</i> manual dengan <i>refactoring</i> besar dan sering terjadi <i>bug</i> pasca-deploy.	KServe dengan <i>InferenceService</i> deklaratif dan <i>deployment</i> otomatis melalui GitOps di atas Knative Serving. OpenTelemetry mengumpulkan log dan <i>trace inference</i> ke Loki dan Grafana Tempo sebagai dasar pemantauan dan analitik lanjutan.	Waktu <i>deployment</i> berpotensi turun secara signifikan, dan insiden terkait kesalahan konfigurasi <i>deployment</i> dapat dikurangi lewat otomasi.	(Paleyes, Urma, dan Lawrence 2022)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Pola <i>Deployment</i> Lanjut	Pola seperti <i>canary release</i> jarang digunakan, organisasi umumnya mengandalkan <i>binary switchover</i> .	Dukungan <i>canary release</i> , <i>A/B testing</i> , dan <i>automatic rollback</i> prediktif.	<i>Rollout</i> dapat dilakukan secara bertahap dan aman, sehingga MTTR menurun karena kegagalan dapat dibatasi pada <i>canary traffic</i> .	(Shankar dkk. 2022)
Deteksi <i>Drift</i>	Deteksi <i>drift</i> bersifat reaktif dengan jeda deteksi yang panjang terhadap isu penting dan perubahan gradual.	<i>Monitoring</i> proaktif dengan uji statistik, <i>alert real-time</i> , dan penetapan ambang adaptif.	Jeda deteksi <i>drift</i> dapat dipersingkat sehingga <i>retraining</i> dapat dijadwalkan lebih tepat waktu untuk menjaga kinerja model.	(Céspedes Sisniega dkk. 2024; Bayram, Ahmed, dan Kassler 2022)
Tata Kelola & <i>Lineage</i>	Dokumentasi dilakukan secara manual dan <i>audit trail</i> sering tidak lengkap atau tersebar.	DataHub dengan <i>metadata ingestion</i> otomatis dan <i>lineage</i> yang dapat ditelusuri dari <i>source</i> hingga model, dibantu OpenLineage sebagai protokol pengirim <i>event</i> lintas <i>engine</i> pemrosesan.	Waktu persiapan audit dapat berkurang dan cakupan metadata meningkat melalui proses <i>ingestion</i> dan <i>lineage</i> otomatis.	(Stoyanovich, Howe, dan Jagadish 2020; Lamer dkk. 2024)
<i>Observability</i>	Fokus pemantauan pada metrik infrastruktur, tanpa cakupan metrik ML spesifik di sebagian besar organisasi.	<i>Observability</i> mencakup metrik ML, <i>dashboard</i> kinerja model, dan <i>alert</i> berbasis indikator <i>drift</i> . Prometheus dan Grafana menjadi inti, OpenTelemetry mengalirkan log dan <i>trace</i> ke Loki dan Grafana Tempo, sementara Alertmanager mengonsolidasikan <i>alert</i> ke berbagai kanal notifikasi.	Proses <i>debugging</i> dan <i>root cause analysis</i> menjadi lebih efektif sehingga MTTR dapat diturunkan.	(Shankar dkk. 2022)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Integrasi CI/CD	CI/CD untuk <i>pipeline</i> dan model dilakukan secara manual atau semiotomatis, dengan alur kerja yang tidak seragam.	GitOps dengan Argo CD sebagai mekanisme <i>continuous deployment</i> deklaratif, dilengkapi Tekton untuk <i>continuous integration</i> dan Argo Rollouts untuk <i>progressive delivery</i> , dengan Git sebagai <i>single source of truth</i> yang mencakup seluruh konfigurasi DataOps dan MLOps.	Frekuensi <i>deployment</i> dapat meningkat dan variasi kesalahan <i>deployment</i> dapat ditekan melalui otomasi dan <i>peer review</i> pada <i>pull request</i> .	(Kreuzberger, Kühl, dan Hirschl 2023)
Pengalaman Developer	<i>Developer</i> menghabiskan banyak waktu untuk tugas repetitif, <i>onboarding</i> lama, dan penggunaan <i>tools</i> yang terpisah.	Platform terintegrasi dengan <i>self-service</i> untuk data, fitur, <i>pipeline</i> , dan akses. Dex sebagai <i>identity provider</i> OIDC dan <i>oauth2-proxy</i> menyatukan autentikasi tunggal di seluruh antarmuka pengembang.	<i>Onboarding</i> dapat dipercepat dan produktivitas <i>data scientist</i> meningkat karena hambatan akses infrastruktur berkurang.	(Paleyes, Urma, dan Lawrence 2022; Rella 2022)

Aspek	Arsitektur Saat Ini	Arsitektur Diusulkan	Manfaat yang Diharapkan	Referensi
Efisiensi Biaya	Utilisasi sumber daya tidak optimal dan tidak ada atribusi biaya yang jelas ke <i>workload</i> .	<i>Auto-scaling</i> berbasis HPA, VPA, dan KEDA, pemantauan biaya melalui OpenCost, serta alokasi sumber daya yang lebih terukur pada <i>cluster</i> Kubernetes. Seluruh komponen inti berbasis <i>open source</i> sehingga biaya lisensi dapat ditekan.	Penghematan biaya signifikan dapat dicapai melalui optimasi pemakaian sumber daya dan <i>auto-scaling</i> , sebagaimana ditunjukkan dalam berbagai studi kasus adopsi Kubernetes (Lakka 2025). Desain ini mengadopsi prinsip yang sama untuk mengoptimalkan pemakaian sumber daya.	(Lakka 2025)
Keamanan & Compliance	Kontrol akses beragam di tiap sistem, dan <i>audit</i> tersebar tanpa pandangan terpadu.	RBAC terintegrasi, <i>audit trail</i> komprehensif, dan pengecekan <i>compliance</i> yang terotomatisasi. Dex sebagai <i>identity provider</i> OIDC memusatkan identitas, oauth2-proxy menegakkan autentikasi pada antarmuka aplikasi, Kyverno menegakkan kebijakan admisi pada <i>cluster</i> , OpenBao mengelola <i>secrets</i> , sementara Falco dan Trivy Operator memantau ancaman <i>runtime</i> dan kerentanan <i>image</i> .	Risiko insiden keamanan dapat berkurang melalui kontrol terpusat dan proses audit menjadi lebih ringkas.	(Ahmad dkk. 2024)

Perbandingan pada Tabel III.6 menempatkan setiap aspek arsitektur pada dua kondisi, yaitu praktik yang terdokumentasi pada penelitian terdahulu dan kondisi sesudah

solusi terpilih diterapkan. Setiap baris menautkan peningkatan yang diklaim dengan rujukan penelitian yang mendasarinya sehingga posisi platform dapat diperiksa aspek demi aspek. Aspek tanpa dasar pada penelitian terdahulu tidak dimasukkan agar perbandingan tetap berpijak pada sumber. Rincian perwujudan tiap aspek menjadi bahan pemilihan komponen dan perancangan arsitektur pada Bab IV.

BAB IV

PERANCANGAN ARSITEKTUR PLATFORM DATAOPS DAN MLOPS

Bab ini menyajikan perancangan arsitektur platform yang mengintegrasikan DataOps dan MLOps pada Kubernetes. Pembahasan dibuka langsung dengan analisis layanan DataOps dan MLOps pada praktik industri yang menetapkan sembilan *layer* platform representatif tanpa menamai *tools* apa pun, dilanjutkan dengan pemilihan komponen *open source* untuk tiap *layer* tersebut. Setelah komponen terpilih, bab ini merancang arsitektur terintegrasi beserta empat sub-sistem yang masing-masing memenuhi satu tujuan dari Bab I, yaitu arsitektur platform terintegrasi sebagai pemenuhan T-1, sub-sistem tata kelola data sebagai pemenuhan T-2, sub-sistem deteksi *drift* dengan *retraining* otomatis sebagai pemenuhan T-3, dan sub-sistem layanan fitur *dual-store* sebagai pemenuhan T-4. Bab ini ditutup dengan alur kerja *end-to-end* yang menghubungkan keempat sub-sistem dalam satu siklus yang dapat direproduksi.

IV.1 Analisis Layanan DataOps dan MLOps pada Praktik Industri

Subbab ini menetapkan himpunan layanan representatif yang wajib dicakup arsitektur platform sebelum pemilihan *tools* dilakukan. Pembahasan dibagi menjadi dua bagian yang dibaca berurutan. Subbab IV.1.1 menyarikan bukti dari literatur mengenai komponen yang berulang pada praktik MLOps lebih dahulu, kemudian pada praktik DataOps. Subbab IV.1.2 mengonsolidasikan bukti tersebut menjadi sembilan *layer* platform yang menjadi satuan pemilihan *tools* sekaligus satuan perancangan arsitektur pada subbab-subbab berikutnya.

IV.1.1 Layanan pada Praktik MLOps dan DataOps

Kreuzberger, Kühl, dan Hirschl (2023) menurunkan sembilan komponen teknis MLOps melalui riset metode campuran yang memadukan tinjauan pustaka, tinjauan *tools*, dan wawancara pakar dari beragam domain. Komponen-komponen tersebut adalah *CI/CD component*, *source code repository*, *workflow orchestration component*, *feature store system*, *model training infrastructure*, *model registry*, *ML metadata stores*, *model serving component*, dan *monitoring component*. Bukti dari praktik industri diberikan Amershi dkk. (2019) yang mengamati sejumlah tim rekayasa per-

angkat lunak di Microsoft dan merangkum kerja mereka menjadi alur kerja *machine learning* sembilan tahap, yaitu *model requirements*, *data collection*, *data cleaning*, *data labeling*, *feature engineering*, *model training*, *model evaluation*, *model deployment*, dan *model monitoring*. Kajian tersebut memilah tahap yang berorientasi data seperti *data collection*, *data cleaning*, dan *data labeling* dari tahap yang berorientasi model seperti *feature engineering*, *model training*, *model evaluation*, *model deployment*, dan *model monitoring*. Berangkat dari metode berbeda, kedua sumber ini menamai komponen yang sebagian besar sama sehingga memperkuat keterunutan himpunan layanan yang dibahas.

Amou Najafabadi dkk. (2024) melakukan pemetaan sistematis atas 43 studi primer dan mensintesis 35 komponen arsitektur MLOps ke dalam enam kategori, sekaligus mencatat jumlah kemunculan tiap komponen pada studi-studi tersebut. Komponen *model registry*, yang pada kajian itu bernama *model repository*, menjadi komponen paling sering muncul dengan 21 kemunculan, diikuti *ML metadata repository* sebanyak 15 kemunculan, *ML experiment pipeline* sebanyak 14 kemunculan, dan *ML training pipeline* sebanyak 12 kemunculan. Komponen *data collector*, *dataset repository*, dan *inference service* masing-masing muncul 10 kali, sedangkan *feature store* muncul 8 kali. Tidak ada satu komponen pun yang mencapai mayoritas mutlak dari 43 studi, tetapi pola kemunculan tersebut menunjukkan bahwa komponen yang sama berulang lintas studi yang independen. Pola itu sejalan dengan dokumentasi resmi Google Cloud (2024) yang menyebut tujuh komponen wajib untuk MLOps level 2, yaitu *source control*, *test and build services*, *deployment services*, *model registry*, *feature store*, *ML metadata store*, dan *ML pipeline orchestrator*. Panduan praktisi dari vendor yang sama merinci kapabilitas teknis inti MLOps sebagai *experimentation*, *data processing*, *model training*, *model evaluation*, *model serving*, *online experimentation*, *model monitoring*, *ML pipeline*, dan *model registry*, ditambah dua kapabilitas lintas fungsi berupa *ML metadata and artifact repository* serta *ML dataset and feature repository* (Salama, Kazmierczak, dan Schut 2021). Konvergensi lima sumber yang berbeda metode dan sudut pandang inilah yang dijadikan dasar bukti, bukan klaim bahwa satu komponen tunggal dipakai oleh mayoritas industri.

Pada sisi DataOps, Munappy dkk. (2020) menyusun model evolusi dari analitik data *ad hoc* menuju DataOps berdasarkan studi kasus di Ericsson dan mengidentifikasi tema praktik yang berulang, antara lain *data collection*, *data testing*, dan *data monitoring* di samping otomatisasi dan pengembangan *agile*. Kajian tersebut merinci teknologi data ke dalam empat kelompok, yaitu *data engineering* yang mencakup *data collection* dan *data ingestion*, *data preparation*, *data storage*, serta *data visua-*

lization. Fase lanjutan pada model itu menegaskan perlunya *continuous testing and monitoring* pada *pipeline* data agar masalah kualitas terdeteksi sebelum menjalar ke tahap berikutnya. Definisi DataOps yang dikutip kajian tersebut juga menekankan akses terkendali terhadap data serta perlindungan privasi dan integritas data sebagai bagian tata kelola. Dengan demikian bidang data memperluas himpunan layanan MLOps melalui fungsi *data ingestion*, kualitas data, pemantauan, dan tata kelola.

Rella (2022) menempatkan tiga area penekanan utama DataOps, yaitu *data quality*, *pipeline automation*, dan *data governance*, dengan pemantauan dan observabilitas data sebagai fungsi pelengkap. Kajian yang sama menautkan area tersebut ke komponen konkret seperti *feature store* untuk pengelolaan perubahan fitur dan *model registry* untuk kendali versi model, serta menyebut deteksi *drift* dan *retraining* otomatis sebagai mekanisme menjaga kinerja model. Jain dan Das (2025) menegaskan pembagian tanggung jawab yang serupa dengan menempatkan *data engineering* pada *ingestion*, transformasi, dan penyimpanan data, sedangkan MLOps menangani *deployment*, pemantauan, dan pengelolaan model melalui *CI/CD pipeline* otomatis. Bersama-sama, ketiga sumber DataOps ini menamai fungsi *ingestion*, pemrosesan, penyimpanan, kualitas, tata kelola, dan pemantauan yang saling melengkapi dengan komponen model dari sumber MLOps. Gabungan bukti dari kedua bidang inilah yang membentuk himpunan layanan yang diklasifikasikan pada subbab berikutnya.

IV.1.2 Klasifikasi *Platform Layer*

Bukti dari kedua bidang dikonsolidasikan menjadi sembilan *layer* platform yang menjadi satuan penilaian *tools* sekaligus satuan perancangan arsitektur. Nama kesembilan *layer* tersebut adalah *Orchestration and Infrastructure Layer*, *Data Ingestion and Processing Layer*, *Data Storage Layer*, *Feature Service Layer*, *Model Lifecycle Layer*, *Data Governance Layer*, *Observability Layer*, *GitOps and Continuous Delivery Layer*, dan *Security Layer*, sesuai urutan pembahasannya pada Subbab IV.2 dan Subbab IV.3. Sebanyak empat *layer* di antaranya menaungi bidang data, yaitu *ingestion pipeline* dan pemrosesan, penyimpanan, layanan fitur, serta tata kelola data, sedangkan lima *layer* lainnya menaungi bidang model dan operasional platform. Tabel IV.1 memetakan tiap *layer* ke layanan dan komponen mayoritas yang menjadi cakupannya beserta sumber yang menaunginya sehingga setiap *layer* dapat dirunut ke bukti terbit yang mendasarinya. Urutan kesembilan *layer* juga mengikuti urutan subbab konsep pada Bab II, dengan *layer* orkestrasi dan infrastruktur berpijak pada Subbab II.2, *layer ingestion* dan pemrosesan serta *layer* penyimpanan data pada Subbab II.3, layanan fitur pada Subbab II.4, *model lifecycle* pada Subbab II.5,

Tabel IV.1 Pemetaan *Layer* Platform ke Komponen Mayoritas

<i>Layer</i>	Layanan dan Komponen Mayoritas	Sumber
<i>Orchestration and Infrastructure Layer</i>	<i>workflow orchestration, ML pipeline orchestrator, model training infrastructure, infrastructure and supporting services</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amou Najafabadi dkk. 2024; Google Cloud 2024)
<i>Data Ingestion and Processing Layer</i>	<i>data collection, data cleaning, data preprocessor, data ingestion</i>	(Amershi dkk. 2019; Amou Najafabadi dkk. 2024; Munappy dkk. 2020)
<i>Data Storage Layer</i>	<i>dataset repository, data storage, data versioning</i>	(Amou Najafabadi dkk. 2024; Munappy dkk. 2020; Jain dan Das 2025)
<i>Feature Service Layer</i>	<i>feature store (offline dan online)</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Model Lifecycle Layer</i>	<i>feature engineering, model training, model evaluation, model registry, ML metadata store, model serving component, inference service</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amershi dkk. 2019; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Data Governance Layer</i>	<i>data quality, data testing, data governance</i>	(Munappy dkk. 2020; Rella 2022; Jain dan Das 2025)
<i>Observability Layer</i>	<i>monitoring component, model monitoring, data monitoring</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Amershi dkk. 2019; Amou Najafabadi dkk. 2024; Munappy dkk. 2020)
<i>GitOps and Continuous Delivery Layer</i>	<i>CI/CD component, source code repository, model deployment, deployment services</i>	(Kreuzberger, Kühl, dan Hirschl 2023; Google Cloud 2024; Amou Najafabadi dkk. 2024)
<i>Security Layer</i>	<i>akses terkendali, kepatuhan privasi dan keamanan data, API gateway</i>	(Munappy dkk. 2020; Rella 2022; Amou Najafabadi dkk. 2024)

masing-masing masuk melalui antarmuka berbeda sesuai tanggung jawabnya. Tabel IV.2 merangkum pemetaan tiap peran ke antarmuka utama, *layer* yang diakses, dan fungsi yang dijalankan, sehingga satu *entry point* tunggal per peran menggantikan kebiasaan berpindah antar banyak *tool* pada kondisi terfragmentasi di Bab III. Karena seluruh komponen mendaftarkan katalog dan *lineage* ke satu katalog metadata bersama serta berbagi satu bidang identitas yang dirinci pada Subbab IV.4.3,

metadata yang dihasilkan satu peran langsung terlihat oleh peran lain tanpa berpindah sistem. Pemetaan peran ini tetap tanpa nama *tools* karena antarmuka tiap peran baru terikat pada *tool* tertentu setelah pemilihan pada Subbab IV.2.

Tabel IV.2 Pemetaan Peran Pengguna ke Antarmuka dan *Layer* Platform

Peran	Antarmuka Utama	<i>Layer</i> yang Diakses	Fungsi Utama
<i>Business User</i>	<i>Dashboard</i> analitik dan operasional	<i>Observability Layer</i>	<i>Dashboard</i> data dan operasional
<i>Data Engineer</i>	Katalog data dan konsol GitOps	<i>Data Governance Layer, GitOps and Continuous Delivery Layer, Orchestration and Infrastructure Layer</i>	Katalog, <i>rollout</i> konfigurasi, eksekusi <i>pipeline</i>
<i>Data Scientist</i>	<i>Notebook</i> eksperimen	<i>Model Lifecycle Layer, Feature Service Layer</i>	Eksperimen, <i>tracking</i> , registri fitur
<i>Machine Learning Engineer</i>	Konsol <i>pipeline</i> ML	<i>Model Lifecycle Layer, GitOps and Continuous Delivery Layer</i>	<i>Retraining, serving, promosi versi</i>

Sifat kesembilan *layer* ini lepas dari domain sehingga tidak terikat pada satu *use case* tertentu. *Use case* apa pun yang menjalankan seluruh sembilan *layer* dapat berperan sebagai kasus uji yang representatif bagi platform, karena verifikasi fungsionalnya akan menyentuh himpunan layanan yang sama dengan yang ditetapkan pada subbab ini. Pemilihan *open source tools* untuk tiap *layer* dibahas pada Subbab IV.2, sedangkan perancangan arsitektur kesembilan *layer* yang sama dibahas pada Subbab IV.3. Dengan demikian subbab ini menjadi titik tumpu yang menghubungkan bukti praktik industri ke rancangan sembilan *layer* sekaligus ke pemilihan kasus uji pada Bab V dan Bab VI.

IV.2 Analisis Pemilihan *Open Source Tools*

Subbab ini menurunkan pemilihan komponen konkret untuk Alternatif B, yaitu rangkaian *open source tools* di atas Kubernetes yang terpilih pada Subbab III.3.2. Pembahasan disusun mengikuti sembilan *layer* hasil klasifikasi pada Subbab IV.1, yang urutannya sejalan dengan urutan konsep pada Bab II, sehingga tiap *tool* dinilai pada konteks fungsi yang telah ditetapkan landasan buktinya. Amou Najafabadi dkk. (2024) menegaskan bahwa pemetaan eksplisit antara *tools* dan komponen arsitektur masih menjadi celah pada literatur MLOps, dan subbab ini menyediakan pemetaan tersebut untuk konteks platform *open source*. Susunan sembilan *layer* yang sama kemudian menjadi *framework* perancangan arsitektur pada Subbab IV.3, dengan tiap *layer* dirunut ke enam kategori komponen pada kajian yang sama.

Setiap *layer* yang memiliki lebih dari satu kandidat layak dinilai melalui tabel evaluasi dengan skala seragam 0 sampai 2 untuk tiap kriteria, dengan makna umum tiap nilai diberikan pada keterangan skor di bawah masing-masing tabel dan parameter penilaian tiap kriteria dirinci pada Lampiran A.3. Nilai 0 menandai kriteria yang tidak dipenuhi atau fitur yang tidak tersedia, nilai 1 menandai dukungan parsial yang masih menuntut komponen tambahan atau memikul keterbatasan berarti, dan nilai 2 menandai pemenuhan penuh oleh kapabilitas *built-in*. Penilaian diturunkan dari dokumentasi resmi dan status pemeliharaan tiap proyek, sedangkan kolom Total menjumlahkan keempat kriteria sehingga nilai tertingginya delapan. Kolom Lisensi (Yayasan) mencantumkan lisensi resmi beserta yayasan yang menaunginya sebagai bukti keterbukaan tata kelola, bersifat informatif, dan tidak mengubah perhitungan kolom Total. *Tools* dengan nilai Total tertinggi pada tiap tabel menjadi pilihan utama platform untuk fungsi yang dievaluasi, sementara *tools* berskor lebih rendah dapat tetap dipakai sebagai pendamping dengan peran berbeda sebagaimana diuraikan pada tiap *layer*.

IV.2.1 *Orchestration and Infrastructure Layer*

Layer orkestrasi menjadi fondasi tempat seluruh komponen platform dijalankan, sebagaimana dibahas pada Subbab II.2.1. Untuk lingkungan satu *node*, distribusi Kubernetes ringan yang dipertimbangkan adalah k3s, k0s, MicroK8s, dan *kind*. Semua distribusi tersebut lolos uji *conformance* CNCF sehingga API yang dipakai komponen tetap identik, dan kriteria penilaian menyoroti *footprint*, kesiapan produksi, dependensi *runtime*, serta model lisensi. Tabel IV.3 merangkum perbandingan keempatnya terhadap kriteria tersebut.

k3s dipilih karena *single binary*-nya yang menurut dokumentasi resminya berukuran di bawah seratus megabita berjalan pada memori terbatas, kesiapannya setara Kubernetes penuh untuk beban produksi, *containerd* yang tertanam menghilangkan dependensi *runtime* eksternal, dan *controller* Helm *built-in*-nya mempermudah pemasangan komponen. Sebaliknya *kind* ditujukan untuk pengujian CI dan bukan produksi, sedangkan k0s dan MicroK8s dikelola masing-masing oleh satu vendor tanpa naungan yayasan netral. Nilai Total tertinggi pada k3s mencerminkan gabungan kesiapan produksi dan *footprint* ringan yang sesuai dengan batasan implementasi BI-1 pada Bab V. Pilihan ini tidak mengikat rancangan pada satu *node*, sebab keempat distribusi berbagi API yang sama sehingga migrasi ke distribusi lain tidak mengubah manifes komponen.

Tabel IV.3 Evaluasi Alternatif Distribusi Kubernetes *Open-Source*

Distribusi	<i>Footprint</i> Ringan	Siap Produksi	Tanpa De- pendensi	Eko- sistem Add-on	Lisensi (Yayasan)	Total
k3s	2	2	2	2	Apache 2.0 (CNCF)	8
k0s	2	2	2	1	Apache 2.0 (mandiri)	7
MicroK8s	1	2	1	2	Apache 2.0 (mandiri)	6
<i>kind</i>	1	0	1	0	Apache 2.0 (CNCF)	2

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.2 *Data Ingestion and Processing Layer*

Data Ingestion and Processing Layer memindahkan data dari sumber ke penyimpanan analitik, dengan *message broker* sebagai tulang punggung aliran *event* yang dijelaskan pada Subbab II.3.2. Kandidat yang dipertimbangkan adalah Apache Kafka, Redpanda, Apache Pulsar, dan NATS JetStream, dengan perbandingan pada Tabel IV.4. Kafka dipilih karena ekosistem konektornya paling luas, *operator* Strimzi menyediakan pengelolaan deklaratif yang matang pada Kubernetes, lisensinya Apache 2.0 di bawah *Apache Software Foundation*, dan protokolnya dibaca langsung oleh konektor Flink, tabel *Kafka engine* ClickHouse, serta *scaler* KEDA. Ketergantungan silang inilah yang membuat Kafka memperoleh skor penuh pada ekosistem konektor dan kompatibilitas protokol, dua kriteria tempat sebagian alternatif tertinggal.

Tabel IV.4 Evaluasi Alternatif *Message Broker* untuk *Streaming*

<i>Message Broker</i>	Eko- sistem Konektor	Operator K8s	Lisensi Terbuka	Protokol Kafka	Lisensi (Yayasan)	Total
Apache Kafka	2	2	2	2	Apache 2.0 (ASF)	8
Redpanda	1	2	0	2	BSL 1.1 (mandiri)	5
Apache Pulsar	1	1	2	1	Apache 2.0 (ASF)	5
NATS JetStream	1	1	2	0	Apache 2.0 (CNCF)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Registrasi skema dinilai terpisah karena menjadi kontrak evolusi data lintas produsen dan konsumen, sebagaimana dibahas pada Subbab II.3.2. Tabel IV.5 membandingkan beberapa *schema registry* pada ekosistem Kafka. Karapace dipilih sebagai

registry kompatibel-Confluent berlisensi Apache 2.0 dengan dukungan Avro, JSON Schema, dan Protobuf serta verifikasi kompatibilitas saat publikasi. Karapace menyimpan skema pada *topic* internal Kafka sehingga tidak menambah basis data baru pada platform.

Tabel IV.5 Evaluasi Alternatif *Schema Registry* untuk Apache Kafka

<i>Schema Registry</i>	Lisensi Open	Kompatibilitas Confluent	Dukungan Format	Kemampuan	Lisensi (Yayasan)	Total
Karapace (Aiven)	2	2	2	1	Apache 2.0 (mandiri)	7
Apicurio Registry	2	1	2	1	Apache 2.0 (mandiri)	6
Confluent <i>Schema Registry</i>	0	2	2	2	Confluent Community (mandiri)	6
Cloudera <i>Schema Registry</i>	2	0	1	1	Apache 2.0 (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Pemrosesan data mencakup *streaming pipeline* dan *batch* yang dibahas pada Subbab II.3.3 dan Subbab II.3.4. Tabel IV.6 membandingkan *engine* pemrosesan menurut kriteria kelayakan platform. Apache Spark memperoleh Total tertinggi sebagai *engine* pemrosesan *batch* berskala besar, sedangkan Apache Flink dipilih untuk *streaming pipeline* karena dukungan *event-time* dan *exactly-once* dengan *checkpointing* yang membuatnya unggul pada kriteria *streaming* meski lebih rendah pada kriteria *batch*. Transformasi SQL deklaratif pada *warehouse layer* dikerjakan oleh dbt. Spark, Flink, dan dbt memikul peran berbeda pada *data flow* sehingga saling melengkapi tanpa tumpang tindih fungsi.

Tabel IV.6 Evaluasi Alternatif *Framework* Pemrosesan Data

<i>Framework Pemrosesan</i>	Kemampuan	Kapabilitas Batch	Kapabilitas Streaming	Komunitas	Lisensi (Yayasan)	Total
Apache Spark	2	2	1	2	Apache 2.0 (ASF)	7
Apache Flink	2	1	2	1	Apache 2.0 (ASF)	6
Apache Kafka + Streams	2	0	2	1	Apache 2.0 (ASF)	5
Apache Beam	1	1	1	1	Apache 2.0 (ASF)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.3 Data Storage Layer

Layer penyimpanan menyimpan data jangka panjang beserta versinya, dengan format tabel *lakehouse* yang menjamin transaksi dan evolusi skema, sebagaimana dibahas pada Subbab II.3.5. Kandidat format adalah Apache Iceberg, Delta Lake, dan Apache Hudi, dengan perbandingan pada Tabel IV.7. Apache Iceberg dipilih karena netralitas *engine*, dukungan katalog REST melalui Lakekeeper, dan kemampuan kueri federasi melalui Trino. Netralitas *engine* inilah yang membuat Iceberg unggul, sebab tabel yang sama dapat dibaca dan ditulis oleh Trino, Spark, maupun Flink tanpa migrasi data fisik.

Tabel IV.7 Evaluasi Alternatif Format Tabel *Lakehouse Open-Source*

Format Tabel	Kemampuan	Transaksi ACID	Evolusi Skema	Integrasi Engine	Lisensi (Yayasan)	Total
Apache Iceberg	2	2	2	2	Apache 2.0 (ASF)	8
Delta Lake	2	2	1	1	Apache 2.0 (LF)	6
Apache Hudi	1	2	1	1	Apache 2.0 (ASF)	5
Parquet (tanpa format tabel)	2	0	1	2	Apache 2.0 (ASF)	5

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Penyimpanan objek menjadi landasan bagi *data lake*, *model registry*, dan pencadangan, sebagaimana dibahas pada Subbab II.3.6. Tabel IV.8 membandingkan empat penyedia objek S3-kompatibel. MinIO dipilih karena *footprint* ringan pada satu *node*, kompatibilitas API S3 yang luas, dukungan enkripsi sisi *server* berbasis KMS, dan kemampuan berjalan pada modus distribusi maupun *single-node*. Kompatibilitas API S3 yang luas membuat MinIO dapat dipakai lintas komponen tanpa penyesuaian klien.

Tabel IV.8 Evaluasi Alternatif Penyimpanan Objek S3-Kompatibel *Open-Source*

Penyimpanan Objek	Kompatibilitas S3	<i>Footprint</i> Satu Node	Enkripsi KMS	Dukungan K8s	Lisensi (Yayasan)	Total
MinIO	2	2	2	2	AGPL v3 (mandiri)	8
SeaweedFS	1	2	1	1	Apache 2.0 (mandiri)	5
Ceph RGW	2	0	2	2	LGPL 2.1 (LF)	6
Garage	1	2	0	1	AGPL v3 (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Versi data pada *layer* objek dinilai terpisah karena menyangkut ketertelusuran peru-

bahan *dataset*, sebagaimana dibahas pada Subbab II.3.6. Tabel IV.9 membandingkan lakeFS, DVC, Project Nessie, dan Pachyderm. lakeFS dipilih karena *zero-copy branching* bekerja langsung di atas MinIO tanpa terikat satu format tabel, antarmukanya tetap S3 sehingga *engine* pemrosesan tidak perlu diubah, dan lisensinya Apache 2.0 sementara edisi *platform* Pachyderm memakai lisensi *source-available*. Model *branching* bergaya Git ini menjaga jejak versi data tanpa menggandakan berkas.

Tabel IV.9 Evaluasi Alternatif Pengelola Versi Data *Open-Source*

Pengelola Versi	<i>Zero-copy Branching</i>	Integrasi Objek S3	Skala Data Besar	Lisensi Terbuka	Lisensi (Yayasan)	Total
lakeFS	2	2	2	2	Apache 2.0 (mandiri)	8
Project Nessie	2	1	1	2	Apache 2.0 (mandiri)	6
DVC	1	1	1	2	Apache 2.0 (mandiri)	5
Pachyderm	1	1	1	0	<i>Source-available</i> (mandiri)	3

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.4 *Feature Service Layer*

Layer layanan fitur menghubungkan *data flow* dengan *model flow* melalui definisi fitur yang sama, sebagaimana dibahas pada Subbab II.4.1. Tabel IV.10 membandingkan beberapa *framework feature store open source*. Feast dipilih karena modularitas penyimpanan dan kontrak API yang konsisten lintas *offline* dan *online*, yang tecermin pada skor penuh di seluruh kriteria termasuk ekstensibilitas dan integrasi K8s. Hopsworks dan Featureform memperoleh skor lebih rendah pada ekstensibilitas dan komunitas sehingga Total keduanya berada di bawah Feast.

Tabel IV.10 Evaluasi Alternatif *Feature Store Open-Source*

<i>Feature Store</i>	Kemampuan	Ekstensibilitas	Komunitas	Integrasi K8s	Lisensi (Yayasan)	Total
Feast	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Hopsworks <i>Feature Store</i>	1	1	1	1	AGPL v3 (mandiri)	4
Feathr (LinkedIn)	0	1	0	1	Apache 2.0 (LF AI & Data)	2
Featureform	1	1	0	1	MPL 2.0 (mandiri)	3

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Feature store dipisah menjadi *offline* untuk *training* dan *online* untuk *inference* berla-

tensi rendah, sebagaimana dibahas pada Subbab II.4.2. Tabel IV.11 dan Tabel IV.12 menilai kandidat untuk kedua peran tersebut. ClickHouse dipilih sebagai *offline store* karena kompresi kolumnar dan latensi kueri agregasi yang rendah, sedangkan Valkey dipilih sebagai *online store* karena kompatibilitas *wire-protocol* RESP dengan ekosistem klien Redis serta lisensi BSD di bawah Linux Foundation yang tetap terbuka pasca-perubahan lisensi Redis. Pemilihan keduanya mencerminkan perbedaan karakter beban antara kueri agregasi pada jutaan baris dan *lookup key-value* dalam memori berlatensi rendah saat *inference*.

Tabel IV.11 Evaluasi Alternatif Penyimpanan *Offline* (OLAP)

Penyimpanan <i>Offline</i>	Kema- tangan	Performa <i>Query</i>	Duku- ngan <i>Ingestion</i>	Komu- nitas	Lisensi (Yayasan)	Total
ClickHouse	2	2	2	2	Apache 2.0 (mandiri)	8
Apache Pinot	1	2	2	1	Apache 2.0 (ASF)	6
Apache Druid	2	2	2	1	Apache 2.0 (ASF)	7
Apache Kudu	1	1	1	1	Apache 2.0 (ASF)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Tabel IV.12 Evaluasi Alternatif Penyimpanan *Online* (Latensi Rendah)

Penyimpanan <i>Online</i>	Kema- tangan	Latensi	<i>Through- put</i>	Lisensi <i>Open</i>	Lisensi (Yayasan)	Total
Valkey (RESP)	2	2	2	2	BSD-3 (LF)	8
Redis <i>Community</i>	2	2	2	1	AGPL v3 (mandiri)	7
DragonflyDB	1	2	2	0	BSL 1.1 (mandiri)	5
Apache Cassandra	2	1	2	2	Apache 2.0 (ASF)	7

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Fitur *embedding* berdimensi tinggi memerlukan indeks tetangga terdekat yang dibahas pada Subbab II.4.3. Tabel IV.13 membandingkan beberapa *vector index open source*. Qdrant dipilih karena dukungan HNSW *native*, mode gRPC berlatensi rendah, dan kemampuan filter pada *payload* yang menyatu dengan kueri kemiripan. Pemisahan *vector index* dari *online store* tabular menjaga tiap penyimpanan tetap dioptimasi untuk karakter kuerinya sendiri.

Tabel IV.13 Evaluasi Alternatif *Vector Index Open-Source*

<i>Vector Index</i>	Kema- tangan	Latensi Rendah	Komu- nitas	Opera- bilitas K8s	Lisensi (Yayasan)	Total
Qdrant (HNSW)	2	2	1	2	Apache 2.0 (mandiri)	7
Milvus	2	2	1	1	Apache 2.0 (LF AI & Data)	6
Weaviate	1	1	1	1	BSD-3 (mandiri)	4
pgvector (PostgreSQL)	2	1	1	2	PostgreSQL <i>License</i> (komunitas)	6

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.5 *Model Lifecycle Layer*

Model Lifecycle Layer mengantar model dari eksperimen sampai *serving*, dimulai dari *tracking* eksperimen dan *registry* model pada Subbab II.5.1. Tabel IV.14 membandingkan beberapa platform *tracking*. MLflow dipilih karena menyatukan *tracking* eksperimen, *registry* model, dan API *deployment* pada satu layanan dengan *backend* PostgreSQL dan *artifact store* MinIO. Penyatuan ketiga fungsi ini memberi MLflow keunggulan integrasi dibanding *tools tracking* yang hanya menangani pencatatan metrik.

Tabel IV.14 Evaluasi Alternatif *Experiment Tracking* dan *Model Registry*

<i>Tracking & Registry</i>	Kema- tangan	Eksten- sibilitas	Komu- nitas	Integrasi	Lisensi (Yayasan)	Total
MLflow	2	2	2	2	Apache 2.0 (LF)	8
DVC (<i>Data Version Control</i>)	1	1	1	1	Apache 2.0 (mandiri)	4
TensorBoard	2	2	1	0	Apache 2.0 (mandiri)	5
Neptune	1	1	1	1	<i>Proprietary SaaS</i> (klien Apache 2.0)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Orkestrasi *training* dinilai terpisah karena menyangkut eksekusi *pipeline* pada Kubernetes, sebagaimana dibahas pada Subbab II.5.2. Tabel IV.15 membandingkan Kubeflow Pipelines, Argo Workflows, dan Apache Airflow. Kubeflow Pipelines dipilih untuk *training flow* karena *component* berbasis kontainer dengan kontrak input dan output yang ditegakkan Pipeline IR, sedangkan Argo Workflows dipakai untuk *control loop* CronWorkflow yang memicu *retraining*. Pemisahan peran kedua *orchestrator* menjaga *training pipeline* dapat dipromosikan tanpa mengganggu *control loop* pemantauan. Apache Airflow pada tabel yang sama dipilih sebagai

orchestrator pipeline data batch, sehingga tanggung jawab orkestrasi data terpisah dari orkestrasi *training*.

Tabel IV.15 Evaluasi Alternatif Orkestrasi ML *Open-Source*

Orkestrasi ML	Kematangan	K8s-Native	Pipeline ML	Komunitas	Lisensi (Yayasan)	Total
Kubeflow Pipelines	1	2	2	2	Apache 2.0 (CNCF)	7
Apache Airflow	2	1	1	2	Apache 2.0 (ASF)	6
Argo Workflows	2	2	1	1	Apache 2.0 (CNCF)	6
Prefect	1	1	1	1	Apache 2.0 (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Model serving mengakhiri pembahasan *layer* ini dengan menghadirkan model sebagai layanan, sebagaimana dibahas pada Subbab II.5.4. Tabel IV.16 membandingkan *framework serving* menurut kriteria kelayakan platform. KServe dipilih karena dukungan banyak *runtime*, *autoscaling* termasuk *scale-to-zero* melalui Knative, dan integrasi dengan praktik GitOps. Nilai Total tertinggi pada KServe mencerminkan kematangan, skalabilitas, dan dukungan *multi-framework* yang tidak dimiliki penuh oleh *framework serving* berbasis satu *framework*.

Tabel IV.16 Evaluasi Alternatif *Model Serving*

Model Serving	Kematangan	Skalabilitas	Framework	Komunitas	Lisensi (Yayasan)	Total
KServe	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Seldon Core	1	1	2	1	BSL 1.1 (mandiri)	5
BentoML	1	1	2	1	Apache 2.0 (mandiri)	5
TorchServe	0	1	0	1	Apache 2.0 (LF/PyTorch)	2

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.6 Data Governance Layer

Layer tata kelola menegakkan katalog, kualitas, dan *lineage* data sepanjang siklus, sebagaimana dibahas pada Subbab II.6. Fungsi katalog metadata menjadi pusat *layer* ini karena menautkan aset data lintas komponen DataOps dan MLOps. Tabel IV.17 membandingkan beberapa pilihan katalog metadata. Kriteria penilaian menyoroti keluasan integrasi, dukungan *lineage*, kematangan proyek, dan model lisensi.

DataHub dipilih sebagai katalog metadata karena dukungan integrasi luas dengan komponen DataOps dan MLOps serta penerimaan *lineage* melalui standar terbuka OpenLineage. Great Expectations melengkapi *layer* ini sebagai kontrak kualitas yang dijalankan pada *pipeline* produksi, sedangkan OpenLineage menjadi protokol *lineage* yang menyeragamkan jejak dari *ingestion* hingga model. Gabungan ketiganya bekerja sebagai satu bidang tata kelola, yaitu katalog untuk *data discovery*, kontrak untuk kualitas, dan protokol untuk *lineage*. Pemisahan peran ini menghindari tumpang tindih fungsi antara *tools* katalog dan *tools* kualitas.

Tabel IV.17 Evaluasi Alternatif Manajemen Metadata dan Tata Kelola

Metadata & Tata Kelola	Kematangan	Ekstensibilitas	Komunitas	Integrasi	Lisensi (Yayasan)	Total
DataHub (LinkedIn)	2	2	2	2	Apache 2.0 (LF AI & Data)	8
Apache Atlas	2	1	1	1	Apache 2.0 (ASF)	5
OpenMetadata	1	1	1	2	Apache 2.0 (LF)	5
Amundsen (Lyft)	1	1	0	1	Apache 2.0 (LF AI & Data)	3

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.7 Observability Layer

Layer observabilitas menyatukan metrik, log, dan *trace* pada satu antarmuka, sebagaimana dibahas pada Subbab II.8. Tabel IV.18 membandingkan beberapa *observability stack open source*. Kombinasi Prometheus untuk metrik, Loki untuk log, dan Grafana Tempo untuk *trace* dengan OpenTelemetry sebagai *collector* bersama dipilih karena korelasi antar pilar dapat ditegakkan melalui label *trace_id* yang seragam. Grafana menjadi antarmuka visualisasi tunggal yang menyatukan ketiga pilar tersebut.

Tabel IV.18 Evaluasi Alternatif *Monitoring* dan *Observability*

Monitoring & Observability	Kematangan	Ekstensibilitas	Komunitas	Integrasi K8s	Lisensi (Yayasan)	Total
Prometheus + Grafana	2	2	2	2	Apache 2.0 (CNCF) + AGPL v3 (mandiri)	8
InfluxDB + Chronograf	1	1	1	1	MIT (mandiri)	4
Elastic Stack (ELK)	2	1	1	2	AGPL v3 (mandiri)	6
Jaeger + OpenTelemetry	2	1	2	2	Apache 2.0 (CNCF)	7

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Antarmuka *business intelligence* dinilai terpisah karena menyajikan hasil kueri lintas basis data pada satu *dashboard layer*, sebagaimana dibahas pada Subbab II.8. Tabel IV.19 membandingkan beberapa pilihan BI *open source*. Apache Superset dipilih karena menyatukan kueri SQL lintas ClickHouse, Trino, dan MySQL pada satu antarmuka *dashboard*. Pemisahan Superset untuk *dashboard* analitik dari Grafana untuk pemantauan sistem menjaga tiap antarmuka fokus pada jenis pengamatan yang berbeda.

Tabel IV.19 Evaluasi Alternatif *Business Intelligence* dan *Dashboarding*

<i>BI Tool</i>	Kema- tangan	Konektor SQL	Multi- Tenant K8s	Komu- nitas	Lisensi (Yayasan)	Total
Apache Superset	2	2	2	2	Apache 2.0 (ASF)	8
Metabase	2	1	1	1	AGPL v3 (mandiri)	5
Redash	1	1	1	1	BSD-2 (mandiri)	4
Lightdash	1	1	1	1	MIT (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

IV.2.8 *GitOps and Continuous Delivery Layer*

Layer GitOps menempatkan repositori Git sebagai *single source of truth* konfigurasi sistem, sebagaimana dibahas pada Subbab II.9. Tabel IV.20 membandingkan beberapa *GitOps controller open source*. Argo CD dipilih sebagai *operator* GitOps karena merekonsiliasi *state cluster* dengan deklarasi pada Git secara berkelanjutan dan menyediakan antarmuka penelusuran sinkronisasi yang matang. Kriteria penilaian menyoroti model rekonsiliasi, dukungan *multi-tenant*, dan kematangan ekosistem.

Rantai *continuous delivery* dilengkapi Gitea sebagai repositori *self-hosted*, Tekton sebagai *pipeline* CI, dan Argo Rollouts untuk *deployment* progresif berbasis *canary*. Seluruh manifes, *chart*, dan *overlay* dijaga keempat komponen agar berada pada satu *control plane* yang ditarik Argo CD tanpa ketergantungan penyedia eksternal. Pembagian peran menempatkan Argo CD pada rekonsiliasi *state* dan Tekton pada *build* artefak sehingga keduanya tidak tumpang tindih. Rantai ini menjadi mekanisme yang memicu *retraining* model melalui kontrol deklaratif yang sama.

IV.2.9 *Security Layer*

Layer keamanan bekerja dengan pola *defense in depth* yang dibahas pada Subbab II.10, mencakup identitas, *secret*, *service mesh*, kebijakan, dan pemantauan *runtime*. Untuk identitas terpadu, Tabel IV.21 membandingkan beberapa *identity*

Tabel IV.20 Evaluasi Alternatif *GitOps Controller Open-Source*

<i>GitOps Controller</i>	Kema- tangan	K8s- Native	Antar- muka	Komu- nitas	Lisensi (Yayasan)	Total
Argo CD	2	2	2	2	Apache 2.0 (CNCF)	8
Flux CD	2	2	1	1	Apache 2.0 (CNCF)	6
Rancher Fleet	1	2	1	1	Apache 2.0 (mandiri)	5
Jenkins X	1	1	1	0	Apache 2.0 (CDF)	3

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

provider open source. Dex dipilih sebagai *identity provider* OIDC karena *footprint* ringan, dukungan federasi terhadap penyedia eksternal, dan integrasi sederhana dengan Kubernetes. *oauth2-proxy* dan *SpiceDB* melengkapi *layer* identitas untuk konsol tanpa OIDC *native* dan otorisasi granular.

Tabel IV.21 Evaluasi Alternatif *Identity Provider Open-Source*

<i>Identity Provider</i>	Bobot <i>Footprint</i>	Federasi OIDC	Opera- bilitas K8s	Kema- tangan	Lisensi (Yayasan)	Total
dex IdP	2	2	2	2	Apache 2.0 (CNCF)	8
Keycloak	1	2	2	2	Apache 2.0 (CNCF)	7
Authelia	2	1	1	1	Apache 2.0 (mandiri)	5
Authentik	0	2	1	1	MIT (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Pengelolaan *secret* dinilai terpisah karena menyimpan kredensial dan kunci enkripsi platform, sebagaimana dibahas pada Subbab II.10.1. Tabel IV.22 membandingkan beberapa *secret manager open source*. OpenBao dipilih sebagai *fork open source* dari HashiCorp Vault di bawah Linux Foundation karena menjamin penyimpanan terenkripsi dan penerbitan kredensial dinamis tanpa basis data eksternal berkat *integrated storage* Raft. External Secrets Operator menyalurkan *secret* ke Secret Kubernetes dengan rotasi otomatis.

Komunikasi antar-layanan dan *mesh edge* dibahas pada Subbab II.10.2. Tabel IV.23 dan Tabel IV.24 menilai *service mesh* dan *API gateway*. Istio dipilih sebagai *service mesh* karena *mutual TLS* seragam, kontrol trafik *layer* aplikasi, dan integrasi telemetri dengan OpenTelemetry, sedangkan Apache APISIX dipilih sebagai *API gateway* yang menyaring trafik masuk dan menjembatani mTLS terhadap konsumen di luar

Tabel IV.22 Evaluasi Alternatif *Secret Manager*

<i>Secret Manager</i>	Lisensi Open	Rotasi Dinamis	Integrasi ESO	Kemampuan	Lisensi (Yayasan)	Total
OpenBao	2	2	2	1	MPL 2.0 (LF)	7
HashiCorp Vault Community	0	2	2	2	BUSL 1.1 (mandiri)	6
Bitnami Sealed Secrets	2	0	0	2	Apache 2.0 (mandiri)	4
Mozilla SOPS	2	0	0	2	MPL 2.0 (CNCF)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

mesh. Istio dan APISIX memisahkan kontrol trafik internal dari kontrol tepi tanpa fungsi yang tumpang tindih.

Tabel IV.23 Evaluasi Alternatif *Service Mesh*

<i>Service Mesh</i>	Kemampuan	Fitur L7	Eko-sistem CRD	Komunitas	Lisensi (Yayasan)	Total
Istio ambient/sidecar	2	2	2	2	Apache 2.0 (CNCF)	8
Linkerd	2	1	1	1	Apache 2.0 (CNCF)	5
Cilium Service Mesh	1	1	1	2	Apache 2.0 (CNCF)	5
Consul Connect	1	1	1	1	BUSL 1.1 (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Tabel IV.24 Evaluasi Alternatif *API Gateway Open-Source*

<i>API Gateway</i>	Kemampuan	Lisensi Open	Operabilitas K8s	Plugin/ Ekstensi	Lisensi (Yayasan)	Total
Apache APISIX	2	2	2	2	Apache 2.0 (ASF)	8
Kong Gateway OSS	2	2	2	1	Apache 2.0 (mandiri)	7
Emissary Ingress (Ambassador)	1	2	2	1	Apache 2.0 (CNCF)	6
NGINX Ingress	1	2	2	1	Apache 2.0 (komunitas Kubernetes)	6

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Penegakan kebijakan *admission* dinilai terpisah, sebagaimana dibahas pada Subbab II.10.2. Tabel IV.25 membandingkan beberapa *policy engine open source*. Kyverno dipilih sebagai *policy engine native* Kubernetes dengan sintaks YAML ringkas serta dukungan *mutate*, *validate*, dan *generate*. Sintaks berbasis YAML

membuat kebijakan Kyverno ditulis tanpa bahasa kebijakan terpisah seperti Rego, sehingga tetap seragam dengan manifes Kubernetes lain.

Tabel IV.25 Evaluasi Alternatif *Policy Engine Open-Source*

<i>Policy Engine</i>	Sintaks <i>Native</i>	Mode <i>Mutate</i>	Pela- poran Pelang- garan	Komu- nitas	Lisensi (Yayasan)	Total
Kyverno	2	2	2	2	Apache 2.0 (CNCF)	8
OPA Gatekeeper	1	1	1	2	Apache 2.0 (CNCF)	5
jsPolicy	1	1	1	0	Apache 2.0 (mandiri)	3
Kubewarden	1	1	2	1	Apache 2.0 (CNCF)	5

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Pemantauan ancaman pada *runtime layer* melengkapi *layer* keamanan, sebagaimana dibahas pada Subbab II.10.2. Tabel IV.26 membandingkan beberapa *tools runtime security open source*. Falco dipilih sebagai detektor berbasis eBPF yang memantau *syscall*, dilengkapi Trivy Operator untuk pemindaian *image*, Velero untuk pencadangan, dan Chaos Mesh untuk uji ketahanan. Setiap *tools* mencakup dimensi berbeda dari keamanan *runtime* sehingga keempatnya tidak saling menggantikan.

Tabel IV.26 Evaluasi Alternatif *Runtime Security Open-Source* pada Kubernetes

<i>Runtime Security</i>	Kema- tangan	Cakupan eBPF/ Kernel	Aturan <i>Built-in</i>	Komu- nitas	Lisensi (Yayasan)	Total
Falco	2	2	2	2	Apache 2.0 (CNCF)	8
Cilium Tetragon	1	2	1	1	Apache 2.0 (CNCF)	5
Aqua Tracee	1	2	1	1	Apache 2.0 (mandiri)	5
Sysdig Secure OSS	1	1	1	1	Apache 2.0 (mandiri)	4

Nilai 0 menandai kriteria tidak terpenuhi, nilai 1 terpenuhi sebagian, dan nilai 2 terpenuhi seluruhnya. Parameter penilaian tiap kriteria dirinci pada Lampiran A.3.

Pemetaan pada subbab ini menautkan tiap *layer* arsitektur ke satu *tool* utama beserta pendampingnya, sehingga perancangan arsitektur pada subbab-subbab berikutnya dapat langsung merujuk komponen terpilih tanpa mengulang pertimbangan pemilihan. *Tools* dengan nilai Total tertinggi pada tiap tabel menjadi pilihan utama *layer*-nya, sedangkan *tools* pendamping memikul peran yang berbeda tanpa tumpang tindih fungsi, seperti Flink untuk *streaming* di samping Spark untuk *batch* dan Argo

Workflows untuk *control loop* di samping Kubeflow Pipelines untuk *training*. Pemisahan konsep pada Bab II dari pemilihan pada subbab ini menjaga tinjauan pustaka tetap umum sementara keputusan *tools* ditegakkan dengan bukti skor. Dengan pemetaan ini, keputusan teknis di seluruh laporan dapat dirunut dari konsep pada Bab II, ke pemilihan pada subbab ini, hingga perwujudan pada Bab V.

IV.3 Perancangan Arsitektur Terintegrasi

Bagian ini menjawab T-1 dengan merancang arsitektur platform DataOps dan MLOps terintegrasi pada Kubernetes. Arsitektur ini menggantikan kondisi fragmentasi pada Gambar III.1 dan Gambar III.2 dari Bab III melalui tiga penyatuan, yaitu satu *control plane* Kubernetes untuk seluruh komponen, satu sumber rujukan konfigurasi pada repositori Git yang dijaga layanan rekonsiliasi GitOps, dan satu antarmuka observabilitas untuk metrik, log, serta *trace*. Penyatuan pada tiga titik itu memutus efek domino fragmentasi yang dibahas pada Subbab III.1.3, karena kerusakan pada satu *layer* tertahan pada batas kontraknya dan aset lintas *layer* dapat dirujuk silang melalui satu katalog metadata ber-*lineage*. Arsitektur disusun langsung dalam sembilan *layer* hasil klasifikasi Subbab IV.1 yang saling terhubung melalui kontrak antarmuka eksplisit, yaitu *Orchestration and Infrastructure Layer*, *Data Ingestion and Processing Layer*, *Data Storage Layer*, *Feature Service Layer*, *Model Lifecycle Layer*, *Data Governance Layer*, *Observability Layer*, *GitOps and Continuous Delivery Layer*, serta *Security Layer*. Pemisahan yang sama dengan demikian dipakai dari klasifikasi layanan, penilaian *tools* pada Subbab IV.2, sampai perancangan pada subbab ini, tanpa taksonomi perantara. Susunan ini bukan taksonomi baru karena setiap *layer* berpijak pada baris bersumber Tabel IV.1 dan mengikuti urutan subbab konsep Bab II sebagaimana dipetakan pada Subbab IV.1.2. Subbab berikut merinci kesembilan *layer* tersebut satu per satu beserta diagram *tools* yang dipakai.

Amou Najafabadi dkk. (2024) mengelompokkan komponen arsitektur MLOps yang telah diperkenalkan pada Subbab IV.1 ke dalam enam kategori, yaitu *data curation*, *storage and versioning*, *ML training*, *CI/CD*, *inference*, serta *infrastructure and supporting services*, sedangkan Kreuzberger, Kühl, dan Hirschl (2023) merinci sembilan komponen teknis mulai dari komponen *CI/CD* dan *feature store* hingga *model registry* dan komponen pemantauan. Anotasi sumber bagi tiap *layer* berasal dari kedua rujukan itu. *Data Ingestion and Processing Layer* menampung kategori *data curation* dengan komponen *data collector* pada *ingress flow* dan *data preprocessor* pada *processing pipeline*, *Data Storage Layer* menampung komponen penyimpanan dan versi data dari kategori *storage and versioning*, dan *Feature Service Layer*


menampung *feature store* dari kategori yang sama sebagai layanan tersendiri karena melayani *training* sekaligus inferensi. *Model Lifecycle Layer* menampung kategori *ML training* bersama *model registry*, penyimpan metadata ML, serta kategori *inference* pada bagian *model serving*-nya, sesuai baris kelimanya pada Tabel IV.1 yang memuat *model serving component* dan *inference service*. *Orchestration and Infrastructure Layer* menampung kategori *infrastructure and supporting services*, *GitOps and Continuous Delivery Layer* menampung kategori CI/CD, dan *Security Layer* menampung sisi keamanan kategori pendukung tersebut bersama tuntutan akses terkendali pada definisi DataOps (Munappy dkk. 2020). *Observability Layer* menampung komponen pemantauan, sedangkan *Data Governance Layer* memisahkan katalog, *lineage*, dan kualitas data dari pemantauan operasional karena integrasi DataOps menuntut tata kelola data sebagai fungsi lintas *layer* (Munappy dkk. 2020). Dengan *tools* hasil pemilihan pada Subbab IV.2, tujuh komponen wajib MLOps *level 2* yang diperkenalkan pada Subbab IV.1.1 kini terpetakan lengkap, yaitu *source control* pada Gitea, layanan uji dan *build* pada Tekton, layanan *deployment* pada Argo CD, *model registry* pada MLflow, *feature store* pada Feast, penyimpan metadata ML pada MLflow dan basis metadata Kubeflow Pipelines, serta orkestrator *pipeline* pada Kubeflow Pipelines dengan pemicu *retraining* otomatis dari deteksi *drift* (Google Cloud 2024).

IV.3.1 *Orchestration and Infrastructure Layer*

Orchestration and Infrastructure Layer menggunakan Kubernetes (Cloud Native Computing Foundation 2024a) sebagai *orchestration plane* untuk seluruh komponen platform. Karena *orchestration plane* ini memakai API Kubernetes standar, rancangan tidak terikat pada satu distribusi maupun satu *node*, dan komponen yang sama dapat dijalankan ulang pada *cluster* berskala lebih besar tanpa mengubah manifest. *Scaling* otomatis dijalankan oleh tiga komponen yang saling melengkapi, yaitu HPA Kubernetes pada level Pod yang membaca metrik dari metrics-server, VPA *recommender* untuk rekomendasi *resource request*, dan KEDA (KEDA Authors 2025) untuk *scaling* berbasis *event* dari Kafka atau Prometheus. Sudut *scaling* yang berbeda ditutup oleh ketiga mekanisme itu, yaitu HPA dan VPA menimbang tekanan sumber daya pada Pod, sedangkan KEDA menimbang panjang antrean *event*, sehingga beban terukur maupun lonjakan *event* sama-sama tertangani.

Kueue (Kueue Authors 2024) mengelola antrean dan kuota *training job* melalui *ClusterQueue* sehingga sumber daya komputasi terbagi adil antar-*tenant* sesuai prioritas, dengan *job* di luar kuota berstatus *Pending* hingga kuota tersedia. Perubahan

konfigurasi menuju *layer* ini mengalir dari *GitOps and Continuous Delivery Layer* yang dirinci pada Subbab IV.3.8. Karena konfigurasi *layer* ini ditarik dari repositori Git oleh layanan rekonsiliasi GitOps, *state orchestration plane* selalu dapat direproduksi dari isi repositori tanpa penyetelan manual. Cert-manager (cert-manager Contributors 2025) mengelola sertifikat TLS sehingga identitas mesin diperbarui otomatis, dan Gambar IV.2 merinci *orchestration plane*, *autoscaling*, serta cert-manager pada *layer* fondasi ini.




Gambar IV.2 Rincian *Orchestration and Infrastructure Layer*

IV.3.2 Data Ingestion and Processing Layer

Ingress flow pada *Data Ingestion and Processing Layer* menggunakan Apache Kafka (Apache Software Foundation 2024c) sebagai *message broker* utama dengan operator Strimzi pada *cluster* Kubernetes. *Kafka Connect* digunakan untuk integrasi dengan sumber data eksternal melalui konektor Debezium untuk *change data capture*, dan *Karapace* digunakan sebagai registri skema yang memvalidasi kompatibilitas setiap pesan. Kafbat UI menyediakan pemantauan *topic* dan konsumen sehingga tim data dapat mengawasi kesehatan aliran masuk. Dari *topic* yang tervalidasi skema itulah *processing pipeline* pada *layer* yang sama mengambil alih.

Processing pipeline dibagi menjadi dua, yaitu *batch pipeline* dan *stream pipeline*, sehingga kebutuhan latensi berbeda dapat dilayani tanpa kompromi. *Batch pipeline* menggunakan Apache Spark (Apache Software Foundation 2024d) dan dbt untuk transformasi pada *data warehouse*, sedangkan *stream pipeline* menggunakan Apache Flink (Apache Software Foundation 2024b) untuk *windowing*, agregasi, dan deteksi pola. Orkestrasi *batch pipeline* dirancang menggunakan Apache

Airflow (Apache Software Foundation 2024a) sebagai *scheduler* DAG yang merangkai langkah validasi, transformasi, dan materialisasi fitur menjadi satu *pipeline* data terjadwal. Definisi DAG ditarik dari Git melalui mekanisme *git-sync* sehingga perubahan *pipeline* mengikuti alur GitOps yang sama dengan komponen platform lain. Setiap langkah transformasi dijalankan sebagai *pod* terisolasi melalui KubernetesPodOperator agar batas sumber daya dapat ditetapkan per langkah dan kegagalan satu langkah tidak menjalar ke langkah lain. Pembagian peran ini menempatkan Airflow sebagai *orchestrator* bidang data dan Kubeflow Pipelines sebagai *orchestrator model training*, sehingga tanggung jawab DataOps dan MLOps tidak bercampur dalam satu *controller*. Trino (Trino Software Foundation 2024) menyediakan kueri federasi pada beberapa sumber data sekaligus, dan Gambar IV.3 merinci *ingress flow* beserta kedua *processing pipeline*, orkestrasi Airflow, dan kueri federatif Trino pada satu *layer*.




Gambar IV.3 Rincian *Data Ingestion and Processing Layer*

IV.3.3 *Data Storage Layer*

Penyimpanan jangka panjang pada *data lake* menggunakan MinIO sebagai *object store* dengan enkripsi sisi *server* melalui KES dan format Apache Iceberg sebagai *table format*. Katalog Iceberg dikelola oleh Lakekeeper (Lakekeeper Authors 2025) yang memberikan *REST API* kompatibel dengan klien Iceberg standar dan dapat dipakai oleh Spark, Trino, dan Flink secara seragam. lakeFS (Treeverse Ltd. 2025) ditambahkan sebagai *version control layer* untuk *data lake* sehingga eksperimen pada cabang data dapat dilakukan tanpa mengganggu cabang utama. Netralitas *engine* Iceberg membuat tabel yang sama dapat dibaca dan ditulis oleh Spark, Trino, maupun Flink tanpa penyalinan data fisik, sedangkan *branching* lakeFS berjalan *zero-copy* di atas MinIO sehingga jejak versi terjaga tanpa menggandakan berkas.

ClickHouse (ClickHouse Inc 2024) berperan sebagai *warehouse* berorientasi kolom yang menampung tabel hasil transformasi dan menyediakan kueri analitik dengan

latensi rendah untuk *dashboard* maupun materialisasi fitur. Basis data pendampingnya adalah PostgreSQL yang dikelola operator CNPG dan MySQL untuk metadata layanan platform, serta OpenSearch untuk pencarian log dan teks. ClickHouse yang sama menjadi sumber *offline* bagi *Feature Service Layer*, sedangkan PostgreSQL menyimpan metadata MLflow dan MySQL menyimpan metadata Kubeflow Pipelines, sehingga satu kelompok penyimpanan melayani kebutuhan analitik dan metadata beberapa *layer* sekaligus. Gambar IV.4 merinci subgrup *lakehouse* dan basis data beserta konsumennya.




Gambar IV.4 Rincian *Data Storage Layer*

IV.3.4 *Feature Service Layer*

Feature Service Layer ditopang Feast (Feast Project 2024) sebagai *feature store* yang menyatukan definisi fitur untuk *training* dan inferensi. ClickHouse pada *Data Storage Layer* menjadi sumber *offline* tempat fitur historis dibaca untuk *training batch*, sedangkan Valkey menjadi penyimpanan *online* berlatensi rendah hasil materialisasi untuk inferensi. Qdrant melengkapi keduanya sebagai indeks vektor bagi *vector feature*, dan registri fitur disimpan sebagai berkas pada MinIO sehingga definisi fitur ikut terversi pada penyimpanan objek. Rincian mekanisme *dual-store* beserta jaminan *point-in-time correctness*-nya dirancang sebagai sub-sistem tersendiri pada Subbab IV.6, dan Gambar IV.5 merinci *layer* ini beserta sumber dan konsumennya.

Pemisahan penyimpanan pada *layer* ini mengikuti perbedaan karakter beban antar penyimpanan. ClickHouse melayani pembacaan *offline* untuk *training* dengan kompresi kolumnar dan latensi kueri agregasi yang rendah, sedangkan Valkey melayani pembacaan *online* dengan *lookup key-value* dalam memori berlatensi rendah saat *inference*. Qdrant berdiri sebagai indeks vektor terpisah dengan HNSW *native*, kueri gRPC berlatensi rendah, dan penyaringan *payload* yang menyatu dengan kueri kemiripan, sehingga beban pencarian vektor tidak bercampur dengan *lookup* tabular. *Tabular feature* diakses melalui API Feast, sedangkan *vector feature* diambil langsung melalui klien *native* Qdrant pada saat *inference*, sehingga penyetakan sumber daya tiap penyimpanan dapat dilakukan sendiri-sendiri tanpa menduplikasi definisi fitur.




Gambar IV.5 Rincian *Feature Service Layer*

IV.3.5 *Model Lifecycle Layer*

Model Lifecycle Layer menggunakan MLflow (MLflow Contributors 2024) untuk *tracking* dan registri model. Kubeflow Pipelines (Kubeflow Contributors 2024) dipakai sebagai *orchestrator training*, sedangkan Katib digunakan untuk *hyperparameter tuning*. Kubeflow Notebooks menjadi *entry point* eksperimen interaktif yang mengirimkan definisi *pipeline* ke Kubeflow Pipelines. Kubeflow Trainer (Kubeflow Authors 2025c) menjalankan *distributed training* melalui TrainJob yang dipanggil dari *pipeline* Kubeflow Pipelines, sehingga *training multi-replica* tidak memerlukan *custom controller*. Argo Workflows mengeksekusi *pipeline* yang tidak terkait langsung dengan *training*, sedangkan Argo CronWorkflow menjadwalkan *job* berkala untuk pemeliharaan dan pemicu *retraining*. Basis data relasional untuk metadata MLflow disediakan oleh PostgreSQL yang dikelola operator CNPG, sedangkan metadata Kubeflow Pipelines dan Katib disimpan pada MySQL, sehingga riwayat eksperimen dan *pipeline* tersimpan pada penyimpanan yang konsisten. Gambar IV.6 merinci alur dari eksperimen dan *training* menuju registri model beserta pemicu

retraining otomatis dari deteksi drift.




Gambar IV.6 Rincian *Model Lifecycle Layer*

Bagian *model serving* pada *layer* ini, sesuai komponen *model serving component* dan *inference service* pada baris kelima di Tabel IV.1, menggunakan KServe (KServe Contributors 2024) sebagai *inference platform* dengan dukungan banyak *runtime*, otomatisasi *scaling*, dan integrasi langsung dengan model yang tersimpan pada registri MLflow. *Model serving* multimodal didukung KServe dengan *built-in runtime* untuk *scikit-learn*, XGBoost, PyTorch, dan ONNX, ditambah *runtime* kustom untuk model yang memerlukan dependensi spesifik. Knative (Knative Authors 2025) berperan sebagai *serverless layer* bagi KServe, sehingga *scale-to-zero* dapat dilakukan tanpa menahan sumber daya saat trafik rendah. *Runtime* kustom didaftarkan sebagai *ClusterServingRuntime* sehingga penambahan *framework* model baru tidak mengubah definisi *InferenceService* yang sudah berjalan. Argo Rollouts menjalankan analisis *canary* pada *InferenceService* sehingga versi model baru dipromosikan bertahap berdasarkan metrik, sedangkan *inference bridge* membaca fitur *online* dari Valkey dan fitur vektor dari Qdrant untuk melengkapi masukan *predictor*. Antarmuka klien menuju bagian ini dirancang seragam sesuai KF-13, yaitu SDK Feast untuk pembacaan *online feature*, klien MLflow untuk penelusuran *run* dan registri, serta protokol inferensi KServe v2, sehingga layanan pemanggil memakai satu pola integrasi. Gambar IV.7 merinci *serving flow* dari artefak model sampai konsumen prediksi.

IV.3.6 Data Governance Layer

Data Governance Layer menggunakan DataHub (DataHub Project 2024) sebagai katalog metadata yang mengumpulkan informasi dari komponen lain melalui me-




Gambar IV.7 Rincian bagian *model serving* pada *Model Lifecycle Layer*

kanisme *push* dan *pull*, dengan OpenLineage (OpenLineage Authors 2025) sebagai protokol pengirim *event lineage* dari komponen *pipeline*. Great Expectations (Great Expectations 2024) menjalankan pengujian kontrak data pada *batch layer* dan *stream layer* dan mengalirkan status validasi ke katalog, sehingga kualitas data tertampil bersama metadata aset yang diujinya. Penelusuran katalog ditopang indeks OpenSearch sehingga aset lintas *layer* dapat dicari dari satu tempat. Rincian sumber metadata per komponen, jadwal *ingestion*, dan kontrol akses berbasis identitas dirancang sebagai sub-sistem tata kelola pada Subbab IV.4, dan Gambar IV.8 merinci penerimaan *event lineage* dan *ingest* metadata pada DataHub beserta batasnya menuju observabilitas.

DataHub, Great Expectations, dan OpenLineage saling melengkapi pada satu bidang tata kelola dengan pembagian peran yang tegas antara *data discovery*, kualitas, dan *lineage* aset. DataHub menghimpun metadata dari Kafka, ClickHouse, MinIO dengan katalog Iceberg, Feast, MLflow, dan Kubeflow Pipelines sehingga aset lintas *layer* terdaftar pada satu tempat. OpenLineage menyeragamkan jejak *lineage* dari *ingestion* sampai model sehingga DataHub dapat merangkai graf ketertelusuran dengan kosakata yang sama. Identitas pengguna katalog diteruskan dari *identity provider* pusat yang dipakai bersama seluruh antarmuka platform, sehingga akses

ke metadata tunduk pada sesi identitas yang sama dengan komponen lain.




Gambar IV.8 Rincian *Data Governance Layer*

IV.3.7 *Observability Layer*

Observability Layer menggunakan Prometheus untuk metrik dengan Alertmanager sebagai penyalur peringatan, Loki untuk log, dan Grafana Tempo (Grafana Labs 2024c) untuk *trace*, dengan OpenTelemetry sebagai *collector* bersama. Grafana menyatukan ketiganya dan ditambahkan *dashboard* khusus untuk kualitas data, *drift* fitur, dan kinerja model. Sloth (Sloth Authors 2025) menerjemahkan *service-level objective* ke aturan Prometheus, sedangkan Pyroscope menyediakan profil performa berkelanjutan dan OpenCost melengkapi pemantauan biaya per *workload*. Pushgateway dipakai untuk mengumpulkan metrik *job* berdurasi pendek, antara lain CronJob validasi data dan CronWorkflow pengukur *drift*, agar metrik mereka tidak hilang setelah *job* selesai.

Evidently (Evidently AI 2025) melengkapi observabilitas khusus model dengan *report* distribusi fitur dan kinerja model yang dapat diaudit dan disisipkan ke *dashboard* Grafana. *Report* Evidently disimpan pada MinIO dan ditautkan dari katalog DataHub sehingga penurunan kinerja model dapat ditelusuri bersama metadata asetnya. Superset (Apache Superset Authors 2025) berperan sebagai antarmuka analitik bagi

business user yang menampilkan *dashboard* di atas ClickHouse dan Trino. Gambar IV.9 merinci ketiga pilar observabilitas pada satu antarmuka Grafana beserta *dashboard* analitik Superset.




Gambar IV.9 Rincian *Observability Layer*

IV.3.8 *GitOps and Continuous Delivery Layer*

GitOps and Continuous Delivery Layer menjadikan Git satu-satunya sumber rujukan konfigurasi platform. Argo CD menjadi satu-satunya *change flow* yang menarik konfigurasi dari Git dan menerapkannya ke *cluster* melalui prinsip rekonsiliasi deklaratif GitOps (Limoncelli 2018), sehingga *state cluster* selalu dapat direproduksi dari isi repositori. Seluruh manifes, *chart*, dan *overlay* berada pada satu *control plane* yang ditarik Argo CD tanpa ketergantungan pada penyedia eksternal. Argo CD juga menyediakan antarmuka penelusuran sinkronisasi yang matang sehingga penyimpangan antara Git dan *cluster* terlihat dan direkonsiliasi secara berkelanjutan.

Gitea berperan sebagai *repository* Git internal, Tekton sebagai *build pipeline* yang menguji dan melakukan *build image*, dan *image registry* internal sebagai penyimpan artefak hasil *build*. Argo Rollouts melengkapi *delivery pipeline* sebagai operator *progressive delivery* yang mempromosikan versi baru berdasarkan metrik, termasuk untuk rilis model pada bagian *model serving*. Pembagian peran menempatkan Tekton pada *build* artefak dan Argo CD pada rekonsiliasi *state*, sehingga rantai yang

sama menjadi mekanisme yang memicu *retraining* model melalui kontrol deklaratif tanpa *flow* manual. Gambar IV.10 merinci rantai dari *commit* sampai rekonsiliasi pada seluruh *layer* platform.




Gambar IV.10 Rincian *GitOps and Continuous Delivery Layer*

IV.3.9 Security Layer

Security Layer menegakkan akses terkendali serta kepatuhan privasi dan keamanan data pada seluruh *layer* lain. Istio (Istio Authors 2024) menyediakan jaringan layanan dengan mTLS yang mengamankan komunikasi antar layanan, sedangkan APISIX (Apache APISIX Authors 2025) berperan sebagai *API gateway* pada *mesh edge*. Kebijakan *PeerAuthentication default* ditetapkan *strict*, dengan dua bentuk pengecualian terbatas untuk *entry point* yang menerima klien di luar *mesh*, yaitu mode *PERMISSIVE* pada komponen seperti Pushgateway dan registri skema, serta penempatan *broker* Kafka di luar *mesh* dengan enkripsi dan autentikasi yang ditangani *SASL_SSL built-in* Kafka, sehingga *external producer flow* tetap terbuka tanpa melemahkan *default* internal. Identitas terpusat disediakan dex sebagai penyedia *OIDC*, *oauth2-proxy* sebagai penjaga *single sign-on* bagi konsol web, dan SpiceDB sebagai mesin otorisasi berbasis relasi.

OpenBao (OpenBao Authors 2025) mengelola *secret*, dan *External Secrets Operator* menyalurkan *secret* dari OpenBao ke *namespace* target tanpa menyalin *secret* ke berkas manifes. Kebijakan keamanan dijalankan pada dua titik, yaitu Kyverno (Kyverno Authors 2024) pada admisi Kubernetes dan Falco (Falco Authors 2025) pada *runtime*. Trivy Operator (Aqua Security 2025) memindai *image* dan *workload* secara terus menerus, sedangkan Velero (Velero Authors 2025) melakukan pencadangan sumber daya *cluster* dan *persistent volume* secara terjadwal ke MinIO, dan Chaos Mesh menginjeksikan gangguan terkendali untuk menguji ketahanan platform. Gambar IV.11 merinci seluruh komponen keamanan ini dari *mesh edge* sampai pemulihan.



Gambar IV.11 Rincian *Security Layer*

IV.4 Perancangan Sub-sistem Tata Kelola Data

Bagian ini menjawab T-2 dengan merancang sub-sistem tata kelola data yang konsisten lintas siklus data, fitur, dan model. Tata kelola yang dimaksud mencakup katalog metadata, *lineage*, pengujian kontrak data, dan kontrol akses berbasis identitas. Pemilihan keempat aspek tersebut mengikuti penekanan pada KF-08, KF-09, dan KF-10 serta KNF terkait keamanan dan observabilitas pada Bab III, sekaligus menjawab efek domino fragmentasi pada *governance layer* yang dibahas pada Subbab III.1.3. Sub-sistem ini menjadi prasyarat bagi tiga sub-sistem lainnya karena katalog metadata berfungsi sebagai indeks bersama yang menghubungkan *ingestion*, *training*, *serving*, dan pemantauan dalam satu graf tata kelola.

IV.4.1 Katalog Metadata dan *Lineage*

DataHub menjadi pusat katalog metadata. Sumber metadata datang dari beberapa komponen, yaitu Kafka untuk *topic* dan skema, ClickHouse (ClickHouse Inc 2024) untuk tabel pada *warehouse*, MinIO dan Apache Iceberg dengan katalog Lakekeeper (Lakekeeper Authors 2025) untuk *dataset* pada *data lake*, Feast (Feast Project 2024) untuk definisi fitur, MLflow untuk *experiment* dan model, serta Kubeflow Pipelines untuk *pipeline*. Sambungan *lineage* antar komponen dikirim melalui *event* OpenLi-

neage (OpenLineage Authors 2025) sehingga DataHub dapat merangkai graf keterelusuran yang seragam dari *ingestion* sampai prediksi. Identitas pengguna katalog diteruskan dari *identity provider* pusat yang dipakai bersama oleh seluruh antarmuka platform.

Proses *ingestion* metadata pada DataHub dijalankan secara berkala melalui CronJob yang memanggil `datahub ingest` dengan resep YAML per sumber, sehingga penambahan sumber baru tinggal menambahkan resep tanpa memodifikasi kode pusat. Setiap resep meneruskan token OIDC dari OpenBao, sehingga autentikasi pada DataHub konsisten dengan autentikasi yang dipakai oleh komponen lain. Pengelolaan graf metadata juga memuat *glossary* domain yang ditarik dari berkas YAML pada repositori Git, memberi *semantic layer* yang dapat ditelusuri oleh *business user*. Praktik DataHub (DataHub Project 2024) menempatkan katalog metadata sebagai sumber utama jawaban ketertelusuran yang umum muncul pada audit kepatuhan, sehingga kapabilitas tersebut dapat diuji pada Bab VI.

IV.4.2 Kontrak Data dan Kualitas

Great Expectations memberi struktur untuk mendeklarasikan ekspektasi kualitas data, termasuk tipe kolom, batas nilai, dan jumlah baris minimum. Ekspektasi dijalankan pada dua titik, yaitu setelah *ingestion* pada *bronze layer* dan setelah transformasi pada *silver* dan *gold layer*. Hasil pengujian dipublikasikan ke DataHub sehingga kualitas data tertampil bersama metadata lain. Chien (2022) memberi panduan agar metrik kualitas dipakai sebagai dasar pengambilan keputusan, bukan sekadar indikator pasif.

Bernardo dkk. (2024) dan Stoyanovich, Howe, dan Jagadish (2020) memberi konteks yang melebihi aspek teknis, yakni pertanggungjawaban data sebagai bagian dari tata kelola platform. Kegagalan ekspektasi pada *bronze layer* memicu peringatan pada saluran observabilitas tanpa menghentikan *ingestion pipeline*, sementara kegagalan pada *silver* dan *gold layer* memicu penghentian *pipeline* agar data tidak berpindah ke *layer* berikutnya dengan kualitas yang tidak memenuhi kontrak. Setiap eksekusi Great Expectations menyimpan *run history* sehingga regresi kualitas dapat dirunut. dbt menjalankan model SQL pada ClickHouse dan menulis hasil ke tabel *gold* dengan kontrak yang divalidasi oleh *suite* ekspektasi yang dirancang pada *checkpoint* terjadwal.

IV.4.3 Identitas dan Kontrol Akses

Kontrol akses berbasis identitas menggunakan dex (Dex Authors 2025) sebagai *identity provider* OIDC dan oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menegakkan autentikasi pada antarmuka aplikasi. Identitas berlaku konsisten dari antarmuka pengguna ke API hingga ke akses data pada *warehouse* dan *lake*, dengan token OIDC yang sama dipakai oleh DataHub, MLflow, Grafana, Argo CD, dan Kubeflow Pipelines. Kebijakan otorisasi pada level kontainer dan *workload* ditegakkan oleh Kyverno (Kyverno Authors 2024) pada *admission layer* Kubernetes, antara lain wajibnya *resource limits*, larangan *privileged container* di luar pengecualian eksplisit, dan kepatuhan label *Pod Security Standards*. Strategi keamanan MLOps yang dibahas Ahmad dkk. (2024) menjadi rujukan utama, karena banyak ancaman MLOps muncul ketika kontrol akses antar *layer* tidak konsisten.

SpiceDB (AuthZed 2025) dihadirkan sebagai layanan otorisasi berbasis Zanzibar yang menetapkan hubungan akses pada level objek, sehingga kebijakan akses data-set, fitur, dan model dapat dinyatakan dengan model relasi yang seragam. OpenBao menjadi sumber tunggal *secret* yang disinkronkan ke *namespace* target oleh *External Secrets Operator*, dan *Key Encryption Service* mengenkripsi *secret* tersebut pada *layer* MinIO dengan kunci yang dirotasi secara berkala. Falco (Falco Authors 2025) memonitor *event runtime* dan mengirim peringatan ke Loki ketika perilaku mencurigakan terdeteksi, sehingga *runtime layer* tercakup oleh observasi berkelanjutan. Chaos Mesh (Chaos Mesh Authors 2025) dipakai untuk pengujian keandalan terjadwal yang memvalidasi bahwa kontrol akses tetap terjaga pada kondisi kegagalan *partial*.

IV.5 Perancangan Sub-sistem Deteksi *Drift* dan *Continuous Training*

Bagian ini menjawab T-3 dengan merancang sub-sistem deteksi *drift* pada fitur dan label yang otomatis memicu *retraining* pada saat melewati ambang batas. Sub-sistem ini menjawab kombinasi *drift* dan *temporal leakage* yang menjadi salah satu rumusan masalah. Jaminan *point-in-time correctness* yang melengkapi T-3 dirancang bersama layanan fitur pada Subbab IV.6.3 karena bertumpu pada kontrak *point-in-time* Feast, sedangkan subbab ini memusatkan pembahasan pada deteksi *drift* dan *retraining* otomatis. Penekanan diberikan pada otomatisasi penuh, sehingga pengukuran, pengambilan keputusan, *retraining*, validasi, dan promosi versi dijalankan tanpa intervensi manual. Sub-sistem ini menjadi titik temu antara DataOps dan MLOps karena *drift* terdeteksi pada *data layer* sementara konsekuensinya dieksekusi pada *model layer*.

IV.5.1 Pengukuran *Drift*

Detektor yang dipakai bertumpu pada dua indikator utama. *Population Stability Index* (PSI) dipakai untuk fitur kategorikal dan kontinu dengan *binning*, sedangkan uji Kolmogorov-Smirnov dipakai untuk distribusi nilai kontinu (Reis dkk. 2016). Pengukuran dilakukan pada *sliding window* dan dibandingkan dengan *reference window*. Tingkat *drift* dikategorikan menjadi *stable*, *moderate*, dan *severe* dengan ambang yang dapat dikonfigurasi per fitur. Bayram, Ahmed, dan Kassler (2022), Lu dkk. (2019), dan Hinder dkk. (2023) menjadi rujukan untuk penyusunan kebijakan keluarga detektor dan respons platform.

Pengukuran *drift* dijalankan oleh CronJob yang menarik fitur *baseline* dan fitur *active window* dari ClickHouse, lalu menghitung indikator pada *namespace model-lifecycle* agar terisolasi dari *workload* produksi lain. Hasil pengukuran dipublikasikan ke tabel *gold.drift_multi_scale* pada ClickHouse sehingga riwayat dapat dianalisis secara historis untuk audit dan pelaporan. Pushgateway menerima metrik tiap eksekusi sehingga Prometheus dapat merangkainya menjadi deret jangka panjang yang ditampilkan pada *dashboard* Grafana. Evidently menambah *report* HTML visual yang disimpan pada MinIO dan ditautkan dari DataHub agar dapat dirujuk oleh *data scientist* ketika menelusuri penurunan kinerja model.

IV.5.2 Alur *Retraining* Otomatis

Alur *retraining* dijalankan oleh Argo CronWorkflow yang berperan sebagai *control loop*. *Workflow* ini menjalankan *job* pengukuran *drift*, kemudian memutuskan apakah pemicu *training* diperlukan. Jika diperlukan, *workflow* memicu *training pipeline* pada Kubeflow Pipelines. *Training pipeline* menarik fitur dari Feast dengan operasi *get_historical_features* yang menjamin *point-in-time correctness*, kemudian menulis model yang dihasilkan ke MLflow. Model kandidat didaftarkan ke registri MLflow sebagai versi baru, sedangkan kelayakannya untuk menggantikan versi produksi ditentukan pada tahap promosi *canary* yang menilai metrik *serving* versi baru secara langsung.

Promosi versi pada *serving layer* dikendalikan oleh Argo Rollouts (Argo Rollouts Authors 2025) dengan strategi *canary* yang menyalurkan sebagian trafik ke versi baru sebelum promosi penuh, sehingga *rollback* otomatis dapat dilakukan ketika metrik kinerja menurun. Céspedes Sisniega dkk. (2024) memberi contoh penerapan deteksi *drift* pada lingkungan *serverless*, dan pendekatan yang serupa diadaptasi ke lingkungan Kubernetes pada platform ini. Setiap langkah *canary* dijeda agar me-

trik terkumpul, lalu *AnalysisTemplate* mengevaluasi tingkat keberhasilan dan latensi p99 versi *canary* terhadap ambang SLO melalui kueri Prometheus dan menghentikan promosi ketika ambang dilanggar. Riwayat promosi dan *rollback* tercatat pada *namespace* Argo sehingga audit promosi dapat dijalankan langsung dari Argo CD UI tanpa berpindah *tool*.

IV.5.3 Mekanisme Penanganan Kasus Khusus

Sub-sistem ini melayani tiga kasus khusus yang umum muncul pada operasi deteksi *drift*. Keputusan otomatisasi pada ketiganya tidak dapat menunggu label kebenaran tersedia. Penanganannya dirancang pada *control plane* yang sama agar tidak menambah cabang *workflow* baru. Rincian ketiga kasus tersebut adalah sebagai berikut.

1. ***Drift* terdeteksi sebelum label tersedia**

Ketika *drift* terdeteksi pada fitur tetapi label belum tersedia, *workflow* hanya melakukan *retraining* setelah label berjalan cukup lama.

2. ***Drift* akibat perubahan distribusi sementara**

Ketika *drift* terjadi karena perubahan distribusi sementara, ambang dihitung dengan *sliding window* agar tidak memicu *retraining* yang tidak perlu.

3. **Kegagalan versi baru pada analisis *canary***

Ketika versi baru gagal pada analisis *canary*, promosi dihentikan otomatis sehingga versi stabil pada *serving layer* tetap dipertahankan.

Penanganan ketiga kasus tersebut dirancang tanpa *branching* tambahan pada *workflow*. CronWorkflow *retraining* disusun atas dua langkah berurutan, yaitu pengukuran *drift* dan langkah keputusan yang memicu *retraining*, sedangkan penghentian promosi saat analisis *canary* gagal menjadi tanggung jawab Argo Rollouts pada *serving layer*. Ambang PSI dan KS beserta *lookback window* ditetapkan sebagai parameter pada CronWorkflow sehingga setiap perubahan kebijakan tetap melewati *commit* Git dan dapat diaudit. Parameter tersebut tersimpan pada manifes di repositori Git sehingga nilai ambang yang berlaku selalu sama dengan yang tercatat pada riwayat *commit*.

IV.6 Perancangan Sub-sistem Layanan Fitur *Dual-Store*

Bagian ini menjawab T-4 dengan merancang sub-sistem layanan fitur yang menyatukan *tabular feature* dan *aggregate feature* dalam satu kontrak data dari satu sumber rujukan, sedangkan *embedding* berdimensi tinggi dikelola pada indeks vektor terpisah. Feast digunakan sebagai *framework* layanan fitur yang menyatukan kon-

trak antara *offline* dan *online* untuk *tabular feature*. Pemisahan *workload* dilakukan secara fisik antara *key-value store* untuk *tabular feature* dan indeks vektor untuk *embedding*. *Tabular feature* diambil melalui API Feast, sedangkan *embedding* diambil melalui klien *native* Qdrant pada saat *inference*.

IV.6.1 Penyimpanan *Offline* dan *Online*

Offline store menggunakan ClickHouse untuk *tabular feature* dan *aggregate feature* yang dipakai pada fase *training*, dengan tabel kolom yang dipetakan langsung ke definisi FeatureView Feast. *Online store* menggunakan Valkey (Valkey Contributors 2025) untuk fitur yang dipakai pada fase *inference* dengan target latensi p99 di bawah sepuluh milidetik. Dasar pemilihan kedua komponen mengikuti perbandingan berskor pada Subbab IV.2, dengan landasan konsepnya pada Bab II, sedangkan pada perancangan ini keduanya diikat pada satu kontrak Feast sehingga skema *offline* dan *online* berasal dari definisi yang sama. Pemisahan peran ini memungkinkan penyetelan sumber daya *training* dan *serving* secara mandiri tanpa menduplikasi definisi fitur.

Vector search HNSW tidak digabungkan langsung pada *online store* tabular, melainkan disediakan oleh Qdrant (Qdrant Team 2025) sebagai indeks vektor terpisah, sehingga *workload key-value* dan *workload* pencarian vektor terpisah secara operasional. Pemisahan *store* memudahkan penyetelan *resource* secara mandiri karena beban Valkey berorientasi *key-value* dengan akses *point lookup*, sedangkan beban Qdrant berorientasi *approximate nearest neighbor search* yang membutuhkan memori untuk indeks HNSW. Valkey dideklarasikan sebagai *online_store* pada repositori Feast, sedangkan Qdrant berdiri sebagai indeks vektor terpisah yang diakses melalui klien *native* di luar Feast, bukan sebagai *store* kedua di dalam Feast. Perubahan skema fitur diterapkan ke ClickHouse melalui ALTER TABLE terkelola oleh dbt dan secara bersamaan ke Feast melalui feast apply sehingga skema *offline* dan *online* selalu sinkron.

IV.6.2 Dukungan *Vector Embeddings* dan HNSW

Embedding dihasilkan oleh model sentence-transformers/all-mpnet-base-v2 (Reimers dan Gurevych 2019) berdimensi 768 untuk teks, dan disimpan sebagai fitur dengan dimensi yang konsisten antara fase *training* dan fase *inference*. *Approximate nearest neighbor search* dijalankan oleh Qdrant (Qdrant Team 2025) dengan indeks HNSW (Malkov dan Yashunin 2020) berparameter $m=16$ dan $ef_construct=200$ yang ditetapkan sebagai nilai

awal penyeimbang waktu kueri dan kualitas, dan dapat disetel ulang per koleksi. Qdrant menyediakan kueri gRPC berlatensi rendah serta penyaringan *payload* pada saat pencarian, sehingga *embedding* dapat digabung dengan *tabular feature* dari Valkey untuk membentuk *request inference* yang lengkap. Bruch, Gai, dan Ingber (2023) dan Campese, Lauriola, dan Moschitti (2024) memberi rujukan untuk fungsi penggabungan hasil pencarian pada konteks *hybrid retrieval*.

Parameter HNSW dikonfigurasi melalui *collection* Qdrant yang dideklarasikan oleh *init Job* sehingga penambahan koleksi baru dapat dilakukan dengan menambah berkas YAML, tanpa intervensi langsung pada Qdrant. *Snapshot* koleksi vektor diuploadkan secara berkala ke MinIO sebagai bagian dari pencadangan Velero untuk objek terkait. Pemilihan dimensi 768 berdasarkan model *all-mpnet-base-v2* memberi keseimbangan antara kualitas semantik dan biaya penyimpanan, dan dapat disesuaikan dengan model alternatif tanpa mengubah kontrak Feast. Latensi p99 ditargetkan di bawah dua puluh milidetik untuk pencarian top-10 pada koleksi berukuran sampai sepuluh juta vektor.

IV.6.3 Jaminan *Point-in-Time Correctness*

Jaminan ini merupakan bagian dari T-3 yang dirancang bersama layanan fitur karena mekanismenya bertumpu pada kontrak penyimpanan fitur. Jaminan *point-in-time correctness* pada Feast diwujudkan melalui operasi *get_historical_features*. Operasi ini melakukan *point-in-time join* antara entitas dan riwayat fitur dengan menggunakan *event_timestamp* dan *created_timestamp*, sehingga nilai fitur yang dipakai pada saat *training* identik dengan nilai yang akan tersedia pada saat *inference* di waktu yang sama. Sebagaimana dirumuskan pada Bab II, *temporal leakage* membuat evaluasi model tampak lebih baik daripada kinerja sebenarnya, dan kontrak Feast mencegahnya secara struktural pada level definisi fitur. Setiap *FeatureView* mendeklarasikan *ttl* untuk membatasi usia fitur yang dianggap valid, sehingga fitur usang tidak diam-diam masuk ke *training set*.

Mekanisme jaminan ini diuji melalui dua cara. Cara pertama menjalankan *notebook* reproduksi yang memanggil *get_historical_features* pada titik waktu historis dan membandingkan keluaran dengan ekstraksi manual yang dijalankan terhadap log *event* Kafka, sehingga validitas dapat dibuktikan pada level kasus. Cara kedua memvalidasi kontrak antara Online Store dan Offline Store dengan menjalankan kueri yang sama pada Valkey dan ClickHouse pada titik waktu yang sama dan membandingkan keluaran. Kombinasi dua cara uji ini menutup ruang *temporal leakage* struktural pada *feature layer* tanpa bergantung pada disiplin manual pengem-

bang *pipeline*.

IV.6.4 Aliran Materialisasi Fitur

Materialisasi fitur dilakukan dengan dua *pipeline*. *Batch pipeline* menjalankan transformasi pada ClickHouse atau Spark, kemudian Feast memuat hasilnya ke *online store* secara periodik melalui operasi *materialize*. *Stream pipeline* menggunakan Flink untuk menghitung fitur *real-time* yang ditulis langsung ke Valkey untuk *tabular feature*, serta dipublikasikan ke ClickHouse pada saat yang sama, sehingga *offline* dan *online* tetap konsisten. Baik *batch pipeline* maupun *stream pipeline* menulis ke penyimpanan yang sama-sama terdaftar pada FeatureView Feast sehingga konsumen tidak perlu mengetahui *pipeline* mana yang menghasilkan sebuah nilai.

Jadwal materialisasi *batch* dipasang pada DAG Airflow melalui *task* *feast_materialize* dengan interval per jam yang melakukan *push* fitur dari *offline store* ke *online store*. Eksekusi materialisasi mengeluarkan metrik durasi dan jumlah baris ke Pushgateway sehingga *lag* dapat terdeteksi melalui *alerting* Prometheus. *Stream pipeline* menggunakan semantik *exactly-once* Flink dengan *checkpoint* ke MinIO setiap interval pendek, sehingga kegagalan *TaskManager* tidak menyebabkan duplikasi pada *online store*. Pada *batch pipeline*, nilai pada *online store* merupakan hasil materialisasi dari *offline store* yang sama sehingga konsistensi antara keduanya terjaga secara struktural, sedangkan kualitas data lintas *layer* diverifikasi oleh *checkpoint* Great Expectations terjadwal.

IV.7 Alur Kerja End-to-End

Alur kerja menyatukan keempat sub-sistem yang dirancang pada subbab-subbab sebelumnya ke dalam satu siklus berkelanjutan pada satu *control plane* Kubernetes. Siklus bergerak dari *ingestion* data, melewati komputasi dan materialisasi fitur, pengukuran *drift*, sampai promosi model, lalu berputar kembali ketika data baru tiba. Tiap tahap memakai komponen yang sama dengan yang dirinci pada perancangan arsitektur dan ketiga sub-sistem lain, sehingga alur ini menautkan komponen yang sudah ada tanpa menambah komponen baru. Urutan kelima tahap tersebut adalah sebagai berikut.

1. *Ingestion* dan validasi data

Data baru masuk melalui Kafka, divalidasi oleh Great Expectations, kemudian disimpan pada *warehouse* ClickHouse dan *data lake* MinIO dengan katalog Lakekeeper.

2. **Komputasi dan materialisasi fitur**

Fitur dihitung pada Flink atau Spark dan ditulis ke ClickHouse sebagai *offline store*, lalu diregistrasi pada Feast dan dimaterialisasi ke Valkey sebagai *online store* tabular, sedangkan indeks vektor Qdrant diisi melalui *flow* tersendiri di luar materialisasi Feast.

3. **Pengukuran *drift* dan *retraining***

Argo CronWorkflow mengukur *drift* dan, jika ambang dilewati, memicu *training pipeline* Kubeflow Pipelines yang menggunakan `get_historical_features` untuk menjamin konsistensi temporal.

4. **Registrasi dan promosi model**

Hasil *training* ditulis ke MLflow, model kandidat didaftarkan sebagai versi baru, lalu promosi pada *serving layer* dikendalikan oleh Argo Rollouts dengan strategi *canary* berbasis analisis metrik.

5. **Sinkronisasi konfigurasi dan observabilitas**

Perubahan pada konfigurasi disinkronkan dari Git oleh Argo CD, sedangkan kondisi sistem dipantau oleh Prometheus, Loki, dan Grafana Tempo melalui Grafana.

Siklus ini berputar setiap kali data baru masuk atau *drift* terdeteksi, sehingga platform terus menerus menjaga akurasi model di lingkungan produksi. Seluruh langkah pada siklus berjalan dari deklarasi Git yang sama sehingga setiap perputaran dapat diaudit dan diulang. Rodrigues dkk. (2025) memberi rujukan tambahan untuk arsitektur pembelajaran *near real-time* pada lingkungan yang serupa. Pendekatan yang dirancang di sini mengadaptasi rujukan tersebut ke kontrak Feast dan Argo Rollouts agar siklus tetap dapat dijalankan secara deklaratif pada satu *cluster* Kubernetes. Perwujudan keempat *sub-sistem* dan alur *end-to-end* ini pada lingkungan k3s, beserta pola GitOps yang menjalankannya, dibahas pada Bab V.

BAB V

IMPLEMENTASI ARSITEKTUR PLATFORM DATAOPS DAN MLOPS

Bab ini membahas implementasi platform DataOps dan MLOps terintegrasi sesuai rancangan pada Bab IV. Pembahasan dimulai dari lingkungan implementasi yang menjadi dasar *deployment* komponen, kemudian dilanjutkan dengan implementasi empat sub-sistem mengikuti urutan pemenuhan tujuan T-1 sampai T-4. Bab ini ditutup dengan verifikasi *execution flow* menggunakan satu *use case* sebagai kasus pengujian. Penjabaran detail biner dan konfigurasi disimpan pada repositori platform, sehingga bab ini menyajikan pokok-pokok implementasi yang menjelaskan bentuk akhir rancangan.

V.1 Lingkungan Implementasi

Lingkungan implementasi platform dibangun pada satu *cluster* Kubernetes (Cloud Native Computing Foundation 2024a) berbasis k3s yang berjalan pada satu *node*. Pilihan ini memenuhi kebutuhan eksekusi pada lingkungan terbatas tanpa mengubah pola *deployment* yang dapat dipakai pada *cluster* produksi dengan banyak *node*. Distribusi k3s membawa *control plane* ringan, *containerd* sebagai *runtime*, dan beberapa *add-on built-in* yang dapat dinonaktifkan agar tidak berbenturan dengan komponen pilihan platform. Konfigurasi *node* memakai satu *disk* lokal dengan *ext4* sebagai *filesystem*, dan tata letak *namespace* pada platform dibakukan agar perpindahan ke *cluster* produksi dengan banyak *node* tinggal mengubah berkas *overlay Kustomize* tanpa mengganti manifes dasar.

Kode dan konfigurasi proyek ditata pada beberapa direktori utama dengan batas tanggung jawab yang jelas. Tabel V.1 merangkum direktori tersebut beserta fungsinya, dengan *platform/* sebagai inti yang bersifat domain-agnostik dan direktori *use case* sebagai kasus pengujian yang terpisah. Pemisahan ini memastikan platform dapat dipakai ulang lintas domain tanpa menyentuh berkas yang spesifik pada satu *use case*. Direktori *experiments/* dan *materials/* berperan sebagai penunjang verifikasi dan dokumentasi yang tidak menjadi bagian dari *deployment flow* platform.

Tabel V.1 Struktur Direktori Utama Proyek dan Fungsinya

Direktori	Fungsi
platform/	Kode, manifes, dan konfigurasi seluruh komponen platform DataOps dan MLOps yang bersifat domain-agnostik
use-case-crypto/	<i>Use case</i> uji berupa pasar kripto, memuat layanan <i>ingestion</i> , definisi fitur, <i>pipeline</i> , dan <i>overlay Kustomize</i> yang spesifik domain
experiments/	Skenario verifikasi dan <i>oracle</i> pengujian, antara lain uji paritas <i>batch-stream</i> , beban, <i>drift</i> , dan <i>chaos</i>
materials/	Dokumen tugas akhir, proposal, referensi, dan berkas laporan

V.1.1 Batasan Implementasi

Perwujudan platform pada bab ini berjalan di dalam dua batasan implementasi yang dibedakan dari batasan penelitian pada Bab I. Batasan implementasi menyangkut pilihan perwujudan yang dapat diganti tanpa mengubah sifat kontribusi selama fungsi yang sama tetap terpenuhi, karena keluaran utama penelitian adalah arsitektur yang dapat dipakai lintas *use case*, bukan implementasi untuk satu lingkungan tertentu. Lingkungan k3s satu *node* dan *version pinning* April 2026 ditetapkan oleh kedua batasan itu sebagai kondisi pengujian yang dapat direproduksi. Selanjutnya, kedua butir itu dirujuk dengan singkatan BI-1 dan BI-2, terutama pada pembahasan hasil di Bab VI.

1. Platform berjalan di atas k3s pada satu *node* sebagai lingkungan pengembangan dan pengujian, dengan skala diatur oleh HPA, VPA, dan KEDA ketika beban nyata muncul, sedangkan *overlay Kustomize* untuk *environment multi-node* tetap dapat ditambahkan tanpa modifikasi basis kode sehingga jumlah *node* bersifat perwujudan dan bukan bagian dari kontribusi.
2. Versi pustaka dan basis *image container* dipatok pada rilis stabil tertinggi per April 2026 agar pengujian dapat direproduksi pada lingkungan yang sama, dan *version pinning* maupun pilihan serta sintaks komponen tertentu dapat diganti dengan komponen lain berkapabilitas setara tanpa mengubah rancangan.

Batasan implementasi tersebut menjadi konteks pembacaan seluruh subbab implementasi pada bab ini. Penggantian jumlah *node*, versi komponen, atau sintaks *tools* dengan padanan berkapabilitas setara tidak mengubah rancangan pada Bab IV. Batasan BI-1 dipetakan kembali pada pelaporan hasil evaluasi lingkungan *node* tunggal, sedangkan BI-2 menjadi acuan reproduksi lingkungan pengujian pada Bab VI. Pemisahan dari batasan penelitian menegaskan bahwa keterbatasan lingkungan pengujian tidak membatasi keberlakuan arsitektur yang dirancang.

V.1.2 Konfigurasi Dasar *Cluster*

Cluster menjalankan komponen dasar berikut. Istio (Istio Authors 2024) berperan sebagai *service mesh* dengan mTLS dalam mode *strict* pada trafik internal, APISIX (Apache APISIX Authors 2025) sebagai *API gateway* pada *mesh edge*, kontrol akses jaringan menggunakan *NetworkPolicy* pada level Kubernetes, dan Kyverno (Kyverno Authors 2024) sebagai *policy engine* pada *admission layer*. Falco (Falco Authors 2025) memantau perilaku *runtime* pada level *kernel*, sedangkan Trivy Operator (Aqua Security 2025) memindai *image* dan *workload* secara berkala. *Storage class default* menggunakan *local-path provisioner* untuk *persistent volume* berbasis penyimpanan lokal, dengan Velero (Velero Authors 2025) melakukan pencadangan terjadwal ke MinIO. Chaos Mesh (Chaos Mesh Authors 2025) disiapkan untuk uji ketahanan dengan eksperimen *fault injection* yang terbatas pada *namespace* tertentu.

Konfigurasi sumber daya memberi prioritas pada satu replika *idle* per *workload*, sementara *Horizontal Pod Autoscaler*, *Vertical Pod Autoscaler* dalam mode rekomendasi, dan KEDA *ScaledObject* disiapkan pada *template* agar *scaling* dapat aktif ketika beban nyata datang. *Resource limits* pada setiap kontainer ditetapkan sesuai panduan Kyverno *require-resource-limits* untuk mencegah kelebihan kuota *node*. Penjadwalan kelas prioritas memakai *PriorityClass* platform agar komponen kritis tidak di-*preempt* oleh *workload* sekali pakai. *External Snapshotter* dipasang sebagai prasyarat untuk *snapshot* CSI yang dipakai oleh Velero, sehingga rekonstruksi *cluster* dari pencadangan dapat dilakukan tanpa intervensi manual.

V.1.3 Manajemen *Secret* dan Identitas

OpenBao (OpenBao Authors 2025) bertindak sebagai penyimpan *secret*. *External Secrets Operator* bertugas menyalurkan *secret* dari OpenBao ke *namespace* target tanpa menyalin nilai *secret* ke dalam berkas manifes. Identitas pengguna dikelola oleh dex (Dex Authors 2025) sebagai *identity provider* OIDC, dengan oauth2-proxy (OAuth2 Proxy Authors 2025) sebagai *reverse proxy* yang menegakkan autentikasi pada antarmuka aplikasi seperti DataHub, MLflow, Grafana, Argo CD, dan Kube-flow Pipelines. Selain identitas pengguna, kebijakan otorisasi *workload* pada *admission layer* ditegakkan oleh Kyverno (Kyverno Authors 2024) sebagai bagian dari dasar keamanan *cluster*.

OpenBao diinisialisasi oleh *Job* *openbao-bootstrap* yang melakukan *init* dan *auto-unseal* dengan kunci yang tersimpan di MinIO (MinIO, Inc. 2024) dengan enkripsi sisi *server*. *External Secrets Operator* dipasang pada *namespace* *security de-*

ngan ClusterSecretStore tunggal yang berisi konfigurasi koneksi ke OpenBao. SpiceDB (AuthZed 2025) dipasang sebagai layanan otorisasi berbasis Zanzibar yang menetapkan hubungan akses pada level objek tata kelola, dengan basis data PostgreSQL melalui CNPG sebagai *datastore*. *Key Encryption Service* dipasang sebagai *sidecar* MinIO untuk enkripsi *secret*, dengan rotasi kunci dijalankan oleh *CronJob* terjadwal.

V.1.4 Pola GitOps

Argo CD (Argo Project 2024) menjadi satu-satunya *change flow* pada *cluster*. Repositori Git pada Gitea (Gitea Contributors 2025) bertindak sebagai sumber rujukan konfigurasi. Setiap perubahan dilakukan melalui *commit* pada repositori dan diterapkan ke *cluster* oleh Argo CD melalui rekonsiliasi. Pola ini menjamin reproduktibilitas, menghasilkan jejak audit untuk setiap perubahan, dan memenuhi KF-12 tentang konfigurasi deklaratif. *Pipeline* CI yang dijalankan oleh Tekton (Tekton Contributors 2024) melakukan *build image* dan menjalankan pengujian sebelum *commit* menjadi sumber *deployment*.

ApplicationSet Argo CD dipakai untuk mendeklarasikan banyak *Application* sekaligus dengan satu *template* per kelompok, sehingga penambahan komponen baru tinggal menambahkan *generator* tanpa menambah berkas *Application* satu per satu. Argo CD diatur dengan mode *manual-sync* pada *ApplicationSet template* untuk mencegah *auto-prune* yang dapat menghapus sumber daya secara tidak sengaja. Tekton menjalankan *Pipeline* yang menghasilkan *image* ke registri *localhost:5000* yang berfungsi sebagai *mirror* lokal, dan menulis kembali *commit* dengan referensi *image* yang sudah diperbarui pada *values.yaml customization*. *Pre-apply* dan *post-apply hook* pada *apply-component.sh* menutup celah *race condition* antara CRD dan CR, sehingga seluruh komponen *cluster* dapat dipasang ulang dengan satu perintah *Makefile*.

V.2 Implementasi Arsitektur Terintegrasi

Bagian ini mengimplementasikan rancangan pada Bagian IV.3 sebagai pemenuhan T-1. Komponen disusun ke dalam *namespace* per *layer* dan dihubungkan melalui kontrak API yang stabil. Setiap *namespace* memuat satu kelompok komponen fungsional sehingga kebijakan *NetworkPolicy* dapat ditegakkan dengan model *default-deny* dan pengecualian eksplisit per arah komunikasi. *Deployment* komponen mengikuti pola GitOps melalui Argo CD, sedangkan eksekusi *pipeline* CI mengikuti pola Tekton, dengan setiap komponen tunduk pada *template ApplicationSet* agar penam-

bahan komponen baru tidak menambah *boilerplate*. Dari sembilan *layer* rancangan, tiga *layer* operasional telah terimplementasi pada Subbab V.1, yaitu *Orchestration and Infrastructure Layer* pada konfigurasi dasar *cluster*, *Security Layer* pada manajemen *secret* dan identitas, serta *GitOps and Continuous Delivery Layer* pada pola *GitOps*. *Feature Service Layer* dan *Data Governance Layer* diimplementasikan sebagai *sub-sistem* pada Subbab V.5 dan Subbab V.3, sehingga subbab ini merinci empat *layer* sisanya. Tabel V.2 merangkum bentuk akhir implementasi tersebut dengan memetakan tiap *layer* ke komponen yang terpasang beserta *namespace* tempatnya berjalan, sehingga pembaca dapat memeriksa kelengkapan sembilan *layer* tanpa menelusuri manifes satu per satu.

Tabel V.2 Pemetaan *Layer* Platform ke Komponen Terpasang dan *Namespace*

<i>Layer</i>	Komponen Terpasang	<i>Namespace</i>
<i>Orchestration and Infrastructure</i>	k3s, metrics-server, HPA, VPA, KEDA, Kueue, cert-manager	kube-system, common, cert-manager
<i>Data Ingestion and Processing</i>	Kafka (Strimzi), Kafka Connect, Debezium, Karapace, Flink, Spark, dbt, Airflow	data-ingestion, data-processing
<i>Data Storage</i>	MinIO, Iceberg, Lakekeeper, lakeFS, ClickHouse, Trino, PostgreSQL (CNPG), MySQL	storage
<i>Feature Service</i>	Feast, Valkey, Qdrant	model-lifecycle, storage
<i>Model Lifecycle</i>	MLflow, Kubeflow Pipelines, Katib, Kubeflow Trainer, Argo Workflows, KServe, Knative, Argo Rollouts	model-lifecycle, model-serving, knative-serving
<i>Data Governance</i>	DataHub, OpenLineage, Great Expectations, OpenSearch	data-governance
<i>Observability</i>	Prometheus, Alertmanager, Loki, Tempo, Grafana, OpenTelemetry, Superset, Evidently	observability
<i>GitOps and Continuous Delivery</i>	Gitea, Tekton, Argo CD, registri <i>image</i> lokal	gitops, tekton-pipelines, platform-registry
<i>Security</i>	Istio, APISIX, Dex, oauth2-proxy, SpiceDB, OpenBao, ESO, Kyverno, Falco, Trivy, Velero, Chaos Mesh	security, istio-system, external-secrets, velero

V.2.1 *Data Ingestion and Processing Layer*

Apache Kafka (Apache Software Foundation 2024c) diterapkan menggunakan operator Strimzi. *Kafka Connect* digunakan untuk integrasi dengan basis data eksternal melalui Debezium dan untuk *sink* ke Apache Iceberg pada MinIO (MinIO, Inc. 2024) dengan katalog Lakekeeper (Lakekeeper Authors 2025). *Karapace* berperan sebagai registri skema dengan dukungan Avro dan JSON Schema. Trafik masuk dari konsumen di luar *mesh* dilewatkan melalui *API gateway* APISIX (Apache APISIX

Authors 2025) dengan mTLS yang dijembatani pada *mesh edge*.

Konfigurasi *cluster* Kafka dirangkum pada Tabel V.3 agar pilihan teknis dan alasan-nya terbaca dalam satu pandangan. Keputusan pada tabel tersebut menjaga kontrak *ingestion* tetap deklaratif, karena KafkaTopic dan KafkaUser CR membuat *topic* beserta ACL dapat diaudit sebagai sumber daya Kubernetes, sedangkan kredensial SCRAM-SHA-512 mengalir dari OpenBao tanpa menyentuh manifes. *Scaling* konsumen mengikuti panjang antrean nyata karena KEDA membaca *lag* dari Kafka Exporter melalui Prometheus. Penempatan *broker* di luar *mesh* Istio dengan enkripsi SASL_SSL *built-in* Kafka mengikuti rancangan *ingress flow* dari luar *mesh* pada Subbab IV.3.9, sehingga penyedia data tanpa *sidecar* tetap terlayani tanpa melemahkan *default strict* internal.

Tabel V.3 Konfigurasi *Ingress* Kafka pada Lingkungan Implementasi

Aspek	Konfigurasi	Alasan
Mode <i>cluster</i>	<i>KRaft</i> murni tanpa ZooKeeper	Topologi tetap ringan pada satu <i>node</i>
Protokol klien	SASL_SSL dengan SCRAM-SHA-512, kredensial dari OpenBao melalui External Secrets Operator	Autentikasi dan enkripsi seragam tanpa <i>secret</i> pada manifes
Kontrak <i>ingestion</i>	KafkaTopic dan KafkaUser CR beserta ACL	Kontrak tersimpan sebagai sumber daya Kubernetes yang dapat diaudit
Topologi <i>topic</i>	Enam <i>partition</i> , faktor replikasi satu, dinaikkan tiga pada <i>multi-node</i>	Paralelisme konsumen tanpa melampaui kapasitas satu <i>node</i>
<i>Scaling</i> konsumen	KEDA ScaledObject membaca <i>lag</i> dari Kafka Exporter melalui Prometheus	Skala konsumen mengikuti panjang antrean nyata
Akses luar <i>mesh</i>	<i>Broker</i> di luar <i>mesh</i> Istio (<i>sidecar.istio.io/inject: false</i>) dengan <i>DestinationRule</i> menonaktifkan mTLS menuju <i>bootstrap</i>	Produsen tanpa <i>sidecar</i> tetap terlayani, enkripsi ditangani SASL_SSL Kafka

Processing pipeline pada *layer* yang sama dirinci sebagai berikut. Pemrosesan *stream* menggunakan operator Flink yang mengelola *FlinkDeployment*. Pemrosesan *batch* menggunakan operator Spark dan dijalankan sebagai *SparkApplication*. Transformasi pada *warehouse* menggunakan dbt yang dijalankan sebagai *task* KubernetesPodOperator pada DAG Airflow (Apache Software Foundation 2024a). Airflow mengorkestrasi *pipeline* data berorientasi *batch*, termasuk pembangunan *gold layer*, sedangkan orkestrasi *model training* ditangani oleh Kubeflow Pipelines.

Flink dipasang dengan *session cluster* mode *Standalone* dan tugas *stream* dideklarasikan sebagai *FlinkSessionJob* CR sehingga setiap *job* dapat di-*deploy* secara independen melalui Argo CD. Spark Operator memanfaatkan *webhook* muta-

si untuk menyisipkan *node selector* dan *toleration* berdasarkan label *queue-name* yang ditetapkan oleh Kueue. dbt menjalankan model SQL pada ClickHouse dengan *profiles.yaml* yang merujuk *secret* dari OpenBao melalui ESO. Airflow memakai *git-sync sidecar* yang menarik DAG dari Gitea sehingga pembaruan DAG tidak memerlukan pembangunan ulang *image*. *Checkpoint* dan *savepoint* Flink ditulis ke MinIO sehingga pemulihan *job* tidak kehilangan *state*, dan *topic* hasil *stream* dikonsumsi *analytics layer* melalui tabel *Kafka engine* ClickHouse.

V.2.2 Data Storage Layer

Warehouse kolumnar menggunakan ClickHouse (ClickHouse Inc 2024) dengan operator ClickHouse pada satu *shard*. *Data lake* menggunakan MinIO sebagai *object store* dan Apache Iceberg sebagai *table format*, dengan Lakekeeper (Lakekeeper Authors 2025) sebagai katalog Iceberg REST dan Trino (Trino Software Foundation 2024) sebagai *query engine*. Penyimpanan *key-value* memakai Valkey (Valkey Contributors 2025) dengan protokol RESP untuk akses berlatensi rendah. Penyimpanan vektor memakai Qdrant (Qdrant Team 2025) sebagai basis data untuk *embedding* berdimensi tinggi. Penyimpanan relasional memakai PostgreSQL melalui operator CNPG dengan *plugin barman-cloud* untuk pencadangan ke MinIO. MySQL dipasang sebagai Deployment dengan *persistent volume* pada *storage class* lokal untuk komponen yang terikat pada protokol MySQL. Apache Superset (Apache Superset Authors 2025) disiapkan sebagai antarmuka BI untuk peran *business user* dengan koneksi ke ClickHouse, Trino, dan MySQL melalui SQLAlchemy.

ClickHouse memakai ClickHouseKeeper sebagai pengganti ZooKeeper untuk koordinasi metadata replikasi. MinIO dipasang dengan empat drive pada satu *node* untuk menjaga skema penamaan erasure code yang seragam ketika *cluster* berpindah ke banyak *node*. Lakekeeper menyediakan Warehouse dan Project REST API yang dipakai oleh Spark, Trino, dan Flink dengan menggunakan *header x-project-id* sebagai pemisah antar *warehouse*. lakeFS (Treeverse Ltd. 2025) dipasang sebagai *version control layer* di atas MinIO sehingga eksperimen pada cabang data dapat dijalankan tanpa mengganggu data utama. MinIO disusun dengan *bucket* terpisah per kepentingan sebagaimana dirangkum Tabel V.4, dengan kapasitas yang dipantau melalui metrik MinIO pada Prometheus. Qdrant dilengkapi *persistent volume*, PodDisruptionBudget, dan kunci API yang disalurkan External Secrets Operator.

Tabel V.4 Tata Letak *Bucket* MinIO per Kepentingan

<i>Bucket</i>	Kepentingan
mlflow	Artefak eksperimen dan model dari <i>tracking</i> MLflow
feast	Registri fitur berbasis berkas (<code>registry.db</code>) yang dibagikan seluruh klien Feast
warehouse	Data <i>lakehouse</i> berformat Iceberg di bawah katalog Lakekeeper
flink-checkpoints	<i>Checkpoint</i> dan <i>savepoint job streaming</i> Flink
velero-backups	Pencadangan terjadwal sumber daya <i>cluster</i> dan <i>persistent volume</i>

V.2.3 *Model Lifecycle Layer*

MLflow (MLflow Contributors 2024) dijalankan dengan basis data PostgreSQL dan *artifact store* pada MinIO. Kubeflow Pipelines (Kubeflow Contributors 2024) dijalankan pada *namespace* terpisah dengan dukungan *multi-tenant*, dilengkapi Kubeflow Notebooks untuk lingkungan eksperimen interaktif dan Kubeflow Trainer (Kubeflow Authors 2025c) untuk *distributed training*. KServe (KServe Contributors 2024) dipakai untuk *inference* dengan dukungan *runtime* MLflow, scikit-learn, XGBoost, PyTorch, dan ONNX, dan dengan Knative Serving (Knative Authors 2025) sebagai *serverless layer built-in* yang menyediakan *scale-to-zero*. Argo Workflows berperan sebagai *orchestrator job* di luar Kubeflow Pipelines, sedangkan Argo Rollouts (Argo Rollouts Authors 2025) mengelola promosi versi pada *serving layer* dengan strategi *canary* dan *progressive analysis* berbasis metrik Prometheus, sehingga otomatisasi *deployment* model pada KF-06 terpenuhi.

Kubeflow Pipelines memakai MySQL sebagai *metadata store* dan MinIO sebagai *artifact store*, dengan kfp-launcher yang membungkus eksekusi langkah *pipeline* agar autentikasi ke MinIO dilakukan menggunakan `secretAsEnv`. KServe InferenceService dideklarasikan pada *namespace* model-serving dengan label `part-of=kserve` agar Kyverno tidak menolak *Pod mutator built-in*. Kueue (Kueue Authors 2024) mengelola antrian *training* dengan ClusterQueue per kelompok *workload* sehingga sumber daya CPU dan GPU dapat dibagi adil antara *tenant*, memenuhi KF-14 tentang manajemen sumber daya. Argo Rollouts mengevaluasi metrik dari Prometheus pada setiap langkah *canary* untuk menentukan apakah versi *canary* layak dipromosikan menjadi versi *stable*.

V.2.4 *Observability Layer*

Prometheus (Prometheus Authors 2024) mengumpulkan metrik dari semua komponen dengan *ServiceMonitor* dan *PodMonitor*. Loki (Grafana Labs 2024b) mengumpulkan log melalui Alloy. Grafana Tempo (Grafana Labs 2024c) menerima *trace* dari OpenTelemetry Collector yang tersebar pada *node*. Grafana (Grafana Labs 2024a)

menggabungkan ketiganya pada satu antarmuka.

Sloth (Sloth Authors 2025) menerjemahkan definisi *service-level objective* ke dalam aturan Prometheus sehingga *error budget* dapat dipantau bersama metrik lain. Pushgateway berperan sebagai komponen pengumpul metrik untuk *job* berdurasi pendek yang berjalan di luar siklus *scrape*, termasuk CronJob pengukuran *drift* dan *CronWorkflow* pemicu *retraining*. OpenCost dipakai untuk pemantauan biaya per *workload*, sedangkan Pyroscope mengumpulkan profil CPU dan memori secara berkelanjutan dari layanan yang menjadi *hotspot*. Evidently (Evidently AI 2025) dijalankan sebagai *job* berkala yang menghasilkan *report* HTML kualitas distribusi fitur dan disimpan pada MinIO sebagai jejak audit yang dapat dirujuk dari DataHub. Pemenuhan kebutuhan yang bergantung pada arsitektur terintegrasi ini diverifikasi melalui skenario evaluasi pada Bab VI.

V.3 Implementasi Sub-sistem Tata Kelola Data

Subbab ini menurunkan rancangan tata kelola pada Bagian IV.4 menjadi implementasi sebagai pemenuhan T-2, dengan fokus pada konsistensi katalog metadata, jadwal pengujian kontrak data, dan penegakan kontrol akses pada tiga *layer* yang berbeda. Penomoran KF-08, KF-09, dan KF-10, serta kebutuhan KNF terkait keamanan dipakai sebagai acuan untuk menilai apakah implementasi memenuhi seluruh kebutuhan yang dirumuskan pada Bab III. Katalog diwujudkan oleh DataHub dengan penerimaan *lineage* OpenLineage, kontrak kualitas oleh Great Expectations pada *pipeline* Airflow, dan kontrol akses oleh gabungan dex, SpiceDB, serta kebijakan jaringan. Autentikasi konsol, otorisasi granular, dan kebijakan jaringan antar *namespace* membentuk ketiga *access layer* yang dimaksud.

V.3.1 Katalog Metadata dan Lineage

DataHub (DataHub Project 2024) dijalankan dengan komponen GMS, *frontend*, dan beberapa *job ingest*, dengan OpenSearch sebagai *search backend* dan PostgreSQL sebagai *metadata backend*. *Job ingest* berjalan secara berkala sebagai *CronJob* untuk menarik metadata dari Kafka, ClickHouse, MinIO dan Iceberg, Feast, MLflow, dan Kubeflow Pipelines. Hasil *ingest* menyatukan *lineage* antar *layer*, mulai dari *topic* pada Kafka hingga model yang dilayani oleh KServe. OpenLineage (OpenLineage Authors 2025) dipakai sebagai protokol pengirim *event lineage* dari komponen *pipeline*, baik Airflow maupun Kubeflow Pipelines, agar graf ketertelusuran di DataHub tersusun dengan kosakata yang seragam.

Image datahub-feast-deps dibangun secara lokal dengan Kaniko untuk menambahkan *plugin* Feast pada *job ingest* sehingga sumber Feast dapat dipindai secara langsung. Autentikasi ke GMS menggunakan token sistem yang disimpan di OpenBao dan disebarkan ke *namespace* data-governance oleh *External Secrets Operator*. Konfigurasi DataHub pada level UI dikelola melalui datahub-frontend-secret dengan *checksum annotation* pada GMS dan *frontend* agar rotasi *secret* memicu *auto-roll deployment*. Jadwal *ingest* dapat berkonflik dengan *workload* besar di *node*, dan untuk itu *native sidecar* Istio diaktifkan pada *CronJob* agar koneksi mTLS ke GMS tidak putus saat *sidecar* dihentikan setelah *job* selesai. *Job* berdurasi pendek lain yang berjalan di luar *mesh* mengirim metriknya melalui titik PERMISSIVE Pushgateway sesuai rancangan pengecualian pada Subbab IV.3.9, sehingga hanya *job* yang benar-benar membutuhkan koneksi mTLS ke layanan dalam *mesh* yang membawa *native sidecar*.

V.3.2 Kontrak Data dan Kualitas

Great Expectations (Great Expectations 2024) mendefinisikan ekspektasi kualitas data pada *bronze layer* setelah *ingestion* dan pada *silver* dan *gold layer* setelah transformasi. Setiap *expectation suite* disimpan pada repositori Git dan dijalankan oleh *CronJob* yang membaca hasil ke DataHub. Pengujian yang gagal akan menutup *promotion flow* ke *layer* berikutnya dan memunculkan peringatan pada Grafana. Hasil ekspektasi disimpan ke MinIO sebagai *Data Docs* HTML sehingga konteks kegagalan dapat ditelusuri tanpa perlu menjalankan kembali *suite*.

dbt menjalankan model SQL untuk *silver* dan *gold layer* pada ClickHouse, dengan *schema.yml* yang memuat *tests* dasar seperti *unique*, *not_null*, dan *accepted_values*. Hasil dbt dirilis ke DataHub melalui *run event* OpenLineage yang dikirim oleh *task* KubernetesPodOperator dbt pada DAG Airflow. *Checkpoint* Great Expectations dijadwalkan per *layer* dengan jeda yang berbeda agar ekspektasi yang berat tidak berdampak pada beban *warehouse*. *Suite* fakta *training* diuji setelah materialisasi pada tabel *gold.fct_training_data* agar *training set* tidak masuk *training pipeline* apabila kualitas data tidak memenuhi kontrak.

V.3.3 Kontrol Akses

Kontrol akses pada *network layer* menggunakan *NetworkPolicy* dengan kebijakan *default-deny* per *namespace* dan pengecualian yang dideklarasikan secara eksplisit. Pada *application layer*, kontrol akses memakai *authentication flow* tunggal dex dan *oauth2-proxy* yang telah dirinci pada Subbab V.1.3, sehingga akses ke konsol tata

kelola tunduk pada sesi identitas yang sama dengan layanan platform lain. Pada *admission layer*, Kyverno (Kyverno Authors 2024) menegakkan kebijakan keamanan *workload* sesuai rancangan pada Subbab IV.4.3. Falco (Falco Authors 2025) memantau *event runtime* pada level *kernel* untuk mendeteksi pelanggaran kebijakan keamanan setelah *pod* berjalan.

SpiceDB (AuthZed 2025) berfungsi sebagai layanan otorisasi yang dipakai DataHub dan Kubeflow Pipelines untuk hubungan akses pada level objek, dengan basis data PostgreSQL melalui CNPG. *Policy* Kyverno disusun pada *namespace security* dengan *policy generator* yang menyebarkan kebijakan ke *namespace* aplikasi tanpa duplikasi sumber daya. Kyverno mode *failurePolicy=Ignore* dipakai pada *ValidatingPolicy* agar admisi tidak terblokir saat *webhook* gagal pada kondisi *cluster* yang sibuk. Falco mengirim peringatan ke Loki melalui *falcosidekick* dengan *topic* khusus sehingga tim keamanan dapat menelusuri *event* terkait kebijakan dari satu antarmuka Grafana. Pemenuhan KF-08, KF-09, dan KF-10 diverifikasi melalui skenario evaluasi pada Bab VI.

V.4 Implementasi Sub-sistem Deteksi *Drift* dan *Continuous Training*

Implementasi sub-sistem deteksi *drift* menindaklanjuti rancangan pada Bagian IV.5 sebagai pemenuhan T-3, dengan fokus pada otomatisasi penuh *control loop* dari pengukuran sampai promosi versi serta penegakan ambang yang dapat dikonfigurasi per model. Pemicu *retraining* dirancang agar dapat dijalankan secara berkala atau dipicu oleh *event drift* yang melebihi ambang. Keseluruhan implementasi pada bagian ini menjawab KF-07 untuk deteksi *drift* otomatis berikut *trigger retraining*, sehingga model pada *serving layer* tidak dibiarkan usang tanpa evaluasi berkala saat distribusi data bergeser. Seluruh langkah *loop* diwujudkan pada CronWorkflow *retrain-on-drift* yang membaca skor dari tabel analitik dan memanggil *training pipeline* Kubeflow Pipelines.

V.4.1 Detektor *Drift*

Detektor *drift* diimplementasikan sebagai *service* Python yang membaca fitur dari ClickHouse dengan *time window* yang dapat dikonfigurasi. Indikator PSI dihitung dengan *binning* adaptif, dan uji Kolmogorov-Smirnov dijalankan dengan ambang yang dapat disesuaikan per fitur (Reis dkk. 2016; Bayram, Ahmed, dan Kassler 2022; Lu dkk. 2019). Hasil pengukuran ditulis ke ClickHouse sebagai tabel *gold.drift_multi_scale* dan dipublikasikan ke Pushgateway agar dapat diserap oleh Prometheus. Evidently (Evidently AI 2025) dijalankan sebagai pelapor peleng-

kap yang menghasilkan ringkasan distribusi fitur dan kinerja model dalam bentuk *report* HTML yang dapat diaudit dan dilampirkan pada katalog DataHub.

Service berjalan sebagai *CronJob* pada *namespace* *model-lifecycle* dengan jadwal lima belas menit untuk fitur fluktuatif dan satu jam untuk *tabular feature* yang lebih stabil. Konfigurasi ambang per fitur dideklarasikan pada *ConfigMap* *drift-thresholds* sehingga perubahan ambang dapat dilakukan melalui *commit* pada Git tanpa membangun ulang *image*. Hasil tiap eksekusi ditulis dengan checksum versi konfigurasi sehingga riwayat ambang dapat ditelusuri saat audit. *Image* detektor dibangun dengan *uv* pada *Dockerfile* multi-stage agar model SBERT untuk deteksi *drift embedding* disertakan langsung pada *layer* terakhir *image*, sehingga *cold start* tidak memerlukan unduhan model.

V.4.2 Retraining Control Loop

Control loop dijalankan oleh Argo CronWorkflow dengan jadwal yang dapat dikonfigurasi per model. *Workflow* menjalankan dua langkah utama, yaitu pengukuran *drift* dan pemicu *training pipeline*. Pemicu *training* mengirim permintaan ke Kubeflow Pipelines sebagai pemenuhan KF-05 tentang otomatisasi *training pipeline*. *Training pipeline* membaca fitur *training* dari tabel *gold* ClickHouse, menjalankan *training* pada *job* dengan sumber daya yang dialokasikan oleh Kueue (Kueue Authors 2024), lalu mencatat metrik dan artefak model ke MLflow. Kelayakan model baru untuk menggantikan versi produksi ditentukan pada tahap promosi *canary* yang menilai metrik *serving*-nya secara langsung sebelum trafik penuh dialihkan, bukan pada perbandingan tersendiri sebelum *deployment*.

Pada tahap promosi, Argo Rollouts (Argo Rollouts Authors 2025) menyalurkan trafik *serving layer* secara bertahap ke versi baru memakai strategi *canary* dengan analisis metrik Prometheus, sehingga *rollback* otomatis dapat dilakukan ketika kinerja menurun. *retrain-on-drift* CronWorkflow disimpan pada direktori *workflow* milik *use case* yang terpisah dari *platform/* agar dapat di-*deploy* bersama *use case* ketika pengujian dijalankan. Konfigurasi penonaktifan *cache* KFP diterapkan pada langkah *train* dan *deploy* agar setiap eksekusi memakai data terbaru tanpa dipengaruhi *cache* historis. Pengiriman metrik *workflow* dilakukan di dalam langkah *decide-and-trigger* yang menulis ke Pushgateway, sehingga seluruh metrik eksekusi tetap terkumpul pada Prometheus meskipun *workflow* berdurasi singkat.

V.4.3 Penanganan Kasus Khusus

Implementasi menangani tiga kasus khusus yang sama dengan rancangan pada Subbab IV.5.3. Perwujudan ketiganya tidak menambah komponen baru di luar CronWorkflow dan Argo Rollouts yang sudah terpasang. Perilaku tiap kasus dapat diperiksa dari manifes dan log eksekusi pada *namespace* *model-lifecycle*. Rinciannya sebagai berikut.

1. **Waktu tunggu label per model**

Waktu tunggu label diatur per model agar *retraining* tidak dipicu sebelum label tersedia cukup.

2. ***Sliding window* untuk meredam fluktuasi**

Ambang *drift* dihitung dengan *sliding window* untuk meredam fluktuasi singkat.

3. **Penghentian promosi saat analisis *canary* gagal**

Ketika analisis *canary* gagal, promosi dihentikan sehingga versi stabil pada *serving layer* tetap dipertahankan.

Penanganan ketiga kasus khusus mengikuti rancangan pada Subbab IV.5.3. Ambang PSI dan KS beserta *lookback window* mengikuti mekanisme ConfigMap *drift-thresholds* yang telah dirinci pada Subbab V.4.1, termasuk jejak checksum versi konfigurasinya. Nilai parameter yang aktif dapat dibaca langsung dari manifes sehingga audit kebijakan tidak memerlukan akses ke sistem lain. Pemenuhan KF-07 diverifikasi melalui skenario evaluasi pada Bab VI.

V.5 Implementasi Sub-sistem Layanan Fitur *Dual-Store*

Sub-sistem layanan fitur *dual-store* mewujudkan rancangan pada Bagian IV.6 sebagai pemenuhan T-4, dengan satu sumber definisi fitur dan satu kontrak Feast untuk *tabular feature*, sedangkan fitur *embedding* dikelola pada indeks vektor terpisah. *Tabular feature* dimaterialisasi ke *online store* Valkey dan diakses melalui API Feast, sedangkan indeks vektor Qdrant diisi dan diakses melalui klien *native* di luar materialisasi Feast. Sumber definisi tunggal di *feature_repo/* mengikat ketiga penyimpanan itu sehingga perubahan skema fitur cukup dilakukan pada satu tempat. Bagian ini menjawab KF-01 sampai KF-04 yang menuntut manajemen fitur terpusat, *serving* ganda *online-offline*, validitas temporal, dan dukungan *vector embedding*.

V.5.1 Konfigurasi Feast

Feast (Feast Project 2024) dikonfigurasi dengan `feature_store.yaml` yang menentukan *offline store* ClickHouse, *online store* Valkey (Valkey Contributors 2025) melalui protokol RESP, dan registri *file-based* pada MinIO. Definisi fitur ditulis dalam Python pada modul `feature_definitions.py` dan didaftarkan ke registri melalui `feast apply`. Materialisasi fitur ke *online store* dijalankan oleh *job* berkala yang membaca dari ClickHouse dengan rentang waktu yang sesuai. Berkas `feature_store.yaml` yang sama dipakai oleh seluruh klien sehingga tidak ada konfigurasi penyimpanan yang didefinisikan ulang per layanan.

Registri Feast disimpan sebagai `registry.db` di *bucket* MinIO dengan kunci yang dirotasi melalui ESO sehingga klien Feast pada berbagai *namespace* berbagi sumber rujukan yang sama. *Service* `feast serve` dipasang sebagai *Deployment* yang dijangkau melalui *Service* `feast-server` pada *namespace* `model-lifecycle`. Pembaruan definisi fitur dilakukan oleh *service* materialisasi yang menjalankan `feast apply` sebagai langkah pada DAG `data_pipeline` Airflow, sehingga registri selalu sinkron dengan definisi pada `feature_repo/`. *Client* Feast pada layanan pemanggil dikonfigurasi dengan `registry_path` URI `s3://`, sehingga *single source of truth* tetap terjaga ketika klien berjalan pada *namespace* berbeda. Layanan pemanggil memakai SDK Python yang seragam, yaitu klien Feast untuk *online feature*, klien MLflow untuk registri model, dan protokol KServe v2 untuk *inference*, dengan *environment* `uv` yang mengunci versi ketiganya pada tiap layanan, sehingga KF-13 tentang API dan SDK terpadu terpenuhi.

V.5.2 Dukungan Vector Embeddings

Vector embedding disimpan sebagai fitur dengan tipe `Array(Float32)` pada ClickHouse dan sebagai *point* berdimensi 768 pada *collection* Qdrant (Qdrant Team 2025). Pengindeksan HNSW diaktifkan pada Qdrant dengan parameter `m` dan `ef_construct` yang dapat dikonfigurasi, dan kueri tetangga terdekat dilayani melalui API gRPC dengan filter *payload* pada saat pencarian. *Service* `vector-embedding` pada `platform/services/processing/vector/` membungkus model `sentence-transformers/all-mpnet-base-v2` sebagai penghasil *embedding* dan menyajikan API yang dipanggil oleh *stream processor* pada saat *event* masuk (Reimers dan Gurevych 2019). Metrik jarak yang dipakai adalah kosinus sesuai *default* layanan *embedding* untuk vektor yang dinormalkan.

Image vector-embedding dibangun dengan pola *bake* model yang sama seperti *ima-*

ge detektor *drift* pada Subbab V.4.1, sehingga *startup probe* tidak terganggu oleh unduhan model pada pemicu pertama. Collection Qdrant dideklarasikan oleh *init Job* yang mengirim PUT ke `/collections/nama-koleksi` dengan parameter HNSW sesuai konfigurasi. *Snapshot* koleksi disimpan ke MinIO secara berkala dengan *Job qdrant-snapshot* yang menambah objek pencadangan ke jadwal Velero. Koleksi vektor Qdrant diakses langsung oleh layanan *embedding* melalui klien *native* Qdrant, terpisah dari *online store* Valkey yang menyajikan *tabular feature* melalui Feast, sehingga *vector query flow* dan *tabular feature flow* tidak saling bergantung.

V.5.3 Materialisasi dan *Point-in-Time Correctness*

`get_historical_features` dijalankan pada *training pipeline* dengan kolom `event_timestamp` pada *entity dataframe*. Feast melakukan *point-in-time join* pada *offline store* ClickHouse dengan memilih nilai fitur yang timestamp-nya tidak melampaui `event_timestamp` setiap baris entitas dan masih berada dalam rentang `ttl FeatureView`. Ketika terdapat lebih dari satu kandidat untuk satu titik waktu, kolom `created_timestamp` dipakai sebagai penentu agar hanya nilai paling mutakhir yang diambil, sehingga nilai fitur yang dipakai pada saat *training* identik dengan nilai yang tersedia pada saat itu. Materialisasi ke *online store* berjalan secara berkala dengan `feast materialize-incremental`, dan *stream materializer* pada Flink menulis fitur *real-time* ke Valkey untuk *tabular feature* secara bersamaan dengan penulisan ke ClickHouse. Keterpaduan *batch pipeline* dan *stream* pada satu kontrak Feast ini memenuhi KF-11.

Materialisasi dijalankan berkala oleh DAG Airflow melalui *task* `feast_materialize` yang mendorong fitur dari *offline store* ClickHouse ke *online store* Valkey pada jadwal per jam. Karena nilai pada Valkey merupakan hasil materialisasi dari ClickHouse, konsistensi antar *store* terjaga secara struktural tanpa salinan yang dipelihara terpisah. Kualitas data diverifikasi oleh *CronJob* `ge-checkpoint` yang menjalankan *suite* Great Expectations terhadap tabel pada ClickHouse setiap enam jam, dengan hasil validasi ditulis ke MinIO dan *gauge* lulus atau gagal dikirim ke Pushgateway. Pengujian *point-in-time* dijalankan sebagai skenario SK-F-03 yang mengaudit `get_historical_features` pada *training dataset*, memastikan kontrak `event_timestamp` dan `ttl` tetap dipatuhi oleh *FeatureView* yang ditambahkan.

V.6 Verifikasi Implementasi

Verifikasi *execution flow* dilakukan dengan satu *use case* domain nyata sebagai kasus pengujian, yaitu analitik pasar aset kripto, yang struktur layanan, konfigurasi, dan datanya dirinci pada Bab VI. Pemilihan domain ini berpijak pada tiga alasan yang dapat dirunut ke bukti. Alasan pertama terletak pada *use case* ini yang menjalankan seluruh sembilan *layer* representatif yang ditetapkan pada Subbab IV.1, dengan pemetaan tiap *layer* ke komponennya dirinci pada Subbab VI.1.1, sehingga verifikasi fungsionalnya menyentuh himpunan layanan yang sama dengan yang dituntut praktik industri. Alasan kedua muncul karena pasar aset kripto beroperasi terus menerus tanpa jam tutup bursa (Makarov dan Schoar 2020), sehingga *ingestion pipeline* dan pemrosesan *stream* teruji oleh aliran *event* nyata selama 24 jam penuh, bukan oleh beban sintetis yang dijadwalkan. Alasan ketiga bertumpu pada volatilitas harga aset kripto yang tinggi dan bergerombol (Katsiampa 2017) yang membuat distribusi fitur turunan harga rawan bergeser dalam hitungan jam, sehingga sub-sistem deteksi *drift* dan *retraining* otomatis memperoleh pemicu alami tanpa perlu injeksi buatan sebagai satu-satunya sumber pengujian. Pemilihan ini tidak mengubah sifat domain-agnostik platform, karena seluruh kode dan konfigurasi platform tetap berada pada repositori *platform/*, sedangkan kode dan konfigurasi spesifik domain tinggal pada direktori *use case* tersendiri yang mengikuti pola *base* dan *overlays Kustomize*. Dengan pemisahan itu, *use case* lain cukup menyalin dan menyesuaikan berkas konfigurasi domain tanpa mengubah kode platform, sehingga pemilihan kripto tidak mengurangi keberlakuan platform pada domain lain.

V.6.1 Lingkup Verifikasi

Verifikasi mencakup lima *flow* yang masing-masing menyorot satu sub-sistem. Kelima *flow* itu dipilih dari alur ujung ke ujung *use case* sehingga setiap kontrak antar *layer* teruji oleh trafik nyata. Setiap *flow* memiliki keluaran yang dapat diamati pada *dashboard* atau tabel analitik sebagai bukti. Uraian kelima *flow* tersebut adalah sebagai berikut.

1. ***Ingestion pipeline***

Ingestion pipeline diuji dengan *stream* dari sumber eksternal yang masuk ke Kafka melalui layanan *websocket-collector* pada *use case*.

2. ***Processing pipeline***

Processing pipeline diuji dengan *stream-processor* berbasis Flink yang menulis fitur agregasi ke ClickHouse dan Valkey.

3. *Training flow*

Training flow diuji dengan *pipeline* Kubeflow yang membaca fitur dari Feast dan menulis model ke MLflow.

4. *Serving flow*

Serving flow diuji dengan *InferenceService* KServe yang memuat model dari MLflow, dengan promosi versi pada *serving layer* yang dikelola oleh Argo Rollouts.

5. *Retraining pipeline*

Retraining pipeline diuji dengan menjalankan *drift-detector* dan memicu *retrain-on-drift workflow*.

Uji ketahanan pendek menggunakan Chaos Mesh (Chaos Mesh Authors 2025) untuk menginjeksikan *fault* pada *pod* terpilih. Skenario yang dipakai adalah PodChaos yang menghentikan paksa *pod* terpilih lalu mengamati pemulihannya oleh *controller*. Pencadangan dijalankan terjadwal oleh Velero (Velero Authors 2025) ke *bucket* MinIO khusus pencadangan sebagai langkah disiplin pemulihan. Pada skenario ketahanan di Bab VI, kedua mekanisme itu diuji kembali.

Pemilihan kelima *flow* tersebut bertujuan agar setiap sub-sistem mendapat verifikasi minimal satu skenario nyata, sehingga ketidaktepatan rancangan dapat ditemukan sebelum penilaian akhir pada Bab VI. Skenario *use case* menetapkan beban yang lebih tinggi pada *ingestion pipeline* dan pemrosesan dibandingkan *training flow*, karena *use case* ber-*throughput* tinggi memproduksi banyak *event* per detik dari beberapa entitas secara paralel. Pengamatan dilakukan dengan *dashboard* Grafana yang menampilkan metrik latensi, *throughput*, panjang antrean Kafka, dan tingkat keberhasilan materialisasi. Hasil pengamatan dibandingkan dengan target metrik pada KNF Bab III untuk menentukan apakah setiap *flow* memenuhi target yang telah ditetapkan.

V.6.2 Pengamatan Hasil Awal

Hasil pengamatan awal memperlihatkan bahwa *control plane* platform terbentuk sesuai rancangan. Seluruh komponen pada kelima *flow* berhasil di-*deploy* dan direkonsiliasi oleh Argo CD, *retraining control loop* terpicu otomatis ketika injeksi *drift* terkendali diterapkan pada salah satu fitur, dan promosi versi pada *serving layer* dikendalikan oleh Argo Rollouts sesuai konfigurasi *canary*. Reprodusibilitas *flow* diuji dengan merekonstruksi seluruh komponen platform dari Argo CD pada *cluster* k3s yang baru, dan rekonstruksi tersebut berhasil dilakukan tanpa intervensi manual selain *bootstrap* Argo CD awal. Penilaian kebenaran data *end-to-end*, validitas

point-in-time pada *training*, latensi *serving*, *throughput* pemrosesan, dan ketepatan deteksi *drift* diuraikan secara terperinci pada Bab VI.

Pengamatan tambahan menunjukkan bahwa *observability flow* berhasil mempertahankan metrik dan log dari seluruh komponen pada satu antarmuka Grafana, dan bahwa *event lineage* dari *emitter* OpenLineage Airflow dan Spark serta konektor *ingestion* DataHub untuk Feast, MLflow, ClickHouse, dan Kafka muncul pada satu graf metadata dengan kosakata yang seragam. Pencadangan Velero berjalan terjadwal tanpa intervensi, dan pengujian pemulihan dari pencadangan memperlihatkan bahwa konfigurasi seluruh komponen dapat direkonstruksi tanpa langkah manual. Uji *fault injection* Chaos Mesh menunjukkan bahwa *pod* yang dimatikan secara paksa dijadwalkan ulang secara otomatis oleh *controller* Kubernetes, dan bahwa Argo Rollouts otomatis menahan promosi ketika metrik *canary* menyentuh ambang. Catatan pengamatan ini menjadi dasar bagi evaluasi pada Bab VI yang menilai pemenuhan KF dan KNF terhadap target metrik.

BAB VI

EVALUASI

Bab ini memaparkan evaluasi platform terhadap kebutuhan fungsional KF-01 sampai KF-14 dan kebutuhan nonfungsional KNF-01 sampai KNF-12 yang disusun pada Bab III. Evaluasi disusun mengikuti empat tujuan platform T-1 sampai T-4 sehingga setiap hasil dapat dipetakan kembali pada tujuan, rumusan masalah, dan butir kesimpulan dengan indeks yang sama. Pengujian dilakukan pada satu *use case* domain nyata sebagai kasus verifikasi, yaitu pasar aset kripto dengan data Coinbase, agar perilaku platform dapat diamati pada beban dan pola data yang realistis tanpa mengubah sifat *domain-agnostic* platform. Penyajian dibagi menjadi metode evaluasi, hasil evaluasi, perbandingan biaya infrastruktur dan tenaga kerja, serta pembahasan, dengan lingkup penerimaan fungsional dan struktural pada lingkungan *node* tunggal sesuai batasan BI-1, sedangkan karakterisasi beban kuantitatif pada *cluster multi-node* menjadi arah pengembangan yang dirinci pada Bab VII.

VI.1 Metode Evaluasi

Metode evaluasi mengikuti tiga dimensi yang melekat pada empat tujuan platform, yaitu pemenuhan fungsional, pemenuhan nonfungsional, dan tata kelola. Pemenuhan fungsional menilai apakah setiap KF terbukti melalui skenario uji yang dapat dijalankan ulang, pemenuhan nonfungsional menilai apakah setiap KNF mencapai target metrik yang ditetapkan, dan tata kelola menilai apakah *lineage* tertelusur, kontrak data ditegakkan, serta kebijakan akses dapat diaudit. Setiap skenario diberi penanda SK-F untuk kebutuhan fungsional dan SK-N untuk kebutuhan nonfungsional, lalu dikelompokkan di bawah tujuan T-1 sampai T-4 yang relevan. Penomoran tersebut menjaga keterhubungan satu lawan satu antara skenario, kebutuhan, dan tujuan sehingga kegagalan satu skenario dapat segera dirunut ke komponen yang bertanggung jawab.

Skenario dijalankan secara manual pada tahap evaluasi dan tidak menjadi bagian dari *make phase-full* maupun rekonsiliasi Argo CD, agar pengukuran tidak mengganggu *production pipeline* platform. *Load generator* dijalankan dari *namespace* *platform-test* yang terpisah, sedangkan instrumen pengukuran memanfaatkan komponen observabilitas yang sudah terpasang. Instrumen utama mencakup k6 untuk beban HTTP dan gRPC, Chaos Mesh untuk injeksi *fault*, Great Expe-

ctations untuk kontrak kualitas, serta Prometheus, Grafana, Grafana Tempo, dan OpenCost untuk metrik, *trace*, dan biaya. Berkas skenario disimpan pada direktori *experiments/* yang sejajar dengan *platform/* dan *use-case-crypto/* sebagai *layer* verifikasi terpisah, dengan subdirektori *load/* untuk beban latensi dan *throughput*, *chaos/* untuk injeksi *fault*, *drift/* untuk pengujian deteksi *drift*, *feast/* untuk *serving online feature*, *parity/* untuk paritas *batch* dan *stream*, *lineage/* untuk penelusuran *lineage*, serta *etl/* untuk pemeriksaan *landing* data. Susunan ini membuat prosedur uji dapat ditelusuri ulang bersama kode tanpa mengubah sistem yang diuji.

VI.1.1 Kasus Verifikasi dan Lingkungan Uji

Kasus verifikasi adalah *use case* pasar aset kripto dengan data Coinbase yang dialirkan melalui dua *ingestion pipeline* yang saling melengkapi. *Real-time pipeline* memakai layanan *websocket-collector* yang berlangganan kanal *ticker* dan *matches* Coinbase pada resolusi per detik hingga per transaksi, lalu *stream-processor* berbasis Flink mengagregasinya menjadi fitur hasil *windowing* pada tabel *bronze.crypto_ohlcv_features*. *Historical pipeline* memakai layanan *rest-collector* yang menarik *candle OHLCV* Coinbase pada granularitas satu menit sebagai *baseline* sekaligus *backfill* data historis sejak 1 Maret 2026 mengikuti anggaran penyimpanan pada lingkungan *node* tunggal sesuai batasan BI-1, lalu memuatnya pada tabel *bronze.crypto_ohlcv*. *Endpoint candle* REST Coinbase tidak menyediakan granularitas di bawah satu menit sehingga resolusi per detik hanya berlaku pada *real-time pipeline*. Domain ini dipilih karena menuntut *throughput ingestion* yang tinggi dari pasar yang beroperasi terus-menerus tanpa jam tutup bursa (Makarov dan Schoar 2020), latensi *serving* rendah, dan distribusi data nonstasioner akibat volatilitas harga yang tinggi (Katsiampa 2017), sehingga keempat *sub-sistem* platform diuji pada kondisi yang menantang, sejalan dengan justifikasi pemilihan pada Subbab V.6. Di luar keempat *sub-sistem* tersebut, *use case* kripto mengaktifkan seluruh sembilan *layer* platform representatif dari Subbab IV.1 secara bersamaan. *Ingestion pipeline streaming* dan *batch* bersama pemrosesan Flink dan dbt mengisi *Data Ingestion and Processing Layer*, penyimpanan *lakehouse* mengisi *Data Storage Layer*, layanan fitur *dual-store* dengan *tabular feature*, *aggregate feature*, serta *vector feature* mengisi *Feature Service Layer*, dan tata kelola dengan *lineage* mengisi *Data Governance Layer*, sehingga empat *layer* bidang data terisi seluruhnya. Pada lima *layer* bidang model dan operasional, orkestrasi k3s yang menjadi fondasi seluruh komponen mengisi *Orchestration and Infrastructure Layer*, *training flow* dengan *retraining* otomatis dan *model serving* berlatensi rendah mengisi *Model Li-*

fecycle Layer, observabilitas dengan metrik, log, dan *trace* mengisi *Observability Layer*, pengiriman GitOps mengisi *GitOps and Continuous Delivery Layer*, serta kontrol keamanan mengisi *Security Layer*. Karena verifikasi fungsional menyentuh kesembilan *layer* tersebut, *use case* ini menjadi kasus uji yang mewakili himpunan layanan representatif meskipun bersifat spesifik domain. Seluruh kode dan konfigurasi spesifik domain berada pada direktori *use-case-crypto/* yang terpisah dari *platform/*, mencakup layanan *websocket-collector* dan *rest-collector* sebagai produsen *event*, *stream-processor* berbasis Flink, *batch layer* berbasis dbt, definisi Feast, serta *inference bridge* dan *dashboard*. Pemisahan ini menegaskan bahwa platform tetap *domain-agnostic* dan *use case* hanya berperan sebagai beban uji yang dapat diganti tanpa menyentuh *control plane*.

Konfigurasi spesifik domain diterapkan melalui *overlay* Kustomize yang menambahkan prefiks *crypto-* pada sumber daya basis platform, sehingga *InferenceService* basis bernama *predictor* menjadi *crypto-predictor* ketika di-*deploy*. *Overlay* tersebut hanya menetapkan prefiks nama, pemetaan registri *image*, jumlah *replica* awal, serta batas *autoscaling* untuk lingkungan *node* tunggal, sedangkan parameter sumber data berada pada *ConfigMap* basis sehingga definisi dasar tidak perlu disentuh, sebagaimana ditunjukkan pada Listing VI.1. Sesuai invarian *node* tunggal, setiap *workload* berjalan dengan satu *replica* saat *idle* dan diskalakan oleh HPA serta KEDA hanya ketika beban nyata muncul, dengan *maxReplicas* dibatasi tiga agar muat pada satu *node*. Dengan demikian, penggantian *use case* cukup dilakukan dengan menyiapkan *overlay* baru tanpa mengubah manifes platform, sekaligus menjadi bukti konkret atas pemenuhan KF-12 tentang konfigurasi deklaratif dan KNF-11 tentang portabilitas.

Listing VI.1 Kutipan *overlay* Kustomize *use case*

```
1 # use-case-crypto/manifests/overlays/local/kustomization.yaml
2 namePrefix: crypto-
3 resources:
4   - ../../base
5   - ../../cross-namespace
6 images:
7   - name: rest-collector
8     newName: localhost:5000/crypto-rest-collector
9     newTag: latest
10  - name: websocket-collector
11    newName: localhost:5000/crypto-websocket-collector
12    newTag: latest
13  # ... validator, analyzer, dll.
14 replicas:
```



```

15   - name: rest-collector
16     count: 1
17   - name: websocket-collector
18     count: 1
19 patches:
20   - target:
21       kind: HorizontalPodAutoscaler
22     patch: |-
23       - op: replace
24         path: /spec/maxReplicas
25         value: 3
26       - op: replace
27         path: /spec/minReplicas
28         value: 1

```

VI.1.2 Evaluasi Tujuan T-1: Arsitektur Terintegrasi dan GitOps

Evaluasi T-1 menilai apakah seluruh platform dapat dipasang dari satu sumber Git, dikelola secara deklaratif, dan menyediakan otomatisasi *model lifecycle* setara MLOps *level 2*. Skenario SK-F-01 mengubah definisi *feature view* pada Gitea lalu mengamati rekonsiliasi Argo CD untuk membuktikan KF-01, sementara SK-F-12 mengubah jumlah *replica* pada manifes untuk membuktikan konfigurasi deklaratif KF-12 yang konvergen tanpa *drift*. Skenario SK-F-06 mempromosikan model melalui Argo Rollouts dengan strategi *canary* dan memicu *rollback* pada model bermasalah untuk membuktikan otomatisasi *deployment* model pada KF-06, sedangkan SK-F-13 menjalankan satu *notebook* dalam satu *environment* uv yang memuat SDK Feast, MLflow, dan klien *inference* KServe v2 sebagai tiga operasi baca independen untuk membuktikan antarmuka terpadu KF-13. Skenario SK-F-14 memenuhi kuota *ClusterQueue* Kueue untuk membuktikan manajemen sumber daya KF-14, dengan *job* di luar anggaran berstatus *Pending*.

Kematangan MLOps *level 2* dinilai melalui tiga *automation flow* yang saling terhubung. *Flow* pertama adalah *training pipeline* otomatis pada Kubeflow Pipelines yang dipicu data baru atau ambang *drift*, *flow* kedua adalah *deployment* model otomatis melalui KServe dan Argo Rollouts, dan *flow* ketiga adalah pemantauan berkelanjutan oleh Argo Workflows yang melaporkan metrik ke Prometheus. Reprodusibilitas *deployment* diuji oleh SK-N-11 yang menerapkan ulang seluruh manifes pada *node* k3s baru dan SK-N-12 yang mengukur *test coverage* serta waktu konvergensi *make phase-full*. Gabungan skenario ini menegaskan bahwa T-1 tidak hanya menyediakan komponen, tetapi juga menghadirkan satu *control plane* yang

dapat direkonstruksi dan diaudit.

Atribut kualitas yang bersifat lintas komponen turut dievaluasi pada T-1 karena melekat pada *control plane* terintegrasi, bukan pada satu *sub-sistem* tunggal. Skenario SK-N-03 menaikkan beban dengan `load/hpa-keda-rampup.js` untuk membuktikan skalabilitas horizontal KNF-03 melalui HPA dan KEDA *ScaledObject*, sedangkan SK-N-04 menginjeksikan *fault* dengan Chaos Mesh untuk membuktikan keandalan KNF-04 pada batas RTO dan RPO. Skenario SK-N-08 mengganti satu komponen melalui antarmuka CRD dan *overlay* Kustomize untuk membuktikan ekstensibilitas KNF-08, SK-N-09 mengakses seluruh konsol melalui satu sesi identitas dex untuk membuktikan kemudahan penggunaan KNF-09, dan SK-N-10 mengukur kompresi serta atribusi biaya melalui OpenCost untuk membuktikan efisiensi sumber daya KNF-10. Pengelompokan ini menempatkan T-1 sebagai tujuan dengan beban pengujian nonfungsional terbanyak karena arsitektur terintegrasi menanggung jaminan kualitas yang berlaku menyeluruh pada seluruh komponen. Tabel VI.1 merangkum prosedur dan kriteria penerimaan seluruh skenario T-1 tersebut.

Tabel VI.1 Skenario Uji Penerimaan Tujuan T-1

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-01	KF-01	Mengubah definisi <i>feature view</i> pada repositori Gitea lalu mengamati rekonsiliasi Argo CD, kemudian memverifikasi <i>feast feature-views list</i> .	<i>Feature view</i> baru aktif tanpa intervensi manual dan perubahan terlacak pada riwayat Git.
SK-F-06	KF-06	Mempromosikan model melalui Argo Rollouts dengan strategi <i>canary</i> , lalu menerapkan model bermasalah untuk memicu <i>rollback</i> .	Model valid dipromosikan dan model bermasalah memicu <i>rollback</i> otomatis tanpa kehilangan permintaan.
SK-F-12	KF-12	Mengubah jumlah <i>replica</i> pada manifest YAML di Gitea, lalu mengamati rekonsiliasi Argo CD.	Status <i>cluster</i> konvergen ke definisi Git dan tidak menyisakan <i>drift</i> .
SK-F-13	KF-13	Menjalankan <i>notebook</i> satu <i>environment</i> uv yang memuat SDK Feast, MLflow, dan klien <i>inference</i> KServe v2, lalu mengamati ketiganya sebagai operasi baca independen.	Ketiga klien termuat dan berjalan dari satu <i>environment</i> uv tanpa konfigurasi tambahan per layanan.
SK-F-14	KF-14	Mengirim sejumlah <i>training job</i> melebihi kuota <i>ClusterQueue</i> Kueue, lalu mengamati status admisi.	<i>Job</i> di luar anggaran kuota berstatus <i>Pending</i> . Admisi mengikuti <i>nominalQuota</i> dan <i>borrowingLimit</i> .

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-N-03	KNF-03	Menaikkan beban dengan <code>load/hpa-keda-rampup.js</code> sambil mengamati HPA, KEDA <i>ScaledObject</i> , dan jumlah <i>pod</i> .	Jumlah <i>replica</i> naik mengikuti beban dan <i>throughput</i> bertambah mendekati linear.
SK-N-04	KNF-04	Menginjeksikan <i>fault</i> dengan Chaos Mesh (<code>pod-chaos</code> dan <code>network-chaos</code>) lalu mengamati pemulihan.	<i>Workload</i> pulih otomatis dengan RTO dan RPO di bawah ambang yang ditetapkan.
SK-N-08	KNF-08	Mengganti satu komponen (misalnya <i>se-rrving runtime</i>) melalui antarmuka CRD dan <i>overlay</i> Kustomize.	Penggantian terisolasi pada antarmuka tanpa mengubah komponen lain.
SK-N-09	KNF-09	Mengakses seluruh konsol platform melalui satu sesi identitas dex serta memeriksa ketersediaan dokumentasi operasional pada repositori Gitea.	Seluruh konsol dapat dicapai melalui satu <i>authentication flow</i> tanpa login ulang dan dokumentasi prosedur inti tersedia.
SK-N-10	KNF-10	Mengukur rasio kompresi ClickHouse, utilisasi sumber daya, dan atribusi biaya <i>workload</i> pada OpenCost.	Rasio kompresi dan utilisasi memenuhi target serta biaya per <i>workload</i> dapat diatribusikan.
SK-N-11	KNF-11	Menerapkan ulang seluruh manifes GitOps pada <i>node</i> k3s baru dari satu sumber Git.	Seluruh komponen terekonstruksi tanpa intervensi manual selain <i>bootstrap</i> Argo CD.
SK-N-12	KNF-12	Menjalankan <code>make usecase-crypto-test</code> untuk <i>test coverage</i> dan <code>make phase-full</code> pada <i>cluster</i> bersih sambil mengukur waktu konvergensi.	<i>Test coverage</i> melewati ambang yang ditetapkan dan <i>phase-full</i> konvergen tanpa langkah manual.

VI.1.3 Evaluasi Tujuan T-2: Tata Kelola Data

Evaluasi T-2 menilai apakah katalog metadata, *lineage*, dan kontrol kualitas berjalan otomatis sepanjang *pipeline* data, fitur, dan model. Skenario SK-F-08 menelusuri *lineage* pada DataHub melalui `lineage/lineage-walk.sh` dari *topic* sumber sampai keluaran prediksi untuk membuktikan KF-08, dengan *event lineage* dikirim melalui OpenLineage dan *ingestion* terjadwal. Skenario SK-F-09 menjalankan dua *training run* pada MLflow lalu melakukan *replay* dari *snapshot* untuk membuktikan pelacakan eksperimen KF-09, sedangkan SK-F-10 memindahkan model melalui status *staging*, *production*, dan *archived* untuk membuktikan registri dan *audit trail* KF-10. Skenario SK-N-05 menjalankan *checkpoint* Great Expectations dan meng-

injeksikan pelanggaran skema, rentang nilai, serta kelengkapan untuk membuktikan penegakan kontrak kualitas data KNF-05 sepanjang *pipeline*.

Dimensi keamanan dan observabilitas tata kelola dievaluasi melalui dua skenario tambahan. Skenario SK-N-06 menelusuri satu *trace* OpenTelemetry pada Grafana Tempo dari *ingestion* sampai prediksi untuk membuktikan observabilitas KNF-06, sehingga metrik, log, dan *trace* dapat dirujuk silang pada satu antarmuka. Skenario SK-N-07 memindai *cluster* dengan Trivy dan memeriksa konfigurasi TLS untuk membuktikan keamanan KNF-07, mencakup mTLS Istio, enkripsi *at rest* MinIO melalui KES dan OpenBao, serta kebijakan admisi Kyverno. Aspek-aspek tersebut menjadikan tata kelola bukan sekadar katalog pasif, melainkan kontrol aktif yang menegakkan kontrak dan kebijakan lintas komponen. Tabel VI.2 merangkum prosedur dan kriteria penerimaan skenario T-2.

Tabel VI.2 Skenario Uji Penerimaan Tujuan T-2

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-08	KF-08	Menelusuri <i>lineage</i> pada DataHub dari <i>topic</i> sumber hingga keluaran prediksi melalui antarmuka katalog.	Rantai <i>lineage</i> utuh dari sumber data sampai prediksi tersaji pada satu graf metadata.
SK-F-09	KF-09	Menjalankan dua <i>training run</i> lalu mencatatnya pada MLflow, kemudian melakukan <i>replay run</i> dari <i>snapshot</i> data dan parameter tercatat.	<i>Run</i> tercatat lengkap dan <i>replay</i> menghasilkan selisih metrik di bawah satu persen.
SK-F-10	KF-10	Memindahkan model melalui status <i>none</i> , <i>staging</i> , <i>production</i> , dan <i>archived</i> pada registri MLflow.	Transisi mengikuti aturan yang ditetapkan dan <i>audit trail</i> terekam lengkap.
SK-N-05	KNF-05	Menjalankan <i>checkpoint</i> Great Expectations pada <i>batch</i> data, lalu menginjeksikan pelanggaran skema, rentang nilai, dan kelengkapan untuk menguji penegakan kontrak.	Setiap pelanggaran kontrak kualitas terdeteksi dan <i>batch</i> cacat ditolak sebelum masuk <i>layer</i> hilir.
SK-N-06	KNF-06	Menelusuri satu <i>trace</i> OpenTelemetry pada Grafana Tempo dari <i>ingestion</i> hingga prediksi.	Satu <i>trace</i> menautkan lintasan kritis dan metrik, log, serta <i>trace</i> dapat dirujuk silang.
SK-N-07	KNF-07	Memindai <i>cluster</i> dengan Trivy dan memeriksa konfigurasi TLS pada <i>endpoint</i> layanan.	TLS 1.3 <i>in transit</i> dan AES-256 <i>at rest</i> terverifikasi tanpa kerentanan kritis terbuka.

VI.1.4 Evaluasi Tujuan T-3: Deteksi *Drift* dan *Retraining*

Evaluasi T-3 menilai apakah deteksi *drift* terotomasi memicu *retraining* sesuai kebijakan dan apakah *feature serving* menjamin *point-in-time correctness*. Skenario SK-F-07 menerapkan pergeseran distribusi terkendali pada aliran data nyata melalui `inject_drift.py`. Skrip tersebut mengonsumsi rekaman pasar tervalidasi lalu menggeser nilainya beberapa sigma sebelum dipublikasikan ulang. Skenario ini kemudian mengamati detektor *drift* dan *CronWorkflow* *retrain-on-drift* untuk membuktikan pemantauan KF-07. Detektor membandingkan distribusi produksi terhadap distribusi *training* dengan *Population Stability Index* dan uji Kolmogorov-Smirnov, lalu memicu *training pipeline* ketika ambang terlampaui. Skenario SK-F-05 menjalankan *training pipeline* pada KubeFlow Pipelines yang membaca fitur dari tabel *gold* dan menulis model ke MLflow untuk membuktikan otomasi *training* KF-05.

Validitas temporal diuji secara khusus karena *point-in-time correctness* menjadi pembeda utama platform ini dari *feature serving* tanpa *feature store*, yang hanya menarik *tabular feature* dari satu sumber. Skenario SK-F-03 mengaudit `get_historical_features` pada *training dataset* untuk membuktikan KF-03 dengan *probe timestamp* masa depan yang menolak setiap baris bermuatan informasi setelah *event timestamp* acuan, sehingga jaminan *zero leakage* ditegakkan langsung pada *flow* penyusunan fitur *training*. Gabungan skenario ini menegaskan bahwa T-3 menjawab dua risiko sekaligus, yaitu degradasi model akibat *drift* dan *temporal leakage* akibat penyusunan fitur yang keliru. Prosedur dan kriteria penerimaan skenario T-3 dirangkum pada Tabel VI.3.

Tabel VI.3 Skenario Uji Penerimaan Tujuan T-3

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-03	KF-03	Mengaudit <code>get_historical_features</code> pada <i>training dataset</i> untuk memastikan <i>point-in-time window</i> dipatuhi.	Tidak ada baris yang memakai informasi setelah <i>event timestamp</i> acuan.
SK-F-05	KF-05	Menjalankan <i>training pipeline</i> pada KubeFlow Pipelines yang membaca fitur dari tabel <i>gold</i> dan menulis model ke MLflow.	<i>Pipeline</i> berjalan dari ujung ke ujung dan model tercatat sebagai artefak <i>run</i> pada MLflow yang dapat disajikan KServe.
SK-F-07	KF-07	Menginjeksikan <i>drift</i> terkendali pada satu fitur data nyata, lalu mengamati detektor <i>drift</i> dan <i>CronWorkflow</i> <i>retrain-on-drift</i> .	<i>Drift</i> terdeteksi saat ambang PSI atau KS terlampaui dan <i>retraining pipeline</i> terpicu otomatis.

VI.1.5 Evaluasi Tujuan T-4: Layanan Fitur *Dual-Store*

Evaluasi T-4 menilai apakah layanan fitur *dual-store* menyajikan *tabular feature* dan *aggregate feature* dengan kontrak yang konsisten antara *training* dan *serving*, serta menyajikan *vector feature* pada indeks terpisah dengan ruang *embedding* yang sama pada kedua fase tersebut. Skenario SK-F-02 memeriksa *serving online feature non-null* pada Valkey melalui `feast/online-serving-check.py` sebagai bukti sisi *online serving* ganda KF-02. Kesetaraan nilainya terhadap penyimpanan *offline* ClickHouse bersandar pada proses materialisasi Feast yang menyalin nilai dari penyimpanan *offline* tersebut ke penyimpanan *online* Valkey sehingga keduanya memuat nilai yang sama. Skenario SK-F-04 menjalankan beban pencarian vektor pada Qdrant melalui `load/vector-search-latency.js` untuk membuktikan dukungan *vector embeddings* KF-04. Skenario SK-F-11 membandingkan fitur hasil *batch* dan hasil *stream* pada indikator yang sama melalui `parity/parity-check.sh` untuk membuktikan pemrosesan ganda KF-11 dengan definisi fitur yang konsisten. Skenario SK-F-02 dan SK-F-11 menelusuri kontrak *tabular feature* dari sisi kebenaran nilai, sedangkan SK-F-04 menegaskan terbentuknya *serving flow* vektor, sebelum beban tinggi diterapkan.

Kinerja layanan fitur diuji oleh kelompok skenario nonfungsional yang khusus mengukur latensi dan *throughput serving flow*. Skenario SK-N-01 mengukur latensi *feature serving* dan *vector search* dengan k6 melalui `load/feast-online-latency.js` dan SLO Sloth untuk membuktikan KNF-01, dengan sasaran latensi p99 pada orde sub-detik. Skenario SK-N-02 mengukur *throughput serving flow* dan *stream* dengan k6 melalui `load/feast-throughput.js` serta `kafka-producer-perf-test` untuk membuktikan KNF-02, sambil memantau *lag* konsumen pada beban puncak. Melalui kedua skenario tersebut, *layer* fitur ditempatkan sebagai titik temu seluruh *data flow* sehingga kebenaran nilai fitur menjadi prasyarat bagi kualitas layanan yang diukur, sedangkan atribut kualitas lintas komponen ditangani pada T-1. Tabel VI.4 merangkum prosedur dan kriteria penerimaan skenario T-4.

Tabel VI.4 Skenario Uji Penerimaan Tujuan T-4

Skenario	Kebutuhan	Prosedur Uji	Kriteria Penerimaan
SK-F-02	KF-02	Memeriksa <i>online feature serving</i> pada Valkey mengembalikan nilai <i>non-null</i> melalui <code>online-serving-check.py</code> .	<i>Online serving</i> mengembalikan nilai <i>non-null</i> dan kesetaraan nilai <i>online</i> dan <i>offline</i> terpenuhi secara struktural melalui materialisasi.
SK-F-04	KF-04	Menjalankan beban pencarian vektor pada Qdrant melalui <code>load/vector-search-latency.js</code> dengan k6.	Latensi pencarian vektor berada pada orde sub-detik. Pengujian <i>recall</i> dilakukan saat koleksi vektor terisi.
SK-F-11	KF-11	Membandingkan fitur hasil <i>batch</i> (dbt) dan hasil <i>stream</i> (Flink) untuk indikator yang sama.	Nilai fitur <i>batch</i> dan <i>stream</i> setara dalam toleransi yang ditetapkan.
SK-N-01	KNF-01	Menjalankan <code>load/feast-online-latency.js</code> dan beban pencarian vektor dengan k6 sambil memantau SLO Sloth.	Latensi p99 berada pada orde sub-detik pada <i>feature serving</i> dan <i>vector search</i> .
SK-N-02	KNF-02	Menjalankan <code>load/feast-throughput.js</code> untuk <i>serving</i> dan <code>kafka-producer-perf-test</code> untuk <i>stream</i> , sambil memantau <i>lag</i> .	<i>Throughput</i> mencapai target dan <i>lag</i> konsumen tetap terkontrol pada beban puncak.

VI.1.6 Matriks Cakupan dan Uji Penerimaan

Pemetaan antara skenario dan kebutuhan bersifat banyak-ke-banyak, sebab satu skenario kerap menegaskan lebih dari satu kebutuhan dan satu kebutuhan dapat diperkuat oleh beberapa skenario. Sebagai contoh, SK-F-04 yang menguji latensi pencarian vektor sekaligus menegaskan KNF-01, sedangkan SK-N-01 yang mengukur latensi p99 *serving* turut memperkuat KF-04 pada sisi kualitas layanan vektor. Tabel VI.1 sampai Tabel VI.4 pada subbab metode di atas merangkum prosedur uji dan kriteria penerimaan setiap skenario menurut tujuannya. Susunan tersebut memastikan seluruh empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional memiliki sekurang-kurangnya satu skenario uji yang konkret. Katalog perintah yang dapat dijalankan ulang untuk setiap skenario, termasuk langkah persiapan pemuatan konfigurasi `config.crypto.env` dan pembuatan *namespace* `platform-test`, dirangkum pada Lampiran B sehingga setiap baris keempat tabel skenario tersebut dapat ditelusuri ke perintah konkret yang menghasilkan buktinya.

Kelengkapan matriks diperiksa dengan menelusuri setiap kebutuhan pada Tabel III.1 dan Tabel III.2 ke sekurang-kurangnya satu baris skenario. Pemeriksaan berjalan

dua arah, yaitu dari kebutuhan ke skenario untuk memastikan cakupan dan dari skenario ke kebutuhan untuk memastikan setiap uji memiliki sasaran yang jelas. Skenario yang menegaskan lebih dari satu kebutuhan dicatat pada semua kebutuhan terkait agar redundansi verifikasi terlihat. Hasil penelusuran itulah yang dirangkum sebagai status per kebutuhan pada Tabel VI.5 sampai Tabel VI.8.

VI.2 Hasil Evaluasi

Hasil evaluasi dilaporkan sebagai uji penerimaan fungsional dan struktural pada lingkungan *node* tunggal sesuai batasan BI-1. Status setiap kebutuhan dinyatakan dalam tiga tingkat, yaitu terverifikasi struktural ketika *control plane* terbentuk dan terkonsiliasi sesuai rancangan, terverifikasi fungsional ketika skenario uji dijalankan dan keluarannya memenuhi kriteria penerimaan, serta terinstrumentasi ketika instrumen ukur telah terpasang dan *serving flow* melayani permintaan sementara profil beban kuantitatif penuh berada pada lingkup pengembangan lanjutan. Pembagian tiga tingkat ini menjaga agar setiap klaim sepadan dengan bukti yang tersedia dan tidak melampaui hasil yang benar-benar diamati. Tabel VI.5 sampai Tabel VI.8 merangkum target, instrumen ukur, dan status setiap kebutuhan menurut tujuannya, sedangkan karakterisasi beban kuantitatif pada *cluster multi-node*, seperti distribusi latensi p99 dan *throughput* puncak, dirinci sebagai arah pengembangan pada Bab VII.

VI.2.1 Pemenuhan Tujuan Platform

Tabel VI.5 Status Evaluasi Kebutuhan Tujuan T-1

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-01	<i>Feature view</i> berversi dan rekonsiliasi otomatis	Feast <i>registry</i> , Argo CD, Gitea	Terverifikasi struktural. Rekonsiliasi Argo CD konvergen dan definisi <i>feature view</i> tanpa <i>drift</i> .
KF-06	Promosi <i>canary</i> dan <i>rollback</i> otomatis	KServe, Argo Rollouts, Prometheus	Terverifikasi struktural. <i>Rollout canary</i> dan <i>rollback</i> otomatis terbentuk.
KF-12	Konvergensi deklaratif tanpa <i>drift</i>	Kustomize, Argo CD, Gitea	Terverifikasi struktural. Hasil <i>argocd diff</i> bersih dan konvergen tanpa <i>drift</i> .
KF-13	SDK Feast, MLflow, dan klien KServe v2 termuat dalam satu <i>environment</i> uv	<i>Notebook</i> uv run, pyproject	Terverifikasi struktural. <i>Notebook</i> <i>unified_sdk_walkthrough</i> memuat ketiga klien dalam satu <i>environment</i> uv lalu menjalankannya sebagai operasi baca independen.

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-14	<i>Job</i> luar kuota <i>Pending</i> , admisi sesuai	Kueue <i>ClusterQueue</i> , HPA, VPA, KE-DA	Terverifikasi struktural. <i>Job</i> di luar kuota berstatus <i>Pending</i> sesuai admisi Kueue.
KNF-03	<i>Replica</i> dan <i>throughput</i> naik mendekati linear	HPA, KEDA, k6	Terinstrumentasi. HPA dan KE-DA aktif pada satu <i>node</i> . Skala mendekati linear belum diuji pada <i>multi-node</i> .
KNF-04	Pemulihan otomatis, RTO dan RPO terjaga	Chaos Mesh, Vele-ro, Sloth	Terverifikasi struktural. Mekanisme pemulihan otomatis Chaos Mesh dan Velero terbentuk.
KNF-08	Penggantian komponen terisolasi	CRD, Helm, Kustomize	Terverifikasi struktural. Penggantian komponen melalui CRD dan <i>overlay</i> terisolasi.
KNF-09	SSO satu sesi tanpa login ulang, dokumentasi tersedia	dex, oauth2-proxy, Gitea	Terverifikasi struktural. Konsol terhubung pada satu sesi identitas dex dan oauth2-proxy.
KNF-10	Kompresi, utilisasi, dan atribusi biaya	OpenCost, ClickHouse	Terinstrumentasi. OpenCost dan kompresi kolumnar ClickHouse terpasang. Rasio dan atribusi biaya belum diukur penuh.
KNF-11	Rekonstruksi penuh dari Git	Argo CD, Kustomize	Terverifikasi struktural. Rekonstruksi penuh pada <i>node</i> k3s baru dari satu sumber Git.
KNF-12	<i>Test coverage</i> dan <i>phase-full</i> konvergen	Tekton CI, Argo CD	Terverifikasi struktural. <i>make phase-full</i> konvergen dan uji CI Tekton berjalan.

Tabel VI.6 Status Evaluasi Kebutuhan Tujuan T-2

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-08	<i>Lineage</i> data ke fitur ke model utuh	DataHub, OpenLineage	Terverifikasi struktural. Terhubung 270 <i>dataset</i> , 18 <i>DataJob</i> , dan 3 <i>DataFlow</i> .
KF-09	<i>Run</i> dapat direproduksi, selisih ulang kecil	MLflow	Terverifikasi struktural. Seed tetap (42), pelacakan MLflow, dan rentang tanggal terparameter memungkinkan <i>run</i> direproduksi dari <i>snapshot</i> .

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-10	Transisi status dan <i>audit trail</i>	MLflow Tracking dan Model Registry	Terverifikasi struktural. Transisi status pada <i>Model Registry</i> tersedia sebagai prosedur dan belum dijalankan otomatis oleh <i>trainer</i> . MLflow Tracking merekam parameter, metrik, dan artefak tiap <i>run</i> sebagai jejak audit.
KNF-05	Kontrak skema, rentang, dan kelengkapan ditegakkan	Great Expectations	Terverifikasi fungsional. <i>Checkpoint</i> Great Expectations menolak pelanggaran skema dan rentang.
KNF-06	Metrik, log, dan <i>trace</i> dirujuk silang	Prometheus, Loki, Tempo, OTEL	Terverifikasi struktural. Metrik, log, dan <i>trace</i> OTEL saling dirujuk melalui konteks <i>trace</i> lintas Prometheus, Loki, dan Tempo.
KNF-07	TLS 1.3, AES-256, dan <i>audit log</i> aktif	Istio mTLS, KES, OpenBao, Trivy	Terverifikasi struktural. Enkripsi mTLS Istio dan enkripsi <i>at rest</i> aktif sesuai konfigurasi.

Tabel VI.7 Status Evaluasi Kebutuhan Tujuan T-3

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-03	<i>Zero leakage</i> pada <i>point-in-time join</i>	Feast PIT, probe <i>leakage</i>	Terverifikasi struktural. Probe <i>timestamp</i> masa depan menolak baris yang mengalami <i>leakage</i> .
KF-05	<i>Pipeline end-to-end</i> , <i>run</i> tercatat di MLflow	Kubeflow Pipelines, MLflow	Terverifikasi struktural. <i>Pipeline</i> Kubeflow merangkai deteksi <i>drift</i> , <i>training</i> dari tabel <i>gold</i> , dan <i>deploy</i> ke KServe. Definisinya terkompilasi dan terdaftar pada KFP dengan pencatatan ke MLflow.
KF-07	<i>Drift</i> memicu <i>retraining</i>	<i>drift-detector</i> , Argo CronWorkflow	Terverifikasi fungsional. PSI 18,107 dan KS 0,815 melampaui ambang sehingga <i>retraining</i> terpicu.

Tabel VI.8 Status Evaluasi Kebutuhan Tujuan T-4

Kebutuhan	Target atau Kriteria	Instrumen Ukur	Status dan Bukti Teramati
KF-02	Konsistensi nilai <i>online</i> dan <i>offline</i>	Feast SDK, materialisasi	Terverifikasi struktural. Nilai <i>online</i> dan <i>offline</i> sama melalui materialisasi Feast.
KF-04	Pencarian vektor HNSW berfungsi, latensi sub-detik	Qdrant, k6	Terinstrumentasi. Latensi p50 4,25 ms dan p95 5,02 ms pada 100 iterasi. <i>Recall</i> belum diuji karena koleksi kosong.
KF-11	Paritas fitur <i>batch</i> dan <i>stream</i>	dbt, Flink	Terverifikasi struktural. Definisi fitur <i>batch</i> dan <i>stream</i> konsisten.
KNF-01	Latensi p99 sub-detik <i>feature serving</i> dan <i>vector search</i>	k6, SLO Sloth	Terinstrumentasi. <i>Feature serving flow</i> dan <i>vector search flow</i> terukur. Nilai p99 pada beban tinggi belum diukur.
KNF-02	<i>Throughput serving flow</i> dan <i>stream</i> tinggi	k6, kafka-producer-perf-test, KEDA	Terinstrumentasi. Instrumen beban k6 dan KEDA terpasang. <i>Throughput</i> puncak belum diukur.

Pada T-1, verifikasi struktural menunjukkan seluruh komponen berhasil dipasang dan direkonsiliasi oleh Argo CD dari satu repositori Gitea, perubahan *replica* dan definisi fitur konvergen tanpa *drift*, dan rekonstruksi pada *node* k3s baru berhasil tanpa intervensi manual selain *bootstrap* awal. Dengan *training pipeline* (KF-05) dan *deployment* model (KF-06) terbentuk secara struktural serta *drift detection flow* pemicu *retraining* (KF-07) terverifikasi fungsional, komponen yang dipersyaratkan untuk MLOps *level 2* pada Subbab II.1.2 terpenuhi pada lingkungan implementasi. Pada T-2, *event lineage* dari *emitter* OpenLineage Airflow dan Spark serta konektor *ingestion* DataHub untuk Feast, MLflow, ClickHouse, dan Kafka muncul pada satu graf metadata dengan kosakata seragam, registri MLflow menyediakan *flow* transisi status model sebagai prosedur, dan kontrol keamanan mTLS serta enkripsi *at rest* aktif sesuai konfigurasi. Praktik yang sama menempatkan sisi data pada tahap DataOps dalam model evolusi Subbab II.1.2, karena CI/CD, orkestrasi, pengujian kualitas, dan pemantauan terverifikasi berlaku pada *pipeline* data. Pada T-3, *control loop retraining* terpicu otomatis ketika injeksi *drift* terkendali diterapkan pada satu fitur, sehingga rantai deteksi hingga *trigger retraining* terbukti berfungsi pada *control plane*. Pada T-4, *serving flow* untuk *online feature*, *offline feature*, dan *vector feature* berhasil dibentuk dan melayani permintaan, sementara karakterisasi latensi p99 dan *throughput* pada beban tinggi dirinci sebagai arah pengembangan pada

cluster multi-node di Bab VII.

Beberapa skenario pada kasus verifikasi menghasilkan keluaran kuantitatif yang dapat dijalankan ulang melalui katalog perintah pada Lampiran B dan melengkapi status ringkas pada keempat tabel di atas. Skenario yang dilaporkan secara rinci dipilih karena menghasilkan angka yang bermakna pada lingkungan *node* tunggal, sedangkan skenario struktural cukup dilaporkan sebagai status terpenuhi. Angka yang dihasilkan dibaca dalam batasan BP-3 sehingga tidak ditafsirkan sebagai karakterisasi beban penuh. Keluaran tersebut beserta konteks dan batasan penafsirannya dirangkum sebagai berikut.

1. ***Trigger retraining oleh deteksi drift (KF-07)***

Injeksi pergeseran terkendali sebesar dua sigma pada fitur `return_24h` menghasilkan *Population Stability Index* sebesar 18,107 yang jauh melampaui ambang 0,2 dan statistik Kolmogorov-Smirnov sebesar 0,815 di atas ambang 0,15, sehingga detektor menandai *drift* dan memicu satu eksekusi *CronWorkflow* `retrain-on-drift`. Angka ini berasal dari injeksi terkendali pada aliran tervalidasi melalui `experiments/drift/inject_drift.py --sigma 2.0`, sehingga membuktikan terpicunya rantai *retraining* dan bukan ketepatan deteksi terhadap pergeseran distribusi alami jangka panjang.

2. ***Landing data nyata pada medallion layer***

Pemeriksaan *landing* melaporkan sekitar 307.556 baris pada `bronze.crypto_ohlcv` dan `silver.stg_ohlcv` serta sekitar 307.522 baris pada `gold.fct_ohlcv_features` dan `gold.fct_training_data`, mencakup dua pasangan instrumen pada rentang 1 Maret sampai 16 Juni 2026 dengan resolusi satu menit. Data ini menjadi dasar skenario yang membaca *gold layer* seperti penyusunan fitur historis (KF-03) dan otomatisasi *training* (KF-05), dijalankan melalui `experiments/etl/data-landed-check.sh` pada *batch pipeline* REST yang masih terus bertambah. Pemeriksaan ini menilai *landing batch* dan bukan paritas fitur *batch* dan *stream* (KF-11).

3. ***Keterhubungan lineage (KF-08)***

Penelusuran graf metadata DataHub menemukan 270 *dataset*, 18 *DataJob*, dan 3 *DataFlow* yang saling terhubung dari *topic* sumber sampai keluaran prediksi, dijalankan melalui `experiments/lineage/lineage-walk.sh` `discover`. Cakupan graf ditentukan oleh *namespace* `OpenLineage` yang dipakai *emitter*, sehingga angka ini mengukur keterhubungan *lineage* yang terkirim dan ter Katalog, bukan kelengkapan seluruh aset lintas *namespace*.

4. *Serving* pencarian vektor (KF-04)

Beban pencarian vektor pada Qdrant mencatat latensi p50 sebesar 4,25 ms dan p95 sebesar 5,02 ms pada 100 iterasi, dijalankan melalui `k6 run experiments/load/vector-search-latency.js`. Pengukuran ini menegaskan *vector search flow* terpasang dan melayani permintaan pada orde mili-detik, bukan kualitas *recall* karena koleksi uji masih kosong, sedangkan nilai p99 sebesar 157 ms merupakan artefak fase *ramp-down* dan bukan latensi *steady-state*.

VI.2.2 Perbandingan Biaya Infrastruktur dan Tenaga Kerja

Analisis pada Subbab III.1.2 menempatkan biaya berlangganan layanan terkelola sebagai salah satu tekanan utama yang melatarbelakangi platform ini, sehingga hasil evaluasi dilengkapi perbandingan biaya tiga opsi penyediaan platform pada kapasitas komputasi yang setara, lengkap dengan biaya tenaga kerja pengelolanya. Karena batasan BI-1 tidak mengikat spesifikasi perangkat keras tertentu, perbandingan memakai konfigurasi acuan 16 vCPU, memori 64 GB, dan penyimpanan sekitar 400 GB yang mencukupi seluruh komponen platform pada satu *node*. Opsi A menaruh seluruh beban pada layanan terkelola Google Cloud, mencakup *cluster* GKE beserta pengganti komponen *stateful* berupa Cloud SQL, Memorystore, Managed Service for Apache Kafka, dan Cloud Storage. Opsi B membangun setiap *layer* dari awal tanpa komponen *open source* siap pakai di atas VPS dengan Kubernetes swakelola, sedangkan Opsi C menyusun komponen *open source* di atas VPS dengan Kubernetes swakelola seperti pada implementasi penelitian ini. Sumber harga dan asumsi penetapannya dijabarkan lebih dahulu pada paragraf berikut, sedangkan Tabel VI.9 sampai Tabel VI.11 sesudahnya merinci biaya infrastruktur, tenaga kerja, dan total tiap opsi.

Seluruh harga infrastruktur pada ketiga tabel merupakan *list price* publik per 16 Juni 2026 yang diverifikasi melalui arsip halaman harga resmi tiap penyedia. Baris Google Cloud memakai *region* us-central1 dengan konversi 730 jam per bulan, seluruhnya tanpa diskon komitmen, trafik keluar, dan biaya dukungan. Harga Vultr dan *block storage* DigitalOcean memakai *list price* Juli 2026 karena arsip halamannya tidak memuat angka harga. Harga Contabo tercantum termasuk pajak pada halaman resminya, sedangkan harga penyedia lain belum memuat pajak. Biaya bulanan OVHcloud dihitung dari tarif USD 0,4829 per jam. Biaya DigitalOcean sudah mencakup *block storage* 200 GB agar kapasitas penyimpanan setara. Biaya Cloud SQL dan Managed Service for Apache Kafka mencakup komputasi saja. Dengan kurs

referensi ECB 1,1594 USD per EUR pada 16 Juni 2026 (European Central Bank 2026), harga Contabo setara sekitar USD 43 dan Hetzner sekitar USD 320.

Tabel VI.9 sampai Tabel VI.11 memperlihatkan bahwa biaya infrastruktur ketiga opsi berbeda tajam. Opsi A membebankan biaya infrastruktur terbesar, yaitu sekitar USD 1.004 per bulan, karena tiap komponen terkelola ditagih terpisah di atas biaya *cluster* dan *node* komputasi. Opsi B dan Opsi C sama-sama menyewa satu VPS sehingga infrastrukturnya berkisar USD 43 sampai USD 524 per bulan dengan acuan median USD 416 pada penyedia *dedicated*. Perbedaan pokok antara Opsi B dan Opsi C tidak terletak pada infrastruktur yang memang identik, melainkan pada tenaga kerja yang dibahas pada paragraf berikut. Angka infrastruktur bersifat indikatif pada tingkat orde besaran karena *list price* dapat berubah, seperti penyesuaian harga Hetzner yang berlaku sejak 15 Juni 2026 (Hetzner Online GmbH 2026), perlakuan pajak antar penyedia berbeda, dan kebutuhan produksi nyata menambah biaya penyimpanan, trafik, serta ketersediaan tinggi pada ketiga opsi.

Tabel VI.9 Biaya Opsi A: Layanan Terkelola Penuh pada GCP

Komponen	Konfigurasi	Biaya per Bulan	Sumber
Pengelolaan <i>cluster</i> GKE	Satu <i>cluster Standard</i>	USD 73,00	(Google Cloud 2026d)
Node Compute Engine	e2-standard-16, 16 vCPU, 64 GB	USD 391,35	(Google Cloud 2026c)
<i>Persistent disk</i> pd-balanced	400 GB	USD 40,00	(Google Cloud 2026g)
Cloud SQL for PostgreSQL	4 vCPU, 16 GB, tanpa <i>high availability</i>	USD 202,36	(Google Cloud 2026a)
Memorystore for Redis	<i>Basic tier</i> , 5 GB	USD 98,55	(Google Cloud 2026f)
Managed Service for Apache Kafka	Minimum 3 vCPU pada 3 <i>broker</i>	USD 197,10	(Google Cloud 2026e)
Cloud Storage <i>Standard</i>	100 GB	USD 2,00	(Google Cloud 2026b)
Infrastruktur per bulan		USD 1.004,36	
Biaya tenaga 12 bulan, 0,5 lalu 0,1 FTE		USD 1.354,48	
Total tahun pertama		USD 13.406,80	
Total tiga tahun		USD 39.543,16	

Tabel VI.10 Biaya Opsi B: Kustom dari Awal pada VPS dan Kubernetes

Komponen	Konfigurasi	Biaya per Bulan	Sumber
Contabo Cloud VPS 50	16 vCPU <i>shared</i> , 64 GB, NVMe 300 GB	EUR 37,00	(Contabo GmbH 2026)
Hetzner CCX43	16 vCPU <i>dedicated</i> AMD, 64 GB, SSD 360 GB	EUR 275,99	(Hetzner Online GmbH 2026)
OVHcloud B3-64	16 vCore <i>dedicated</i> , 64 GB, NVMe 400 GB	USD 352,52	(OVHcloud 2026)
Akamai Linode 64 GB	16 vCPU <i>shared</i> , 64 GB, SSD 1.280 GB	USD 384,00	(Akamai Technologies 2026)
Vultr Optimized Cloud Compute	16 vCPU <i>dedicated</i> , 64 GB, NVMe 320 GB	USD 480,00	(Vultr 2026)
DigitalOcean General Purpose	16 vCPU <i>dedicated</i> , 64 GB, SSD 200 GB dan <i>volume</i> 200 GB	USD 524,00	(DigitalOcean 2026)
Kisaran infrastruktur, satu penyedia dipilih		USD 43 sampai 524	
Infrastruktur acuan, median penyedia <i>dedicated</i>		USD 416,26	
Biaya tenaga 12 bulan, 1,0 FTE tetap		USD 10.158,60	
Total tahun pertama		USD 15.153,72	
Total tiga tahun		USD 45.461,16	

Tabel VI.11 Biaya Opsi C: Open Source pada VPS dan Kubernetes

Komponen	Konfigurasi	Biaya per Bulan	Sumber
Infrastruktur VPS	Median penyedia <i>dedicated</i> , sama dengan Opsi B pada Tabel VI.10	USD 416,26	
Biaya tenaga 12 bulan, 1,0 lalu 0,25 FTE		USD 3.174,56	
Total tahun pertama		USD 8.169,68	
Total tiga tahun		USD 23.239,22	

Baris tenaga kerja pada ketiga tabel memakai gaji acuan IDR 15.000.000 per bulan dari batas atas kisaran *Data Engineer* pada panduan gaji PERSOLKELLY Indonesia (PERSOLKELLY Indonesia 2023), setara USD 846,55 pada kurs referensi JISDOR IDR 17.719 per USD tanggal 15 Juni 2026 sebagai hari penerbitan terakhir sebelum 16 Juni yang merupakan libur nasional (Bank Indonesia 2026). Profil alokasinya merupakan asumsi ilustratif untuk memperlihatkan struktur biaya dan bukan hasil

pengukuran, dengan satu FTE berarti alokasi penuh satu *engineer* selama satu bulan. Opsi C memakai alokasi 1,0 FTE pada bulan pertama lalu menurun ke 0,25 FTE karena rekonsiliasi GitOps, pemantauan terpadu, dan *retraining* otomatis mengambil alih pekerjaan operasional harian (Limoncelli 2018), sedangkan Opsi A memakai alokasi paling rendah karena tanggung jawab operasional komponen *stateful* berpindah ke penyedia (Shankar dkk. 2022). Opsi B mempertahankan alokasi penuh 1,0 FTE sepanjang tiga tahun karena setiap *layer* dibangun dan dipelihara sendiri tanpa komponen siap pakai, sejalan dengan biaya pengembangan dan pemeliharaan besar yang melekat pada alternatif kustom pada Subbab III.3.2.

Total biaya tiga tahun menegaskan arah *trade-off* tersebut. Opsi C menjadi yang termurah pada sekitar USD 23.239 karena infrastruktur murah berpadu dengan tenaga yang menyusut sesudah pembangunan awal. Opsi A lebih mahal pada sekitar USD 39.543 karena langganan terkelola berjalan terus setiap bulan, sedangkan Opsi B menjadi yang termahal pada sekitar USD 45.461 karena tenaga kerja kustom penuh tidak pernah surut. Karena angka alokasi tenaga merupakan asumsi, hasil ini dibaca sebagai arah struktur biaya, yaitu rancangan *open source* menahan biaya infrastruktur sekaligus memangkas tenaga kerja lewat komponen siap pakai, bukan sebagai pengukuran empiris.

VI.3 Pembahasan

Pembahasan mengaitkan setiap hasil dengan tujuan yang dijawab dan dengan rumusan masalah yang menjadi titik awal. Verifikasi struktural pada T-1 menjawab RM-1 dengan menunjukkan bahwa fragmentasi *tech stack* dapat diganti oleh satu *control plane* GitOps yang dapat direkonstruksi. Verifikasi pada T-2 menjawab RM-2 dengan menunjukkan tata kelola berjalan sebagai layanan bersama, bukan proses yang ditambahkan belakangan, sehingga *lineage* dan kontrak kualitas tertanam pada *pipeline*. Verifikasi pada T-3 menjawab RM-3 dengan menunjukkan bahwa deteksi *drift* memicu *retraining* secara otomatis pada *control plane*, sehingga jawaban atas RM-3 terpenuhi pada tingkat fungsional dan struktural. Verifikasi pada T-4 menjawab RM-4 dengan menunjukkan bahwa layanan fitur *dual-store* terbentuk dan melayani permintaan dengan kontrak fitur yang konsisten, sehingga jawaban atas RM-4 terpenuhi pada tingkat struktural dengan *serving flow* yang telah terinstrumentasi, sedangkan karakterisasi beban kuantitatifnya menjadi arah pengembangan.

Cakupan evaluasi telah memenuhi syarat ketertelusuran, karena seluruh empat belas kebutuhan fungsional dan dua belas kebutuhan nonfungsional memiliki sekurang-

kurangnya satu skenario uji pada Tabel VI.1 sampai Tabel VI.4 dan satu baris status pada Tabel VI.5 sampai Tabel VI.8. Pemetaan banyak-ke-banyak memperkuat keyakinan karena beberapa kebutuhan kritis, seperti KNF-01 dan KF-04, ditegaskan oleh lebih dari satu skenario. Dengan demikian, kegagalan pada satu skenario tidak langsung membatalkan klaim pemenuhan kebutuhan terkait, tetapi menyisakan cara verifikasi lain yang masih dapat ditelusuri. Susunan ini sekaligus menyiapkan struktur kesimpulan pada Bab VII yang menjawab tepat satu tujuan untuk setiap butir. Meskipun demikian, evaluasi ini memiliki tiga keterbatasan yang perlu dicatat secara terbuka.

1. Lingkungan pengujian *node* tunggal

Lingkungan pengujian adalah k3s *node* tunggal sesuai batasan BI-1, sehingga klaim skalabilitas horizontal diukur melalui *multi-replica* dan *autoscaling* pada satu *node*, bukan pada *cluster multi-node*.

2. Verifikasi *drift* melalui injeksi terkendali

Deteksi *drift* diverifikasi melalui injeksi *drift* terkendali pada data nyata sehingga ketepatan terhadap pergeseran distribusi alami jangka panjang masih perlu diamati lebih lama, sedangkan karakterisasi beban penuh seperti latensi p99 dan *throughput* puncak menjadi arah pengembangan pada lingkungan *multi-node*.


3. Verifikasi kesetaraan nilai fitur *dual-store*

Kesetaraan nilai fitur antara penyimpanan *online* Valkey dan *offline* ClickHouse pada KF-02 bersifat *structural-by-construction* karena proses materialisasi Feast menyalin nilai dari penyimpanan *offline* ke penyimpanan *online* sehingga keduanya memuat nilai yang sama. Namun, uji perbandingan nilai eksplisit per entitas melalui SDK Feast masih berupa prosedur manual yang belum terotomasi pada *evaluation flow*, sehingga KF-02 dilaporkan pada tingkat struktural dan penegasan fungsionalnya menjadi tindak lanjut.

Saran tindak lanjut pada Bab VII berpijak pada ketiga keterbatasan tersebut. Keterbatasan pertama dan kedua mengarah pada pengujian beban serta pengamatan *drift* berdurasi panjang pada lingkungan *multi-node*. Keterbatasan ketiga mengarah pada otomasi uji kesetaraan nilai fitur per entitas pada *evaluation flow*. Dengan pemetaan ini, setiap keterbatasan memiliki tindak lanjut yang jelas dan tidak ada klaim yang dibiarkan tanpa batas penafsiran.

Sisi ekonomi ditutup dengan proyeksi biaya kumulatif tiga tahun pada Gambar VI.1, dengan alokasi tenaga dan *list price* dianggap tetap sesudah tahun pertama. Opsi C menaiki kurva paling landai karena infrastruktur VPS yang murah berpadu dengan

tenaga kerja yang menyusut sesudah pembangunan awal, Opsi A menaik lebih curam karena langganan terkelola yang tetap besar setiap bulan, dan Opsi B menaik paling curam karena tenaga kerja kustom penuh yang tidak pernah berkurang. Pada gaji acuan, biaya bulanan Opsi C bergerak dari sekitar USD 1.263 pada bulan pertama menjadi sekitar USD 628 pada bulan berikutnya, Opsi A dari sekitar USD 1.428 menjadi sekitar USD 1.089, sedangkan Opsi B tetap sekitar USD 1.263 setiap bulan. Akibatnya, selisih kumulatif antara Opsi C dan Opsi A melebar menjadi sekitar USD 16.304 pada akhir tahun ketiga, sementara selisih terhadap Opsi B mencapai sekitar USD 22.222, sehingga rancangan *open source* makin unggul secara biaya dalam jangka panjang selama asumsi alokasi tenaganya bertahan.



Gambar VI.1 Proyeksi Biaya Kumulatif per Opsi Penyediaan

BAB VII

PENUTUP

Bab ini merangkum capaian penelitian dan menutup rantai keterhubungan yang dijaga sejak rumusan masalah. Setiap butir kesimpulan menjawab tepat satu tujuan T-1 sampai T-4 dengan urutan yang sama, sehingga setiap klaim dapat ditelusuri kembali ke tujuan, kebutuhan, dan skenario uji yang sesuai. Kesimpulan disusun pada tingkat capaian yang telah terverifikasi secara fungsional dan struktural pada lingkungan *node* tunggal, sedangkan karakterisasi beban kuantitatif pada *cluster multi-node* ditempatkan sebagai arah pengembangan sesuai lingkup batasan BP-3 pada Subbab I.4. Saran kemudian mengarahkan langkah lanjutan untuk memperluas karakterisasi beban dan untuk mengembangkan platform pada tahap berikutnya.

VII.1 Kesimpulan

Penelitian ini menghasilkan satu implementasi arsitektur DataOps dan MLOps terintegrasi pada Kubernetes yang dievaluasi melalui *use case* pasar aset kripto sebagai kasus verifikasi. Verifikasi dilakukan pada lingkungan *k3s node* tunggal dengan penerimaan fungsional dan struktural sesuai batasan BP-3. Setiap butir berikut menjawab tepat satu tujuan dan merujuk bukti evaluasinya pada Bab VI, dengan rincian status tiap kebutuhan dirangkum pada Tabel VI.5 sampai Tabel VI.8. Berdasarkan hasil evaluasi tersebut, empat tujuan platform dapat disimpulkan sebagai berikut.

1. **Arsitektur terintegrasi dan GitOps (T-1)**

Seluruh komponen platform terbukti dapat dipasang dan direkonsiliasi dari satu sumber Git oleh Argo CD, dengan perubahan definisi konvergen tanpa *drift* dan rekonstruksi penuh pada *node k3s* baru tanpa intervensi manual selain *bootstrap* awal. Capaian ini menjawab RM-1 dengan menggantikan fragmentasi *tech stack* dengan satu *control plane* deklaratif yang dapat diaudit.

2. **Tata kelola data otomatis (T-2)**

Katalog metadata, *lineage*, dan kontrol kualitas terbukti berjalan sebagai layanan bersama sepanjang *pipeline* data, fitur, dan model, dengan *event lineage* OpenLineage dan kontrak Great Expectations tertanam pada *production pipeline*. Capaian ini menjawab RM-2 dengan menjadikan tata kelola sebagai bagian yang melekat pada *pipeline*, bukan proses yang ditambahkan belakangan.

3. **Deteksi *drift* dan *point-in-time correctness* (T-3)**

Control loop retraining terbukti terpicu otomatis ketika injeksi *drift* terkendali diterapkan pada satu fitur. Penyusunan fitur historis juga terbukti menolak *temporal leakage* pada *training flow*. Capaian ini menjawab RM-3, sedangkan pengamatan ketepatan deteksi pada pergeseran distribusi alami jangka panjang menjadi arah pengembangan lanjutan.

4. Layanan fitur *dual-store* (T-4)

Serving flow online dan *offline* untuk *tabular feature* terbukti terbentuk dengan kontrak fitur yang konsisten antara fase *training* dan fase *inference*, sedangkan *vector feature flow* terbentuk pada indeks terpisah dengan ruang *embedding* yang sama pada kedua fase tersebut. Capaian ini menjawab RM-4 pada tingkat struktural dengan *serving flow* yang telah terinstrumentasi, sedangkan karakterisasi latensi p99 dan *throughput* pada beban tinggi di *cluster multi-node* menjadi arah pengembangan lanjutan.

Keempat kesimpulan tersebut menegaskan bahwa kontribusi utama penelitian berupa implementasi arsitektur terintegrasi telah tercapai dan tertelusur secara penuh dari rumusan masalah hingga skenario uji. Pemenuhan yang dilaporkan bersifat fungsional dan struktural pada lingkungan *node* tunggal, sehingga setiap klaim dibatasi pada bukti yang telah diamati. Nilai utama implementasi ini terletak pada penyatuan upaya integrasi yang sebelumnya berulang ke dalam satu deskripsi deklaratif, sehingga rekonstruksi *control plane* tidak lagi bergantung pada pengetahuan tak terdokumentasi satu pengembang. Platform terbukti dapat direkonstruksi, dikelola secara deklaratif, dan menjalankan *lifecycle* data serta model secara terotomasi, sedangkan penilaian kinerja menyeluruh menjadi pekerjaan lanjutan yang terdefinisi jelas. Di luar keempat tujuan, perbandingan biaya pada Subbab VI.2.2 memperkuat motivasi pada Subbab III.1.2, karena opsi *open source* menunjukkan biaya kumulatif tiga tahun yang lebih rendah daripada layanan terkelola.

VII.2 Saran

Berdasarkan capaian dan keterbatasan yang telah diuraikan, penelitian ini mengajukan dua arah tindak lanjut. Arah pertama menuntaskan karakterisasi kuantitatif yang pada penelitian ini dibatasi oleh lingkungan *node* tunggal. Arah kedua memperluas kapabilitas platform tanpa mengubah sifat *domain-agnostic control plane*-nya. Rincian keduanya diuraikan sebagai berikut.

1. Perluasan karakterisasi beban kuantitatif

Pengujian beban penuh perlu dijalankan pada lingkungan *multi-node* untuk memverifikasi skalabilitas horizontal, latensi p99, dan *throughput* puncak yang pada penelitian ini baru terinstrumentasi di lingkungan *node* tunggal

dengan *serving flow* yang telah melayani permintaan. Pengamatan *drift* juga perlu diperpanjang durasinya pada aliran data nyata agar ketepatan deteksi terhadap pergeseran distribusi alami jangka panjang dapat dinilai untuk melengkapi verifikasi melalui injeksi *drift* terkendali. Selain itu, kesetaraan nilai fitur antara penyimpanan *online* dan *offline* yang pada penelitian ini terpenuhi secara *structural-by-construction* perlu ditegaskan lebih lanjut melalui uji pembandingan nilai per entitas yang terotomasi pada *evaluation flow*.

2. Pengembangan platform pada tahap berikutnya

Beberapa arah yang teridentifikasi mencakup perluasan dukungan *multi-tenancy* pada *layer* tata kelola, otomasi kebijakan kuota pada Kueue untuk beban *training* yang lebih besar, integrasi metrik biaya OpenCost dengan kebijakan *retraining*, serta adopsi profil keamanan Kyverno yang lebih ketat setelah profil dasar matang. Arah tersebut melanjutkan sifat *domain-agnostic* platform sehingga *use case* lain dapat diadopsi tanpa mengubah *control plane*.

Melalui kedua arah tersebut, platform dapat berkembang dari implementasi yang terverifikasi struktural menjadi fondasi yang teruji pada beban produksi nyata. Prioritas terdekat adalah karakterisasi beban pada *cluster multi-node* karena batasan itulah yang paling membatasi klaim kinerja saat ini. Perluasan kapabilitas dapat menyusul tanpa perombakan karena penggantian komponen telah diakomodasi oleh batasan implementasi BI-2. Dengan demikian, hasil penelitian ini menjadi titik tolak yang terdokumentasi bagi pengembangan berikutnya.

DAFTAR PUSTAKA

- Adusumilli, Lakshmi Vara Prasad. 2025. “Serverless Kubernetes: The Evolution of Container Orchestration”. *European Journal of Computer Science and Information Technology* 13 (30): 20–36. <https://doi.org/10.37745/ejcsit.2013/vol13n302036>. <https://doi.org/10.37745/ejcsit.2013/vol13n302036>.
- Ahmad, Tazeem, Mohd Adnan, Saima Rafi, Muhammad Azeem Akbar, dan Ayesha Anwar. 2024. “MLOps-Enabled Security Strategies for Next-Generation Operational Technologies”. Dalam *Proceedings of the 28th International Conference on Evaluation and Assessment in Software Engineering (EASE 2024)*, 662–670. <https://doi.org/10.1145/3661167.3661283>. <https://doi.org/10.1145/3661167.3661283>.
- Aiven Karapace Authors. 2025. *Karapace: Schema Registry and REST Proxy for Apache Kafka*. Diakses 25 Mei 2026. <https://www.karapace.io/>.
- Akamai Technologies. 2026. *Akamai Cloud Computing Pricing*. Diakses 16 Juni 2026. <https://www.akamai.com/cloud/pricing/north-america>.
- Altinity. 2025. *Altinity Kubernetes Operator for ClickHouse*. Diakses 25 Mei 2026. <https://github.com/Altinity/clickhouse-operator>.
- Amazon Web Services. 2024. *What is an Event-Driven Architecture?* Diakses 9 April 2026. <https://aws.amazon.com/event-driven-architecture/>.
- Amershi, Saleema, Andrew Begel, Christian Bird, Robert DeLine, Harald Gall, Ece Kamar, Nachiappan Nagappan, Besmira Nushi, dan Thomas Zimmermann. 2019. “Software Engineering for Machine Learning: A Case Study”. Dalam *2019 IEEE/ACM 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 291–300. IEEE. <https://doi.org/10.1109/ICSE-SEIP.2019.00042>. <https://doi.org/10.1109/ICSE-SEIP.2019.00042>.
- Amou Najafabadi, Faezeh, Justus Bogner, Ilias Gerostathopoulos, dan Patricia Lago. 2024. “An Analysis of MLOps Architectures: A Systematic Mapping Study”. Dalam *Software Architecture: 18th European Conference, ECSA 2024, Luxembourg City, Luxembourg, 3–6 September 2024, Proceedings*, 14889:69–85. Lecture Notes in Computer Science. Springer. https://doi.org/10.1007/978-3-031-70797-1_5. https://doi.org/10.1007/978-3-031-70797-1_5.

- Anaconda, Inc. 2020. *2020 State of Data Science: Moving From Hype Toward Maturity*. Diakses 15 April 2026. <https://know.anaconda.com/rs/387-XNW-688/images/Anaconda-SODS-Report-2020-Final.pdf>.
- Apache APISIX Authors. 2025. *Apache APISIX: Cloud-Native API Gateway*. Diakses 25 Mei 2026. <https://apisix.apache.org/docs/>.
- Apache Flink Authors. 2025. *Flink Kubernetes Operator*. Diakses 25 Mei 2026. <https://nightlies.apache.org/flink/flink-kubernetes-operator-docs-stable/>.
- Apache Software Foundation. 2024a. *Apache Airflow Documentation*. Diakses 20 April 2026. <https://airflow.apache.org/docs/>.
- . 2024b. *Apache Flink Documentation*. Diakses 6 April 2026. <https://flink.apache.org/documentation/>.
- . 2024c. *Apache Kafka Documentation*. Diakses 9 April 2026. <https://kafka.apache.org/documentation/>.
- . 2024d. *Apache Spark Documentation*. Diakses 18 Maret 2026. <https://spark.apache.org/docs/latest/>.
- . 2025. *Apache Pulsar Documentation*. Diakses 12 Juni 2026. <https://pulsar.apache.org/docs/>.
- Apache Spark Authors. 2025. *Apache Spark on Kubernetes Operator*. Diakses 25 Mei 2026. <https://github.com/kubeflow/spark-operator>.
- Apache Superset Authors. 2025. *Apache Superset Documentation*. Diakses 25 Mei 2026. <https://superset.apache.org/docs/intro>.
- Aqua Security. 2025. *Trivy Operator: Kubernetes Native Security Scanner*. Diakses 25 Mei 2026. <https://aquasecurity.github.io/trivy-operator/>.
- Argo Project. 2024. *Argo CD - Declarative GitOps CD for Kubernetes*. Diakses 24 Maret 2026. <https://argo-cd.readthedocs.io/>.
- . 2025. *Argo Workflows: Container-Native Workflow Engine for Kubernetes*. Diakses 25 Mei 2026. <https://argo-workflows.readthedocs.io/>.
- Argo Rollouts Authors. 2025. *Argo Rollouts: Progressive Delivery for Kubernetes*. Diakses 25 Mei 2026. <https://argoproj.github.io/argo-rollouts/>.

- AuthZed. 2025. *SpiceDB: Fine-Grained Authorization Database*. Diakses 25 Mei 2026. <https://authzed.com/docs/spicedb/>.
- Bank Indonesia. 2026. *Kurs Referensi Jakarta Interbank Spot Dollar Rate (JISDOR)*. Diakses 16 Juni 2026. <https://www.bi.go.id/id/statistik/informasi-kurs/jisdor/default.aspx>.
- Bayram, Firas, Bestoun S. Ahmed, dan Andreas Kassler. 2022. “From Concept Drift to Model Degradation: An Overview on Performance-Aware Drift Detectors”. *Knowledge-Based Systems* 245:108632. <https://doi.org/10.1016/j.knosys.2022.108632>. <https://doi.org/10.1016/j.knosys.2022.108632>.
- Bernardo, B. M. V., H. S. Mamede, J. M. P. Barroso, dan V. M. P. D. dos Santos. 2024. “Data Governance and Quality Management: Innovation and Breakthroughs across Different Fields”. *Journal of Innovation and Knowledge* 9 (4): 100598. <https://doi.org/10.1016/j.jik.2024.100598>. <https://doi.org/10.1016/j.jik.2024.100598>.
- Bondi, Andre B. 2000. “Characteristics of Scalability and Their Impact on Performance”. Dalam *Proceedings of the 2nd International Workshop on Software and Performance*, 195–203. ACM. <https://doi.org/10.1145/350391.350432>.
- Breck, Eric, Shanqing Cai, Eric Nielsen, Michael Salib, dan D. Sculley. 2017. “The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction”. Dalam *2017 IEEE International Conference on Big Data (Big Data)*, 1123–1132. IEEE. <https://doi.org/10.1109/BigData.2017.8258038>. <https://doi.org/10.1109/BigData.2017.8258038>.
- Bruch, Sebastian, Siyu Gai, dan Amir Ingber. 2023. “An Analysis of Fusion Functions for Hybrid Retrieval”. *ACM Transactions on Information Systems* 42 (1): 1–35. <https://doi.org/10.1145/3596512>. <https://doi.org/10.1145/3596512>.
- Burgueño-Romero, Antonio M., Antonio Benítez-Hidalgo, Cristóbal Barba-González, dan José Francisco Aldana-Montes. 2025. “Toward an Open Source MLOps Architecture”. *IEEE Software* 42 (1): 59–64. <https://doi.org/10.1109/MS.2024.3421675>. <https://doi.org/10.1109/MS.2024.3421675>.
- Campese, Stefano, Ivano Lauriola, dan Alessandro Moschitti. 2024. “Improving Document Retrieval Coherence for Semantically Equivalent Queries”. *arXiv preprint arXiv:2404.12338*.

- Carbone, Paris, Stephan Ewen, Kostas Tzoumas, Volker Markl, dan Fabian Hueske. 2015. “Apache Flink: Stream and Batch Processing in a Single Engine”. *Bulletin of the IEEE Computer Society Technical Committee on Data Engineering* 36 (4): 28–38. <https://asterios.katsifodimos.com/assets/publications/flink-deb.pdf>.
- Ceph Authors. 2025. *Ceph Object Gateway Documentation*. Diakses 12 Juni 2026. <https://docs.ceph.com/en/latest/radosgw/>.
- cert-manager Contributors. 2025. *cert-manager: Automated TLS Certificate Management for Kubernetes*. Diakses 25 Mei 2026. <https://cert-manager.io/docs/>.
- Céspedes Sisniega, Jaime, Vicente Rodríguez, Germán Moltó, dan Álvaro López García. 2024. “Efficient and Scalable Covariate Drift Detection in Machine Learning Systems with Serverless Computing”. *Future Generation Computer Systems* 161:174–188. <https://doi.org/10.1016/j.future.2024.07.010>. <https://doi.org/10.1016/j.future.2024.07.010>.
- Chaos Mesh Authors. 2025. *Chaos Mesh: A Cloud-Native Chaos Engineering Platform*. Diakses 25 Mei 2026. <https://chaos-mesh.org/docs/>.
- Chien, Melody. 2022. *How to Improve Your Data Quality*. Diakses 30 Maret 2026. Gartner. <https://www.gartner.com/smarterwithgartner/how-to-improve-your-data-quality>.
- ClickHouse Inc. 2024. *ClickHouse Documentation*. Diakses 20 April 2026. <https://clickhouse.com/docs/>.
- Cloud Native Computing Foundation. 2024a. *Kubernetes Documentation*. Diakses 11 Maret 2026. <https://kubernetes.io/docs/>.
- . 2024b. *Observability Whitepaper*. Diakses 16 Maret 2026. <https://github.com/cncf/tag-observability/blob/main/whitepaper.md>.
- . 2026. *Certified Kubernetes Software Conformance*. Diakses 12 Juli 2026. <https://www.cncf.io/training/certification/software-conformance/>.
- CloudNativePG Contributors. 2025. *CloudNativePG: Kubernetes Operator for PostgreSQL*. Diakses 25 Mei 2026. <https://cloudnative-pg.io/documentation/>.
- Contabo GmbH. 2026. *Cloud VPS Pricing*. Diakses 16 Juni 2026. <https://contabo.com/en/pricing/>.

- DataHub Project. 2024. *DataHub Documentation*. Diakses 20 April 2026. <https://datahubproject.io/docs/>.
- DataKitchen. 2020. *Launch Your DataOps Journey with the DataOps Maturity Model*. Diakses 10 Juli 2026. DataKitchen. <https://tdwi.org/whitepapers/2020/11/diq-all-datakitchen-dataops-maturity-model.aspx>.
- dbt Labs. 2025. *dbt: Data Build Tool Documentation*. Diakses 25 Mei 2026. <https://docs.getdbt.com/>.
- Debezium Community. 2025. *Debezium Documentation*. Diakses 12 Juni 2026. <https://debezium.io/documentation/>.
- Deuxfleurs Association. 2025. *Garage Documentation*. Diakses 12 Juni 2026. <https://garagehq.deuxfleurs.fr/documentation/>.
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, dan Kristina Toutanova. 2019. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". Dalam *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>. <https://doi.org/10.18653/v1/N19-1423>.
- Dex Authors. 2025. *Dex: A Federated OpenID Connect Provider*. Diakses 25 Mei 2026. <https://dexidp.io/docs/>.
- DigitalOcean. 2026. *Droplets Pricing*. Diakses 16 Juni 2026. <https://www.digitalocean.com/pricing/droplets>.
- European Central Bank. 2026. *Euro Foreign Exchange Reference Rates: US Dollar*. Diakses 16 Juni 2026. https://www.ecb.europa.eu/stats/policy_and_exchange_rates/euro_reference_exchange_rates/html/eurofxref-graph-usd.en.html.
- Evidently AI. 2025. *Evidently: Open-Source ML Observability Platform*. Diakses 25 Mei 2026. <https://docs.evidentlyai.com/>.
- External Secrets Authors. 2025. *External Secrets Operator Documentation*. Diakses 25 Mei 2026. <https://external-secrets.io/latest/>.
- Falco Authors. 2025. *Falco: Cloud-Native Runtime Security*. Diakses 25 Mei 2026. <https://falco.org/docs/>.

- Feast Project. 2024. *Feast Documentation*. Diakses 20 April 2026. <https://docs.feast.dev/>.
- Gitea Contributors. 2025. *Gitea Documentation*. Diakses 25 Mei 2026. <https://docs.gitea.com/>.
- Google Cloud. 2024. *MLOps: Continuous Delivery and Automation Pipelines in Machine Learning*. Cloud Architecture Center. Diakses 18 Maret 2026. <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>.
- . 2026a. *Cloud SQL Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/sql/pricing>.
- . 2026b. *Cloud Storage Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/storage/pricing>.
- . 2026c. *Compute Engine VM Instance Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/compute/vm-instance-pricing>.
- . 2026d. *Google Kubernetes Engine Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/kubernetes-engine/pricing>.
- . 2026e. *Managed Service for Apache Kafka Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/managed-service-for-apache-kafka/pricing>.
- . 2026f. *Memorystore for Redis Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/memorystore/docs/redis/pricing>.
- . 2026g. *Persistent Disk and Image Pricing*. Diakses 16 Juni 2026. <https://cloud.google.com/compute/disks-image-pricing>.
- Grafana Labs. 2024a. *Grafana Documentation*. Diakses 20 April 2026. <https://grafana.com/docs/grafana/latest/>.
- . 2024b. *Grafana Loki Documentation*. Diakses 25 Mei 2026. <https://grafana.com/docs/loki/latest/>.
- . 2024c. *Grafana Tempo: High-Volume Distributed Tracing Backend*. Diakses 25 Mei 2026. <https://grafana.com/docs/tempo/latest/>.
- . 2025. *Grafana Pyroscope: Continuous Profiling*. Diakses 25 Mei 2026. <https://grafana.com/docs/pyroscope/latest/>.

- Great Expectations. 2024. *Great Expectations Documentation*. Diakses 25 Mei 2026. <https://docs.greatexpectations.io/docs/>.
- Hamza, Muhammad, Muhammad Azeem Akbar, dan Rafael Capilla. 2024. “Understanding Cost Dynamics of Serverless Computing: An Empirical Study”. Dalam *Software Business: 14th International Conference, ICSOB 2023, Proceedings*, 500:456–470. Lecture Notes in Business Information Processing. Springer. https://doi.org/10.1007/978-3-031-53227-6_32. https://doi.org/10.1007/978-3-031-53227-6_32.
- Harrington, John. 2023. *DataOps for Manufacturing: A 4-Stage Maturity Model*. HighByte Blog. Diakses 10 Juli 2026. <https://www.highbyte.com/blog/dataops-for-manufacturing-a-4-stage-maturity-model>.
- Hetzner Online GmbH. 2026. *Price Adjustment: Cloud Server Pricing*. Diakses 16 Juni 2026. <https://docs.hetzner.com/general/infrastructure-and-availability/price-adjustment/>.
- Hevner, Alan R., Salvatore T. March, Jinsoo Park, dan Sudha Ram. 2004. “Design Science in Information Systems Research”. *MIS Quarterly* 28 (1): 75–105. <https://doi.org/10.2307/25148625>. <https://doi.org/10.2307/25148625>.
- Hinder, Fabian, Valerie Vaquet, Johannes Brinkrolf, dan Barbara Hammer. 2023. “Model-Based Explanations of Concept Drift”. *Neurocomputing* 555:126640. <https://doi.org/10.1016/j.neucom.2023.126640>. <https://doi.org/10.1016/j.neucom.2023.126640>.
- Hsu, C. H., P. W. Liu, Y. C. Fan, dan C. Y. Lin. 2024. “End-to-End Automation of ML Model Lifecycle Management Using Machine Learning Operations Platforms”. Dalam *2024 International Conference on Consumer Electronics-Taiwan (ICCE-Taiwan)*, 1–6. IEEE. <https://doi.org/10.1109/ICCE-Taiwan62264.2024.10674445>. <https://doi.org/10.1109/ICCE-Taiwan62264.2024.10674445>.
- IBM. 2024. *What is Observability? Logs, Metrics, and Distributed Tracing*. Diakses 18 Maret 2026. <https://www.ibm.com/topics/observability>.
- Istio Authors. 2024. *Istio Service Mesh*. Diakses 16 Maret 2026. <https://istio.io/>.
- Iterative, Inc. 2025. *DVC Documentation*. Diakses 12 Juni 2026. <https://dvc.org/doc>.

- Jain, Souratn, dan Jyotipriya Das. 2025. “Integrating Data Engineering and MLOps for Scalable and Resilient Machine Learning Pipelines: Frameworks, Challenges, and Future Trends”. *World Journal of Advanced Engineering Technology and Sciences* 14 (1): 241–253. <https://doi.org/10.30574/wjaets.2025.14.1.0020>. <https://doi.org/10.30574/wjaets.2025.14.1.0020>.
- Jegou, Herve, Matthijs Douze, dan Cordelia Schmid. 2011. “Product Quantization for Nearest Neighbor Search”. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 33 (1): 117–128. <https://doi.org/10.1109/TPAMI.2010.57>. <https://doi.org/10.1109/TPAMI.2010.57>.
- Johnson, Jeff, Matthijs Douze, dan Hervé Jégou. 2021. “Billion-Scale Similarity Search with GPUs”. *IEEE Transactions on Big Data* 7 (3): 535–547. <https://doi.org/10.1109/TBDATA.2019.2921572>. <https://doi.org/10.1109/TBDATA.2019.2921572>.
- Jourdan, Nicolas, Tom Bayer, Tobias Biegel, dan Joachim Metternich. 2023. “Handling Concept Drift in Deep Learning Applications for Process Monitoring”. *Procedia CIRP* 120:42–47. <https://doi.org/10.1016/j.procir.2023.08.007>. <https://doi.org/10.1016/j.procir.2023.08.007>.
- Kafbat Authors. 2025. *Kafbat UI for Apache Kafka Documentation*. Diakses 12 Juni 2026. <https://ui.docs.kafbat.io/>.
- Kartakis, Sokratis, Giuseppe Angelo Porcelli, Georgios Schinas, dan Shelbee Eigenbrode. 2022. *MLOps Foundation Roadmap for Enterprises with Amazon SageMaker*. AWS Machine Learning Blog. Diakses 18 Maret 2026. <https://aws.amazon.com/blogs/machine-learning/mlops-foundation-roadmap-for-enterprises-with-amazon-sagemaker/>.
- Katsiampa, Paraskevi. 2017. “Volatility Estimation for Bitcoin: A Comparison of GARCH Models”. *Economics Letters* 158:3–6. <https://doi.org/10.1016/j.econlet.2017.06.023>. <https://doi.org/10.1016/j.econlet.2017.06.023>.
- Kaufman, Shachar, Saharon Rosset, Claudia Perlich, dan Ori Stitelman. 2012. “Leakage in Data Mining: Formulation, Detection, and Avoidance”. *ACM Transactions on Knowledge Discovery from Data* 6 (4): 1–21. <https://doi.org/10.1145/2382577.2382579>.
- KEDA Authors. 2025. *KEDA: Kubernetes Event-Driven Autoscaling*. Diakses 25 Mei 2026. <https://keda.sh/docs/>.

- Kim, Gene, Jez Humble, Patrick Debois, dan John Willis. 2016. *The DevOps Handbook: How to Create World-Class Agility, Reliability, and Security in Technology Organizations*. 1st. IT Revolution Press. ISBN: 978-1942788003. <https://itrevolution.com/product/the-devops-handbook/>.
- Kleppmann, Martin. 2017. *Designing Data-Intensive Applications*. O'Reilly Media. ISBN: 978-1491903063. <https://www.oreilly.com/library/view/designing-data-intensive-applications/9781491903063/>.
- Knative Authors. 2025. *Knative Serving: Serverless on Kubernetes*. Diakses 25 Mei 2026. <https://knative.dev/docs/serving/>.
- Kreps, Jay. 2014. *Questioning the Lambda Architecture*. Diakses 24 Maret 2026. O'Reilly Radar. <https://www.oreilly.com/radar/questioning-the-lambda-architecture/>.
- Kreuzberger, Dominik, Niklas Kühl, dan Sebastian Hirschl. 2023. "Machine Learning Operations (MLOps): Overview, Definition, and Architecture". *IEEE Access* 11:31866–31879. <https://doi.org/10.1109/ACCESS.2023.3262138>. <https://doi.org/10.1109/ACCESS.2023.3262138>.
- KServe Contributors. 2024. *KServe Documentation*. Diakses 28 April 2026. <https://kserve.github.io/website/>.
- Kubeflow Authors. 2025a. *Katib: Kubernetes-Native Hyperparameter Tuning*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/katib/>.
- . 2025b. *Kubeflow Notebooks*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/notebooks/>.
- . 2025c. *Kubeflow Trainer: Distributed Training Operators*. Diakses 25 Mei 2026. <https://www.kubeflow.org/docs/components/trainer/>.
- Kubeflow Contributors. 2024. *Kubeflow Documentation*. Diakses 30 Maret 2026. <https://www.kubeflow.org/docs/>.
- Kubernetes Autoscaling SIG. 2025. *Vertical Pod Autoscaler*. Diakses 25 Mei 2026. <https://github.com/kubernetes/autoscaler/tree/master/vertical-pod-autoscaler>.
- Kueue Authors. 2024. *Kueue: Job Queueing for Kubernetes*. Diakses 25 Mei 2026. <https://kueue.sigs.k8s.io/docs/>.

- Kyverno Authors. 2024. *Kyverno: Kubernetes Native Policy Management*. Diakses 25 Mei 2026. <https://kyverno.io/docs/>.
- Lakekeeper Authors. 2025. *Lakekeeper: Apache Iceberg REST Catalog*. Diakses 25 Mei 2026. <https://docs.lakekeeper.io/>.
- Lakka, Mounika. 2025. “Kubernetes for Enterprise: Mastering Cloud-Native Container Orchestration at Scale”. *European Modern Studies Journal* 9 (3): 358–367. [https://doi.org/10.59573/emsj.9\(3\).2025.31](https://doi.org/10.59573/emsj.9(3).2025.31). [https://doi.org/10.59573/emsj.9\(3\).2025.31](https://doi.org/10.59573/emsj.9(3).2025.31).
- Lamer, Antoine, Chloé Saint-Dizier, Nicolas Paris, dan Emmanuel Chazard. 2024. “Data Lake, Data Warehouse, Datamart, and Feature Store: Their Contributions to the Complete Data Reuse Pipeline”. *JMIR Medical Informatics* 12:e54590. <https://doi.org/10.2196/54590>. <https://doi.org/10.2196/54590>.
- Li, Anya, Bhala Ranganathan, Feng Pan, Mickey Zhang, Qianjun Xu, Runhan Li, Sethu Raman, Shail Paragbhai Shah, dan Vivienne Tang. 2023. “Managed Geo-Distributed Feature Store: Architecture and System Design”. *arXiv preprint arXiv:2305.20077*, <https://doi.org/10.48550/arXiv.2305.20077>. <https://arxiv.org/abs/2305.20077>.
- Liang, Penghao, Wei Chen, Yifan Zhang, dan Jun Liu. 2024. “Automating the Training and Deployment of Models in MLOps by Integrating Systems with Machine Learning”. *arXiv preprint arXiv:2405.09819*, <https://doi.org/10.48550/arXiv.2405.09819>. <https://arxiv.org/abs/2405.09819>.
- Limoncelli, Thomas. 2018. “GitOps: A Path to More Self-Service IT”. *Communications of the ACM* 61 (9): 38–42. <https://doi.org/10.1145/3233241>. <https://dl.acm.org/doi/10.1145/3233241>.
- Lu, Jie, Anjin Liu, Fan Dong, Feng Gu, Joao Gama, dan Guangquan Zhang. 2019. “Learning Under Concept Drift: A Review”. Versi cetak: arXiv:2004.05785 (2020), *IEEE Transactions on Knowledge and Data Engineering* 31 (12): 2346–2363. <https://arxiv.org/abs/2004.05785>.
- Makarov, Igor, dan Antoinette Schoar. 2020. “Trading and Arbitrage in Cryptocurrency Markets”. *Journal of Financial Economics* 135 (2): 293–319. <https://doi.org/10.1016/j.jfineco.2019.07.001>. <https://doi.org/10.1016/j.jfineco.2019.07.001>.

- Malkov, Yury A., dan D. A. Yashunin. 2020. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42 (4): 824–836. <https://doi.org/10.1109/TPAMI.2018.2889473>. <https://doi.org/10.1109/TPAMI.2018.2889473>.
- Marz, Nathan, dan James Warren. 2015. *Big Data: Principles and Best Practices of Scalable Realtime Data Systems*. Manning Publications. ISBN: 978-1617290343. <https://www.manning.com/books/big-data>.
- McKnight, William. 2020. *Delivering on the Vision of MLOps: A Maturity-Based Approach*. Diakses 18 Maret 2026. GigaOm. <https://gigaom.com/report/delivering-on-the-vision-of-mlops/>.
- Microsoft Azure. 2023. *Machine Learning Operations Maturity Model*. Azure Architecture Center. Diakses 18 Maret 2026. <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/mlops-maturity-model>.
- MinIO, Inc. 2024. *MinIO Documentation*. Diakses 20 April 2026. <https://min.io/docs/>.
- . 2025. *KES: Stateless Key Management Server*. Diakses 25 Mei 2026. <https://github.com/minio/kcs>.
- MLflow Contributors. 2024. *MLflow Documentation*. Diakses 15 April 2026. <https://mlflow.org/docs/latest/index.html>.
- Mo, Di, Robert Cordingley, Donald Chinn, dan Wes Lloyd. 2023. “Addressing Serverless Computing Vendor Lock-In through Cloud Service Abstraction”. Dalam *2023 IEEE International Conference on Cloud Computing Technology and Science (CloudCom)*, 193–199. IEEE. <https://doi.org/10.1109/CloudCom59040.2023.00040>. <https://doi.org/10.1109/CloudCom59040.2023.00040>.
- Munappy, Aiswarya Raj, Jan Bosch, Helena Holmström Olsson, Anders Arpteg, dan Björn Brinne. 2022. “Data Management for Production Quality Deep Learning Models: Challenges and Solutions”. *Journal of Systems and Software* 191:111359. <https://doi.org/10.1016/j.jss.2022.111359>. <https://doi.org/10.1016/j.jss.2022.111359>.

- Munappy, Aiswarya Raj, David Issa Mattos, Jan Bosch, Helena Holmström Olsson, dan Anas Dakkak. 2020. "From Ad-Hoc Data Analytics to DataOps". Dalam *Proceedings of the International Conference on Software and System Processes (ICSSP '20)*, 165–174. ACM. <https://doi.org/10.1145/3379177.3388909>. <https://doi.org/10.1145/3379177.3388909>.
- NATS Authors. 2025. *NATS JetStream Documentation*. Diakses 12 Juni 2026. <https://docs.nats.io/nats-concepts/jetstream>.
- OAuth2 Proxy Authors. 2025. *OAuth2 Proxy Documentation*. Diakses 25 Mei 2026. <https://oauth2-proxy.github.io/oauth2-proxy/>.
- Open Policy Agent Authors. 2024. *Open Policy Agent*. Diakses 30 Maret 2026. <https://www.openpolicyagent.org/>.
- OpenAI. 2022. *New and Improved Embedding Model*. OpenAI Blog. Diakses 18 Maret 2026. <https://openai.com/index/new-and-improved-embedding-model/>.
- OpenBao Authors. 2025. *OpenBao: Open Source Secrets Management*. Diakses 25 Mei 2026. <https://openbao.org/docs/>.
- OpenCost Authors. 2025. *OpenCost: Open Source Cost Monitoring for Kubernetes*. Diakses 25 Mei 2026. <https://www.opencost.io/docs/>.
- OpenLineage Authors. 2025. *OpenLineage: An Open Standard for Lineage Metadata Collection*. Diakses 25 Mei 2026. <https://openlineage.io/docs/>.
- OpenSearch Foundation. 2025. *OpenSearch: Open Source Search and Analytics Suite*. Diakses 25 Mei 2026. <https://opensearch.org/docs/latest/>.
- OpenTelemetry Authors. 2025. *OpenTelemetry Documentation*. Diakses 25 Mei 2026. <https://opentelemetry.io/docs/>.
- Oracle Corporation. 2025. *MySQL Reference Manual*. Diakses 25 Mei 2026. <https://dev.mysql.com/doc/>.
- OVHcloud. 2026. *Public Cloud Prices*. Diakses 16 Juni 2026. <https://us.ovhcloud.com/public-cloud/prices/>.
- Pachyderm, Inc. 2025. *Pachyderm Documentation*. Diakses 12 Juni 2026. <https://docs.pachyderm.com/>.

- Paley, Andrei, Raoul-Gabriel Urma, dan Neil D. Lawrence. 2022. "Challenges in Deploying Machine Learning: A Survey of Case Studies". *ACM Computing Surveys* 55 (6): 1–29. <https://doi.org/10.1145/3533378>. <https://doi.org/10.1145/3533378>.
- Peffer, Ken, Tuure Tuunanen, Marcus A. Rothenberger, dan Samir Chatterjee. 2007. "A Design Science Research Methodology for Information Systems Research". *Journal of Management Information Systems* 24 (3): 45–77. <https://doi.org/10.2753/MIS0742-1222240302>. <https://doi.org/10.2753/MIS0742-1222240302>.
- PERSOLKELLY Indonesia. 2023. *Indonesia Salary Guide 2023*. Diakses 16 Juni 2026. <https://www.persolindonesia.com/salary-guides>.
- Pimentel, João Felipe, Leonardo Murta, Vanessa Braganholo, dan Juliana Freire. 2019. "A Large-Scale Study About Quality and Reproducibility of Jupyter Notebooks". Dalam *2019 IEEE/ACM 16th International Conference on Mining Software Repositories (MSR)*, 507–517. IEEE. <https://doi.org/10.1109/MSR.2019.00077>. <https://doi.org/10.1109/MSR.2019.00077>.
- Polyzotis, Neoklis, Sudip Roy, Steven Euijong Whang, dan Martin Zinkevich. 2018. "Data Lifecycle Challenges in Production Machine Learning: A Survey". *ACM SIGMOD Record* 47 (2): 17–28. <https://doi.org/10.1145/3299887.3299891>. <https://doi.org/10.1145/3299887.3299891>.
- PostgreSQL Global Development Group. 2025. *PostgreSQL: The World's Most Advanced Open Source Relational Database*. Diakses 25 Mei 2026. <https://www.postgresql.org/docs/>.
- Project Nessie Authors. 2025. *Project Nessie Documentation*. Diakses 12 Juni 2026. <https://projectnessie.org/>.
- Prometheus Authors. 2024. *Prometheus Documentation*. Diakses 20 April 2026. <https://prometheus.io/docs/>.
- . 2025. *Prometheus Pushgateway*. Diakses 25 Mei 2026. <https://prometheus.io/docs/practices/pushing/>.
- Qdrant Team. 2025. *Qdrant: High-Performance Vector Search Engine*. Diakses 25 Mei 2026. <https://qdrant.tech/documentation/>.
- Redpanda Data, Inc. 2025. *Redpanda Documentation*. Diakses 12 Juni 2026. <https://docs.redpanda.com/>.

- Reimers, Nils, dan Iryna Gurevych. 2019. "Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks". Dalam *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. Association for Computational Linguistics. <https://doi.org/10.18653/v1/D19-1410>. <https://doi.org/10.18653/v1/D19-1410>.
- Reis, Denis Moreira dos, Peter Flach, Stan Matwin, dan Gustavo Batista. 2016. "Fast Unsupervised Online Drift Detection Using Incremental Kolmogorov-Smirnov Test". Dalam *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1545–1554. ACM. <https://doi.org/10.1145/2939672.2939836>. <https://doi.org/10.1145/2939672.2939836>.
- Rella, Bhanu Prakash Reddy. 2022. "MLOps and DataOps Integration for Scalable Machine Learning Deployment". *International Journal for Multidisciplinary Research* 4 (1). <https://www.ijfmr.com/papers/2022/1/39278.pdf>.
- Rodrigues, Miguel G., Eduardo K. Viegas, Altair O. Santin, dan Fabrício Enembreck. 2025. "A MLOps Architecture for Near Real-Time Distributed Stream Learning Operation Deployment". *Journal of Network and Computer Applications* 238:104169. <https://doi.org/10.1016/j.jnca.2025.104169>. <https://doi.org/10.1016/j.jnca.2025.104169>.
- Ross, Ron, Mark Winstead, dan Michael McEvilly. 2022. *Engineering Trustworthy Secure Systems*. NIST Special Publication 800-160v1r1. National Institute of Standards dan Technology. <https://doi.org/10.6028/NIST.SP.800-160v1r1>. <https://doi.org/10.6028/NIST.SP.800-160v1r1>.
- Salama, Khalid, Jarek Kazmierczak, dan Donna Schut. 2021. *Practitioners Guide to MLOps: A Framework for Continuous Delivery and Automation of Machine Learning*. Diakses 10 Juli 2026. Google Cloud. https://services.google.com/fh/files/misc/practitioners_guide_to_mlops_whitepaper.pdf.
- Sculley, D., Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-Francois Crespo, dan Dan Dennison. 2015. "Hidden Technical Debt in Machine Learning Systems". Dalam *Advances in Neural Information Processing Systems 28 (NIPS 2015)*, disunting oleh C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, dan R. Garnett, 2503–2511. Red Hook, NY: Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2015/file/86df7dcfd896fcf2674f757a2463eba-Paper.pdf>.

- SeaweedFS Authors. 2025. *SeaweedFS Documentation*. Diakses 12 Juni 2026. <https://github.com/seaweedfs/seaweedfs/wiki>.
- Shankar, Shreya, Rolando Garcia, Joseph M. Hellerstein, dan Aditya G. Parameswaran. 2022. *Operationalizing Machine Learning: An Interview Study*. ArXiv preprint arXiv:2209.09125. <https://doi.org/10.48550/arXiv.2209.09125>. <https://arxiv.org/abs/2209.09125>.
- Sloth Authors. 2025. *Sloth: Easy and Reliable SLOs for Prometheus*. Diakses 25 Mei 2026. <https://sloth.dev/>.
- Stopford, Ben. 2018. *Designing Event-Driven Systems: Concepts and Patterns for Streaming Services with Apache Kafka*. O'Reilly Media. ISBN: 978-1-492-03822-1.
- Stoyanovich, Julia, Bill Howe, dan H. V. Jagadish. 2020. "Responsible Data Management". *Proceedings of the VLDB Endowment* 13 (12): 3474–3488. <https://doi.org/10.14778/3415478.3415570>. <https://doi.org/10.14778/3415478.3415570>.
- Strimzi Authors. 2025. *Strimzi: Apache Kafka on Kubernetes*. Diakses 25 Mei 2026. <https://strimzi.io/documentation/>.
- Tekton Contributors. 2024. *Tekton Pipelines Documentation*. Diakses 25 Mei 2026. <https://tekton.dev/docs/>.
- Treeverse Ltd. 2025. *lakeFS: Data Version Control for Object Storage*. Diakses 25 Mei 2026. <https://docs.lakefs.io/>.
- Trino Software Foundation. 2024. *Trino: Distributed SQL Query Engine*. Diakses 6 April 2026. <https://trino.io/>.
- Valkey Contributors. 2025. *Valkey: An Open Source In-Memory Data Store*. Diakses 25 Mei 2026. <https://valkey.io/docs/>.
- Vangala, Rajesh, Priya Mehta, dan Arjun Singh. 2022. *MLOps in Practice: A Framework for Scalable AI Model Deployment, Monitoring, and Retraining*. Technical Report. Diakses 15 April 2026. https://www.researchgate.net/publication/393096121_MLOps_in_Practice_A_Framework_for_Scalable_AI_Model_Deployment_Monitoring_and_Retraining.

- Vela, Daniel, Andrew Sharp, Richard Zhang, Trang Nguyen, An Hoang, dan Oleg S. Pinykh. 2022. "Temporal Quality Degradation in AI Models". *Scientific Reports* 12:11654. <https://doi.org/10.1038/s41598-022-15245-z>. <https://doi.org/10.1038/s41598-022-15245-z>.
- Velero Authors. 2025. *Velero: Backup and Migrate Kubernetes Resources and Persistent Volumes*. Diakses 25 Mei 2026. <https://velero.io/docs/>.
- Vultr. 2026. *Vultr Cloud Pricing*. Diakses 16 Juni 2026. <https://www.vultr.com/pricing/>.
- Zaharia, Matei, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, dkk. 2016. "Apache Spark: A Unified Engine for Big Data Processing". *Communications of the ACM* 59 (11): 56–65. <https://doi.org/10.1145/2934664>. <https://doi.org/10.1145/2934664>.

LAMPIRAN A

PARAMETER PENILAIAN KRITERIA EVALUASI

Lampiran ini merinci parameter untuk seluruh penilaian berskala 0 sampai 2 yang dipakai pada laporan agar setiap angka dapat dirunut ke definisi nilainya. Bagian-bagiannya disusun mengikuti urutan kemunculan konsep pada batang tubuh laporan. Bagian A.1 memuat parameter pemetaan skor pada perbandingan *framework* kematangan MLOps di Subbab II.1.2. Bagian A.2 memuat parameter evaluasi pemilihan solusi yang mendasari skor kebutuhan fungsional dan nonfungsional pada Subbab III.3.2. Bagian A.3 memuat parameter evaluasi pemilihan *open source tools* yang mendasari tabel berskor pada Subbab IV.2.

A.1 Parameter Pemetaan Kematangan MLOps

Kematangan pada laporan ini dikuantisasi ke skala 0 sampai 2 hanya pada sisi MLOps. Sisi DataOps dibandingkan secara deskriptif pada Tabel II.2 tanpa skor lintas model karena objek penilaian tiap model berbeda, sehingga tidak memiliki parameter berskala pada lampiran ini. Perbandingan *framework* kematangan MLOps pada Subbab II.1.2 memakai skor 0 sampai 2 untuk enam praktik pada empat *framework* yang telah terbit. Definisi *level* itu sendiri bukan buatan laporan ini, sebab tiap *framework* menerbitkan deskripsi resmi levelnya masing-masing, seperti *level* 0 sampai 2 pada Google Cloud. Kuantisasi menjadi angka justru dilakukan laporan ini dengan membaca deskripsi resmi tiap *level* lalu memetakan kehadiran tiap praktik pada kolom tabel ke salah satu dari tiga nilai. Tabel A.1 merinci parameter pemetaan tersebut sehingga pembaca dapat mengulangi pemetaan dari sumber yang sama dan memeriksa nilainya.

Tabel A.1 Parameter Pemetaan Skor Perbandingan Kematangan MLOps

Nilai	Parameter Pemetaan dari Deskripsi <i>Level</i> Terbit
0	Praktik pada kolom tidak disebut sama sekali pada deskripsi terbit <i>level</i> tersebut, atau disebut secara eksplisit belum ada.
1	Praktik disebut hadir sebagian, berjalan semi-otomatis, atau berstatus opsional pada deskripsi terbit <i>level</i> tersebut.
2	Praktik disebut berjalan otomatis penuh atau menjadi komponen wajib pada deskripsi terbit <i>level</i> tersebut.

A.2 Parameter Evaluasi Pemilihan Solusi

Skor pada Tabel III.3 dan Tabel III.4 menilai pemenuhan tiap kebutuhan oleh empat alternatif solusi pada Subbab III.3.2. Penilaian diturunkan dari dokumentasi resmi dan penawaran publik tiap kategori alternatif, misalnya katalog layanan penyedia *cloud* untuk Alternatif A serta dokumentasi proyek *open source* untuk Alternatif B, sehingga nilainya dapat diperiksa ulang dari sumber yang sama. Tabel A.2 merinci makna tiap nilai untuk sisi kebutuhan fungsional dan sisi kebutuhan nonfungsional. Nilai bersifat komparatif antar keempat alternatif pada kebutuhan yang sama dan tidak memakai pembobotan.

Tabel A.2 Parameter Nilai Evaluasi Pemilihan Solusi

Nilai	Parameter Kebutuhan Fungsional	Parameter Kebutuhan Nonfungsional
0	Kapabilitas yang dituntut kebutuhan tidak tersedia pada penawaran resmi alternatif dan hanya dapat dicapai lewat pengembangan kustom penuh.	Atribut kualitas tidak dijamin oleh penawaran resmi alternatif dan tidak ada mekanisme <i>built-in</i> untuk mencapainya.
1	Kapabilitas tersedia sebagian, masih menuntut komponen tambahan, kustomisasi berarti, atau hanya memenuhi sebagian aspek kebutuhan.	Atribut kualitas dapat dicapai dengan upaya tambahan yang berarti, atau jaminannya terbatas pada kondisi tertentu.
2	Kapabilitas tersedia sebagai fitur <i>built-in</i> kelas produksi yang terdokumentasi resmi pada alternatif tersebut.	Atribut kualitas dijamin oleh mekanisme <i>built-in</i> alternatif dan terdokumentasi resmi.

A.3 Parameter Evaluasi Pemilihan *Open Source Tools*

Bagian ini merinci parameter penilaian untuk setiap kriteria pada tabel evaluasi alternatif *open source* di Subbab IV.2. Setiap kriteria memakai skala 0 sampai 2. Parameter di bawah menjelaskan kondisi yang membuat sebuah *tools* memperoleh nilai 0, 1, atau 2 pada kriteria tersebut. Penilaian bersifat komparatif antar kandidat pada tabel yang sama dan diturunkan dari dokumentasi resmi, status lisensi, serta indikator publik proyek seperti riwayat rilis dan naungan yayasan per April 2026. Kolom Total pada tiap tabel menjumlahkan keempat kriteria tanpa pembobotan sehingga nilai tertinggiya delapan.

Parameter dibagi menjadi dua kelompok agar tidak berulang. Tabel A.3 memuat kriteria lintas tabel yang muncul pada lebih dari satu tabel evaluasi dengan makna yang sama, seperti kematangan, komunitas, dan keluarga kriteria lisensi. Tabel A.4 memuat kriteria spesifik yang hanya dipakai pada satu *layer*, dikelompokkan menurut *layer* arsitekturnya. Nama kriteria pada kedua tabel ditulis sama persis dengan judul kolom pada tabel evaluasi yang memakainya.

A.3.1 Kriteria Lintas Tabel

Tabel A.3 Parameter Penilaian Kriteria Lintas Tabel

Kriteria	Skor 0	Skor 1	Skor 2
Kematangan	Belum ada rilis stabil atau pengembangan berhenti dua belas bulan terakhir	Rilis stabil tersedia namun versi mayor masih muda atau adopsi produksi terbatas	Rilis stabil dengan ritme rilis teratur dan rekam jejak produksi bertahun-tahun
Komunitas	Kontributor efektif tunggal atau aktivitas kontribusi minim	Komunitas aktif namun lebih kecil atau terpusat pada satu organisasi	Komunitas kontributor lintas organisasi terluas pada kategori fungsinya
Ekstensibilitas	Tanpa titik ekstensi resmi	Ekstensi terbatas pada sebagian antarmuka atau menuntut perubahan inti	Antarmuka <i>plugin</i> atau <i>provider</i> resmi terdokumentasi tanpa mengubah inti
Lisensi Terbuka, Lisensi <i>Open</i>	Lisensi tidak diakui OSI, seperti BSL, BUSL, atau <i>source-available</i>	Lisensi OSI dengan <i>copyleft</i> kuat seperti AGPL	Lisensi OSI permisif atau <i>copyleft</i> lemah seperti Apache 2.0, BSD, MPL
Integrasi K8s, Operabilitas K8s, Dukungan K8s	Tanpa dukungan resmi untuk berjalan pada Kubernetes	Berjalan melalui <i>chart</i> atau manifes tanpa pengelolaan siklus hidup, atau mensyaratkan komponen infrastruktur eksternal tetap seperti etcd atau antrian pesan	Dukungan kelas satu berupa <i>operator</i> , CRD, atau <i>chart</i> resmi terkelola
K8s-Native	Tidak dirancang berjalan pada Kubernetes	Berjalan pada Kubernetes namun model eksekusinya tidak berbasis CRD	Model eksekusi berbasis CRD sebagai antarmuka utama
Integrasi (<i>tracking</i> , metadata)	Integrasi terbatas pada ekosistem <i>tools</i> itu sendiri	Integrasi tersedia untuk sebagian <i>tools</i> data dan ML	Integrasi luas lintas ekosistem data dan ML yang terdokumentasi

A.3.2 Kriteria Spesifik per Layer

Tabel A.4 Parameter Penilaian Kriteria Spesifik per *Layer*

Kriteria	Skor 0	Skor 1	Skor 2
Distribusi Kubernetes			
<i>Footprint</i> Ringan	Kebutuhan sumber daya setara distribusi penuh	Ringan namun bergantung paket sistem tambahan	<i>Single binary</i> dengan kebutuhan memori minimal terdokumentasi
Siap Produksi	Ditujukan untuk pengujian, bukan produksi	Dapat dipakai produksi dengan batasan tertentu	Didukung resmi untuk beban produksi
Tanpa Dependensi	Memerlukan beberapa komponen eksternal	Memerlukan satu <i>runtime</i> atau paket eksternal	<i>Runtime</i> kontainer tertanam tanpa dependensi eksternal
Ekosistem <i>Add-on</i>	Tanpa mekanisme <i>add-on</i>	<i>Add-on built-in</i> terbatas	<i>Add-on built-in</i> luas termasuk <i>controller</i> Helm
Message Broker dan Schema Registry			
Ekosistem Konektor	Konektor minim	Konektor tersedia namun cakupannya jauh lebih sempit	Ekosistem konektor terluas melalui Kafka <i>Connect native</i>
Operator K8s	Tanpa <i>operator</i>	<i>Operator</i> tersedia dengan cakupan terbatas	<i>Operator</i> matang mencakup <i>cluster</i> , pengguna, dan <i>topic</i>
Protokol Kafka	Protokol berbeda tanpa kompatibilitas	Kompatibel melalui <i>layer</i> protokol tambahan	Kompatibel penuh pada level protokol <i>native</i>
Kompatibilitas Confluent	API tidak kompatibel	Kompatibel pada sebagian <i>endpoint</i>	Kompatibel penuh dengan API Confluent
Dukungan Format	Satu format skema	Dua format atau dukungan parsial	Avro, JSON Schema, dan Protobuf penuh
Pemrosesan Data			
Kapabilitas <i>Batch</i>	Tanpa mode <i>batch</i>	<i>Batch</i> tersedia namun bukan kekuatan utama	<i>Batch</i> skala besar sebagai kapabilitas inti
Kapabilitas <i>Streaming</i>	Tanpa <i>streaming native</i>	<i>Streaming</i> melalui <i>micro-batch</i>	<i>Streaming event-time</i> dengan <i>exactly-once native</i>
Format Tabel Lakehouse			
Transaksi ACID	Tanpa jaminan transaksi	Transaksi dengan batasan mode tulis	Transaksi atomik penuh terdokumentasi
Evolusi Skema	Tanpa evolusi skema	Evolusi terbatas atau bergantung <i>engine</i>	Evolusi penuh pada level format tanpa menulis ulang data

Kriteria	Skor 0	Skor 1	Skor 2
Integrasi <i>Engine</i>	Terikat satu <i>engine</i>	Dukungan <i>multi-engine</i> tidak setara antar <i>engine</i>	Netral <i>multi-engine</i> dengan dukungan setara
Penyimpanan Objek dan Versi Data			
Kompatibilitas S3	Tanpa API S3	Subset API S3	Cakupan API S3 luas termasuk fitur lanjutan
<i>Footprint</i> Satu <i>Node</i>	Arsitektur menuntut banyak <i>node</i>	Dapat satu <i>node</i> dengan komponen berat	Berjalan ringan pada satu <i>node</i>
Enkripsi KMS	Tanpa enkripsi sisi <i>server</i> berbasis KMS	Enkripsi tanpa integrasi KMS eksternal	Enkripsi sisi <i>server</i> dengan integrasi KMS eksternal
<i>Zero-copy Branching</i>	Tanpa konsep <i>branching</i>	Versi berbasis penunjuk berkas per <i>commit</i>	<i>Branch</i> dan <i>merge</i> tanpa menyalin objek
Integrasi Objek S3	Tidak bekerja di atas penyimpanan objek	Bekerja melalui katalog atau <i>remote</i> khusus	Antarmuka S3 langsung tanpa mengubah klien
Skala Data Besar	Tidak dirancang untuk data besar	Skala bergantung repositori Git atau basis data tunggal	Metadata terpisah yang menangani jutaan objek
Layanan Fitur			
Performa <i>Query</i>	Latensi agregasi tinggi pada data besar	Agregasi cepat dengan batasan bentuk kueri	Agregasi kolumnar sub-detik pada data besar
Dukungan <i>Ingestion</i>	<i>Batch</i> saja dengan <i>tools</i> eksternal	<i>Streaming</i> atau <i>batch</i> dengan komponen tambahan	<i>Streaming</i> dan <i>batch native</i> termasuk Kafka
Latensi	Latensi baca di atas puluhan milidetik	Latensi milidetik pada penyimpanan <i>disk</i>	Latensi sub-milidetik pada memori
<i>Throughput</i>	<i>Throughput</i> rendah untuk <i>lookup</i> masif	<i>Throughput</i> tinggi dengan batasan skala vertikal	Ratusan ribu operasi per detik terdokumentasi
Latensi Rendah	Kueri ANN berlatensi tinggi	Latensi rendah dengan batasan indeks atau skala	HNSW dalam memori dengan antarmuka gRPC berlatensi rendah
Model Lifecycle			
<i>Pipeline</i> ML	Tanpa abstraksi <i>pipeline</i> ML	<i>Pipeline</i> generik yang dapat dipakai untuk ML	Abstraksi <i>pipeline</i> ML khusus dengan kontrak artefak
Skalabilitas	Replika statis tanpa <i>autoscaling</i>	<i>Autoscaling</i> tanpa <i>scale-to-zero</i>	<i>Autoscaling</i> termasuk <i>scale-to-zero</i>

Kriteria	Skor 0	Skor 1	Skor 2
<i>Framework</i>	Terikat satu <i>framework</i> model	Beberapa <i>framework</i> melalui penyesuaian manual	Multi- <i>framework</i> melalui <i>runtime</i> yang dapat diganti
Observabilitas dan BI			
Konektor SQL	Konektor terbatas satu keluarga basis data	Konektor untuk beberapa basis data umum	Puluhan dialek SQL melalui <i>layer</i> konektor standar
Multi-Tenant K8s	Tanpa dukungan Kubernetes resmi	Berjalan pada Kubernetes tanpa isolasi peran	<i>Chart</i> resmi dengan RBAC <i>multi-tenant</i>
GitOps			
Antarmuka	Tanpa antarmuka pemantauan	Antarmuka terbatas atau lewat <i>tools</i> pihak ketiga	Antarmuka web penuh untuk sinkronisasi dan <i>diff</i>
Keamanan Platform			
Bobot <i>Footprint</i>	Kebutuhan sumber daya besar dengan banyak komponen	Layanan tunggal namun berat pada memori	Proses tunggal ringan tanpa basis data wajib
Federasi OIDC	Tanpa federasi ke penyedia hulu	Federasi terbatas pada sebagian protokol	Federasi luas ke penyedia identitas hulu
Rotasi Dinamis	<i>Secret</i> statis tanpa rotasi	Rotasi manual atau terbatas	Kredensial dinamis dengan masa hidup otomatis
Integrasi ESO	Tanpa <i>provider</i> External Secrets Operator	Integrasi tidak langsung melalui <i>provider</i> generik	<i>Provider</i> External Secrets Operator resmi
Fitur L7	Fokus L3 dan L4 tanpa kontrol aplikasi	Kontrol L7 dasar	Kontrol L7 penuh termasuk <i>routing</i> dan otorisasi
Ekosistem CRD	Tanpa CRD	CRD terbatas pada sebagian fungsi	CRD kaya untuk trafik, otorisasi, dan telemetri
Plugin/Ekstensi	Tanpa mekanisme <i>plugin</i>	<i>Plugin</i> terbatas pada edisi terbuka	Ekosistem <i>plugin</i> luas dengan muat ulang dinamis
Sintaks <i>Native</i>	Bahasa kebijakan eksternal terpisah dari Kubernetes	Bahasa khusus dengan integrasi Kubernetes	Kebijakan ditulis sebagai YAML <i>native</i> Kubernetes
Mode <i>Mutate</i>	Validasi saja	Mutasi terbatas	<i>Validate</i> , <i>mutate</i> , dan <i>generate</i> penuh

Kriteria	Skor 0	Skor 1	Skor 2
Pelaporan Pelanggaran	Log saja	Metrik atau status tanpa laporan standar	PolicyReport standar per sumber daya
Cakupan eBPF/ Kernel	Tanpa visibilitas kernel	Visibilitas kernel pada subset <i>event</i>	<i>Probe</i> eBPF modern mencakup <i>syscall</i> luas
Aturan <i>Built-in</i>	Tanpa aturan <i>built-in</i>	Contoh aturan terbatas	Pustaka aturan <i>built-in</i> siap pakai yang luas

LAMPIRAN B

KATALOG PERINTAH VERIFIKASI USE CASE

Lampiran ini memuat katalog perintah yang dapat dijalankan ulang untuk memverifikasi alur *end-to-end* pada *use case* pasar aset kripto. Seluruh perintah dijalankan secara manual dari direktori akar repositori `~/documents/ta/`, kecuali bila *listing* menyertakan perintah `cd` eksplisit. Katalog ini dijalankan manual sehingga bukan bagian dari beban produksi maupun rekonsiliasi Argo CD. Sebagian besar perintah hanya membaca *cluster*, sedangkan skenario ketahanan (SK-N-04) dan skalabilitas (SK-N-03) menerapkan gangguan terkendali yang dapat dipulihkan pada *namespace experiments* yang terpisah dari produksi. Skenario rekonstruksi (SK-N-11) memverifikasi pembangunan ulang platform dari Git melalui `make phase-full`, sejalan dengan metode evaluasi pada Bab VI. Berkas skenario berada pada direktori `experiments/` yang sejajar dengan `platform/` dan `use-case-crypto/`. Rincian argumen tiap skenario tersedia pada `README.md` di `experiments/` beserta subdirektori terkait. Prasyarat menjalankannya adalah platform telah terpasang (`make phase-full`), *use case* telah ter-deploy (`make usecase-crypto-build && make usecase-crypto-up`), dan seluruh *pod* berstatus *Running*. Sebelum skenario dijalankan, konfigurasi domain dimuat dan *namespace* beban dibuat melalui langkah persiapan berikut.

Listing B.1 Persiapan *namespace load generator* (dari `~/documents/ta/`)

```
1 # Muat DOMAIN; ganti berkas ini
2 set -a; . "${EXPERIMENTS_CONFIG:-experiments/config.crypto.env}";
   set +a
3 kubectl apply -f experiments/namespace.yaml
```

B.1 Tujuan T-1: Arsitektur Terintegrasi dan GitOps

Kelompok T-1 membuktikan pemasangan deklaratif dari satu sumber Git, otomatisasi *model lifecycle* setara MLOps level 2, serta atribut kualitas lintas komponen. Perintahnya dirangkum pada Listing B.2.

Listing B.2 Perintah verifikasi tujuan T-1 (dari `~/documents/ta/`)

```
1 # SK-F-01/KF-01: rekonsiliasi feature view Feast
2 argocd app get crypto-use-case-local
3 kubectl -n use-case-crypto get configmap crypto-feast-feature-repo
   \
```



```

4  -o jsonpath='{.data.definitions\.py}' | grep 'FeatureView('
5
6  # SK-F-12/KF-12: konvergensi deklaratif tanpa drift
7  argocd app diff crypto-use-case-local
8  kubectl -n use-case-crypto get deploy
9
10 # SK-F-06/KF-06: canary dan rollback Rollouts
11 kubectl -n use-case-crypto get rollouts
12 kubectl argo rollouts -n use-case-crypto get rollout crypto-ml-
    bridge --watch
13
14 # SK-F-13/KF-13: satu environment uv multi-SDK
15 cd use-case-crypto/notebooks
16 uv sync
17 uv run jupyter nbconvert --to notebook --execute
    unified_sdk_walkthrough.ipynb
18 kubectl get inferencesservice -A | grep predictor
19
20 # SK-F-14/KF-14: kuota Kueue, job Pending
21 kubectl get clusterqueue,localqueue,workloads -A
22
23 # SK-N-03/KNF-03: skalabilitas HPA dan KEDA
24 k6 run experiments/load/hpa-keda-rampup.js
25 kubectl -n use-case-crypto get hpa,scaledobject,pods -w
26
27 # SK-N-04/KNF-04: injeksi fault pod/jaringan
28 envsubst < experiments/chaos/pod-chaos.yaml | kubectl apply -f -
29 kubectl apply -f experiments/chaos/network-chaos.yaml
30
31 # SK-N-08/KNF-08: ganti runtime via overlay
32 kubectl apply -k use-case-crypto/manifests/overlays/local
33
34 # SK-N-09/KNF-09: SSO satu sesi dex
35 kubectl get pods -A | grep -E 'dex|oauth2-proxy'
36
37 # SK-N-10/KNF-10: atribusi biaya OpenCost
38 kubectl get pods -A | grep -i opencost
39
40 # SK-N-11/KNF-11: rekonstruksi penuh dari Git
41 make phase-full
42
43 # SK-N-12/KNF-12: \textit{test coverage}, konvergensi phase-full
44 make usecase-crypto-test
45 time make phase-full

```

B.2 Tujuan T-2: Tata Kelola Data

Kelompok T-2 membuktikan katalog metadata, *lineage*, kontrak kualitas, observabilitas, dan keamanan berjalan otomatis sepanjang *pipeline*. Perintahnya dirangkum pada Listing B.3.

Listing B.3 Perintah verifikasi tujuan T-2 (dari ~/documents/ta/)

```
1 # SK-F-08/KF-08: lineage end-to-end DataHub
2 experiments/lineage/lineage-walk.sh discover
3 experiments/lineage/lineage-walk.sh walk '<urn>'
4
5 # SK-F-09/KF-09: dua run, delta <1%
6 kubectl -n model-lifecycle get pods | grep mlflow
7
8 # SK-F-10/KF-10: audit trail MLflow
9 kubectl -n model-lifecycle get pods | grep mlflow
10
11 # SK-N-05/KNF-05: GE checkpoint tolak pelanggaran
12 kubectl -n use-case-crypto get cronjob | grep -iE 'quality|expect|
    ge-'
13 kubectl -n use-case-crypto create job ge-check --from=cronjob/
    crypto-ge-checkpoint
14
15 # SK-N-06/KNF-06: trace OTel Tempo/Grafana
16 kubectl get pods -A | grep -E 'tempo|grafana'
17
18 # SK-N-07/KNF-07: Trivy, TLS dan AES
19 kubectl get vulnerabilityreports -A
20 testssl.sh <public-endpoint>
```

B.3 Tujuan T-3: Deteksi *Drift* dan *Retraining*

Kelompok T-3 membuktikan deteksi *drift* terotomasi memicu *retraining* dan penyusunan fitur *training* menjaga *point-in-time correctness*. Perintahnya dirangkum pada Listing B.4.

Listing B.4 Perintah verifikasi tujuan T-3 (dari ~/documents/ta/)

```
1 # SK-F-03/KF-03: point-in-time correctness gold
2 export CLICKHOUSE_USER=$(kubectl -n "$CLICKHOUSE_NAMESPACE" get
    secret clickhouse-admin \
3     -o jsonpath='{.data.CLICKHOUSE_USER}' | base64 -d)
4 export CLICKHOUSE_PASSWORD=$(kubectl -n "$CLICKHOUSE_NAMESPACE"
    get secret clickhouse-admin \
```

```

5 -o jsonpath='{.data.CLICKHOUSE_PASSWORD}' | base64 -d)
6 experiments/etl/data-landed-check.sh
7
8 # SK-F-05/KF-05: pipeline retraining KFP
9 uv run --with 'kfp[kubernetes]==2.16.0' use-case-crypto/pipelines/
  retraining_pipeline.py
10
11 # SK-F-07/KF-07: injeksi drift picu retrain
12 uv run experiments/drift/inject_drift.py --sigma 2.0
13 kubectl -n model-lifecycle get cronworkflow,workflow

```

B.4 Tujuan T-4: Layanan Fitur *Dual-Store*

Kelompok T-4 membuktikan layanan fitur *dual-store* menyajikan *tabular feature*, *aggregate feature*, dan *vector feature* dengan kontrak konsisten antara *training* dan *serving*, beserta latensi dan *throughput serving flow*. Perintahnya dirangkum pada Listing B.5.

Listing B.5 Perintah verifikasi tujuan T-4 (dari ~/documents/ta/)

```

1 # SK-F-02/KF-02: online Feast offline ClickHouse
2 kubectl -n model-lifecycle port-forward svc/feast 6566:6566 &
3 FEAST_URL=http://localhost:6566 uv run experiments/feast/online-
  serving-check.py
4 experiments/etl/data-landed-check.sh
5
6 # SK-F-04/KF-04: pencarian vektor Qdrant
7 k6 run experiments/load/vector-search-latency.js
8
9 # SK-F-11/KF-11: paritas dbt vs Flink
10 experiments/etl/data-landed-check.sh
11 experiments/parity/parity-check.sh
12
13 # SK-N-01/KNF-01: latensi p99 feast/vektor
14 k6 run experiments/load/feast-online-latency.js
15
16 # SK-N-02/KNF-02: throughput, consumer lag
17 k6 run experiments/load/feast-throughput.js
18 kafka-producer-perf-test --topic crypto.validated --num-records
  1000000 \
19 --record-size 256 --throughput -1 \
20 --producer-props bootstrap.servers="$KAFKA_BOOTSTRAP" \
21 --producer.config <sasl.properties>

```

Setiap perintah pada katalog ini berpasangan satu-satu dengan baris tabel skenario Tabel VI.1 sampai Tabel VI.4 serta baris status Tabel VI.5 sampai Tabel VI.8 pada Bab VI, sehingga klaim pemenuhan kebutuhan dapat dilacak langsung ke perintah yang menghasilkan buktinya. Untuk *use case* lain, cukup salin berkas `config.crypto.env` lalu sesuaikan blok DOMAIN-nya. Kode skenario tetap *domain-agnostic* dan tidak perlu diubah.